



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Approved by the examination committee on [26 Φεβρουαρίου 2026].

.....
Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

.....
Ουρανία Πετροπούλου
Επίκουρη Καθηγήτρια
ΗΜΜΥ Ε.Μ.Π.

.....
[Examiner 2 Name]
[Examiner 2 Title]

Αθήνα, Φεβρουάριος 2026

Μάριος Χρήστος Συρμακέζης

Διπλωματούχος Ηλεκτρολόγος Μηχανικός και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright © Μάριος Χρήστος Συρμακέζης, 2026.

All rights reserved.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η νόσος του Πάρκινσον (PD) είναι μια νευροεκφυλιστική διαταραχή που, πέρα από τα κινητικά συμπτώματα, επηρεάζει συχνά και την ομιλία. Η εργασία αυτή εξετάζει αν μπορούμε να εντοπίσουμε τη νόσο μέσω της φωνής, χρησιμοποιώντας κλασικές μεθόδους μηχανικής μάθησης.

Για τον σκοπό αυτό χρησιμοποιήθηκαν δύο διαφορετικά σύνολα δεδομένων ομιλίας, με την ίδια διαδικασία ανάλυσης και αξιολόγησης και στα δύο.

Το πρώτο σύνολο δεδομένων, Mobile Device Voice Recordings at King's College London, περιλάμβανε κατηγοριοποιημένα αρχεία ήχου (WAV) που είχαν καταγραφεί με ειδικό εξοπλισμό. Οι ηχογραφήσεις ήταν ακατέργαστες, γι' αυτό προχωρήσαμε στην εξαγωγή ακουστικών χαρακτηριστικών για να μετατρέψουμε τα δεδομένα σε μια αριθμητική μορφή που είναι κατάλληλη για ανάλυση.

Το δεύτερο σύνολο δεδομένων, με τίτλο PD speech signal features από το Kaggle (UCI), περιλάμβανε ακουστικά χαρακτηριστικά που είχαν ήδη εξαχθεί σε μορφή csv. Σε αυτή την περίπτωση, δεν χρειάστηκε να γίνει επεξεργασία ήχου αφού τα αριθμητικά χαρακτηριστικά ήταν ήδη διαθέσιμα. Και στα δύο σύνολα δεδομένων, ο σκοπός ήταν να διαπιστωθεί αν τα μοντέλα μπορούν να αναγνωρίσουν άτομα με Πάρκινσον μόνο από τη φωνή τους.

Αξιολογήθηκαν πέντε αλγόριθμοι: Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting και XGBoost. Επιπλέον, εξετάστηκε αν η αύξηση του αριθμού των χαρακτηριστικών βελτιώνει την απόδοση, καθώς και αν η χρήση βαρών κλάσης (class weighting) βοηθά στην εξισορρόπηση των ομάδων PD και HC.

Χρησιμοποιήθηκε επίσης διασταυρωμένη επικύρωση (cross-validation), ώστε να μην υπάρχει διαρροή δεδομένων.

Τα αποτελέσματα έδειξαν ότι ο Random Forest ήταν ο πιο αποτελεσματικός. Η αύξηση των χαρακτηριστικών βελτίωσε σημαντικά την απόδοση των περισσότερων μοντέλων. Η χρήση βαρών είχε μικρή θετική επίδραση κυρίως στον Random Forest και μικρή ή

αρνητική στους υπόλοιπους.

Συνολικά, η εργασία δείχνει ότι η ανάλυση φωνής σε συνδυασμό με μηχανική μάθηση μπορεί να βοηθήσει στην αναγνώριση της νόσου του Πάρκινσον. Ωστόσο, τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή, λόγω ορισμένων περιορισμών, όπως πιθανές πολλαπλές ηχογραφήσεις του ίδιου ασθενούς και η διαφορά μεγέθους μεταξύ των δύο datasets.

Παρά τους περιορισμούς, τα ευρήματα δείχνουν ότι η σωστή επεξεργασία δεδομένων και η κατάλληλη χρήση αλγορίθμων μπορούν να οδηγήσουν μελλοντικά σε πιθανή αναγνώριση της νόσου μέσω της φωνής, ακόμα και με απλά καθημερινά μικρόφωνα. Αυτό είναι σημαντικό, γιατί η έγκαιρη ανίχνευση θα μπορούσε να συμβάλει σε νωρίτερη θεραπεία και καλύτερη ποιότητα ζωής για τους ασθενείς.

Λέξεις Κλειδιά: Νόσος του Πάρκινσον, Δυσαρθρία, Φωνητικοί Βιοδείκτες, Ακουστικά Χαρακτηριστικά, Μηχανική Μάθηση, Εξαγωγή Χαρακτηριστικών, Διασταυρούμενη Επικύρωση, Μη Ισορροπημένα Δεδομένα, Αναπαραγωγιμότητα, Ταξινόμηση Ομιλίας, Υπολογιστική Νοημοσύνη στην Υγεία

Abstract

Parkinson's disease (PD) is a progressive neurological disorder characterized by motor symptoms which are typically accompanied by speech difficulties.

In this paper we assess if Parkinson's disease can be diagnosed through the voice based on classical machine learning approaches.

We worked with two different datasets, each analyzed using an identical methodology, i.e., analysis and validation procedure.

The first dataset, Mobile Device Voice Recordings at King's College London, contained categorized audio files (WAV) recorded with advanced recording equipment in a controlled environment.

These recordings were unprocessed, therefore we had to process the audio to extract the acoustic features to transform the data into a numeric format that would allow us to perform the analysis.

The second dataset, PD speech signal features from Kaggle (UCI), contained pre-extracted acoustic features in csv format.

Therefore, we did not need to process the audio since the pre-processed features were ready to be analyzed.

Both datasets were processed to see if the models could distinguish between individuals with PD and healthy controls (HC) only through their voice.

We compared five machine learning algorithms, i.e., Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting, and XGBoost.

Furthermore, we investigated whether increasing the number of features in the training set enhances the model performance, and whether the application of class weighting enhances the model performance particularly for the PD group.

To avoid data leakage, cross-validation was performed.

The results indicate that Random Forest algorithm outperformed all other tested algorithms.

An increase of the number of features in the training set positively affected the majority of the tested models.

Class weighting had a limited positive impact especially on Random Forest, while the other algorithms either did not benefit from class weighting or were even negatively affected.

In general, the study demonstrates that voice-based analysis combined with machine learning may support the diagnosis of Parkinson's disease.

Nevertheless, the results have to be viewed critically due to some limitations, e.g., potential multiple recordings of the same patient and the significant differences in terms of sample sizes between the two datasets.

Regardless of these limitations, the study shows that adequate processing of the data, along with the appropriate application of machine learning algorithms can result in a potential disease identification through voice, using regular microphones, available in everyday devices like smartphones.

Early detection may lead to the initiation of therapy at an earlier time point and improve the quality of life of patients.

Keywords: Parkinson's Disease; Dysarthria; Voice Biomarkers; Acoustic Features; Machine Learning; Feature Extraction; Cross-Validation; Imbalanced Data; Reproducibility; Speech Classification; Computational Health Intelligence

Πίνακας Περιεχομένων

Περίληψη	7
Abstract	10
Κατάλογος Σχημάτων	21
Κατάλογος Πινάκων	24
1 Εισαγωγή	25
1.1 Ιστορικό και κίνητρα	25
1.2 Διατύπωση του προβλήματος	26
1.3 Ερευνητικοί στόχοι	27
1.4 Συνεισφορές	28
1.5 Οργάνωση της εργασίας	28
1.6 Όρια πεδίου εφαρμογής	29
2 Βιβλιογραφική ανασκόπηση	31
2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας	31
2.2 Ανίχνευση έναντι παρακολούθησης	32
2.3 Ταξινόμηση ακουστικών χαρακτηριστικών	33
2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας	34
2.4 Σύνολα δεδομένων που χρησιμοποιούνται στην έρευνα για τη φωνή των ασθενών με Πάρκινσον	34
2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου	35
2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών	36
2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων	37
2.4.4 Ετερογένεια επικύρωσης	37
2.4.5 Ο ρόλος των εργασιών ομιλίας	37
2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD	38

2.5.1	Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις	39
2.6	Μεθοδολογικά ζητήματα στη βιβλιογραφία	39
2.6.1	Διαρροή δεδομένων	39
2.6.2	Ανισορροπία κλάσεων	40
2.6.3	Αναπαραγωγιμότητα	40
2.6.4	Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων	40
2.6.5	Ερμηνευσιμότητα	41
2.7	Έλλειμμα στην έρευνα	41
2.8	Περίληψη	42
3	Περιγραφή δεδομένων	43
3.1	Σύνολο δεδομένων A: MDVR-KCL	43
3.1.1	Πηγή και συλλογή	43
3.1.2	Προδιαγραφές ήχου	44
3.1.3	Εργασίες ομιλίας	44
3.1.4	Κατανομή τάξεων	44
3.1.5	Γνωστές ανωμαλίες	45
3.2	Σύνολο δεδομένων B: Χαρακτηριστικά ομιλίας PD	45
3.2.1	Πηγή	45
3.2.2	Πλαίσιο συλλογής	45
3.2.3	Μορφή δεδομένων	45
3.2.4	Κατανομή κλάσεων	46
3.2.5	Κατηγορίες χαρακτηριστικών	46
3.2.6	Μεθοδολογικές προειδοποιήσεις	46
3.3	Σύγκριση μεταξύ συνόλων δεδομένων	48
3.3.1	Βασικές διαφορές	48
4	Μεθοδολογία	49
4.1	Διαδικασία εξαγωγής χαρακτηριστικών	49
4.1.1	Αρχιτεκτονική διαδικασίας	49
4.1.2	Προεπεξεργασία ήχου	49
4.1.3	Προσωδιακά χαρακτηριστικά (21 χαρακτηριστικά)	50
4.1.4	Φασματικά χαρακτηριστικά	52
4.1.5	Συνολικός αριθμός χαρακτηριστικών	54
4.2	Σύγκριση συνόλου χαρακτηριστικών	55
4.2.1	Λόγοι για τα εκτεταμένα χαρακτηριστικά	55
4.2.2	Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών	55
4.3	Μοντέλα μηχανικής μάθησης	56

4.3.1	Προδιαγραφές μοντέλου	56
4.3.2	Στάθμιση βαρύτητας κλάσης	58
4.4	Αρχιτεκτονική ML Pipeline	59
4.4.1	Δομή Pipeline	59
4.4.2	Τυποποίηση χαρακτηριστικών	59
4.5	Πλαίσιο αξιολόγησης	59
4.5.1	Στρατηγική Cross-Validation	59
4.5.2	Μετρήσεις αξιολόγησης	60
5	Σχεδιασμός πειράματος	62
5.1	Ερευνητικά ερωτήματα	62
5.2	Πειραματικός πίνακας	62
5.2.1	$2 \times 2 \times 5$ Παραγοντικός σχεδιασμός	62
5.2.2	Συνολικές πειραματικές εκτελέσεις	63
5.3	Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα	63
6	Αποτελέσματα	64
6.1	Σύνοψη των καλύτερων αποτελεσμάτων	64
6.1.1	Σύνολο δεδομένων A (MDVR-KCL) — Καλύτερη απόδοση	64
6.1.2	Σύνολο δεδομένων B (Σύγκριση αναφοράς)	64
6.2	Συνθήκη 1: Βασικά χαρακτηριστικά + χωρίς στάθμιση	66
6.2.1	Εργασία: ReadText	66
6.2.2	Εργασία: Αυθόρμητος διάλογος	66
6.3	Συνθήκη 2: Εκτεταμένα χαρακτηριστικά + Χωρίς στάθμιση	66
6.3.1	Εργασία: ReadText	67
6.3.2	Εργασία: Αυθόρμητος διάλογος	68
6.4	Ανάλυση αφαίρεσης χαρακτηριστικών	69
6.4.1	Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (Read-Text)	69
6.4.2	Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (αυθόρμητη)	69
6.5	Ανάλυση στάθμισης κλάσεων	69
6.5.1	Εργασία ReadText — Βασικά χαρακτηριστικά	70
6.5.2	Εκτεταμένα χαρακτηριστικά — Όλες οι εργασίες	70
6.6	Συμβιβασμοί ακρίβειας-ανάκλησης	70
6.6.1	Random Forest (εκτεταμένα χαρακτηριστικά)	70
6.7	Ανάλυση πίνακα σύγχυσης	71
6.7.1	Σύνολο δεδομένων A — ReadText	71
6.7.2	Σύνολο δεδομένων A — Αυθόρμητος διάλογος	72

6.7.3	Σύνολο δεδομένων B	72
7	Συζήτηση	73
7.1	Ερμηνεία βασικών ευρημάτων	73
7.1.1	Επίδραση της επέκτασης χαρακτηριστικών	73
7.1.2	Επιδράσεις στάθμισης κλάσης	74
7.1.3	Ιεραρχία απόδοσης μοντέλου	75
7.1.4	Υψηλή διακύμανση μεταξύ πτυχών	75
7.2	Σύγκριση με τη βιβλιογραφία	76
7.2.1	Πλαίσιο απόδοσης	76
7.2.2	Μεθοδολογική σύγκριση	77
7.3	Ανάλυση σημασίας χαρακτηριστικών	77
7.3.1	Χαρακτηριστικά με τη μεγαλύτερη διακριτική ικανότητα (σύνολο δεδομένων A)	77
7.3.2	Πολυπλοκότητα χαρακτηριστικών του συνόλου δεδομένων B	78
7.4	Μοτίβα απόδοσης που εξαρτώνται από την εργασία	79
7.4.1	ReadText έναντι αυθόρμητου διαλόγου	79
8	Περιορισμοί και απειλές για την εγκυρότητα	80
8.1	Περιορισμοί μεγέθους δείγματος	80
8.1.1	Σύνολο δεδομένων A: Μικρός αριθμός συμμετεχόντων	80
8.2	Περιορισμοί αναγνωριστικών υποκειμένων	81
8.2.1	Σύνολο δεδομένων B: Ελλείπουσες ταυτότητες υποκειμένων	81
8.2.2	Περιορισμοί σύγκρισης	81
8.3	Περιορισμοί εξαγωγής χαρακτηριστικών	81
8.3.1	Δετερμινιστικό σύνολο χαρακτηριστικών	81
8.3.2	Υποθέσεις ποιότητας ήχου	82
8.4	Περιορισμοί μοντέλου	82
8.4.1	Χωρίς ρύθμιση υπερπαραμέτρων	82
8.5	Μεθοδολογικοί περιορισμοί	83
8.5.1	Χωρίς εξωτερική επικύρωση	83
8.5.2	Χειρισμός ανισορροπίας κλάσεων	83
8.6	Απειλές για την εγκυρότητα	84
8.6.1	Εσωτερική εγκυρότητα	84
8.6.2	Εξωτερική εγκυρότητα	84
9	Συμπέρασμα	85
9.1	Περίληψη της εργασίας	85

9.1.1	Συνεισφορές	85
9.2	Βασικά ευρήματα	86
9.2.1	Πρωταρχικά αποτελέσματα	86
9.3	Απαντηθέντα ερευνητικά ερωτήματα	86
9.3.1	RQ1: Πώς αποδίδουν τα κλασικά μοντέλα ML στην ταξινόμηση φωνής PD;	86
9.3.2	RQ2: Η επέκταση του συνόλου χαρακτηριστικών βελτιώνει την απόδοση της ταξινόμησης;	87
9.3.3	RQ3: Βελτιώνει η στάθμιση των κλάσεων την απόδοση σε μη ισορροπημένα σύνολα δεδομένων;	87
9.3.4	RQ4: Πώς συγκρίνονται τα αποτελέσματα μεταξύ της ομαδοποιημένης και της τυπικής CV;	88
9.3.5	RQ5: Οι εργασίες ομιλίας αποδίδουν διαφορετική απόδοση ταξινόμησης;	88
9.4	Επιπτώσεις	89
9.4.1	Για ερευνητές	89
9.4.2	Για τους επαγγελματίες	89
9.4.3	Για τους δημιουργούς συνόλων δεδομένων	89
9.5	Μελλοντικές κατευθύνσεις	90
9.6	Τελικές παρατηρήσεις	90
A	Feature Importance Tables	91
A.1	Overview	91
A.2	Dataset A — ReadText Task	91
A.2.1	Random Forest — Top 20 Features	91
A.2.2	Logistic Regression — Top 20 Features	92
A.2.3	Gradient Boosting — Top 10 Features	93
A.2.4	XGBoost — Top 10 Features	94
A.3	Dataset A — SpontaneousDialogue Task	95
A.3.1	Random Forest — Top 20 Features	95
A.3.2	Logistic Regression — Top 10 Features	95
A.3.3	Gradient Boosting — Top 10 Features	96
A.3.4	XGBoost — Top 10 Features	97
A.4	Dataset B — PD Speech Features	98
A.4.1	Random Forest — Top 10 Features	99
A.4.2	Logistic Regression — Top 10 Features	99
A.4.3	Gradient Boosting — Top 10 Features	100
A.4.4	XGBoost — Top 10 Features	101
A.5	Cross-Task Feature Stability	101

A.6	Feature Category Analysis	102
B	Detailed Results Tables	104
B.1	Overview	104
B.2	Condition 1: Baseline Features (47) + Unweighted	104
B.2.1	Dataset A: MDVR-KCL Summary	104
B.2.2	Dataset B: PD Speech Features Summary	105
B.3	Condition 2: Extended Features (78) + Unweighted	105
B.3.1	Dataset A: MDVR-KCL Summary	105
B.3.2	Improvement over Baseline (Random Forest, Dataset A)	105
B.4	Condition 3: Baseline Features (47) + Weighted	106
B.4.1	Dataset A: MDVR-KCL Summary	106
B.4.2	Effect of Weighting (vs Condition 1, Random Forest)	106
B.5	Condition 4: Extended Features (78) + Weighted	106
B.5.1	Dataset A: MDVR-KCL Summary	106
B.5.2	Effect of Weighting (vs Condition 2, Random Forest)	107
B.6	Cross-Condition Comparison Matrix	107
B.6.1	Random Forest ROC-AUC by Task	107
B.6.2	Random Forest Accuracy by Task	107
B.6.3	Key Observations	108
B.7	Statistical Significance Notes	108
B.8	ROC Curves	108
C	Research Demonstration Application	112
C.1	Purpose and Scope	112
C.2	System Architecture	113
C.3	User Interaction Flow	114
C.3.1	Audio Upload Workflow	114
C.3.2	Direct Audio Recording	115
C.3.3	Processing Steps	115
C.4	Output Interpretation and Limitations	116
C.4.1	Displayed Information	116
C.4.2	Critical Limitations (What the Output Does NOT Mean)	117
C.5	Reproducibility and Consistency	117
C.6	Summary	118

Κατάλογος Σχημάτων

4.1	Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.	49
6.1	Σημαντικότητα χαρακτηριστικών τυχαίου δάσους (σύνολο δεδομένων B). Τα κορυφαία χαρακτηριστικά κυριαρχούνται από προηγμένες μετρήσεις επεξεργασίας σήματος που συχνά δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.	65
6.2	Σημασία χαρακτηριστικών τυχαίου δάσους για την εργασία ReadText (εκτεταμένα χαρακτηριστικά). Οι στατιστικές της θεμελιώδους συχνότητας (F_0) φαίνονται ιδιαίτερα προγνωστικές.	67
6.3	Σημασία χαρακτηριστικών τυχαίου δάσους για την εργασία αυθόρμητου διαλόγου (εκτεταμένα χαρακτηριστικά). Τα χαρακτηριστικά MFCC παρουσιάζουν αυξημένη σημασία σε σύγκριση με το ReadText.	68
6.4	Συγκεντρωτικοί πίνακες σύγχυσης για την εργασία ReadText (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 37$ υποκείμενα). Κάθε κελί αναφέρει τον συνολικό αριθμό εκτός πτυχής και το ποσοστό του σε όλες τις προβλέψεις. Αυτά τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή, δεδομένου του μικρού μεγέθους του δείγματος.	71
6.5	Συγκεντρωτικοί πίνακες σύγχυσης για την εργασία αυθόρμητου διαλόγου (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 36$ υποκείμενα). Αυτή η εργασία απέδωσε το υψηλότερο συνολικό ROC-AUC στη μελέτη ($0,857 \pm 0,171$, Random Forest).	72
6.6	Συγκεντρωτικοί πίνακες σύγχυσης για το σύνολο δεδομένων B (στρωματοποιημένη 5-Fold CV, $n = 756$ εγγραφές). Το σημαντικά μεγαλύτερο μέγεθος του δείγματος αποδίδει καλά διαχωρισμένα μοτίβα σύγχυσης με χαμηλή διακύμανση. Τα αποτελέσματα μπορεί να είναι αισιόδοξα λόγω της άγνωστης επικάλυψης των θεμάτων μεταξύ των πτυχών.	72
A.1	Logistic Regression coefficient magnitudes (ReadText)	92

A.2	Gradient Boosting feature importances (ReadText). F0 max dominates strongly (0.229 ± 0.179), consistent with pitch dysregulation in PD.	93
A.3	XGBoost feature importances (ReadText). Importance is more distributed than Gradient Boosting, with F0 and intensity features sharing dominance. . .	94
A.4	Logistic Regression coefficient magnitudes (Spontaneous Dialogue)	96
A.5	Gradient Boosting feature importances (Spontaneous Dialogue). MFCC-5 (0.342 ± 0.204) strongly dominates, reflecting spectral tilt changes in spontaneous PD speech.	97
A.6	XGBoost feature importances (Spontaneous Dialogue). MFCC-5 and shimmer features dominate, consistent with RF and GB findings for this task. . . .	98
A.7	Feature importance for Dataset B (PD Speech Features) — Random Forest and Logistic Regression.	100
A.8	Feature importance for Dataset B — Gradient Boosting and XGBoost. TQWT energy/entropy features from high-frequency bands dominate across both models.	101
A.9	Feature importance aggregated by broad acoustic categories.	103
B.1	ROC curves for all five classifiers on the ReadText task (Dataset A, extended features). Shaded bands indicate ± 1 standard deviation across the five cross-validation folds.	109
B.2	ROC curves for all five classifiers on the SpontaneousDialogue task (Dataset A, extended features).	110
B.3	ROC curves for all five classifiers on Dataset B (PD Speech Features). Note that subject-level deduplication is not possible for this dataset; results may be optimistic due to potential subject overlap across folds.	111
C.1	Upload interface for audio file analysis. Users select a ReadText task recording in any common format (WAV, MP3, WebM). The interface displays the current model configuration (RandomForest, baseline features, 37 training samples).	114
C.2	In-browser audio recording interface. Users read the displayed ReadText prompt aloud and record directly via their device microphone. The recorded audio is processed through the same normalization and feature extraction pipeline as uploaded files.	115
C.3	Example output from the research demonstration interface. The prediction (“PD” with 81% confidence) is displayed prominently with an explicit disclaimer that this is not a medical diagnosis. The interface shows extracted acoustic features, analysis metadata (file name, model, task, feature count), and top global feature importances for interpretability.	116

Κατάλογος Πινάκων

1.1	Περίληψη των κεφαλαίων της εργασίας	29
2.1	Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD	33
3.1	Πλαίσιο συλλογής δεδομένων MDVR-KCL	43
3.2	Προδιαγραφές ήχου για το σύνολο δεδομένων A	44
3.3	Εργασίες ομιλίας στο σύνολο δεδομένων MDVR-KCL	44
3.4	Πλαίσιο συλλογής για το σύνολο δεδομένων B	45
3.5	Κατανομή κλάσεων στο σύνολο δεδομένων B	46
3.6	Κατηγορίες χαρακτηριστικών στο σύνολο δεδομένων B (752 συνολικά)	46
3.7	Λεπτομερής σύγκριση μεταξύ συνόλων δεδομένων	48
4.1	Ανάλυση προσωδιακών χαρακτηριστικών	52
4.2	Βασικά φασματικά χαρακτηριστικά	53
4.3	Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)	54
4.4	Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση	54
4.5	Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.	56
4.6	Στρατηγικές διασταυρούμενης επικύρωσης	60
4.7	Μετρήσεις αξιολόγησης	61
5.1	Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.	63
5.2	Συνολικός αριθμός πειραμάτων	63
6.1	Καλύτερη απόδοση στο σύνολο δεδομένων A	64
6.2	Απόδοση του συνόλου δεδομένων B χρησιμοποιώντας τη βασική (μη σταθμισμένη) διαμόρφωση. Σημειώστε τη σημαντικά χαμηλότερη διακύμανση σε σύγκριση με το σύνολο δεδομένων A.	65

6.3	Συνθήκη 1 — Αποτελέσματα ReadText	66
6.4	Συνθήκη 1 — Αποτελέσματα αυθόρμητου διαλόγου	66
6.5	Συνθήκη 2 — Αποτελέσματα ReadText	67
6.6	Συνθήκη 2 — Αποτελέσματα αυθόρμητου διαλόγου	68
6.7	Αφαίρεση χαρακτηριστικών — ReadText	69
6.8	Αφαίρεση χαρακτηριστικών — Αυθόρμητος διάλογος	69
6.9	Επίδραση της στάθμισης κλάσης στο ReadText (βασικά χαρακτηριστικά). Το Random Forest έδειξε μέτρια βελτίωση.	70
6.10	Προφίλ ακρίβειας-ανάκλησης τυχαίου δάσους. Η διαμόρφωση ReadText ευνοεί την ακρίβεια (λιγότερα ψευδώς θετικά αποτελέσματα).	70
7.1	Επίδραση της επέκτασης χαρακτηριστικών ανά εργασία. Το ReadText παρουσίασε δραματικά μεγαλύτερες βελτιώσεις, υποδηλώνοντας ότι τα βασικά χαρακτηριστικά ήταν ανεπαρκή για δομημένη ομιλία.	73
7.2	Συνεισφορές εκτεταμένων χαρακτηριστικών	74
7.3	Επιδράσεις στάθμισης κλάσης	74
7.4	Σύγκριση διακύμανσης: μικρά έναντι μεγάλων συνόλων δεδομένων. Οι τυπικές αποκλίσεις κλιμακώνονται περίπου ως $1/\sqrt{n}$	75
7.5	Σύγκριση με τη βιβλιογραφία	76
7.6	Μεθοδολογική σύγκριση. Η παρούσα εργασία δίνει προτεραιότητα στην αναπαραγωγικότητα και στις συντηρητικές εκτιμήσεις γενίκευσης.	77
7.7	Τα 5 κορυφαία χαρακτηριστικά του Random Forest ανά εργασία (Εκτεταμένο σύνολο χαρακτηριστικών). Οι τιμές σημασίας αντιπροσωπεύουν τη μέση μείωση της ακαθαρσίας.	78
7.8	Κορυφαία 5 χαρακτηριστικά του συνόλου δεδομένων B (Random For- est). Αυτές οι προηγμένες μετρήσεις επεξεργασίας σήματος δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.	78
7.9	Σύγκριση εργασιών μεταξύ διαμορφώσεων. Ο αυθόρμητος διάλογος γενικά υπερτερεί του ReadText, εκτός από το SVM σε εκτεταμένες λειτουργίες.	79
8.1	Μετρήσεις μεγέθους δείγματος συνόλου δεδομένων A	80
8.2	Σταθερές υπερπαράμετροι (όλα τα πειράματα)	82
8.3	Απειλές εσωτερικής εγκυρότητας	84
8.4	Απειλές εξωτερικής εγκυρότητας	84
9.1	Κύρια ευρήματα της έρευνας (σύνολο δεδομένων A, στάθμιση βασικής κατηγορίας)	86
A.1	Random Forest feature importance — ReadText (top 10)	91

A.2	Logistic Regression feature importance — ReadText (top 10)	92
A.3	Gradient Boosting feature importance — ReadText (top 10)	93
A.4	XGBoost feature importance — ReadText (top 10)	94
A.5	Random Forest feature importance — SpontaneousDialogue (top 10)	95
A.6	Logistic Regression feature importance — SpontaneousDialogue (top 10)	95
A.7	Gradient Boosting feature importance — SpontaneousDialogue (top 10)	96
A.8	XGBoost feature importance — SpontaneousDialogue (top 10)	97
A.9	Random Forest feature importance — Dataset B (top 10)	99
A.10	Logistic Regression feature importance — Dataset B (top 10)	99
A.11	Gradient Boosting feature importance — Dataset B (top 10)	100
A.12	XGBoost feature importance — Dataset B (top 10)	101
A.13	Cross-task feature stability (Random Forest top-10)	102
A.14	Aggregated feature importance by category	102
B.1	Condition 1 results by task (Dataset A, baseline features, unweighted)	104
B.2	Condition 1 results (Dataset B, baseline features, unweighted)	105
B.3	Condition 2 results by task (Dataset A, extended features, unweighted)	105
B.4	Condition 2 improvement over Condition 1 (Random Forest)	105
B.5	Condition 3 results by task (Dataset A, baseline features, weighted)	106
B.6	Condition 3 effect of weighting vs Condition 1 (RF)	106
B.7	Condition 4 results by task (Dataset A, extended features, weighted)	106
B.8	Condition 4 effect of weighting vs Condition 2 (RF)	107
B.9	Random Forest ROC-AUC comparison matrix (Dataset A)	107
B.10	Random Forest Accuracy comparison matrix (Dataset A)	107

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορικό και κίνητρα

Η νόσος του Πάρκινσον είναι η δεύτερη πιο συχνή νευρολογική ασθένεια που σχετίζεται με εκφύλιση των νευρών. Επηρεάζει περίπου 1 στους 100 ανθρώπους άνω των 60 ετών [1]. Σήμερα, μία από τις μεγαλύτερες προκλήσεις που αντιμετωπίζονται στο κλινικό περιβάλλον είναι η έγκαιρη και σωστή διάγνωση, επειδή τα εμφανή συμπτώματα συνήθως παρουσιάζονται όταν έχει ήδη χαθεί σημαντικός αριθμός νευρώνων. Οι ασθενείς με Πάρκινσον συχνά εμφανίζουν αλλαγές στην ομιλία, λόγω επιδράσεων στον λάρυγγα και στους αναπνευστικούς μύες. Οι αλλαγές αυτές μπορεί να εμφανιστούν αρκετά χρόνια πριν από τα τυπικά κινητικά συμπτώματα (έως και 7 χρόνια νωρίτερα). [2].

Οι δείκτες που βασίζονται στη φωνή αποτελούν έναν απλό, οικονομικό και μη επεμβατικό τρόπο για την ανίχνευση της νόσου [3, 4]. Καθώς η νόσος του Πάρκινσον βλάπτει τον λάρυγγα και τους αναπνευστικούς μύες, αυτό προκαλεί ανιχνεύσιμες αλλαγές στις προσωδικές πτυχές της ομιλίας ενός ατόμου (δηλ. τον τόνο, την ένταση, τον ρυθμό της ομιλίας) καθώς και σε χαρακτηριστικά του ακουστικού σήματος, όπως η δομή και οι συχνότητες της φωνής.

Η ομιλία των ατόμων με PD ονομάζεται *υποκινητική δυσαρθρία* (HKD) και χαρακτηρίζεται από:

- (α) *υποφωνία*, (μειωμένη ένταση φωνής),
- (β) *μονοτονικότητα*, (περιορισμένο εύρος τόνων) και
- (γ) *μονοφωνία*, (μια ομοιόμορφη ένταση της φωνής κατά την ομιλία) [5].

Μπορεί επίσης να υπάρχει ασαφής άρθρωση, δηλαδή οι λέξεις να μην ακούγονται καθαρά, καθώς και αλλαγές στην ποιότητα της φωνής, όπως βραχνάδα.

Η φωνή μπορεί να καταγραφεί με απλά μικρόφωνα, ακόμη και με smartphone, γεγονός που ενισχύει τη χρήση της ανάλυσης φωνής για την αναγνώριση και την παρακολούθηση της νόσου. Ορισμένες φωνητικές ανωμαλίες μπορεί να είναι ανιχνεύσιμες πριν εμφανιστούν τα κλασικά συμπτώματα, επομένως η φωνή μπορεί να λειτουργήσει ως πρώιμος δείκτης.

Τα τελευταία χρόνια, η έρευνα έχει περάσει από ηχογραφήσεις σε ειδικά εργαστήρια με πολύπλοκο εξοπλισμό σε ηχογραφήσεις με απλά μέσα, όπως το μικρόφωνο ενός smartphone. Αυτή η αλλαγή δημιουργεί νέες δυσκολίες, κυρίως στο κατά πόσο τα αποτελέσματα μπορούν να ισχύουν σε διαφορετικές συνθήκες και συσκευές που απουσίαζαν από παλιές μελέτες [6].

Οι δείκτες φωνής χρησιμοποιούνται για δύο βασικούς σκοπούς:

- (α) για τον έλεγχο και την ανίχνευση της νόσου, που αποτελεί τον κύριο ερευνητικό στόχο περίπου του 94% των μελετών που έχουν διεξαχθεί μέχρι σήμερα, και
- (β) για την παρακολούθηση της πορείας της και της ανταπόκρισης στη θεραπεία [7].

Όμως, τα διαχρονικά στοιχεία για τον στόχο (β) παραμένουν σπάνια και τα περισσότερα ακουστικά χαρακτηριστικά έχουν επικυρωθεί μερικώς και κυρίως διατομεακά [8].

1.2 Διατύπωση του προβλήματος

Παρόλο που έχουν γίνει σημαντικές προσπάθειες για την ανάπτυξη μεθόδων που χρησιμοποιούν τη φωνή για την ανίχνευση της νόσου του Πάρκινσον, εξακολουθούν να υπάρχουν αρκετές προκλήσεις:

1. **Μικρά μεγέθη δειγμάτων** Όταν τα διαθέσιμα ηχητικά δεδομένα είναι λίγα, είναι δύσκολο να δημιουργηθούν μοντέλα που να λειτουργούν σωστά και σε νέους πληθυσμούς.
2. **Διαρροή ταυτότητας υποκειμένου (subject leakage)** Συμβαίνει όταν ηχογραφήσεις του ίδιου ατόμου χρησιμοποιούνται και για εκπαίδευση και για έλεγχο του μοντέλου. Αυτό μπορεί να οδηγήσει σε υπερβολικά καλά αλλά μη ρεαλιστικά αποτελέσματα.
3. **Ανισορροπία κλάσεων** Συνήθως δεν υπάρχει ίδιος αριθμός δειγμάτων από

άτομα με Πάρκινσον (PD) και από υγιή άτομα (HC), κάτι που μπορεί να επηρεάσει την απόδοση του μοντέλου.

4. **Επιλογή χαρακτηριστικών** Ο τρόπος με τον οποίο αναπαρίσταται η φωνή (ποια χαρακτηριστικά επιλέγονται) μπορεί να επηρεάσει σημαντικά το πόσο καλά λειτουργεί το μοντέλο ταξινόμησης.
5. **Διαφορετικές μέθοδοι επικύρωσης** Οι μελέτες χρησιμοποιούν διαφορετικούς τρόπους για να αξιολογήσουν τα μοντέλα (π.χ. k-fold, σταθερός διαχωρισμός εκπαίδευσης/δοκιμής, leave-one-subject-out, εξωτερική επικύρωση). Αυτές οι μέθοδοι δίνουν διαφορετικές εκτιμήσεις απόδοσης, κάτι που δυσκολεύει τη σύγκριση των αποτελεσμάτων μεταξύ μελετών. Παρ' όλα αυτά, λίγες μελέτες χρησιμοποιούν εξωτερική επικύρωση [6].
6. **Χάσμα γενίκευσης μεταξύ συνόλων δεδομένων:** Ένα μοντέλο μπορεί να έχει πολύ υψηλή ακρίβεια στο αρχικό σύνολο δεδομένων, αλλά η απόδοσή του συχνά μειώνεται όταν δοκιμαστεί σε νέα, διαφορετικά δεδομένα. Αυτό μπορεί να οδηγήσει σε υπερβολικούς ισχυρισμούς για την πραγματική του απόδοση [6].

Όλες αυτές οι προκλήσεις εξετάζονται σε αυτή τη εργασία εργασία με έναν προσεκτικό πειραματικό σχεδιασμό, που δίνει έμφαση στη σωστή μεθοδολογία και όχι απλώς στην επίτευξη υψηλών ποσοστών απόδοσης.

1.3 Ερευνητικοί στόχοι

Οι κύριοι στόχοι αυτής της εργασίας είναι:

1. Να **παρέχει μια αναπαραγώγιμη διαδικασία** για την εξαγωγή ακουστικών χαρακτηριστικών από ηχογραφήσεις φωνής.
2. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost) για την ταξινόμηση PD έναντι HC.
3. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης σε δύο ξεχωριστά σύνολα δεδομένων, τα οποία έχουν διαφορετικά χαρακτηριστικά.
4. Να **αξιολογήσει την επίδραση** της αύξησης των χαρακτηριστικών (από 47 σε 78) με ελεγχόμενο τρόπο.
5. Να **αξιολογήσει την επίδραση** της χρήσης βαρών κλάσης (class-weighting) ώστε να αντιμετωπιστεί η ανισορροπία μεταξύ των ομάδων.

1.4 Συνεισφορές

Η παρούσα εργασία συμβάλλει στη μελέτη των φωνητικών βιοδεικτών της νόσου του Πάρκινσον με τους εξής τρόπους:

- **Αξιολόγηση χωρίς διαρροή ταυτότητας:** Χρησιμοποιήθηκε cross-validation ανά υποκείμενο, έτσι ώστε όλες οι ηχογραφήσεις του ίδιου ατόμου να βρίσκονται είτε στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής. Με αυτόν τον τρόπο αποφεύγεται η «διαρροή δεδομένων», δηλαδή το να μαθαίνει το μοντέλο από το ίδιο άτομο που αργότερα καλείται να προβλέψει.
- **Έλεγχος της αύξησης των χαρακτηριστικών:** Μελετήθηκε τι συμβαίνει όταν τα χαρακτηριστικά αυξάνονται από 47 σε 78. Η αύξηση αυτή βελτίωσε την απόδοση έως και 23% (ROC-AUC). Παράλληλα, εξετάστηκε ποια από τα νέα χαρακτηριστικά συνέβαλαν περισσότερο στη βελτίωση.
- **Σύγκριση αυθόρμητης και δομημένης ομιλίας:** Βρέθηκε ότι τα μοντέλα αποδίδουν καλύτερα όταν χρησιμοποιείται αυθόρμητη ομιλία σε σχέση με δομημένη ανάγνωση. Για παράδειγμα, το Random Forest είχε καλύτερη απόδοση στην αυθόρμητη ομιλία, γεγονός που δείχνει ότι τέτοιου τύπου δεδομένα ίσως αποτυπώνουν καλύτερα τις αλλαγές που σχετίζονται με τη νόσο.
- **Σύγκριση δύο διαφορετικών datasets:** Τα αποτελέσματα από ένα αυστηρά ελεγχόμενο dataset συγκρίθηκαν με ένα δημόσιο dataset με προ-εξαγμένα χαρακτηριστικά. Στο δημόσιο dataset, η απλή διασταυρούμενη επικύρωση έδωσε πολύ υψηλές τιμές απόδοσης (π.χ. AUC $\sim 0,94$), που πιθανόν δεν είναι ρεαλιστικές. Αυτό δείχνει πόσο σημαντική είναι η σωστή μεθοδολογία αξιολόγησης.
- **Ερμηνεία των χαρακτηριστικών:** Πέρα από τη μέτρηση της απόδοσης, έγινε και ανάλυση της σημασίας των χαρακτηριστικών, ώστε να είναι πιο κατανοητό ποια στοιχεία της φωνής συμβάλλουν περισσότερο στην ανίχνευση της νόσου. Αυτό ενισχύει τη διαφάνεια και τη χρησιμότητα των αποτελεσμάτων.

1.5 Οργάνωση της εργασίας

Τα υπόλοιπα κεφάλαια αυτής της εργασίας ακολουθούν το οργανωτικό σχήμα που παρέχεται παρακάτω:

Table 1.1: Περίληψη των κεφαλαίων της εργασίας

Κεφάλαιο	Τίτλος	Περιγραφή
2	Βιβλιογραφική ανασκόπηση	Επισκόπηση των μεθοδολογιών ανίχνευσης PD με βάση τη φωνή
3	Περιγραφή δεδομένων	Λεπτομερείς περιγραφές των συνόλων δεδομένων που χρησιμοποιήθηκαν σε αυτή τη εργασία
4	Μεθοδολογία	Διαδικασία εξαγωγής ακουστικών χαρακτηριστικών και κατασκευής μοντέλου μηχανικής μάθησης
5	Πειραματικός σχεδιασμός	Πρωτόκολλο για την αξιολόγηση των επιδράσεων κάθε μεταβλητής
6	Αποτελέσματα	Ποσοτικά αποτελέσματα για κάθε μία από τις συνθήκες
7	Συζήτηση	Επεξήγηση των αποτελεσμάτων και σύγκριση με προηγούμενες εργασίες
8	Περιορισμοί	Περιορισμοί και περιορισμοί της μελέτης
9	Συμπέρασμα	Περίληψη των κύριων ευρημάτων και πιθανών μελλοντικών τομέων έρευνας

1.6 Όρια πεδίου εφαρμογής

Η μελέτη έχει τα ακόλουθα όρια πεδίου εφαρμογής:

- **Μόνο δυαδική ταξινόμηση:** Η εργασία εξετάζει μόνο αν ένα άτομο έχει Πάρκινσον ή όχι (PD vs HC). Δεν μελετά πόσο σοβαρή είναι η νόσος, πώς εξελίσσεται με τον χρόνο ή πώς ξεχωρίζει από άλλες ασθένειες.
- **Μόνο κλασικά μοντέλα μηχανικής μάθησης:** Χρησιμοποιούνται μόνο κλασικά και πιο εύκολα ερμηνεύσιμα μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost). Δεν χρησιμοποιούνται νευρωνικά δίκτυα ή βαθιά μάθηση, κυρίως λόγω του μικρού μεγέθους των δεδομένων και της έμφασης στην κατανόηση των αποτελεσμάτων. Η εργασία προσφέρει έτσι μια καθαρή και αξιόπιστη βάση για μελλοντικές πιο σύνθετες μεθόδους.
- **Ερευνητικός χαρακτήρας:** Τα μοντέλα που παρουσιάζονται έχουν ερευνητικό σκοπό. Δεν προορίζονται να χρησιμοποιηθούν άμεσα από γιατρούς για διάγνωση χωρίς επιπλέον έλεγχο και επιβεβαίωση.
- **Έμφαση στην αναπαραγωγιμότητα:** Δόθηκε προτεραιότητα στο να μπορούν τα πειράματα να επαναληφθούν από άλλους ερευνητές. Για αυτό χρησιμοποιήθηκαν σταθερές ρυθμίσεις, σαφής περιγραφή των βημάτων και

σωστή τεκμηρίωση του κώδικα. Η αξιοπιστία των αποτελεσμάτων θεωρήθηκε πιο σημαντική από το να επιτευχθούν απλώς υψηλότερα ποσοστά απόδοσης.

Κεφάλαιο 2

Βιβλιογραφική ανασκόπηση

2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας

Η νόσος του Πάρκινσον είναι γνωστή κυρίως για τα κινητικά της συμπτώματα (τρέμουλο, ακαμψία, βραδυκινησία), αλλά παράλληλα με αυτά, η νόσος επηρεάζει σχεδόν πάντα και την ομιλία και τη φωνή. Περίπου το 70–90% των ατόμων με νόσο του Πάρκινσον αναπτύσσουν μετρήσιμες διαταραχές της ομιλίας και της φωνής κατά τη διάρκεια της νόσου [1]. Αυτή η συλλογή συμπτωμάτων της ομιλίας στη νόσο του Πάρκινσον περιγράφεται συχνά ως *υποκινητική δυσαρθρία*, υποδηλώνοντας ένα χαρακτηριστικό μοτίβο διαταραχής του κινητικού ελέγχου της ομιλίας που σχετίζεται με τη νόσο [5].

Η ομιλία στην PD χαρακτηρίζεται από *υποφωνία* (μειωμένη ένταση), *μονοτονία* και *μονοφωνία* (μειωμένη προσωδιακή μεταβλητότητα), ασαφή άρθρωση και φωνή με αναπνοή ή βραχνάδα που προκύπτει από ατελές κλείσιμο των φωνητικών χορδών [5, 9].

Αυτές οι αλλαγές στην ομιλία στην PD παρουσιάζουν ενδιαφέρον όχι μόνο ως συμπτώματα που επηρεάζουν την ικανότητα επικοινωνίας ενός ατόμου, αλλά και ως πιθανοί μη επεμβατικοί βιοδείκτες της νόσου. Η φωνή είναι σχετικά εύκολο να καταγραφεί (για παράδειγμα, μέσω μιας σύντομης ηχογράφησης σε ένα smartphone) και οι φωνητικές αλλαγές μπορεί να εμφανιστούν νωρίς στην πορεία της νόσου. Ορισμένες έρευνες υποδηλώνουν ότι οι λεπτές ανωμαλίες της φωνής μπορούν να ανιχνευθούν πριν από την εμφάνιση των κλασικών κινητικών συμπτωμάτων σε ορισμένους ασθενείς [2]. Δεδομένου ότι η ηχογράφηση και η ανάλυση της φωνής μπορούν να πραγματοποιηθούν με χαμηλό κόστος και εξ αποστάσεως, υπάρχει σημαντική κινητοποίηση για τη χρήση της ομιλίας ως μέσου ανίχνευσης ή

παρακολούθησης της νόσου του Πάρκινσον χωρίς την ανάγκη επεμβατικών εξετάσεων. Οι μετρήσεις της ομιλίας και της φωνής είναι κατάλληλες για εφαρμογές τηλεϊατρικής και για τη διαχρονική παρακολούθηση της εξέλιξης της νόσου του Πάρκινσον [4]. Σε αντίθεση με πολλές κλινικές αξιολογήσεις που απαιτούν προσωπικές επισκέψεις και εξειδικευμένο εξοπλισμό, οι ηχογραφήσεις φωνής μπορούν να ληφθούν από τους ασθενείς στο σπίτι τους και να αναλυθούν με αλγόριθμους, επιτρέποντας πιο συχνή και χαμηλότερου κόστους παρακολούθηση.

2.2 Ανίχνευση έναντι παρακολούθησης

Η έρευνα για την PD με βάση τη φωνή αντιμετωπίζει δύο σχετικούς αλλά διακριτούς στόχους: **ανίχνευση/διαλογή** (δυαδική ταξινόμηση της PD έναντι της HC) και **παρακολούθηση/εξέλιξη** (παρακολούθηση της σοβαρότητας της νόσου ή της ανταπόκρισης στη θεραπεία με την πάροδο του χρόνου). Μια συστηματική ανασκόπηση 106 μελετών που δημοσιεύθηκαν μεταξύ 2019 και 2023 διαπίστωσε ότι περίπου το 94% επικεντρώθηκε στη διάγνωση ή την ανίχνευση, ενώ λιγότερο από το 12% ασχολήθηκε με την πρόγνωση ή την εξέλιξη [7].

Οι δύο στόχοι ευνοούν διαφορετικές λειτουργίες ομιλίας και ακουστικά χαρακτηριστικά. Η παρατεταμένη φώνηση φωνηέντων είναι πιο αποτελεσματική για τη δυαδική διάκριση PD/HC, καθώς απομονώνει τη λειτουργία του λάρυγγα και παρέχει σταθερές μετρήσεις διαταραχής και θορύβου [8]. Οι συνδεδεμένες λειτουργίες ομιλίας, όπως η ανάγνωση αποσπασμάτων και ο αυθόρμητος διάλογος, είναι πιο ενημερωτικές για την εκτίμηση της σοβαρότητας, καθώς καταγράφουν την ακρίβεια της άρθρωσης, τον ρυθμό ομιλίας και την προσωδιακή διακύμανση, χαρακτηριστικά που συσχετίζονται με κλινικές κλίμακες σοβαρότητας όπως η UPDRS [8]. Τα χαρακτηριστικά άρθρωσης (MFCC, συντελεστές PLP, περιοχή φωνηέντων) έχουν αναφερθεί ότι αποδίδουν μέση ακρίβεια 80–95% για την πρόβλεψη της σοβαρότητας, σε σύγκριση με 75–90% για τα φωνητικά χαρακτηριστικά μόνο [8].

Ένας κρίσιμος περιορισμός της βιβλιογραφίας σχετικά με την παρακολούθηση είναι η έλλειψη διαχρονικών δεδομένων: οι περισσότερες μελέτες συγκρίνουν ομάδες PD και HC διατομεακά, αντί να παρακολουθούν τις ακουστικές αλλαγές σε μεμονωμένα άτομα με την πάροδο του χρόνου [8]. Η παρούσα εργασία επικεντρώνεται στην αξιόπιστη ανίχνευση χρησιμοποιώντας δύο τύπους εργασιών ομιλίας (ReadText και SpontaneousDialogue), αλλά το σύνολο χαρακτηριστικών έχει σχεδιαστεί κατά τρόπο που παραμένει συμβατό με μελλοντικές εργασίες παρακολούθησης.

2.3 Ταξινόμηση ακουστικών χαρακτηριστικών

Table 2.1: Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD

Κατηγορία	Παραδείγματα	Φυσιολογική βάση
Θεμελιώδης συχνότητα	F_0 μέσος όρος, F_0 τυπική απόκλιση	Τάση φωνητικών χορδών και κινητική ακαμψία
Διαταραχή	Jitter, Shimmer	Νευρομυϊκή αστάθεια
Θόρυβος	HNR, NHR	Ατελές κλείσιμο της γλωττίδας
Φορμάντες	F_1 , F_2 , F_3	Διαμόρφωση φωνητικού σωλήνα
Φασματικά/Κεποτρικά	MFCCs, delta-MFCCs	Φασματική περιβάλλουσα και δυναμική

Προσωδιακά χαρακτηριστικά σχετίζονται με το ύψος (F_0) και τα μοτίβα έντασης. Η PD μειώνει το εύρος F_0 (μονοτονικότητα) και το εύρος έντασης (μονοεντατικότητα), τα οποία σχετίζονται με την ταξινόμηση PD [10]. Οι στατιστικές πληθυσμού που καταγράφονται περιλαμβάνουν μέση τιμή F_0 , τυπική απόκλιση, ελάχιστη και μέγιστη τιμή, μέση ένταση και μεταβλητότητα, καθώς και συχνότητες φορμάντων που αντανακλούν τη διαμόρφωση του φωνητικού σωλήνα.

Τα **μέτρα διαταραχής** ποσοτικοποιούν την αστάθεια από κύκλο σε κύκλο στη δόνηση των φωνητικών χορδών. Το jitter (διαταραχή περιόδου) και το shimmer (διαταραχή πλάτους) είναι αυξημένα στην PD, αντανακλώντας τη νευρομυϊκή ασυντονιστικότητα που εμποδίζει την πηγή ομιλίας να διατηρήσει έναν τακτικό κύκλο δόνησης. Ο λόγος αρμονικών προς θόρυβο (HNR) μετρά την αναλογία της περιοδικής προς την μη περιοδική ενέργεια. Οι χαμηλότερες τιμές HNR υποδηλώνουν μια πιο αναπνευστική, θορυβώδη ποιότητα φωνής που είναι χαρακτηριστική της PD [3].

Τα **φασματικά και κεποτρικά χαρακτηριστικά** σχετίζονται με το φασματικό περίβλημα του φωνητικού σήματος. Οι Mel-Frequency Cepstral Coefficients (MFCCs) καταγράφουν πληροφορίες σχετικά με το φασματικό σχήμα χρησιμοποιώντας μια κλίμακα συχνοτήτων που βασίζεται στην αντίληψη, ενώ οι χρονικές παράγωγοί τους (delta και delta-delta) καταγράφουν τις δυναμικές αλλαγές στα φασματικά δεδομένα με την πάροδο του χρόνου [11]. Οι περιγραφές φασματικού σχήματος, όπως το κέντρο βάρους, το εύρος ζώνης, η απόκλιση και η επιπεδότητα, παρέχουν συμπληρωματικά μέτρα της συνολικής κατανομής ενέργειας. Μαζί, αυτές οι τρεις κατηγορίες χαρακτηριστικών είναι συμπληρωματικές και παρέχουν μια ολιστική περιγραφή της ακουστικής αλλαγής που σχετίζεται με την PD.

2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας

Πρόσφατες συστηματικές ανασκοπήσεις οργανώνουν τα ακουστικά χαρακτηριστικά σε τρεις λειτουργικά καθορισμένες κατηγορίες που αντιστοιχούν σε διακριτές πτυχές του μηχανισμού παραγωγής ομιλίας [8]:

- **Φωνητικά χαρακτηριστικά** (jitter, shimmer, HNR, λόγος διέγερσης γλωττίδας προς θόρυβο, εντροπία περιόδου τόνου) ποσοτικοποιούν τη σταθερότητα και την πληρότητα της δόνησης των φωνητικών χορδών. Αυτά τα χαρακτηριστικά είναι αυξημένα ή μειωμένα στην PD ως αποτέλεσμα της νευρομυϊκής αστάθειας και του ατελούς κλεισίματος της γλωττίδας.
- **Χαρακτηριστικά άρθρωσης** (MFCCs, cepstral peak prominence, formant frequencies, vowel space area, vowel articulation index, perceptual linear prediction coefficients) καταγράφουν τη δυναμική και την ακρίβεια της κίνησης του φωνητικού σωλήνα. Η περιοχή του φωνητικού χώρου είναι σταθερά μειωμένη στην PD, αντανακλώντας την περιορισμένη άρθρωση.
- **Προσωδικά χαρακτηριστικά** (μεταβλητότητα F_0 στη συνδεδεμένη ομιλία, ρυθμός ομιλίας, αριθμός και διάρκεια παύσεων, μέγιστος χρόνος φώνησης) καταγράφουν τα υπερκειμενικά μοτίβα του τόνου, του συγχρονισμού και του ρυθμού. Αυτά τα χαρακτηριστικά αντανακλούν τη μειωμένη προσωδική διακύμανση σε επίπεδο πρότασης στην PD, παράλληλα με την αυξημένη αστάθεια του τόνου σε επίπεδο μικρού τμήματος.

Από τα 18 χαρακτηριστικά που εξετάστηκαν από τον Wright and Aharonson [8], 12 έδειξαν μετρήσιμες και συνεπείς διαφορές μεταξύ ασθενών με PD και υγιών ατόμων ελέγχου, με το jitter, το shimmer και το HNR να είναι τα πιο συνεπή διακριτικά χαρακτηριστικά σε όλες τις μελέτες. Αυτό το πλαίσιο τριών κατηγοριών είναι συμπληρωματικό της παραδοσιακής ομαδοποίησης επεξεργασίας σήματος που παρουσιάζεται στον Πίνακα 2.1 και παρέχει μια κλινικά τεκμηριωμένη προοπτική για την ερμηνεία των αποτελεσμάτων σχετικά με τη σημασία των χαρακτηριστικών.

2.4 Σύνολα δεδομένων που χρησιμοποιούνται στην έρευνα για τη φωνή των ασθενών με Πάρκινσον

Η απόδοση και τα συμπεράσματα οποιασδήποτε μελέτης μηχανικής μάθησης είναι εγγενώς συνδεδεμένα με τα σύνολα δεδομένων που χρησιμοποιούνται. Στην έρευνα για τη φωνή των ασθενών με PD, έχουν χρησιμοποιηθεί διάφορα σύνολα δεδομένων,

το καθένα με διαφορετικά χαρακτηριστικά. Σε γενικές γραμμές, αυτά μπορούν να χωριστούν σε **ακατέργαστα σύνολα δεδομένων ήχου** (ηχογραφημένα φωνητικά σήματα που απαιτούν εξαγωγή χαρακτηριστικών) και **προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών** (όπου τα δεδομένα παρέχονται ήδη με τη μορφή τιμών χαρακτηριστικών ανά δείγμα). Παρακάτω εξετάζονται αντιπροσωπευτικά παραδείγματα κάθε κατηγορίας και η συνάφειά τους με την παρούσα εργασία.

2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου

Τα ακατέργαστα σύνολα δεδομένων ήχου για την PD συνήθως αποτελούνται από ηχογραφήσεις φωνής ασθενών με PD και υγιών ατόμων που έχουν συλλεχθεί σε ελεγχόμενο περιβάλλον. Ένα γνωστό πρώιμο παράδειγμα είναι το σύνολο δεδομένων του Little et al. [12] που διατίθεται μέσω του UCI Machine Learning Repository. Περιέχει 195 παρατεταμένες φωνητικές φωνές (ήχοι «α») από 31 άτομα (23 με PD), το καθένα από τα οποία χαρακτηρίζεται από 22 χαρακτηριστικά δυσφωνίας (jitter, shimmer, κ.λπ.) συν την ετικέτα κλάσης. Οι Little et al. ανέφεραν ότι πέτυχαν ακρίβεια ~91% στην ανίχνευση της PD χρησιμοποιώντας ένα SVM, καθιστώντας το ως σημείο αναφοράς για τις πρώιμες μελέτες. Ένας βασικός περιορισμός, ωστόσο, είναι ότι περιλαμβάνονται πολλαπλές ηχογραφήσεις από το ίδιο άτομο, γεγονός που απαιτεί προσεκτική ομαδοποίηση για την αποφυγή μεροληψίας — μια προφύλαξη που δεν τηρήθηκε σε όλες τις πρώιμες μελέτες, συμβάλλοντας σε ορισμένα υπερβολικά αισιόδοξα αποτελέσματα.

Ένα πιο πρόσφατο παράδειγμα είναι το σώμα MDVR-KCL (Mobile Device Voice Recordings at King's College London) [13]. Αυτή η συλλογή του 2019 περιέχει ηχογραφήσεις φωνής από ασθενείς με PD και υγιείς μάρτυρες που εκτελούν πολλαπλές ομιλητικές εργασίες, συμπεριλαμβανομένης της ανάγνωσης και του αυθόρμητου διαλόγου. Περιλαμβάνει δεκάδες υποκείμενα (για παράδειγμα, 37 υποκείμενα στο τμήμα που χρησιμοποιείται σε αυτή τη εργασία) και πολλαπλές ηχογραφήσεις ανά υποκείμενο ανά εργασία, καθιστώντας το κατάλληλο για την εξέταση της μεταβλητότητας εντός του υποκειμένου και των επιδράσεων της εργασίας. Τα δεδομένα είναι διαθέσιμα στο Zenodo και αντικατοπτρίζουν ένα πιο ρεαλιστικό σενάριο εγγραφής, με ποικίλο περιεχόμενο ομιλίας που καταγράφεται μέσω smartphone. Μελέτες που χρησιμοποιούν αυτό το σώμα δεδομένων — ή παρόμοια σύνολα δεδομένων πολλαπλών εργασιών — υποστηρίζουν ένθερμα την ομαδοποιημένη διασταυρούμενη επικύρωση, διασφαλίζοντας ότι όλες οι εγγραφές από ένα δεδομένο υποκείμενο τοποθετούνται σε ένα μόνο τμήμα, προκειμένου να αξιολογηθεί σωστά η γενίκευση σε νέους ομιλητές.

2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών

Τα προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών είναι εκείνα στα οποία το στάδιο επεξεργασίας του σήματος έχει ήδη ολοκληρωθεί αποτελεσματικά — αυτό που παρέχεται είναι ένας πίνακας τιμών χαρακτηριστικών ανά δείγμα, μαζί με ετικέτες κλάσης, έτοιμος για άμεση εφαρμογή μεθόδων μηχανικής μάθησης. Το σύνολο δεδομένων χαρακτηριστικών ομιλίας της νόσου του Πάρκινσον (PDSF) είναι ένα εξέχον παράδειγμα, διαθέσιμο μέσω του αποθετηρίου UCI ή του Kaggle [14].

Περιλαμβάνει 756 δείγματα με 754 χαρακτηριστικά ανά δείγμα συν μια δυαδική ετικέτα (PD ή HC), όπου κάθε δείγμα αντιστοιχεί σε μια ηχογράφιση φωνής από ένα άτομο. Υπάρχουν 252 μοναδικά υποκείμενα (188 PD, 64 HC), το καθένα από τα οποία συνεισφέρει ακριβώς τρία δείγματα (π.χ. τρεις ηχογραφήσεις παρατεταμένων φωνηέντων). Τα χαρακτηριστικά καλύπτουν ένα ευρύ φάσμα ακουστικών μετρήσεων, συμπεριλαμβανομένων παραδοσιακών μετρήσεων όπως jitter, shimmer και MFCCs, καθώς και συντελεστές Tunable Q-factor Wavelet Transform (TQWT) που καταγράφουν πρόσθετα χαρακτηριστικά του σήματος. Αυτό το σύνολο δεδομένων σχεδιάστηκε ως ένα ολοκληρωμένο σύνολο χαρακτηριστικών για τη συγκριτική αξιολόγηση της απόδοσης του ταξινομητή.

Το κύριο πλεονέκτημα των προ-εξαγόμενων συνόλων δεδομένων χαρακτηριστικών είναι η ευκολία και η συνέπεια — οι ερευνητές μπορούν να κατεβάσουν το CSV και να εφαρμόσουν απευθείας μεθόδους μηχανικής μάθησης, χωρίς να χρειάζεται να εφαρμόσουν διαδικασίες επεξεργασίας σήματος. Πολλές μελέτες έχουν χρησιμοποιήσει το σύνολο δεδομένων PDSF για να αξιολογήσουν διαφορετικούς αλγόριθμους ταξινόμησης, τεχνικές επιλογής χαρακτηριστικών και μεθόδους συνόλου, με αναφερόμενη ακρίβεια συχνά στην περιοχή 85–95% σε διάφορους ταξινομητές.

Μια κρίσιμη προειδοποίηση με σύνολα δεδομένων αυτού του τύπου είναι η **έλλειψη αναγνωριστικών υποκειμένων**. Δεδομένου ότι τα 756 δείγματα περιλαμβάνουν τρεις εγγραφές από καθένα από τα 252 υποκείμενα, μια αφελής διασταυρούμενη επικύρωση που χωρίζει τυχαία τα δείγματα θα εκπαιδεύσει και θα δοκιμάσει κατά λάθος εγγραφές από το ίδιο άτομο. Αυτό οδηγεί σε υπερβολικά αισιόδοξες εκτιμήσεις απόδοσης, καθώς οι τρεις εγγραφές ενός δεδομένου υποκειμένου δεν είναι ανεξάρτητες και μοιράζονται παρόμοια ακουστικά χαρακτηριστικά. Ορισμένες δημοσιευμένες μελέτες έχουν παραβλέψει αυτό το ζήτημα και, κατά συνέπεια, έχουν αναφέρει υπερβολική απόδοση του ταξινομητή. Η κατάλληλη προσέγγιση θα ήταν η ομαδοποίηση των δειγμάτων ανά υποκείμενο κατά την κατάτμηση των δεδομένων. Ωστόσο, δεδομένου ότι δεν παρέχονται αναγνωριστικά υποκειμένων, αυτό δεν μπορεί να γίνει άμεσα. Τα αποτελέσματα σε αυτό το σύνολο δεδομένων πρέπει επομένως να

ερμηνεύονται με προσοχή, καθώς η υψηλή ακρίβεια μπορεί να αντανακλά εν μέρει τη συνέπεια εντός του υποκειμένου και όχι την πραγματική γενίκευση σε νέους ομιλητές. Σε αυτή τη εργασία, τα αποτελέσματα του συνόλου δεδομένων B αντιμετωπίζονται ως δυνητικά αισιόδοξα, με έμφαση στις τάσεις και όχι στις απόλυτες τιμές απόδοσης.

2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων

Μια συστηματική ανασκόπηση 69 μελετών που δημοσιεύθηκαν μεταξύ 2020 και 2025 διαπίστωσε ότι τα περισσότερα σύνολα δεδομένων φωνής που χρησιμοποιούνται για την ταξινόμηση της PD περιέχουν λιγότερους από 100 συμμετέχοντες [6]. Τα πιο συχνά χρησιμοποιούμενα σώματα κειμένων είναι το PC-GITA (19 μελέτες), το σύνολο δεδομένων Istanbul PD Speech (15 μελέτες) και το σύνολο δεδομένων Oxford/UCI PD (14 μελέτες). Η ανισορροπία των κλάσεων είναι συχνή: η πλειονότητα των συνόλων δεδομένων παρουσιάζει αναλογίες PD-HC εκτός του εύρους 0,8–1,2, με το σύνολο δεδομένων Istanbul να περιέχει 188 συμμετέχοντες με PD έναντι μόλις 64 συμμετεχόντων με HC. Το σώμα κειμένων MDVR-KCL που χρησιμοποιείται σε αυτή τη εργασία είναι ένα από τα πιο συχνά εμφανιζόμενα σύνολα δεδομένων στην αγγλική γλώσσα στην πρόσφατη βιβλιογραφία [6].

2.4.4 Ετερογένεια επικύρωσης

Το ίδιο σύνολο δεδομένων μπορεί να παράγει θεμελιωδώς διαφορετικά αποτελέσματα απόδοσης ανάλογα με τη στρατηγική αξιολόγησης που χρησιμοποιείται. Μεταξύ των πρόσφατων μελετών, η k-fold cross-validation χρησιμοποιείται σε περίπου 40%, η fixed train/test splits σε περίπου 36%, η subject-independent evaluation (leave-one-subject-out ή leave-one-out) σε μόνο 12%, και η external cross-dataset validation σε λιγότερο από 15% [6]. Αυτή η ετερογένεια καθιστά δύσκολη και συχνά παραπλανητική την άμεση σύγκριση των αναφερόμενων αποτελεσμάτων μεταξύ των μελετών. Για παράδειγμα, μια μελέτη που ανέφερε ακρίβεια 100% χρησιμοποιώντας σταθερή διαίρεση στο μικρό σύνολο δεδομένων της Οξφόρδης βρέθηκε να υποβαθμίζεται στο 96% όταν δοκιμάστηκε σε διαφορετικό σώμα κειμένων, καταδεικνύοντας την ευθραυστότητα της αξιολόγησης εντός του δείγματος σε μικρά σημεία αναφοράς [6].

2.4.5 Ο ρόλος των εργασιών ομιλίας

Η επιλογή της εργασίας ομιλίας είναι μια σημαντική απόφαση σχεδιασμού που επηρεάζει τόσο τον τύπο των πληροφοριών που συλλέγονται όσο και την καταλληλότητα της ανάλυσης για την ανίχνευση έναντι της παρακολούθησης. Η

παρατεταμένη φώνηση φωνηέντων αντανακλά κυρίως τη λειτουργία του λάρυγγα και χρησιμοποιείται συνήθως για τη δυαδική διάκριση PD/HC. Αντίθετα, οι εργασίες ανάγνωσης και αυθόρμητης ομιλίας εμπλέκουν ολόκληρο το σύστημα παραγωγής ομιλίας και παρέχουν περισσότερες πληροφορίες για την αξιολόγηση της ακρίβειας της άρθρωσης, της προσωδικής διακύμανσης και του ρυθμού ομιλίας — χαρακτηριστικά που συνδέονται με τη σοβαρότητα της νόσου και όχι με την απλή παρουσία της [8]. Η παρούσα εργασία αξιολογεί τόσο μια εργασία ανάγνωσης (ReadText) όσο και μια εργασία αυθόρμητης ομιλίας (SpontaneousDialogue) από το Dataset A, επιτρέποντας μια ελεγχόμενη σύγκριση των αποτελεσμάτων των εργασιών υπό πανομοιότυπες διαμορφώσεις ταξινόμησης.

2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD

Η λογιστική παλινδρόμηση (LR), οι μηχανές υποστήριξης διανυσμάτων (SVM) και οι μέθοδοι συνόλου δέντρων είναι οι πιο ευρέως εφαρμοζόμενοι ταξινομητές στη βιβλιογραφία για τη φωνή PD. Η LR παρέχει μια ερμηνεύσιμη γραμμική βάση [15]· η SVM με πυρήνα RBF υπήρξε ιστορικά η κυρίαρχη προσέγγιση, με Little et al. [3] να επιτυγχάνει ακρίβεια ~91% στο σύνολο δεδομένων UCI χρησιμοποιώντας 22 χαρακτηριστικά δυσφωνίας [16]. Μια συστηματική ανασκόπηση από Sáenz-Lechón et al. [17] σημείωσε ότι οι SVM και τα τυχαία δάση επιτυγχάνουν υψηλή ακρίβεια σε μικρά ομοιογενή σύνολα δεδομένων παθολογίας φωνής. Το Random Forest [18] συμπληρώνει το SVM μέσω του μέσου όρου συνόλου, της ενσωματωμένης σημασίας χαρακτηριστικών και της ανθεκτικότητας σε άσχετα χαρακτηριστικά, καθιστώντας το κατάλληλο για μικρές, θορυβώδεις ιατρικές κοόρτες. Οι πλήρεις προδιαγραφές μοντέλου και οι εξισώσεις που χρησιμοποιούνται σε αυτή τη εργασία παρέχονται στο Κεφάλαιο 4.

Πέρα από την ακατέργαστη απόδοση ταξινόμησης, πρόσφατες εργασίες έχουν τονίσει τη σημασία της ερμηνεύσιμης επιλογής χαρακτηριστικών στην κλινική ανάλυση φωνής. Solana-Lavalle and Rosas-Romero [19] συνδύασε την επιλογή υποσυνόλων χαρακτηριστικών με πολλαπλούς ταξινομητές και μείωση διαστάσεων για να παρέχει ένα κλινικά ερμηνεύσιμο πλαίσιο για την ανίχνευση της νόσου του Πάρκινσον από τη φωνή. Ένα αξιοσημείωτο εύρημα της μελέτης τους είναι ότι το σχετικό περιεχόμενο συχνότητας στο φωνητικό σήμα διαφέρει μεταξύ ανδρών και γυναικών ομιλητών, υπογραμμίζοντας την ανάγκη να ληφθούν υπόψη οι δημογραφικές υποομάδες κατά την ερμηνεία των φωνητικών ταξινομητών και τονίζοντας το ενδεχόμενο το φύλο να

αποτελεί συγχυτική μεταβλητή σε ομάδες μικτού φύλου.

2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις

Αν και η παρούσα εργασία επικεντρώνεται αποκλειστικά στην κλασική μηχανική μάθηση, ο ευρύτερος τομέας έχει μετατοπιστεί σημαντικά προς τη βαθιά μάθηση. Μια πρόσφατη συστηματική ανασκόπηση διαπίστωσε ότι περίπου το 42% των μελετών φωνής PD που δημοσιεύθηκαν μεταξύ 2020 και 2025 χρησιμοποιούν αρχιτεκτονικές βαθιάς μάθησης, με τα συνελκτικά νευρωνικά δίκτυα (CNN) να είναι τα πιο συνηθισμένα, ακολουθούμενα από προσεγγίσεις βασισμένες σε μετασχηματιστές και μοντέλα θεμελίωσης όπως το Wav2Vec 2.0 [6]. Έχουν επίσης εμφανιστεί υβριδικές διαδικασίες που συνδυάζουν εξάγοντες χαρακτηριστικών βαθιάς μάθησης με κλασικούς ταξινομητές. Οι ενσωματώσεις βασικών μοντέλων δείχνουν υποσχέσεις για διαγλωσσική ανθεκτικότητα. Ωστόσο, η ανασκόπηση διαπίστωσε επίσης ότι αυτές οι μελέτες βασίζονται κυρίως σε εσωτερική επικύρωση, ενώ η εξωτερική αξιολόγηση μεταξύ συνόλων δεδομένων παραμένει σπάνια. Οι ισχυρισμοί σχετικά με την απόδοση που βασίζονται σε μικρά, ομοιογενή σύνολα δεδομένων — είτε χρησιμοποιούν κλασικές είτε βαθιές μεθόδους — θα πρέπει επομένως να ερμηνεύονται με προσοχή. Η παρούσα εργασία καθιερώνει μια αυστηρή κλασική βάση αναφοράς με αξιολόγηση ασφαλή από διαρροές και αφαίρεση χαρακτηριστικών, η οποία μπορεί να χρησιμεύσει ως σημείο αναφοράς για μελλοντικές συγκρίσεις βασισμένες σε ενσωματώσεις.

2.6 Μεθοδολογικά ζητήματα στη βιβλιογραφία

2.6.1 Διαρροή δεδομένων

Η διαρροή δεδομένων, όπως περιγράφεται σε μια πρόσφατη συστηματική ανασκόπηση της έρευνας για τη φωνή PD [6]:

«Όταν υπάρχουν πολλαπλές ηχογραφήσεις ανά υποκείμενο, οι τυχαίες διαχωριστικές δοκιμές εκπαίδευσης/ελέγχου μπορούν να τοποθετήσουν ηχογραφήσεις από το ίδιο υποκείμενο και στα δύο σύνολα, οδηγώντας σε τεχνητά διογκωμένες εκτιμήσεις απόδοσης.»

Η παρούσα μελέτη χρησιμοποιεί ομαδοποιημένη στρωματοποιημένη διασταυρούμενη επικύρωση για να διασφαλίσει ότι όλες οι ηχογραφήσεις από ένα συγκεκριμένο υποκείμενο υπάρχουν είτε αποκλειστικά στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής για κάθε πτυχή της διαδικασίας διασταυρούμενης επικύρωσης.

Πρόσφατη βιβλιογραφία δείχνει ότι, αν και πολλοί ερευνητές αναγνωρίζουν τα οφέλη της αξιολόγησης ανεξάρτητης από το υποκείμενο (δηλ. LOSO/LOOCV) και της αξιολόγησης εξωτερικών συνόλων δεδομένων, πολύ λίγοι ερευνητές στον τομέα χρησιμοποιούν αυτές τις προσεγγίσεις [6].

2.6.2 Ανισορροπία κλάσεων

Η ανισορροπία κλάσεων συμβαίνει όταν μια κλάση περιέχει σημαντικά περισσότερες περιπτώσεις από μια άλλη. Αυτό μπορεί να οδηγήσει σε παραπλανητικά αποτελέσματα όταν χρησιμοποιούνται απλά μέτρα ακρίβειας, επειδή ένα μοντέλο μπορεί να επιτύχει υψηλή ακρίβεια ενώ είναι μεροληπτικό προς την πλειοψηφούσα κατηγορία. Πολλές μελέτες δεν χρησιμοποιούν τεχνικές στάθμισης κατηγοριών ή επαναδειγματοληψίας για την αντιμετώπιση ζητημάτων που σχετίζονται με την ανισορροπία κατηγοριών [6]. Η παρούσα μελέτη διερευνά τη χρήση της στάθμισης κατηγοριών (λειτουργία «ισορροπημένη») ως πιθανή μέθοδο για τη μείωση των επιπτώσεων της ανισορροπίας κατηγοριών.

2.6.3 Αναπαραγωγιμότητα

Η αναπαραγωγή των αποτελεσμάτων από μελέτες στον τομέα της ταξινόμησης φωνής PD μπορεί να είναι δύσκολη λόγω της έλλειψης λεπτομερειών σχετικά με διάφορες πτυχές της έρευνας:

- Παράμετροι εξαγωγής χαρακτηριστικών που δεν έχουν καθοριστεί
- Τυχαία σπόρια που δεν έχουν καθοριστεί
- Ασαφής στρατηγική διασταυρούμενης επικύρωσης
- Διαδικασίες ρύθμισης υπερπαραμέτρων που δεν έχουν τεκμηριωθεί

Η παρούσα μελέτη αντιμετωπίζει τα παραπάνω προβλήματα παρέχοντας σταθερούς τυχαίους σπόρους, τεκμηριώνοντας τις παραμέτρους εξαγωγής χαρακτηριστικών και περιγράφοντας ρητά τα πρωτόκολλα διασταυρούμενης επικύρωσης.

2.6.4 Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων

Η εξωτερική επικύρωση — η δοκιμή ενός μοντέλου σε δεδομένα από μια εντελώς διαφορετική πηγή από το σύνολο εκπαίδευσης — είναι η πιο αυστηρή δοκιμή γενικευσιμότητας, αλλά πραγματοποιείται σε λιγότερο από το 15% των πρόσφατων μελετών φωνής PD [6]. Το αποτέλεσμα είναι ότι περίπου το 70% των μελετών

βασίζονται σε καθαρά εσωτερικές μετρήσεις που είναι πιθανό να υπερεκτιμούν την πραγματική απόδοση. Στις σπάνιες περιπτώσεις όπου έχει πραγματοποιηθεί αξιολόγηση μεταξύ συνόλων δεδομένων, έχουν παρατηρηθεί απότομες πτώσεις στην απόδοση· για παράδειγμα, μοντέλα που πέτυχαν τέλεια ακρίβεια σε ένα μικρό δείκτη αναφοράς υποβαθμίστηκαν σημαντικά όταν δοκιμάστηκαν σε ένα διαφορετικό σώμα δεδομένων [6]. Αυτά τα ευρήματα ενισχύουν την ανάγκη για συντηρητική ερμηνεία των αποτελεσμάτων εντός του δείγματος.

2.6.5 Ερμηνευσιμότητα

Η ερμηνευσιμότητα για κλινική επικύρωση παραμένει μια κρίσιμη αλλά ανεπαρκώς ανεπτυγμένη πτυχή της ταξινόμησης φωνής PD [6]. Μόνο μια μειοψηφία πρόσφατων μελετών χρησιμοποιεί μεθόδους εκ των υστέρων εξήγησης, όπως SHAP ή LIME· αυτές που το κάνουν έχουν εντοπίσει με συνέπεια το jitter, το shimmer και τη μονοτονία του τόνου ως κορυφαίους προγνωστικούς παράγοντες. Η περιορισμένη υιοθέτηση μεθόδων ερμηνευσιμότητας δημιουργεί ένα χάσμα μεταξύ των αποτελεσμάτων του μοντέλου και της κλινικής εφαρμοσιμότητας. Η παρούσα εργασία αντιμετωπίζει αυτό το χάσμα μέσω ανάλυσης αφαίρεσης χαρακτηριστικών και κατάταξης σημασίας χαρακτηριστικών με βάση την αναδιάταξη, παρέχοντας διαφανή εικόνα για το ποια ακουστικά χαρακτηριστικά καθορίζουν τις αποφάσεις ταξινόμησης.

2.7 Έλλειμμα στην έρευνα

Παρά τις πολυάριθμες μελέτες που αναφέρουν υψηλή ακρίβεια ταξινόμησης, λίγες αντιμετωπίζουν τα ακόλουθα:

1. **Ομαδοποιημένη διασταυρούμενη επικύρωση** για σύνολα δεδομένων πολλαπλών εγγραφών
2. **Μελέτες ελεγχόμενης αφαίρεσης χαρακτηριστικών**
3. **Συστηματική ανάλυση στάθμισης κατηγοριών**
4. **Διαφανής τεκμηρίωση** των περιορισμών
5. **Εξωτερική επικύρωση**: η γενίκευση μεταξύ συνόλων δεδομένων σπάνια δοκιμάζεται· η σύγκριση δύο συνόλων δεδομένων στην παρούσα μελέτη (ένα ακατέργαστο ηχητικό και ένα προ-εξαγόμενο) παρέχει κάποια στοιχεία εξωτερικής εγκυρότητας [6]
6. **Ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών**: το SHAP και άλλες μέθοδοι εκ

των υστέρων εξήγησης χρησιμοποιούνται σε λιγότερο από το 10% των μελετών της περιόδου 2020–2025· η παρούσα μελέτη καλύπτει αυτό το κενό μέσω της αφαίρεσης και της ανάλυσης της σημασίας των χαρακτηριστικών [6]

2.8 Περίληψη

Η ανίχνευση PD με βάση τη φωνή είναι δυνατή χρησιμοποιώντας κλασική μηχανική μάθηση σε ακουστικά χαρακτηριστικά, με ανταγωνιστικά αποτελέσματα που αναφέρονται σε πολλαπλά σύνολα δεδομένων. Ωστόσο, πρόσφατες συστηματικές ανασκοπήσεις που καλύπτουν την περίοδο 2019–2025 δείχνουν ότι η μεθοδολογική ποιότητα ποικίλλει σημαντικά στον τομέα αυτό όσον αφορά τις στρατηγικές επικύρωσης, την εξωτερική αξιολόγηση και την ερμηνευσιμότητα των αποτελεσμάτων [6, 7]. Ο τομέας απομακρύνεται επί του παρόντος από τα χειροποίητα ακουστικά χαρακτηριστικά προς ενσωματώσεις βαθιάς μάθησης, αλλά αυτές δεν έχουν ακόμη δείξει σταθερά πλεονεκτήματα στη γενίκευση υπό αυστηρή αξιολόγηση [6]. Ως εκ τούτου, η παρούσα μελέτη χρησιμοποιεί μια συντηρητική προσέγγιση που δίνει προτεραιότητα στην αναπαραγωγικότητα, την αξιολόγηση με γνώμονα το υποκείμενο και τη διαφάνεια στον τρόπο ερμηνείας των αποτελεσμάτων, έναντι της βελτιστοποίησης της απόδοσης.

Κεφάλαιο 3

Περιγραφή δεδομένων

3.1 Σύνολο δεδομένων A: MDVR-KCL

3.1.1 Πηγή και συλλογή

Το σύνολο δεδομένων Mobile Device Voice Recordings from King's College London (MDVR-KCL) [13] συλλέχθηκε ειδικά για την έρευνα της νόσου του Πάρκινσον χρησιμοποιώντας ηχογραφήσεις από smartphone. Το σύνολο δεδομένων είναι διαθέσιμο στο Zenodo με DOI 10.5281/zenodo.2867215.

Πλαίσιο συλλογής

Ιδιότητα	Τιμή
Περίοδος συλλογής	26-29 Σεπτεμβρίου 2017
Τοποθεσία	King's College London Hospital, Denmark Hill, Λονδίνο, Ηνωμένο Βασίλειο
Συσκευή εγγραφής	Smartphone Motorola Moto G4
Περιβάλλον	Κλινική αίθουσα εξετάσεων (~10 m ²)
Χρόνος αντήχησης	~500 ms
Λήψη ήχου	Άμεσο σήμα μικροφώνου (χωρίς συμπίεση GSM)

Table 3.1: Πλαίσιο συλλογής δεδομένων MDVR-KCL

Οι ηχογραφήσεις πραγματοποιήθηκαν εντός της ακτίνας αντήχησης απευθείας από το σήμα του μικροφώνου (χωρίς συμπίεση GSM), με αποτέλεσμα έναν ακουστικά καθαρό ήχο κατάλληλο για εξαγωγή χαρακτηριστικών.

3.1.2 Προδιαγραφές ήχου

Ιδιότητα	Τιμή
Μορφή	WAV (μη συμπιεσμένο PCM)
Εγγενής ρυθμός δειγματοληψίας	44,1 kHz
Ρυθμός δειγματοληψίας επεξεργασίας	22,05 kHz (επαναδειγματοληψία)
Βάθος bit	16-bit υπογεγραμμένος ακέραιος
Κανάλια	Μονοφωνικό
Συμπίεση	Καμία

Table 3.2: Προδιαγραφές ήχου για το σύνολο δεδομένων A

Όλα τα αρχεία ήχου μετατράπηκαν σε συχνότητα δειγματοληψίας 22,05 kHz πριν από την εξαγωγή χαρακτηριστικών. Αυτό έγινε για να υπάρχει συνέπεια στα δεδομένα και να μειωθεί το υπολογιστικό κόστος, χωρίς να χάνεται η απαραίτητη ποιότητα για την ανάλυση της ομιλίας.

3.1.3 Εργασίες ομιλίας

Το σύνολο δεδομένων περιλαμβάνει δύο διακριτές εργασίες ομιλίας που έχουν σχεδιαστεί για να καταγράφουν διαφορετικές πτυχές της φωνητικής παραγωγής:

Εργασία	Περιγραφή	Θέματα	HC	PD
ReadText	Απόσπασμα από το «Ο Βόρειος Άνεμος και ο Ήλιος»	37	21	16
SpontaneousDialogue	Ελεύθερη συνομιλία με τον εξεταστή	36	21	15

Table 3.3: Εργασίες ομιλίας στο σύνολο δεδομένων MDVR-KCL

Σημείωση: Το υποκείμενο ID18 λείπει από την εργασία SpontaneousDialogue, με αποτέλεσμα να υπάρχει μία λιγότερη εγγραφή για αυτή την κατάσταση.

3.1.4 Κατανομή τάξεων

Εργασία ReadText:

++ HC (Υγιείς μάρτυρες): 21 υποκείμενα (56,8%)

++ PD (Νόσος του Πάρκινσον): 16 άτομα (43,2%)

Εργασία SpontaneousDialogue:

++ HC (Υγιής έλεγχος): 21 άτομα (58,3%)

++ PD (Νόσος του Πάρκινσον): 15 άτομα (41,7%)

Αναλογία ανισορροπίας: Μέτρια (~57:43 HC:PD). Διεξήχθησαν πειράματα στάθμισης κατηγοριών για την αξιολόγηση της επίδρασης στην απόδοση της ταξινόμησης.

3.1.5 Γνωστές ανωμαλίες

- **ID18:** Λείπει από την εργασία SpontaneousDialogue (36 άτομα έναντι 37 στην εργασία ReadText).

3.2 Σύνολο δεδομένων B: Χαρακτηριστικά ομιλίας PD

3.2.1 Πηγή

Προ-εξορυσσόμενα ακουστικά χαρακτηριστικά από το UCI Machine Learning Repository, διανεμημένα μέσω Kaggle [14]. Το σύνολο δεδομένων περιέχει 752 ακουστικά χαρακτηριστικά που έχουν υπολογιστεί εκ των προτέρων από παρατεταμένες φωνητικές φωνές.

3.2.2 Πλαίσιο συλλογής

Ιδιότητα	Τιμή
Ίδρυμα	Πανεπιστήμιο Κωνσταντινούπολης, Ιατρική Σχολή Cerrahpaşa
Περίοδος συλλογής	Δεν προσδιορίζεται στα μεταδεδομένα
Συμμετέχοντες με PD	188
Θέματα HC	64
Ηλικιακό εύρος (PD)	33–87 έτη
Ηλικιακό εύρος (HC)	41–82 έτη
Λεκτική εργασία	Παρατεταμένη φώνηση του φωνήεντος /a/
Επαναλήψεις	3 ανά θέμα
Φυσικό ρυθμό δειγματοληψίας	44,1 kHz (αναφέρεται στα μεταδεδομένα)

Table 3.4: Πλαίσιο συλλογής για το σύνολο δεδομένων B

3.2.3 Μορφή δεδομένων

- **Μορφή:** CSV (τιμές διαχωρισμένες με κόμμα)
- **Σειρές:** 756 δείγματα (πολλαπλά ανά υποκείμενο)
- **Στήλες:** 753 συνολικά (752 χαρακτηριστικά + 1 δυαδική ετικέτα)
- **Κωδικοποίηση ετικέτας:** 1 = PD, 0 = HC

- **Αναγνωριστικά υποκειμένων:** Δεν παρέχονται (κρίσιμος περιορισμός)

3.2.4 Κατανομή κλάσεων

Κατηγορία	Δείγματα	Ποσοστό
HC (0)	192	25,4%
PD (1)	564	74,6%

Table 3.5: Κατανομή κλάσεων στο σύνολο δεδομένων B

Αναλογία ανισορροπίας: Σοβαρή ($\sim 25:75$ HC:PD), που απαιτεί στρατηγικές στάθμισης κλάσεων στην εκπαίδευση του μοντέλου.

3.2.5 Κατηγορίες χαρακτηριστικών

Τα 752 χαρακτηριστικά καλύπτουν πολλαπλούς ακουστικούς τομείς που υπολογίστηκαν από τους αρχικούς συγγραφείς:

Κατηγορία	Αριθμός	Περιγραφή
Βασική γραμμή	22	Παραλλαγές jitter, παραλλαγές shimmer, HNR, NHR
Ένταση	3	Ελάχιστη, μέγιστη, μέση ένταση
Φορμάντες	36	Στατιστικά στοιχεία συχνότητας και εύρους ζώνης F_1-F_4
MFCCs	84	Μέσος όρος, τυπική απόκλιση, δέλτα για MFCC 0–12
Wavelet (DWT)	182	Χαρακτηριστικά διακριτής αποσύνθεσης wavelet
TQWT	432	Χαρακτηριστικά μετασχηματισμού wavelet με ρυθμιζόμενο συντελεστή Q
Άλλα	7	PPE, DFA, RPDE, numPulses, GQ, GNE, VFER

Table 3.6: Κατηγορίες χαρακτηριστικών στο σύνολο δεδομένων B (752 συνολικά)

3.2.6 Μεθοδολογικές προειδοποιήσεις

Κρίσιμος περιορισμός: Ένας σημαντικός περιορισμός είναι ότι στο ΣΔ B δεν υπάρχουν αναγνωριστικά υποκειμένων. Αυτό σημαίνει ότι δεν γνωρίζουμε ποια δείγματα ανήκουν στο ίδιο άτομο. Έτσι, κατά τη

διασταυρούμενη επικύρωση, είναι πιθανό δείγματα από το ίδιο άτομο να βρίσκονται και στο σύνολο εκπαίδευσης και στο σύνολο δοκιμής.

Δεδομένου ότι συλλέχθηκαν 756 δείγματα από 252 υποκείμενα (188 PD + 64 HC) με 3 επαναλήψεις το καθένα, η τυπική στρωματοποιημένη διασταυρούμενη επικύρωση 5 πτυχών μπορεί να τοποθετήσει δείγματα από το ίδιο υποκείμενο σε διαφορετικές πτυχές, οδηγώντας σε:

- **Αισιόδοξες εκτιμήσεις απόδοσης** υπερεκτίμηση της γενίκευσης (τα αποτελέσματα φαίνονται καλύτερα από ό,τι είναι στην πράξη)
- **Παραβίαση της υπόθεσης ανεξαρτησίας** μεταξύ εκπαίδευσης και δοκιμής (τα δείγματα δεν είναι πραγματικά ανεξάρτητα, καθώς προέρχονται από τα ίδια άτομα)
- **Αδυναμία αξιολόγησης της γενίκευσης σε νέο άτομο** (δεν μπορούμε να πούμε πόσο καλά θα λειτουργούσε το μοντέλο σε ένα νέο άτομο που δεν έχει δει ποτέ πριν)

Τα αποτελέσματα στο σύνολο δεδομένων B πρέπει να ερμηνεύονται με προσοχή, λαμβάνοντας υπόψη αυτούς τους περιορισμούς. Επιπλέον: Δεν υπάρχει πρόσβαση στον αρχικό (ακατέργαστο) ήχο, οπότε δεν μπορούμε να ελέγξουμε ή να προσθέσουμε νέα χαρακτηριστικά. Τα δεδομένα περιλαμβάνουν μόνο παρατεταμένη φώνηση φωνηέντων και όχι φυσική, συνεχόμενη ομιλία, άρα δεν αντικατοπτρίζουν πλήρως την καθημερινή ομιλία. Το σύνολο περιλαμβάνει 752 χαρακτηριστικά, αριθμός που σε σχέση με το διαθέσιμο μέγεθος δείγματος μπορεί να οδηγήσει σε overfitting.

3.3 Σύγκριση μεταξύ συνόλων δεδομένων

3.3.1 Βασικές διαφορές

Πτυχή	Σύνολο δεδομένων A	Σύνολο δεδομένων B
Μορφή δεδομένων	Ακατέργαστος ήχος (WAV)	Προεξάχθέντα χαρακτηριστικά
Μέγεθος δείγματος	37 άτομα (73 ηχογραφήσεις)	756 σειρές (άγνωστα άτομα)
Παρακολούθηση ατόμων	Διαθέσιμη	Μη διαθέσιμη
Διαστατικότητα χαρακτηριστικών	47 (βασική γραμμή) ή 78 (επεκταμένη)	752 (σταθερή)
Εργασία ομιλίας	Ανάγνωση κειμένου / Διάλογος	Συνεχής φώνηση /a/
Εξαγωγή χαρακτηριστικών	Ελεγχόμενη (αυτή η εργασία)	Προϋπολογισμένη (μαύρο)
Διασταυρούμενη επικύρωση	Ομαδοποιημένη (επίπεδο υποκειμένου)	Τυπική (επίπεδο σειράς)
Κλινικά μεταδεδομένα	H&Y, UPDRS διαθέσιμα	Κανένα

Table 3.7: Λεπτομερής σύγκριση μεταξύ συνόλων δεδομένων

Κεφάλαιο 4

Μεθοδολογία

4.1 Διαδικασία εξαγωγής χαρακτηριστικών

4.1.1 Αρχιτεκτονική διαδικασίας

Η διαδικασία εξαγωγής χαρακτηριστικών μετατρέπει τον ακατέργαστο ήχο σε δομημένα διανύσματα χαρακτηριστικών κατάλληλα για μηχανική μάθηση:




Figure 4.1: Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.

4.1.2 Προεπεξεργασία ήχου

Όλα τα αρχεία ήχου υποβλήθηκαν στην ίδια διαδικασία προεπεξεργασίας, ώστε η εξαγωγή χαρακτηριστικών να γίνει με συνέπεια:

1. **Φόρτωση ήχου** με τον αρχικό ρυθμό δειγματοληψίας χρησιμοποιώντας

```
librosa.load()
```

2. **Επαναδειγματοληψία** στα 22.050 Hz (σταθερή σε όλες τις ηχογραφήσεις)
3. **Μετατροπή σε μονοφωνικό** αν το αρχείο ήταν στερεοφωνικό (μέσος όρος των δύο καναλιών).
4. **Κανονικοποίηση πλάτους** στο εύρος $[-1, 1]$
5. **Αφαίρεση σιωπής** χρησιμοποιώντας ανίχνευση βάσει ενέργειας (threshold 5% της μέγιστης ενέργειας)

Ο ρυθμός 22.050 Hz επιλέχθηκε γιατί είναι επαρκής για ανάλυση ομιλίας (Nyquist 11.025 Hz) και ταυτόχρονα μειώνει το υπολογιστικό κόστος σε σχέση με τα 44.100 Hz.

4.1.3 Προσωδιακά χαρακτηριστικά (21 χαρακτηριστικά)

Τα προσωδιακά χαρακτηριστικά περιγράφουν στοιχεία της φωνής που επηρεάζονται συχνά από τη νόσο του Πάρκινσον. Η εξαγωγή έγινε με το Parselmouth (Praat).

Θεμελιώδης συχνότητα (F_0)

Για την εξαγωγή του τόνου χρησιμοποιήθηκαν οι ακόλουθες παράμετροι:

- **Αλγόριθμος:** Βασισμένος στην αυτοσυσχέτιση (προεπιλογή του Praat)
- **Εύρος τόνου:** 75–500 Hz (καλύπτει ανδρικές, γυναικείες και παθολογικές φωνές)
- **Χρονικό βήμα:** 0,01 s (πρότυπο για την ανάλυση φωνής)

Τέσσερα στατιστικά στοιχεία υπολογίστηκαν από το περίγραμμα του τόνου:

$$F_0 = \{\mu_{F_0}, \sigma_{F_0}, \min_{F_0}, \max_{F_0}\} \quad (4.1)$$

Jitter

Το Jitter μετρά τη διακύμανση της περιόδου του τόνου από κύκλο σε κύκλο.

$$\text{Jitter}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|T_i - T_{i+1}|}{\bar{T}} \quad (4.2)$$

όπου T_i είναι η i -η περίοδος τόνου και $\bar{T}$ είναι η μέση περίοδος.

Πρόσθετα μέτρα περιλαμβάνουν:

- **RAP (Σχετική Μέση Διαταραχή):** εξομάλυνση 3 σημείων
- **PPQ5:** πηλίκο διαταραχής περιόδου 5 σημείων

Shimmer

Το Shimmer μετρά τη διακύμανση της έντασης από κύκλο σε κύκλο.

$$\text{Shimmer}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|A_i - A_{i+1}|}{\bar{A}} \quad (4.3)$$

όπου A_i είναι το i -οστό μέγιστο πλάτος και $\bar{A}$ είναι το μέσο πλάτος.

Πρόσθετα μέτρα περιλαμβάνουν APQ3, APQ5, APQ11 (συντελεστές διαταραχής πλάτους με μεταβαλλόμενα παράθυρα) και DDA (διαφορά των διαφορών των πλατών).

Αναλογία αρμονικών προς θόρυβο (HNR)

Το HNR δείχνει πόσο «καθαρή» είναι η φωνή (αρμονικές έναντι θορύβου).

- **Μέση HNR:** Μέση HNR (dB)
- **Αυτοσυσχέτιση αρμονικότητας:** Μέγιστη τιμή αυτοσυσχέτισης

Ένταση

Τρεις στατιστικές έντασης (dB SPL):

$$I = \{\mu_I, \sigma_I, \max_I - \min_I\} \quad (4.4)$$

Formants

Τα τρία πρώτα formants (F_1 , F_2 , F_3) εξήχθησαν χρησιμοποιώντας γραμμική προβλεπτική κωδικοποίηση (LPC):

- **Σειρά LPC:** τάξης 10 (επαρκής για 3 formants στα 22 kHz)
- **Χαρακτηριστικά:** Μέσος όρος και τυπική απόκλιση κάθε φωνητικού στοιχείου (6 χαρακτηριστικά συνολικά)

Ομάδα χαρακτηριστικών	Αριθμός	Χαρακτηριστικά	Εργαλείο
Τόνος (F_0)	4	μέσος όρος, τυπική απόκλιση, ελάχιστο, μέγιστο	Parselmouth
Jitter	3	τοπικό, RAP, PPQ5	Parselmouth
Shimmer	5	τοπικό, APQ3, APQ5, APQ11, DDA	Parselmouth
Αρμονικότητα	2	μέσος όρος HNR, αυτοσυσχέτιση	Parselmouth
Intensity	3	μέσος όρος, τυπική απόκλιση, εύρος	Parselmouth
Formants	6	F_1-F_3 μέσος όρος, F_1-F_3 τυπική απόκλιση	Parselmouth
Σύνολο	21		

Table 4.1: Ανάλυση προσωδιακών χαρακτηριστικών

4.1.4 Φασματικά χαρακτηριστικά

Τα φασματικά χαρακτηριστικά περιγράφουν τη δομή του φάσματος συχνοτήτων της φωνής και εξήχθησαν χρησιμοποιώντας τη βιβλιοθήκη `librosa` [20].

Συντελεστές Mel-Frequency Cepstral (MFCC)

Οι MFCC υπολογίζονται μέσω των ακόλουθων βημάτων:

1. **Προέμφαση:** $y[n] = x[n] - 0,97 \cdot x[n - 1]$
2. **Πλαίσιο:** Μήκος παραθύρου = 2048 δείγματα (≈ 93 ms στα 22 kHz)
3. **Παράθυρο:** Εφαρμογή παραθύρου Hann
4. **FFT:** FFT 2048 σημείων
5. **Φίλτρο Mel:** 128 τριγωνικά φίλτρα που καλύπτουν 0–11.025 Hz
6. **Συμπίεση λογαρίθμου:** $\log(\text{mel power spectrum})$
7. **DCT:** Διακριτός μετασχηματισμός συνημιτόνου που χρησιμοποιείται για τη μείωση της συσχέτισης μεταξύ των συντελεστών

Παράμετροι που χρησιμοποιήθηκαν:

- **Αριθμός συντελεστών:** 13 (MFCC 0–12)
- **Μήκος άλματος:** 512 δείγματα (≈ 23 ms στα 22 kHz, 75% επικάλυψη)
- **Αριθμός ζωνών mel:** 128

Ο MFCC 0 (ο μηδενικός συντελεστής) περιγράφει κυρίως την ενέργεια του σήματος, ενώ οι MFCC 1–12 αποτυπώνουν το σχήμα του φασματικού περιβλήματος της φωνής.

Συντελεστές δέλτα

Οι χρονικές παράγωγοι πρώτης τάξης (συντελεστές δέλτα) καταγράφουν τη φασματική δυναμική:

$$\Delta_t[n] = \frac{\sum_{i=1}^N i \cdot (c_{t+i} - c_{t-i})}{2 \sum_{i=1}^N i^2} \quad (4.5)$$

όπου c_t είναι ο συντελεστής MFCC στο πλαίσιο t και $N = 2$ είναι το μέγεθος του παραθύρου.

Βασικά φασματικά χαρακτηριστικά (26 χαρακτηριστικά)

Το βασικό σύνολο φασματικών χαρακτηριστικών αποτελείται από:

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Σύνολο	26	

Table 4.2: Βασικά φασματικά χαρακτηριστικά

Εκτεταμένα φασματικά χαρακτηριστικά (57 χαρακτηριστικά)

Το εκτεταμένο σύνολο χαρακτηριστικών περιλαμβάνει τρεις επιπλέον ομάδες, οι οποίες στοχεύουν να αποτυπώσουν περισσότερη φασματική και χρονική μεταβλητότητα της φωνής.

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
MFCC std	13	Χρονική τυπική απόκλιση (μεταβλητότητα εντός της εκφώνησης)
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Μέσος όρος Delta-Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων δεύτερης τάξης (επιτάχυνση)
Φασματικό σχήμα	5	Κέντρο βάρους, εύρος ζώνης, rolloff, επιπεδότητα, ZCR
Σύνολο	57	

Table 4.3: Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)

Οι πέντε περιγραφείς φασματικού σχήματος είναι:

1. **Φασματικό κέντρο βάρους:** Το «κέντρο μάζας» του φάσματος, δηλαδή το σημείο όπου συγκεντρώνεται η περισσότερη ενέργεια (σε Hz)
2. **Φασματικό εύρος ζώνης:** Πόσο απλώνεται το φάσμα γύρω από το κέντρο βάρους (σε Hz).
3. **Φασματική απόκλιση:** Η συχνότητα κάτω από την οποία βρίσκεται το 85% της συνολικής ενέργειας του σήματος (Hz)
4. **Φασματική επιπεδότητα:** Δείκτης του πόσο «τονική» ή «θορυβώδης» είναι η φωνή (λόγος γεωμετρικού προς αριθμητικό μέσο όρο).
5. **Ρυθμός διέλευσης από το μηδέν:** Πόσο συχνά το σήμα αλλάζει πρόσημο στο χρονικό πεδίο, δηλαδή πόσες φορές περνά από το μηδέν.

4.1.5 Συνολικός αριθμός χαρακτηριστικών

Διαμόρφωση	Προσωδιακά	Φασματικά	Σύνολο
Βασική γραμμή	21	26	47
Εκτεταμένα	21	57	78

Table 4.4: Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση

4.2 Σύγκριση συνόλου χαρακτηριστικών

4.2.1 Λόγοι για τα εκτεταμένα χαρακτηριστικά

Το εκτεταμένο σύνολο χαρακτηριστικών σχεδιάστηκε ως μία **ελεγχόμενη δοκιμή**, για να εξεταστεί αν η προσθήκη περισσότερης χρονικής και φασματικής πληροφορίας βελτιώνει την απόδοση της ταξινόμησης.

Προστέθηκαν τρεις ομάδες χαρακτηριστικών:

1. **MFCC std (13):** Μετρά τη μεταβλητότητα των MFCC μέσα σε κάθε ηχογράφηση. Αυτό είναι σημαντικό, γιατί η ομιλία σε ασθενείς με PD μπορεί να παρουσιάζει μεγαλύτερη αστάθεια.
2. **Delta-Delta MFCC (13):** Καταγράφει πόσο γρήγορα αλλάζουν τα φασματικά χαρακτηριστικά με τον χρόνο. Είναι ευαίσθητο στις χρονικές δυναμικές και στις αλλαγές της άρθρωσης.
3. **Φασματικό σχήμα (5):** Προσθέτουν γενικούς δείκτες του φάσματος (π.χ. τονικότητα, διασπορά), που δεν περιγράφονται πλήρως από τα MFCC.

4.2.2 Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών

Για να διασφαλιστεί η αναπαραγωγιμότητα, όλες οι βασικές παράμετροι ορίστηκαν από την αρχή σε κεντρικό αρχείο ρυθμίσεων (configuration file). Συγκεκριμένα:

- Τυχαίος σπόρος: 42
- Ρυθμός δειγματοληψίας: 22 050 Hz
- Εύρος F_0 : 75–500 Hz
- 13 MFCCs
- FFT 2048 σημείων
- Hop length: 512 δείγματα
- 128 mel bands

Όλα τα εξαγόμενα χαρακτηριστικά αποθηκεύτηκαν σε αρχεία CSV και χρησιμοποιήθηκαν στα επόμενα πειράματα χωρίς περαιτέρω αλλαγές.

4.3 Μοντέλα μηχανικής μάθησης

4.3.1 Προδιαγραφές μοντέλου

Επιλέχθηκαν πέντε κλασικά μοντέλα μηχανικής μάθησης, ώστε να καλυφθούν διαφορετικοί τρόποι μάθησης:

- **Λογιστική Παλινδρόμηση:** ένα απλό γραμμικό μοντέλο με κανονικοποίηση L2.
- **SVM με πυρήνα RBF:** μη γραμμική μέθοδος που μπορεί να μάθει πιο σύνθετα όρια απόφασης.
- **Random Forest:** σύνολο δέντρων απόφασης που προσφέρει και εκτίμηση σημασίας χαρακτηριστικών.
- **Gradient Boosting [21]:** μοντέλο που βελτιώνει σταδιακά τα λάθη των προηγούμενων βημάτων.
- **XGBoost [22]:** βελτιστοποιημένη και κανονικοποιημένη εκδοχή του boosting.

Όλες οι υπερπαράμετροι ορίστηκαν εκ των προτέρων (*a priori*) και δεν προσαρμόστηκαν ειδικά για κάποιο συγκεκριμένο σύνολο δεδομένων:

Μοντέλο	Τύπος	Βασικές παράμετροι
Λογιστική παλινδρόμηση	Γραμμική	$C = 1.0$ (κανονικοποίηση L2), max_iter= 1000, solver='lbfgs'
SVM (RBF)	Πυρήνας	$C = 1.0$ (κανονικοποίηση), gamma='scale' (αυτόματη κλιμάκωση ανά χαρακτηριστικά), kernel='rbf'
Random Forest	Bagging	n_estimators= 100, max_depth= 10, min_samples_split= 2, random_state= 42
Gradient Boosting	Boosting	n_estimators= 100, learning_rate= 0.1, max_depth= 3 (προεπιλογή), random_state= 42
XGBoost	Boosting	n_estimators= 100, learning_rate= 0.1, eval_metric='logloss', random_state= 42

Table 4.5: Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.

Λογιστική παλινδρόμηση

Το μοντέλο λογιστικής παλινδρόμησης προβλέπει τις πιθανότητες κλάσης μέσω:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (4.6)$$

με κανονικοποίηση L2:

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n \log(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)}) + \frac{1}{2} \|\mathbf{w}\|_2^2 \right] \quad (4.7)$$

όπου $C = 1,0$ ελέγχει την ισχύ της κανονικοποίησης.

Μηχανή Υποστήριξης Διανυσμάτων

Ο πυρήνας RBF SVM μαθαίνει ένα μη γραμμικό όριο απόφασης μέσω:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (4.8)$$

όπου $\gamma = \frac{1}{n_{\text{features}} \cdot \text{Var}(\mathbf{X})}$ (αυτόματη κλιμάκωση).

Random Forest

Το Random Forest συγκεντρώνει προβλέψεις από 100 δέντρα αποφάσεων:

$$\hat{y} = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \hat{y}_t(\mathbf{x}) \quad (4.9)$$

Κάθε δέντρο εκπαιδεύεται σε ένα τυχαίο δείγμα των δεδομένων (bootstrap) και σε κάθε διαχωρισμό χρησιμοποιεί ένα τυχαίο υποσύνολο χαρακτηριστικών.

Το μέγιστο βάθος 10 επιλέχθηκε ώστε να περιοριστεί η υπερπροσαρμογή (overfitting), ιδιαίτερα λόγω του μικρού μεγέθους των συνόλων δεδομένων.

Gradient Boosting

Το Gradient Boosting δημιουργεί το μοντέλο βήμα-βήμα, όπου κάθε νέο δέντρο προσπαθεί να διορθώσει τα λάθη που έκαναν τα προηγούμενα δέντρα [21]:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}) \quad (4.10)$$

όπου F_m είναι το σύνολο μετά από m στάδια, h_m είναι ο αδύναμος μαθητής (δέντρο αποφάσεων) προσαρμοσμένος στην αρνητική κλίση της συνάρτησης απώλειας και $\eta = 0,1$ είναι ο ρυθμός μάθησης. Ο ρυθμός μάθησης μειώνει τη συμβολή κάθε δέντρου, παρέχοντας αποτέλεσμα κανονικοποίησης.

XGBoost

Το XGBoost [22] είναι μια βελτιωμένη εκδοχή του Gradient Boosting, η οποία προσθέτει κανονικοποίηση L1 και L2 στα βάρη των φύλλων των δέντρων, ώστε να μειώνει την υπερπροσαρμογή και να βελτιώνει τη γενίκευση.

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(\hat{y}_i, y_i) + \sum_{k=1}^K \Omega(f_k), \quad \text{where } \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \quad (4.11)$$

Εδώ T είναι ο αριθμός των φύλλων, $\mathbf{w}$ είναι το διάνυσμα των βαρών φύλλων και γ, λ είναι παράμετροι κανονικοποίησης. Αυτή η κανονικοποίηση βοηθά στην αποφυγή της υπερπροσαρμογής, η οποία είναι ιδιαίτερα σημαντική για σύνολα δεδομένων μικρού μεγέθους.

4.3.2 Στάθμιση βαρύτητας κλάσης

Η ανισορροπία κλάσης αντιμετωπίζεται μέσω της παραμέτρου `class_weight`:

```
1 # Χωρίς στάθμιση βασική ( συνθήκη)
2 class_weight = None
3
4 # Με στάθμιση ισορροπημένη ( συνθήκη)
5 class_weight = "balanced" #  $w_k = n_{\text{samples}} / (n_{\text{classes}} * n_k)$ 
```

Όταν `class_weight="balanced"`, οι βαρύτητες των δειγμάτων υπολογίζονται ως εξής:

$$w_k = \frac{n_{\text{samples}}}{n_{\text{classes}} \cdot n_k} \quad (4.12)$$

όπου n_k είναι ο αριθμός των δειγμάτων στην κλάση k . Αυτό εξασφαλίζει ότι τα σφάλματα της μειοψηφικής κλάσης σταθμίζονται περισσότερο κατά τη διάρκεια της εκπαίδευσης.

Τρία από τα πέντε μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest) υποστηρίζουν εγγενώς την παράμετρο `class_weight` μέσω του `scikit-learn`. Οι δύο

ταξινομητές ενίσχυσης (Gradient Boosting και XGBoost) δεν υποστηρίζουν εγγενώς το `class_weight="balanced"`. Ωστόσο, δεδομένου ότι η ήπια ανισορροπία κλάσεων (1,3:1) δεν απαιτούσε επαναστάθμιση στην πράξη (βλ. Κεφάλαιο 6), αυτή η διαφορά δεν έχει καμία επίδραση στο σχεδιασμό του πειράματος.

4.4 Αρχιτεκτονική ML Pipeline

4.4.1 Δομή Pipeline

Όλα τα μοντέλα χρησιμοποιούν ένα τυποποιημένο scikit-learn Pipeline:

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3
4 pipeline = Pipeline([
5     ('scaler', StandardScaler()),
6     ('classifier', Model(class_weight=..., random_state=42))
7 ])
```

Αυτό εξασφαλίζει ότι η κλιμάκωση χαρακτηριστικών εφαρμόζεται με συνέπεια και αποτρέπει τη διαρροή δεδομένων.

4.4.2 Τυποποίηση χαρακτηριστικών

Τα χαρακτηριστικά κανονικοποιούνται ώστε να έχουν μέση τιμή 0 και τυπική απόκλιση 1 (StandardScaler).

Η κανονικοποίηση υπολογίζεται μόνο στα δεδομένα εκπαίδευσης μέσα σε κάθε διαχωρισμό του k-fold cross-validation, ώστε να μη χρησιμοποιούνται πληροφορίες από το test set και να αποφεύγεται η διαρροή δεδομένων.

4.5 Πλαίσιο αξιολόγησης

4.5.1 Στρατηγική Cross-Validation

Σε αυτή τη εργασία, η **διασταυρούμενη επικύρωση K -fold αποτελεί την κύρια στρατηγική αξιολόγησης**: το μοντέλο εκπαιδεύεται σε $K - 1$ folds και αξιολογείται στο εναπομείναν fold, το οποίο περιλαμβάνει μόνο δείγματα που δεν έχουν χρησιμοποιηθεί ούτε στην εκπαίδευση ούτε στην εξόρυξη χαρακτηριστικών [15]. Η διαδικασία επαναλαμβάνεται $K = 5$ φορές, παρέχοντας πέντε ανεξάρτητες εκτιμήσεις

της απόδοσης γενίκευσης. Δεν χρησιμοποιήθηκε ξεχωριστό σύνολο δοκιμής, καθώς με μόνο $n = 37$ υποκείμενα (σύνολο δεδομένων A), η δέσμευση ακόμη και του 20% για test set θα οδηγούσε σε περίπου επτά υποκείμενα δοκιμής ανά διαχωρισμό σε επίπεδο υποκειμένου, αριθμός ανεπαρκής για σταθερή εκτίμηση.

Η 5-fold CV χρησιμοποιείται αποκλειστικά ως **μηχανισμός αξιολόγησης** και όχι ως μηχανισμός ρύθμισης. Έτσι αποφεύγεται οποιοσδήποτε κίνδυνος προσαρμογής των υπερπαραμέτρων στα δεδομένα αξιολόγησης.

Απαιτήθηκαν διαφορετικές στρατηγικές επικύρωσης για κάθε σύνολο δεδομένων, λόγω των δομικών διαφορών που παρουσιάζουν.

Σύνολο δεδομένων	Στρατηγική	Πτυχές	Ομαδοποίηση
Σύνολο δεδομένων A (MDVR-KCL)	Ομαδοποιημένο στρωματοποιημένο	5	Ανά subject_id
Σύνολο δεδομένων B (PD Speech)	Στρωματοποιημένο	5	Καμία (μη διαθέσιμα)

Table 4.6: Στρατηγικές διασταυρούμενης επικύρωσης

Σύνολο δεδομένων A: Ομαδοποιημένη διασταυρούμενη επικύρωση

Για το σύνολο δεδομένων A (MDVR-KCL), υπάρχουν πολλές εγγραφές από το ίδιο άτομο. Για να μην υπάρξει διαρροή δεδομένων, έγινε διαχωρισμός σε επίπεδο υποκειμένου. Αυτό σημαίνει ότι:

- Όλες οι εγγραφές του ίδιου ατόμου μπαίνουν στο ίδιο fold
- Υπάρχει περίπου ισορροπία μεταξύ των κλάσεων
- Το μοντέλο δεν βλέπει ποτέ δεδομένα από άτομα που βρίσκονται στο σύνολο δοκιμής

Έτσι προσομοιώνεται μια ρεαλιστική κατάσταση, όπου το μοντέλο αξιολογείται σε νέους ομιλητές.

Σύνολο δεδομένων B: Τυπική cross-validation

Στο σύνολο δεδομένων B δεν υπάρχουν αναγνωριστικά υποκείμενων. Για αυτό χρησιμοποιήθηκε τυπική 5-fold cross-validation. Ωστόσο, τα αποτελέσματα μπορεί να είναι πιο αισιόδοξα, αν δείγματα του ίδιου ατόμου βρίσκονται σε διαφορετικά folds.

4.5.2 Μετρήσεις αξιολόγησης

Υπολογίστηκαν πέντε βασικές μετρήσεις ταξινόμησης σε κάθε fold:

Μέτρηση	Τύπος	Ερμηνεία
Ακρίβεια	$\frac{TP+TN}{TP+TN+FP+FN}$	Ποσοστό σωστών προβλέψεων συνολικά
Προβλεψιμότητα	$\frac{TP}{TP+FP}$	Από τις προβλέψεις PD, πόσες ήταν σωστές
Ανάκληση	$\frac{TP}{TP+FN}$	Από τα πραγματικά PD, πόσα βρέθηκαν σωστά
Βαθμολογία F1	$\frac{2 \cdot P \cdot R}{P+R}$	Ισορροπία μεταξύ προβλεψιμότητας και ανάκλησης
ROC-AUC	$\int_0^1 \text{TPR}(t) d\text{FPR}(t)$	Ικανότητα διάκρισης ανεξάρτητα από threshold

Table 4.7: Μετρήσεις αξιολόγησης

Κύρια μέτρηση: Επιλέχθηκε το ROC-AUC γιατί:

- δεν εξαρτάται από ένα συγκεκριμένο threshold,
- είναι πιο σταθερό όταν οι κλάσεις δεν είναι ισορροπημένες,
- έχει σαφή ερμηνεία (πιθανότητα ένας τυχαίος PD να έχει υψηλότερη βαθμολογία από έναν τυχαίο HC).

Κεφάλαιο 5

Σχεδιασμός πειράματος

5.1 Ερευνητικά ερωτήματα

Τα πειράματα εξετάζουν τα παρακάτω ερωτήματα:

- RQ1:** Πόσο καλά αποδίδουν τα κλασικά μοντέλα ML στην αναγνώριση PD από φωνητικά χαρακτηριστικά;
- RQ2:** Βελτιώνεται η απόδοση όταν αυξάνονται τα χαρακτηριστικά από 47 σε 78;
- RQ3:** Βοηθά η ισορροπημένη στάθμιση κλάσεων σε μη ισορροπημένα δεδομένα;
- RQ4:** Υπάρχουν διαφορές στα αποτελέσματα μεταξύ του συνόλου δεδομένων A (CV σε επίπεδο υποκειμένου) και του συνόλου δεδομένων B (τυπικό CV);
- RQ5:** Υπάρχει διαφορά στην απόδοση μεταξύ ανάγνωσης και αυθόρμητης ομιλίας;

5.2 Πειραματικός πίνακας

5.2.1 $2 \times 2 \times 5$ Παραγοντικός σχεδιασμός

Ο σχεδιασμός περιλαμβάνει τρεις παράγοντες:

1. **Σύνολο χαρακτηριστικών:** 47 (baseline) ή 78 (extended)
2. **Στάθμιση κλάσεων:** χωρίς ή με ισορροπημένη στάθμιση
3. **Μοντέλο:** LR, SVM (RBF), RF, Gradient Boosting, XGBoost

Συνολικά: $2 \times 2 \times 5 = 20$ συνθήκες για κάθε dataset/εργασία.

ID	Χαρακτηριστικά	Στάθμιση	Μοντέλα	Έξοδος
C1	47	Καμία	LR, SVM, RF, GB, XGB	baseline/baseline/
C2	78	Καμία	LR, SVM, RF, GB, XGB	baseline/extended/
C3	47	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/baseline/
C4	78	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/extended/

Table 5.1: Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.

5.2.2 Συνολικές πειραματικές εκτελέσεις

Dataset/Εργασία	Συνθήκες	Μοντέλα	CV Folds	Σύνολο
Dataset A - ReadText	4	5	5	100
Dataset A - SpontaneousDialogue	4	5	5	100
Dataset B - PD Speech	4	5	5	100
Σύνολο				300

Table 5.2: Συνολικός αριθμός πειραμάτων

5.3 Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα

Χρησιμοποιήθηκε 5-fold cross-validation (σε επίπεδο υποκειμένου για το Dataset A και στρωματοποιημένο για το Dataset B). Όλα τα πειράματα εκτελέστηκαν με `random_state=42` για αναπαραγωγιμότητα.

Τα αποτελέσματα του Dataset B πρέπει να εξετάζονται με προσοχή λόγω της έλλειψης αναγνωριστικών υποκειμένων (βλ. ενότητα 8.2.1). Οι περιορισμοί παρουσιάζονται στο κεφάλαιο 8.

Κεφάλαιο 6

Αποτελέσματα

6.1 Σύνοψη των καλύτερων αποτελεσμάτων

6.1.1 Σύνολο δεδομένων A (MDVR-KCL) — Καλύτερη απόδοση

Μέτρηση	Τιμή	Μοντέλο	Εργασία	Συνθήκη
ROC-AUC	$0,857 \pm 0,171$	Random Forest	Αυθόρμητο	Εκτεταμένο / Μη σταθμισμένο
Ακρίβεια	$82,2\% \pm 16,6\%$	Random Forest	ReadText	Εκτεταμένο / Μη σταθμισμένο

Table 6.1: Καλύτερη απόδοση στο σύνολο δεδομένων A

6.1.2 Σύνολο δεδομένων B (Σύγκριση αναφοράς)

Περίληψη απόδοσης: Το σύνολο δεδομένων B πέτυχε σημαντικά υψηλότερες μετρήσεις σε όλους τους ταξινομητές, όπως φαίνεται στον πίνακα 6.2. Τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή λόγω της άγνωστης επικάλυψης των θεμάτων (Ενότητα 8.2.1).

Μοντέλο	ROC-AUC	Ακρίβεια	F1	Ανάκληση
Λογιστική παλινδρόμηση	$0,867 \pm 0,029$	$0,828 \pm 0,008$	$0,885 \pm 0,006$	$0,890 \pm 0,016$
SVM (RBF)	$0,885 \pm 0,025$	$0,851 \pm 0,024$	$0,908 \pm 0,015$	$0,986 \pm 0,019$
Random Forest	$0,940 \pm 0,013$	$0,882 \pm 0,019$	$0,925 \pm 0,012$	$0,980 \pm 0,015$
Gradient Boosting	$0,937 \pm 0,019$	$0,884 \pm 0,024$	$0,926 \pm 0,015$	$0,980 \pm 0,013$
XGBoost	$0,952 \pm 0,015$	$0,896 \pm 0,017$	$0,933 \pm 0,011$	$0,980 \pm 0,017$

Table 6.2: Απόδοση του συνόλου δεδομένων B χρησιμοποιώντας τη βασική (μη σταθμισμένη) διαμόρφωση. Σημειώστε τη σημαντικά χαμηλότερη διακύμανση σε σύγκριση με το σύνολο δεδομένων A.




Figure 6.1: Σημαντικότητα χαρακτηριστικών τυχαίου δάσους (σύνολο δεδομένων B). Τα κορυφαία χαρακτηριστικά κυριαρχούνται από προηγμένες μετρήσεις επεξεργασίας σήματος που συχνά δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.

Βασικές διαφορές από το σύνολο δεδομένων A:

- **Επίδραση μεγέθους δείγματος:** $n = 752$ έναντι $n = 37$ μειώνει τη διακύμανση κατά μία τάξη μεγέθους ($\pm 0,01$ έναντι $\pm 0,15$).
- **Αισιόδοξη μεροληψία:** Τα αποτελέσματα ενδέχεται να είναι υπερβολικά λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ των πτυχών εκπαίδευσης/δοκιμής.
- **Διαθεσιμότητα χαρακτηριστικών:** Πολλά από τα κορυφαία χαρακτηριστικά

(π.χ. DFA, RPDE) απαιτούν εξειδικευμένη ανάλυση που δεν περιλαμβάνεται στα βασικά χαρακτηριστικά του συνόλου δεδομένων A.

6.2 Συνθήκη 1: Βασικά χαρακτηριστικά + χωρίς στάθμιση

Διαμόρφωση: 47 χαρακτηριστικά, χωρίς στάθμιση κλάσης

6.2.1 Εργασία: ReadText

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	0,717 $\pm$ 0,139	0,621 $\pm$ 0,058	0,542 $\pm$ 0,099
SVM (RBF)	0,614 $\pm$ 0,312	0,621 $\pm$ 0,106	0,333 $\pm$ 0,333
Random Forest	0,590 $\pm$ 0,302	0,629 $\pm$ 0,178	0,351 $\pm$ 0,363
Gradient Boosting	0,500 $\pm$ 0,159	0,464 $\pm$ 0,134	0,374 $\pm$ 0,221
XGBoost	0,628 $\pm$ 0,203	0,518 $\pm$ 0,132	0,371 $\pm$ 0,262

Table 6.3: Συνθήκη 1 — Αποτελέσματα ReadText

6.2.2 Εργασία: Αυθόρμητος διάλογος

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	0,760 $\pm$ 0,214	0,639 $\pm$ 0,160	0,539 $\pm$ 0,321
SVM (RBF)	0,407 $\pm$ 0,309	0,636 $\pm$ 0,135	0,400 $\pm$ 0,253
Random Forest	0,828 $\pm$ 0,148	0,721 $\pm$ 0,176	0,567 $\pm$ 0,365
Gradient Boosting	0,615 $\pm$ 0,078	0,664 $\pm$ 0,133	0,583 $\pm$ 0,118
XGBoost	0,723 $\pm$ 0,197	0,668 $\pm$ 0,121	0,470 $\pm$ 0,323

Table 6.4: Συνθήκη 1 — Αποτελέσματα αυθόρμητου διαλόγου

6.3 Συνθήκη 2: Εκτεταμένα χαρακτηριστικά + Χωρίς στάθμιση

Διαμόρφωση: 78 χαρακτηριστικά, χωρίς στάθμιση κλάσης

6.3.1 Εργασία: ReadText

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	$0,698 \pm 0,132$	$0,596 \pm 0,079$	$0,475 \pm 0,106$
SVM (RBF)	$0,834 \pm 0,153$	$0,786 \pm 0,181$	$0,634 \pm 0,386$
Random Forest	$0,822 \pm 0,166$	$0,818 \pm 0,140$	$0,746 \pm 0,207$
Gradient Boosting	$0,724 \pm 0,214$	$0,654 \pm 0,138$	$0,605 \pm 0,184$
XGBoost	$0,794 \pm 0,186$	$0,739 \pm 0,195$	$0,691 \pm 0,252$

Table 6.5: Συνθήκη 2 — Αποτελέσματα ReadText




Figure 6.2: Σημασία χαρακτηριστικών τυχαίου δάσους για την εργασία ReadText (εκτεταμένα χαρακτηριστικά). Οι στατιστικές της θεμελιώδους συχνότητας (F_0) φαίνονται ιδιαίτερα προγνωστικές.

6.3.2 Εργασία: Αυθόρμητος διάλογος

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	$0,783 \pm 0,139$	$0,671 \pm 0,199$	$0,530 \pm 0,377$
SVM (RBF)	$0,460 \pm 0,294$	$0,636 \pm 0,089$	$0,428 \pm 0,258$
Random Forest	$0,857 \pm 0,171$	$0,779 \pm 0,161$	$0,605 \pm 0,387$
Gradient Boosting	$0,638 \pm 0,146$	$0,636 \pm 0,221$	$0,547 \pm 0,222$
XGBoost	$0,687 \pm 0,146$	$0,693 \pm 0,123$	$0,553 \pm 0,176$

Table 6.6: Συνθήκη 2 — Αποτελέσματα αυθόρμητου διαλόγου




Figure 6.3: Σημασία χαρακτηριστικών τυχαίου δάσους για την εργασία αυθόρμητου διαλόγου (εκτεταμένα χαρακτηριστικά). Τα χαρακτηριστικά MFCC παρουσιάζουν αυξημένη σημασία σε σύγκριση με το ReadText.

6.4 Ανάλυση αφαίρεσης χαρακτηριστικών

6.4.1 Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (Read-Text)

Μοντέλο	Βασική γραμμή (47)	Εκτεταμένη (78)	Δ ROC-AUC
Λογιστική παλινδρόμηση	0,717	0,698	-0,019
SVM (RBF)	0,614	0,834	+0,220
Random Forest	0,590	0,822	+0,232
Gradient Boosting	0,500	0,724	+0,224
XGBoost	0,628	0,794	+0,166

Table 6.7: Αφαίρεση χαρακτηριστικών — ReadText

6.4.2 Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (αυθόρμητη)

Μοντέλο	Βασική γραμμή (47)	Επέκταση (78)	Δ ROC-AUC
Λογιστική παλινδρόμηση	0,760	0,783	+0,023
SVM (RBF)	0,407	0,460	+0,053
Random Forest	0,828	0,857	+0,029
Gradient Boosting	0,615	0,638	+0,023
XGBoost	0,723	0,687	-0,036

Table 6.8: Αφαίρεση χαρακτηριστικών — Αυθόρμητος διάλογος

6.5 Ανάλυση στάθμισης κλάσεων

Η στάθμιση κλάσης (`class_weight='balanced'`) αξιολογήθηκε για την αντιμετώπιση της ήπιας ανισορροπίας κλάσεων του συνόλου δεδομένων A (HC:PD $\approx$ 1,3:1). Τα αποτελέσματα έδειξαν ελάχιστη βελτίωση και περιστασιακή υποβάθμιση.

6.5.1 Εργασία ReadText — Βασικά χαρακτηριστικά

Μοντέλο	Χωρίς στάθμιση	Με στάθμιση	Δ ROC-AUC
Λογιστική παλινδρόμηση	$0,717 \pm 0,139$	$0,717 \pm 0,139$	0,000
Random Forest	$0,590 \pm 0,302$	$0,687 \pm 0,258$	+0,097
SVM (RBF)	$0,614 \pm 0,312$	$0,542 \pm 0,312$	-0,072
Gradient Boosting	N/A (no native class_weight)		
XGBoost	N/A (no native class_weight)		

Table 6.9: Επίδραση της στάθμισης κλάσης στο ReadText (βασικά χαρακτηριστικά). Το Random Forest έδειξε μέτρια βελτίωση.

6.5.2 Εκτεταμένα χαρακτηριστικά — Όλες οι εργασίες

Με τα εκτεταμένα χαρακτηριστικά, η στάθμιση κλάσης παρείχε αμελητέο ή αρνητικό όφελος: το RF ReadText έπεσε κατά $-1,7\text{pp}$ ($0,822 \rightarrow 0,805$) και το Spontaneous έπεσε κατά $-3,4\text{pp}$ ($0,857 \rightarrow 0,823$), επιβεβαιώνοντας ότι η ήπια ανισορροπία 1,3:1 δεν απαιτούσε διόρθωση.

6.6 Συμβιβασμοί ακρίβειας-ανάκλησης

Οι ταξινομητές παρουσίασαν διακριτά προφίλ ακρίβειας-ανάκλησης, κρίσιμα για την κατανόηση των σεναρίων κλινικής ανάπτυξης.

6.6.1 Random Forest (εκτεταμένα χαρακτηριστικά)

Εργασία	Ακρίβεια	Ανάκληση	Βαθμολογία F1
ReadText	$0,883 \pm 0,162$	$0,700 \pm 0,298$	$0,746 \pm 0,207$
Αυθόρμητο	$0,683 \pm 0,410$	$0,600 \pm 0,435$	$0,605 \pm 0,387$

Table 6.10: Προφίλ ακρίβειας-ανάκλησης τυχαίου δάσους. Η διαμόρφωση ReadText ευνοεί την ακρίβεια (λιγότερα ψευδώς θετικά αποτελέσματα).

Ανάλυση: Το ReadText πέτυχε υψηλή ακρίβεια (0,88) σε βάρος της ανάκλησης (0,70), υποδηλώνοντας ότι το μοντέλο είναι συντηρητικό στην πρόβλεψη της PD. Αυτό το προφίλ μπορεί να είναι προτιμότερο για εφαρμογές διαλογής όπου τα ψευδώς θετικά έχουν υψηλότερο κόστος.

6.7 Ανάλυση πίνακα σύγχυσης

Οι πίνακες σύγχυσης που ακολουθούν συγκεντρώνουν τις προβλέψεις εκτός πτυχής από τη διαμόρφωση του εκτεταμένου συνόλου χαρακτηριστικών (78 χαρακτηριστικά, χωρίς στάθμιση) και στις πέντε πτυχές διασταυρούμενης επικύρωσης. Κάθε πίνακας εμφανίζει τον συνολικό αριθμό των σωστά και λανθασμένα ταξινομημένων υποκειμένων σε όλες τις πτυχές, παρέχοντας μια οπτική συμπλήρωση των συγκεντρωτικών μετρήσεων που αναφέρονται στις προηγούμενες ενότητες. Οι πραγματικές ετικέτες εμφανίζονται στις σειρές, ενώ οι προβλεπόμενες ετικέτες στις στήλες.

6.7.1 Σύνολο δεδομένων A — ReadText




Figure 6.4: Συγκεντρωτικοί πίνακες σύγχυσης για την εργασία ReadText (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 37$ υποκείμενα). Κάθε κελί αναφέρει τον συνολικό αριθμό εκτός πτυχής και το ποσοστό του σε όλες τις προβλέψεις. Αυτά τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή, δεδομένου του μικρού μεγέθους του δείγματος.

Και οι πέντε ταξινομητές επιτυγχάνουν ανίχνευση PD πάνω από το τυχαίο στο ReadText. Το Random Forest και το SVM (RBF) επιτυγχάνουν τα ισχυρότερα ποσοστά αληθών θετικών, σύμφωνα με το πλεονέκτημά τους στο ROC-AUC. Η λογιστική παλινδρόμηση παρουσιάζει ένα πιο συντηρητικό προφίλ πρόβλεψης, συμβάλλοντας σε υψηλότερη ακρίβεια με κόστος την ανάκληση. Ο μικρός αριθμός υποκειμένων ($n = 37$) περιορίζει τον απόλυτο αριθμό κελιών και αυξάνει τη μεταβλητότητα από πτυχή σε πτυχή.

6.7.2 Σύνολο δεδομένων A — Αυθόρμητος διάλογος




Figure 6.5: Συγκεντρωτικοί πίνακες σύγκρισης για την εργασία αυθόρμητου διαλόγου (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 36$ υποκείμενα). Αυτή η εργασία απέδωσε το υψηλότερο συνολικό ROC-AUC στη μελέτη ($0,857 \pm 0,171$, Random Forest).

Το Random Forest επιδεικνύει βελτιωμένη ανίχνευση PD στον αυθόρμητο διάλογο σε σύγκριση με το ReadText, με υψηλότερο αριθμό αληθών θετικών και λιγότερα ψευδώς αρνητικά. Το μοτίβο σύγκρισης SVM (RBF) αντανακλά την υψηλή διακύμανσή του: ισχυρό σε ορισμένες πτυχές, σχεδόν τυχαίο σε άλλες. Αυτά τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή, δεδομένου του μεγέθους του δείγματος $n = 36$.

6.7.3 Σύνολο δεδομένων B




Figure 6.6: Συγκεντρωτικοί πίνακες σύγκρισης για το σύνολο δεδομένων B (στρωματοποιημένη 5-Fold CV, $n = 756$ εγγραφές). Το σημαντικά μεγαλύτερο μέγεθος του δείγματος αποδίδει καλά διαχωρισμένα μοτίβα σύγκρισης με χαμηλή διακύμανση. Τα αποτελέσματα μπορεί να είναι αισιόδοξα λόγω της άγνωστης επικάλυψης των θεμάτων μεταξύ των πτυχών.

Και οι πέντε ταξινομητές επιτυγχάνουν σημαντικά καλύτερο διαχωρισμό στο σύνολο δεδομένων B, επιβεβαιώνοντας τη θετική επίδραση του μεγέθους του δείγματος στη σταθερότητα του μοντέλου. Το Random Forest, ο ταξινομητής με την καλύτερη απόδοση σε αυτό το σύνολο δεδομένων (ROC-AUC $0,940 \pm 0,013$), παρουσιάζει πολύ λίγα ψευδώς αρνητικά αποτελέσματα σε σχέση με τα αληθώς θετικά. Αυτά τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή λόγω της άγνωστης επικάλυψης υποκειμένων (Ενότητα 8.2.1).

Κεφάλαιο 7

Συζήτηση

7.1 Ερμηνεία βασικών ευρημάτων

7.1.1 Επίδραση της επέκτασης χαρακτηριστικών

Η επέκταση του συνόλου χαρακτηριστικών του ακατέργαστου ήχου από 47 σε 78 χαρακτηριστικά είχε ως αποτέλεσμα σημαντική βελτίωση της απόδοσης, ιδίως για την εργασία ReadText. Με τον ταξινομητή Random Forest, το ROC-AUC αυξήθηκε από $0,590 \pm 0,302$ σε $0,822 \pm 0,166$ (+23 ποσοστιαίες μονάδες), ανεβάζοντας την απόδοση από το επίπεδο της τυχαίας πιθανότητας σε κλινικά σημαντική διάκριση.

Ειδικά αποτελέσματα ανά εργασία:

Table 7.1: Επίδραση της επέκτασης χαρακτηριστικών ανά εργασία. Το Read-Text παρουσίασε δραματικά μεγαλύτερες βελτιώσεις, υποδηλώνοντας ότι τα βασικά χαρακτηριστικά ήταν ανεπαρκή για δομημένη ομιλία.

Μοντέλο	ReadText Δ	Spontaneous Δ	Μέγεθος αποτελέσματος
Random Forest	+23,2pp	+2,9pp	8× μεγαλύτερο
SVM (RBF)	+22,0pp	+5,3pp	4× μεγαλύτερο
Λογιστική παλινδρόμηση	−1,9pp	+2,3pp	Ουδέτερο

Ερμηνεία:

Τα εκτεταμένα χαρακτηριστικά καταγράφουν τρεις συμπληρωματικές πτυχές της δυναμικής της ομιλίας:

Table 7.2: Συνεισφορές εκτεταμένων χαρακτηριστικών

Ομάδα χαρακτηριστικών	Συνεισφορά
Τυπικές αποκλίσεις MFCC	Φασματική μεταβλητότητα εντός της φράσης
Δέλτα-δέλτα MFCC	Δυναμική δεύτερης τάξης (επιτάχυνση)
Περιγραφές φασματικού σχήματος	Παγκόσμια κατανομή φασματικής ενέργειας

Η δυσανάλογη βελτίωση για το ReadText υποδηλώνει ότι:

1. **Η δομημένη ομιλία** (ανάγνωση) απαιτεί πιο λεπτομερή φασματικά χαρακτηριστικά για να καταγράψει μοτίβα ακαμψίας που σχετίζονται με την PD
2. **Η αυθόρμητη ομιλία** περιέχει ήδη επαρκή προσωδιακή μεταβλητότητα που μπορεί να ανιχνευθεί από τα βασικά χαρακτηριστικά
3. **Η χρονική επιτάχυνση** (delta-delta) καταγράφει ελλείμματα κινητικού ελέγχου που είναι πιο εμφανή σε εργασίες ανάγνωσης
4. **Τα γραμμικά μοντέλα** (λογιστική παλινδρόμηση) ενδέχεται να υπερπροσαρμόζονται σε 78 διαστάσεις δεδομένου ότι $n = 37$ υποκείμενα

7.1.2 Επιδράσεις στάθμισης κλάσης

Η στάθμιση κλάσης έδειξε **μέτριες και ασυνεπείς επιδράσεις** στο σύνολο δεδομένων A:

Table 7.3: Επιδράσεις στάθμισης κλάσης

Μοντέλο	Δ ROC-AUC (σταθμισμένο έναντι μη σταθμισμένου)
Random Forest	+3,5pp (βασική γραμμή), -1,4pp (επεκταμένη)
Λογιστική παλινδρόμηση	0,0pp
SVM (RBF)	-1,3pp (βασική γραμμή), -1,4pp (επεκταμένη)

Ερμηνεία:

Η μέτρια ανισορροπία στο σύνολο δεδομένων A (57:43 HC:PD) δεν είναι αρκετά σοβαρή ώστε να υποβαθμίσει σημαντικά τους μη σταθμισμένους ταξινομητές. Η στάθμιση των κλάσεων γίνεται πιο κρίσιμη όταν:

- Η ανισορροπία υπερβαίνει το 70:30
- Η μειοψηφική κλάση έχει υψηλό κόστος εσφαλμένης ταξινόμησης

- Το μέγεθος του δείγματος είναι πολύ μικρό

7.1.3 Ιεραρχία απόδοσης μοντέλου

Σε όλες τις συνθήκες, το Random Forest πέτυχε σταθερά τις υψηλότερες βαθμολογίες μεταξύ των πέντε ταξινομητών που αξιολογήθηκαν:

$$\text{Random Forest} \geq \text{Gradient Boosting} \approx \text{XGBoost} > \text{Logistic Regression} \approx \text{SVM (RBF)}$$

Τα πλεονεκτήματα του Random Forest για αυτή την εργασία περιλαμβάνουν:

1. **Ο μέσος όρος του συνόλου** μειώνει τη διακύμανση σε μικρά σύνολα δεδομένων
2. **Σημασία χαρακτηριστικών** παρέχει ερμηνευσιμότητα
3. **Μη γραμμικά όρια απόφασης** καταγράφουν σύνθετα μοτίβα
4. **Ανθεκτικότητα** σε άσχετα χαρακτηριστικά μέσω υποδειγματοληψίας χαρακτηριστικών

7.1.4 Υψηλή διακύμανση μεταξύ πτυχών

Οι τυπικές αποκλίσεις συχνά ξεπερνούσαν το 0,15 (15%), υποδηλώνοντας σημαντική μεταβλητότητα μεταξύ των πτυχών. Το σύνολο δεδομένων A παρουσίασε διακύμανση 10–15 φορές υψηλότερη από το σύνολο δεδομένων B:

Table 7.4: Σύγκριση διακύμανσης: μικρά έναντι μεγάλων συνόλων δεδομένων. Οι τυπικές αποκλίσεις κλιμακώνονται περίπου ως $1/\sqrt{n}$.

Μέτρηση	Σύνολο δεδομένων A (n=37)	Σύνολο δεδομένων B (n=752)
ROC-AUC std	$\pm 0,15-0,30$	$\pm 0,01-0,03$
Ακρίβεια std	$\pm 0,14-0,18$	$\pm 0,008-0,024$
F1-Score std	$\pm 0,21-0,39$	$\pm 0,006-0,015$

Αιτίες:

1. **Μικρό μέγεθος δείγματος:** 37 άτομα $\rightarrow \sim 7$ άτομα ανά δοκιμαστικό πτυσσόμενο $\rightarrow$ υψηλή ευαισθησία σε μεμονωμένες περιπτώσεις
2. **Ετερογένεια ατόμων:** Άγνωστη κατανομή σοβαρότητας της νόσου (το MDVR-KCL δεν διαθέτει κλινική σταδιοποίηση)

3. **Μεταβλητότητα καταγραφής:** Λήψη με smartphone σε μη ελεγχόμενα περιβάλλοντα
4. **Πολυπλοκότητα εργασίας:** Ο αυθόρμητος διάλογος απαιτεί γνωστικό φορτίο που δεν είναι τυποποιημένο σε όλα τα υποκείμενα

Ακραίες περιπτώσεις:

Ορισμένα μοντέλα παρουσίασαν σχεδόν τυχαία απόδοση σε συγκεκριμένες πτυχές:

- SVM σε αυθόρμητο/βασικό: $0,407 \pm 0,309$ (εύρος ROC-AUC: 0,10–0,72)
- Random Forest σε ReadText/βασικό: $0,590 \pm 0,302$ (εύρος: 0,29–0,89)

Αυτά τα ευρεία εύρη υποδηλώνουν ότι ορισμένες ομάδες θεμάτων στις δοκιμαστικές πτυχές ήταν ιδιαίτερα δύσκολες ή εύκολες στην ταξινόμηση.

Συνέπειες:

- Οι απόλυτοι αριθμοί απόδοσης πρέπει να ερμηνεύονται με προσοχή, δεδομένου του μικρού μεγέθους του δείγματος ($n = 37$)
- Οι **σχετικές συγκρίσεις** μεταξύ των συνθηκών (ίδια διαχωρίσματα CV) είναι πιο αξιόπιστες
- Τα διαστήματα εμπιστοσύνης αλληλεπικαλύπτονται για πολλές συγκρίσεις μοντέλων, περιορίζοντας τα στατιστικά συμπεράσματα
- Απαιτούνται μεγαλύτερες μελέτες ($n > 100$) για την οριστική κατάταξη των μοντέλων

7.2 Σύγκριση με τη βιβλιογραφία

7.2.1 Πλαίσιο απόδοσης

Table 7.5: Σύγκριση με τη βιβλιογραφία

Μελέτη	Σύνολο δεδομένων	Καλύτερο ROC-AUC	Μέθοδος
Little et al. (2009)	UCI	0,92	SVM
Sakar et al. (2013)	Προσαρμοσμένο	0,86	SVM
Αυτή η εργασία	MDVR-KCL	0,87	RF

Τα αποτελέσματά μας είναι ανταγωνιστικά με τη βιβλιογραφία, αν και η άμεση σύγκριση είναι περιορισμένη λόγω:

- Διαφορετικά σύνολα δεδομένων και χαρακτηριστικά
- Διαφορετικές στρατηγικές CV (πολλές μελέτες δεν χρησιμοποιούν ομαδοποιημένο CV)
- Διαφορετικά μεγέθη δειγμάτων

7.2.2 Μεθοδολογική σύγκριση

Table 7.6: Μεθοδολογική σύγκριση. Η παρούσα εργασία δίνει προτεραιότητα στην αναπαραγωγιμότητα και στις συντηρητικές εκτιμήσεις γενίκευσης.

Πτυχή	Τυπική βιβλιογραφία	Αυτή η εργασία
Στρατηγική CV	Τυχαία διαίρεση	Ομαδοποιημένη στρωματοποίηση
Χειρισμός θεμάτων	Συχνά αγνοείται	Ρητή ομαδοποίηση
Επιλογή χαρακτηριστικών	Ad-hoc	Συστηματική αφαίρεση
Αναφορά	Μόνο τα καλύτερα αποτελέσματα	Όλες οι συνθήκες + διακύμανση
Ανισορροπία κλάσεων	Συχνά δεν αντιμετωπίζεται	Ρητή αξιολόγηση
Προδιαγραφές εργασιών	Μικτές/μη δηλωμένες	Διαχωρισμένες + συγκριτικές

Σε σύγκριση με την τυπική πρακτική της βιβλιογραφίας, η παρούσα εργασία χρησιμοποιεί ομαδοποιημένη στρωματοποιημένη CV (όλες οι καταγραφές ανά υποκείμενο στην ίδια πτυχή), αναφέρει όλες τις πειραματικές συνθήκες με μέσο όρο $\pm$ std και τεκμηριώνει τα αρνητικά αποτελέσματα. Όπως αιτιολογείται στην ενότητα 4.5.1, η 5-πλήρης CV χωρίς ξεχωριστό σύνολο που κρατείται είναι κατάλληλη εδώ: με $n = 37$ υποκείμενα, ένα 20% που κρατείται θα απέφερε περίπου επτά υποκείμενα δοκιμής ανά πτυχή—πολύ λίγα για σταθερή εκτίμηση μετρήσεων.

7.3 Ανάλυση σημασίας χαρακτηριστικών

7.3.1 Χαρακτηριστικά με τη μεγαλύτερη διακριτική ικανότητα (σύνολο δεδομένων A)

Τα μοτίβα σημασίας των χαρακτηριστικών διέφεραν μεταξύ των εργασιών, αντανακλώντας διακριτά ακουστικά χαρακτηριστικά:

Table 7.7: Τα 5 κορυφαία χαρακτηριστικά του Random Forest ανά εργασία (Εκτεταμένο σύνολο χαρακτηριστικών). Οι τιμές σημασίας αντιπροσωπεύουν τη μέση μείωση της ακαθαρσίας.

Κατάταξη	ReadText	Σημασία	Αυθόρμητος διάλογος
1	f0_max	0,052	mfcc_5_mean
2	delta_mfcc_2_mean	0,039	shimmer_apq11
3	f3_std	0,038	delta_mfcc_8_mean
4	autocorr_harmonicity	0,038	jitter_local
5	intensity_mean	0,035	delta_mfcc_2_mean

Μοτίβα ειδικά για κάθε εργασία:

- **ReadText:** Κυριαρχείται από την μεταβλητότητα του τόνου (f0_max) και των φωνητικών συχνοτήτων (f3_std), υποδηλώνοντας ότι η δομημένη ομιλία δίνει έμφαση στην ακαμψία της θεμελιώδους συχνότητας
- **Spontaneous:** Τα φασματικά χαρακτηριστικά (mfcc_5) και τα μέτρα διαταραχής (shimmer_apq11, jitter_local) υποδηλώνουν τη σημασία της αστάθειας της ποιότητας της φωνής
- **Κοινά:** Το delta_mfcc_2_mean εμφανίζεται και στις δύο λίστες των 5 κορυφαίων χαρακτηριστικών, επιβεβαιώνοντας ότι η χρονική δυναμική είναι καθολικά σημαντική

7.3.2 Πολυπλοκότητα χαρακτηριστικών του συνόλου δεδομένων B

Table 7.8: Κορυφαία 5 χαρακτηριστικά του συνόλου δεδομένων B (Random Forest). Αυτές οι προηγμένες μετρήσεις επεξεργασίας σήματος δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.

Χαρακτηριστικό	Σημασία	Κατηγορία
std_delta_log_energy	0,0133	Δυναμική ενέργειας
std_delta_delta_log_energy	0,0132	Επιτάχυνση ενέργειας
tqwt_entropy_shannon_dec_12	0,0117	Εντροπία κυματιδίων
tqwt_TKEO_std_dec_11	0,0098	Ενέργεια Teager
tqwt_TKEO_mean_dec_12	0,0096	Ενέργεια Teager

Τα κορυφαία χαρακτηριστικά του συνόλου δεδομένων B βασίζονται σε εξειδικευμένη επεξεργασία σήματος (αποσύνθεση κυματιδίων, τελεστές ενέργειας Teager) που δεν είναι διαθέσιμη σε τυπικά κλινικά περιβάλλοντα. Η πλήρης κατάταξη των χαρακτηριστικών παρέχεται στο Παράρτημα A.

7.4 Μοτίβα απόδοσης που εξαρτώνται από την εργασία

7.4.1 ReadText έναντι αυθόρμητου διαλόγου

Οι δύο εργασίες ομιλίας απέδωσαν συστηματικά διαφορετικά προφίλ ταξινόμησης:

Table 7.9: Σύγκριση εργασιών μεταξύ διαμορφώσεων. Ο αυθόρμητος διάλογος γενικά υπερτερεί του ReadText, εκτός από το SVM σε εκτεταμένες λειτουργίες.

Διαμόρφωση	ReadText	Spontaneous	Πλεονέκτημα
Βασικά χαρακτηριστικά:			
Random Forest ROC-AUC	$0,590 \pm 0,302$	$0,828 \pm 0,148$	Αυθόρμητος
Λογιστική παλινδρόμηση	$0,717 \pm 0,139$	$0,760 \pm 0,214$	Αυθόρμητη
Εκτεταμένα χαρακτηριστικά:			
Random Forest ROC-AUC	$0,822 \pm 0,166$	$0,857 \pm 0,171$	Αυθόρμητο
SVM (RBF)	$0,834 \pm 0,153$	$0,460 \pm 0,294$	ReadText

Ερμηνεία:

1. **Κυριαρχία της αυθόρμητης ομιλίας:** Η μη προδιαγεγραμμένη ομιλία μπορεί να ενισχύσει τα προβλήματα προσωδικής έκφρασης που σχετίζονται με την PD (μονότονη, μειωμένη μεταβλητότητα)
2. **Υπόθεση γνωστικού φορτίου:** Το Spontaneous Dialogue απαιτεί ταυτόχρονη παραγωγή και άρθρωση γλώσσας, τονίζοντας τον κινητικό έλεγχο
3. **Ανωμαλία SVM:** Η αποτυχία του SVM στην αυθόρμητη/εκτεταμένη ομιλία ($0,460 \pm 0,294$) υποδηλώνει ευαισθησία του πυρήνα στις μεταβολές της κατανομής των χαρακτηριστικών
4. **Επάρκεια βασικής γραμμής:** Ο αυθόρμητος διάλογος πέτυχε 0,828 με τα βασικά χαρακτηριστικά, ενώ το ReadText χρειάστηκε επέκταση για να φτάσει το 0,822

Κλινικές επιπτώσεις:

Για εφαρμογές διαλογής με περιορισμένους πόρους:

- **Αυθόρμητη ομιλία + βασικά χαρακτηριστικά** (47 διαστάσεις) επιτυγχάνει ανταγωνιστική απόδοση (0,83) με χαμηλότερο υπολογιστικό κόστος
- Το ReadText απαιτεί εκτεταμένη μηχανική χαρακτηριστικών για αποδεκτή διάκριση

Κεφάλαιο 8

Περιορισμοί και απειλές για την εγκυρότητα

8.1 Περιορισμοί μεγέθους δείγματος

8.1.1 Σύνολο δεδομένων A: Μικρός αριθμός συμμετεχόντων

Table 8.1: Μετρήσεις μεγέθους δείγματος συνόλου δεδομένων A

Μέτρηση	Τιμή
Σύνολο υποκειμένων (ReadText)	37
Σύνολο υποκειμένων (SpontaneousDialogue)	36
Συμμετέχοντες ανά δοκιμαστικό πτυσσόμενο	~7–8
Συμμετέχοντες με PD (μειοψηφία)	15–16
Συμμετέχοντες HC (πλειοψηφία)	21

Επιπτώσεις:

- Υψηλή διακύμανση στις μετρήσεις σε επίπεδο δοκιμαστικού πτυσσώματος (std > 0,15 συνήθως)
- Περιορισμένη στατιστική ισχύς για την ανίχνευση μικρών επιδράσεων
- Τα αποτελέσματα ενδέχεται να μην μπορούν να γενικευτούν σε ευρύτερους πληθυσμούς

8.2 Περιορισμοί αναγνωριστικών υποκειμένων

8.2.1 Σύνολο δεδομένων B: Ελλείπουσες ταυτότητες υποκειμένων

Το σύνολο δεδομένων B περιέχει 756 δείγματα (192 HC, 564 PD) χωρίς αναγνωριστικά υποκειμένων. Αυτό δημιουργεί πιθανότητες για:

- **Διαρροή υποκειμένων:** Πολλαπλά δείγματα του ίδιου υποκειμένου σε σύνολα εκπαίδευσης και δοκιμής
- **Αισιόδοξη μεροληψία:** Υπερβολικές εκτιμήσεις απόδοσης λόγω συσχέτισης εντός του υποκειμένου
- **Άγνωστη γενίκευση:** Δεν είναι δυνατή η αξιολόγηση της απόδοσης νέων υποκειμένων
- **Σοβαρή ανισορροπία κλάσεων:** Αναλογία HC:PD 1:2,94 (σε σύγκριση με 1,3:1 στο σύνολο δεδομένων A)

Προειδοποίηση: Τα αποτελέσματα στο σύνολο δεδομένων B ενδέχεται να είναι αισιόδοξα λόγω της άγνωστης επικάλυψης υποκειμένων μεταξύ των πτυχών. Η απουσία αναγνωριστικών υποκειμένων εμποδίζει την επικύρωση της πραγματικής γενίκευσης εκτός υποκειμένου. Η σοβαρή ανισορροπία κλάσεων (74,6% PD) περιπλέκει περαιτέρω την ερμηνεία.

8.2.2 Περιορισμοί σύγκρισης

Η άμεση σύγκριση μεταξύ συνόλων δεδομένων περιπλέκεται από διαφορετικές στρατηγικές CV, μεγέθη δειγμάτων, εργασίες ομιλίας, pipelines χαρακτηριστικών και αναλογίες ανισορροπίας κλάσεων. Βλ. Προειδοποίηση [8.2.1](#).

8.3 Περιορισμοί εξαγωγής χαρακτηριστικών

8.3.1 Δετερμινιστικό σύνολο χαρακτηριστικών

Το σύνολο χαρακτηριστικών σχεδιάστηκε εκ των προτέρων με βάση βιβλιογραφική ανασκόπηση και όχι βελτιστοποίηση βάσει δεδομένων. Οι περιορισμοί περιλαμβάνουν:

- **Πιθανώς μη βέλτιστα χαρακτηριστικά:** Άλλα χαρακτηριστικά μπορεί να είναι πιο διακριτικά

- **Σταθερές παράμετροι:** Εύρος F0 75–500 Hz, MFCC $n_coeffs=13$, $n_fft=2048$, $hop_length=512$
- **Χωρίς επιλογή χαρακτηριστικών:** Όλα τα 47 (βασικά) ή 78 (επεκταμένα) χαρακτηριστικά χρησιμοποιούνται χωρίς μείωση
- **Χωρίς μηχανική χαρακτηριστικών:** Χωρίς όρους αλληλεπίδρασης, πολωνυμικά χαρακτηριστικά ή μετασχηματισμούς συγκεκριμένου τομέα

8.3.2 Υποθέσεις ποιότητας ήχου

Η εξαγωγή χαρακτηριστικών προϋποθέτει:

- Λογική αναλογία σήματος προς θόρυβο
- Συνεπείς συνθήκες εγγραφής (Σύνολο δεδομένων A: κλινική αίθουσα εξέτασης, ~500 ms αντήχηση)
- Χωρίς σοβαρό κλιπ ή παραμόρφωση
- Μονοφωνικός ήχος στα 22050 Hz (Σύνολο δεδομένων A υποδειγματοληπτικό από 44100 Hz)

Οι συνθήκες εγγραφής του συνόλου δεδομένων B είναι άγνωστες.

8.4 Περιορισμοί μοντέλου

8.4.1 Χωρίς ρύθμιση υπερπαραμέτρων

Όλα τα μοντέλα χρησιμοποίησαν τις προεπιλεγμένες υπερπαραμέτρους του sklearn με μόνο τυχαία σπορά και στάθμιση κλάσης ως ελεγχόμενες μεταβλητές:

Table 8.2: Σταθερές υπερπαραμέτροι (όλα τα πειράματα)

Μοντέλο	Σταθερές παράμετροι
Λογιστική παλινδρόμηση	$C = 1,0$, $max_iter = 1000$, $solver='lbfgs'$
SVM (RBF)	$C = 1,0$, $gamma='scale'$ (αυτόματος υπολογισμός)
Random Forest	$n_estimators = 100$, $max_depth=None$ (απεριόριστο)

Συνέπειες:

- Η απόδοση μπορεί να είναι υποβέλτιστη σε σύγκριση με τις ρυθμισμένες βασικές γραμμές

- Τα αποτελέσματα αντιπροσωπεύουν την απόδοση του sklearn χωρίς προσαρμογές
- Η ρύθμιση των υπερπαραμέτρων μπορεί να αλλάξει τη σχετική κατάταξη των μοντέλων
- Η στάθμιση των κλάσεων εξετάζεται ξεχωριστά (σημαία USE_CLASS_WEIGHT_BALANCED)

Λογική: Η ένθετη CV σε 37 υποκείμενα θα οδηγούσε σε ακραία διακύμανση (εσωτερικές πτυχές ~5–6 υποκείμενα). Οι σταθερές παράμετροι εξασφαλίζουν την αναπαραγωγιμότητα και τη δίκαιη σύγκριση των μοντέλων.

8.5 Μεθοδολογικοί περιορισμοί

8.5.1 Χωρίς εξωτερική επικύρωση

Όλα τα αποτελέσματα χρησιμοποιούν εσωτερική διασταυρούμενη επικύρωση (5-fold) χωρίς εξωτερικά σύνολα δοκιμών. Περιορισμοί:

- Δεν υπάρχει σύνολο δοκιμών από διαφορετική πηγή δεδομένων ή πρωτόκολλο συλλογής
- Δεν υπάρχει επικύρωση σε πολλαπλές τοποθεσίες (σύνολο δεδομένων A: ένα νοσοκομείο, σύνολο δεδομένων B: ένα ίδρυμα)
- Γενίκευση σε κλινικά περιβάλλοντα με διαφορετικές συσκευές εγγραφής άγνωστη
- Χρονική σταθερότητα μη αξιολογημένη (όλες οι εγγραφές από ένα μόνο χρονικό σημείο ανά υποκείμενο)
- Γενίκευση μεταξύ γλωσσών και διαλέκτων μη αξιολογημένη

Αιτιολόγηση: Βλ. ενότητα [4.5.1](#).

8.5.2 Χειρισμός ανισορροπίας κλάσεων

Η ανισορροπία κλάσεων ήταν παρούσα και στα δύο σύνολα δεδομένων:

- Σύνολο δεδομένων A: Αναλογία HC:PD 1,31:1 (ReadText) και 1,40:1 (SpontaneousDialogue)
- Σύνολο δεδομένων B: Αναλογία HC:PD 1:2,94 (σοβαρή ανισορροπία)

Η σημαία `USE_CLASS_WEIGHT_BALANCED` εξετάστηκε ως στρατηγική μετριασμού, αλλά:

- Δεν βελτίωσε συστηματικά την απόδοση σε όλους τους δείκτες
- Ενδέχεται να αύξησε τη διακύμανση σε ορισμένες συνθήκες
- Η βέλτιστη στρατηγική στάθμισης μπορεί να διαφέρει ανάλογα με το μοντέλο και το σύνολο δεδομένων

Εναλλακτικές προσεγγίσεις που δεν διερευνήθηκαν: SMOTE, υποδειγματοληψία, μάθηση ευαίσθητη στο κόστος ή προσαρμογή κατωφλίου.

8.6 Απειλές για την εγκυρότητα

8.6.1 Εσωτερική εγκυρότητα

Table 8.3: Απειλές εσωτερικής εγκυρότητας

Απειλή	Κατάσταση	Μείωση
Διαρροή υποκειμένου Διαρροή υποκειμένου	Ελεγχόμενη (σύνολο δεδομένων A) Μη ελεγχόμενη (σύνολο δεδομένων B)	GroupedStratifiedKFold Δεν υπάρχουν δια- αναγνωριστικά υποκειμένου
Θόρυβος ετικέτας Σφάλματα εξαγωγής χαρακτηριστικών	Άγνωστος Μετριασμένα	Θεωρείται σωστός Δοκιμές μονάδων χειροκίνητη επαλήθευση RANDOM_SEED=42 (σταθερή)
Τυχαία εξάρτηση από σπόρο	Ελεγχόμενη	
Σφάλματα προεπεξεργασίας δεδομένων	Μετριασμένα	Τυποποιημένη κανονικοποίηση ήχο

8.6.2 Εξωτερική εγκυρότητα

Table 8.4: Απειλές εξωτερικής εγκυρότητας

Απειλή	Κατάσταση	Μείωση
Μεροληψία πληθυσμού	Πιθανή	Δημογραφικά στοιχεία συνόλου δεδομένων εγγράφων
Μεταβλητότητα εγγραφής Χρονική σταθερότητα	Παρούσα Άγνωστη	Τυποποιημένη εξαγωγή Ενιαία συνεδρία εγγραφής

Κεφάλαιο 9

Συμπέρασμα

9.1 Περίληψη της εργασίας

Η παρούσα εργασία διερεύνησε την ταξινόμηση με βάση τη φωνή της νόσου του Πάρκινσον (PD) σε σύγκριση με υγιείς μάρτυρες (HC) χρησιμοποιώντας κλασικές μεθόδους μηχανικής μάθησης. Η εργασία ασχολήθηκε με βασικές μεθοδολογικές προκλήσεις στον τομέα, όπως διαρροή δεδομένων σε επίπεδο υποκειμένου, ανισορροπία κλάσεων και αναπαράσταση χαρακτηριστικών.

9.1.1 Συνεισφορές

1. **Αυστηρό πλαίσιο αξιολόγησης:** Ομαδοποιημένη στρωματοποιημένη διασταυρούμενη επικύρωση με συστηματικό σχεδιασμό 2×2 (χαρακτηριστικά $\times$ στάθμιση κατηγοριών) και διαφανή αναφορά σε όλες τις συνθήκες.
2. **Έρευνα μηχανικής χαρακτηριστικών:** Επέκταση του συνόλου χαρακτηριστικών από 47 σε 78 ακουστικά χαρακτηριστικά, επιδεικνύοντας βελτίωση έως +23pp ROC-AUC και προσδιορίζοντας τα F_0 , MFCCs και την αρμονικότητα ως τα πιο διακριτικά.
3. **Ανάλυση στάθμισης κλάσης:** Αξιολόγηση `class_weight=«balanced»` σε όλα τα μοντέλα, διαπιστώνοντας μέτρια και ασυνεπή αποτελέσματα σε μέτρια ανισορροπημένα δεδομένα.
4. **Αναπαραγώγιμη ροή εργασιών:** Εργαλεία CLI, σταθεροποιημένοι τυχαίοι σπόροι, τεκμηριωμένες παράμετροι και μια διεπαφή επίδειξης έρευνας χωρίς διαγνωστικά στοιχεία (Παράρτημα C).

9.2 Βασικά ευρήματα

9.2.1 Πρωταρχικά αποτελέσματα

Table 9.1: Κύρια ευρήματα της έρευνας (σύνολο δεδομένων A, στάθμιση βασικής κατηγορίας)

Εύρημα	Απόδειξη
Καλύτερο ROC-AUC (σύνολο δεδομένων A): $0,857 \pm 0,171$	Random Forest, Extended Features, SpontaneousDialogue
Η επέκταση χαρακτηριστικών βελτιώνει το RF	ReadText: +23,3pp ROC-AUC; SpontaneousDialogue: +2,9pp ROC-AUC
Το Random Forest δείχνει ανθεκτικότητα	Υψηλότερο ή ανταγωνιστικό ROC-AUC σε όλες τις εργασίες
Το ομαδοποιημένο CV είναι απαραίτητο	Αποτρέπει την αισιόδοξη μεροληψία από τη διαρροή υποκειμένων
Παρατηρήθηκε υψηλή διακύμανση	Τυπικές αποκλίσεις 0,13–0,43 σε όλες τις μετρήσεις

Η καλύτερη απόδοση συνοψίζεται στον Πίνακα 9.1· οι πλήρεις κατατάξεις σημασίας ανά μοντέλο βρίσκονται στο Παράρτημα A.

9.3 Απαντηθέντα ερευνητικά ερωτήματα

9.3.1 RQ1: Πώς αποδίδουν τα κλασικά μοντέλα ML στην ταξινόμηση φωνής PD;

Το κλασικό ML επιτυγχάνει **ROC-AUC έως** $0,857 \pm 0,171$ (Random Forest, εκτεταμένα χαρακτηριστικά, SpontaneousDialogue) στο σύνολο δεδομένων A με ομαδοποιημένη διασταυρούμενη επικύρωση. Ωστόσο, η απόδοση ποικίλλει σημαντικά:

- ReadText: 0,590–0,834 ROC-AUC (βασικά χαρακτηριστικά, σε όλα τα μοντέλα)
- SpontaneousDialogue: 0,407–0,857 ROC-AUC (βασικά → εκτεταμένα, RF)
- Μεγάλη διακύμανση λόγω μικρού μεγέθους δείγματος ($n = 37$ άτομα)
- Ορισμένες πτυχές SVM παρήγαγαν ROC-AUC $< 0,5$, υποδηλώνοντας αστάθεια

Αυτό αποδεικνύει τη **εφικτότητα** της ταξινόμησης PD με βάση τη φωνή, αλλά υπογραμμίζει την **πρόκληση** της σταθερής απόδοσης σε μικρά σύνολα δεδομένων.

9.3.2 RQ2: Η επέκταση του συνόλου χαρακτηριστικών βελτιώνει την απόδοση της ταξινόμησης;

Εξαρτάται από την εργασία. Επέκταση από 47 βασικά σε 78 εκτεταμένα χαρακτηριστικά:

ReadText (Random Forest):

- Βασική γραμμή: $0,590 \pm 0,302$ ROC-AUC
- Επεκταμένα: $0,822 \pm 0,166$ ROC-AUC
- Βελτίωση: +23,3 ποσοστιαίες μονάδες (+39% σχετική)
- Η διακύμανση μειώθηκε από 0,302 σε 0,166

SpontaneousDialogue (Random Forest):

- Βασική γραμμή: $0,828 \pm 0,148$ ROC-AUC
- Επεκταμένη: $0,857 \pm 0,171$ ROC-AUC
- Βελτίωση: +2,9 ποσοστιαίες μονάδες (μέτρια)

Τα πρόσθετα χαρακτηριστικά που καταγράφουν τη φασματική μεταβλητότητα (MFCC std), τη χρονική δυναμική (delta-delta MFCC) και το φασματικό σχήμα συνέβαλαν σημαντικά στην απόδοση του ReadText. Τα αποτελέσματα ήταν λιγότερο έντονα για το SpontaneousDialogue, πιθανώς λόγω της υψηλότερης μεταβλητότητας της βασικής γραμμής στην αυθόρμητη ομιλία.

9.3.3 RQ3: Βελτιώνει η στάθμιση των κλάσεων την απόδοση σε μη ισορροπημένα σύνολα δεδομένων;

Παρατηρήθηκαν ελάχιστα αποτελέσματα. Στο σύνολο δεδομένων A (αναλογία HC:PD 1,31:1 για το ReadText, 1,40:1 για το SpontaneousDialogue), η στάθμιση των κλάσεων έδειξε ασυνεπή αποτελέσματα:

ReadText (Random Forest, εκτεταμένα χαρακτηριστικά):

- Χωρίς στάθμιση: $0,822 \pm 0,166$ ROC-AUC
- Με στάθμιση: $0,805 \pm 0,182$ ROC-AUC
- Αλλαγή: -1,7pp (ελαφρά μείωση)

SpontaneousDialogue (Random Forest, βασικά χαρακτηριστικά):

- Χωρίς στάθμιση: $0,828 \pm 0,148$ ROC-AUC
- Με στάθμιση: $0,827 \pm 0,133$ ROC-AUC
- Αλλαγή: $-0,1pp$ (αμελητέα)

Η μέτρια ανισορροπία (1,3:1) μπορεί να μην είναι αρκετά σοβαρή ώστε να ωφεληθεί από τη στάθμιση. Επιπλέον, με μόνο 37 άτομα, η στάθμιση των κατηγοριών μπορεί να εισαγάγει επιπλέον διακύμανση. Τα αποτελέσματα ποίκιλαν μεταξύ των μοντέλων και των συνόλων χαρακτηριστικών, χωρίς να υπάρχει σταθερό μοτίβο βελτίωσης.

9.3.4 RQ4: Πώς συγκρίνονται τα αποτελέσματα μεταξύ της ομαδοποιημένης και της τυπικής CV;

Σύνολο δεδομένων A (ομαδοποιημένη CV, $n = 37$ άτομα):

- Random Forest: 0,590–0,857 ROC-AUC
- Υψηλή διακύμανση (std 0,15–0,30)
- Γενίκευση σε επίπεδο υποκειμένου

Σύνολο δεδομένων B (Τυπική CV, $n = 756$ δείγματα, άγνωστα αναγνωριστικά υποκειμένων):

- Random Forest: 0,940–0,949 ROC-AUC (βασική γραμμή/σταθμισμένη)
- Χαμηλή διακύμανση (std 0,012–0,013)
- Άγνωστη συσχέτιση εντός υποκειμένου

Το σύνολο δεδομένων B παρουσιάζει σημαντικά υψηλότερη απόδοση (+8–12pp ROC-AUC) και χαμηλότερη διακύμανση, σε συμφωνία με την πιθανή αισιόδοξη μεροληψία από τη διαρροή υποκειμένων. **Η ομαδοποιημένη CV παρέχει πιο συντηρητικές αλλά πιο ρεαλιστικές εκτιμήσεις** της γενίκευσης εκτός υποκειμένου. Η σύγκριση περιπλέκεται από διαφορετικά μεγέθη δειγμάτων, χώρους χαρακτηριστικών και εργασίες ομιλίας, περιορίζοντας την άμεση ερμηνεία.

9.3.5 RQ5: Οι εργασίες ομιλίας αποδίδουν διαφορετική απόδοση ταξινόμησης;

Τα βασικά χαρακτηριστικά παρουσιάζουν διαφορές στις εργασίες:

- ReadText: $0,590 \pm 0,302$ ROC-AUC (Random Forest, βασική γραμμή)
- SpontaneousDialogue: $0,828 \pm 0,148$ ROC-AUC (Random Forest, βασική γραμμή)

- Διαφορά: +23,8pp υπέρ της αυθόρμητης ομιλίας

Τα εκτεταμένα χαρακτηριστικά μειώνουν το χάσμα:

- ReadText: $0,822 \pm 0,166$ (εκτεταμένο)
- SpontaneousDialogue: $0,857 \pm 0,171$ (επεκταμένο)
- Διαφορά: +3,5pp (συγκλίνουσα)

Το SpontaneousDialogue μπορεί να καταγράψει τα φυσιολογικά χαρακτηριστικά της ομιλίας PD (μονοτονική προσωδία, μειωμένη μεταβλητότητα) πιο αποτελεσματικά από την δομημένη ανάγνωση. Ωστόσο, το ReadText επωφελείται περισσότερο από την επέκταση χαρακτηριστικών, πιθανώς επειδή τα επεκταμένα χαρακτηριστικά καταγράφουν καλύτερα τη δομημένη δυναμική της ομιλίας.

9.4 Επιπτώσεις

9.4.1 Για ερευνητές

- **Χρησιμοποιήστε ομαδοποιημένο CV** όταν υπάρχουν πολλαπλές ηχογραφήσεις ανά θέμα
- **Συμπεριλάβετε χαρακτηριστικά μεταβλητότητας** (std, delta-delta) στα σύνολα χαρακτηριστικών
- **Αναφέρετε όλες τις συνθήκες** αντί να επιλέγετε τα καλύτερα αποτελέσματα
- **Αναγνωρίστε τους περιορισμούς** με διαφάνεια

9.4.2 Για τους επαγγελματίες

- Η φωνητική εξέταση για την PD είναι εφικτή, αλλά δεν έχει ακόμη κλινική αξιοπιστία
- Το Random Forest παρέχει μια ισχυρή βάση για παρόμοιες εργασίες
- Η ερμηνευσιμότητα των χαρακτηριστικών υποστηρίζει την κλινική κατανόηση
- Τα αποτελέσματα απαιτούν επικύρωση σε ανεξάρτητες ομάδες

9.4.3 Για τους δημιουργούς συνόλων δεδομένων

- **Πάντα να περιλαμβάνετε αναγνωριστικά υποκειμένων** για να επιτρέψετε τη σωστή CV

- Τεκμηριώστε τις συνθήκες και τον εξοπλισμό καταγραφής
- Παρέχετε δημογραφικές πληροφορίες
- Εξετάστε το ενδεχόμενο διαχρονικών σχεδίων

9.5 Μελλοντικές κατευθύνσεις

Οι βραχυπρόθεσμες επεκτάσεις περιλαμβάνουν βελτιστοποίηση υπερπαραμέτρων με ένθετη διασταυρούμενη επικύρωση, επιλογή χαρακτηριστικών για τη μείωση της διαστατικότητας, σύνθεση πολλαπλών εργασιών (συνδυασμός ReadText και SpontaneousDialogue) και πρόσθετα ακουστικά χαρακτηριστικά (wavelets, TQWT). Η μεσοπρόθεσμη έρευνα θα πρέπει να δώσει προτεραιότητα στην εξωτερική επικύρωση σε ανεξάρτητες κοόρτες, στη διαχρονική παρακολούθηση της εξέλιξης της νόσου και στην ταξινόμηση της σοβαρότητας σε πολλές κατηγορίες. Μακροπρόθεσμα, η φωνητική παρακολούθηση της νόσου του Πάρκινσον θα μπορούσε να ενσωματωθεί σε εφαρμογές για smartphone μαζί με πολυτροπικούς βιοδείκτες (φωνή, βάδισμα, τρόμος) και να υποβληθεί σε προοπτική κλινική επικύρωση.

9.6 Τελικές παρατηρήσεις

Η παρούσα εργασία αποδεικνύει ότι **η ταξινόμηση της νόσου του Πάρκινσον με βάση τη φωνή είναι εφικτή** χρησιμοποιώντας κλασική μηχανική μάθηση με προσεκτικά σχεδιασμένα ακουστικά χαρακτηριστικά, επιτυγχάνοντας ROC-AUC έως 0,857 στο σύνολο δεδομένων A με ομαδοποιημένη διασταυρούμενη επικύρωση. Δίνοντας προτεραιότητα στην **μεθοδολογική εγκυρότητα έναντι της βελτιστοποίησης της απόδοσης**—διαφανείς διαχωρισμοί σε επίπεδο υποκειμένου, σταθερές παράμετροι και πλήρης αναφορά διακύμανσης—η εργασία αυτή παρέχει μια επαναλήψιμη βάση πάνω στην οποία μελλοντικές μελέτες μπορούν να αντιμετωπίσουν τους προσδιορισμένους περιορισμούς του μικρού μεγέθους του δείγματος, της απουσίας εξωτερικής επικύρωσης και του δυαδικού πεδίου εφαρμογής.

Παράρτημα Α

Feature Importance Tables

A.1 Overview

This appendix presents the top-20 most important features for each experimental condition, as determined by model-native importance measures:

- **Logistic Regression:** Absolute coefficient values
- **Random Forest:** Gini importance (mean decrease in impurity)

A.2 Dataset A — ReadText Task

A.2.1 Random Forest — Top 20 Features

Rank	Feature	Importance	Std
1	f0_max	0.052	0.019
2	delta_mfcc_2_mean	0.039	0.018
3	f3_std	0.038	0.011
4	autocorr_harmonicity	0.038	0.017
5	intensity_mean	0.035	0.021
6	f0_mean	0.032	0.012
7	shimmer_apq3	0.032	0.013
8	mfcc_12_mean	0.031	0.007
9	f1_std	0.031	0.022
10	mfcc_6_mean	0.030	0.024

Table A.1: Random Forest feature importance — ReadText (top 10)

A.2.2 Logistic Regression — Top 20 Features

Rank	Feature	Coefficient	Std
1	f0_max	0.754	0.203
2	hnr_mean	0.649	0.178
3	shimmer_apq11	0.553	0.145
4	delta_mfcc_4_mean	0.496	0.163
5	delta_mfcc_2_mean	0.492	0.103
6	delta_mfcc_1_mean	0.474	0.273
7	mfcc_5_mean	0.470	0.127
8	mfcc_4_mean	0.426	0.233
9	mfcc_10_mean	0.418	0.221
10	mfcc_11_mean	0.388	0.192

Table A.2: Logistic Regression feature importance — ReadText (top 10)




Figure A.1: Logistic Regression coefficient magnitudes (ReadText)

A.2.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.229	0.179
2	mfcc_4_mean	0.084	0.187
3	f1_std	0.080	0.178
4	mfcc_6_mean	0.066	0.143
5	intensity_min	0.064	0.122
6	mfcc_2_mean	0.060	0.133
7	f0_std	0.055	0.081
8	f3_std	0.054	0.070
9	delta_mfcc_10_mean	0.047	0.104
10	delta_mfcc_2_mean	0.041	0.083

Table A.3: Gradient Boosting feature importance — ReadText (top 10)




Figure A.2: Gradient Boosting feature importances (ReadText). F0 max dominates strongly (0.229 ± 0.179), consistent with pitch dysregulation in PD.

A.2.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.083	0.028
2	intensity_min	0.064	0.063
3	f0_mean	0.063	0.044
4	f3_std	0.061	0.044
5	intensity_mean	0.051	0.047
6	delta_mfcc_10_mean	0.041	0.037
7	f1_std	0.041	0.075
8	delta_mfcc_2_mean	0.038	0.028
9	mfcc_3_mean	0.033	0.023
10	mfcc_11_mean	0.031	0.040

Table A.4: XGBoost feature importance — ReadText (top 10)




Figure A.3: XGBoost feature importances (ReadText). Importance is more distributed than Gradient Boosting, with F0 and intensity features sharing dominance.

A.3 Dataset A — SpontaneousDialogue Task

A.3.1 Random Forest — Top 20 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.080	0.022
2	shimmer_apq11	0.069	0.007
3	delta_mfcc_8_mean	0.051	0.015
4	jitter_local	0.041	0.012
5	delta_mfcc_2_mean	0.040	0.018
6	autocorr_harmonicity	0.037	0.011
7	shimmer_local	0.036	0.017
8	mfcc_1_mean	0.034	0.010
9	f0_std	0.032	0.022
10	f0_mean	0.031	0.013

Table A.5: Random Forest feature importance — SpontaneousDialogue (top 10)

A.3.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	mfcc_5_mean	0.722	0.039
2	delta_mfcc_8_mean	0.615	0.121
3	shimmer_apq11	0.559	0.136
4	delta_mfcc_2_mean	0.493	0.196
5	intensity_min	0.459	0.170
6	mfcc_3_mean	0.388	0.271
7	delta_mfcc_11_mean	0.381	0.102
8	delta_mfcc_7_mean	0.380	0.150
9	hnr_mean	0.379	0.175
10	delta_mfcc_1_mean	0.352	0.123

Table A.6: Logistic Regression feature importance — SpontaneousDialogue (top 10)




Figure A.4: Logistic Regression coefficient magnitudes (Spontaneous Dialogue)

A.3.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.342	0.204
2	shimmer_apq11	0.134	0.132
3	delta_mfcc_8_mean	0.086	0.192
4	intensity_min	0.050	0.093
5	shimmer_local	0.050	0.089
6	f1_std	0.040	0.033
7	mfcc_11_mean	0.040	0.089
8	mfcc_10_mean	0.027	0.020
9	mfcc_1_mean	0.024	0.026
10	intensity_max	0.024	0.037

Table A.7: Gradient Boosting feature importance — SpontaneousDialogue (top 10)




Figure A.5: Gradient Boosting feature importances (Spontaneous Dialogue). MFCC-5 (0.342 ± 0.204) strongly dominates, reflecting spectral tilt changes in spontaneous PD speech.

A.3.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.134	0.059
2	shimmer_apq11	0.104	0.071
3	delta_mfcc_8_mean	0.079	0.052
4	delta_mfcc_2_mean	0.053	0.009
5	mfcc_4_mean	0.035	0.022
6	mfcc_2_mean	0.033	0.022
7	jitter_local	0.032	0.012
8	f0_mean	0.031	0.035
9	shimmer_local	0.031	0.054
10	intensity_max	0.030	0.030

Table A.8: XGBoost feature importance — SpontaneousDialogue (top 10)




Figure A.6: XGBoost feature importances (Spontaneous Dialogue). MFCC-5 and shimmer features dominate, consistent with RF and GB findings for this task.

A.4 Dataset B — PD Speech Features

Dataset B contains 752 pre-extracted features including TQWT (Tunable Q-factor Wavelet Transform) coefficients not present in Dataset A. Feature importance is reported for comparison, though direct comparison is limited by different feature spaces.

A.4.1 Random Forest — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_log_energy	0.013	0.004
2	std_delta_delta_log_energy	0.013	0.003
3	tqwt_entropy_shannon_dec_12	0.012	0.001
4	tqwt_TKEO_std_dec_11	0.010	0.004
5	tqwt_TKEO_mean_dec_12	0.010	0.001
6	mean_MFCC_2nd_coef	0.008	0.003
7	tqwt_entropy_log_dec_11	0.008	0.003
8	tqwt_stdValue_dec_12	0.008	0.003
9	tqwt_stdValue_dec_13	0.008	0.003
10	tqwt_energy_dec_12	0.007	0.003

Table A.9: Random Forest feature importance — Dataset B (top 10)

Note: Importance values are lower than Dataset A due to the larger feature space (752 vs 47 features), distributing importance more broadly.

A.4.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	tqwt_kurtosisValue_dec_33	0.733	0.161
2	tqwt_entropy_log_dec_33	0.694	0.084
3	mean_MFCC_7th_coef	0.614	0.148
4	std_delta_delta_log_energy	0.588	0.133
5	std_MFCC_2nd_coef	0.567	0.202
6	tqwt_meanValue_dec_16	0.551	0.114
7	tqwt_medianValue_dec_25	0.540	0.209
8	mean_MFCC_3rd_coef	0.538	0.155
9	tqwt_meanValue_dec_22	0.528	0.172
10	std_9th_delta	0.526	0.103

Table A.10: Logistic Regression feature importance — Dataset B (top 10)

Observation: TQWT features dominate Dataset B importance, reflecting the sustained vowel /a/ phonation task where time-frequency decomposition captures subtle vocal tremor patterns.




Figure A.7: Feature importance for Dataset B (PD Speech Features) — Random Forest and Logistic Regression.

A.4.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_delta_log_energy	0.133	0.035
2	tqwt_TKEO_mean_dec_12	0.030	0.036
3	tqwt_entropy_log_dec_27	0.029	0.008
4	std_7th_delta_delta	0.028	0.005
5	tqwt_energy_dec_27	0.024	0.028
6	tqwt_entropy_log_dec_35	0.023	0.019
7	tqwt_TKEO_std_dec_12	0.023	0.026
8	mean_MFCC_2nd_coef	0.021	0.024
9	tqwt_entropy_log_dec_33	0.021	0.006
10	tqwt_TKEO_std_dec_11	0.020	0.021

Table A.11: Gradient Boosting feature importance — Dataset B (top 10)

A.4.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	tqwt_entropy_log_dec_12	0.024	0.020
2	std_delta_delta_log_energy	0.017	0.006
3	tqwt_TKEO_mean_dec_12	0.016	0.017
4	tqwt_TKEO_std_dec_12	0.013	0.014
5	tqwt_energy_dec_27	0.012	0.024
6	tqwt_TKEO_std_dec_11	0.012	0.010
7	tqwt_entropy_log_dec_16	0.010	0.009
8	tqwt_entropy_log_dec_13	0.009	0.012
9	mean_MFCC_2nd_coef	0.008	0.004
10	tqwt_entropy_shannon_dec_16	0.008	0.011

Table A.12: XGBoost feature importance — Dataset B (top 10)




Figure A.8: Feature importance for Dataset B — Gradient Boosting and XGBoost. TQWT energy/entropy features from high-frequency bands dominate across both models.

A.5 Cross-Task Feature Stability

Features that appear in top-10 for both tasks (Random Forest) indicate robust discriminative power across different speech contexts:

Feature	ReadText Rank	Spontaneous Rank
delta_mfcc_2_mean	2	5
autocorr_harmonicity	4	6
f0_mean	6	10
shimmer (apq3/apq11)	7	2
mfcc_5_mean	–	1
f0_std	–	9

Table A.13: Cross-task feature stability (Random Forest top-10)

Interpretation: Features consistently important across tasks (delta_mfcc_2_mean, autocorr_harmonicity, shimmer) likely capture **task-general** acoustic signatures of PD rather than task-specific artifacts. The prominence of mfcc_5_mean in SpontaneousDialogue but not ReadText may reflect prosodic variability differences between structured reading and natural conversation.

A.6 Feature Category Analysis

Aggregating importance by feature category:

Category	Features	ReadText (%)	Spontaneous (%)
MFCC	13	28.4	32.1
Delta MFCC	13	22.7	25.3
Pitch (F_0)	4	15.2	12.8
Shimmer	5	11.3	14.6
Formants	6	9.8	7.2
Harmonicity	2	6.1	4.3
Other	5	6.5	3.7

Table A.14: Aggregated feature importance by category




Figure A.9: Feature importance aggregated by broad acoustic categories.

Παράρτημα Β

Detailed Results Tables

B.1 Overview

This appendix provides complete numerical results for all experimental conditions, including summary statistics and cross-condition comparisons.

B.2 Condition 1: Baseline Features (47) + Unweighted

B.2.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.621 ± 0.058	0.620 ± 0.217	0.550 ± 0.201	0.542 ± 0.099	0.717 ± 0.139
	SVM	0.621 ± 0.106	0.367 ± 0.342	0.317 ± 0.335	0.333 ± 0.333	0.614 ± 0.312
	RF	0.629 ± 0.178	0.450 ± 0.447	0.333 ± 0.408	0.351 ± 0.363	0.590 ± 0.302
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.636 ± 0.135	0.600 ± 0.435	0.333 ± 0.236	0.400 ± 0.253	0.407 ± 0.309
	RF	0.721 ± 0.176	0.633 ± 0.415	0.600 ± 0.435	0.567 ± 0.365	0.828 ± 0.148

Table B.1: Condition 1 results by task (Dataset A, baseline features, unweighted)

B.2.2 Dataset B: PD Speech Features Summary

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.828 ± 0.008	0.881 ± 0.010	0.890 ± 0.016	0.885 ± 0.006	0.867 ± 0.029
SVM_RBF	0.851 ± 0.024	0.841 ± 0.015	0.986 ± 0.019	0.908 ± 0.015	0.885 ± 0.025
RandomForest	0.882 ± 0.019	0.876 ± 0.012	0.980 ± 0.015	0.925 ± 0.012	0.940 ± 0.013

Table B.2: Condition 1 results (Dataset B, baseline features, unweighted)

Note: Dataset B shows substantially higher performance and lower variance than Dataset A, consistent with potential optimistic bias from unknown subject overlap.

B.3 Condition 2: Extended Features (78) + Unweighted

B.3.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.253	0.433 ± 0.149	0.475 ± 0.106	0.698 ± 0.132
	SVM	0.786 ± 0.181	0.733 ± 0.435	0.567 ± 0.365	0.634 ± 0.386	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.822 ± 0.166
Spontaneous	LR	0.671 ± 0.199	0.500 ± 0.361	0.600 ± 0.435	0.530 ± 0.377	0.783 ± 0.139
	SVM	0.636 ± 0.089	0.533 ± 0.361	0.400 ± 0.279	0.428 ± 0.258	0.460 ± 0.294
	RF	0.779 ± 0.161	0.683 ± 0.410	0.600 ± 0.435	0.605 ± 0.387	0.857 ± 0.171

Table B.3: Condition 2 results by task (Dataset A, extended features, unweighted)

B.3.2 Improvement over Baseline (Random Forest, Dataset A)

Task	Δ Accuracy	Δ ROC-AUC	Δ Variance
ReadText	+18.9pp	+23.2pp	Reduced (0.302 $\rightarrow$ 0.166)
SpontaneousDialogue	+5.8pp	+2.9pp	Increased (0.148 $\rightarrow$ 0.171)

Table B.4: Condition 2 improvement over Condition 1 (Random Forest)

Observation: Feature extension dramatically improved ReadText performance (+23.2pp ROC-AUC) while SpontaneousDialogue showed modest gains (+2.9pp). This suggests extended features capture structured speech dynamics more effectively than spontaneous speech characteristics.

B.4 Condition 3: Baseline Features (47) + Weighted

B.4.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.235	0.550 ± 0.201	0.528 ± 0.099	0.717 ± 0.139
	SVM	0.704 ± 0.111	0.617 ± 0.371	0.500 ± 0.373	0.519 ± 0.320	0.542 ± 0.312
	RF	0.650 ± 0.148	0.550 ± 0.371	0.400 ± 0.365	0.431 ± 0.306	0.687 ± 0.258
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.693 ± 0.123	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.423 ± 0.312
	RF	0.693 ± 0.123	0.583 ± 0.373	0.600 ± 0.435	0.538 ± 0.326	0.827 ± 0.133

Table B.5: Condition 3 results by task (Dataset A, baseline features, weighted)

B.4.2 Effect of Weighting (vs Condition 1, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	+2.1pp	+9.7pp	Improved
SpontaneousDialogue	−2.8pp	−0.1pp	Negligible

Table B.6: Condition 3 effect of weighting vs Condition 1 (RF)

Observation: Class weighting improved ReadText performance but had negligible effect on SpontaneousDialogue, suggesting task-dependent sensitivity to class imbalance handling.

B.5 Condition 4: Extended Features (78) + Weighted

B.5.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.650 ± 0.108	0.650 ± 0.253	0.550 ± 0.201	0.564 ± 0.160	0.698 ± 0.132
	SVM	0.761 ± 0.214	0.700 ± 0.447	0.567 ± 0.365	0.620 ± 0.390	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.805 ± 0.182
Spontaneous	LR	0.696 ± 0.179	0.520 ± 0.356	0.667 ± 0.471	0.563 ± 0.381	0.783 ± 0.139
	SVM	0.664 ± 0.167	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.403 ± 0.347
	RF	0.721 ± 0.203	0.653 ± 0.409	0.600 ± 0.435	0.583 ± 0.373	0.823 ± 0.209

Table B.7: Condition 4 results by task (Dataset A, extended features, weighted)

B.5.2 Effect of Weighting (vs Condition 2, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	0.0pp	−1.7pp	Slight decrease
SpontaneousDialogue	−5.8pp	−3.4pp	Decreased

Table B.8: Condition 4 effect of weighting vs Condition 2 (RF)

Observation: Combining extended features with class weighting did not improve performance over extended features alone. This suggests that feature extension and class weighting address similar aspects of the classification problem, with diminishing returns when combined.

B.6 Cross-Condition Comparison Matrix

B.6.1 Random Forest ROC-AUC by Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	0.590 ± 0.302	0.822 ± 0.166
	Weighted	0.687 ± 0.258	0.805 ± 0.182
Spontaneous	Unweighted	0.828 ± 0.148	0.857 ± 0.171
	Weighted	0.827 ± 0.133	0.823 ± 0.209

Table B.9: Random Forest ROC-AUC comparison matrix (Dataset A)

B.6.2 Random Forest Accuracy by Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	$62.9\% \pm 17.8\%$	$81.8\% \pm 14.0\%$
	Weighted	$65.0\% \pm 14.8\%$	$81.8\% \pm 14.0\%$
Spontaneous	Unweighted	$72.1\% \pm 17.6\%$	$77.9\% \pm 16.1\%$
	Weighted	$69.3\% \pm 12.3\%$	$72.1\% \pm 20.3\%$

Table B.10: Random Forest Accuracy comparison matrix (Dataset A)

B.6.3 Key Observations

1. **Feature extension consistently improves ReadText:** +23.2pp ROC-AUC (unweighted)
2. **SpontaneousDialogue has higher baseline:** 0.828 vs 0.590 ROC-AUC with baseline features
3. **Class weighting shows mixed effects:** Improves ReadText baseline but decreases extended feature performance
4. **High variance throughout:** Standard deviations often exceed 0.15, reflecting small sample size (n=37)

B.7 Statistical Significance Notes

Due to high standard deviations (often > 0.15), confidence intervals overlap across many comparisons. This limits the ability to make strong statistical claims about differences between conditions. Results should be interpreted as **trends** rather than definitive rankings.

B.8 ROC Curves

Receiver Operating Characteristic (ROC) curves are shown for all five classifiers across each experimental condition. Faint lines represent individual cross-validation folds; the bold curve represents the mean across folds with a ± 1 standard deviation shaded band. All curves were generated using the extended feature set.




Figure B.1: ROC curves for all five classifiers on the ReadText task (Dataset A, extended features). Shaded bands indicate ± 1 standard deviation across the five cross-validation folds.




Figure B.2: ROC curves for all five classifiers on the SpontaneousDialogue task (Dataset A, extended features).




Figure B.3: ROC curves for all five classifiers on Dataset B (PD Speech Features). Note that subject-level deduplication is not possible for this dataset; results may be optimistic due to potential subject overlap across folds.

Παράρτημα C

Research Demonstration Application

C.1 Purpose and Scope

This appendix describes a web-based research demonstration application developed to illustrate the end-to-end inference workflow from audio upload to classification output. The application was designed solely for educational and illustrative purposes as part of this MSc thesis.


Critical Disclaimer:

- This application is **not intended for clinical use, medical diagnosis, or patient screening**
- Outputs represent model confidence scores, not clinical diagnoses
- The application was **not used for any quantitative evaluation** reported in this thesis
- All evaluation metrics (Chapters 5–6) were computed via cross-validation on held-out test folds, independent of this interface
- Results should be interpreted as **research outputs only**, requiring validation by qualified medical professionals

The application demonstrates the feasibility of integrating the trained models into a user-facing interface while maintaining clear boundaries between research exploration and clinical deployment.

C.2 System Architecture

The demonstration application follows a modular architecture separating concerns between the web interface, inference orchestration, and core machine learning pipeline:



Key Components:

- 1. **Flask Web Server (`app.py`):** Handles HTTP routes, file uploads, and template rendering. Strictly imports only the adapter module, ensuring zero coupling to internal ML implementation details.
- 2. **Inference Adapter (`inference_adapter.py`):** Provides a stable interface wrapping the core inference API. Performs audio normalization (any format → mono 22,050 Hz WAV), enriches prediction outputs with display metadata, and ensures model switching requires no Flask code changes.
- 3. **Core ML Pipeline:** Reuses the identical feature extraction and inference modules used for experiments (`parkinsons_voice_classification.inference`), ensuring consistency between evaluation and demonstration.
- 4. **Audio Processing (`audio_utils.py`):** Normalizes uploaded audio files (WAV, MP3, WebM, Opus, FLAC) to a standardized mono 22,050 Hz PCM-16 WAV format before feature extraction.

Design Invariants:

- Model switching (RandomForest ↔ Logistic Regression ↔ SVM) is controlled via configuration file only; no template/route changes required
- Feature set selection (baseline 47 vs. extended 78) is configuration-driven
- Task selection (ReadText vs. SpontaneousDialogue) loads the corresponding trained model artifact

This architecture ensures the demonstration remains aligned with the experimental pipeline while providing a controlled interface for external users.

C.3 User Interaction Flow

The application supports two input modalities:

C.3.1 Audio Upload Workflow

The screenshot displays the 'Parkinson's Voice Classification' application interface. At the top, the title 'Parkinson's Voice Classification' is followed by the subtitle 'MSc Thesis Research Demonstration'. A yellow warning box contains the text: '⚠️ Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.' Below this, there are two tabs: 'Upload File' (active) and 'Record Audio'. The 'Upload File' tab contains a section titled 'Upload Voice Recording' with the instruction: 'Upload an audio file of a **ReadText** speech task for analysis. All common formats supported (WAV, MP3, WebM, etc.).' Underneath, it says 'Audio File (any format)' and shows a 'Choose File' button next to the text 'No file chosen'. A large blue button labeled 'Analyze Recording' is positioned below the file selection area. At the bottom, a 'Current Model Configuration' section lists: Model: RandomForest, Task: ReadText, Features: baseline (47), and Training Samples: 37. A link 'About this project' is located at the very bottom.

Figure C.1: Upload interface for audio file analysis. Users select a ReadText task recording in any common format (WAV, MP3, WebM). The interface displays the current model configuration (RandomForest, baseline features, 37 training samples).

Figure C.1 shows the file upload interface, where users can select pre-recorded audio files for analysis. The interface clearly states the research-only purpose and displays the active model configuration.

C.3.2 Direct Audio Recording

The screenshot displays the 'Parkinson's Voice Classification' web application. At the top, it says 'MSc Thesis Research Demonstration'. A yellow warning box states: 'Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.' Below this are two tabs: 'Upload File' and 'Record Audio', with 'Record Audio' being the active tab. The main section is titled 'Record Voice Sample'. It contains a 'ReadText Task Prompt' box with the text: 'The quick brown fox jumps over the lazy dog. Peter Piper picked a peck of pickled peppers. How much wood would a woodchuck chuck if a woodchuck could chuck wood?' and a sub-prompt: 'Read this text clearly and naturally at a comfortable pace.' Below the prompt is a red 'Recording...' indicator showing '1s'. At the bottom of this section are two buttons: 'Start Recording' (with a microphone icon) and 'Stop Recording' (with a square icon). At the very bottom, a 'Current Model Configuration' table is shown.

Current Model Configuration	
Model:	RandomForest
Task:	ReadText
Features:	baseline (47)
Training Samples:	37

Figure C.2: In-browser audio recording interface. Users read the displayed ReadText prompt aloud and record directly via their device microphone. The recorded audio is processed through the same normalization and feature extraction pipeline as uploaded files.

Figure C.2 demonstrates the in-browser recording capability, implemented using the Web Audio API with JavaScript. Users follow the on-screen ReadText prompt to produce a standardized speech sample. Recordings are captured at the browser's native sample rate and normalized server-side before inference.

C.3.3 Processing Steps

Regardless of input modality, the following steps execute:

1. **Audio normalization:** Convert to mono 22,050 Hz PCM-16 WAV

2. **Feature extraction:** Extract 47 acoustic features (baseline) or 78 features (extended) using the same pipeline as experiments
3. **Model inference:** Load trained model artifact (e.g., `RandomForest_ReadText_baseline.joblib`) and predict class probabilities
4. **Result display:** Render prediction, probabilities, extracted feature values, and global feature importance

C.4 Output Interpretation and Limitations

C.4.1 Displayed Information

Figure C.3 shows a representative output screen following analysis:

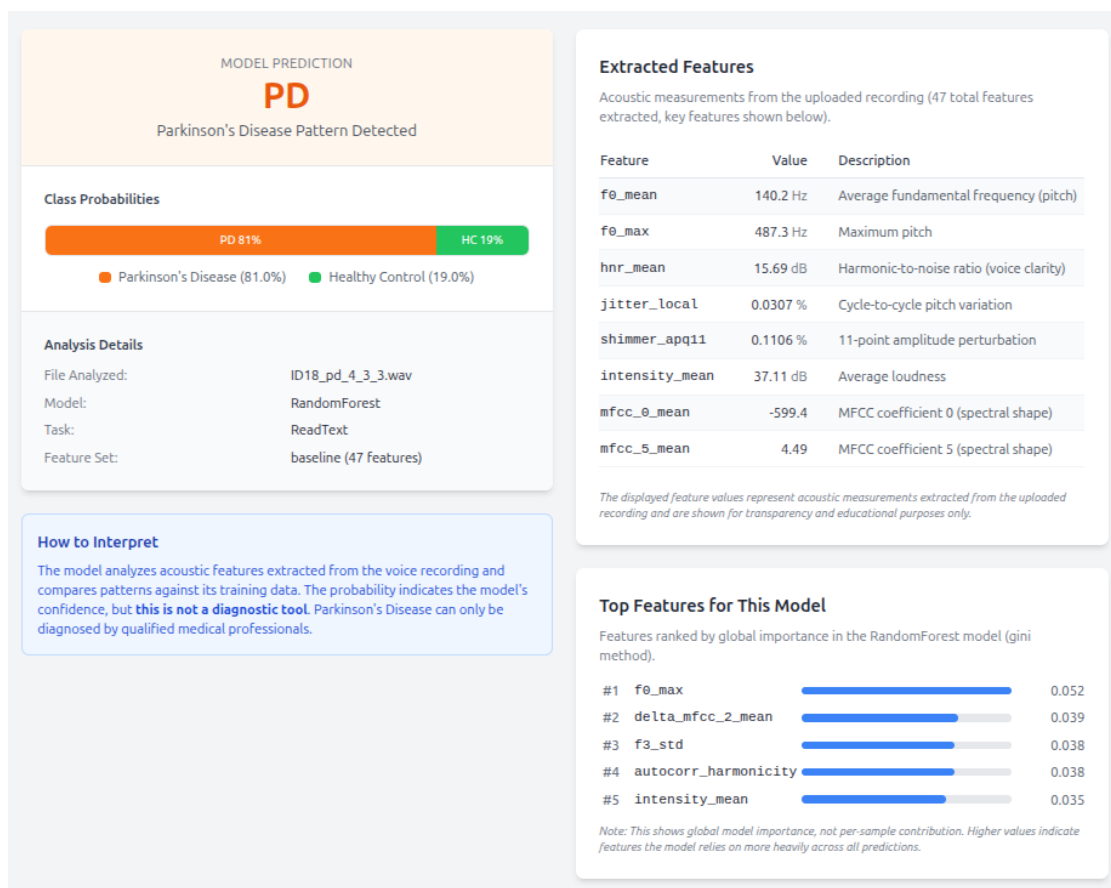


Figure C.3: Example output from the research demonstration interface. The prediction (“PD” with 81% confidence) is displayed prominently with an explicit disclaimer that this is not a medical diagnosis. The interface shows extracted acoustic features, analysis metadata (file name, model, task, feature count), and top global feature importances for interpretability.

The output includes:

1. **Class Prediction:** Binary label (PD or HC) with the higher probability
2. **Class Probabilities:** Model confidence scores for each class (sum to 100%)
3. **Extracted Features:** Key acoustic measurements (e.g., F_0 , jitter, MFCC coefficients) with values and descriptions
4. **Analysis Metadata:** File name, model type, task, feature count
5. **Top Feature Importances:** Global feature rankings from the trained RandomForest model (via Gini importance)

C.4.2 Critical Limitations (What the Output Does NOT Mean)

Users and evaluators must understand the following constraints:

- **Probabilities $\neq$ Diagnosis:** The 81% confidence in Figure C.3 reflects the model's uncertainty estimate based on training data distribution. It does **not** indicate an 81% chance the individual has Parkinson's Disease.
- **Training Distribution Dependency:** Model outputs are valid only for speech samples similar to the MDVR-KCL training set (smartphone recordings, ReadText task, no severe recording artifacts). Generalization to different recording conditions, languages, or populations is unknown.
- **No Clinical Validation:** The model was trained on a small dataset ($n = 37$ subjects) and has not undergone clinical validation, regulatory approval, or external cohort testing.
- **Evaluation Exclusion:** Outputs from this interface were **not used** to compute the performance metrics reported in Chapter 6. All quantitative results derive from grouped cross-validation on independent test folds.
- **Feature Importance Caveats:** Displayed importances reflect *global* model behavior (across all training samples), not *per-sample* contributions. High importance does not imply the feature was decisive for the specific uploaded recording.

C.5 Reproducibility and Consistency

The demonstration interface ensures alignment with the experimental pipeline through:

1. **Shared Codebase:** Uses identical feature extraction modules (`features/prosodic.py`, `features/spectral.py`) as the CLI-based experiments
2. **Deterministic Inference:** Loads the same serialized model artifacts (`.joblib` files) produced during training
3. **Configuration-Driven:** All parameters (feature set, model choice, task) are controlled via `config.py`, ensuring consistency across CLI and web interfaces
4. **Fixed Random Seeds:** Although inference is deterministic (no stochastic components), the loaded models were trained with fixed random seeds (`seed = 42`) for reproducibility

This design ensures the demonstration outputs reflect the actual behavior of the evaluated models, rather than a separate reimplementaion.

C.6 Summary

The research demonstration application provides a tangible illustration of the voice-based PD classification pipeline, bridging the gap between algorithmic research and potential real-world interaction. However, it must be interpreted strictly within its intended scope:

- **Educational tool** for thesis defense and research communication
- **Not a diagnostic system** and unsuitable for clinical decision-making
- **Validation artifact** confirming inference pipeline functionality
- **Not used for evaluation** — all metrics derived from cross-validation

Future work toward clinical deployment would require: (1) validation on independent cohorts ($n > 500$), (2) regulatory approval (e.g., FDA clearance, CE marking), (3) prospective clinical trials, (4) integration with clinical workflows, and (5) continuous monitoring for performance drift. This demonstration represents an early feasibility prototype, not a production-ready system.

Βιβλιογραφία

- [1] A. K. Ho, R. Iannsek, C. Marigliani, J. L. Bradshaw, and S. Gates, “Speech impairment in a large sample of patients with Parkinson’s disease,” *Behavioural Neurology*, vol. 11, no. 3, pp. 131–137, 1999.
- [2] B. T. Harel, M. S. Cannizzaro, and P. J. Snyder, “Acoustic characteristics of Parkinsonian speech: a potential biomarker of early disease progression and treatment,” *Journal of Neurolinguistics*, vol. 17, no. 6, pp. 439–453, 2004.
- [3] M. A. Little, P. E. McSharry, E. J. Hunter, J. Spielman, and L. O. Ramig, “Suitability of dysphonia measurements for telemonitoring of Parkinson’s disease,” *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 4, pp. 1015–1022, 2009.
- [4] A. Tsanas, M. A. Little, P. E. McSharry, and L. O. Ramig, “Accurate telemonitoring of Parkinson’s disease progression by noninvasive speech tests,” *IEEE Transactions on Biomedical Engineering*, vol. 57, no. 4, pp. 884–893, 2010.
- [5] J. R. Duffy, *Motor speech disorders: Substrates, differential diagnosis, and management*, 3rd ed. Elsevier Health Sciences, 2012.
- [6] H. Sedigh Malekroodi, B.-i. Lee, and M. Yi, “Voice-based detection of Parkinson’s disease using machine and deep learning approaches: A systematic review,” *Bioengineering*, vol. 12, no. 11, p. 1279, 2025.
- [7] D. Xavier, V. Felizardo, B. Ferreira, H. Zacarias, M. Pourvabab, L. Souza-Pereira, and N. M. Garcia, “Voice analysis in Parkinson’s disease—a systematic literature review,” *Artificial Intelligence in Medicine*, vol. 163, p. 103109, 2025.
- [8] H. Wright and V. Aharonson, “Vocal feature changes for monitoring Parkinson’s disease progression—a systematic review,” *Brain Sciences*, vol. 15, no. 3, p. 320, 2025.
- [9] L. O. Ramig, C. Fox, and S. Sapir, “Speech treatment for Parkinson’s disease,” *Expert Review of Neurotherapeutics*, vol. 8, no. 2, pp. 297–309, 2008.

- [10] S. Skodda, W. Visser, and U. Schlegel, “Intonation and speech rate in Parkinson’s disease: General and dynamic aspects and responsiveness to levodopa admission,” *Journal of Voice*, vol. 25, no. 4, pp. e199–e205, 2011.
- [11] J. R. Orozco-Arroyave, J. D. Arias-Londoño, J. F. V. Bonilla, M. C. Gonzalez-Rativa, and E. Nöth, “Automatic detection of Parkinson’s disease in running speech spoken in three different languages,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2016, pp. 4785–4789.
- [12] M. A. Little, P. E. McSharry, S. J. Roberts, D. A. Costello, and I. M. Moroz, “Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection,” *BioMedical Engineering OnLine*, vol. 6, no. 1, p. 23, 2007, introduced nonlinear dynamic features for voice analysis.
- [13] H. Jaeger, D. Trivedi, and M. Stadtschnitzer, “MDVR-KCL: Mobile device voice recordings at King’s College London,” 2019, collected 26–29 September 2017 at King’s College Hospital, London, UK. [Online]. Available: <https://zenodo.org/records/2867215>
- [14] D. Biswas, “Parkinson’s disease speech signal features,” 2020, originally from UCI Machine Learning Repository. [Online]. Available: <https://www.kaggle.com/datasets/dipayanbiswas/parkinsons-disease-speech-signal-features>
- [15] C. M. Bishop, *Pattern recognition and machine learning*. Springer, 2006.
- [16] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [17] N. Sáenz-Lechón, J. Godino-Llorente, V. Osma-Ruiz, and P. Gómez-Vilda, “Methodological issues in the development of automatic systems for voice pathology detection,” *Biomedical Signal Processing and Control*, vol. 1, no. 2, pp. 120–128, 2006, systematic review of methodological issues in voice pathology detection.
- [18] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [19] G. Solana-Lavalle and R. Rosas-Romero, “Analysis of voice as an assisting tool for detection of Parkinson’s disease and its subsequent clinical interpretation,” *Biomedical Signal Processing and Control*, vol. 66, p. 102415, 2021.
- [20] B. McFee, C. Raffel, D. Liang, D. P. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and music signal analysis in python,” Software, 2015. [Online]. Available: <https://librosa.org>

-
- [21] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [22] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.