



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΣΥΣΤΗΜΑΤΩΝ ΜΕΤΑΔΟΣΗΣ ΠΛΗΡΟΦΟΡΙΑΣ
ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ ΥΛΙΚΩΝ

Ταξινόμηση Νόσου Parkinson μέσω Φωνής με Χρήση Κλασικής Μηχανικής Μάθησης

**Voice-Based Classification of Parkinson's Disease Using
Classical Machine Learning**

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Μάριος Χρήστος Συρμακέζης

Επιβλέπων: Γεώργιος Ματσόπουλος
Καθηγητής, Ε.Μ.Π.

Συνεπιβλέπουσα: Δρ. Ουρανία Πετροπούλου
ΕΔΙΠ, Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ
ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ ΣΥΣΤΗΜΑΤΩΝ ΜΕΤΑΔΟΣΗΣ ΠΛΗΡΟΦΟΡΙΑΣ
ΚΑΙ ΤΕΧΝΟΛΟΓΙΑΣ ΥΛΙΚΩΝ

Ταξινόμηση Νόσου Parkinson μέσω Φωνής με Χρήση Κλασικής Μηχανικής Μάθησης

Voice-Based Classification of Parkinson's Disease Using
Classical Machine Learning

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

Μάριος Χρήστος Συρμακέζης

Επιβλέπων: Γεώργιος Ματσόπουλος
Καθηγητής, Ε.Μ.Π.

Συνεπιβλέπουσα: Δρ. Ουρανία Πετροπούλου
ΕΔΙΠ, Ε.Μ.Π.

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 26η Φεβρουαρίου 2026.

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....
Γεώργιος Ματσόπουλος

.....
Παναγιώτης Τσανάκας

.....
Αθανάσιος Δ.

Καθηγητής, Ε.Μ.Π.

Καθηγητής, Ε.Μ.Π.

Παναγόπουλος
Καθηγητής, Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026

.....

Μάριος Χρήστος Συρμακέζης

26 Φεβρουαρίου 2026

Διπλωματούχος Ηλεκτρολόγος Μηχανικός και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright © Μάριος Χρήστος Συρμακέζης, 2026.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η νόσος του Πάρκινσον (PD) είναι μια νευροεκφυλιστική διαταραχή που, πέρα από τα κινητικά συμπτώματα, επηρεάζει συχνά και την ομιλία. Η εργασία αυτή εξετάζει αν μπορούμε να εντοπίσουμε τη νόσο μέσω της φωνής, χρησιμοποιώντας κλασικές μεθόδους μηχανικής μάθησης.

Για τον σκοπό αυτό χρησιμοποιήθηκαν δύο διαφορετικά σύνολα δεδομένων ομιλίας, με την ίδια διαδικασία ανάλυσης και αξιολόγησης και στα δύο.

Το πρώτο σύνολο δεδομένων, Mobile Device Voice Recordings at King's College London, περιλάμβανε κατηγοριοποιημένα αρχεία ήχου (WAV) που είχαν καταγραφεί με ειδικό εξοπλισμό. Οι ηχογραφήσεις ήταν ακατέργαστες, γι' αυτό προχωρήσαμε στην εξαγωγή ακουστικών χαρακτηριστικών για να μετατρέψουμε τα δεδομένα σε μια αριθμητική μορφή που είναι κατάλληλη για ανάλυση.

Το δεύτερο σύνολο δεδομένων, με τίτλο PD speech signal features από το Kaggle (UCI), περιλάμβανε ακουστικά χαρακτηριστικά που είχαν ήδη εξαχθεί σε μορφή csv. Σε αυτή την περίπτωση, δεν χρειάστηκε να γίνει επεξεργασία ήχου αφού τα αριθμητικά χαρακτηριστικά ήταν ήδη διαθέσιμα. Και στα δύο σύνολα δεδομένων, ο σκοπός ήταν να διαπιστωθεί αν τα μοντέλα μπορούν να αναγνωρίσουν άτομα με Πάρκινσον μόνο από τη φωνή τους.

Αξιολογήθηκαν πέντε αλγόριθμοι: Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting και XGBoost. Επιπλέον, εξετάστηκε αν η αύξηση του αριθμού των χαρακτηριστικών βελτιώνει την απόδοση, καθώς και αν η χρήση βαρών κλάσης (class weighting) βοηθά στην εξισορρόπηση των ομάδων PD και HC. Χρησιμοποιήθηκε επίσης διασταυρωμένη επικύρωση (cross-validation), ώστε να μην υπάρχει διαρροή δεδομένων.

Τα αποτελέσματα έδειξαν ότι ο Random Forest ήταν ο πιο αποτελεσματικός. Η αύξηση των χαρακτηριστικών βελτίωσε σημαντικά την απόδοση των περισσότερων μοντέλων. Η χρήση βαρών είχε μικρή θετική επίδραση κυρίως στον Random Forest και μικρή ή αρνητική στους υπόλοιπους.

Συνολικά, η εργασία δείχνει ότι η ανάλυση φωνής σε συνδυασμό με μηχανική μάθηση μπορεί να βοηθήσει στην αναγνώριση της νόσου του Πάρκινσον. Ωστόσο, τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή, λόγω ορισμένων περιορισμών, όπως πιθανές πολλαπλές ηχογραφήσεις του ίδιου ασθενούς και η διαφορά μεγέθους μεταξύ των δύο datasets.

Παρά τους περιορισμούς, τα ευρήματα δείχνουν ότι η σωστή επεξεργασία δεδομένων και η κατάλληλη χρήση αλγορίθμων μπορούν να οδηγήσουν μελλοντικά σε πιθανή αναγνώριση της νόσου μέσω της φωνής, ακόμα και με απλά καθημερινά μικρόφωνα. Αυτό είναι σημαντικό, γιατί η έγκαιρη ανίχνευση θα μπορούσε να συμβάλει σε νωρίτερη θεραπεία και καλύτερη ποιότητα ζωής για τους ασθενείς.

Λέξεις Κλειδιά: Νόσος του Πάρκινσον, Δυσαρθρία, Φωνητικοί Βιοδείκτες, Ακουστικά Χαρακτηριστικά, Μηχανική Μάθηση, Εξαγωγή Χαρακτηριστικών, Διασταυρούμενη Επικύρωση, Μη Ισορροπημένα Δεδομένα, Αναπαραγωγιμότητα, Ταξινόμηση Ομιλίας, Υπολογιστική Νοημοσύνη στην Υγεία

Abstract

Parkinson's disease (PD) is a progressive neurological disorder characterized by motor symptoms which are typically accompanied by speech difficulties.

In this paper we assess if Parkinson's disease can be diagnosed through the voice based on classical machine learning approaches.

We worked with two different datasets, each analyzed using an identical methodology, i.e., analysis and validation procedure.

The first dataset, Mobile Device Voice Recordings at King's College London, contained categorized audio files (WAV) recorded with advanced recording equipment in a controlled environment.

These recordings were unprocessed, therefore we had to process the audio to extract the acoustic features to transform the data into a numeric format that would allow us to perform the analysis.

The second dataset, PD speech signal features from Kaggle (UCI), contained pre-extracted acoustic features in csv format.

Therefore, we did not need to process the audio since the pre-processed features were ready to be analyzed.

Both datasets were processed to see if the models could distinguish between individuals with PD and healthy controls (HC) only through their voice.

We compared five machine learning algorithms, i.e., Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting, and XGBoost.

Furthermore, we investigated whether increasing the number of features in the training set enhances the model performance, and whether the application of class weighting enhances the model performance particularly for the PD group.

To avoid data leakage, cross-validation was performed.

The results indicate that Random Forest algorithm outperformed all other tested algorithms.

An increase of the number of features in the training set positively affected the majority of the tested models.

Class weighting had a limited positive impact especially on Random Forest, while the other algorithms either did not benefit from class weighting or were even negatively affected.

In general, the study demonstrates that voice-based analysis combined with machine learning may support the diagnosis of Parkinson's disease.

Nevertheless, the results have to be viewed critically due to some limitations, e.g., potential multiple

recordings of the same patient and the significant differences in terms of sample sizes between the two datasets.

Regardless of these limitations, the study shows that adequate processing of the data, along with the appropriate application of machine learning algorithms can result in a potential disease identification through voice, using regular microphones, available in everyday devices like smartphones.

Early detection may lead to the initiation of therapy at an earlier time point and improve the quality of life of patients.

Keywords: Parkinson's Disease; Dysarthria; Voice Biomarkers; Acoustic Features; Machine Learning; Feature Extraction; Cross-Validation; Reproducibility; Speech Classification;

Πίνακας Περιεχομένων

Περίληψη	5
Abstract	7
Κατάλογος Σχημάτων	14
Κατάλογος Πινάκων	16
1 Εισαγωγή	17
1.1 Ιστορικό και κίνητρα	17
1.2 Διατύπωση του προβλήματος	18
1.3 Ερευνητικοί στόχοι	20
1.4 Συνεισφορές	20
1.5 Οργάνωση της εργασίας	23
1.6 Όρια πεδίου εφαρμογής	24
2 Βιβλιογραφική ανασκόπηση	25
2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας	25
2.2 Ανίχνευση έναντι παρακολούθησης	26
2.3 Ταξινόμηση ακουστικών χαρακτηριστικών	27
2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας	27
2.4 Σύνολα δεδομένων για τη φωνή ασθενών με Πάρκινσον	28
2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου	28
2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών	29
2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων	30
2.4.4 Ετερογένεια επικύρωσης (Cross-validation heterogeneity)	30
2.4.5 Ο ρόλος των εργασιών ομιλίας	31
2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD	31
2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις	32
2.6 Μεθοδολογικά ζητήματα στη βιβλιογραφία	32
2.6.1 Διαρροή δεδομένων	32
2.6.2 Ανισορροπία κλάσεων	32
2.6.3 Αναπαραγωγικότητα	33
2.6.4 Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων	33
2.6.5 Ερμηνευσιμότητα	33
2.7 Έλλειμμα στην έρευνα	34
2.8 Περίληψη	34

3	Περιγραφή δεδομένων	35
3.1	Επισκόπηση	35
3.2	Σύνολο δεδομένων A: MDVR-KCL	35
3.3	Σύνολο δεδομένων B: PD Speech Features	35
3.4	Συγκριτική αποτίμηση των δύο συνόλων	36
4	Μεθοδολογία	37
4.1	Διαδικασία εξαγωγής χαρακτηριστικών	37
4.1.1	Αρχιτεκτονική διαδικασίας	37
4.1.2	Προεπεξεργασία ήχου	37
4.1.3	Προσωδιακά χαρακτηριστικά (21 χαρακτηριστικά)	38
4.1.4	Φασματικά χαρακτηριστικά	40
4.1.5	Συνολικός αριθμός χαρακτηριστικών	42
4.2	Σύγκριση συνόλου χαρακτηριστικών	42
4.2.1	Λόγοι για τα εκτεταμένα χαρακτηριστικά	42
4.2.2	Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών	42
4.3	Μοντέλα μηχανικής μάθησης	43
4.3.1	Προδιαγραφές μοντέλου	43
4.3.2	Στάθμιση βαρύτητας κλάσης	45
4.4	Αρχιτεκτονική ML Pipeline	45
4.4.1	Δομή Pipeline	45
4.4.2	Τυποποίηση χαρακτηριστικών	46
4.5	Πλαίσιο αξιολόγησης	46
4.5.1	Στρατηγική Cross-Validation	46
4.5.2	Μετρήσεις αξιολόγησης	47
5	Σχεδιασμός πειράματος	49
5.1	Ερευνητικά ερωτήματα	49
5.2	Σχεδιασμός πειραμάτων	49
5.2.1	Συνολικές πειραματικές εκτελέσεις	50
5.3	Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα	50
6	Αποτελέσματα	52
6.1	Σύνοψη κύριων αποτελεσμάτων	52
6.2	Επίδραση χαρακτηριστικών και στάθμισης κλάσεων (Dataset A)	53
6.2.1	Σύγκριση baseline έναντι extended χαρακτηριστικών	53
6.2.2	Σύνοψη επίδρασης class weighting	53
6.3	Σταθερότητα και διακύμανση	53
6.4	Συγκριτικός πίνακας Random Forest ανά συνθήκη	54
6.5	Οπτική επιβεβαίωση αποτελεσμάτων	55
6.5.1	Confusion matrices	55
6.6	Παραπομπή σε πλήρη αποτελέσματα	56

7	Συζήτηση	57
7.1	Ερμηνεία βασικών ευρημάτων	57
7.1.1	Επέκταση χαρακτηριστικών	57
7.1.2	Στάθμιση κλάσεων	57
7.1.3	Ιεραρχία μοντέλων και σταθερότητα	57
7.2	Σύγκριση με προηγούμενη βιβλιογραφία	57
7.3	Ερμηνεία σημαντικότητας χαρακτηριστικών	58
7.4	Μεθοδολογικές συνέπειες	59
8	Περιορισμοί και απειλές για την εγκυρότητα	60
8.1	Περιορισμοί δεδομένων και δειγματοληψίας	60
8.2	Μεθοδολογικοί και τεχνικοί περιορισμοί	60
8.2.1	Επιλογές μοντελοποίησης και ρύθμισης	60
8.2.2	Περιορισμοί εξαγωγής χαρακτηριστικών	61
8.2.3	Εξωτερική επικύρωση και γενίκευση	61
8.3	Απειλές για την εγκυρότητα	61
9	Συμπεράσματα	62
9.1	Περίληψη	62
9.2	Κύριες συνεισφορές	62
9.3	Συνοπτικές απαντήσεις στα ερευνητικά ερωτήματα	62
9.4	Επιπτώσεις και προτεραιότητες συνέχειας	63
9.5	Τελική τοποθέτηση	63
	Βιβλιογραφία	64
A	Πίνακες Σημαντικότητας Χαρακτηριστικών	69
A.1	Επισκόπηση	69
A.2	Dataset A — ReadText Task	69
A.2.1	Random Forest — Top 20 Features	69
A.2.2	Logistic Regression — Top 20 Features	70
A.2.3	Gradient Boosting — Top 10 Features	71
A.2.4	XGBoost — Top 10 Features	72
A.3	Dataset A — SpontaneousDialogue Task	73
A.3.1	Random Forest — Top 20 Features	73
A.3.2	Logistic Regression — Top 10 Features	73
A.3.3	Gradient Boosting — Top 10 Features	74
A.3.4	XGBoost — Top 10 Features	75
A.4	Dataset B — PD Speech Features	76
A.4.1	Random Forest — Top 10 Features	77
A.4.2	Logistic Regression — Top 10 Features	77
A.4.3	Gradient Boosting — Top 10 Features	78

A.4.4	XGBoost — Top 10 Features	79
A.5	Σταθερότητα Χαρακτηριστικών μεταξύ Tasks	79
A.6	Ανάλυση Κατηγοριών Χαρακτηριστικών	80
B	Παράρτημα: Αναλυτικοί Πίνακες Αποτελεσμάτων	81
B.1	Επισκόπηση	81
B.2	Συνθήκη C1: Baseline (47) + Unweighted	81
B.3	Συνθήκη C2: Baseline (47) + Weighted	82
B.4	Συνθήκη C3: Extended (78) + Unweighted	82
B.5	Συνθήκη C4: Extended (78) + Weighted	83
B.6	Θερμικοί χάρτες σημαντικότητας χαρακτηριστικών	83
B.7	Σημείωση ερμηνείας	84

Κατάλογος Σχημάτων

1.1	Κλινικό πλαίσιο αξιοποίησης βιοδεικτών ομιλίας και γλώσσας στη νόσο του Πάρκινσον σε όλα τα στάδια της νόσου. Απεικονίζονται τρεις κύριες εφαρμογές: (1) έγκαιρη ανίχνευση και διαλογή στο πρόδρομο στάδιο, (2) υποστήριξη διαφορικής διάγνωσης και εξατομικευμένη διαχείριση στο πρώιμο στάδιο, και (3) παρακολούθηση εξέλιξης νόσου και ρύθμιση θεραπείας στα μεταγενέστερα στάδια. Προσαρμογή από Cao et al. [1].	18
1.2	Σύνοψη της πειραματικής ροής της εργασίας για τα δύο σύνολα δεδομένων. Η ανάλυση στο Dataset A ακολουθεί τη διαδρομή $WAV \rightarrow$ εξαγωγή χαρακτηριστικών $\rightarrow$ κλασική μηχανική μάθηση, ενώ στο Dataset B η είσοδος είναι ήδη πίνακας χαρακτηριστικών. Σε όλες τις περιπτώσεις αναφέρονται οι ίδιες μετρικές αξιολόγησης (Accuracy, Precision, Recall, F1, ROC-AUC).	19
1.3	Αρχιτεκτονική της εφαρμογής ερευνητικής επίδειξης και κύρια σελίδα εισόδου σε παράθεση δίπλα-δίπλα.	21
1.4	Κύριες οθόνες της εφαρμογής ερευνητικής επίδειξης σε διάταξη 2x1.	22
1.5	Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά ακουστική κατηγορία (Random Forest, Dataset A). Τα MFCC και Delta-MFCC κυριαρχούν και στα δύο tasks: η σχετική βαρύτητα Pitch/Shimmer υποδηλώνει task-εξαρτώμενη ευαισθησία.	23
4.1	Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.	37
6.1	ROC curves για τα βασικά πειράματα. Για το Dataset B, τα αποτελέσματα ενδέχεται να είναι αισιόδοξα λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds.	55
6.2	Confusion matrix για το ReadText task (Dataset A, Random Forest, extended features, unweighted). HC = Healthy Control, PD = Parkinson's Disease.	56
6.3	Confusion matrix για το SpontaneousDialogue task (Dataset A, Random Forest, extended features, unweighted).	56
6.4	Confusion matrix για το Dataset B (XGBoost, baseline features, unweighted). Σημείωση: λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds, τα αποτελέσματα ενδέχεται να είναι αισιόδοξα.	56
A.1	Μέγεθος συντελεστών του Logistic Regression (ReadText)	70
A.2	Σημαντικότητα χαρακτηριστικών του Gradient Boosting (ReadText). Το F0 max εμφανίζει ισχυρή κυριαρχία (0.229 ± 0.179), σε συμφωνία με διαταραχές στη ρύθμιση του pitch στην PD.	71

A.3	Σημαντικότητα χαρακτηριστικών του XGBoost (ReadText). Η σημαντικότητα είναι πιο κατανοητή σε σχέση με το Gradient Boosting, με τα χαρακτηριστικά F0 και έντασης να μοιράζονται την κυριαρχία.	72
A.4	Μέγεθος συντελεστών του Logistic Regression (Spontaneous Dialogue)	74
A.5	Σημαντικότητα χαρακτηριστικών του Gradient Boosting (Spontaneous Dialogue). Το MFCC-5 (0.342 ± 0.204) κυριαρχεί, αντανakλώντας αλλαγές στο spectral tilt στην αυθόρμητη ομιλία PD.	75
A.6	Σημαντικότητα χαρακτηριστικών του XGBoost (Spontaneous Dialogue). Τα MFCC-5 και τα shimmer χαρακτηριστικά κυριαρχούν, σε συμφωνία με τα ευρήματα των RF και GB για αυτό το task.	76
A.7	Σημαντικότητα χαρακτηριστικών για το Dataset B (PD Speech Features) — Random Forest και Logistic Regression.	78
A.8	Σημαντικότητα χαρακτηριστικών για το Dataset B — Gradient Boosting και XGBoost. Τα χαρακτηριστικά ενέργειας/εντροπίας TQWT από ζώνες υψηλής συχνότητας κυριαρχούν και στα δύο μοντέλα.	79
A.9	Σημαντικότητα χαρακτηριστικών συγκεντρωμένη ανά ευρείες ακουστικές κατηγορίες.	80
B.1	Σύγκριση θερμικών χαρτών σημαντικότητας χαρακτηριστικών για τα δύο tasks του Dataset A.	84

Κατάλογος Πινάκων

1.1	Συνοπτικός πίνακας από τα feature-importance summary CSV (Random Forest, baseline, Dataset A): κορυφαία 3 χαρακτηριστικά ανά task (mean $\pm$ std).	23
1.2	Περίληψη των κεφαλαίων της εργασίας	24
2.1	Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD	27
3.1	Σύνοψη Dataset A (MDVR-KCL)	35
3.2	Σύνοψη Dataset B	36
3.3	Κύριες διαφορές Dataset A και Dataset B	36
4.1	Ανάλυση προσωδιακών χαρακτηριστικών	39
4.2	Βασικά φασματικά χαρακτηριστικά	41
4.3	Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)	41
4.4	Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση	42
4.5	Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.	43
4.6	Στρατηγικές διασταυρούμενης επικύρωσης	46
4.7	Μετρήσεις αξιολόγησης	47
5.1	Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.	50
5.2	Συνολικός αριθμός πειραμάτων	50
5.3	Σύνθεση συνόλων χαρακτηριστικών ανά ακουστική κατηγορία.	50
5.4	Στρατηγική cross-validation ανά dataset και αιτιολόγηση.	51
6.1	Κύρια αποτελέσματα ανά σύνολο δεδομένων	52
6.2	Random Forest ROC-AUC ανά task και πειραματική συνθήκη (Dataset A, mean $\pm$ std, 5-fold CV).	52
6.3	Επίδραση feature extension (78 έναντι 47 χαρακτηριστικών) στο Dataset A	53
6.4	Επίδραση class weighting στο Random Forest (Dataset A)	53
6.5	Σύγκριση διακύμανσης μεταξύ Dataset A και Dataset B	53
6.6	Random Forest Accuracy ανά task και πειραματική συνθήκη (Dataset A, mean $\pm$ std, 5-fold CV).	54
7.1	Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά ακουστική κατηγορία (Random Forest, Dataset A). Αριθμός χαρακτηριστικών ανά κατηγορία στο baseline set (47 χαρ.). Πλήρης ανάλυση ανά μοντέλο στο Παράρτημα A.	58

7.2	Χαρακτηριστικά με σταθερή σημαντικότητα και στα δύο speech tasks (Random Forest, top-10 per task, Dataset A). Τιμή “–” υποδηλώνει απουσία από το top-10 του αντίστοιχου task. Πλήρης ανάλυση στο Παράρτημα Α.	59
8.1	Κρίσιμοι περιορισμοί ανά σύνολο δεδομένων	60
8.2	Σύνοψη απειλών εγκυρότητας και μετριάσιμων	61
A.1	Σημαντικότητα χαρακτηριστικών του Random Forest — ReadText (top 10)	69
A.2	Σημαντικότητα χαρακτηριστικών του Logistic Regression — ReadText (top 10)	70
A.3	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — ReadText (top 10)	71
A.4	Σημαντικότητα χαρακτηριστικών του XGBoost — ReadText (top 10)	72
A.5	Σημαντικότητα χαρακτηριστικών του Random Forest — SpontaneousDialogue (top 10)	73
A.6	Σημαντικότητα χαρακτηριστικών του Logistic Regression — SpontaneousDialogue (top 10)	73
A.7	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — SpontaneousDialogue (top 10)	74
A.8	Σημαντικότητα χαρακτηριστικών του XGBoost — SpontaneousDialogue (top 10)	75
A.9	Σημαντικότητα χαρακτηριστικών του Random Forest — Dataset B (top 10)	77
A.10	Σημαντικότητα χαρακτηριστικών του Logistic Regression — Dataset B (top 10)	77
A.11	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — Dataset B (top 10)	78
A.12	Σημαντικότητα χαρακτηριστικών του XGBoost — Dataset B (top 10)	79
A.13	Σταθερότητα χαρακτηριστικών μεταξύ tasks (Random Forest top-10)	80
A.14	Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά κατηγορία	80
B.1	Dataset A (C1: baseline χαρακτηριστικά + χωρίς στάθμιση κλάσεων).	81
B.2	Dataset B (C1: baseline χαρακτηριστικά + χωρίς στάθμιση κλάσεων).	81
B.3	Dataset A (C2: baseline χαρακτηριστικά + με στάθμιση κλάσεων).	82
B.4	Dataset B (C2: baseline χαρακτηριστικά + με στάθμιση κλάσεων).	82
B.5	Dataset A (C3: extended χαρακτηριστικά + χωρίς στάθμιση κλάσεων).	82
B.6	Dataset B (C3: extended χαρακτηριστικά + χωρίς στάθμιση κλάσεων).	82
B.7	Dataset A (C4: extended χαρακτηριστικά + με στάθμιση κλάσεων).	83
B.8	Dataset B (C4: extended χαρακτηριστικά + με στάθμιση κλάσεων).	83

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορικό και κίνητρα

Η δεύτερη πιο συχνή νευροεκφυλιστική διαταραχή είναι η νόσος Πάρκινσον, η οποία επηρεάζει περίπου το 1% των ατόμων άνω των 60 ετών. Μία από τις μεγαλύτερες προκλήσεις στην παροχή κλινικής φροντίδας σε ασθενείς με νόσο Πάρκινσον είναι η δυνατότητα έγκαιρης και ακριβούς διάγνωσης. Συνήθως, όταν ο ασθενής εμφανίσει εμφανή συμπτώματα, έχει χάσει σημαντική ποσότητα νευρώνων του.

Επιπλέον, πολλά άτομα με νόσο Πάρκινσον παρουσιάζουν αλλαγές στην ομιλία τους λόγω επιδράσεων στις φωνητικές χορδές (που βρίσκονται μέσα στον λάρυγγα) και στους αναπνευστικούς μύες (λόγω εξασθένησης και των δύο). Αυτές οι αλλαγές μπορεί στην πραγματικότητα να συμβούν έως και επτά χρόνια πριν ένας ασθενής εμφανίσει οποιοδήποτε από τα συνηθισμένα σωματικά συμπτώματα [2]. Οι βιοδείκτες που βασίζονται στη φωνή είναι στην πραγματικότητα ένας πολύ εύκολος τρόπος για τη διάγνωση της νόσου, ο οποίος είναι επίσης φθηνός και δεν απαιτεί ειδικό εξοπλισμό [3, 4].

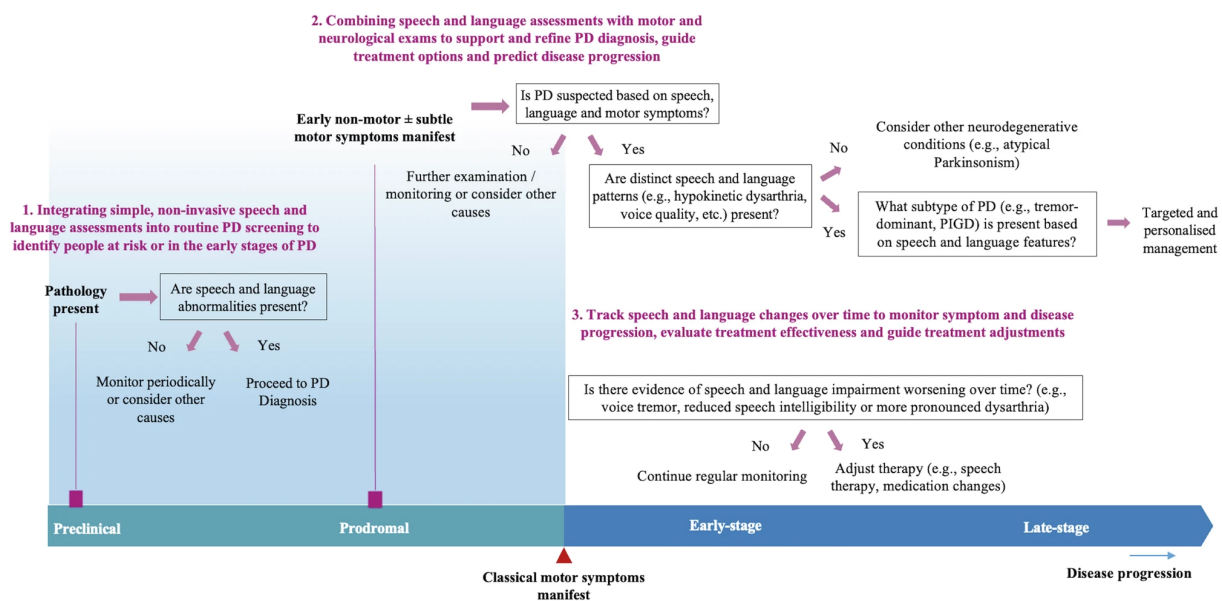
Ο λάρυγγας και οι αναπνευστικοί μύες επηρεάζονται από τη νόσο του Πάρκινσον. Αυτό έχει ως αποτέλεσμα αισθητές αλλοιώσεις στην προσωδία της ομιλίας ενός ατόμου (όπως η ένταση, η ένταση και ο ρυθμός) και τα χαρακτηριστικά του ίδιου του ήχου (δηλαδή, η δομή και η συχνότητα). Τα χαρακτηριστικά ομιλίας που εκδηλώνονται συχνότερα από άτομα που έχουν διαγνωστεί με νόσο του Πάρκινσον (PD) αναφέρονται ως υποκινητική δυσαρθρία (HKD).

Η HKD χαρακτηρίζεται γενικά από τις ακόλουθες ανωμαλίες στην ομιλία: (α) υποφωνία, η οποία είναι η μείωση της έντασης ή της φωνητικής έντασης της ομιλίας· (β) μονοτονία, η οποία αναφέρεται στην ικανότητα παραγωγής ομοιόμορφης ή περιορισμένης ποσότητας ύψους ή τόνου κατά την ομιλία· και (γ) μονοφωνία, που σημαίνει ότι ένα άτομο θα μιλάει σε ένα επίπεδο έντασης, αν και μπορεί να μιλάει σε ποικίλες εντάσεις [5]. Επιπλέον, το άτομο μπορεί να παράγει ομιλία που είναι ασαφής και δύσκολη στην κατανόηση· μπορεί να υπάρχουν κάποιες αλλοιώσεις στη φωνή ενός ατόμου, όπως η δύσπνοια, η βραχνάδα ή η τραχιά φωνή. Μπορεί επίσης να υπάρχουν διαφορές στον ρυθμό, την ταχύτητα και τη ροή της ομιλίας κάποιου [5].

Βασικά, μπορείτε να ηχογραφήσετε τη φωνή σας με ένα απλό μικρόφωνο ή το τηλέφωνό σας, γεγονός που διευκολύνει τη χρήση της ανάλυσης ομιλίας στην ιατρική για τη διάγνωση ή την παρακολούθηση ασθενειών. Μερικές φορές υπάρχουν ασυνήθιστοι ήχοι στις φωνές μας που μπορούν να ανιχνευθούν πριν αρχίσουμε να εμφανίζουμε τυπικά συμπτώματα μιας ασθένειας, επομένως η

ομιλία μας μπορεί να αποτελεί ένδειξη μιας ασθένειας.

Τα τελευταία χρόνια, η έρευνα έχει γίνει με φθηνά κινητά τηλέφωνα, αντί για τον ακριβό εξοπλισμό που χρησιμοποιούνταν σε ειδικά εργαστήρια στο παρελθόν. Αυτό οδηγεί στο ερώτημα κατά πόσον τα αποτελέσματα αυτού του είδους των μελετών έχουν εφαρμογή σε άλλες καταστάσεις και τύπους εξοπλισμού από αυτούς που χρησιμοποιήθηκαν για τις παλιές μελέτες [6]. Οι φωνητικοί δείκτες έχουν χρησιμοποιηθεί για δύο κύριους λόγους: (1) για τον έλεγχο και την ανίχνευση της νόσου, που αποτελεί τον κύριο ερευνητικό στόχο περίπου του 94% των μελετών που έχουν διεξαχθεί μέχρι σήμερα και (β) προκειμένου να παρακολουθηθεί η πρόοδος και τα αποτελέσματα της θεραπείας [7]. Ωστόσο, τα στοιχεία από διαχρονικές μελέτες που υποστηρίζουν τον στόχο β παραμένουν περιορισμένα και σχεδόν όλα τα ακουστικά χαρακτηριστικά της φωνής που έχουν μελετηθεί και επικυρωθεί στον ακουστικό τομέα υπάρχουν κυρίως μέσω διατομεακής επικύρωσης [8].



Σχήμα 1.1: Κλινικό πλαίσιο αξιοποίησης βιοδεικτών ομιλίας και γλώσσας στη νόσο του Πάρκινσον σε όλα τα στάδια της νόσου. Απεικονίζονται τρεις κύριες εφαρμογές: (1) έγκαιρη ανίχνευση και διάλογη στο πρόδρομο στάδιο, (2) υποστήριξη διαφορικής διάγνωσης και εξατομικευμένη διαχείριση στο πρώιμο στάδιο, και (3) παρακολούθηση εξέλιξης νόσου και ρύθμιση θεραπείας στα μεταγενέστερα στάδια. Προσαρμογή από Cao et al. [1].

1.2 Διατύπωση του προβλήματος

Παρόλο που έχουν γίνει σημαντικές προσπάθειες για την ανάπτυξη μεθόδων που χρησιμοποιούν τη φωνή για την ανίχνευση της νόσου του Πάρκινσον, εξακολουθούν να υπάρχουν αρκετές προκλήσεις:


1. **Μικρά μεγέθη δειγμάτων** Όταν τα διαθέσιμα ηχητικά δεδομένα είναι λίγα, είναι δύσκολο να δημιουργηθούν μοντέλα που να λειτουργούν σωστά και σε νέους πληθυσμούς.
2. **Διαρροή ταυτότητας υποκειμένου (subject leakage)** Συμβαίνει όταν ηχογραφήσεις του ίδιου ατόμου χρησιμοποιούνται και για εκπαίδευση και για έλεγχο του μοντέλου. Αυτό μπορεί να

οδηγήσει σε υπερβολικά καλά αλλά μη ρεαλιστικά αποτελέσματα.

3. **Ανισορροπία κλάσεων** Συνήθως δεν υπάρχει ίδιος αριθμός δειγμάτων από άτομα με Πάρκινσον (PD) και από υγιή άτομα (HC), κάτι που μπορεί να επηρεάσει την απόδοση του μοντέλου.
4. **Επιλογή χαρακτηριστικών** Ο τρόπος με τον οποίο αναπαρίσταται η φωνή (ποια χαρακτηριστικά επιλέγονται) μπορεί να επηρεάσει σημαντικά το πόσο καλά λειτουργεί το μοντέλο ταξινόμησης.
5. **Διαφορετικές μέθοδοι επικύρωσης** Οι μελέτες χρησιμοποιούν διαφορετικούς τρόπους για να αξιολογήσουν τα μοντέλα (π.χ. k-fold cross-validation, fixed train/test split, leave-one-subject-out, external validation). Αυτές οι μέθοδοι δίνουν διαφορετικές εκτιμήσεις απόδοσης και επηρεάζουν metrics όπως accuracy, precision, recall, F1-score και ROC-AUC, κάτι που δυσκολεύει τη σύγκριση των αποτελεσμάτων μεταξύ μελετών. Παρ' όλα αυτά, λίγες μελέτες χρησιμοποιούν external validation [6].
6. **Χάσμα γενίκευσης μεταξύ συνόλων δεδομένων**: Ένα μοντέλο μπορεί να έχει πολύ υψηλό accuracy στο αρχικό σύνολο δεδομένων, αλλά η απόδοσή του συχνά μειώνεται όταν δοκιμαστεί σε νέα, διαφορετικά δεδομένα. Αυτό μπορεί να οδηγήσει σε υπερβολικούς ισχυρισμούς για την πραγματική του απόδοση [6].

Όλες αυτές οι προκλήσεις εξετάζονται σε αυτή τη εργασία εργασία με έναν προσεκτικό πειραματικό σχεδιασμό, που δίνει έμφαση στη σωστή μεθοδολογία και όχι απλώς στην επίτευξη υψηλών ποσοστών απόδοσης.

Το Σχήμα 1.2 συνοψίζει τη συνολική πειραματική ροή της εργασίας και αναδεικνύει τον διαχωρισμό μεταξύ των δύο pipelines (Dataset A: ακατέργαστος ήχος → εξαγωγή χαρακτηριστικών, Dataset B: προ-εξαγμένα χαρακτηριστικά → ταξινόμηση).



Σχήμα 1.2: Σύνοψη της πειραματικής ροής της εργασίας για τα δύο σύνολα δεδομένων. Η ανάλυση στο Dataset A ακολουθεί τη διαδρομή WAV → εξαγωγή χαρακτηριστικών → κλασική μηχανική μάθηση, ενώ στο Dataset B η είσοδος είναι ήδη πίνακας χαρακτηριστικών. Σε όλες τις περιπτώσεις αναφέρονται οι ίδιες μετρικές αξιολόγησης (Accuracy, Precision, Recall, F1, ROC-AUC).

1.3 Ερευνητικοί στόχοι

Οι κύριοι στόχοι αυτής της εργασίας είναι:

1. Να **παρέχει μια αναπαραγώγιμη διαδικασία** για την εξαγωγή ακουστικών χαρακτηριστικών από ηχογραφήσεις φωνής.
2. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost) για την ταξινόμηση PD έναντι HC.
3. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης σε δύο ξεχωριστά σύνολα δεδομένων, τα οποία έχουν διαφορετικά χαρακτηριστικά.
4. Να **αξιολογήσει την επίδραση** της αύξησης των χαρακτηριστικών (από 47 σε 78) με ελεγχόμενο τρόπο.
5. Να **αξιολογήσει την επίδραση** της χρήσης βαρών κλάσης (class-weighting) ώστε να αντιμετωπιστεί η ανισορροπία μεταξύ των ομάδων.

1.4 Συνεισφορές

Η παρούσα διπλωματική συμβάλλει στη μελέτη των φωνητικών βιοδεικτών της νόσου του Πάρκινσον με τους εξής τρόπους:

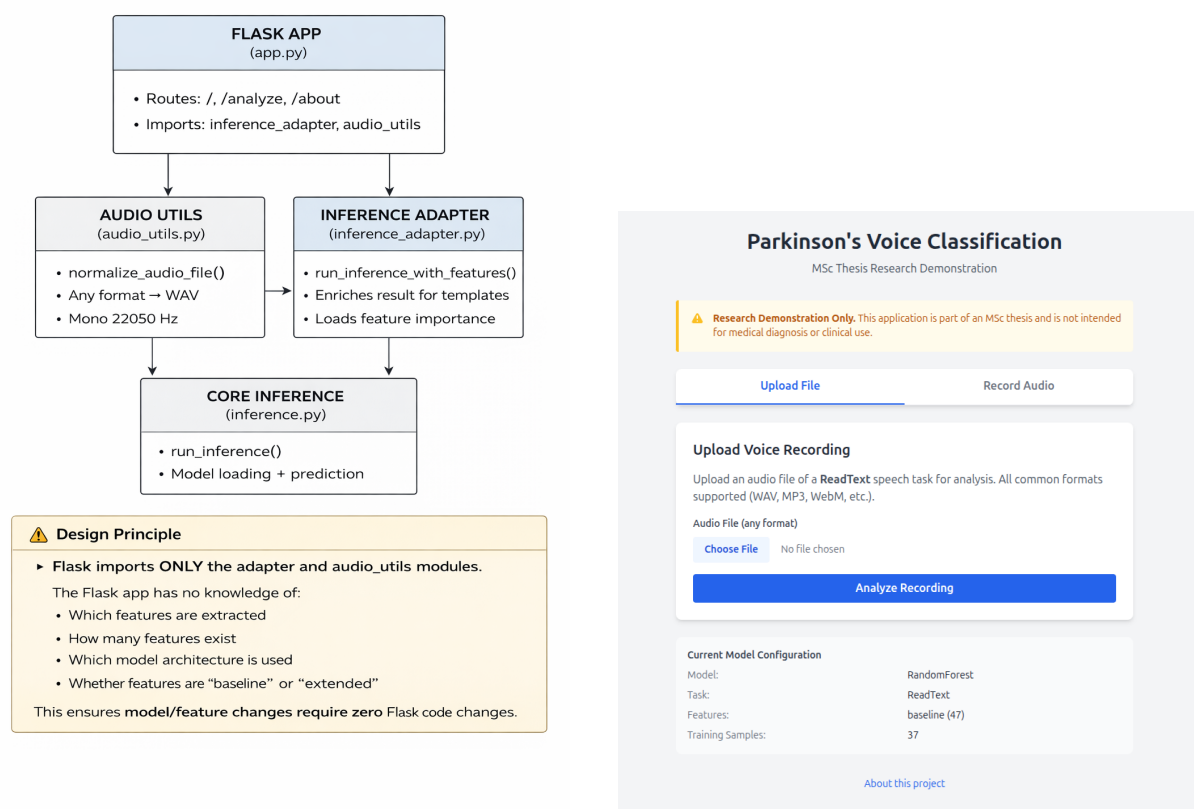
- **Αξιολόγηση χωρίς διαρροή ταυτότητας:** Χρησιμοποιήθηκε cross-validation ανά υποκείμενο, έτσι ώστε όλες οι ηχογραφήσεις του ίδιου ατόμου να βρίσκονται είτε στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής. Με αυτόν τον τρόπο αποφεύγεται η «διαρροή δεδομένων», δηλαδή το να μαθαίνει το μοντέλο από το ίδιο άτομο που αργότερα καλείται να προβλέψει.
- **Έλεγχος της αύξησης των χαρακτηριστικών:** Μελετήθηκε τι συμβαίνει όταν τα χαρακτηριστικά αυξάνονται από 47 σε 78. Η αύξηση αυτή βελτίωσε την απόδοση έως και 23% (ROC-AUC). Παράλληλα, εξετάστηκε ποια από τα νέα χαρακτηριστικά συνέβαλαν περισσότερο στη βελτίωση.
- **Σύγκριση αυθόρμητης και δομημένης ομιλίας:** Βρέθηκε ότι τα μοντέλα αποδίδουν καλύτερα όταν χρησιμοποιείται αυθόρμητη ομιλία σε σχέση με δομημένη ανάγνωση. Για παράδειγμα, το Random Forest είχε καλύτερη απόδοση στην αυθόρμητη ομιλία, γεγονός που δείχνει ότι τέτοιου τύπου δεδομένα ίσως αποτυπώνουν καλύτερα τις αλλαγές που σχετίζονται με τη νόσο.
- **Σύγκριση δύο διαφορετικών datasets:** Τα αποτελέσματα από ένα αυστηρά ελεγχόμενο dataset συγκρίθηκαν με ένα δημόσιο dataset με προ-εξαγμένα χαρακτηριστικά. Στο δημόσιο dataset, η απλή cross-validation έδωσε πολύ υψηλές τιμές απόδοσης (π.χ. AUC ~0,94), που πιθανόν δεν είναι ρεαλιστικές. Αυτό δείχνει πόσο σημαντική είναι η σωστή μεθοδολογία αξιολόγησης.
- **Ερμηνεία των χαρακτηριστικών:** Πέρα από τη μέτρηση της απόδοσης, έγινε και ανάλυση της σημασίας των χαρακτηριστικών, ώστε να είναι πιο κατανοητό ποια στοιχεία της φωνής

συμβάλλουν περισσότερο στην ανίχνευση της νόσου. Αυτό ενισχύει τη διαφάνεια και τη χρησιμότητα των αποτελεσμάτων.

Για να υποστηριχθεί η παρουσίαση της μεθοδολογίας και η ποιοτική ερμηνεία του pipeline, αναπτύχθηκε επίσης μια απλή διαδικτυακή εφαρμογή ερευνητικής επίδειξης. Η εφαρμογή έχει αποκλειστικά ερευνητικό και εκπαιδευτικό χαρακτήρα και δεν αποτελεί κλινικό εργαλείο ή διαγνωστικό σύστημα.

Η αρχιτεκτονική της εφαρμογής ακολουθεί αρθρωτή ροή, όπως φαίνεται στο Σχήμα 1.3.

Architecture



(α') Αρχιτεκτονική της εφαρμογής ερευνητικής επίδειξης.

(β') Κύρια προβολή φόρμας εισόδου.

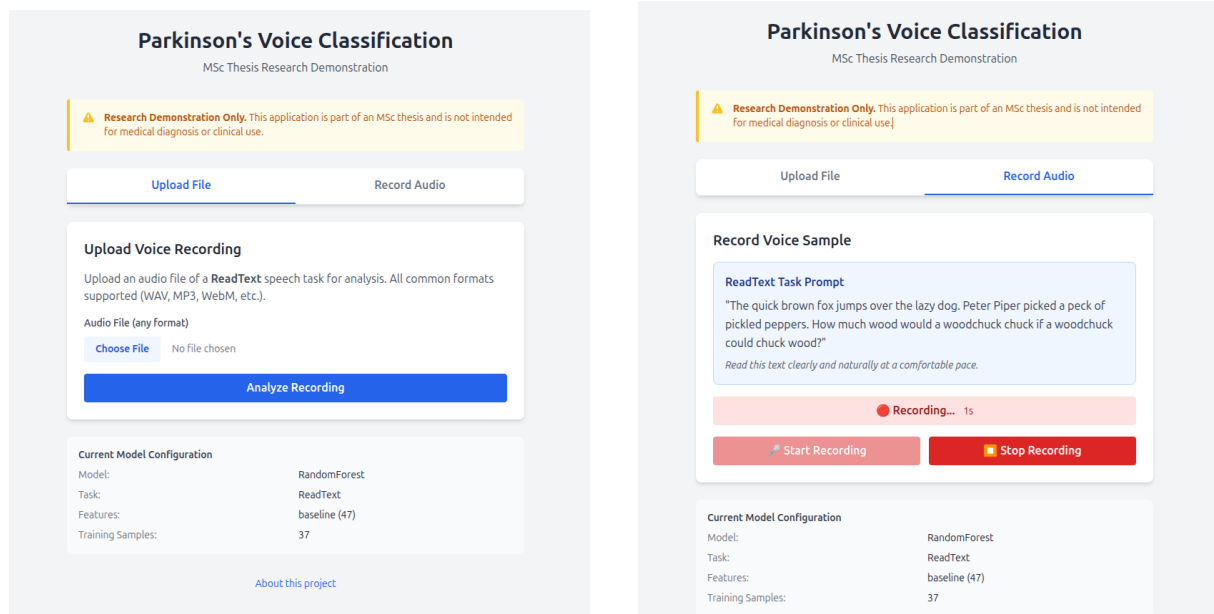
Σχήμα 1.3: Αρχιτεκτονική της εφαρμογής ερευνητικής επίδειξης και κύρια σελίδα εισόδου σε παράθεση δίπλα-δίπλα.

Συγκεκριμένα:

- το `app.py` διαχειρίζεται διαδρομές, μεταφόρτωση/καταγραφή ήχου και προβολή αποτελεσμάτων,
- το `inference_adapter.py` λειτουργεί ως ενιαίο σημείο κλήσης για προεπεξεργασία, πρόβλεψη και μορφοποίηση εξόδου,
- το `audio_utils.py` κανονικοποιεί κάθε είσοδο σε mono 22,050 Hz PCM-16 WAV πριν από

την εξαγωγή χαρακτηριστικών.

Η διεπαφή υποστηρίζει μεταφόρτωση αρχείου και άμεση καταγραφή από μικρόφωνο. Η συνοπτική απεικόνιση των βασικών οθονών που χρησιμοποιήθηκαν στην επίδειξη δίνεται στο Σχήμα 1.4.



(α') Μεταφόρτωση αρχείου ήχου.


(β') Άμεση καταγραφή μέσω φυλλομετρητή.

Σχήμα 1.4: Κύριες οθόνες της εφαρμογής ερευνητικής επίδειξης σε διάταξη 2x1.

Για κάθε είσοδο εκτελούνται τα ίδια βήματα: (1) κανονικοποίηση ήχου, (2) εξαγωγή χαρακτηριστικών (47 ή 78), (3) φόρτωση εκπαιδευμένου μοντέλου και πρόβλεψη, (4) προβολή ετικέτας, πιθανοτήτων και μεταδεδομένων ανάλυσης.

Η ερμηνεία των εξόδων απαιτεί προσοχή: οι πιθανότητες εξόδου είναι δείκτες εμπιστοσύνης του μοντέλου και όχι ιατρική απόφαση, ενώ η εφαρμογή δεν χρησιμοποιήθηκε για τον υπολογισμό των μετρικών των Κεφαλαίων 5–6.

Η οπτική σύνοψη στο Σχήμα 1.5 λειτουργεί ως σύντομη προεπισκόπηση των κύριων εμπειρικών μοτίβων που αναλύονται εκτενώς στα Κεφάλαια 6 και 7.



Σχήμα 1.5: Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά ακουστική κατηγορία (Random Forest, Dataset A). Τα MFCC και Delta-MFCC κυριαρχούν και στα δύο tasks· η σχετική βαρύτητα Pitch/Shimmer υποδηλώνει task-εξαρτώμενη ευαισθησία.

Πίνακας 1.1: Συνοπτικός πίνακας από τα feature-importance summary CSV (Random Forest, baseline, Dataset A): κορυφαία 3 χαρακτηριστικά ανά task (mean $\pm$ std).

Task	Feature	Importance
ReadText	f0_max	0,0516 $\pm$ 0,0192
	delta_mfcc_2_mean	0,0387 $\pm$ 0,0178
	f3_std	0,0378 $\pm$ 0,0114
SpontaneousDialogue	mfcc_5_mean	0,0805 $\pm$ 0,0225
	shimmer_apq11	0,0693 $\pm$ 0,0068
	delta_mfcc_8_mean	0,0509 $\pm$ 0,0148

1.5 Οργάνωση της εργασίας

Τα υπόλοιπα κεφάλαια αυτής της εργασίας ακολουθούν το οργανωτικό σχήμα που παρέχεται παρακάτω:

Πίνακας 1.2: Περίληψη των κεφαλαίων της εργασίας

Κεφάλαιο	Τίτλος	Περιγραφή
2	Βιβλιογραφική ανασκόπηση	Επισκόπηση των μεθοδολογιών ανίχνευσης PD με βάση τη φωνή
3	Περιγραφή δεδομένων	Λεπτομερείς περιγραφές των συνόλων δεδομένων που χρησιμοποιήθηκαν σε αυτή τη εργασία
4	Μεθοδολογία	Διαδικασία εξαγωγής ακουστικών χαρακτηριστικών και κατασκευής μοντέλου μηχανικής μάθησης
5	Πειραματικός σχεδιασμός	Πρωτόκολλο για την αξιολόγηση των επιδράσεων κάθε μεταβλητής
6	Αποτελέσματα	Ποσοτικά αποτελέσματα για κάθε μία από τις συνθήκες
7	Συζήτηση	Επεξήγηση των αποτελεσμάτων και σύγκριση με προηγούμενες εργασίες
8	Περιορισμοί	Περιορισμοί και περιορισμοί της μελέτης
9	Συμπεράσματα	Περίληψη των κύριων ευρημάτων και πιθανών μελλοντικών τομέων έρευνας

1.6 Όρια πεδίου εφαρμογής

Η μελέτη έχει τα ακόλουθα όρια πεδίου εφαρμογής:

- **Μόνο δυαδική ταξινόμηση:** Η εργασία εξετάζει μόνο αν ένα άτομο έχει Πάρκινσον ή όχι (PD vs HC). Δεν μελετά πόσο σοβαρή είναι η νόσος, πώς εξελίσσεται με τον χρόνο ή πώς ξεχωρίζει από άλλες ασθένειες.
- **Μόνο κλασικά μοντέλα μηχανικής μάθησης:** Χρησιμοποιούνται μόνο κλασικά και πιο εύκολα ερμηνεύσιμα μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost). Δεν χρησιμοποιούνται νευρωνικά δίκτυα ή βαθιά μάθηση, κυρίως λόγω του μικρού μεγέθους των δεδομένων και της έμφασης στην κατανόηση των αποτελεσμάτων. Η εργασία προσφέρει έτσι μια καθαρή και αξιόπιστη βάση για μελλοντικές πιο σύνθετες μεθόδους.
- **Ερευνητικός χαρακτήρας:** Τα μοντέλα που παρουσιάζονται έχουν ερευνητικό σκοπό. Δεν προορίζονται να χρησιμοποιηθούν άμεσα από γιατρούς για διάγνωση χωρίς επιπλέον έλεγχο και επιβεβαίωση.
- **Έμφαση στην αναπαραγωγιμότητα:** Δόθηκε προτεραιότητα στο να μπορούν τα πειράματα να επαναληφθούν από άλλους ερευνητές. Για αυτό χρησιμοποιήθηκαν σταθερές ρυθμίσεις, σαφής περιγραφή των βημάτων και σωστή τεκμηρίωση του κώδικα. Η αξιοπιστία των αποτελεσμάτων θεωρήθηκε πιο σημαντική από το να επιτευχθούν απλώς υψηλότερα ποσοστά απόδοσης.

Κεφάλαιο 2

Βιβλιογραφική ανασκόπηση

2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας

Η νόσος του Πάρκινσον είναι γνωστή κυρίως για τα κινητικά της συμπτώματα (τρέμουλο, ακαμψία, βραδυκινησία), αλλά παράλληλα με αυτά επηρεάζει συστηματικά και την ομιλία και τη φωνή [9]. Η κλινική ετερογένεια και η διαγνωστική πολυπλοκότητα της νόσου έχουν επίσης τεκμηριωθεί εκτενώς [10]. Σύμφωνα με τον Παγκόσμιο Οργανισμό Υγείας, αποτελεί μία από τις ταχύτερα αυξανόμενες νευρολογικές διαταραχές παγκοσμίως [11]. Περίπου το 70–90% των ατόμων με νόσο του Πάρκινσον αναπτύσσουν μετρήσιμες διαταραχές της ομιλίας και της φωνής κατά τη διάρκεια της νόσου [12]. Αυτή η συλλογή συμπτωμάτων της ομιλίας στη νόσο του Πάρκινσον περιγράφεται συχνά ως *υποκινητική δυσαρθρία*, υποδηλώνοντας ένα χαρακτηριστικό μοτίβο διαταραχής του κινητικού ελέγχου της ομιλίας που σχετίζεται με τη νόσο [5]. Σε επίπεδο βιομηχανικής φώνησης, οι αλλαγές αυτές μπορούν να κατανοηθούν μέσω του μοντέλου πηγής-φίλτρου της παραγωγής ομιλίας [13].

Η ομιλία στην PD χαρακτηρίζεται από *υποφωνία* (μειωμένη ένταση), *μονοτονία* και *μονοφωνία* (μειωμένη προσωδιακή μεταβλητότητα), ασαφή άρθρωση και φωνή με αναπνοή ή βραχνάδα που προκύπτει από ατελές κλείσιμο των φωνητικών χορδών [5, 14].

Αυτές οι αλλαγές στην ομιλία στην PD παρουσιάζουν ενδιαφέρον όχι μόνο ως συμπτώματα που επηρεάζουν την ικανότητα επικοινωνίας ενός ατόμου, αλλά και ως πιθανοί μη επεμβατικοί βιοδείκτες της νόσου. Η φωνή είναι σχετικά εύκολο να καταγραφεί (για παράδειγμα, μέσω μιας σύντομης ηχογράφησης σε ένα smartphone) και οι φωνητικές αλλαγές μπορεί να εμφανιστούν νωρίς στην πορεία της νόσου. Ορισμένες έρευνες υποδηλώνουν ότι οι λεπτές ανωμαλίες της φωνής μπορούν να ανιχνευθούν πριν από την εμφάνιση των κλασικών κινητικών συμπτωμάτων σε ορισμένους ασθενείς [2]. Δεδομένου ότι η ηχογράφηση και η ανάλυση της φωνής μπορούν να πραγματοποιηθούν με χαμηλό κόστος και εξ αποστάσεως, υπάρχει σημαντική κινητοποίηση για τη χρήση της ομιλίας ως μέσου ανίχνευσης ή παρακολούθησης της νόσου του Πάρκινσον χωρίς την ανάγκη επεμβατικών εξετάσεων [15]. Οι μετρήσεις της ομιλίας και της φωνής είναι κατάλληλες για εφαρμογές τηλεϊατρικής και για τη διαχρονική παρακολούθηση της εξέλιξης της νόσου του Πάρκινσον [4]. Σε αντίθεση με πολλές κλινικές αξιολογήσεις που απαιτούν προσωπικές επισκέψεις και εξειδικευμένο εξοπλισμό, οι ηχογραφήσεις φωνής μπορούν να ληφθούν από τους ασθενείς στο σπίτι τους και να αναλυθούν με αλγόριθμους, επιτρέποντας πιο συχνή και χαμηλότερου κόστους παρακολούθηση.

2.2 Ανίχνευση έναντι παρακολούθησης

Η έρευνα για την PD με βάση τη φωνή αντιμετωπίζει δύο σχετικούς αλλά διακριτούς στόχους: **ανίχνευση/διαλογή** (δυαδική ταξινόμηση της PD έναντι της HC) και **παρακολούθηση/εξέλιξη** (παρακολούθηση της σοβαρότητας της νόσου ή της ανταπόκρισης στη θεραπεία με την πάροδο του χρόνου). Μια συστηματική ανασκόπηση 106 μελετών που δημοσιεύθηκαν μεταξύ 2019 και 2023 διαπίστωσε ότι περίπου το 94% επικεντρώθηκε στη διάγνωση ή την ανίχνευση, ενώ λιγότερο από το 12% ασχολήθηκε με την πρόγνωση ή την εξέλιξη [7].

Οι δύο στόχοι ευνοούν διαφορετικές λειτουργίες ομιλίας και ακουστικά χαρακτηριστικά. Η παρατεταμένη φώνηση φωνηέντων είναι πιο αποτελεσματική για τη δυαδική διάκριση PD/HC, καθώς απομονώνει τη λειτουργία του λάρυγγα και παρέχει σταθερές μετρήσεις διαταραχής και θορύβου [8]. Οι συνδεδεμένες λειτουργίες ομιλίας, όπως η ανάγνωση αποσπασμάτων και ο αυθόρμητος διάλογος, είναι πιο ενημερωτικές για την εκτίμηση της σοβαρότητας, καθώς καταγράφουν την ακρίβεια της άρθρωσης, τον ρυθμό ομιλίας και την προσωδιακή διακύμανση, χαρακτηριστικά που συσχετίζονται με κλινικές κλίμακες σοβαρότητας όπως η UPDRS [8]. Τα χαρακτηριστικά άρθρωσης (MFCC, συντελεστές PLP, περιοχή φωνηέντων) έχουν αναφερθεί ότι αποδίδουν μέσο accuracy 80–95% για την πρόβλεψη της σοβαρότητας, σε σύγκριση με 75–90% για τα φωνητικά χαρακτηριστικά μόνο [8].

Ένας κρίσιμος περιορισμός της βιβλιογραφίας σχετικά με την παρακολούθηση είναι η έλλειψη διαχρονικών δεδομένων: οι περισσότερες μελέτες συγκρίνουν ομάδες PD και HC διατομεακά, αντί να παρακολουθούν τις ακουστικές αλλαγές σε μεμονωμένα άτομα με την πάροδο του χρόνου [8]. Η παρούσα εργασία επικεντρώνεται στην αξιόπιστη ανίχνευση χρησιμοποιώντας δύο τύπους εργασιών ομιλίας (ReadText και SpontaneousDialogue), αλλά το σύνολο χαρακτηριστικών έχει σχεδιαστεί κατά τρόπο που παραμένει συμβατό με μελλοντικές εργασίες παρακολούθησης.

Το Σχήμα 1.1 (Κεφάλαιο 1) απεικονίζει ένα κλινικό πλαίσιο από τον Cao et al. [1] που συνοψίζει τους τρεις ρόλους των βιοδεικτών ομιλίας και γλώσσας κατά μήκος του συνεχούς εξέλιξης της νόσου: (1) ανίχνευση και διαλογή ατόμων υψηλού κινδύνου στο προκλινικό και προδρομικό στάδιο, (2) υποστήριξη της διαφορικής διάγνωσης και εξατομίκευση της θεραπείας στο πρώιμο στάδιο, και (3) παρακολούθηση της εξέλιξης της νόσου και ρύθμιση της αγωγής στα μεταγενέστερα στάδια. Η παρούσα εργασία εστιάζει στο πρώτο σκέλος—δυαδική ταξινόμηση PD έναντι HC—ως θεμέλιο για τα δύο επόμενα.

2.3 Ταξινόμηση ακουστικών χαρακτηριστικών

Πίνακας 2.1: Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD

Κατηγορία	Παραδείγματα	Φυσιολογική βάση
Θεμελιώδης συχνότητα	F_0 μέσος όρος, F_0 τυπική απόκλιση	Τάση φωνητικών χορδών και κινητική ακαμψία
Διαταραχή	Jitter, Shimmer	Νευρομυϊκή αστάθεια
Θόρυβος	HNR, NHR	Ατελής κλείσιμο της γλωττίδας
Formants	F_1 , F_2 , F_3	Διαμόρφωση φωνητικού σωλήνα
Φασματικά/Cepstral	MFCCs, delta-MFCCs	Φασματική περιβάλλουσα και δυναμική

Προσωδιακά χαρακτηριστικά σχετίζονται με το ύψος (F_0) και τα μοτίβα έντασης. Η PD μειώνει το εύρος F_0 (μονοτονικότητα) και το εύρος έντασης (μονοεντατικότητα), τα οποία σχετίζονται με την ταξινόμηση PD [16]. Οι στατιστικές πληθυσμού που καταγράφονται περιλαμβάνουν μέση τιμή F_0 , τυπική απόκλιση, ελάχιστη και μέγιστη τιμή, μέση ένταση και μεταβλητότητα, καθώς και συχνότητες φορμώντων που αντανακλούν τη διαμόρφωση του φωνητικού σωλήνα.

Τα **μέτρα διαταραχής** ποσοτικοποιούν την αστάθεια από κύκλο σε κύκλο στη δόνηση των φωνητικών χορδών. Το jitter (διαταραχή περιόδου) και το shimmer (διαταραχή πλάτους) είναι αυξημένα στην PD, αντανακλώντας τη νευρομυϊκή ασυντονιστικότητα που εμποδίζει την πηγή ομιλίας να διατηρήσει έναν τακτικό κύκλο δόνησης. Ο λόγος αρμονικών προς θόρυβο (HNR) μετρά την αναλογία της περιοδικής προς την μη περιοδική ενέργεια. Οι χαμηλότερες τιμές HNR υποδηλώνουν μια πιο αναπνευστική, θορυβώδη ποιότητα φωνής που είναι χαρακτηριστική της PD [3].

Τα **φασματικά και cepstral χαρακτηριστικά** σχετίζονται με το φασματικό περίβλημα του φωνητικού σήματος. Οι Mel-Frequency Cepstral Coefficients (MFCCs), που εισήχθησαν αρχικά από τους Davis and Mermelstein [17], καταγράφουν πληροφορίες σχετικά με το φασματικό σχήμα χρησιμοποιώντας μια κλίμακα συχνοτήτων που βασίζεται στην αντίληψη, ενώ οι χρονικές παράγωγοί τους (delta και delta-delta) καταγράφουν τις δυναμικές αλλαγές στα φασματικά δεδομένα με την πάροδο του χρόνου [18]. Οι περιγραφές φασματικού σχήματος, όπως το κέντρο βάρους, το εύρος ζώνης, η απόκλιση και η επιπεδότητα, παρέχουν συμπληρωματικά μέτρα της συνολικής κατανομής ενέργειας. Μαζί, αυτές οι τρεις κατηγορίες χαρακτηριστικών είναι συμπληρωματικές και παρέχουν μια ολιστική περιγραφή της ακουστικής αλλαγής που σχετίζεται με την PD.

2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας

Πρόσφατες συστηματικές ανασκοπήσεις οργανώνουν τα ακουστικά χαρακτηριστικά σε τρεις λειτουργικά καθορισμένες κατηγορίες που αντιστοιχούν σε διακριτές πτυχές του μηχανισμού παραγωγής ομιλίας [8]:

- **Φωνητικά χαρακτηριστικά** (jitter, shimmer, HNR, λόγος διέγερσης γλωττίδας προς θόρυβο, εντροπία περιόδου τόνου) ποσοτικοποιούν τη σταθερότητα και την πληρότητα της δόνησης

των φωνητικών χορδών. Αυτά τα χαρακτηριστικά είναι αυξημένα ή μειωμένα στην PD ως αποτέλεσμα της νευρομυϊκής αστάθειας και του ατελούς κλεισίματος της γλωττίδας.

- **Χαρακτηριστικά άρθρωσης** (MFCCs, cepstral peak prominence, formant frequencies, vowel space area, vowel articulation index, perceptual linear prediction coefficients) καταγράφουν τη δυναμική και την ακρίβεια της κίνησης του φωνητικού σωλήνα. Η περιοχή του φωνητικού χώρου είναι σταθερά μειωμένη στην PD, αντανακλώντας την περιορισμένη άρθρωση.
- **Προσωδιακά χαρακτηριστικά** (μεταβλητότητα F_0 στη συνδεδεμένη ομιλία, ρυθμός ομιλίας, αριθμός και διάρκεια παύσεων, μέγιστος χρόνος φώνησης) καταγράφουν τα υπερκειμενικά μοτίβα του τόνου, του συγχρονισμού και του ρυθμού. Αυτά τα χαρακτηριστικά αντανακλούν τη μειωμένη προσωδιακή διακύμανση σε επίπεδο πρότασης στην PD, παράλληλα με την αυξημένη αστάθεια του τόνου σε επίπεδο μικρού τμήματος.

Από τα 18 χαρακτηριστικά που εξετάστηκαν από τον Wright and Aharonson [8], 12 έδειξαν μετρήσιμες και συνεπείς διαφορές μεταξύ ασθενών με PD και υγιών ατόμων ελέγχου, με το jitter, το shimmer και το HNR να είναι τα πιο συνεπή διακριτικά χαρακτηριστικά σε όλες τις μελέτες. Συμπληρωματικά, η συστηματική ανασκόπηση των Ngo et al. [19] επισημαίνει ότι η ετερογένεια datasets και πρωτοκόλλων αξιολόγησης δυσχεραίνει τις άμεσες συγκρίσεις μεταξύ μελετών. Αυτό το πλαίσιο τριών κατηγοριών είναι συμπληρωματικό της παραδοσιακής ομαδοποίησης επεξεργασίας σήματος που παρουσιάζεται στον Πίνακα 2.1 και παρέχει μια κλινικά τεκμηριωμένη προοπτική για την ερμηνεία των αποτελεσμάτων σχετικά με τη σημασία των χαρακτηριστικών.

2.4 Σύνολα δεδομένων για τη φωνή ασθενών με Πάρκινσον

Η απόδοση και τα συμπεράσματα μιας μελέτης μηχανικής μάθησης εξαρτώνται άμεσα από τα δεδομένα που χρησιμοποιούνται. Στην έρευνα για τη φωνή των ασθενών με PD, έχουν χρησιμοποιηθεί διάφορα σύνολα δεδομένων, το καθένα με διαφορετικά χαρακτηριστικά. Γενικά, αυτά μπορούν να χωριστούν σε **ακατέργαστα σύνολα δεδομένων ήχου** (ηχογραφημένα φωνητικά σήματα που απαιτούν εξαγωγή χαρακτηριστικών) και **προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών** (όπου τα δεδομένα παρέχονται ήδη με τη μορφή τιμών χαρακτηριστικών ανά δείγμα). Παρακάτω εξετάζονται αντιπροσωπευτικά παραδείγματα κάθε κατηγορίας και η συνάφειά τους με την παρούσα εργασία.

2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου

Τα ακατέργαστα σύνολα δεδομένων ήχου για την PD συνήθως αποτελούνται από ηχογραφήσεις φωνής ασθενών με PD και υγιών ατόμων που έχουν συλλεχθεί σε ελεγχόμενο περιβάλλον. Ένα γνωστό πρώιμο παράδειγμα είναι το σύνολο δεδομένων του Little et al. [20] που διατίθεται μέσω του UCI Machine Learning Repository. Η κλασική μελέτη των Rusz et al. [21] κατέδειξε ποσοτικά ότι οι ακουστικές μετρήσεις μπορούν να χαρακτηρίσουν διαταραχές ομιλίας σε πρώιμα στάδια μη θεραπευμένης PD. Περιέχει 195 παρατεταμένες φωνητικές φωνές (ήχοι «α») από 31 άτομα (23 με PD), το καθένα από τα οποία χαρακτηρίζεται από 22 χαρακτηριστικά δυσφωνίας (jitter, shimmer,

κ.λπ.) συν την ετικέτα κλάσης. Οι Little et al. ανέφεραν ότι πέτυχαν accuracy $\sim 91\%$ στην ανίχνευση της PD χρησιμοποιώντας ένα SVM, καθιστώντας το ως σημείο αναφοράς για τις πρώιμες μελέτες. Ένας βασικός περιορισμός, ωστόσο, είναι ότι περιλαμβάνονται πολλαπλές ηχογραφήσεις από το ίδιο άτομο, γεγονός που απαιτεί προσεκτική ομαδοποίηση για την αποφυγή μεροληψίας, μια προφύλαξη που δεν τηρήθηκε σε όλες τις πρώιμες μελέτες, συμβάλλοντας σε ορισμένα υπερβολικά αισιόδοξα αποτελέσματα.

Ένα πιο πρόσφατο παράδειγμα είναι το σώμα MDVR-KCL (Mobile Device Voice Recordings at King's College London) [22]. Αυτή η συλλογή του 2019 περιέχει ηχογραφήσεις φωνής από ασθενείς με PD και υγιείς μάρτυρες που εκτελούν πολλαπλές ομιλητικές εργασίες, συμπεριλαμβανομένης της ανάγνωσης και του αυθόρμητου διαλόγου. Περιλαμβάνει δεκάδες υποκείμενα (για παράδειγμα, 37 υποκείμενα στο τμήμα που χρησιμοποιείται σε αυτή τη εργασία) και πολλαπλές ηχογραφήσεις ανά υποκείμενο ανά εργασία, καθιστώντας το κατάλληλο για την εξέταση της μεταβλητότητας εντός του υποκειμένου και των επιδράσεων της εργασίας. Τα δεδομένα είναι διαθέσιμα στο Zenodo και αντιστοιχούν σε smartphone call-scenario καταγραφή από το μικρόφωνο της συσκευής (44.1 kHz/16-bit), όχι σε studio ειδικού εξοπλισμού, κάτι που υποστηρίζει την πρακτική συνάφεια της αξιολόγησης. Μελέτες που χρησιμοποιούν αυτό το σώμα δεδομένων, ή παρόμοια σύνολα δεδομένων πολλαπλών εργασιών, υποστηρίζουν ένθερμα την grouped cross-validation, διασφαλίζοντας ότι όλες οι εγγραφές από ένα δεδομένο υποκείμενο τοποθετούνται σε ένα μόνο fold, προκειμένου να αξιολογηθεί σωστά η γενίκευση σε νέους ομιλητές.

2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών

Τα προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών είναι εκείνα στα οποία το στάδιο επεξεργασίας του σήματος έχει ήδη ολοκληρωθεί αποτελεσματικά, αυτό που παρέχεται είναι ένας πίνακας τιμών χαρακτηριστικών ανά δείγμα, μαζί με ετικέτες κλάσης, έτοιμος για άμεση εφαρμογή μεθόδων μηχανικής μάθησης. Το σύνολο δεδομένων χαρακτηριστικών ομιλίας της νόσου του Πάρκινσον (PDSF) είναι ένα εξέχον παράδειγμα, με κύρια επίσημη τεκμηρίωση στο UCI Repository και ευρέως χρησιμοποιούμενη αναδημοσίευση στο Kaggle [23, 24]. Περιλαμβάνει 756 δείγματα με 754 χαρακτηριστικά ανά δείγμα συν μια δυαδική ετικέτα (PD ή HC), όπου κάθε δείγμα αντιστοιχεί σε μια ηχογράφιση φωνής από ένα άτομο. Υπάρχουν 252 μοναδικά υποκείμενα (188 PD, 64 HC), το καθένα από τα οποία συνεισφέρει ακριβώς τρία δείγματα (π.χ. τρεις ηχογραφήσεις παρατεταμένων φωνηέντων). Τα χαρακτηριστικά καλύπτουν ένα ευρύ φάσμα ακουστικών μετρήσεων, συμπεριλαμβανομένων παραδοσιακών μετρήσεων όπως jitter, shimmer και MFCCs, καθώς και συντελεστές Tunable Q-factor Wavelet Transform (TQWT), των οποίων η θεωρητική βάση έχει περιγραφεί από τον Selesnick [25]. Αυτό το σύνολο δεδομένων σχεδιάστηκε ως ένα ολοκληρωμένο σύνολο χαρακτηριστικών για τη συγκριτική αξιολόγηση της απόδοσης του ταξινομητή.

Το κύριο πλεονέκτημα των προ-εξαγόμενων συνόλων δεδομένων χαρακτηριστικών είναι η ευκολία και η συνέπεια, οι ερευνητές μπορούν να κατεβάσουν το CSV και να εφαρμόσουν απευθείας μεθόδους μηχανικής μάθησης, χωρίς να χρειάζεται να εφαρμόσουν διαδικασίες επεξεργασίας σήματος. Πολλές μελέτες έχουν χρησιμοποιήσει το σύνολο δεδομένων PDSF για να αξιολογήσουν διαφορε-

τικούς αλγόριθμους ταξινόμησης, τεχνικές επιλογής χαρακτηριστικών και μεθόδους συνόλου, με αναφερόμενο accuracy συχνά στην περιοχή 85–95% σε διάφορους ταξινομητές.

Μια κρίσιμη προειδοποίηση με σύνολα δεδομένων αυτού του τύπου είναι η **έλλειψη αναγνωριστικών υποκειμένων**. Δεδομένου ότι τα 756 δείγματα περιλαμβάνουν τρεις εγγραφές από καθένα από τα 252 υποκείμενα, μια αφελής cross-validation που χωρίζει τυχαία τα δείγματα θα εκπαιδεύσει και θα δοκιμάσει κατά λάθος εγγραφές από το ίδιο άτομο. Αυτό οδηγεί σε υπερβολικά αισιόδοξες εκτιμήσεις απόδοσης, καθώς οι τρεις εγγραφές ενός δεδομένου υποκειμένου δεν είναι ανεξάρτητες και μοιράζονται παρόμοια ακουστικά χαρακτηριστικά. Ορισμένες δημοσιευμένες μελέτες έχουν παραβλέψει αυτό το ζήτημα και, κατά συνέπεια, έχουν αναφέρει υπερβολική απόδοση του ταξινομητή. Η κατάλληλη προσέγγιση θα ήταν η ομαδοποίηση των δειγμάτων ανά υποκείμενο κατά την κατάτμηση των δεδομένων. Ωστόσο, δεδομένου ότι δεν παρέχονται αναγνωριστικά υποκειμένων, αυτό δεν μπορεί να γίνει άμεσα. Τα αποτελέσματα σε αυτό το σύνολο δεδομένων πρέπει επομένως να ερμηνεύονται με προσοχή, καθώς το υψηλό accuracy μπορεί να αντανακλά εν μέρει τη συνέπεια εντός του υποκειμένου και όχι την πραγματική γενίκευση σε νέους ομιλητές. Σε αυτή τη εργασία, τα αποτελέσματα του συνόλου δεδομένων B αντιμετωπίζονται ως δυνητικά αισιόδοξα, με έμφαση στις τάσεις και όχι στις απόλυτες τιμές απόδοσης.

2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων

Μια συστηματική ανασκόπηση 69 μελετών που δημοσιεύθηκαν μεταξύ 2020 και 2025 διαπίστωσε ότι τα περισσότερα σύνολα δεδομένων φωνής που χρησιμοποιούνται για την ταξινόμηση της PD περιέχουν λιγότερους από 100 συμμετέχοντες [6]. Τα πιο συχνά χρησιμοποιούμενα σώματα κειμένων είναι το PC-GITA (19 μελέτες), το σύνολο δεδομένων Istanbul PD Speech (15 μελέτες) και το σύνολο δεδομένων Oxford/UCI PD (14 μελέτες). Η ανισορροπία των κλάσεων είναι συχνή: η πλειονότητα των συνόλων δεδομένων παρουσιάζει αναλογίες PD-HC εκτός του εύρους 0,8–1,2, με το σύνολο δεδομένων Istanbul να περιέχει 188 συμμετέχοντες με PD έναντι μόλις 64 συμμετεχόντων με HC. Το σώμα κειμένων MDVR-KCL που χρησιμοποιείται σε αυτή τη εργασία είναι ένα από τα πιο συχνά εμφανιζόμενα σύνολα δεδομένων στην αγγλική γλώσσα στην πρόσφατη βιβλιογραφία [6].

2.4.4 Ετερογένεια επικύρωσης (Cross-validation heterogeneity)

Το ίδιο σύνολο δεδομένων μπορεί να παράγει θεμελιωδώς διαφορετικά αποτελέσματα απόδοσης ανάλογα με τη στρατηγική αξιολόγησης που χρησιμοποιείται. Μεταξύ των πρόσφατων μελετών, η k-fold cross-validation χρησιμοποιείται σε περίπου 40%, η fixed train/test split σε περίπου 36%, η subject-independent evaluation (leave-one-subject-out ή leave-one-out) σε μόνο 12%, και η external cross-dataset validation σε λιγότερο από 15% [6]. Αυτή η ετερογένεια καθιστά δύσκολη και συχνά παραπλανητική την άμεση σύγκριση των αναφερόμενων αποτελεσμάτων μεταξύ των μελετών. Για παράδειγμα, μια μελέτη που ανέφερε accuracy 100% χρησιμοποιώντας fixed split στο μικρό σύνολο δεδομένων της Οξφόρδης βρέθηκε να υποβαθμίζεται στο 96% όταν δοκιμάστηκε σε διαφορετικό σώμα κειμένων, καταδεικνύοντας την ευθραυστότητα της αξιολόγησης εντός του δείγματος σε μικρά σημεία αναφοράς [6].

2.4.5 Ο ρόλος των εργασιών ομιλίας

Η επιλογή της εργασίας ομιλίας είναι μια σημαντική απόφαση σχεδιασμού που επηρεάζει τόσο τον τύπο των πληροφοριών που συλλέγονται όσο και την καταλληλότητα της ανάλυσης για την ανίχνευση έναντι της παρακολούθησης. Η παρατεταμένη φώνηση φωνηέντων αντανακλά κυρίως τη λειτουργία του λάρυγγα και χρησιμοποιείται συνήθως για τη δυαδική διάκριση PD/HC. Αντίθετα, οι εργασίες ανάγνωσης και αυθόρμητης ομιλίας εμπλέκουν ολόκληρο το σύστημα παραγωγής ομιλίας και παρέχουν περισσότερες πληροφορίες για την αξιολόγηση της ακρίβειας της άρθρωσης, της προσωδικής διακύμανσης και του ρυθμού ομιλίας, χαρακτηριστικά που συνδέονται με τη σοβαρότητα της νόσου και όχι με την απλή παρουσία της [8]. Η παρούσα εργασία αξιολογεί τόσο μια εργασία ανάγνωσης (ReadText) όσο και μια εργασία αυθόρμητης ομιλίας (SpontaneousDialogue) από το Dataset A, επιτρέποντας μια ελεγχόμενη σύγκριση των αποτελεσμάτων των εργασιών υπό πανομοιότυπες διαμορφώσεις ταξινόμητων.

2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD

Η λογιστική παλινδρόμηση (LR), οι μηχανές υποστήριξης διανυσμάτων (SVM) και οι μέθοδοι συνόλου δέντρων είναι οι πιο ευρέως εφαρμοζόμενοι ταξινομητές στη βιβλιογραφία για τη φωνή PD. Η LR, η οποία εδράζεται στην κλασική εργασία του Cox [26], παρέχει μια ερμηνεύσιμη γραμμική βάση [27, 28]· η SVM με πυρήνα RBF υπήρξε ιστορικά η κυρίαρχη προσέγγιση, με Little et al. [3] να επιτυγχάνει accuracy ~91% στο σύνολο δεδομένων UCI χρησιμοποιώντας 22 χαρακτηριστικά δυσφωνίας [29]. Μια συστηματική ανασκόπηση από Sáenz-Lechón et al. [30] σημείωσε ότι οι SVM και τα τυχαία δάση επιτυγχάνουν υψηλό accuracy σε μικρά ομοιογενή σύνολα δεδομένων παθολογίας φωνής. Το Random Forest [31] συμπληρώνει το SVM μέσω του μέσου όρου συνόλου, της ενσωματωμένης σημασίας χαρακτηριστικών και της ανθεκτικότητας σε άσχετα χαρακτηριστικά, καθιστώντας το κατάλληλο για μικρές, θορυβώδεις ιατρικές κοόρτες. Οι πλήρεις προδιαγραφές μοντέλου και οι εξισώσεις που χρησιμοποιούνται σε αυτή τη εργασία παρέχονται στο Κεφάλαιο 4.

Πέρα από την ακατέργαστη απόδοση ταξινόμησης, πρόσφατες εργασίες έχουν τονίσει τη σημασία της ερμηνεύσιμης επιλογής χαρακτηριστικών στην κλινική ανάλυση φωνής. Solana-Lavalle and Rosas-Romero [32] συνδύασε την επιλογή υποσυνόλων χαρακτηριστικών με πολλαπλούς ταξινομητές και μείωση διαστάσεων για να παρέχει ένα κλινικά ερμηνεύσιμο πλαίσιο για την ανίχνευση της νόσου του Πάρκινσον από τη φωνή. Ένα αξιοσημείωτο εύρημα της μελέτης τους είναι ότι το σχετικό περιεχόμενο συχνότητας στο φωνητικό σήμα διαφέρει μεταξύ ανδρών και γυναικών ομιλητών, υπογραμμίζοντας την ανάγκη να ληφθούν υπόψη οι δημογραφικές υποομάδες κατά την ερμηνεία των φωνητικών ταξινομητών και τονίζοντας το ενδεχόμενο το φύλο να αποτελεί συγχυτική μεταβλητή σε ομάδες μικτού φύλου.

2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις

Αν και η παρούσα εργασία επικεντρώνεται αποκλειστικά στην κλασική μηχανική μάθηση, ο ευρύτερος τομέας έχει μετατοπιστεί σημαντικά προς τη βαθιά μάθηση. Μια πρόσφατη συστηματική ανασκόπηση διαπίστωσε ότι περίπου το 42% των μελετών φωνής PD που δημοσιεύθηκαν μεταξύ 2020 και 2025 χρησιμοποιούν αρχιτεκτονικές βαθιάς μάθησης, με τα συνελκτικά νευρωνικά δίκτυα (CNN) να είναι τα πιο συνηθισμένα, ακολουθούμενα από προσεγγίσεις βασισμένες σε μετασχηματιστές και μοντέλα θεμελίωσης όπως το Wav2Vec 2.0 [6]. Έχουν επίσης εμφανιστεί υβριδικές διαδικασίες που συνδυάζουν εξάγοντες χαρακτηριστικών βαθιάς μάθησης με κλασικούς ταξινομητές. Οι ενσωματώσεις βασικών μοντέλων δείχνουν υποσχέσεις για διαγλωσσική ανθεκτικότητα. Ωστόσο, η ανασκόπηση διαπίστωσε επίσης ότι αυτές οι μελέτες βασίζονται κυρίως σε εσωτερική επικύρωση, ενώ η εξωτερική αξιολόγηση μεταξύ συνόλων δεδομένων παραμένει σπάνια. Οι ισχυρισμοί σχετικά με την απόδοση που βασίζονται σε μικρά, ομοιογενή σύνολα δεδομένων, είτε χρησιμοποιούν κλασικές είτε βαθιές μεθόδους, θα πρέπει επομένως να ερμηνεύονται με προσοχή. Η παρούσα εργασία καθιερώνει μια αυστηρή κλασική βάση αναφοράς με αξιολόγηση ασφαλή από διαρροές και αφαίρεση χαρακτηριστικών, η οποία μπορεί να χρησιμεύσει ως σημείο αναφοράς για μελλοντικές συγκρίσεις βασισμένες σε ενσωματώσεις.

2.6 Μεθοδολογικά ζητήματα στη βιβλιογραφία

2.6.1 Διαρροή δεδομένων

Η διαρροή δεδομένων, όπως περιγράφεται σε μια πρόσφατη συστηματική ανασκόπηση της έρευνας για τη φωνή PD [6]:

«Όταν υπάρχουν πολλαπλές ηχογραφήσεις ανά υποκείμενο, οι τυχαίες διαχωριστικές δοκιμές εκπαίδευσης/ελέγχου μπορούν να τοποθετήσουν ηχογραφήσεις από το ίδιο υποκείμενο και στα δύο σύνολα, οδηγώντας σε τεχνητά διογκωμένες εκτιμήσεις απόδοσης.»

Η παρούσα μελέτη χρησιμοποιεί grouped stratified cross-validation για να διασφαλίσει ότι όλες οι ηχογραφήσεις από ένα συγκεκριμένο υποκείμενο υπάρχουν είτε αποκλειστικά στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής για κάθε fold της διαδικασίας. Η σημασία αυτού του διαχωρισμού τεκμηριώνεται επίσης από μελέτες στην κλινική μηχανική μάθηση, όπου η ταυτόχρονη χρήση CV για ρύθμιση και αξιολόγηση οδηγεί σε μεροληπτικές εκτιμήσεις σφάλματος [33, 34].

Πρόσφατη βιβλιογραφία δείχνει ότι, αν και πολλοί ερευνητές αναγνωρίζουν τα οφέλη της αξιολόγησης ανεξάρτητης από το υποκείμενο (δηλ. LOSO/LOOCV) και της αξιολόγησης εξωτερικών συνόλων δεδομένων, πολύ λίγοι ερευνητές στον τομέα χρησιμοποιούν αυτές τις προσεγγίσεις [6].

2.6.2 Ανισορροπία κλάσεων

Η ανισορροπία κλάσεων συμβαίνει όταν μια κλάση περιέχει σημαντικά περισσότερες περιπτώσεις από μια άλλη. Αυτό μπορεί να οδηγήσει σε παραπλανητικά αποτελέσματα όταν χρησιμοποιούνται

απλά μέτρα accuracy, επειδή ένα μοντέλο μπορεί να επιτύχει υψηλό accuracy ενώ είναι μεροληπτικό προς την πλειοψηφούσα κατηγορία. Πολλές μελέτες δεν χρησιμοποιούν τεχνικές class weighting ή επαναδειγματοληψίας για την αντιμετώπιση ζητημάτων που σχετίζονται με την ανισορροπία κατηγοριών [6]. Η παρούσα μελέτη διερευνά τη χρήση class weighting (λειτουργία “balanced”) ως πιθανή μέθοδο για τη μείωση των επιπτώσεων της ανισορροπίας κατηγοριών.

2.6.3 Αναπαραγωγιμότητα

Η αναπαραγωγή των αποτελεσμάτων από μελέτες στον τομέα της ταξινόμησης φωνής PD μπορεί να είναι δύσκολη λόγω της έλλειψης λεπτομερειών σχετικά με διάφορες πτυχές της έρευνας [35]:

- Παράμετροι εξαγωγής χαρακτηριστικών που δεν έχουν καθοριστεί
- Τυχαία σπόρια που δεν έχουν καθοριστεί
- Ασαφής στρατηγική διασταυρούμενης επικύρωσης
- Διαδικασίες ρύθμισης υπερπαραμέτρων που δεν έχουν τεκμηριωθεί

Η παρούσα μελέτη αντιμετωπίζει τα παραπάνω προβλήματα παρέχοντας σταθερούς τυχαίους σπόρους, τεκμηριώνοντας τις παραμέτρους εξαγωγής χαρακτηριστικών και περιγράφοντας ρητά τα πρωτόκολλα διασταυρούμενης επικύρωσης.

2.6.4 Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων

Η εξωτερική επικύρωση, η δοκιμή ενός μοντέλου σε δεδομένα από μια εντελώς διαφορετική πηγή από το σύνολο εκπαίδευσης, είναι η πιο αυστηρή δοκιμή γενικευσιμότητας, αλλά πραγματοποιείται σε λιγότερο από το 15% των πρόσφατων μελετών φωνής PD [6]. Πρόσφατα πρότυπα αναφοράς, όπως η δήλωση TRIPOD+AI [36] και το εργαλείο αξιολόγησης PROBAST+AI [37], τονίζουν τη διάκριση μεταξύ εσωτερικής και εξωτερικής επικύρωσης και παρέχουν δομημένα πλαίσια για τη διαφανή αναφορά μοντέλων πρόβλεψης στον τομέα της υγείας. Το αποτέλεσμα είναι ότι περίπου το 70% των μελετών βασίζονται σε καθαρά εσωτερικές μετρήσεις που είναι πιθανό να υπερεκτιμούν την πραγματική απόδοση. Στις σπάνιες περιπτώσεις όπου έχει πραγματοποιηθεί αξιολόγηση μεταξύ συνόλων δεδομένων, έχουν παρατηρηθεί απότομες πτώσεις στην απόδοση· για παράδειγμα, μοντέλα που πέτυχαν perfect accuracy σε ένα μικρό δείκτη αναφοράς υποβαθμίστηκαν σημαντικά όταν δοκιμάστηκαν σε ένα διαφορετικό σώμα δεδομένων [6]. Αυτά τα ευρήματα ενισχύουν την ανάγκη για συντηρητική ερμηνεία των αποτελεσμάτων εντός του δείγματος.

2.6.5 Ερμηνευσιμότητα

Η ερμηνευσιμότητα για κλινική επικύρωση παραμένει μια κρίσιμη αλλά ανεπαρκώς ανεπτυγμένη πτυχή της ταξινόμησης φωνής PD [6]. Μόνο μια μειοψηφία πρόσφατων μελετών χρησιμοποιεί μεθόδους εκ των υστέρων εξήγησης, όπως SHAP ή LIME· αυτές που το κάνουν έχουν εντοπίσει με συνέπεια το jitter, το shimmer και τη μονοτονία του τόνου ως κορυφαίους προγνωστικούς παράγοντες. Η περιορισμένη υιοθέτηση μεθόδων ερμηνευσιμότητας δημιουργεί ένα χάσμα μεταξύ των αποτελε-

σμάτων του μοντέλου και της κλινικής εφαρμοσιμότητας. Η παρούσα εργασία αντιμετωπίζει αυτό το χάσμα μέσω ανάλυσης αφαίρεσης χαρακτηριστικών και κατάταξης σημασίας χαρακτηριστικών με βάση την αναδιάρθρωση, παρέχοντας διαφανή εικόνα για το ποια ακουστικά χαρακτηριστικά καθορίζουν τις αποφάσεις ταξινόμησης.

2.7 Έλλειμμα στην έρευνα

Παρά τις πολυάριθμες μελέτες που αναφέρουν υψηλές τιμές ακρίβειας ταξινόμησης, λίγες αντιμετωπίζουν τα ακόλουθα:

1. **Grouped cross-validation** για σύνολα δεδομένων πολλαπλών εγγραφών
2. **Μελέτες ελεγχόμενης αφαίρεσης χαρακτηριστικών**
3. **Συστηματική ανάλυση στάθμισης κατηγοριών**
4. **Διαφανής τεκμηρίωση** των περιορισμών
5. **Εξωτερική επικύρωση**: η γενίκευση μεταξύ ανεξάρτητων συνόλων δεδομένων σπάνια δοκιμάζεται· στην παρούσα μελέτη η χρήση δύο datasets λειτουργεί ως ανάλυση συγκριτικής ευρωστίας εντός μελέτης και δεν υποκαθιστά ανεξάρτητο εξωτερικό test set [6]
6. **Ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών**: το SHAP και άλλες μέθοδοι εκ των υστέρων εξήγησης χρησιμοποιούνται σε λιγότερο από το 10% των μελετών της περιόδου 2020–2025· η παρούσα μελέτη καλύπτει αυτό το κενό μέσω της αφαίρεσης και της ανάλυσης της σημασίας των χαρακτηριστικών [6]

2.8 Περίληψη

Η ανίχνευση PD με βάση τη φωνή φαίνεται εφικτή με κλασική μηχανική μάθηση σε ακουστικά χαρακτηριστικά, αλλά τα συμπεράσματα πρέπει να ερμηνεύονται προσεκτικά στο πλαίσιο εσωτερικής επικύρωσης. Ωστόσο, πρόσφατες συστηματικές ανασκοπήσεις που καλύπτουν την περίοδο 2019–2025 δείχνουν ότι η μεθοδολογική ποιότητα ποικίλλει σημαντικά στον τομέα αυτό όσον αφορά τις στρατηγικές επικύρωσης, την εξωτερική αξιολόγηση και την ερμηνευσιμότητα των αποτελεσμάτων [6, 7]. Ο τομέας απομακρύνεται επί του παρόντος από τα χειροποίητα ακουστικά χαρακτηριστικά προς ενσωματώσεις βαθιάς μάθησης, αλλά αυτές δεν έχουν ακόμη δείξει σταθερά πλεονεκτήματα στη γενίκευση υπό αυστηρή αξιολόγηση [6]. Ως εκ τούτου, η παρούσα μελέτη υιοθετεί συντηρητική προσέγγιση που δίνει προτεραιότητα στην αναπαραγωγιμότητα, την αξιολόγηση με γνώμονα το υποκείμενο και τη διαφάνεια στην ερμηνεία, έναντι της απλής βελτιστοποίησης της απόδοσης.

Κεφάλαιο 3

Περιγραφή δεδομένων

3.1 Επισκόπηση

Η εργασία χρησιμοποιεί δύο συμπληρωματικά σύνολα δεδομένων με διαφορετικό επίπεδο ελέγχου: (i) raw audio με διαθέσιμα subject IDs (Dataset A: MDVR-KCL) και (ii) προ-εξαγμένα χαρακτηριστικά χωρίς subject IDs (Dataset B). Η διάκριση αυτή καθορίζει και το πρωτόκολλο αξιολόγησης.

3.2 Σύνολο δεδομένων A: MDVR-KCL

To Mobile Device Voice Recordings from King’s College London (MDVR-KCL) [22] συλλέχθηκε σε ρεαλιστικό smartphone call-scenario σε κλινικό περιβάλλον και περιέχει καταγραφή από το μικρόφωνο της συσκευής (όχι GSM συμπίεση) σε WAV mono 44.1 kHz/16-bit. Δεν πρόκειται για dataset τύπου “special equipment studio”, γεγονός που ενισχύει την πρακτική αξία των πειραμάτων ως προς συνθήκες εγγύτερες στη χρήση πεδίου.

Ιδιότητα	Τιμή
Πηγή	Zenodo, DOI 10.5281/zenodo.2867216
Μορφή ήχου	WAV PCM, mono, 16-bit
Ρυθμός δειγματοληψίας	44.1 kHz (resample σε 22.05 kHz για επεξεργασία)
Εργασίες ομιλίας	ReadText, SpontaneousDialogue
Υποκείμενα	37 (ReadText), 36 (SpontaneousDialogue)
Κλάσεις	HC: 21, PD: 16 (ReadText) / HC: 21, PD: 15 (SpontaneousDialogue)

Πίνακας 3.1: Σύνοψη Dataset A (MDVR-KCL)

To Dataset A επιτρέπει subject-level διαχωρισμό folds και συνεπώς αυστηρό έλεγχο διαρροής υποκειμένων. Η ποιότητα των ακουστικών μετρήσεων που εξάγονται από τέτοια σύνολα δεδομένων εξαρτάται κρίσιμα από τις συνθήκες ηχογράφησης, όπως έχει τεκμηριωθεί σε πρώιμες μελέτες ποσοτικής ακουστικής ανάλυσης για την PD [21]. Η απουσία του ID18 στο SpontaneousDialogue εξηγεί τη διαφορά 37 έναντι 36 υποκειμένων.

3.3 Σύνολο δεδομένων B: PD Speech Features

To Dataset B προέρχεται από UCI/Kaggle [24] και παρέχει προ-υπολογισμένα χαρακτηριστικά σε μορφή CSV. Η αρχική συλλογή του συνόλου δεδομένων περιγράφεται από τους Sakar et al. [38], ενώ

η συγκριτική ανάλυση των αλγορίθμων επεξεργασίας σήματος και των TQWT χαρακτηριστικών παρέχεται από τους Sakar et al. [39].

Ιδιότητα	Τιμή
Μορφή	CSV (752 features + 1 label)
Δείγματα	756 γραμμές
Κλάσεις	HC: 192 (25.4%), PD: 564 (74.6%)
Υποκείμενα	Subject IDs δεν παρέχονται
Εργασία ομιλίας	Παρατεταμένη φώνηση /a/

Πίνακας 3.2: Σύνοψη Dataset B

Τα χαρακτηριστικά καλύπτουν πολλαπλούς τομείς (jitter/shimmer, formants, MFCC, wavelet, TQWT κ.ά.), αλλά δεν υπάρχει πρόσβαση στον αρχικό ήχο. Αυτό περιορίζει την επαναληψιμότητα της εξαγωγής και την προσθήκη νέων χαρακτηριστικών.

Κρίσιμη προειδοποίηση: Η απουσία subject IDs στο Dataset B δεν επιτρέπει ασφαλή subject-level cross-validation. Συνεπώς, η τυπική stratified CV μπορεί να οδηγεί σε αισιόδοξες εκτιμήσεις απόδοσης λόγω πιθανής επικάλυψης ίδιων υποκειμένων σε train και test.

3.4 Συγκριτική αποτίμηση των δύο συνόλων

Πτυχή	Dataset A	Dataset B
Μονάδα εισόδου	Raw audio (WAV)	Προ-εξαγμένα features (CSV)
Subject IDs	Διαθέσιμα	Μη διαθέσιμα
Validation	Grouped (subject-level)	Stratified (sample-level)
Speech task	ReadText / SpontaneousDialogue	Sustained vowel /a/
Feature pipeline	Ελεγχόμενο από την εργασία	Προ-υπολογισμένο

Πίνακας 3.3: Κύριες διαφορές Dataset A και Dataset B

Η μελέτη δεν αντιμετωπίζει τα δύο datasets ως άμεσα συγκρίσιμα σε απόλυτους όρους. Τα αποτελέσματα ερμηνεύονται με βάση τις δομικές διαφορές τους και με ιδιαίτερη προσοχή στο πιθανό optimistic bias του Dataset B.


Κεφάλαιο 4

Μεθοδολογία

4.1 Διαδικασία εξαγωγής χαρακτηριστικών

4.1.1 Αρχιτεκτονική διαδικασίας

Η διαδικασία εξαγωγής χαρακτηριστικών μετατρέπει τον ακατέργαστο ήχο σε δομημένα διανύσματα χαρακτηριστικών κατάλληλα για μηχανική μάθηση:



Σχήμα 4.1: Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.

4.1.2 Προεπεξεργασία ήχου

Όλα τα αρχεία ήχου υποβλήθηκαν στην ίδια διαδικασία προεπεξεργασίας, ώστε η εξαγωγή χαρακτηριστικών να γίνει με συνέπεια:

1. **Φόρτωση ήχου** με τον αρχικό ρυθμό δειγματοληψίας χρησιμοποιώντας `librosa.load()`
2. **Επαναδειγματοληψία** στα 22.050 Hz (σταθερή σε όλες τις ηχογραφήσεις)
3. **Μετατροπή σε μονοφωνικό** αν το αρχείο ήταν στερεοφωνικό (μέσος όρος των δύο καναλιών).
4. **Κανονικοποίηση πλάτους** στο εύρος $[-1, 1]$
5. **Αφαίρεση σιωπής** χρησιμοποιώντας ανίχνευση βάσει ενέργειας (threshold 5% της μέγιστης ενέργειας)

Ο ρυθμός 22.050 Hz επιλέχθηκε γιατί είναι επαρκής για ανάλυση ομιλίας (Nyquist 11.025 Hz) και ταυτόχρονα μειώνει το υπολογιστικό κόστος σε σχέση με τα 44.100 Hz.

4.1.3 Προσωδικά χαρακτηριστικά (21 χαρακτηριστικά)

Τα προσωδικά χαρακτηριστικά περιγράφουν στοιχεία της φωνής που επηρεάζονται συχνά από τη νόσο του Πάρκινσον. Η εξαγωγή έγινε με το Parselmouth (Praat) [40].

Θεμελιώδης συχνότητα (F_0)

Για την εξαγωγή του τόνου χρησιμοποιήθηκαν οι ακόλουθες παράμετροι. Η επιλογή αυτοσυσχέτισης ως βασικού μηχανισμού ανίχνευσης θεμελιώδους συχνότητας ακολουθεί την κλασική βιβλιογραφία εξαγωγής pitch [41]:

- **Αλγόριθμος:** Βασισμένος στην αυτοσυσχέτιση (προεπιλογή του Praat)
- **Εύρος τόνου:** 75–500 Hz (καλύπτει ανδρικές, γυναικείες και παθολογικές φωνές)
- **Χρονικό βήμα:** 0,01 s (πρότυπο για την ανάλυση φωνής)

Τέσσερα στατιστικά στοιχεία υπολογίστηκαν από το περίγραμμα του τόνου:

$$F_0 = \{\mu_{F_0}, \sigma_{F_0}, \min_{F_0}, \max_{F_0}\} \quad (4.1)$$

Jitter

Το Jitter μετρά τη διακύμανση της περιόδου του τόνου από κύκλο σε κύκλο. Η εκτίμησή του είναι ευαίσθητη στην ποιότητα και στο κανάλι καταγραφής, επομένως απαιτεί συνεπή προεπεξεργασία [42].

$$\text{Jitter}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|T_i - T_{i+1}|}{\bar{T}} \quad (4.2)$$

όπου T_i είναι η i -η περίοδος τόνου και $\bar{T}$ είναι η μέση περίοδος.

Πρόσθετα μέτρα περιλαμβάνουν:

- **RAP (Σχετική Μέση Διαταραχή):** εξομάλυνση 3 σημείων
- **PPQ5:** πηλίκο διαταραχής περιόδου 5 σημείων

Shimmer

Το Shimmer μετρά τη διακύμανση της έντασης από κύκλο σε κύκλο και, όπως και το jitter, επηρεάζεται από το πρωτόκολλο λήψης και τη σταθερότητα της καταγραφής [42].

$$\text{Shimmer}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|A_i - A_{i+1}|}{\bar{A}} \quad (4.3)$$

όπου A_i είναι το i -οστό μέγιστο πλάτος και $\bar{A}$ είναι το μέσο πλάτος.

Πρόσθετα μέτρα περιλαμβάνουν APQ3, APQ5, APQ11 (συντελεστές διαταραχής πλάτους με μεταβαλλόμενα παράθυρα) και DDA (διαφορά των διαφορών των πλατών).

Αναλογία αρμονικών προς θόρυβο (HNR)

Το HNR δείχνει πόσο «καθαρή» είναι η φωνή (αρμονικές έναντι θορύβου). Η μεθοδολογική θεμελίωση της εκτίμησης HNR ακολουθεί κλασικές προσεγγίσεις της βιβλιογραφίας φωνής [43].

- **Μέση HNR:** Μέση HNR (dB)
- **Αυτοσυσχέτιση αρμονικότητας:** Μέγιστη τιμή αυτοσυσχέτισης

Ένταση

Τρεις στατιστικές έντασης (dB SPL):

$$I = \{\mu_I, \sigma_I, \max_I - \min_I\} \quad (4.4)$$

Formants

Τα τρία πρώτα formants (F_1 , F_2 , F_3) εξήχθησαν χρησιμοποιώντας γραμμική προβλεπτική κωδικοποίηση (LPC):

- **Σειρά LPC:** τάξης 10 (επαρκής για 3 formants στα 22 kHz)
- **Χαρακτηριστικά:** Μέσος όρος και τυπική απόκλιση κάθε φωνητικού στοιχείου (6 χαρακτηριστικά συνολικά)

Ομάδα χαρακτηριστικών	Αριθμός	Χαρακτηριστικά	Εργαλείο
Τόνος (F_0)	4	μέσος όρος, τυπική απόκλιση, ελάχιστο, μέγιστο	Parselmouth
Jitter	3	τοπικό, RAP, PPQ5	Parselmouth
Shimmer	5	τοπικό, APQ3, APQ5, APQ11, DDA	Parselmouth
Αρμονικότητα	2	μέσος όρος HNR, αυτοσυσχέτιση	Parselmouth
Intensity	3	μέσος όρος, τυπική απόκλιση, εύρος	Parselmouth
Formants	6	F_1-F_3 μέσος όρος, F_1-F_3 τυπική απόκλιση	Parselmouth
Σύνολο	21		

Πίνακας 4.1: Ανάλυση προσωδιακών χαρακτηριστικών

4.1.4 Φασματικά χαρακτηριστικά

Τα φασματικά χαρακτηριστικά περιγράφουν τη δομή του φάσματος συχνοτήτων της φωνής και εξήχθησαν χρησιμοποιώντας τη βιβλιοθήκη `librosa` [44].

Συντελεστές Mel-Frequency Cepstral (MFCC)

Οι MFCC υπολογίζονται μέσω των ακόλουθων βημάτων [17]:

1. **Προέμφαση:** $y[n] = x[n] - 0,97 \cdot x[n - 1]$
2. **Πλαίσιο:** Μήκος παραθύρου = 2048 δείγματα (≈ 93 ms στα 22 kHz)
3. **Παράθυρο:** Εφαρμογή παραθύρου Hann
4. **FFT:** FFT 2048 σημείων
5. **Φίλτρο Mel:** 128 τριγωνικά φίλτρα που καλύπτουν 0–11.025 Hz
6. **Συμπίεση λογαρίθμου:** $\log(\text{mel power spectrum})$
7. **DCT:** Διακριτός μετασχηματισμός συνημιτόνου που χρησιμοποιείται για τη μείωση της συσχέτισης μεταξύ των συντελεστών

Παράμετροι που χρησιμοποιήθηκαν:

- **Αριθμός συντελεστών:** 13 (MFCC 0–12)
- **Μήκος άλματος:** 512 δείγματα (≈ 23 ms στα 22 kHz, 75% επικάλυψη)
- **Αριθμός ζωνών mel:** 128

Ο MFCC 0 (ο μηδενικός συντελεστής) περιγράφει κυρίως την ενέργεια του σήματος, ενώ οι MFCC 1–12 αποτυπώνουν το σχήμα του φασματικού περιβλήματος της φωνής.

Συντελεστές δέλτα

Οι χρονικές παράγωγοι πρώτης τάξης (συντελεστές δέλτα) καταγράφουν τη φασματική δυναμική:

$$\Delta_t[n] = \frac{\sum_{i=1}^N i \cdot (c_{t+i} - c_{t-i})}{2 \sum_{i=1}^N i^2} \quad (4.5)$$

όπου c_t είναι ο συντελεστής MFCC στο πλαίσιο t και $N = 2$ είναι το μέγεθος του παραθύρου.

Βασικά φασματικά χαρακτηριστικά (26 χαρακτηριστικά)

Το βασικό σύνολο φασματικών χαρακτηριστικών αποτελείται από:

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Σύνολο	26	

Πίνακας 4.2: Βασικά φασματικά χαρακτηριστικά

Εκτεταμένα φασματικά χαρακτηριστικά (57 χαρακτηριστικά)

Το εκτεταμένο σύνολο χαρακτηριστικών περιλαμβάνει τρεις επιπλέον ομάδες, οι οποίες στοχεύουν να αποτυπώσουν περισσότερη φασματική και χρονική μεταβλητότητα της φωνής.

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
MFCC std	13	Χρονική τυπική απόκλιση (μεταβλητότητα εντός της εκφώνησης)
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Μέσος όρος Delta-Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων δεύτερης τάξης (επιτάχυνση)
Φασματικό σχήμα	5	Κέντρο βάρους, εύρος ζώνης, rolloff, επιπεδότητα, ZCR
Σύνολο	57	

Πίνακας 4.3: Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)

Οι πέντε περιγραφείς φασματικού σχήματος είναι:

1. **Φασματικό κέντρο βάρους:** Το «κέντρο μάζας» του φάσματος, δηλαδή το σημείο όπου συγκεντρώνεται η περισσότερη ενέργεια (σε Hz)
2. **Φασματικό εύρος ζώνης:** Πόσο απλώνεται το φάσμα γύρω από το κέντρο βάρους (σε Hz).
3. **Φασματική απόκλιση:** Η συχνότητα κάτω από την οποία βρίσκεται το 85% της συνολικής ενέργειας του σήματος (Hz)
4. **Φασματική επιπεδότητα:** Δείκτης του πόσο «τονική» ή «θορυβώδης» είναι η φωνή (λόγος γεωμετρικού προς αριθμητικό μέσο όρο).
5. **Ρυθμός διέλευσης από το μηδέν:** Πόσο συχνά το σήμα αλλάζει πρόσημο στο χρονικό πεδίο, δηλαδή πόσες φορές περνά από το μηδέν.

4.1.5 Συνολικός αριθμός χαρακτηριστικών

Διαμόρφωση	Προσωδιακά	Φασματικά	Σύνολο
Βασική γραμμή	21	26	47
Εκτεταμένη	21	57	78

Πίνακας 4.4: Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση

4.2 Σύγκριση συνόλου χαρακτηριστικών

4.2.1 Λόγοι για τα εκτεταμένα χαρακτηριστικά

Το εκτεταμένο σύνολο χαρακτηριστικών σχεδιάστηκε ως μία **ελεγχόμενη δοκιμή**, για να εξεταστεί αν η προσθήκη περισσότερης χρονικής και φασματικής πληροφορίας βελτιώνει την απόδοση της ταξινόμησης.

Προστέθηκαν τρεις ομάδες χαρακτηριστικών:

1. **MFCC std (13):** Μετρά τη μεταβλητότητα των MFCC μέσα σε κάθε ηχογράφιση. Αυτό είναι σημαντικό, γιατί η ομιλία σε ασθενείς με PD μπορεί να παρουσιάζει μεγαλύτερη αστάθεια.
2. **Delta-Delta MFCC (13):** Καταγράφει πόσο γρήγορα αλλάζουν τα φασματικά χαρακτηριστικά με τον χρόνο. Είναι ευαίσθητο στις χρονικές δυναμικές και στις αλλαγές της άρθρωσης.
3. **Φασματικό σχήμα (5):** Προσθέτουν γενικούς δείκτες του φάσματος (π.χ. τονικότητα, διασπορά), που δεν περιγράφονται πλήρως από τα MFCC.

4.2.2 Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών

Για να διασφαλιστεί η αναπαραγωγιμότητα, όλες οι βασικές παράμετροι ορίστηκαν από την αρχή σε κεντρικό αρχείο ρυθμίσεων (configuration file). Συγκεκριμένα:

- Τυχαίος σπόρος: 42
- Ρυθμός δειγματοληψίας: 22 050 Hz
- Εύρος F_0 : 75–500 Hz
- 13 MFCCs
- FFT 2048 σημείων
- Hop length: 512 δείγματα
- 128 mel bands

Όλα τα εξαγόμενα χαρακτηριστικά αποθηκεύτηκαν σε αρχεία CSV και χρησιμοποιήθηκαν στα επόμενα πειράματα χωρίς περαιτέρω αλλαγές.

4.3 Μοντέλα μηχανικής μάθησης

4.3.1 Προδιαγραφές μοντέλου

Επιλέχθηκαν πέντε κλασικά μοντέλα μηχανικής μάθησης, ώστε να καλυφθούν διαφορετικοί τρόποι μάθησης:

- **Λογιστική Παλινδρόμηση** [26, 28, 45]: ένα απλό γραμμικό μοντέλο με κανονικοποίηση L2.
- **SVM με πυρήνα RBF** [29]: μη γραμμική μέθοδος που μπορεί να μάθει πιο σύνθετα όρια απόφασης.
- **Random Forest** [31]: σύνολο δέντρων απόφασης που προσφέρει και εκτίμηση σημασίας χαρακτηριστικών.
- **Gradient Boosting** [46]: μοντέλο που βελτιώνει σταδιακά τα λάθη των προηγούμενων βημάτων.
- **XGBoost** [47]: βελτιστοποιημένη και κανονικοποιημένη εκδοχή του boosting.

Όλες οι υπερπαράμετροι ορίστηκαν εκ των προτέρων (*a priori*) και δεν προσαρμόστηκαν ειδικά για κάποιο συγκεκριμένο σύνολο δεδομένων:

Μοντέλο	Τύπος	Βασικές παράμετροι
Λογιστική παλινδρόμηση	Γραμμική	$C = 1.0$ (κανονικοποίηση L2), max_iter= 1000, solver='lbfgs'
SVM (RBF)	Πυρήνας	$C = 1.0$ (κανονικοποίηση), gamma='scale' (αυτόματη κλιμάκωση ανά χαρακτηριστικά), kernel='rbf'
Random Forest	Bagging	n_estimators= 100, max_depth= 10, min_samples_split= 2, random_state= 42
Gradient Boosting	Boosting	n_estimators= 100, learning_rate= 0.1, max_depth= 3 (προεπιλογή), random_state= 42
XGBoost	Boosting	n_estimators= 100, learning_rate= 0.1, eval_metric='logloss', random_state= 42

Πίνακας 4.5: Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.

Λογιστική παλινδρόμηση

Το μοντέλο λογιστικής παλινδρόμησης προβλέπει τις πιθανότητες κλάσης μέσω:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (4.6)$$

με κανονικοποίηση L2:

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n \log(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)}) + \frac{1}{2} \|\mathbf{w}\|_2^2 \right] \quad (4.7)$$

όπου $C = 1,0$ ελέγχει την ισχύ της κανονικοποίησης.

Μηχανή Υποστήριξης Διανυσμάτων

Ο πυρήνας RBF SVM μαθαίνει ένα μη γραμμικό όριο απόφασης μέσω:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (4.8)$$

όπου $\gamma = \frac{1}{n_{\text{features}} \cdot \text{Var}(\mathbf{X})}$ (αυτόματη κλιμάκωση).

Random Forest

Το Random Forest συγκεντρώνει προβλέψεις από 100 δέντρα αποφάσεων:

$$\hat{y} = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \hat{y}_t(\mathbf{x}) \quad (4.9)$$

Κάθε δέντρο εκπαιδεύεται σε ένα τυχαίο δείγμα των δεδομένων (bootstrap) και σε κάθε διαχωρισμό χρησιμοποιεί ένα τυχαίο υποσύνολο χαρακτηριστικών.

Το μέγιστο βάθος 10 επιλέχθηκε ώστε να περιοριστεί η υπερπροσαρμογή (overfitting), ιδιαίτερα λόγω του μικρού μεγέθους των συνόλων δεδομένων.

Gradient Boosting

Το Gradient Boosting δημιουργεί το μοντέλο βήμα-βήμα, όπου κάθε νέο δέντρο προσπαθεί να διορθώσει τα λάθη που έκαναν τα προηγούμενα δέντρα [46]:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}) \quad (4.10)$$

όπου F_m είναι το σύνολο μετά από m στάδια, h_m είναι ο αδύναμος μαθητής (δέντρο αποφάσεων) προσαρμοσμένος στην αρνητική κλίση της συνάρτησης απώλειας και $\eta = 0,1$ είναι ο ρυθμός μάθησης. Ο ρυθμός μάθησης μειώνει τη συμβολή κάθε δέντρου, παρέχοντας αποτέλεσμα κανονικοποίησης.

XGBoost

Το XGBoost [47] είναι μια βελτιωμένη εκδοχή του Gradient Boosting, η οποία προσθέτει κανονικοποίηση L1 και L2 στα βάρη των φύλλων των δέντρων, ώστε να μειώνει την υπερπροσαρμογή και να βελτιώνει τη γενίκευση.

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(\hat{y}_i, y_i) + \sum_{k=1}^K \Omega(f_k), \quad \text{where } \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \quad (4.11)$$

Εδώ T είναι ο αριθμός των φύλλων, $\mathbf{w}$ είναι το διάνυσμα των βαρών φύλλων και γ, λ είναι παράμετροι κανονικοποίησης. Αυτή η κανονικοποίηση βοηθά στην αποφυγή της υπερπροσαρμογής, η οποία είναι ιδιαίτερα σημαντική για σύνολα δεδομένων μικρού μεγέθους.

4.3.2 Στάθμιση βαρύτητας κλάσης

Η ανισορροπία κλάσης αντιμετωπίζεται μέσω της παραμέτρου `class_weight`:

```
1 # Χωρίς στάθμιση βασική (συνθήκη)
2 class_weight = None
3
4 # Με στάθμιση ισορροπημένη (συνθήκη)
5 class_weight = "balanced" # w_k = n_samples / (n_classes * n_k)
```

Όταν `class_weight="balanced"`, οι βαρύτητες των δειγμάτων υπολογίζονται ως εξής:

$$w_k = \frac{n_{\text{samples}}}{n_{\text{classes}} \cdot n_k} \quad (4.12)$$

όπου n_k είναι ο αριθμός των δειγμάτων στην κλάση k . Αυτό εξασφαλίζει ότι τα σφάλματα της μειοψηφικής κλάσης σταθμίζονται περισσότερο κατά τη διάρκεια της εκπαίδευσης.

Τρία από τα πέντε μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest) υποστηρίζουν εγγενώς την παράμετρο `class_weight` μέσω του `scikit-learn`. Οι δύο ταξινομητές ενίσχυσης (Gradient Boosting και XGBoost) δεν υποστηρίζουν εγγενώς το `class_weight="balanced"`. Ωστόσο, δεδομένου ότι η ήπια ανισορροπία κλάσεων (1,3:1) δεν απαιτούσε επαναστάθμιση στην πράξη (βλ. Κεφάλαιο 6), αυτή η διαφορά δεν έχει καμία επίδραση στο σχεδιασμό του πειράματος.

4.4 Αρχιτεκτονική ML Pipeline

4.4.1 Δομή Pipeline

Όλα τα μοντέλα χρησιμοποιούν ένα τυποποιημένο `scikit-learn Pipeline` [48]:

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3
```

```

4 pipeline = Pipeline([
5     ('scaler', StandardScaler()),
6     ('classifier', Model(class_weight=..., random_state=42))
7 ])

```

Αυτό εξασφαλίζει ότι η κλιμάκωση χαρακτηριστικών εφαρμόζεται με συνέπεια και αποτρέπει τη διαρροή δεδομένων.

4.4.2 Τυποποίηση χαρακτηριστικών

Τα χαρακτηριστικά κανονικοποιούνται ώστε να έχουν μέση τιμή 0 και τυπική απόκλιση 1.

Η κανονικοποίηση υπολογίζεται μόνο στα δεδομένα εκπαίδευσης μέσα σε κάθε διαχωρισμό του k-fold cross-validation, ώστε να μη χρησιμοποιούνται πληροφορίες από το test set και να αποφεύγεται η διαρροή δεδομένων.

4.5 Πλαίσιο αξιολόγησης

4.5.1 Στρατηγική Cross-Validation

Σε αυτή τη εργασία, η **διασταυρούμενη επικύρωση K-fold αποτελεί την κύρια στρατηγική αξιολόγησης**: το μοντέλο εκπαιδεύεται σε $K - 1$ folds και αξιολογείται στο εναπομείναν fold, το οποίο περιλαμβάνει μόνο δείγματα που δεν έχουν χρησιμοποιηθεί ούτε στην εκπαίδευση ούτε στην εξόρυξη χαρακτηριστικών [27]. Η διαδικασία επαναλαμβάνεται $K = 5$ φορές, παρέχοντας πέντε ανεξάρτητες εκτιμήσεις της απόδοσης γενίκευσης. Δεν χρησιμοποιήθηκε ξεχωριστό σύνολο δοκιμής, καθώς με μόνο $n = 37$ υποκείμενα (σύνολο δεδομένων A), η δέσμευση ακόμη και του 20% για test set θα οδηγούσε σε περίπου επτά υποκείμενα δοκιμής ανά διαχωρισμό σε επίπεδο υποκειμένου, αριθμός ανεπαρκής για σταθερή εκτίμηση.

Η 5-fold CV χρησιμοποιείται αποκλειστικά ως **μηχανισμός αξιολόγησης** και όχι ως μηχανισμός ρύθμισης. Έτσι αποφεύγεται οποιοσδήποτε κίνδυνος προσαρμογής των υπερπαραμέτρων στα δεδομένα αξιολόγησης.

Απαιτήθηκαν διαφορετικές στρατηγικές επικύρωσης για κάθε σύνολο δεδομένων, λόγω των δομικών διαφορών που παρουσιάζουν.

Σύνολο δεδομένων	Στρατηγική	Πτυχές	Ομαδοποίηση
Σύνολο δεδομένων A (MDVR-KCL)	Ομαδοποιημένο στρωματοποιημένο	5	Ανά subject_id
Σύνολο δεδομένων B (PD Speech)	Στρωματοποιημένο	5	Καμία (μη διαθέσιμη)

Πίνακας 4.6: Στρατηγικές διασταυρούμενης επικύρωσης

Σύνολο δεδομένων A: Ομαδοποιημένη διασταυρούμενη επικύρωση

Για το σύνολο δεδομένων A (MDVR-KCL), υπάρχουν πολλές εγγραφές από το ίδιο άτομο. Για να μην υπάρξει διαρροή δεδομένων, έγινε διαχωρισμός σε επίπεδο υποκειμένου. Αυτό σημαίνει ότι:

- Όλες οι εγγραφές του ίδιου ατόμου μπαίνουν στο ίδιο fold
- Υπάρχει περίπου ισορροπία μεταξύ των κλάσεων
- Το μοντέλο δεν βλέπει ποτέ δεδομένα από άτομα που βρίσκονται στο σύνολο δοκιμής

Έτσι προσομοιώνεται μια ρεαλιστική κατάσταση, όπου το μοντέλο αξιολογείται σε νέους ομιλητές.

Σύνολο δεδομένων B: Τυπική cross-validation

Στο σύνολο δεδομένων B δεν υπάρχουν αναγνωριστικά υποκειμένων. Για αυτό χρησιμοποιήθηκε τυπική 5-fold cross-validation. Ωστόσο, τα αποτελέσματα μπορεί να είναι πιο αισιόδοξα, αν δείγματα του ίδιου ατόμου βρίσκονται σε διαφορετικά folds.

4.5.2 Μετρήσεις αξιολόγησης

Υπολογίστηκαν πέντε βασικές μετρήσεις ταξινόμησης σε κάθε fold:

Μέτρηση	Τύπος	Ερμηνεία
Ακρίβεια	$\frac{TP+TN}{TP+TN+FP+FN}$	Ποσοστό σωστών προβλέψεων συνολικά
Προβλεψιμότητα	$\frac{TP}{TP+FP}$	Από τις προβλέψεις PD, πόσες ήταν σωστές
Ανάκληση	$\frac{TP}{TP+FN}$	Από τα πραγματικά PD, πόσα βρέθηκαν σωστά
Βαθμολογία F1	$\frac{2 \cdot P \cdot R}{P+R}$	Ισορροπία μεταξύ προβλεψιμότητας και ανάκλησης
ROC-AUC	$\int_0^1 \text{TPR}(t) d\text{FPR}(t)$	Ικανότητα διάκρισης ανεξάρτητα από threshold

Πίνακας 4.7: Μετρήσεις αξιολόγησης

Κύρια μέτρηση: Επιλέχθηκε το ROC-AUC γιατί:

- δεν εξαρτάται από ένα συγκεκριμένο threshold,
- είναι πιο σταθερό όταν οι κλάσεις δεν είναι ισορροπημένες,
- έχει σαφή ερμηνεία (πιθανότητα ένας τυχαίος PD να έχει υψηλότερη βαθμολογία από έναν τυχαίο HC).

Η ερμηνεία του ROC-AUC ακολουθεί το κλασικό πλαίσιο του Fawcett [49], ενώ η σχέση ROC και precision-recall καμπυλών λαμβάνεται υπόψη για περιπτώσεις ανισορροπίας κλάσεων [50]. Επι-

πλέον, η διαφανής αναφορά του πειραματικού πρωτοκόλλου και των μετρικών ευθυγραμμίζεται με τις σύγχρονες κατευθυντήριες οδηγίες TRIPOD+AI για μοντέλα πρόβλεψης στην υγεία [36].

Κεφάλαιο 5

Σχεδιασμός πειράματος

5.1 Ερευνητικά ερωτήματα

Τα πειράματα εξετάζουν τα παρακάτω ερωτήματα:

RQ1: Πόσο καλά αποδίδουν τα κλασικά μοντέλα ML στην αναγνώριση PD από φωνητικά χαρακτηριστικά;

RQ2: Βελτιώνεται η απόδοση όταν αυξάνονται τα χαρακτηριστικά από 47 σε 78;

RQ3: Βοηθά η ισορροπημένη στάθμιση κλάσεων σε μη ισορροπημένα δεδομένα;

RQ4: Υπάρχουν διαφορές στα αποτελέσματα μεταξύ του συνόλου δεδομένων A (CV σε επίπεδο υποκειμένου) και του συνόλου δεδομένων B (τυπικό CV);

RQ5: Υπάρχει διαφορά στην απόδοση μεταξύ ανάγνωσης και αυθόρμητης ομιλίας;

5.2 Σχεδιασμός πειραμάτων

Ο σχεδιασμός ακολουθεί την αρχή ότι η αξιολόγηση πρέπει να είναι αυστηρά διαχωρισμένη από τη ρύθμιση υπερπαραμέτρων, καθώς η ταυτόχρονη χρήση του ίδιου βρόχου CV και για τις δύο διαδικασίες οδηγεί σε μεροληπτικές εκτιμήσεις σφάλματος [33, 34]. Επιπλέον, η αβεβαιότητα των εκτιμήσεων υπό K -fold CV ερμηνεύεται με προσοχή, καθώς δεν υπάρχει αμερόληπτος εκτιμητής διακύμανσης για το γενικό πρόβλημα [51]. Για τον λόγο αυτό, οι υπερπαραμέτροι καθορίστηκαν εκ των προτέρων (*a priori*) και το CV χρησιμοποιείται αποκλειστικά για αξιολόγηση. Ο σχεδιασμός περιλαμβάνει τρεις παράγοντες:

1. **Σύνολο χαρακτηριστικών:** 47 (baseline) ή 78 (extended)
2. **Στάθμιση κλάσεων:** χωρίς ή με ισορροπημένη στάθμιση (weighted) για LR, SVM και RF
3. **Μοντέλο:** LR, SVM (RBF), RF, Gradient Boosting, XGBoost

Συνολικά: $2 \times 2 \times 5 = 20$ συνθήκες για κάθε dataset/εργασία.

ID	Χαρακτηριστική	Στάθμιση	Μοντέλα	Έξοδος
C1	47	Καμία	LR, SVM, RF, GB, XGB	baseline/baseline/
C2	47	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/baseline/
C3	78	Καμία	LR, SVM, RF, GB, XGB	baseline/extended/
C4	78	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/extended/

Πίνακας 5.1: Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.

5.2.1 Συνολικές πειραματικές εκτελέσεις

Dataset/Εργασία	Συνθήκες	Μοντέλα	CV Folds	Σύνολο
Dataset A - ReadText	4	5	5	100
Dataset A - SpontaneousDialogue	4	5	5	100
Dataset B - PD Speech	4	5	5	100
Σύνολο				300

Πίνακας 5.2: Συνολικός αριθμός πειραμάτων

Πίνακας 5.3: Σύνθεση συνόλων χαρακτηριστικών ανά ακουστική κατηγορία.

Κατηγορία	Baseline (47)	Extended (78)	Κατηγορία
MFCC (means)	13	13	Φασματικά
Delta-MFCC (1st order)	13	13	Φασματικά/Χρονικά
Pitch (F_0 : mean, std, min, max)	4	4	Προσωδικά
Shimmer (local, apq3, apq5, apq11, dda)	5	5	Προσωδικά
Jitter (local, rap, ppq5)	3	3	Προσωδικά
Formants ($F_1 - F_3$: mean, std, bandwidth)	6	6	Φασματικά
Harmonicity (HNR, autocorr)	2	2	Φωνητικότητα
Intensity (mean, std, min, max) + ZCR	5	5	Ενέργεια
MFCC std	–	13	Φασματικά
Delta-Delta MFCC (means)	–	13	Χρονικά
Spectral shape (centroid, rolloff, contrast, flux)	–	5	Φασματικά
Σύνολο	47	78	

5.3 Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα

Χρησιμοποιήθηκε 5-fold cross-validation (σε επίπεδο υποκειμένου για το Dataset A και στρωματοποιημένο για το Dataset B) [27]. Τα datasets τεκμηριώνονται μέσω των επίσημων πηγών τους (MDVR-KCL στο Zenodo και UCI Parkinson's Disease Classification) [22, 23]. Όλα τα πειράματα εκτελέστηκαν

με `random_state=42` για αναπαραγωγιμότητα. Η προσέγγιση αυτή συμβαδίζει με τις συστάσεις των Ge et al. [35] για την αποφυγή διογκωμένων εκτιμήσεων απόδοσης στην κλινική μηχανική μάθηση.

Η επιλογή του ROC-AUC ως κύριας μέτρησης βασίζεται στο κλασικό πλαίσιο ερμηνείας ROC του Fawcett [49]. Η συμπληρωματική αναφορά precision/recall και F1 χρησιμοποιείται επειδή η βιβλιογραφία δείχνει ότι οι καμπύλες PR παρέχουν επιπλέον πληροφορία σε σενάρια ανισορροπίας κλάσεων [50].

Η αναφορά του πειραματικού σχεδιασμού είναι ευθυγραμμισμένη με σύγχρονες οδηγίες διαφάνειας για μελέτες πρόβλεψης/διαγνωστικής ακρίβειας (TRIPOD+AI, STARD 2015), χωρίς αυτό να συνεπάγεται πλήρη κανονιστική συμμόρφωση κλινικής δοκιμής [36, 52].

Ο Πίνακας 5.4 συνοψίζει τη στρατηγική cross-validation για κάθε dataset, συμπεριλαμβανομένης της αιτιολογίας για τις αντίστοιχες επιλογές.

Πίνακας 5.4: Στρατηγική cross-validation ανά dataset και αιτιολόγηση.

Dataset	CV Τύπος	Μονάδα διαχωρισμού	Αιτιολόγηση
Dataset A (MDVR-KCL)	Grouped Stratified 5-Fold	Υποκείμενο	Πολλαπλές ηχογραφήσεις ανά υποκείμενο: απαιγορεύεται data leakage *Η αγνωσία
Dataset B (PD Speech)	Stratified 5-Fold	Δείγμα (rows)	Αγνωστοί IDs υποκειμένων*

IDs υποκειμένων δεν επιτρέπει grouped CV· τα αποτελέσματα ενδέχεται να είναι αισιόδοξα (§ 8.1).

Τα αποτελέσματα του Dataset B πρέπει να εξετάζονται με προσοχή λόγω της έλλειψης αναγνωριστικών υποκειμένων (βλ. ενότητα 8.1). Οι περιορισμοί παρουσιάζονται στο κεφάλαιο 8.

Κεφάλαιο 6

Αποτελέσματα

6.1 Σύνοψη κύριων αποτελεσμάτων

Dataset	Καλύτερο ROC-AUC	Μοντέλο/Task	Συνθήκη
Dataset A	$0,857 \pm 0,171$	Random Forest / SpontaneousDialogue	Extended (78), unweighted
Dataset A (ReadText)	$0,834 \pm 0,153$	SVM (RBF) / ReadText	Extended (78), unweighted
Dataset B	$0,952 \pm 0,015$	XGBoost	Baseline (47), unweighted

Πίνακας 6.1: Κύρια αποτελέσματα ανά σύνολο δεδομένων

Το Dataset B παρουσιάζει υψηλότερες τιμές και μικρότερη διακύμανση σε σχέση με το Dataset A. Ωστόσο, η σύγκριση πρέπει να ερμηνεύεται με προσοχή λόγω άγνωστης επικάλυψης υποκειμένων (Ενότητα 8.1).

Πίνακας 6.2: Random Forest ROC-AUC ανά task και πειραματική συνθήκη (Dataset A, mean $\pm$ std, 5-fold CV).

Task		Baseline (47 χαρ.)	Extended (78 χαρ.)
ReadText	Unweighted	$0,590 \pm 0,302$	$0,822 \pm 0,166$
	Weighted	$0,687 \pm 0,258$	$0,805 \pm 0,182$
SpontaneousDialogue	Unweighted	$0,828 \pm 0,148$	$0,857 \pm 0,171$
	Weighted	$0,827 \pm 0,133$	$0,823 \pm 0,209$

6.2 Επίδραση χαρακτηριστικών και στάθμισης κλάσεων (Dataset A)

6.2.1 Σύγκριση baseline έναντι extended χαρακτηριστικών

Μοντέλο	Δ ROC-AUC ReadText	Δ ROC-AUC SpontaneousDialogue
Λογιστική παλινδρόμηση	-0,019	+0,023
SVM (RBF)	+0,220	+0,053
Random Forest	+0,232	+0,029
Gradient Boosting	+0,224	+0,023
XGBoost	+0,166	-0,036

Πίνακας 6.3: Επίδραση feature extension (78 έναντι 47 χαρακτηριστικών) στο Dataset A

Το feature extension συνδέεται με ουσιαστική βελτίωση στο ReadText, ενώ στο SpontaneousDialogue η μεταβολή είναι μικρότερη και model-dependent.

6.2.2 Σύνοψη επίδρασης class weighting

Task	Δ ROC-AUC RF (baseline)	Δ ROC-AUC RF (extended)
ReadText	+0,097	-0,017
SpontaneousDialogue	-0,001	-0,034

Πίνακας 6.4: Επίδραση class weighting στο Random Forest (Dataset A)

Η στάθμιση κλάσεων δεν παρείχε σταθερό όφελος στις παρούσες συνθήκες, ιδιαίτερα όταν χρησιμοποιήθηκαν extended χαρακτηριστικά.

6.3 Σταθερότητα και διακύμανση

Μετρική	Dataset A	Dataset B
ROC-AUC std	$\pm 0,15-0,30$	$\pm 0,01-0,03$
Accuracy std	$\pm 0,14-0,18$	$\pm 0,008-0,024$
F1 std	$\pm 0,21-0,39$	$\pm 0,006-0,015$

Πίνακας 6.5: Σύγκριση διακύμανσης μεταξύ Dataset A και Dataset B

Η υψηλή διακύμανση στο Dataset A είναι συμβατή με το μικρό μέγεθος δείγματος ($n = 37/36$) και απαιτεί συντηρητική ερμηνεία των διαφορών μεταξύ μοντέλων.

6.4 Συγκριτικός πίνακας Random Forest ανά συνθήκη


Ο Random Forest επιλέχθηκε ως αντιπροσωπευτικό μοντέλο για τη συνολική σύγκριση, λόγω της σταθερής του συμπεριφοράς σε όλες τις ρυθμίσεις. Ο Πίνακας 6.2 έχει παρουσιαστεί νωρίτερα για συνοπτική ανάγνωση, ενώ ο Πίνακας 6.6 παραθέτει την Accuracy σε κάθε συνδυασμό feature set και class weighting. Αναλυτικά αποτελέσματα για όλα τα μοντέλα δίνονται στο Παράρτημα B.

Πίνακας 6.6: Random Forest Accuracy ανά task και πειραματική συνθήκη (Dataset A, mean $\pm$ std, 5-fold CV).

Task		Baseline (47 χαρ.)	Extended (78 χαρ.)
ReadText	Unweighted	62,9% $\pm$ 17,8%	81,8% $\pm$ 14,0%
	Weighted	65,0% $\pm$ 14,8%	81,8% $\pm$ 14,0%
SpontaneousDialogue	Unweighted	72,1% $\pm$ 17,6%	77,9% $\pm$ 16,1%
	Weighted	69,3% $\pm$ 12,3%	72,1% $\pm$ 20,3%


Τα δεδομένα υποδηλώνουν ότι το extended feature set παρέχει σταθερά υψηλότερη απόδοση στο ReadText (+23,2 pp ROC-AUC, unweighted), ενώ στο SpontaneousDialogue η βελτίωση είναι πιο περιορισμένη. Η προσθήκη class weighting δεν οδηγεί σε σταθερό όφελος και εμφανίζει task-εξαρτώμενη συμπεριφορά.

6.5 Οπτική επιβεβαίωση αποτελεσμάτων



(α') ReadText (Dataset A, extended, grouped 5-fold CV).

(β') SpontaneousDialogue (Dataset A, extended, grouped 5-fold CV).




(γ') Dataset B (stratified 5-fold CV).


Σχήμα 6.1: ROC curves για τα βασικά πειράματα. Για το Dataset B, τα αποτελέσματα ενδέχεται να είναι αισιόδοξα λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds.

6.5.1 Confusion matrices


Οι confusion matrices παρουσιάζουν τις ταξινομήσεις του καλύτερου μοντέλου ανά dataset, επιτρέποντας την αξιολόγηση των σφαλμάτων τύπου I (false positive) και τύπου II (false negative) ξεχωριστά.



Σχήμα 6.2: Confusion matrix για το ReadText task (Dataset A, Random Forest, extended features, unweighted). HC = Healthy Control, PD = Parkinson's Disease.



Σχήμα 6.3: Confusion matrix για το SpontaneousDialogue task (Dataset A, Random Forest, extended features, unweighted).



Σχήμα 6.4: Confusion matrix για το Dataset B (XGBoost, baseline features, unweighted). Σημείωση: λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds, τα αποτελέσματα ενδέχεται να είναι αισιόδοξα.

6.6 Παραπομπή σε πλήρη αποτελέσματα

Οι αναλυτικοί πίνακες για όλες τις πειραματικές συνθήκες (C1–C4, ανά task και μοντέλο) παρατίθενται στο Παράρτημα B και περιλαμβάνουν Accuracy, Precision, Recall, F1 και ROC-AUC για όλα τα μοντέλα. Η πλήρης κατάταξη σημαντικότητας χαρακτηριστικών ανά μοντέλο παρατίθεται στο Παράρτημα A. Οι θερμικοί χάρτες σημαντικότητας χαρακτηριστικών για ReadText και SpontaneousDialogue παρατίθενται συγκριτικά στο Παράρτημα B (Σχήματα B.1α' και B.1β') για συνοπτικότερη παρουσίαση στο κύριο κείμενο.

Κεφάλαιο 7

Συζήτηση

7.1 Ερμηνεία βασικών ευρημάτων

Τα αποτελέσματα του Κεφαλαίου 6 υποδηλώνουν ότι η επίδοση εξαρτάται κυρίως από τρεις παράγοντες: (i) το είδος χαρακτηριστικών, (ii) το speech task και (iii) το πρωτόκολλο επικύρωσης. Η καλύτερη επίδοση στο Dataset A ($0,857 \pm 0,171$ ROC-AUC) παρατηρήθηκε με Random Forest και extended χαρακτηριστικά (C3), ενώ η διακύμανση παρέμεινε υψηλή, κάτι αναμενόμενο για μικρό δείγμα.

7.1.1 Επέκταση χαρακτηριστικών

Η επέκταση από 47 σε 78 χαρακτηριστικά βελτίωσε κυρίως το ReadText και πιο ήπια το SpontaneousDialogue. Αυτό υποδηλώνει ότι στη δομημένη ομιλία τα πρόσθετα φασματικά/δυναμικά χαρακτηριστικά προσθέτουν διακριτική πληροφορία που δεν καλύπτεται από το baseline σύνολο.

7.1.2 Στάθμιση κλάσεων

Η επιλογή `class_weight='balanced'` δεν παρουσίασε σταθερό όφελος. Σε αρκετές συνθήκες οι διαφορές ήταν μικρές ή αρνητικές, γεγονός συμβατό με την ήπια ανισορροπία του Dataset A και την υψηλή μεταβλητότητα fold-to-fold.

7.1.3 Ιεραρχία μοντέλων και σταθερότητα

Το Random Forest εμφάνισε τη πιο σταθερή συμπεριφορά στις περισσότερες ρυθμίσεις, ενώ τα γραμμικά ή περισσότερο ευαίσθητα μοντέλα εμφάνισαν μεγαλύτερη αστάθεια σε μικρά folds. Συνεπώς, οι διαφορές πρέπει να διαβάζονται ως τάσεις και όχι ως οριστικές κατατάξεις, ειδικά όταν τα διαστήματα αβεβαιότητας επικαλύπτονται. Η αναλυτική εικόνα για όλες τις συνθήκες C1–C4 και όλα τα μοντέλα δίνεται στο Παράρτημα B.

7.2 Σύγκριση με προηγούμενη βιβλιογραφία

Η παρούσα μελέτη είναι μεθοδολογικά συντηρητική σε σύγκριση με συχνές πρακτικές της βιβλιογραφίας [35]: χρησιμοποιεί grouped stratified CV στο Dataset A, διαχωρίζει ρητά τα speech tasks και αναφέρει συστηματικά $\text{mean} \pm \text{std}$ για όλες τις συνθήκες. Αυτές οι επιλογές τείνουν να αποφεύγουν αισιόδοξες εκτιμήσεις και να βελτιώνουν την αναπαραγωγικότητα. Η ερμηνεία των ευρημά-

των ακολουθεί επίσης τις αρχές διαφανούς αναφοράς και αξιολόγησης κινδύνου μεροληψίας που προτείνονται από τα TRIPOD+AI και PROBAST+AI [36, 37].

Τα παρόντα ευρήματα πρέπει να ερμηνεύονται ως αποτελέσματα εσωτερικής επικύρωσης στα διαθέσιμα datasets και όχι ως τεκμήριο γενίκευσης σε νέους πληθυσμούς ή κλινικά περιβάλλοντα. Η εξωτερική επικύρωση σε ανεξάρτητες κοόρτες, συσκευές και πρωτόκολλα καταγραφής αποτελεί αναγκαίο επόμενο βήμα.

Οι απόλυτες τιμές ROC-AUC είναι συγκρίσιμες με αναφορές κλασικών μελετών [3, 32, 53], αλλά η άμεση αντιπαραβολή παραμένει περιορισμένη λόγω διαφορών σε datasets, features και validation protocols. Πρόσφατες συστηματικές ανασκοπήσεις [6–8] επιβεβαιώνουν ότι η ετερογένεια στις στρατηγικές αξιολόγησης καθιστά την άμεση σύγκριση μεταξύ μελετών προβληματική.

7.3 Ερμηνεία σημαντικότητας χαρακτηριστικών

Τα μοτίβα σημαντικότητας έδειξαν εξάρτηση από το task:

- Στο ReadText, χαρακτηριστικά που σχετίζονται με θεμελιώδη συχνότητα και σταθερότητα φωνής εμφανίστηκαν συχνότερα στις κορυφαίες θέσεις, σε συμφωνία με τα ευρήματα των Little et al. [3] και Rusz et al. [21] για τη σημασία των φωνητικών χαρακτηριστικών στην PD.
- Στο SpontaneousDialogue, αυξήθηκε η συνεισφορά MFCC και μέτρων perturbation, υποδηλώνοντας εντονότερη πληροφορία φασματικής μεταβλητότητας.
- Στο Dataset B, τα κυρίαρχα χαρακτηριστικά περιλαμβάνουν εξειδικευμένες αναπαραστάσεις σήματος, γεγονός που δυσκολεύει την άμεση αντιστοίχιση με πιο απλά κλινικά pipelines.

Για μια ευρύτερη εποπτεία, ο Πίνακας 7.1 συνοψίζει τη σχετική σημαντικότητα ανά ακουστική κατηγορία, αποκαλύπτοντας ότι τα MFCC και Delta-MFCC κυριαρχούν και στα δύο tasks, ενώ η σχετική βαρύτητα Pitch και Shimmer διαφέρει.

Πίνακας 7.1: Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά ακουστική κατηγορία (Random Forest, Dataset A). Αριθμός χαρακτηριστικών ανά κατηγορία στο baseline set (47 χαρ.). Πλήρης ανάλυση ανά μοντέλο στο Παράρτημα A.

Κατηγορία	# Χαρ.	ReadText (%)	Spontaneous (%)
MFCC	13	28,4	32,1
Delta MFCC	13	22,7	25,3
Pitch (F_0)	4	15,2	12,8
Shimmer	5	11,3	14,6
Formants	6	9,8	7,2
Harmonicity	2	6,1	4,3
Άλλα	5	6,5	3,7

Το Σχήμα 1.5 παρουσιάστηκε στην Ενότητα των συνεισφορών (Κεφάλαιο 1) ως συνοπτική προεπισκόπηση και εδώ χρησιμοποιείται για λεπτομερή ερμηνεία ανά κατηγορία χαρακτηριστικών.

Επιπλέον, ο Πίνακας 7.2 αναδεικνύει χαρακτηριστικά που εμφανίζονται στο top-10 και στα δύο tasks, υποδηλώνοντας task-general ακουστικές υπογραφές της PD.

Πίνακας 7.2: Χαρακτηριστικά με σταθερή σημαντικότητα και στα δύο speech tasks (Random Forest, top-10 per task, Dataset A). Τιμή “–” υποδηλώνει απουσία από το top-10 του αντίστοιχου task. Πλήρης ανάλυση στο Παράρτημα A.

Χαρακτηριστικό	Κατάταξη ReadText	Κατάταξη Spontaneous
delta_mfcc_2_mean	2	5
autocorr_harmonicity	4	6
f0_mean	6	10
shimmer_apq (apq3/apq11)	7	2
mfcc_5_mean	–	1
f0_std	–	9

Τα task-general χαρακτηριστικά (delta_mfcc_2_mean, autocorr_harmonicity, shimmer) πιθανότατα αποτυπώνουν θεμελιώδεις φωνητικές επιπτώσεις της PD, ανεξάρτητα από το speech context. Αυτό συμφωνεί με την ανασκόπηση των Wright and Aharonson [8], όπου το jitter, το shimmer και το HNR αναδείχθηκαν ως τα πιο συνεπή διακριτικά χαρακτηριστικά σε όλες τις μελέτες, και με την εργασία των Cao et al. [1] που αναγνωρίζει τα φωνητικά χαρακτηριστικά ως πιθανούς ψηφιακούς βιοδείκτες. Η κυριαρχία του mfcc_5_mean αποκλειστικά στο SpontaneousDialogue μπορεί να αντανάκλα διαφορές στην prosodic variability μεταξύ δομημένης ανάγνωσης και φυσικού διαλόγου.

Η πλήρης κατάταξη χαρακτηριστικών ανά μοντέλο δίνεται στο Παράρτημα A.

7.4 Μεθοδολογικές συνέπειες

Τα ευρήματα υποστηρίζουν τρεις πρακτικές για μελλοντικές μελέτες:

1. χρήση grouped CV όταν υπάρχουν πολλαπλές εγγραφές ανά υποκείμενο,
2. συστηματική αναφορά διακύμανσης και όχι μόνο καλύτερων τιμών,
3. διάκριση μεταξύ ReadText και SpontaneousDialogue αντί για σιωπηρή ενοποίηση.

Στο πλαίσιο αυτό, τα αποτελέσματα του Dataset B πρέπει να ερμηνεύονται ως δυνητικά αισιόδοξα λόγω του περιορισμού που αναφέρεται στην Ενότητα 8.1.

Κεφάλαιο 8

Περιορισμοί και απειλές για την εγκυρότητα

8.1 Περιορισμοί δεδομένων και δειγματοληψίας

Ο βασικός περιορισμός της μελέτης είναι η ταυτόχρονη παρουσία μικρού δείγματος στο Dataset A και απουσίας αναγνωριστικών υποκειμένων στο Dataset B.

Πίνακας 8.1: Κρίσιμοι περιορισμοί ανά σύνολο δεδομένων

Σύνολο	Περιορισμός	Επίπτωση
Dataset A (ReadText + SpontaneousDialogues)	37/36 υποκείμενα, περίπου 7–8 ανά fold, ήπια ανισορροπία κλάσεων	Αυξημένη διακύμανση fold-to-fold, περιορισμένη ισχύς για μικρές διαφορές, προσεκτική ερμηνεία γενίκευσης
Dataset B (PD Speech Features)	756 δείγματα χωρίς IDs υποκειμένων, έντονη ανισορροπία (74,6% PD)	Πιθανή επικάλυψη train-test στο ίδιο άτομο, δυνητικά αισιόδοξη εκτίμηση απόδοσης, δυσκολότερη σύγκριση με Dataset A

Προειδοποίηση: Τα αποτελέσματα του Dataset B μπορεί να είναι αισιόδοξα, επειδή δεν είναι γνωστό αν υπάρχει επικάλυψη υποκειμένων μεταξύ των folds. Η έντονη ανισορροπία κλάσεων δυσκολεύει επιπλέον την ερμηνεία.

Η άμεση σύγκριση μεταξύ Dataset A και Dataset B πρέπει να γίνεται με προσοχή, καθώς διαφοροποιούνται ταυτόχρονα η στρατηγική cross-validation, το μέγεθος δείγματος, το είδος ομιλίας και το επίπεδο ανισορροπίας. Άρα, οι διαφορές διαβάζονται κυρίως ως ενδείξεις τάσης και όχι ως οριστικά συμπεράσματα γενίκευσης.

8.2 Μεθοδολογικοί και τεχνικοί περιορισμοί

8.2.1 Επιλογές μοντελοποίησης και ρύθμισης

Η μελέτη χρησιμοποίησε προεπιλεγμένες ρυθμίσεις sklearn, με σταθερό random seed και έλεγχο στάθμησης κλάσεων. Η επιλογή αυτή ενισχύει αναπαραγωγικότητα και δίκαιη σύγκριση μοντέλων, αλλά πιθανόν υποεκτιμά το μέγιστο εφικτό επίπεδο απόδοσης.

Η μη χρήση nested CV για εκτενή ρύθμιση υπερπαραμέτρων είναι συνειδητή: με τόσο μικρό δείγμα στο Dataset A, τα εσωτερικά folds θα ήταν πολύ μικρά και ιδιαίτερα ασταθή. Αναγνωρίζεται ότι η ταυτόχρονη χρήση CV για ρύθμιση και αξιολόγηση μπορεί να οδηγήσει σε μεροληπτικές εκτιμήσεις σφάλματος [33, 34], αλλά η προσέγγιση της παρούσας εργασίας μετριάξει αυτόν τον κίνδυνο μέσω της χρήσης σταθερών, εκ των προτέρων καθορισμένων υπερπαραμέτρων. Η αιτιολόγηση της στρατηγικής cross-validation παραμένει στην Ενότητα 4.5.1.

8.2.2 Περιορισμοί εξαγωγής χαρακτηριστικών

Το σύνολο χαρακτηριστικών καθορίστηκε εκ των προτέρων από τη βιβλιογραφία (47 baseline, 78 extended) [30], χωρίς διαδικασία επιλογής χαρακτηριστικών ή διερεύνηση εναλλακτικών μετασχηματισμών. Επιπλέον, η εξαγωγή βασίζεται σε υπόθεση επαρκούς ποιότητας ηχογράφησης, η οποία δεν είναι πλήρως ελέγξιμη για το Dataset B.

8.2.3 Εξωτερική επικύρωση και γενίκευση

Όλα τα αποτελέσματα βασίζονται σε εσωτερική 5-fold διασταυρούμενη επικύρωση, χωρίς ανεξάρτητο εξωτερικό test set. Όπως επισημαίνουν οι Ge et al. [35], η εσωτερική αξιολόγηση μπορεί να υπερεκτιμήσει την πραγματική απόδοση στον τομέα της υγείας. Σύμφωνα με τις κατευθυντήριες γραμμές TRIPOD+AI [36] και PROBAST+AI [37], η διάκριση μεταξύ εσωτερικής επικύρωσης και εξωτερικής αξιολόγησης είναι κρίσιμη για τη σωστή ερμηνεία των αποτελεσμάτων. Συνεπώς, η γενίκευση σε άλλες συσκευές, περιβάλλοντα, γλώσσες ή χρονικά σημεία παραμένει ανοικτό ερευνητικό ερώτημα.

8.3 Απειλές για την εγκυρότητα

Πίνακας 8.2: Σύνοψη απειλών εγκυρότητας και μετριάσμών

Τύπος εγκυρότητας	Κύριες απειλές	Μέτρα μετριάσμού
Εσωτερική	Διαρροή υποκειμένου (Dataset B), θόρυβος ετικέτας, σφάλματα προεπεξεργασίας	GroupedStratifiedKFold στο Dataset A, σταθερό RANDOM_SEED=42, τυποποιημένη κανονικοποίηση ήχου και έλεγχοι pipeline
Εξωτερική	Μεροληψία πληθυσμού, μεταβλητότητα συνθηκών εγγραφής, άγνωστη χρονική σταθερότητα	Διαφανής αναφορά περιορισμών και συντηρητική ερμηνεία αποτελεσμάτων

Συνολικά, τα ευρήματα πρέπει να ερμηνεύονται ως αναπαραγώγιμη ερευνητική βάση εσωτερικής επικύρωσης και όχι ως οριστικό συμπέρασμα κλινικής γενίκευσης.

Κεφάλαιο 9

Συμπεράσματα

9.1 Περίληψη

Η εργασία διερεύνησε την ταξινόμηση PD έναντι HC από φωνητικά χαρακτηριστικά, με έμφαση στη μεθοδολογική αυστηρότητα (ομαδοποιημένη CV όπου απαιτείται, σταθερές παράμετροι, πλήρης αναφορά διακύμανσης). Τα αποτελέσματα δείχνουν ότι η ταξινόμηση είναι εφικτή, αλλά η σταθερότητα εξαρτάται έντονα από το μέγεθος δείγματος, το είδος ομιλίας και το πρωτόκολλο επικύρωσης.

9.2 Κύριες συνεισφορές

1. **Αυστηρό πρωτόκολλο αξιολόγησης:** εφαρμογή grouped stratified 5-fold CV για αποφυγή διαρροής υποκειμένων στο Dataset A.
2. **Συστηματική σύγκριση χαρακτηριστικών:** αξιολόγηση baseline (47) και extended (78) συνόλων με κοινό πειραματικό σχεδιασμό.
3. **Αναπαραγωγιμότητα:** σταθερός random seed, καθορισμένες παράμετροι και ενιαίο workflow εξαγωγής/εκπαίδευσης.

9.3 Συνοπτικές απαντήσεις στα ερευνητικά ερωτήματα

- **RQ1 – Απόδοση κλασικών μοντέλων:** Η καλύτερη επίδοση στο Dataset A έφτασε ROC-AUC $0,857 \pm 0,171$ (Random Forest, extended, SpontaneousDialogue), με εμφανή μεταβλητότητα λόγω μικρού δείγματος.
- **RQ2 – Επίδραση επέκτασης χαρακτηριστικών:** Η επέκταση 47→78 βελτίωσε ουσιαστικά το ReadText και πιο ήπια το SpontaneousDialogue, δείχνοντας εξάρτηση από το task.
- **RQ3 – Στάθμιση κλάσεων:** Η επιλογή `class_weight=balanced` δεν έδωσε σταθερό και γενικεύσιμο όφελος στις παρούσες ρυθμίσεις.
- **RQ4 – Grouped έναντι τυπικής CV:** Το Dataset B εμφάνισε υψηλότερες και σταθερότερες τιμές, αλλά η απουσία IDs υποκειμένων επιβάλλει προσεκτική ερμηνεία.
- **RQ5 – Διαφορά εργασιών ομιλίας:** Η SpontaneousDialogue παρέμεινε ισχυρή, ενώ το ReadText ωφελήθηκε περισσότερο από την επέκταση χαρακτηριστικών.

9.4 Επιπτώσεις και προτεραιότητες συνέχειας

- **Μεθοδολογική πρακτική:** grouped CV όταν υπάρχουν πολλαπλές εγγραφές ανά υποκείμενο και αναφορά όλων των συνθηκών, όχι μόνο των καλύτερων.
- **Διαχείριση δεδομένων:** τα μελλοντικά datasets πρέπει να περιλαμβάνουν IDs υποκειμένων και μεταδεδομένα συνθηκών εγγραφής.
- **Επόμενα βήματα:** εξωτερική επικύρωση, nested CV για υπερπαραμέτρους [33], και στοχευμένη επιλογή χαρακτηριστικών. Η πρόσφατη εργασία των Cao et al. [1] υποδεικνύει ότι τα φωνητικά χαρακτηριστικά μπορούν να λειτουργήσουν ως ψηφιακοί βιοδείκτες για την PD, καθιστώντας τα αποτελέσματα της παρούσας εργασίας σχετικά με την ευρύτερη επιδίωξη μη επεμβατικής ανίχνευσης.

9.5 Τελική τοποθέτηση

Τα ευρήματα υποστηρίζουν ότι η φωνητική ταξινόμηση PD/HC με κλασικά μοντέλα είναι επιστημονικά τεκμηριώσιμη ως ερευνητική προσέγγιση, όχι όμως έτοιμη για κλινική χρήση. Τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή δεδομένου του μικρού δείγματος στο Dataset A και της πιθανής αισιοδοξίας στο Dataset B λόγω άγνωστης επικάλυψης υποκειμένων.

Βιβλιογραφία

- [1] F. Cao, A. P. Vogel, P. Gharahkhani, and M. E. Renteria, “Speech and language biomarkers for Parkinson’s disease prediction, early diagnosis and progression,” *npj Parkinson’s Disease*, vol. 11, no. 1, p. 57, 2025.
- [2] B. T. Harel, M. S. Cannizzaro, and P. J. Snyder, “Acoustic characteristics of Parkinsonian speech: a potential biomarker of early disease progression and treatment,” *Journal of Neurolinguistics*, vol. 17, no. 6, pp. 439–453, 2004.
- [3] M. A. Little, P. E. McSharry, E. J. Hunter, J. Spielman, and L. O. Ramig, “Suitability of dysphonia measurements for telemonitoring of Parkinson’s disease,” *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 4, pp. 1015–1022, 2009.
- [4] A. Tsanas, M. A. Little, P. E. McSharry, and L. O. Ramig, “Accurate telemonitoring of Parkinson’s disease progression by noninvasive speech tests,” *IEEE Transactions on Biomedical Engineering*, vol. 57, no. 4, pp. 884–893, 2010.
- [5] J. R. Duffy, *Motor speech disorders: Substrates, differential diagnosis, and management*, 3rd ed. Elsevier Health Sciences, 2012.
- [6] H. Sedigh Malekroodi, B.-i. Lee, and M. Yi, “Voice-based detection of Parkinson’s disease using machine and deep learning approaches: A systematic review,” *Bioengineering*, vol. 12, no. 11, p. 1279, 2025.
- [7] D. Xavier, V. Felizardo, B. Ferreira, H. Zacarias, M. Pourvahab, L. Souza-Pereira, and N. M. Garcia, “Voice analysis in Parkinson’s disease—a systematic literature review,” *Artificial Intelligence in Medicine*, vol. 163, p. 103109, 2025.
- [8] H. Wright and V. Aharonson, “Vocal feature changes for monitoring Parkinson’s disease progression—a systematic review,” *Brain Sciences*, vol. 15, no. 3, p. 320, 2025.
- [9] L. V. Kalia and A. E. Lang, “Parkinson’s disease,” *The Lancet*, vol. 386, no. 9996, pp. 896–912, 2015.
- [10] J. Jankovic, “Parkinson’s disease: Clinical features and diagnosis,” *Journal of Neurology, Neurosurgery & Psychiatry*, vol. 79, no. 4, pp. 368–376, 2008.
- [11] World Health Organization, “Parkinson disease,” WHO Fact Sheet, 2023. [Online]. Available: <https://www.who.int/news-room/fact-sheets/detail/parkinson-disease>
- [12] A. K. Ho, R. Iansek, C. Marigliani, J. L. Bradshaw, and S. Gates, “Speech impairment in a large sample of patients with Parkinson’s disease,” *Behavioural Neurology*, vol. 11, no. 3, pp. 131–137, 1999.

- [13] I. R. Titze, *Principles of Voice Production*. Englewood Cliffs, NJ: Prentice Hall, 1994.
- [14] L. O. Ramig, C. Fox, and S. Sapir, “Speech treatment for Parkinson’s disease,” *Expert Review of Neurotherapeutics*, vol. 8, no. 2, pp. 297–309, 2008.
- [15] J. M. Tracy, C. Özsancak, P. Atkins, and J. S. Kelso, “Investigating voice as a biomarker: deep phenotyping methods for early detection of Parkinson’s disease,” *Journal of Biomedical Informatics*, vol. 44, no. Suppl 1, pp. S24–S30, 2011.
- [16] S. Skodda, W. Visser, and U. Schlegel, “Intonation and speech rate in Parkinson’s disease: General and dynamic aspects and responsiveness to levodopa admission,” *Journal of Voice*, vol. 25, no. 4, pp. e199–e205, 2011.
- [17] S. B. Davis and P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 28, no. 4, pp. 357–366, 1980.
- [18] J. R. Orozco-Arroyave, J. D. Arias-Londoño, J. F. V. Bonilla, M. C. Gonzalez-Rativa, and E. Nöth, “Automatic detection of Parkinson’s disease in running speech spoken in three different languages,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2016, pp. 4785–4789.
- [19] Q. C. Ngo, M. A. Motin, N. D. Pah, P. Drotár, P. Kempster, and D. Kumar, “Computerized analysis of speech and voice for parkinson’s disease: A systematic review,” *Computer Methods and Programs in Biomedicine*, vol. 226, p. 107133, 2022.
- [20] M. A. Little, P. E. McSharry, S. J. Roberts, D. A. Costello, and I. M. Moroz, “Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection,” *BioMedical Engineering OnLine*, vol. 6, no. 1, p. 23, 2007, introduced nonlinear dynamic features for voice analysis.
- [21] J. Ruzs, R. Cmejla, H. Ruzickova, and E. Ruzicka, “Quantitative acoustic measurements for characterization of speech and voice disorders in early untreated Parkinson’s disease,” *The Journal of the Acoustical Society of America*, vol. 129, no. 1, pp. 350–367, 2011.
- [22] H. Jaeger, D. Trivedi, and M. Stadtschnitzer, “MDVR-KCL: Mobile device voice recordings at King’s College London,” 2019, collected 26–29 September 2017 at King’s College Hospital, London, UK. [Online]. Available: <https://zenodo.org/records/2867216>
- [23] C. O. Sakar, G. Serbes, A. Gunduz, H. C. Tunc, H. Nizam, B. E. Sakar, M. Tutuncu, T. Aydin, M. E. Isenkul, and H. Apaydin, “Parkinson’s disease classification dataset,” 2018. [Online]. Available: <https://doi.org/10.24432/C5MS4X>
- [24] D. Biswas, “Parkinson’s disease speech signal features,” 2020, originally from UCI Machine Learning Repository. [Online]. Available: <https://www.kaggle.com/datasets/dipayanbiswas/parkinsons-disease-speech-signal-features>

- [25] I. W. Selesnick, “Wavelet transform with tunable q-factor,” *IEEE Transactions on Signal Processing*, vol. 59, no. 8, pp. 3560–3575, 2011.
- [26] D. R. Cox, “The regression analysis of binary sequences,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–242, 1958.
- [27] C. M. Bishop, *Pattern recognition and machine learning*. Springer, 2006.
- [28] D. W. Hosmer, S. Lemeshow, and R. X. Sturdivant, *Applied Logistic Regression*, 3rd ed. Wiley, 2013.
- [29] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [30] N. Sáenz-Lechón, J. Godino-Llorente, V. Oasma-Ruiz, and P. Gómez-Vilda, “Methodological issues in the development of automatic systems for voice pathology detection,” *Biomedical Signal Processing and Control*, vol. 1, no. 2, pp. 120–128, 2006, systematic review of methodological issues in voice pathology detection.
- [31] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [32] G. Solana-Lavalle and R. Rosas-Romero, “Analysis of voice as an assisting tool for detection of Parkinson’s disease and its subsequent clinical interpretation,” *Biomedical Signal Processing and Control*, vol. 66, p. 102415, 2021.
- [33] S. Varma and R. Simon, “Bias in error estimation when using cross-validation for model selection,” *BMC Bioinformatics*, vol. 7, no. 1, p. 91, 2006.
- [34] G. C. Cawley and N. L. Talbot, “On over-fitting in model selection and subsequent selection bias in performance evaluation,” *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010.
- [35] W. Ge, C. Lueck, H. Suominen, and D. Apthorp, “Has machine learning over-promised in healthcare? A critical analysis of peril and the path to progress,” *Artificial Intelligence in Medicine*, vol. 140, p. 102524, 2023.
- [36] G. S. Collins, K. G. Moons, P. Dhiman, R. D. Riley, A. L. Beam, B. Van Calster, M. Ghassemi, X. Liu, J. B. Reitsma, M. van Smeden *et al.*, “TRIPOD+AI statement: Updated guidance for reporting clinical prediction models that use regression or machine learning methods,” *BMJ*, vol. 385, p. e078378, 2024.
- [37] K. G. Moons, P. Dhiman, R. D. Riley, G. S. Collins, B. Van Calster, M. Ghassemi, X. Liu, J. B. Reitsma, M. van Smeden *et al.*, “PROBAST+AI: An updated quality, risk of bias, and applicability assessment tool for prediction models using regression or machine learning methods,” *BMJ*, vol. 389, p. e082505, 2025.
- [38] B. E. Sakar, M. E. Isenkul, C. O. Sakar, A. Sertbas, F. Gurgen, S. Delil, H. Apaydin, and O. Kursun, “Collection and analysis of a Parkinson speech dataset with multiple types of sound recordings,” *IEEE Journal of Biomedical and Health Informatics*, vol. 17, no. 4, pp. 828–834, 2013.

- [39] C. O. Sakar, G. Serbes, A. Gunduz, H. C. Tunc, H. Nizam, B. E. Sakar, M. Tutuncu, T. Aydin, M. E. Isenkul, and H. Apaydin, "A comparative analysis of speech signal processing algorithms for Parkinson's disease classification and the use of the tunable Q-factor wavelet transform," *Applied Soft Computing*, vol. 74, pp. 255–263, 2019.
- [40] Y. Jadoul, B. Thompson, and B. de Boer, "Parselmouth: Praat in Python," Software, 2018. [Online]. Available: <https://github.com/YannickJadoul/Parselmouth>
- [41] L. R. Rabiner, "On the use of autocorrelation analysis for pitch detection," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 25, no. 1, pp. 24–33, 1977.
- [42] M. P. Gelfer and D. M. Fendel, "Comparisons of jitter, shimmer, and signal-to-noise ratio from directly digitized versus taped voice samples," *Journal of Voice*, vol. 9, no. 4, pp. 378–382, 1995.
- [43] S. N. Awan and M. L. Frenkel, "Improvements in estimating the harmonics-to-noise ratio of the voice," *Journal of Voice*, vol. 8, no. 3, pp. 255–262, 1994.
- [44] B. McFee, C. Raffel, D. Liang, D. P. Ellis, M. McVicar, E. Battenberg, and O. Nieto, "librosa: Audio and music signal analysis in python," Software, 2015. [Online]. Available: <https://librosa.org>
- [45] J. A. Nelder and R. W. M. Wedderburn, "Generalized linear models," *Journal of the Royal Statistical Society. Series A (General)*, vol. 135, no. 3, pp. 370–384, 1972.
- [46] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [47] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.
- [48] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [49] T. Fawcett, "An introduction to roc analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [50] J. Davis and M. Goadrich, "The relationship between precision-recall and roc curves," in *Proceedings of the 23rd International Conference on Machine Learning*. ACM, 2006, pp. 233–240.
- [51] Y. Bengio and Y. Grandvalet, "No unbiased estimator of the variance of k-fold cross-validation," *Journal of Machine Learning Research*, vol. 5, pp. 1089–1105, 2004. [Online]. Available: <https://jmlr.org/papers/v5/grandvalet04a.html>
- [52] P. M. Bossuyt, J. B. Reitsma, D. E. Bruns, C. A. Gatsonis, P. P. Glasziou, L. M. Irwig, J. G. Lijmer, D. Moher, D. Rennie, H. C. W. de Vet, H. Y. Kressel, N. Rifai, R. M. Golub, D. G. Altman, L. Hooft, D. A. Korevaar, and J. F. Cohen, "STARD 2015: An updated list of essential items for reporting diagnostic accuracy studies," *BMJ*, vol. 351, p. h5527, 2015.

-
- [53] A. Tsanas, M. A. Little, P. E. McSharry, and L. O. Ramig, “A comparison of regression methods for remote tracking of Parkinson’s disease progression,” *Expert Systems with Applications*, vol. 39, no. 5, pp. 5764–5771, 2012.

Παράρτημα Α

Πίνακες Σημαντικότητας Χαρακτηριστικών

A.1 Επισκόπηση

Το παρόν παράρτημα παρουσιάζει τα 20 σημαντικότερα χαρακτηριστικά για κάθε πειραματική συνθήκη, όπως προκύπτουν από τις εγγενείς μετρικές σημαντικότητας των μοντέλων:

- **Logistic Regression:** Απόλυτες τιμές coefficients
- **Random Forest:** Gini importance (mean decrease in impurity)

A.2 Dataset A — ReadText Task

A.2.1 Random Forest — Top 20 Features


Rank	Feature	Importance	Std
1	f0_max	0.052	0.019
2	delta_mfcc_2_mean	0.039	0.018
3	f3_std	0.038	0.011
4	autocorr_harmonicity	0.038	0.017
5	intensity_mean	0.035	0.021
6	f0_mean	0.032	0.012
7	shimmer_apq3	0.032	0.013
8	mfcc_12_mean	0.031	0.007
9	f1_std	0.031	0.022
10	mfcc_6_mean	0.030	0.024

Πίνακας A.1: Σημαντικότητα χαρακτηριστικών του Random Forest — ReadText (top 10)

A.2.2 Logistic Regression — Top 20 Features

Rank	Feature	Coefficient	Std
1	f0_max	0.754	0.203
2	hnr_mean	0.649	0.178
3	shimmer_apq11	0.553	0.145
4	delta_mfcc_4_mean	0.496	0.163
5	delta_mfcc_2_mean	0.492	0.103
6	delta_mfcc_1_mean	0.474	0.273
7	mfcc_5_mean	0.470	0.127
8	mfcc_4_mean	0.426	0.233
9	mfcc_10_mean	0.418	0.221
10	mfcc_11_mean	0.388	0.192

Πίνακας A.2: Σημαντικότητα χαρακτηριστικών του Logistic Regression — ReadText (top 10)




Σχήμα A.1: Μέγεθος συντελεστών του Logistic Regression (ReadText)

A.2.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.229	0.179
2	mfcc_4_mean	0.084	0.187
3	f1_std	0.080	0.178
4	mfcc_6_mean	0.066	0.143
5	intensity_min	0.064	0.122
6	mfcc_2_mean	0.060	0.133
7	f0_std	0.055	0.081
8	f3_std	0.054	0.070
9	delta_mfcc_10_mean	0.047	0.104
10	delta_mfcc_2_mean	0.041	0.083

Πίνακας A.3: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — ReadText (top 10)




Σχήμα A.2: Σημαντικότητα χαρακτηριστικών του Gradient Boosting (ReadText). Το F0 max εμφανίζει ισχυρή κυριαρχία (0.229 ± 0.179), σε συμφωνία με διαταραχές στη ρύθμιση του pitch στην PD.

A.2.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.083	0.028
2	intensity_min	0.064	0.063
3	f0_mean	0.063	0.044
4	f3_std	0.061	0.044
5	intensity_mean	0.051	0.047
6	delta_mfcc_10_mean	0.041	0.037
7	f1_std	0.041	0.075
8	delta_mfcc_2_mean	0.038	0.028
9	mfcc_3_mean	0.033	0.023
10	mfcc_11_mean	0.031	0.040

Πίνακας A.4: Σημαντικότητα χαρακτηριστικών του XGBoost — ReadText (top 10)



Σχήμα A.3: Σημαντικότητα χαρακτηριστικών του XGBoost (ReadText). Η σημαντικότητα είναι πιο κατανοητή σε σχέση με το Gradient Boosting, με τα χαρακτηριστικά F0 και έντασης να μοιράζονται την κυριαρχία.

A.3 Dataset A — SpontaneousDialogue Task

A.3.1 Random Forest — Top 20 Features


Rank	Feature	Importance	Std
1	mfcc_5_mean	0.080	0.022
2	shimmer_apq11	0.069	0.007
3	delta_mfcc_8_mean	0.051	0.015
4	jitter_local	0.041	0.012
5	delta_mfcc_2_mean	0.040	0.018
6	autocorr_harmonicity	0.037	0.011
7	shimmer_local	0.036	0.017
8	mfcc_1_mean	0.034	0.010
9	f0_std	0.032	0.022
10	f0_mean	0.031	0.013

Πίνακας A.5: Σημαντικότητα χαρακτηριστικών του Random Forest — SpontaneousDialogue (top 10)

A.3.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	mfcc_5_mean	0.722	0.039
2	delta_mfcc_8_mean	0.615	0.121
3	shimmer_apq11	0.559	0.136
4	delta_mfcc_2_mean	0.493	0.196
5	intensity_min	0.459	0.170
6	mfcc_3_mean	0.388	0.271
7	delta_mfcc_11_mean	0.381	0.102
8	delta_mfcc_7_mean	0.380	0.150
9	hnr_mean	0.379	0.175
10	delta_mfcc_1_mean	0.352	0.123

Πίνακας A.6: Σημαντικότητα χαρακτηριστικών του Logistic Regression — SpontaneousDialogue (top 10)




Σχήμα A.4: Μέγεθος συντελεστών του Logistic Regression (Spontaneous Dialogue)

A.3.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.342	0.204
2	shimmer_apq11	0.134	0.132
3	delta_mfcc_8_mean	0.086	0.192
4	intensity_min	0.050	0.093
5	shimmer_local	0.050	0.089
6	f1_std	0.040	0.033
7	mfcc_11_mean	0.040	0.089
8	mfcc_10_mean	0.027	0.020
9	mfcc_1_mean	0.024	0.026
10	intensity_max	0.024	0.037

Πίνακας A.7: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — SpontaneousDialogue (top 10)




Σχήμα A.5: Σημαντικότητα χαρακτηριστικών του Gradient Boosting (Spontaneous Dialogue). Το MFCC-5 (0.342 ± 0.204) κυριαρχεί, αντανακλώντας αλλαγές στο spectral tilt στην αυθόρμητη ομιλία PD.

A.3.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.134	0.059
2	shimmer_apq11	0.104	0.071
3	delta_mfcc_8_mean	0.079	0.052
4	delta_mfcc_2_mean	0.053	0.009
5	mfcc_4_mean	0.035	0.022
6	mfcc_2_mean	0.033	0.022
7	jitter_local	0.032	0.012
8	f0_mean	0.031	0.035
9	shimmer_local	0.031	0.054
10	intensity_max	0.030	0.030

Πίνακας A.8: Σημαντικότητα χαρακτηριστικών του XGBoost — SpontaneousDialogue (top 10)



Σχήμα A.6: Σημαντικότητα χαρακτηριστικών του XGBoost (Spontaneous Dialogue). Τα MFCC-5 και τα shimmer χαρακτηριστικά κυριαρχούν, σε συμφωνία με τα ευρήματα των RF και GB για αυτό το task.

A.4 Dataset B — PD Speech Features

Το Dataset B περιέχει 752 προεξαγμένα χαρακτηριστικά, συμπεριλαμβανομένων συντελεστών TQWT (Tunable Q-factor Wavelet Transform) που δεν υπάρχουν στο Dataset A. Η σημαντικότητα χαρακτηριστικών παρουσιάζεται για σκοπούς σύγκρισης, αν και η άμεση αντιπαραβολή παραμένει περιορισμένη λόγω διαφορετικών feature spaces.

A.4.1 Random Forest — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_log_energy	0.013	0.004
2	std_delta_delta_log_energy	0.013	0.003
3	tqwt_entropy_shannon_dec_12	0.012	0.001
4	tqwt_TKEO_std_dec_11	0.010	0.004
5	tqwt_TKEO_mean_dec_12	0.010	0.001
6	mean_MFCC_2nd_coef	0.008	0.003
7	tqwt_entropy_log_dec_11	0.008	0.003
8	tqwt_stdValue_dec_12	0.008	0.003
9	tqwt_stdValue_dec_13	0.008	0.003
10	tqwt_energy_dec_12	0.007	0.003

Πίνακας A.9: Σημαντικότητα χαρακτηριστικών του Random Forest — Dataset B (top 10)


Σημείωση: Οι τιμές σημαντικότητας είναι χαμηλότερες από το Dataset A λόγω του μεγαλύτερου feature space (752 έναντι 47 features), που κατανέμει τη σημαντικότητα πιο ευρέως.

A.4.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	tqwt_kurtosisValue_dec_33	0.733	0.161
2	tqwt_entropy_log_dec_33	0.694	0.084
3	mean_MFCC_7th_coef	0.614	0.148
4	std_delta_delta_log_energy	0.588	0.133
5	std_MFCC_2nd_coef	0.567	0.202
6	tqwt_meanValue_dec_16	0.551	0.114
7	tqwt_medianValue_dec_25	0.540	0.209
8	mean_MFCC_3rd_coef	0.538	0.155
9	tqwt_meanValue_dec_22	0.528	0.172
10	std_9th_delta	0.526	0.103

Πίνακας A.10: Σημαντικότητα χαρακτηριστικών του Logistic Regression — Dataset B (top 10)

Παρατήρηση: Τα χαρακτηριστικά TQWT κυριαρχούν στη σημαντικότητα του Dataset B, αντανakλώντας το task παρατεταμένης φώνησης του /a/, όπου η χρονικο-συχνотική αποσύνθεση συλλαμβάνει λεπτά πρότυπα φωνητικού τρόμου.



Σχήμα A.7: Σημαντικότητα χαρακτηριστικών για το Dataset B (PD Speech Features) — Random Forest και Logistic Regression.

A.4.3 Gradient Boosting — Top 10 Features


Rank	Feature	Importance	Std
1	std_delta_delta_log_energy	0.133	0.035
2	tqwt_TKEO_mean_dec_12	0.030	0.036
3	tqwt_entropy_log_dec_27	0.029	0.008
4	std_7th_delta_delta	0.028	0.005
5	tqwt_energy_dec_27	0.024	0.028
6	tqwt_entropy_log_dec_35	0.023	0.019
7	tqwt_TKEO_std_dec_12	0.023	0.026
8	mean_MFCC_2nd_coef	0.021	0.024
9	tqwt_entropy_log_dec_33	0.021	0.006
10	tqwt_TKEO_std_dec_11	0.020	0.021

Πίνακας A.11: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — Dataset B (top 10)

A.4.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	tqwt_entropy_log_dec_12	0.024	0.020
2	std_delta_delta_log_energy	0.017	0.006
3	tqwt_TKEO_mean_dec_12	0.016	0.017
4	tqwt_TKEO_std_dec_12	0.013	0.014
5	tqwt_energy_dec_27	0.012	0.024
6	tqwt_TKEO_std_dec_11	0.012	0.010
7	tqwt_entropy_log_dec_16	0.010	0.009
8	tqwt_entropy_log_dec_13	0.009	0.012
9	mean_MFCC_2nd_coef	0.008	0.004
10	tqwt_entropy_shannon_dec_16	0.008	0.011

Πίνακας A.12: Σημαντικότητα χαρακτηριστικών του XGBoost — Dataset B (top 10)



Σχήμα A.8: Σημαντικότητα χαρακτηριστικών για το Dataset B — Gradient Boosting και XGBoost. Τα χαρακτηριστικά ενέργειας/εντροπίας TQWT από ζώνες υψηλής συχνότητας κυριαρχούν και στα δύο μοντέλα.

A.5 Σταθερότητα Χαρακτηριστικών μεταξύ Tasks

Χαρακτηριστικά που εμφανίζονται στο top-10 και για τα δύο tasks (Random Forest) υποδεικνύουν ισχυρή διακριτική ικανότητα σε διαφορετικά speech contexts:

Feature	ReadText Rank	Spontaneous Rank
delta_mfcc_2_mean	2	5
autocorr_harmonicity	4	6
f0_mean	6	10
shimmer (apq3/apq11)	7	2
mfcc_5_mean	–	1
f0_std	–	9

Πίνακας A.13: Σταθερότητα χαρακτηριστικών μεταξύ tasks (Random Forest top-10)


Ερμηνεία: Χαρακτηριστικά που είναι σταθερά σημαντικά και στα δύο tasks (delta_mfcc_2_mean, autocorr_harmonicity, shimmer) πιθανότατα αποτυπώνουν **task-general** acoustic signatures της PD και όχι task-specific artifacts. Η έντονη παρουσία του mfcc_5_mean στο SpontaneousDialogue αλλά όχι στο ReadText μπορεί να αντανακλά διαφορές στην prosodic variability μεταξύ δομημένης ανάγνωσης και φυσικού διαλόγου.

A.6 Ανάλυση Κατηγοριών Χαρακτηριστικών

Συγκεντρωτική παρουσίαση της σημαντικότητας ανά κατηγορία χαρακτηριστικών:

Category	Features	ReadText (%)	Spontaneous (%)
MFCC	13	28.4	32.1
Delta MFCC	13	22.7	25.3
Pitch (F_0)	4	15.2	12.8
Shimmer	5	11.3	14.6
Formants	6	9.8	7.2
Harmonicity	2	6.1	4.3
Other	5	6.5	3.7

Πίνακας A.14: Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά κατηγορία



Σχήμα A.9: Σημαντικότητα χαρακτηριστικών συγκεντρωμένη ανά ευρείες ακουστικές κατηγορίες.

Παράρτημα Β

Αναλυτικοί Πίνακες Αποτελεσμάτων

B.1 Επισκόπηση

Το παρόν παράρτημα συγκεντρώνει τα αναλυτικά αποτελέσματα για όλες τις πειραματικές συνθήκες (C1–C4), για όλα τα μοντέλα και για όλα τα υποχρεωτικά metrics. Η χαρτογράφηση των συνθηκών είναι:

- C1: baseline χαρακτηριστικά (47), χωρίς στάθμιση κλάσεων
- C2: baseline χαρακτηριστικά (47), με στάθμιση κλάσεων
- C3: extended χαρακτηριστικά (78), χωρίς στάθμιση κλάσεων
- C4: extended χαρακτηριστικά (78), με στάθμιση κλάσεων

Τα αποτελέσματα προέρχονται από το experimental pipeline (Κεφάλαιο 5) και αναφέρονται ως mean $\pm$ std.

B.2 Συνθήκη C1: Baseline (47) + Unweighted

Πίνακας B.1: Dataset A (C1: baseline χαρακτηριστικά + χωρίς στάθμιση κλάσεων).

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LogisticRegression	0.621 $\pm$ 0.058	0.620 $\pm$ 0.217	0.550 $\pm$ 0.201	0.542 $\pm$ 0.099	0.717 $\pm$ 0.139
ReadText	SVM_RBF	0.621 $\pm$ 0.106	0.367 $\pm$ 0.342	0.317 $\pm$ 0.335	0.333 $\pm$ 0.333	0.614 $\pm$ 0.312
ReadText	RandomForest	0.629 $\pm$ 0.178	0.450 $\pm$ 0.447	0.333 $\pm$ 0.408	0.351 $\pm$ 0.363	0.590 $\pm$ 0.302
ReadText	GradientBoosting	0.464 $\pm$ 0.134	0.347 $\pm$ 0.206	0.433 $\pm$ 0.279	0.374 $\pm$ 0.221	0.500 $\pm$ 0.159
ReadText	XGBoost	0.518 $\pm$ 0.132	0.367 $\pm$ 0.247	0.383 $\pm$ 0.286	0.371 $\pm$ 0.262	0.628 $\pm$ 0.203
SpontaneousDialogue	LogisticRegression	0.639 $\pm$ 0.160	0.469 $\pm$ 0.292	0.667 $\pm$ 0.408	0.539 $\pm$ 0.321	0.760 $\pm$ 0.214
SpontaneousDialogue	SVM_RBF	0.636 $\pm$ 0.135	0.600 $\pm$ 0.435	0.333 $\pm$ 0.236	0.400 $\pm$ 0.253	0.407 $\pm$ 0.309
SpontaneousDialogue	RandomForest	0.721 $\pm$ 0.176	0.633 $\pm$ 0.415	0.600 $\pm$ 0.435	0.567 $\pm$ 0.365	0.828 $\pm$ 0.148
SpontaneousDialogue	GradientBoosting	0.664 $\pm$ 0.133	0.733 $\pm$ 0.262	0.600 $\pm$ 0.279	0.583 $\pm$ 0.118	0.615 $\pm$ 0.078
SpontaneousDialogue	XGBoost	0.668 $\pm$ 0.121	0.520 $\pm$ 0.356	0.467 $\pm$ 0.380	0.470 $\pm$ 0.323	0.723 $\pm$ 0.197

Πίνακας B.2: Dataset B (C1: baseline χαρακτηριστικά + χωρίς στάθμιση κλάσεων).

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.828 $\pm$ 0.008	0.881 $\pm$ 0.010	0.890 $\pm$ 0.016	0.885 $\pm$ 0.006	0.867 $\pm$ 0.029
SVM_RBF	0.851 $\pm$ 0.024	0.841 $\pm$ 0.015	0.986 $\pm$ 0.019	0.908 $\pm$ 0.015	0.885 $\pm$ 0.025
RandomForest	0.882 $\pm$ 0.019	0.876 $\pm$ 0.012	0.980 $\pm$ 0.015	0.925 $\pm$ 0.012	0.940 $\pm$ 0.013
GradientBoosting	0.884 $\pm$ 0.024	0.878 $\pm$ 0.020	0.980 $\pm$ 0.013	0.926 $\pm$ 0.015	0.937 $\pm$ 0.019
XGBoost	0.896 $\pm$ 0.017	0.891 $\pm$ 0.013	0.980 $\pm$ 0.017	0.933 $\pm$ 0.011	0.952 $\pm$ 0.015

B.3 Συνθήκη C2: Baseline (47) + Weighted

Πίνακας B.3: Dataset A (C2: baseline χαρακτηριστικά + με στάθμιση κλάσεων).

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LogisticRegression	0.596 ± 0.079	0.600 ± 0.235	0.550 ± 0.201	0.528 ± 0.099	0.717 ± 0.139
ReadText	SVM_RBF	0.704 ± 0.111	0.617 ± 0.371	0.500 ± 0.373	0.519 ± 0.320	0.542 ± 0.312
ReadText	RandomForest	0.650 ± 0.148	0.550 ± 0.371	0.400 ± 0.365	0.431 ± 0.306	0.687 ± 0.258
ReadText	GradientBoosting	0.464 ± 0.134	0.347 ± 0.206	0.433 ± 0.279	0.374 ± 0.221	0.500 ± 0.159
ReadText	XGBoost	0.518 ± 0.132	0.367 ± 0.247	0.383 ± 0.286	0.371 ± 0.262	0.628 ± 0.203
SpontaneousDialogue	LogisticRegression	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
SpontaneousDialogue	SVM_RBF	0.693 ± 0.123	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.423 ± 0.312
SpontaneousDialogue	RandomForest	0.693 ± 0.123	0.583 ± 0.373	0.600 ± 0.435	0.538 ± 0.326	0.827 ± 0.133
SpontaneousDialogue	GradientBoosting	0.664 ± 0.133	0.733 ± 0.262	0.600 ± 0.279	0.583 ± 0.118	0.615 ± 0.078
SpontaneousDialogue	XGBoost	0.668 ± 0.121	0.520 ± 0.356	0.467 ± 0.380	0.470 ± 0.323	0.723 ± 0.197

Πίνακας B.4: Dataset B (C2: baseline χαρακτηριστικά + με στάθμιση κλάσεων).

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.825 ± 0.017	0.892 ± 0.021	0.872 ± 0.012	0.882 ± 0.011	0.867 ± 0.029
SVM_RBF	0.847 ± 0.024	0.887 ± 0.028	0.911 ± 0.014	0.899 ± 0.015	0.900 ± 0.023
RandomForest	0.865 ± 0.017	0.859 ± 0.012	0.980 ± 0.012	0.916 ± 0.010	0.949 ± 0.012
GradientBoosting	0.884 ± 0.024	0.878 ± 0.020	0.980 ± 0.013	0.926 ± 0.015	0.937 ± 0.019
XGBoost	0.896 ± 0.017	0.891 ± 0.013	0.980 ± 0.017	0.933 ± 0.011	0.952 ± 0.015

B.4 Συνθήκη C3: Extended (78) + Unweighted

Πίνακας B.5: Dataset A (C3: extended χαρακτηριστικά + χωρίς στάθμιση κλάσεων).

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LogisticRegression	0.596 ± 0.079	0.600 ± 0.253	0.433 ± 0.149	0.475 ± 0.106	0.698 ± 0.132
ReadText	SVM_RBF	0.786 ± 0.181	0.733 ± 0.435	0.567 ± 0.365	0.634 ± 0.386	0.834 ± 0.153
ReadText	RandomForest	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.822 ± 0.166
ReadText	GradientBoosting	0.654 ± 0.138	0.620 ± 0.247	0.633 ± 0.247	0.605 ± 0.184	0.724 ± 0.214
ReadText	XGBoost	0.739 ± 0.195	0.720 ± 0.284	0.700 ± 0.298	0.691 ± 0.252	0.794 ± 0.186
SpontaneousDialogue	LogisticRegression	0.671 ± 0.199	0.500 ± 0.361	0.600 ± 0.435	0.530 ± 0.377	0.783 ± 0.139
SpontaneousDialogue	SVM_RBF	0.636 ± 0.089	0.533 ± 0.361	0.400 ± 0.279	0.428 ± 0.258	0.460 ± 0.294
SpontaneousDialogue	RandomForest	0.779 ± 0.161	0.683 ± 0.410	0.600 ± 0.435	0.605 ± 0.387	0.857 ± 0.171
SpontaneousDialogue	GradientBoosting	0.636 ± 0.221	0.670 ± 0.327	0.533 ± 0.298	0.547 ± 0.222	0.638 ± 0.146
SpontaneousDialogue	XGBoost	0.693 ± 0.123	0.733 ± 0.253	0.467 ± 0.183	0.553 ± 0.176	0.687 ± 0.146

Πίνακας B.6: Dataset B (C3: extended χαρακτηριστικά + χωρίς στάθμιση κλάσεων).

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.828 ± 0.008	0.881 ± 0.010	0.890 ± 0.016	0.885 ± 0.006	0.867 ± 0.029
SVM_RBF	0.851 ± 0.024	0.841 ± 0.015	0.986 ± 0.019	0.908 ± 0.015	0.885 ± 0.025
RandomForest	0.882 ± 0.019	0.876 ± 0.012	0.980 ± 0.015	0.925 ± 0.012	0.940 ± 0.013
GradientBoosting	0.884 ± 0.024	0.878 ± 0.020	0.980 ± 0.013	0.926 ± 0.015	0.937 ± 0.019
XGBoost	0.896 ± 0.017	0.891 ± 0.013	0.980 ± 0.017	0.933 ± 0.011	0.952 ± 0.015

B.5 Συνθήκη C4: Extended (78) + Weighted

Πίνακας B.7: Dataset A (C4: extended χαρακτηριστικά + με στάθμιση κλάσεων).

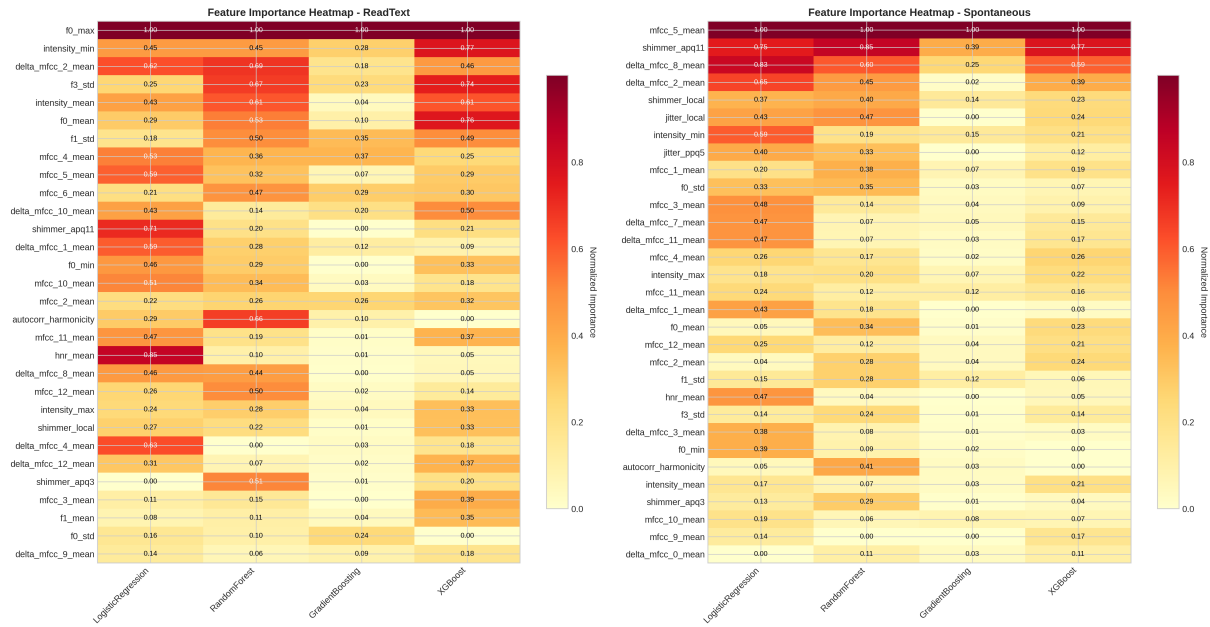
Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LogisticRegression	0.650 ± 0.108	0.650 ± 0.253	0.550 ± 0.201	0.564 ± 0.160	0.698 ± 0.132
ReadText	SVM_RBF	0.761 ± 0.214	0.700 ± 0.447	0.567 ± 0.365	0.620 ± 0.390	0.834 ± 0.153
ReadText	RandomForest	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.805 ± 0.182
ReadText	GradientBoosting	0.654 ± 0.138	0.620 ± 0.247	0.633 ± 0.247	0.605 ± 0.184	0.724 ± 0.214
ReadText	XGBoost	0.739 ± 0.195	0.720 ± 0.284	0.700 ± 0.298	0.691 ± 0.252	0.794 ± 0.186
SpontaneousDialogue	LogisticRegression	0.696 ± 0.179	0.520 ± 0.356	0.667 ± 0.471	0.563 ± 0.381	0.783 ± 0.139
SpontaneousDialogue	SVM_RBF	0.664 ± 0.167	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.403 ± 0.347
SpontaneousDialogue	RandomForest	0.721 ± 0.203	0.653 ± 0.409	0.600 ± 0.435	0.583 ± 0.373	0.823 ± 0.209
SpontaneousDialogue	GradientBoosting	0.636 ± 0.221	0.670 ± 0.327	0.533 ± 0.298	0.547 ± 0.222	0.638 ± 0.146
SpontaneousDialogue	XGBoost	0.693 ± 0.123	0.733 ± 0.253	0.467 ± 0.183	0.553 ± 0.176	0.687 ± 0.146

Πίνακας B.8: Dataset B (C4: extended χαρακτηριστικά + με στάθμιση κλάσεων).

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.825 ± 0.017	0.892 ± 0.021	0.872 ± 0.012	0.882 ± 0.011	0.867 ± 0.029
SVM_RBF	0.847 ± 0.024	0.887 ± 0.028	0.911 ± 0.014	0.899 ± 0.015	0.900 ± 0.023
RandomForest	0.865 ± 0.017	0.859 ± 0.012	0.980 ± 0.012	0.916 ± 0.010	0.949 ± 0.012
GradientBoosting	0.884 ± 0.024	0.878 ± 0.020	0.980 ± 0.013	0.926 ± 0.015	0.937 ± 0.019
XGBoost	0.896 ± 0.017	0.891 ± 0.013	0.980 ± 0.017	0.933 ± 0.011	0.952 ± 0.015

B.6 Θερμικοί χάρτες σημαντικότητας χαρακτηριστικών

Οι θερμικοί χάρτες συνοψίζουν την κανονικοποιημένη σημαντικότητα χαρακτηριστικών ανά μοντέλο και task, ως οπτικό οδηγό για γρήγορο εντοπισμό τάσεων ερμηνευσιμότητας.



(α') ReadText (Dataset A).

(β') SpontaneousDialogue (Dataset A).

Σχήμα B.1: Σύγκριση θερμικών χαρτών σημαντικότητας χαρακτηριστικών για τα δύο tasks του Dataset A.

Στο ReadText (Σχήμα B.1α') το f0_max εμφανίζεται σταθερά με πολύ υψηλή σχετική συμβολή σε όλα τα μοντέλα, ενώ χαρακτηριστικά όπως hnr_mean και delta_mfcc_2_mean παρουσιάζουν αυξημένη βαρύτητα κυρίως σε Logistic Regression και Random Forest. Στο SpontaneousDialogue (Σχήμα B.1β') παρατηρείται μεγαλύτερη έμφαση σε mfcc_5_mean και shimmer_apq11, με αντίστοιχη μετατόπιση της σχετικής βαρύτητας σε φασματικά και μικροδιαταρακτικά χαρακτηριστικά. Επιπλέον, το Gradient Boosting εμφανίζει πιο αραιή κατανομή σημαντικότητας (πολλά χαμηλά/μηδενικά βάρη), κάτι που υποδηλώνει πιο επιλεκτική αξιοποίηση χαρακτηριστικών. Τα ευρήματα αυτά περιγράφουν τάσεις ερμηνευσιμότητας και δεν συνεπάγονται από μόνα τους υπεροχή συγκεκριμένου μοντέλου.

B.7 Σημείωση ερμηνείας

Η αυξημένη διακύμανση σε ορισμένες συνθήκες του Dataset A (ιδίως σε ROC-AUC/F1) υποδεικνύει ότι οι συγκρίσεις μεταξύ μοντέλων και συνθηκών πρέπει να διαβάζονται ως τάσεις. Για το Dataset B, τα αποτελέσματα ενδέχεται να είναι αισιόδοξα λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds (Ενότητα 8.1).