



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Approved by the examination committee on [26 Φεβρουαρίου 2026].

.....		
Γεώργιος Ματσόπουλος	Ουρανία Πετροπούλου	[Examiner 2 Name]
Καθηγητής ΗΜΜΥ Ε.Μ.Π.	Επίκουρη Καθηγήτρια	[Examiner 2 Title]
	ΗΜΜΥ Ε.Μ.Π.	

Αθήνα, Φεβρουάριος 2026

Μάριος Χρήστος Συρμακέζης

Διπλωματούχος Ηλεκτρολόγος Μηχανικός και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright © Μάριος Χρήστος Συρμακέζης, 2026.

All rights reserved.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η νόσος του Πάρκινσον (PD) είναι μια νευροεκφυλιστική διαταραχή που, πέρα από τα κινητικά συμπτώματα, επηρεάζει συχνά και την ομιλία. Η εργασία αυτή εξετάζει αν μπορούμε να εντοπίσουμε τη νόσο μέσω της φωνής, χρησιμοποιώντας κλασικές μεθόδους μηχανικής μάθησης.

Για τον σκοπό αυτό χρησιμοποιήθηκαν δύο διαφορετικά σύνολα δεδομένων ομιλίας, με την ίδια διαδικασία ανάλυσης και αξιολόγησης και στα δύο.

Το πρώτο σύνολο δεδομένων, Mobile Device Voice Recordings at King's College London, περιλάμβανε κατηγοριοποιημένα αρχεία ήχου (WAV) που είχαν καταγραφεί με ειδικό εξοπλισμό. Οι ηχογραφήσεις ήταν ακατέργαστες, γι' αυτό προχωρήσαμε στην εξαγωγή ακουστικών χαρακτηριστικών για να μετατρέψουμε τα δεδομένα σε μια αριθμητική μορφή που είναι κατάλληλη για ανάλυση.

Το δεύτερο σύνολο δεδομένων, με τίτλο PD speech signal features από το Kaggle (UCI), περιλάμβανε ακουστικά χαρακτηριστικά που είχαν ήδη εξαχθεί σε μορφή csv. Σε αυτή την περίπτωση, δεν χρειάστηκε να γίνει επεξεργασία ήχου αφού τα αριθμητικά χαρακτηριστικά ήταν ήδη διαθέσιμα. Και στα δύο σύνολα δεδομένων, ο σκοπός ήταν να διαπιστωθεί αν τα μοντέλα μπορούν να αναγνωρίσουν άτομα με Πάρκινσον μόνο από τη φωνή τους.

Αξιολογήθηκαν πέντε αλγόριθμοι: Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting και XGBoost. Επιπλέον, εξετάστηκε αν η αύξηση του αριθμού των χαρακτηριστικών βελτιώνει την απόδοση, καθώς και αν η χρήση βαρών κλάσης (class weighting) βοηθά στην εξισορρόπηση των ομάδων PD και HC.

Χρησιμοποιήθηκε επίσης διασταυρωμένη επικύρωση (cross-validation), ώστε να μην υπάρχει διαρροή δεδομένων.

Τα αποτελέσματα έδειξαν ότι ο Random Forest ήταν ο πιο αποτελεσματικός. Η αύξηση των χαρακτηριστικών βελτίωσε σημαντικά την απόδοση των περισσότερων μοντέλων. Η χρήση βαρών είχε μικρή θετική επίδραση κυρίως στον Random Forest και μικρή ή

αρνητική στους υπόλοιπους.

Συνολικά, η εργασία δείχνει ότι η ανάλυση φωνής σε συνδυασμό με μηχανική μάθηση μπορεί να βοηθήσει στην αναγνώριση της νόσου του Πάρκινσον. Ωστόσο, τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή, λόγω ορισμένων περιορισμών, όπως πιθανές πολλαπλές ηχογραφήσεις του ίδιου ασθενούς και η διαφορά μεγέθους μεταξύ των δύο datasets.

Παρά τους περιορισμούς, τα ευρήματα δείχνουν ότι η σωστή επεξεργασία δεδομένων και η κατάλληλη χρήση αλγορίθμων μπορούν να οδηγήσουν μελλοντικά σε πιθανή αναγνώριση της νόσου μέσω της φωνής, ακόμα και με απλά καθημερινά μικρόφωνα. Αυτό είναι σημαντικό, γιατί η έγκαιρη ανίχνευση θα μπορούσε να συμβάλει σε νωρίτερη θεραπεία και καλύτερη ποιότητα ζωής για τους ασθενείς.

Λέξεις Κλειδιά: Νόσος του Πάρκινσον, Δυσαρθρία, Φωνητικοί Βιοδείκτες, Ακουστικά Χαρακτηριστικά, Μηχανική Μάθηση, Εξαγωγή Χαρακτηριστικών, Διασταυρούμενη Επικύρωση, Μη Ισορροπημένα Δεδομένα, Αναπαραγωγιμότητα, Ταξινόμηση Ομιλίας, Υπολογιστική Νοημοσύνη στην Υγεία

Abstract

Parkinson's disease (PD) is a progressive neurological disorder characterized by motor symptoms which are typically accompanied by speech difficulties.

In this paper we assess if Parkinson's disease can be diagnosed through the voice based on classical machine learning approaches.

We worked with two different datasets, each analyzed using an identical methodology, i.e., analysis and validation procedure.

The first dataset, Mobile Device Voice Recordings at King's College London, contained categorized audio files (WAV) recorded with advanced recording equipment in a controlled environment.

These recordings were unprocessed, therefore we had to process the audio to extract the acoustic features to transform the data into a numeric format that would allow us to perform the analysis.

The second dataset, PD speech signal features from Kaggle (UCI), contained pre-extracted acoustic features in csv format.

Therefore, we did not need to process the audio since the pre-processed features were ready to be analyzed.

Both datasets were processed to see if the models could distinguish between individuals with PD and healthy controls (HC) only through their voice.

We compared five machine learning algorithms, i.e., Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting, and XGBoost.

Furthermore, we investigated whether increasing the number of features in the training set enhances the model performance, and whether the application of class weighting enhances the model performance particularly for the PD group.

To avoid data leakage, cross-validation was performed.

The results indicate that Random Forest algorithm outperformed all other tested algorithms.

An increase of the number of features in the training set positively affected the majority of the tested models.

Class weighting had a limited positive impact especially on Random Forest, while the other algorithms either did not benefit from class weighting or were even negatively affected.

In general, the study demonstrates that voice-based analysis combined with machine learning may support the diagnosis of Parkinson's disease.

Nevertheless, the results have to be viewed critically due to some limitations, e.g., potential multiple recordings of the same patient and the significant differences in terms of sample sizes between the two datasets.

Regardless of these limitations, the study shows that adequate processing of the data, along with the appropriate application of machine learning algorithms can result in a potential disease identification through voice, using regular microphones, available in everyday devices like smartphones.

Early detection may lead to the initiation of therapy at an earlier time point and improve the quality of life of patients.

Keywords: Parkinson's Disease; Dysarthria; Voice Biomarkers; Acoustic Features; Machine Learning; Feature Extraction; Cross-Validation; Imbalanced Data; Reproducibility; Speech Classification; Computational Health Intelligence

Πίνακας Περιεχομένων

Περίληψη	7
Abstract	10
Κατάλογος Σχημάτων	22
Κατάλογος Πινάκων	25
1 Εισαγωγή	27
1.1 Ιστορικό και κίνητρα	27
1.2 Διατύπωση του προβλήματος	28
1.3 Ερευνητικοί στόχοι	29
1.4 Συνεισφορές	30
1.5 Οργάνωση της εργασίας	30
1.6 Όρια πεδίου εφαρμογής	31
2 Βιβλιογραφική ανασκόπηση	33
2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας	33
2.2 Ανίχνευση έναντι παρακολούθησης	34
2.3 Ταξινόμηση ακουστικών χαρακτηριστικών	35
2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας	36
2.4 Σύνολα δεδομένων που χρησιμοποιούνται στην έρευνα για τη φωνή των ασθενών με Πάρκινσον	36
2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου	37
2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών	38
2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων	39
2.4.4 Ετερογένεια επικύρωσης	39
2.4.5 Ο ρόλος των εργασιών ομιλίας	39
2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD	40

2.5.1	Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις	41
2.6	Μεθοδολογικά ζητήματα στη βιβλιογραφία	41
2.6.1	Διαρροή δεδομένων	41
2.6.2	Ανισορροπία κλάσεων	42
2.6.3	Αναπαραγωγιμότητα	42
2.6.4	Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων	42
2.6.5	Ερμηνευσιμότητα	43
2.7	Έλλειμμα στην έρευνα	43
2.8	Περίληψη	44
3	Περιγραφή δεδομένων	45
3.1	Σύνολο δεδομένων A: MDVR-KCL	45
3.1.1	Πηγή και συλλογή	45
3.1.2	Προδιαγραφές ήχου	46
3.1.3	Εργασίες ομιλίας	46
3.1.4	Κατανομή τάξεων	46
3.1.5	Γνωστές ανωμαλίες	47
3.2	Σύνολο δεδομένων B: Χαρακτηριστικά ομιλίας PD	47
3.2.1	Πηγή	47
3.2.2	Πλαίσιο συλλογής	47
3.2.3	Μορφή δεδομένων	47
3.2.4	Κατανομή κλάσεων	48
3.2.5	Κατηγορίες χαρακτηριστικών	48
3.2.6	Μεθοδολογικές προειδοποιήσεις	48
3.3	Σύγκριση μεταξύ συνόλων δεδομένων	50
3.3.1	Βασικές διαφορές	50
4	Μεθοδολογία	51
4.1	Διαδικασία εξαγωγής χαρακτηριστικών	51
4.1.1	Αρχιτεκτονική διαδικασίας	51
4.1.2	Προεπεξεργασία ήχου	51
4.1.3	Προσωδιακά χαρακτηριστικά (21 χαρακτηριστικά)	52
4.1.4	Φασματικά χαρακτηριστικά	54
4.1.5	Συνολικός αριθμός χαρακτηριστικών	56
4.2	Σύγκριση συνόλου χαρακτηριστικών	57
4.2.1	Λόγοι για τα εκτεταμένα χαρακτηριστικά	57
4.2.2	Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών	57
4.3	Μοντέλα μηχανικής μάθησης	58

4.3.1	Προδιαγραφές μοντέλου	58
4.3.2	Στάθμιση βαρύτητας κλάσης	60
4.4	Αρχιτεκτονική ML Pipeline	61
4.4.1	Δομή Pipeline	61
4.4.2	Τυποποίηση χαρακτηριστικών	61
4.5	Πλαίσιο αξιολόγησης	61
4.5.1	Στρατηγική Cross-Validation	61
4.5.2	Μετρήσεις αξιολόγησης	62
5	Σχεδιασμός πειράματος	64
5.1	Ερευνητικά ερωτήματα	64
5.2	Πειραματικός πίνακας	64
5.2.1	$2 \times 2 \times 5$ Παραγοντικός σχεδιασμός	64
5.2.2	Συνολικές πειραματικές εκτελέσεις	65
5.3	Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα	65
6	Αποτελέσματα	66
6.1	Σύνοψη των καλύτερων αποτελεσμάτων	66
6.1.1	Σύνολο δεδομένων A (MDVR-KCL) — Καλύτερη απόδοση	66
6.1.2	Σύνολο δεδομένων B (Σύγκριση αναφοράς)	66
6.2	Συνθήκη 1: Βασικά χαρακτηριστικά + χωρίς στάθμιση	68
6.2.1	Task: ReadText	68
6.2.2	Task: Spontaneous dialogue	68
6.3	Συνθήκη 2: Εκτεταμένα χαρακτηριστικά + Χωρίς στάθμιση	68
6.3.1	Task: ReadText	69
6.3.2	Task: Spontaneous dialogue	70
6.4	Ανάλυση αφαίρεσης χαρακτηριστικών	71
6.4.1	Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (Read-Text)	71
6.4.2	Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (Spontaneous)	71
6.5	Ανάλυση στάθμισης κλάσεων	71
6.5.1	Task ReadText — Βασικά χαρακτηριστικά	72
6.5.2	Εκτεταμένα χαρακτηριστικά — Όλες οι εργασίες	72
6.6	Συμβιβασμοί ακρίβειας-ανάκλησης	72
6.6.1	Random Forest (εκτεταμένα χαρακτηριστικά)	72
6.7	Ανάλυση πίνακα σύγχυσης	73
6.7.1	Σύνολο δεδομένων A — ReadText	73

6.7.2	Σύνολο δεδομένων A — Spontaneous dialogue	74
6.7.3	Σύνολο δεδομένων B	74
7	Συζήτηση	75
7.1	Ερμηνεία βασικών ευρημάτων	75
7.1.1	Επίδραση της επέκτασης χαρακτηριστικών	75
7.1.2	Επιδράσεις στάθμισης κλάσης	76
7.1.3	Ιεραρχία απόδοσης μοντέλου	77
7.1.4	Υψηλή διακύμανση μεταξύ πτυχών	77
7.2	Σύγκριση με τη βιβλιογραφία	78
7.2.1	Πλαίσιο απόδοσης	78
7.2.2	Μεθοδολογική σύγκριση	79
7.3	Ανάλυση σημασίας χαρακτηριστικών	79
7.3.1	Χαρακτηριστικά με τη μεγαλύτερη διακριτική ικανότητα (σύνολο δεδομένων A)	79
7.3.2	Πολυπλοκότητα χαρακτηριστικών του συνόλου δεδομένων B	80
7.4	Μοτίβα απόδοσης που εξαρτώνται από την εργασία	80
7.4.1	ReadText έναντι αυθόρμητου διαλόγου	80
8	Περιορισμοί και απειλές για την εγκυρότητα	82
8.1	Περιορισμοί μεγέθους δείγματος	82
8.1.1	Σύνολο δεδομένων A: Μικρός αριθμός συμμετεχόντων	82
8.2	Περιορισμοί αναγνωριστικών υποκειμένων	83
8.2.1	Σύνολο δεδομένων B: Δεν υπάρχουν ταυτότητες υποκειμένων	83
8.2.2	Περιορισμοί σύγκρισης	83
8.3	Περιορισμοί εξαγωγής χαρακτηριστικών	83
8.3.1	Προκαθορισμένο σύνολο χαρακτηριστικών	83
8.3.2	Υποθέσεις για την ποιότητα ήχου	84
8.4	Περιορισμοί μοντέλου	84
8.4.1	Χωρίς ρύθμιση υπερπαραμέτρων	84
8.5	Μεθοδολογικοί περιορισμοί	85
8.5.1	Χωρίς εξωτερική επικύρωση	85
8.5.2	Χειρισμός ανισορροπίας κλάσεων	85
8.6	Απειλές για την εγκυρότητα	86
8.6.1	Εσωτερική εγκυρότητα	86
8.6.2	Εξωτερική εγκυρότητα	86
9	Συμπέρασμα	87

9.1	Περίληψη της εργασίας	87
9.1.1	Συνεισφορές	87
9.2	Βασικά ευρήματα	88
9.3	Απαντήσεις στα ερευνητικά ερωτήματα	88
9.3.1	RQ1: Πόσο καλά αποδίδουν τα κλασικά μοντέλα;	88
9.3.2	RQ2: Η επέκταση του συνόλου χαρακτηριστικών βελτιώνει την απόδοση της ταξινόμησης;	88
9.3.3	RQ3: Βελτιώνει η στάθμιση των κλάσεων την απόδοση σε μη ισορροπημένα σύνολα δεδομένων;	89
9.3.4	RQ4: Πώς συγκρίνονται τα αποτελέσματα μεταξύ της ομαδοποιημένης και της τυπικής CV;	89
9.3.5	RQ5: Οι εργασίες ομιλίας αποδίδουν διαφορετική απόδοση ταξινόμησης;	89
9.4	Επιπτώσεις	90
9.4.1	Για ερευνητές	90
9.4.2	Για επαγγελματίες	90
9.4.3	Για δημιουργούς datasets	90
9.5	Μελλοντικές κατευθύνσεις	90
9.6	Τελικό συμπέρασμα	91
A	Πίνακες Σημαντικότητας Χαρακτηριστικών	92
A.1	Επισκόπηση	92
A.2	Dataset A — ReadText Task	92
A.2.1	Random Forest — Top 20 Features	92
A.2.2	Logistic Regression — Top 20 Features	93
A.2.3	Gradient Boosting — Top 10 Features	94
A.2.4	XGBoost — Top 10 Features	95
A.3	Dataset A — SpontaneousDialogue Task	96
A.3.1	Random Forest — Top 20 Features	96
A.3.2	Logistic Regression — Top 10 Features	96
A.3.3	Gradient Boosting — Top 10 Features	97
A.3.4	XGBoost — Top 10 Features	98
A.4	Dataset B — PD Speech Features	99
A.4.1	Random Forest — Top 10 Features	100
A.4.2	Logistic Regression — Top 10 Features	100
A.4.3	Gradient Boosting — Top 10 Features	101
A.4.4	XGBoost — Top 10 Features	102
A.5	Σταθερότητα Χαρακτηριστικών μεταξύ Tasks	102
A.6	Ανάλυση Κατηγοριών Χαρακτηριστικών	103

B	Αναλυτικοί Πίνακες Αποτελεσμάτων	105
B.1	Επισκόπηση	105
B.2	Συνθήκη 1: Baseline Features (47) + Unweighted	105
B.2.1	Dataset A: MDVR-KCL Σύνοψη	105
B.2.2	Dataset B: PD Speech Features Σύνοψη	106
B.3	Συνθήκη 2: Extended Features (78) + Unweighted	106
B.3.1	Dataset A: MDVR-KCL Σύνοψη	106
B.3.2	Βελτίωση έναντι Baseline (Random Forest, Dataset A)	106
B.4	Συνθήκη 3: Baseline Features (47) + Weighted	107
B.4.1	Dataset A: MDVR-KCL Σύνοψη	107
B.4.2	Επίδραση του Weighting (vs Condition 1, Random Forest)	107
B.5	Συνθήκη 4: Extended Features (78) + Weighted	108
B.5.1	Dataset A: MDVR-KCL Σύνοψη	108
B.5.2	Επίδραση του Weighting (vs Condition 2, Random Forest)	108
B.6	Matrix Σύγκρισης μεταξύ Conditions	108
B.6.1	Random Forest ROC-AUC ανά Task	108
B.6.2	Random Forest Accuracy ανά Task	109
B.6.3	Κύριες Παρατηρήσεις	109
B.7	Σημειώσεις για τη Statistical Significance	109
B.8	Καμπύλες ROC	109
C	Research Demonstration Application	113
C.1	Σκοπός και Εύρος	113
C.2	Αρχιτεκτονική Συστήματος	114
C.3	Ροή Αλληλεπίδρασης Χρήστη	115
C.3.1	Audio Upload Workflow	115
C.3.2	Direct Audio Recording	116
C.3.3	Processing Steps	117
C.4	Ερμηνεία Output και Περιορισμοί	117
C.4.1	Displayed Information	117
C.4.2	Κρίσιμοι Περιορισμοί (Τι ΔΕΝ Σημαίνει το Output)	118
C.5	Reproducibility και Συνέπεια	119
C.6	Σύνοψη	120

Κατάλογος Σχημάτων

4.1	Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.	51
6.1	Σημαντικότητα χαρακτηριστικών Random Forest (σύνολο δεδομένων B). Τα κορυφαία χαρακτηριστικά κυριαρχούνται από προηγμένες μετρήσεις επεξεργασίας σήματος που συχνά δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.	67
6.2	Σημασία χαρακτηριστικών Random Forest για το Task ReadText (εκτεταμένα χαρακτηριστικά). Οι στατιστικές της θεμελιώδους συχνότητας (F_0) φαίνονται ιδιαίτερα προγνωστικές.	69
6.3	Σημασία χαρακτηριστικών Random Forest για το Task Spontaneous dialogue (εκτεταμένα χαρακτηριστικά). Τα χαρακτηριστικά MFCC παρουσιάζουν αυξημένη σημασία σε σύγκριση με το ReadText.	70
6.4	Συγκεντρωτικοί πίνακες σύγχυσης για το Task ReadText (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 37$ υποκείμενα). Κάθε κελί αναφέρει τον συνολικό αριθμό εκτός fold και το ποσοστό του σε όλες τις προβλέψεις. Αυτά τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή, δεδομένου του μικρού μεγέθους του δείγματος.	73
6.5	Συγκεντρωτικοί πίνακες σύγχυσης για το Task Spontaneous dialogue (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 36$ υποκείμενα). Αυτό το Task απέδωσε το υψηλότερο συνολικό ROC-AUC στη μελέτη ($0,857 \pm 0,171$, Random Forest).	74
6.6	Συγκεντρωτικοί πίνακες σύγχυσης για το σύνολο δεδομένων B (στρωματοποιημένη 5-Fold CV, $n = 756$ εγγραφές). Το σημαντικά μεγαλύτερο μέγεθος του δείγματος αποδίδει καλά διαχωρισμένα μοτίβα σύγχυσης με χαμηλή διακύμανση. Τα αποτελέσματα μπορεί να είναι αισιόδοξα λόγω της άγνωστης επικάλυψης των θεμάτων μεταξύ των πτυχών.	74
A.1	Μέγεθος συντελεστών του Logistic Regression (ReadText)	93

A.2	Σημαντικότητα χαρακτηριστικών του Gradient Boosting (ReadText). Το F0 max εμφανίζει ισχυρή κυριαρχία (0.229 ± 0.179), σε συμφωνία με διαταραχές στη ρύθμιση του pitch στην PD.	94
A.3	Σημαντικότητα χαρακτηριστικών του XGBoost (ReadText). Η σημαντικότητα είναι πιο κατανεμημένη σε σχέση με το Gradient Boosting, με τα χαρακτηριστικά F0 και έντασης να μοιράζονται την κυριαρχία.	95
A.4	Μέγεθος συντελεστών του Logistic Regression (Spontaneous Dialogue) . . .	97
A.5	Σημαντικότητα χαρακτηριστικών του Gradient Boosting (Spontaneous Dialogue). Το MFCC-5 (0.342 ± 0.204) κυριαρχεί, αντανακλώντας αλλαγές στο spectral tilt στην αυθόρμητη ομιλία PD.	98
A.6	Σημαντικότητα χαρακτηριστικών του XGBoost (Spontaneous Dialogue). Τα MFCC-5 και τα shimmer χαρακτηριστικά κυριαρχούν, σε συμφωνία με τα ευρήματα των RF και GB για αυτό το task.	99
A.7	Σημαντικότητα χαρακτηριστικών για το Dataset B (PD Speech Features) — Random Forest και Logistic Regression.	101
A.8	Σημαντικότητα χαρακτηριστικών για το Dataset B — Gradient Boosting και XGBoost. Τα χαρακτηριστικά ενέργειας/εντροπίας TQWT από ζώνες υψηλής συχνότητας κυριαρχούν και στα δύο μοντέλα.	102
A.9	Σημαντικότητα χαρακτηριστικών συγκεντρωμένη ανά ευρείες ακουστικές κατηγορίες.	104
B.1	ROC curves για όλους τους πέντε classifiers στο ReadText task (Dataset A, extended features). Τα shaded bands υποδεικνύουν ± 1 standard deviation στα πέντε cross-validation folds.	110
B.2	ROC curves για όλους τους πέντε classifiers στο SpontaneousDialogue task (Dataset A, extended features).	111
B.3	ROC curves για όλους τους πέντε classifiers στο Dataset B (PD Speech Features). Σημειώνεται ότι subject-level deduplication δεν είναι εφικτό για αυτό το dataset: τα αποτελέσματα ενδέχεται να είναι optimistic λόγω πιθανής επικάλυψης subjects μεταξύ folds.	112
C.1	Upload interface για audio file analysis. Οι χρήστες επιλέγουν recording του ReadText task σε common formats (WAV, MP3, WebM). Το interface εμφανίζει το τρέχον model configuration (RandomForest, baseline features, 37 training samples).	115

- C.2 In-browser audio recording interface. Οι χρήστες διαβάζουν δυνατά το εμφανιζόμενο ReadText prompt και καταγράφουν απευθείας μέσω του device microphone. Το recorded audio επεξεργάζεται με το ίδιο normalization και feature extraction pipeline που χρησιμοποιείται και για τα uploaded files. 116
- C.3 Παράδειγμα output από το research demonstration interface. Το prediction (“PD” με 81% confidence) εμφανίζεται εμφανώς με ρητό disclaimer ότι δεν αποτελεί medical diagnosis. Το interface δείχνει extracted acoustic features, analysis metadata (file name, model, task, feature count) και top global feature importances για interpretability. 118

Κατάλογος Πινάκων

1.1	Περίληψη των κεφαλαίων της εργασίας	31
2.1	Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD	35
3.1	Πλαίσιο συλλογής δεδομένων MDVR-KCL	45
3.2	Προδιαγραφές ήχου για το σύνολο δεδομένων A	46
3.3	Εργασίες ομιλίας στο σύνολο δεδομένων MDVR-KCL	46
3.4	Πλαίσιο συλλογής για το σύνολο δεδομένων B	47
3.5	Κατανομή κλάσεων στο σύνολο δεδομένων B	48
3.6	Κατηγορίες χαρακτηριστικών στο σύνολο δεδομένων B (752 συνολικά)	48
3.7	Λεπτομερής σύγκριση μεταξύ συνόλων δεδομένων	50
4.1	Ανάλυση προσωδιακών χαρακτηριστικών	54
4.2	Βασικά φασματικά χαρακτηριστικά	55
4.3	Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)	56
4.4	Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση	56
4.5	Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.	58
4.6	Στρατηγικές διασταυρούμενης επικύρωσης	62
4.7	Μετρήσεις αξιολόγησης	63
5.1	Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.	65
5.2	Συνολικός αριθμός πειραμάτων	65
6.1	Καλύτερη απόδοση στο σύνολο δεδομένων A	66
6.2	Απόδοση του συνόλου δεδομένων B χρησιμοποιώντας τη βασική (μη σταθμισμένη) διαμόρφωση. Σημειώστε τη σημαντικά χαμηλότερη διακύμανση σε σύγκριση με το σύνολο δεδομένων A.	67

6.3	Συνθήκη 1 — Αποτελέσματα ReadText	68
6.4	Συνθήκη 1 — Αποτελέσματα Spontaneous dialogue	68
6.5	Συνθήκη 2 — Αποτελέσματα ReadText	69
6.6	Συνθήκη 2 — Αποτελέσματα Spontaneous dialogue	70
6.7	Αφαίρεση χαρακτηριστικών — ReadText	71
6.8	Αφαίρεση χαρακτηριστικών — Spontaneous dialogue	71
6.9	Επίδραση της στάθμισης κλάσης στο ReadText (βασικά χαρακτηριστικά). To Random Forest έδειξε μέτρια βελτίωση.	72
6.10	Προφίλ ακρίβειας-ανάκλησης Random Forest. Η διαμόρφωση ReadText ευνοεί την ακρίβεια (λιγότερα ψευδώς θετικά αποτελέσματα).	72
7.1	Επίδραση της επέκτασης χαρακτηριστικών ανά εργασία. Το ReadText παρουσίασε μεγαλύτερες βελτιώσεις, κάτι που δείχνει ότι τα βασικά χαρακτηριστικά δεν ήταν αρκετά για τη δομημένη ομιλία.	75
7.2	Συνεισφορές εκτεταμένων χαρακτηριστικών	76
7.3	Επιδράσεις στάθμισης κλάσης	76
7.4	Σύγκριση διακύμανσης: μικρά έναντι μεγάλων συνόλων δεδομένων. Οι τυπικές αποκλίσεις μειώνονται περίπου όσο μεγαλώνει το n	77
7.5	Σύγκριση με τη βιβλιογραφία	78
7.6	Μεθοδολογική σύγκριση. Η παρούσα εργασία δίνει προτεραιότητα στην αναπαραγωγιμότητα και στις συντηρητικές εκτιμήσεις γενίκευσης. . . .	79
7.7	Τα 5 κορυφαία χαρακτηριστικά του Random Forest ανά εργασία (Εκτεταμένο σύνολο χαρακτηριστικών). Οι τιμές σημασίας αντιπροσωπεύουν τη μέση μείωση της ακαθαρσίας.	79
7.8	Κορυφαία 5 χαρακτηριστικά του συνόλου δεδομένων B (Random For- est). Αυτές οι προηγμένες μετρήσεις επεξεργασίας σήματος δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.	80
7.9	Σύγκριση εργασιών μεταξύ διαμορφώσεων. Ο αυθόρμητος διάλογος γενικά αποδίδει καλύτερα από το ReadText, εκτός από το SVM στα εκτεταμένα χαρακτηριστικά.	81
8.1	Μετρήσεις μεγέθους δείγματος συνόλου δεδομένων A	82
8.2	Σταθερές υπερπαραμέτροι (όλα τα πειράματα)	84
8.3	Απειλές εσωτερικής εγκυρότητας	86
8.4	Απειλές εξωτερικής εγκυρότητας	86
A.1	Σημαντικότητα χαρακτηριστικών του Random Forest — ReadText (top 10)	92
A.2	Σημαντικότητα χαρακτηριστικών του Logistic Regression — ReadText (top 10)	93

A.3	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — ReadText (top 10)	94
A.4	Σημαντικότητα χαρακτηριστικών του XGBoost — ReadText (top 10)	95
A.5	Σημαντικότητα χαρακτηριστικών του Random Forest — SpontaneousDialogue (top 10)	96
A.6	Σημαντικότητα χαρακτηριστικών του Logistic Regression — SpontaneousDialogue (top 10)	96
A.7	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — SpontaneousDialogue (top 10)	97
A.8	Σημαντικότητα χαρακτηριστικών του XGBoost — SpontaneousDialogue (top 10)	98
A.9	Σημαντικότητα χαρακτηριστικών του Random Forest — Dataset B (top 10)	100
A.10	Σημαντικότητα χαρακτηριστικών του Logistic Regression — Dataset B (top 10)	100
A.11	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — Dataset B (top 10)	101
A.12	Σημαντικότητα χαρακτηριστικών του XGBoost — Dataset B (top 10)	102
A.13	Σταθερότητα χαρακτηριστικών μεταξύ tasks (Random Forest top-10)	103
A.14	Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά κατηγορία	103
B.1	Αποτελέσματα Condition 1 ανά task (Dataset A, baseline features, χωρίς weighting)	105
B.2	Αποτελέσματα Condition 1 (Dataset B, baseline features, χωρίς weighting)	106
B.3	Αποτελέσματα Condition 2 ανά task (Dataset A, extended features, χωρίς weighting)	106
B.4	Βελτίωση Condition 2 έναντι Condition 1 (Random Forest)	106
B.5	Αποτελέσματα Condition 3 ανά task (Dataset A, baseline features, με weighting)	107
B.6	Επίδραση του weighting στο Condition 3 έναντι Condition 1 (RF)	107
B.7	Αποτελέσματα Condition 4 ανά task (Dataset A, extended features, με weighting)	108
B.8	Επίδραση του weighting στο Condition 4 έναντι Condition 2 (RF)	108
B.9	Πίνακας σύγκρισης Random Forest ROC-AUC (Dataset A)	108
B.10	Πίνακας σύγκρισης Random Forest Accuracy (Dataset A)	109

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορικό και κίνητρα

Η νόσος του Πάρκινσον είναι η δεύτερη πιο συχνή νευρολογική ασθένεια που σχετίζεται με εκφύλιση των νευρών. Επηρεάζει περίπου 1 στους 100 ανθρώπους άνω των 60 ετών [1]. Σήμερα, μία από τις μεγαλύτερες προκλήσεις που αντιμετωπίζονται στο κλινικό περιβάλλον είναι η έγκαιρη και σωστή διάγνωση, επειδή τα εμφανή συμπτώματα συνήθως παρουσιάζονται όταν έχει ήδη χαθεί σημαντικός αριθμός νευρώνων. Οι ασθενείς με Πάρκινσον συχνά εμφανίζουν αλλαγές στην ομιλία, λόγω επιδράσεων στον λάρυγγα και στους αναπνευστικούς μύες. Οι αλλαγές αυτές μπορεί να εμφανιστούν αρκετά χρόνια πριν από τα τυπικά κινητικά συμπτώματα (έως και 7 χρόνια νωρίτερα). [2].

Οι δείκτες που βασίζονται στη φωνή αποτελούν έναν απλό, οικονομικό και μη επεμβατικό τρόπο για την ανίχνευση της νόσου [3, 4]. Καθώς η νόσος του Πάρκινσον βλάπτει τον λάρυγγα και τους αναπνευστικούς μύες, αυτό προκαλεί ανιχνεύσιμες αλλαγές στις προσωδικές πτυχές της ομιλίας ενός ατόμου (δηλ. τον τόνο, την ένταση, τον ρυθμό της ομιλίας) καθώς και σε χαρακτηριστικά του ακουστικού σήματος, όπως η δομή και οι συχνότητες της φωνής.

Η ομιλία των ατόμων με PD ονομάζεται *υποκινητική δυσαρθρία* (HKD) και χαρακτηρίζεται από:

- (α) *υποφωνία*, (μειωμένη ένταση φωνής),
- (β) *μονοτονικότητα*, (περιορισμένο εύρος τόνων) και
- (γ) *μονοφωνία*, (μια ομοιόμορφη ένταση της φωνής κατά την ομιλία) [5].

Μπορεί επίσης να υπάρχει ασαφής άρθρωση, δηλαδή οι λέξεις να μην ακούγονται καθαρά, καθώς και αλλαγές στην ποιότητα της φωνής, όπως βραχνάδα.

Η φωνή μπορεί να καταγραφεί με απλά μικρόφωνα, ακόμη και με smartphone, γεγονός που ενισχύει τη χρήση της ανάλυσης φωνής για την αναγνώριση και την παρακολούθηση της νόσου. Ορισμένες φωνητικές ανωμαλίες μπορεί να είναι ανιχνεύσιμες πριν εμφανιστούν τα κλασικά συμπτώματα, επομένως η φωνή μπορεί να λειτουργήσει ως πρώιμος δείκτης.

Τα τελευταία χρόνια, η έρευνα έχει περάσει από ηχογραφήσεις σε ειδικά εργαστήρια με πολύπλοκο εξοπλισμό σε ηχογραφήσεις με απλά μέσα, όπως το μικρόφωνο ενός smartphone. Αυτή η αλλαγή δημιουργεί νέες δυσκολίες, κυρίως στο κατά πόσο τα αποτελέσματα μπορούν να ισχύουν σε διαφορετικές συνθήκες και συσκευές που απουσίαζαν από παλιές μελέτες [6].

Οι δείκτες φωνής χρησιμοποιούνται για δύο βασικούς σκοπούς:

- (α) για τον έλεγχο και την ανίχνευση της νόσου, που αποτελεί τον κύριο ερευνητικό στόχο περίπου του 94% των μελετών που έχουν διεξαχθεί μέχρι σήμερα, και
- (β) για την παρακολούθηση της πορείας της και της ανταπόκρισης στη θεραπεία [7].

Όμως, τα διαχρονικά στοιχεία για τον στόχο (β) παραμένουν σπάνια και τα περισσότερα ακουστικά χαρακτηριστικά έχουν επικυρωθεί μερικώς και κυρίως διατομεακά [8].

1.2 Διατύπωση του προβλήματος

Παρόλο που έχουν γίνει σημαντικές προσπάθειες για την ανάπτυξη μεθόδων που χρησιμοποιούν τη φωνή για την ανίχνευση της νόσου του Πάρκινσον, εξακολουθούν να υπάρχουν αρκετές προκλήσεις:

1. **Μικρά μεγέθη δειγμάτων** Όταν τα διαθέσιμα ηχητικά δεδομένα είναι λίγα, είναι δύσκολο να δημιουργηθούν μοντέλα που να λειτουργούν σωστά και σε νέους πληθυσμούς.
2. **Διαρροή ταυτότητας υποκειμένου (subject leakage)** Συμβαίνει όταν ηχογραφήσεις του ίδιου ατόμου χρησιμοποιούνται και για εκπαίδευση και για έλεγχο του μοντέλου. Αυτό μπορεί να οδηγήσει σε υπερβολικά καλά αλλά μη ρεαλιστικά αποτελέσματα.
3. **Ανισορροπία κλάσεων** Συνήθως δεν υπάρχει ίδιος αριθμός δειγμάτων από

άτομα με Πάρκινσον (PD) και από υγιή άτομα (HC), κάτι που μπορεί να επηρεάσει την απόδοση του μοντέλου.

4. **Επιλογή χαρακτηριστικών** Ο τρόπος με τον οποίο αναπαρίσταται η φωνή (ποια χαρακτηριστικά επιλέγονται) μπορεί να επηρεάσει σημαντικά το πόσο καλά λειτουργεί το μοντέλο ταξινόμησης.
5. **Διαφορετικές μέθοδοι επικύρωσης** Οι μελέτες χρησιμοποιούν διαφορετικούς τρόπους για να αξιολογήσουν τα μοντέλα (π.χ. k-fold, σταθερός διαχωρισμός εκπαίδευσης/δοκιμής, leave-one-subject-out, εξωτερική επικύρωση). Αυτές οι μέθοδοι δίνουν διαφορετικές εκτιμήσεις απόδοσης, κάτι που δυσκολεύει τη σύγκριση των αποτελεσμάτων μεταξύ μελετών. Παρ' όλα αυτά, λίγες μελέτες χρησιμοποιούν εξωτερική επικύρωση [6].
6. **Χάσμα γενίκευσης μεταξύ συνόλων δεδομένων:** Ένα μοντέλο μπορεί να έχει πολύ υψηλή ακρίβεια στο αρχικό σύνολο δεδομένων, αλλά η απόδοσή του συχνά μειώνεται όταν δοκιμαστεί σε νέα, διαφορετικά δεδομένα. Αυτό μπορεί να οδηγήσει σε υπερβολικούς ισχυρισμούς για την πραγματική του απόδοση [6].

Όλες αυτές οι προκλήσεις εξετάζονται σε αυτή τη εργασία εργασία με έναν προσεκτικό πειραματικό σχεδιασμό, που δίνει έμφαση στη σωστή μεθοδολογία και όχι απλώς στην επίτευξη υψηλών ποσοστών απόδοσης.

1.3 Ερευνητικοί στόχοι

Οι κύριοι στόχοι αυτής της εργασίας είναι:

1. Να **παρέχει μια αναπαραγώγιμη διαδικασία** για την εξαγωγή ακουστικών χαρακτηριστικών από ηχογραφήσεις φωνής.
2. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost) για την ταξινόμηση PD έναντι HC.
3. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης σε δύο ξεχωριστά σύνολα δεδομένων, τα οποία έχουν διαφορετικά χαρακτηριστικά.
4. Να **αξιολογήσει την επίδραση** της αύξησης των χαρακτηριστικών (από 47 σε 78) με ελεγχόμενο τρόπο.
5. Να **αξιολογήσει την επίδραση** της χρήσης βαρών κλάσης (class-weighting) ώστε να αντιμετωπιστεί η ανισορροπία μεταξύ των ομάδων.

1.4 Συνεισφορές

Η παρούσα εργασία συμβάλλει στη μελέτη των φωνητικών βιοδεικτών της νόσου του Πάρκινσον με τους εξής τρόπους:

- **Αξιολόγηση χωρίς διαρροή ταυτότητας:** Χρησιμοποιήθηκε cross-validation ανά υποκείμενο, έτσι ώστε όλες οι ηχογραφήσεις του ίδιου ατόμου να βρίσκονται είτε στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής. Με αυτόν τον τρόπο αποφεύγεται η «διαρροή δεδομένων», δηλαδή το να μαθαίνει το μοντέλο από το ίδιο άτομο που αργότερα καλείται να προβλέψει.
- **Έλεγχος της αύξησης των χαρακτηριστικών:** Μελετήθηκε τι συμβαίνει όταν τα χαρακτηριστικά αυξάνονται από 47 σε 78. Η αύξηση αυτή βελτίωσε την απόδοση έως και 23% (ROC-AUC). Παράλληλα, εξετάστηκε ποια από τα νέα χαρακτηριστικά συνέβαλαν περισσότερο στη βελτίωση.
- **Σύγκριση αυθόρμητης και δομημένης ομιλίας:** Βρέθηκε ότι τα μοντέλα αποδίδουν καλύτερα όταν χρησιμοποιείται αυθόρμητη ομιλία σε σχέση με δομημένη ανάγνωση. Για παράδειγμα, το Random Forest είχε καλύτερη απόδοση στην αυθόρμητη ομιλία, γεγονός που δείχνει ότι τέτοιου τύπου δεδομένα ίσως αποτυπώνουν καλύτερα τις αλλαγές που σχετίζονται με τη νόσο.
- **Σύγκριση δύο διαφορετικών datasets:** Τα αποτελέσματα από ένα αυστηρά ελεγχόμενο dataset συγκρίθηκαν με ένα δημόσιο dataset με προ-εξαγμένα χαρακτηριστικά. Στο δημόσιο dataset, η απλή διασταυρούμενη επικύρωση έδωσε πολύ υψηλές τιμές απόδοσης (π.χ. AUC $\sim 0,94$), που πιθανόν δεν είναι ρεαλιστικές. Αυτό δείχνει πόσο σημαντική είναι η σωστή μεθοδολογία αξιολόγησης.
- **Ερμηνεία των χαρακτηριστικών:** Πέρα από τη μέτρηση της απόδοσης, έγινε και ανάλυση της σημασίας των χαρακτηριστικών, ώστε να είναι πιο κατανοητό ποια στοιχεία της φωνής συμβάλλουν περισσότερο στην ανίχνευση της νόσου. Αυτό ενισχύει τη διαφάνεια και τη χρησιμότητα των αποτελεσμάτων.

1.5 Οργάνωση της εργασίας

Τα υπόλοιπα κεφάλαια αυτής της εργασίας ακολουθούν το οργανωτικό σχήμα που παρέχεται παρακάτω:

Table 1.1: Περίληψη των κεφαλαίων της εργασίας

Κεφάλαιο	Τίτλος	Περιγραφή
2	Βιβλιογραφική ανασκόπηση	Επισκόπηση των μεθοδολογιών ανίχνευσης PD με βάση τη φωνή
3	Περιγραφή δεδομένων	Λεπτομερείς περιγραφές των συνόλων δεδομένων που χρησιμοποιήθηκαν σε αυτή τη εργασία
4	Μεθοδολογία	Διαδικασία εξαγωγής ακουστικών χαρακτηριστικών και κατασκευής μοντέλου μηχανικής μάθησης
5	Πειραματικός σχεδιασμός	Πρωτόκολλο για την αξιολόγηση των επιδράσεων κάθε μεταβλητής
6	Αποτελέσματα	Ποσοτικά αποτελέσματα για κάθε μία από τις συνθήκες
7	Συζήτηση	Επεξήγηση των αποτελεσμάτων και σύγκριση με προηγούμενες εργασίες
8	Περιορισμοί	Περιορισμοί και περιορισμοί της μελέτης
9	Συμπέρασμα	Περίληψη των κύριων ευρημάτων και πιθανών μελλοντικών τομέων έρευνας

1.6 Όρια πεδίου εφαρμογής

Η μελέτη έχει τα ακόλουθα όρια πεδίου εφαρμογής:

- **Μόνο δυαδική ταξινόμηση:** Η εργασία εξετάζει μόνο αν ένα άτομο έχει Πάρκινσον ή όχι (PD vs HC). Δεν μελετά πόσο σοβαρή είναι η νόσος, πώς εξελίσσεται με τον χρόνο ή πώς ξεχωρίζει από άλλες ασθένειες.
- **Μόνο κλασικά μοντέλα μηχανικής μάθησης:** Χρησιμοποιούνται μόνο κλασικά και πιο εύκολα ερμηνεύσιμα μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost). Δεν χρησιμοποιούνται νευρωνικά δίκτυα ή βαθιά μάθηση, κυρίως λόγω του μικρού μεγέθους των δεδομένων και της έμφασης στην κατανόηση των αποτελεσμάτων. Η εργασία προσφέρει έτσι μια καθαρή και αξιόπιστη βάση για μελλοντικές πιο σύνθετες μεθόδους.
- **Ερευνητικός χαρακτήρας:** Τα μοντέλα που παρουσιάζονται έχουν ερευνητικό σκοπό. Δεν προορίζονται να χρησιμοποιηθούν άμεσα από γιατρούς για διάγνωση χωρίς επιπλέον έλεγχο και επιβεβαίωση.
- **Έμφαση στην αναπαραγωγιμότητα:** Δόθηκε προτεραιότητα στο να μπορούν τα πειράματα να επαναληφθούν από άλλους ερευνητές. Για αυτό χρησιμοποιήθηκαν σταθερές ρυθμίσεις, σαφής περιγραφή των βημάτων και

σωστή τεκμηρίωση του κώδικα. Η αξιοπιστία των αποτελεσμάτων θεωρήθηκε πιο σημαντική από το να επιτευχθούν απλώς υψηλότερα ποσοστά απόδοσης.

Κεφάλαιο 2

Βιβλιογραφική ανασκόπηση

2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας

Η νόσος του Πάρκινσον είναι γνωστή κυρίως για τα κινητικά της συμπτώματα (τρέμουλο, ακαμψία, βραδυκίνησία), αλλά παράλληλα με αυτά, η νόσος επηρεάζει σχεδόν πάντα και την ομιλία και τη φωνή. Περίπου το 70–90% των ατόμων με νόσο του Πάρκινσον αναπτύσσουν μετρήσιμες διαταραχές της ομιλίας και της φωνής κατά τη διάρκεια της νόσου [1]. Αυτή η συλλογή συμπτωμάτων της ομιλίας στη νόσο του Πάρκινσον περιγράφεται συχνά ως *υποκινητική δυσαρθρία*, υποδηλώνοντας ένα χαρακτηριστικό μοτίβο διαταραχής του κινητικού ελέγχου της ομιλίας που σχετίζεται με τη νόσο [5].

Η ομιλία στην PD χαρακτηρίζεται από *υποφωνία* (μειωμένη ένταση), *μονοτονία* και *μονοφωνία* (μειωμένη προσωδιακή μεταβλητότητα), ασαφή άρθρωση και φωνή με αναπνοή ή βραχνάδα που προκύπτει από ατελές κλείσιμο των φωνητικών χορδών [5, 9].

Αυτές οι αλλαγές στην ομιλία στην PD παρουσιάζουν ενδιαφέρον όχι μόνο ως συμπτώματα που επηρεάζουν την ικανότητα επικοινωνίας ενός ατόμου, αλλά και ως πιθανοί μη επεμβατικοί βιοδείκτες της νόσου. Η φωνή είναι σχετικά εύκολο να καταγραφεί (για παράδειγμα, μέσω μιας σύντομης ηχογράφησης σε ένα smartphone) και οι φωνητικές αλλαγές μπορεί να εμφανιστούν νωρίς στην πορεία της νόσου. Ορισμένες έρευνες υποδηλώνουν ότι οι λεπτές ανωμαλίες της φωνής μπορούν να ανιχνευθούν πριν από την εμφάνιση των κλασικών κινητικών συμπτωμάτων σε ορισμένους ασθενείς [2]. Δεδομένου ότι η ηχογράφηση και η ανάλυση της φωνής μπορούν να πραγματοποιηθούν με χαμηλό κόστος και εξ αποστάσεως, υπάρχει σημαντική κινητοποίηση για τη χρήση της ομιλίας ως μέσου ανίχνευσης ή

παρακολούθησης της νόσου του Πάρκινσον χωρίς την ανάγκη επεμβατικών εξετάσεων. Οι μετρήσεις της ομιλίας και της φωνής είναι κατάλληλες για εφαρμογές τηλείατρικής και για τη διαχρονική παρακολούθηση της εξέλιξης της νόσου του Πάρκινσον [4]. Σε αντίθεση με πολλές κλινικές αξιολογήσεις που απαιτούν προσωπικές επισκέψεις και εξειδικευμένο εξοπλισμό, οι ηχογραφήσεις φωνής μπορούν να ληφθούν από τους ασθενείς στο σπίτι τους και να αναλυθούν με αλγόριθμους, επιτρέποντας πιο συχνή και χαμηλότερου κόστους παρακολούθηση.

2.2 Ανίχνευση έναντι παρακολούθησης

Η έρευνα για την PD με βάση τη φωνή αντιμετωπίζει δύο σχετικούς αλλά διακριτούς στόχους: **ανίχνευση/διαλογή** (δυαδική ταξινόμηση της PD έναντι της HC) και **παρακολούθηση/εξέλιξη** (παρακολούθηση της σοβαρότητας της νόσου ή της ανταπόκρισης στη θεραπεία με την πάροδο του χρόνου). Μια συστηματική ανασκόπηση 106 μελετών που δημοσιεύθηκαν μεταξύ 2019 και 2023 διαπίστωσε ότι περίπου το 94% επικεντρώθηκε στη διάγνωση ή την ανίχνευση, ενώ λιγότερο από το 12% ασχολήθηκε με την πρόγνωση ή την εξέλιξη [7].

Οι δύο στόχοι ευνοούν διαφορετικές λειτουργίες ομιλίας και ακουστικά χαρακτηριστικά. Η παρατεταμένη φώνηση φωνηέντων είναι πιο αποτελεσματική για τη δυαδική διάκριση PD/HC, καθώς απομονώνει τη λειτουργία του λάρυγγα και παρέχει σταθερές μετρήσεις διαταραχής και θορύβου [8]. Οι συνδεδεμένες λειτουργίες ομιλίας, όπως η ανάγνωση αποσπασμάτων και ο αυθόρμητος διάλογος, είναι πιο ενημερωτικές για την εκτίμηση της σοβαρότητας, καθώς καταγράφουν την ακρίβεια της άρθρωσης, τον ρυθμό ομιλίας και την προσωδιακή διακύμανση, χαρακτηριστικά που συσχετίζονται με κλινικές κλίμακες σοβαρότητας όπως η UPDRS [8]. Τα χαρακτηριστικά άρθρωσης (MFCC, συντελεστές PLP, περιοχή φωνηέντων) έχουν αναφερθεί ότι αποδίδουν μέση ακρίβεια 80–95% για την πρόβλεψη της σοβαρότητας, σε σύγκριση με 75–90% για τα φωνητικά χαρακτηριστικά μόνο [8].

Ένας κρίσιμος περιορισμός της βιβλιογραφίας σχετικά με την παρακολούθηση είναι η έλλειψη διαχρονικών δεδομένων: οι περισσότερες μελέτες συγκρίνουν ομάδες PD και HC διατομεακά, αντί να παρακολουθούν τις ακουστικές αλλαγές σε μεμονωμένα άτομα με την πάροδο του χρόνου [8]. Η παρούσα εργασία επικεντρώνεται στην αξιόπιστη ανίχνευση χρησιμοποιώντας δύο τύπους εργασιών ομιλίας (ReadText και SpontaneousDialogue), αλλά το σύνολο χαρακτηριστικών έχει σχεδιαστεί κατά τρόπο που παραμένει συμβατό με μελλοντικές εργασίες παρακολούθησης.

2.3 Ταξινόμηση ακουστικών χαρακτηριστικών

Table 2.1: Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD

Κατηγορία	Παραδείγματα	Φυσιολογική βάση
Θεμελιώδης συχνότητα	F_0 μέσος όρος, F_0 τυπική απόκλιση	Τάση φωνητικών χορδών και κινητική ακαμψία
Διαταραχή	Jitter, Shimmer	Νευρομυϊκή αστάθεια
Θόρυβος	HNR, NHR	Ατελές κλείσιμο της γλωττίδας
Φορμάντες	F_1 , F_2 , F_3	Διαμόρφωση φωνητικού σωλήνα
Φασματικά/Κεποτρικά	MFCCs, delta-MFCCs	Φασματική περιβάλλουσα και δυναμική

Προσωδιακά χαρακτηριστικά σχετίζονται με το ύψος (F_0) και τα μοτίβα έντασης. Η PD μειώνει το εύρος F_0 (μονοτονικότητα) και το εύρος έντασης (μονοεντατικότητα), τα οποία σχετίζονται με την ταξινόμηση PD [10]. Οι στατιστικές πληθυσμού που καταγράφονται περιλαμβάνουν μέση τιμή F_0 , τυπική απόκλιση, ελάχιστη και μέγιστη τιμή, μέση ένταση και μεταβλητότητα, καθώς και συχνότητες φορμάντων που αντανακλούν τη διαμόρφωση του φωνητικού σωλήνα.

Τα **μέτρα διαταραχής** ποσοτικοποιούν την αστάθεια από κύκλο σε κύκλο στη δόνηση των φωνητικών χορδών. Το jitter (διαταραχή περιόδου) και το shimmer (διαταραχή πλάτους) είναι αυξημένα στην PD, αντανακλώντας τη νευρομυϊκή ασυντονιστικότητα που εμποδίζει την πηγή ομιλίας να διατηρήσει έναν τακτικό κύκλο δόνησης. Ο λόγος αρμονικών προς θόρυβο (HNR) μετρά την αναλογία της περιοδικής προς την μη περιοδική ενέργεια. Οι χαμηλότερες τιμές HNR υποδηλώνουν μια πιο αναπνευστική, θορυβώδη ποιότητα φωνής που είναι χαρακτηριστική της PD [3].

Τα **φασματικά και κεποτρικά χαρακτηριστικά** σχετίζονται με το φασματικό περίβλημα του φωνητικού σήματος. Οι Mel-Frequency Cepstral Coefficients (MFCCs) καταγράφουν πληροφορίες σχετικά με το φασματικό σχήμα χρησιμοποιώντας μια κλίμακα συχνοτήτων που βασίζεται στην αντίληψη, ενώ οι χρονικές παράγωγοί τους (delta και delta-delta) καταγράφουν τις δυναμικές αλλαγές στα φασματικά δεδομένα με την πάροδο του χρόνου [11]. Οι περιγραφές φασματικού σχήματος, όπως το κέντρο βάρους, το εύρος ζώνης, η απόκλιση και η επιπεδότητα, παρέχουν συμπληρωματικά μέτρα της συνολικής κατανομής ενέργειας. Μαζί, αυτές οι τρεις κατηγορίες χαρακτηριστικών είναι συμπληρωματικές και παρέχουν μια ολιστική περιγραφή της ακουστικής αλλαγής που σχετίζεται με την PD.

2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας

Πρόσφατες συστηματικές ανασκοπήσεις οργανώνουν τα ακουστικά χαρακτηριστικά σε τρεις λειτουργικά καθορισμένες κατηγορίες που αντιστοιχούν σε διακριτές πτυχές του μηχανισμού παραγωγής ομιλίας [8]:

- **Φωνητικά χαρακτηριστικά** (jitter, shimmer, HNR, λόγος διέγερσης γλωττίδας προς θόρυβο, εντροπία περιόδου τόνου) ποσοτικοποιούν τη σταθερότητα και την πληρότητα της δόνησης των φωνητικών χορδών. Αυτά τα χαρακτηριστικά είναι αυξημένα ή μειωμένα στην PD ως αποτέλεσμα της νευρομυϊκής αστάθειας και του ατελούς κλεισίματος της γλωττίδας.
- **Χαρακτηριστικά άρθρωσης** (MFCCs, cepstral peak prominence, formant frequencies, vowel space area, vowel articulation index, perceptual linear prediction coefficients) καταγράφουν τη δυναμική και την ακρίβεια της κίνησης του φωνητικού σωλήνα. Η περιοχή του φωνητικού χώρου είναι σταθερά μειωμένη στην PD, αντανακλώντας την περιορισμένη άρθρωση.
- **Προσωδικά χαρακτηριστικά** (μεταβλητότητα F_0 στη συνδεδεμένη ομιλία, ρυθμός ομιλίας, αριθμός και διάρκεια παύσεων, μέγιστος χρόνος φώνησης) καταγράφουν τα υπερκειμενικά μοτίβα του τόνου, του συγχρονισμού και του ρυθμού. Αυτά τα χαρακτηριστικά αντανακλούν τη μειωμένη προσωδική διακύμανση σε επίπεδο πρότασης στην PD, παράλληλα με την αυξημένη αστάθεια του τόνου σε επίπεδο μικρού τμήματος.

Από τα 18 χαρακτηριστικά που εξετάστηκαν από τον Wright and Aharonson [8], 12 έδειξαν μετρήσιμες και συνεπείς διαφορές μεταξύ ασθενών με PD και υγιών ατόμων ελέγχου, με το jitter, το shimmer και το HNR να είναι τα πιο συνεπή διακριτικά χαρακτηριστικά σε όλες τις μελέτες. Αυτό το πλαίσιο τριών κατηγοριών είναι συμπληρωματικό της παραδοσιακής ομαδοποίησης επεξεργασίας σήματος που παρουσιάζεται στον Πίνακα 2.1 και παρέχει μια κλινικά τεκμηριωμένη προοπτική για την ερμηνεία των αποτελεσμάτων σχετικά με τη σημασία των χαρακτηριστικών.

2.4 Σύνολα δεδομένων που χρησιμοποιούνται στην έρευνα για τη φωνή των ασθενών με Πάρκινσον

Η απόδοση και τα συμπεράσματα οποιασδήποτε μελέτης μηχανικής μάθησης είναι εγγενώς συνδεδεμένα με τα σύνολα δεδομένων που χρησιμοποιούνται. Στην έρευνα για τη φωνή των ασθενών με PD, έχουν χρησιμοποιηθεί διάφορα σύνολα δεδομένων,

το καθένα με διαφορετικά χαρακτηριστικά. Σε γενικές γραμμές, αυτά μπορούν να χωριστούν σε **ακατέργαστα σύνολα δεδομένων ήχου** (ηχογραφημένα φωνητικά σήματα που απαιτούν εξαγωγή χαρακτηριστικών) και **προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών** (όπου τα δεδομένα παρέχονται ήδη με τη μορφή τιμών χαρακτηριστικών ανά δείγμα). Παρακάτω εξετάζονται αντιπροσωπευτικά παραδείγματα κάθε κατηγορίας και η συνάφειά τους με την παρούσα εργασία.

2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου

Τα ακατέργαστα σύνολα δεδομένων ήχου για την PD συνήθως αποτελούνται από ηχογραφήσεις φωνής ασθενών με PD και υγιών ατόμων που έχουν συλλεχθεί σε ελεγχόμενο περιβάλλον. Ένα γνωστό πρώιμο παράδειγμα είναι το σύνολο δεδομένων του Little et al. [12] που διατίθεται μέσω του UCI Machine Learning Repository. Περιέχει 195 παρατεταμένες φωνητικές φωνές (ήχοι «α») από 31 άτομα (23 με PD), το καθένα από τα οποία χαρακτηρίζεται από 22 χαρακτηριστικά δυσφωνίας (jitter, shimmer, κ.λπ.) συν την ετικέτα κλάσης. Οι Little et al. ανέφεραν ότι πέτυχαν ακρίβεια ~91% στην ανίχνευση της PD χρησιμοποιώντας ένα SVM, καθιστώντας το ως σημείο αναφοράς για τις πρώιμες μελέτες. Ένας βασικός περιορισμός, ωστόσο, είναι ότι περιλαμβάνονται πολλαπλές ηχογραφήσεις από το ίδιο άτομο, γεγονός που απαιτεί προσεκτική ομαδοποίηση για την αποφυγή μεροληψίας — μια προφύλαξη που δεν τηρήθηκε σε όλες τις πρώιμες μελέτες, συμβάλλοντας σε ορισμένα υπερβολικά αισιόδοξα αποτελέσματα.

Ένα πιο πρόσφατο παράδειγμα είναι το σώμα MDVR-KCL (Mobile Device Voice Recordings at King's College London) [13]. Αυτή η συλλογή του 2019 περιέχει ηχογραφήσεις φωνής από ασθενείς με PD και υγιείς μάρτυρες που εκτελούν πολλαπλές ομιλητικές εργασίες, συμπεριλαμβανομένης της ανάγνωσης και του αυθόρμητου διαλόγου. Περιλαμβάνει δεκάδες υποκείμενα (για παράδειγμα, 37 υποκείμενα στο τμήμα που χρησιμοποιείται σε αυτή τη εργασία) και πολλαπλές ηχογραφήσεις ανά υποκείμενο ανά εργασία, καθιστώντας το κατάλληλο για την εξέταση της μεταβλητότητας εντός του υποκειμένου και των επιδράσεων της εργασίας. Τα δεδομένα είναι διαθέσιμα στο Zenodo και αντικατοπτρίζουν ένα πιο ρεαλιστικό σενάριο εγγραφής, με ποικίλο περιεχόμενο ομιλίας που καταγράφεται μέσω smartphone. Μελέτες που χρησιμοποιούν αυτό το σώμα δεδομένων — ή παρόμοια σύνολα δεδομένων πολλαπλών εργασιών — υποστηρίζουν ένθερμα την ομαδοποιημένη διασταυρούμενη επικύρωση, διασφαλίζοντας ότι όλες οι εγγραφές από ένα δεδομένο υποκείμενο τοποθετούνται σε ένα μόνο τμήμα, προκειμένου να αξιολογηθεί σωστά η γενίκευση σε νέους ομιλητές.

2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών

Τα προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών είναι εκείνα στα οποία το στάδιο επεξεργασίας του σήματος έχει ήδη ολοκληρωθεί αποτελεσματικά — αυτό που παρέχεται είναι ένας πίνακας τιμών χαρακτηριστικών ανά δείγμα, μαζί με ετικέτες κλάσης, έτοιμος για άμεση εφαρμογή μεθόδων μηχανικής μάθησης. Το σύνολο δεδομένων χαρακτηριστικών ομιλίας της νόσου του Πάρκινσον (PDSF) είναι ένα εξέχον παράδειγμα, διαθέσιμο μέσω του αποθετηρίου UCI ή του Kaggle [14].

Περιλαμβάνει 756 δείγματα με 754 χαρακτηριστικά ανά δείγμα συν μια δυαδική ετικέτα (PD ή HC), όπου κάθε δείγμα αντιστοιχεί σε μια ηχογράφηση φωνής από ένα άτομο. Υπάρχουν 252 μοναδικά υποκείμενα (188 PD, 64 HC), το καθένα από τα οποία συνεισφέρει ακριβώς τρία δείγματα (π.χ. τρεις ηχογραφήσεις παρατεταμένων φωνηέντων). Τα χαρακτηριστικά καλύπτουν ένα ευρύ φάσμα ακουστικών μετρήσεων, συμπεριλαμβανομένων παραδοσιακών μετρήσεων όπως jitter, shimmer και MFCCs, καθώς και συντελεστές Tunable Q-factor Wavelet Transform (TQWT) που καταγράφουν πρόσθετα χαρακτηριστικά του σήματος. Αυτό το σύνολο δεδομένων σχεδιάστηκε ως ένα ολοκληρωμένο σύνολο χαρακτηριστικών για τη συγκριτική αξιολόγηση της απόδοσης του ταξινομητή.

Το κύριο πλεονέκτημα των προ-εξαγόμενων συνόλων δεδομένων χαρακτηριστικών είναι η ευκολία και η συνέπεια — οι ερευνητές μπορούν να κατεβάσουν το CSV και να εφαρμόσουν απευθείας μεθόδους μηχανικής μάθησης, χωρίς να χρειάζεται να εφαρμόσουν διαδικασίες επεξεργασίας σήματος. Πολλές μελέτες έχουν χρησιμοποιήσει το σύνολο δεδομένων PDSF για να αξιολογήσουν διαφορετικούς αλγόριθμους ταξινόμησης, τεχνικές επιλογής χαρακτηριστικών και μεθόδους συνόλου, με αναφερόμενη ακρίβεια συχνά στην περιοχή 85–95% σε διάφορους ταξινομητές.

Μια κρίσιμη προειδοποίηση με σύνολα δεδομένων αυτού του τύπου είναι η **έλλειψη αναγνωριστικών υποκειμένων**. Δεδομένου ότι τα 756 δείγματα περιλαμβάνουν τρεις εγγραφές από καθένα από τα 252 υποκείμενα, μια αφελής διασταυρούμενη επικύρωση που χωρίζει τυχαία τα δείγματα θα εκπαιδεύσει και θα δοκιμάσει κατά λάθος εγγραφές από το ίδιο άτομο. Αυτό οδηγεί σε υπερβολικά αισιόδοξες εκτιμήσεις απόδοσης, καθώς οι τρεις εγγραφές ενός δεδομένου υποκειμένου δεν είναι ανεξάρτητες και μοιράζονται παρόμοια ακουστικά χαρακτηριστικά. Ορισμένες δημοσιευμένες μελέτες έχουν παραβλέψει αυτό το ζήτημα και, κατά συνέπεια, έχουν αναφέρει υπερβολική απόδοση του ταξινομητή. Η κατάλληλη προσέγγιση θα ήταν η ομαδοποίηση των δειγμάτων ανά υποκείμενο κατά την κατάτμηση των δεδομένων. Ωστόσο, δεδομένου ότι δεν παρέχονται αναγνωριστικά υποκειμένων, αυτό δεν μπορεί να γίνει άμεσα. Τα αποτελέσματα σε αυτό το σύνολο δεδομένων πρέπει επομένως να

ερμηνεύονται με προσοχή, καθώς η υψηλή ακρίβεια μπορεί να αντανακλά εν μέρει τη συνέπεια εντός του υποκειμένου και όχι την πραγματική γενίκευση σε νέους ομιλητές. Σε αυτή τη εργασία, τα αποτελέσματα του συνόλου δεδομένων B αντιμετωπίζονται ως δυνητικά αισιόδοξα, με έμφαση στις τάσεις και όχι στις απόλυτες τιμές απόδοσης.

2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων

Μια συστηματική ανασκόπηση 69 μελετών που δημοσιεύθηκαν μεταξύ 2020 και 2025 διαπίστωσε ότι τα περισσότερα σύνολα δεδομένων φωνής που χρησιμοποιούνται για την ταξινόμηση της PD περιέχουν λιγότερους από 100 συμμετέχοντες [6]. Τα πιο συχνά χρησιμοποιούμενα σώματα κειμένων είναι το PC-GITA (19 μελέτες), το σύνολο δεδομένων Istanbul PD Speech (15 μελέτες) και το σύνολο δεδομένων Oxford/UCI PD (14 μελέτες). Η ανισορροπία των κλάσεων είναι συχνή: η πλειονότητα των συνόλων δεδομένων παρουσιάζει αναλογίες PD-HC εκτός του εύρους 0,8–1,2, με το σύνολο δεδομένων Istanbul να περιέχει 188 συμμετέχοντες με PD έναντι μόλις 64 συμμετεχόντων με HC. Το σώμα κειμένων MDVR-KCL που χρησιμοποιείται σε αυτή τη εργασία είναι ένα από τα πιο συχνά εμφανιζόμενα σύνολα δεδομένων στην αγγλική γλώσσα στην πρόσφατη βιβλιογραφία [6].

2.4.4 Ετερογένεια επικύρωσης

Το ίδιο σύνολο δεδομένων μπορεί να παράγει θεμελιωδώς διαφορετικά αποτελέσματα απόδοσης ανάλογα με τη στρατηγική αξιολόγησης που χρησιμοποιείται. Μεταξύ των πρόσφατων μελετών, η k-fold cross-validation χρησιμοποιείται σε περίπου 40%, η fixed train/test splits σε περίπου 36%, η subject-independent evaluation (leave-one-subject-out ή leave-one-out) σε μόνο 12%, και η external cross-dataset validation σε λιγότερο από 15% [6]. Αυτή η ετερογένεια καθιστά δύσκολη και συχνά παραπλανητική την άμεση σύγκριση των αναφερόμενων αποτελεσμάτων μεταξύ των μελετών. Για παράδειγμα, μια μελέτη που ανέφερε ακρίβεια 100% χρησιμοποιώντας σταθερή διαίρεση στο μικρό σύνολο δεδομένων της Οξφόρδης βρέθηκε να υποβαθμίζεται στο 96% όταν δοκιμάστηκε σε διαφορετικό σώμα κειμένων, καταδεικνύοντας την ευθραυστότητα της αξιολόγησης εντός του δείγματος σε μικρά σημεία αναφοράς [6].

2.4.5 Ο ρόλος των εργασιών ομιλίας

Η επιλογή της εργασίας ομιλίας είναι μια σημαντική απόφαση σχεδιασμού που επηρεάζει τόσο τον τύπο των πληροφοριών που συλλέγονται όσο και την καταλληλότητα της ανάλυσης για την ανίχνευση έναντι της παρακολούθησης. Η

παρατεταμένη φώνηση φωνηέντων αντανακλά κυρίως τη λειτουργία του λάρυγγα και χρησιμοποιείται συνήθως για τη δυαδική διάκριση PD/HC. Αντίθετα, οι εργασίες ανάγνωσης και αυθόρμητης ομιλίας εμπλέκουν ολόκληρο το σύστημα παραγωγής ομιλίας και παρέχουν περισσότερες πληροφορίες για την αξιολόγηση της ακρίβειας της άρθρωσης, της προσωδικής διακύμανσης και του ρυθμού ομιλίας — χαρακτηριστικά που συνδέονται με τη σοβαρότητα της νόσου και όχι με την απλή παρουσία της [8]. Η παρούσα εργασία αξιολογεί τόσο μια εργασία ανάγνωσης (ReadText) όσο και μια εργασία αυθόρμητης ομιλίας (SpontaneousDialogue) από το Dataset A, επιτρέποντας μια ελεγχόμενη σύγκριση των αποτελεσμάτων των εργασιών υπό πανομοιότυπες διαμορφώσεις ταξινόμησης.

2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD

Η λογιστική παλινδρόμηση (LR), οι μηχανές υποστήριξης διανυσμάτων (SVM) και οι μέθοδοι συνόλου δέντρων είναι οι πιο ευρέως εφαρμοζόμενοι ταξινομητές στη βιβλιογραφία για τη φωνή PD. Η LR παρέχει μια ερμηνεύσιμη γραμμική βάση [15]· η SVM με πυρήνα RBF υπήρξε ιστορικά η κυρίαρχη προσέγγιση, με Little et al. [3] να επιτυγχάνει ακρίβεια ~91% στο σύνολο δεδομένων UCI χρησιμοποιώντας 22 χαρακτηριστικά δυσφωνίας [16]. Μια συστηματική ανασκόπηση από Sáenz-Lechón et al. [17] σημείωσε ότι οι SVM και τα τυχαία δάση επιτυγχάνουν υψηλή ακρίβεια σε μικρά ομοιογενή σύνολα δεδομένων παθολογίας φωνής. Το Random Forest [18] συμπληρώνει το SVM μέσω του μέσου όρου συνόλου, της ενσωματωμένης σημασίας χαρακτηριστικών και της ανθεκτικότητας σε άσχετα χαρακτηριστικά, καθιστώντας το κατάλληλο για μικρές, θορυβώδεις ιατρικές κοόρτες. Οι πλήρεις προδιαγραφές μοντέλου και οι εξισώσεις που χρησιμοποιούνται σε αυτή τη εργασία παρέχονται στο Κεφάλαιο 4.

Πέρα από την ακατέργαστη απόδοση ταξινόμησης, πρόσφατες εργασίες έχουν τονίσει τη σημασία της ερμηνεύσιμης επιλογής χαρακτηριστικών στην κλινική ανάλυση φωνής. Solana-Lavalle and Rosas-Romero [19] συνδύασε την επιλογή υποσυνόλων χαρακτηριστικών με πολλαπλούς ταξινομητές και μείωση διαστάσεων για να παρέχει ένα κλινικά ερμηνεύσιμο πλαίσιο για την ανίχνευση της νόσου του Πάρκινσον από τη φωνή. Ένα αξιοσημείωτο εύρημα της μελέτης τους είναι ότι το σχετικό περιεχόμενο συχνότητας στο φωνητικό σήμα διαφέρει μεταξύ ανδρών και γυναικών ομιλητών, υπογραμμίζοντας την ανάγκη να ληφθούν υπόψη οι δημογραφικές υποομάδες κατά την ερμηνεία των φωνητικών ταξινομητών και τονίζοντας το ενδεχόμενο το φύλο να

αποτελεί συγχυτική μεταβλητή σε ομάδες μικτού φύλου.

2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις

Αν και η παρούσα εργασία επικεντρώνεται αποκλειστικά στην κλασική μηχανική μάθηση, ο ευρύτερος τομέας έχει μετατοπιστεί σημαντικά προς τη βαθιά μάθηση. Μια πρόσφατη συστηματική ανασκόπηση διαπίστωσε ότι περίπου το 42% των μελετών φωνής PD που δημοσιεύθηκαν μεταξύ 2020 και 2025 χρησιμοποιούν αρχιτεκτονικές βαθιάς μάθησης, με τα συνελκτικά νευρωνικά δίκτυα (CNN) να είναι τα πιο συνηθισμένα, ακολουθούμενα από προσεγγίσεις βασισμένες σε μετασχηματιστές και μοντέλα θεμελίωσης όπως το Wav2Vec 2.0 [6]. Έχουν επίσης εμφανιστεί υβριδικές διαδικασίες που συνδυάζουν εξάγοντες χαρακτηριστικών βαθιάς μάθησης με κλασικούς ταξινομητές. Οι ενσωματώσεις βασικών μοντέλων δείχνουν υποσχέσεις για διαγλωσσική ανθεκτικότητα. Ωστόσο, η ανασκόπηση διαπίστωσε επίσης ότι αυτές οι μελέτες βασίζονται κυρίως σε εσωτερική επικύρωση, ενώ η εξωτερική αξιολόγηση μεταξύ συνόλων δεδομένων παραμένει σπάνια. Οι ισχυρισμοί σχετικά με την απόδοση που βασίζονται σε μικρά, ομοιογενή σύνολα δεδομένων — είτε χρησιμοποιούν κλασικές είτε βαθιές μεθόδους — θα πρέπει επομένως να ερμηνεύονται με προσοχή. Η παρούσα εργασία καθιερώνει μια αυστηρή κλασική βάση αναφοράς με αξιολόγηση ασφαλή από διαρροές και αφαίρεση χαρακτηριστικών, η οποία μπορεί να χρησιμεύσει ως σημείο αναφοράς για μελλοντικές συγκρίσεις βασισμένες σε ενσωματώσεις.

2.6 Μεθοδολογικά ζητήματα στη βιβλιογραφία

2.6.1 Διαρροή δεδομένων

Η διαρροή δεδομένων, όπως περιγράφεται σε μια πρόσφατη συστηματική ανασκόπηση της έρευνας για τη φωνή PD [6]:

«Όταν υπάρχουν πολλαπλές ηχογραφήσεις ανά υποκείμενο, οι τυχαίες διαχωριστικές δοκιμές εκπαίδευσης/ελέγχου μπορούν να τοποθετήσουν ηχογραφήσεις από το ίδιο υποκείμενο και στα δύο σύνολα, οδηγώντας σε τεχνητά διογκωμένες εκτιμήσεις απόδοσης.»

Η παρούσα μελέτη χρησιμοποιεί ομαδοποιημένη στρωματοποιημένη διασταυρούμενη επικύρωση για να διασφαλίσει ότι όλες οι ηχογραφήσεις από ένα συγκεκριμένο υποκείμενο υπάρχουν είτε αποκλειστικά στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής για κάθε πτυχή της διαδικασίας διασταυρούμενης επικύρωσης.

Πρόσφατη βιβλιογραφία δείχνει ότι, αν και πολλοί ερευνητές αναγνωρίζουν τα οφέλη της αξιολόγησης ανεξάρτητης από το υποκείμενο (δηλ. LOSO/LOOCV) και της αξιολόγησης εξωτερικών συνόλων δεδομένων, πολύ λίγοι ερευνητές στον τομέα χρησιμοποιούν αυτές τις προσεγγίσεις [6].

2.6.2 Ανισορροπία κλάσεων

Η ανισορροπία κλάσεων συμβαίνει όταν μια κλάση περιέχει σημαντικά περισσότερες περιπτώσεις από μια άλλη. Αυτό μπορεί να οδηγήσει σε παραπλανητικά αποτελέσματα όταν χρησιμοποιούνται απλά μέτρα ακρίβειας, επειδή ένα μοντέλο μπορεί να επιτύχει υψηλή ακρίβεια ενώ είναι μεροληπτικό προς την πλειοψηφούσα κατηγορία. Πολλές μελέτες δεν χρησιμοποιούν τεχνικές στάθμισης κατηγοριών ή επαναδειγματοληψίας για την αντιμετώπιση ζητημάτων που σχετίζονται με την ανισορροπία κατηγοριών [6]. Η παρούσα μελέτη διερευνά τη χρήση της στάθμισης κατηγοριών (λειτουργία «ισορροπημένη») ως πιθανή μέθοδο για τη μείωση των επιπτώσεων της ανισορροπίας κατηγοριών.

2.6.3 Αναπαραγωγιμότητα

Η αναπαραγωγή των αποτελεσμάτων από μελέτες στον τομέα της ταξινόμησης φωνής PD μπορεί να είναι δύσκολη λόγω της έλλειψης λεπτομερειών σχετικά με διάφορες πτυχές της έρευνας:

- Παράμετροι εξαγωγής χαρακτηριστικών που δεν έχουν καθοριστεί
- Τυχαία σπόρια που δεν έχουν καθοριστεί
- Ασαφής στρατηγική διασταυρούμενης επικύρωσης
- Διαδικασίες ρύθμισης υπερπαραμέτρων που δεν έχουν τεκμηριωθεί

Η παρούσα μελέτη αντιμετωπίζει τα παραπάνω προβλήματα παρέχοντας σταθερούς τυχαίους σπόρους, τεκμηριώνοντας τις παραμέτρους εξαγωγής χαρακτηριστικών και περιγράφοντας ρητά τα πρωτόκολλα διασταυρούμενης επικύρωσης.

2.6.4 Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων

Η εξωτερική επικύρωση — η δοκιμή ενός μοντέλου σε δεδομένα από μια εντελώς διαφορετική πηγή από το σύνολο εκπαίδευσης — είναι η πιο αυστηρή δοκιμή γενικευσιμότητας, αλλά πραγματοποιείται σε λιγότερο από το 15% των πρόσφατων μελετών φωνής PD [6]. Το αποτέλεσμα είναι ότι περίπου το 70% των μελετών

βασίζονται σε καθαρά εσωτερικές μετρήσεις που είναι πιθανό να υπερεκτιμούν την πραγματική απόδοση. Στις σπάνιες περιπτώσεις όπου έχει πραγματοποιηθεί αξιολόγηση μεταξύ συνόλων δεδομένων, έχουν παρατηρηθεί απότομες πτώσεις στην απόδοση· για παράδειγμα, μοντέλα που πέτυχαν τέλεια ακρίβεια σε ένα μικρό δείκτη αναφοράς υποβαθμίστηκαν σημαντικά όταν δοκιμάστηκαν σε ένα διαφορετικό σώμα δεδομένων [6]. Αυτά τα ευρήματα ενισχύουν την ανάγκη για συντηρητική ερμηνεία των αποτελεσμάτων εντός του δείγματος.

2.6.5 Ερμηνευσιμότητα

Η ερμηνευσιμότητα για κλινική επικύρωση παραμένει μια κρίσιμη αλλά ανεπαρκώς ανεπτυγμένη πτυχή της ταξινόμησης φωνής PD [6]. Μόνο μια μειοψηφία πρόσφατων μελετών χρησιμοποιεί μεθόδους εκ των υστέρων εξήγησης, όπως SHAP ή LIME· αυτές που το κάνουν έχουν εντοπίσει με συνέπεια το jitter, το shimmer και τη μονοτονία του τόνου ως κορυφαίους προγνωστικούς παράγοντες. Η περιορισμένη υιοθέτηση μεθόδων ερμηνευσιμότητας δημιουργεί ένα χάσμα μεταξύ των αποτελεσμάτων του μοντέλου και της κλινικής εφαρμοσιμότητας. Η παρούσα εργασία αντιμετωπίζει αυτό το χάσμα μέσω ανάλυσης αφαίρεσης χαρακτηριστικών και κατάταξης σημασίας χαρακτηριστικών με βάση την αναδιάταξη, παρέχοντας διαφανή εικόνα για το ποια ακουστικά χαρακτηριστικά καθορίζουν τις αποφάσεις ταξινόμησης.

2.7 Έλλειμμα στην έρευνα

Παρά τις πολυάριθμες μελέτες που αναφέρουν υψηλή ακρίβεια ταξινόμησης, λίγες αντιμετωπίζουν τα ακόλουθα:

1. **Ομαδοποιημένη διασταυρούμενη επικύρωση** για σύνολα δεδομένων πολλαπλών εγγραφών
2. **Μελέτες ελεγχόμενης αφαίρεσης χαρακτηριστικών**
3. **Συστηματική ανάλυση στάθμισης κατηγοριών**
4. **Διαφανής τεκμηρίωση** των περιορισμών
5. **Εξωτερική επικύρωση**: η γενίκευση μεταξύ συνόλων δεδομένων σπάνια δοκιμάζεται· η σύγκριση δύο συνόλων δεδομένων στην παρούσα μελέτη (ένα ακατέργαστο ηχητικό και ένα προ-εξαγόμενο) παρέχει κάποια στοιχεία εξωτερικής εγκυρότητας [6]
6. **Ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών**: το SHAP και άλλες μέθοδοι εκ

των υστέρων εξήγησης χρησιμοποιούνται σε λιγότερο από το 10% των μελετών της περιόδου 2020–2025· η παρούσα μελέτη καλύπτει αυτό το κενό μέσω της αφαίρεσης και της ανάλυσης της σημασίας των χαρακτηριστικών [6]

2.8 Περίληψη

Η ανίχνευση PD με βάση τη φωνή είναι δυνατή χρησιμοποιώντας κλασική μηχανική μάθηση σε ακουστικά χαρακτηριστικά, με ανταγωνιστικά αποτελέσματα που αναφέρονται σε πολλαπλά σύνολα δεδομένων. Ωστόσο, πρόσφατες συστηματικές ανασκοπήσεις που καλύπτουν την περίοδο 2019–2025 δείχνουν ότι η μεθοδολογική ποιότητα ποικίλλει σημαντικά στον τομέα αυτό όσον αφορά τις στρατηγικές επικύρωσης, την εξωτερική αξιολόγηση και την ερμηνευσιμότητα των αποτελεσμάτων [6, 7]. Ο τομέας απομακρύνεται επί του παρόντος από τα χειροποίητα ακουστικά χαρακτηριστικά προς ενσωματώσεις βαθιάς μάθησης, αλλά αυτές δεν έχουν ακόμη δείξει σταθερά πλεονεκτήματα στη γενίκευση υπό αυστηρή αξιολόγηση [6]. Ως εκ τούτου, η παρούσα μελέτη χρησιμοποιεί μια συντηρητική προσέγγιση που δίνει προτεραιότητα στην αναπαραγωγικότητα, την αξιολόγηση με γνώμονα το υποκείμενο και τη διαφάνεια στον τρόπο ερμηνείας των αποτελεσμάτων, έναντι της βελτιστοποίησης της απόδοσης.

Κεφάλαιο 3

Περιγραφή δεδομένων

3.1 Σύνολο δεδομένων A: MDVR-KCL

3.1.1 Πηγή και συλλογή

Το σύνολο δεδομένων Mobile Device Voice Recordings from King's College London (MDVR-KCL) [13] συλλέχθηκε ειδικά για την έρευνα της νόσου του Πάρκινσον χρησιμοποιώντας ηχογραφήσεις από smartphone. Το σύνολο δεδομένων είναι διαθέσιμο στο Zenodo με DOI 10.5281/zenodo.2867215.

Πλαίσιο συλλογής

Ιδιότητα	Τιμή
Περίοδος συλλογής	26-29 Σεπτεμβρίου 2017
Τοποθεσία	King's College London Hospital, Denmark Hill, Λονδίνο, Ηνωμένο Βασίλειο
Συσκευή εγγραφής	Smartphone Motorola Moto G4
Περιβάλλον	Κλινική αίθουσα εξετάσεων (~10 m ²)
Χρόνος αντήχησης	~500 ms
Λήψη ήχου	Άμεσο σήμα μικροφώνου (χωρίς συμπίεση GSM)

Table 3.1: Πλαίσιο συλλογής δεδομένων MDVR-KCL

Οι ηχογραφήσεις πραγματοποιήθηκαν εντός της ακτίνας αντήχησης απευθείας από το σήμα του μικροφώνου (χωρίς συμπίεση GSM), με αποτέλεσμα έναν ακουστικά καθαρό ήχο κατάλληλο για εξαγωγή χαρακτηριστικών.

3.1.2 Προδιαγραφές ήχου

Ιδιότητα	Τιμή
Μορφή	WAV (μη συμπιεσμένο PCM)
Εγγενής ρυθμός δειγματοληψίας	44,1 kHz
Ρυθμός δειγματοληψίας επεξεργασίας	22,05 kHz (επαναδειγματοληψία)
Βάθος bit	16-bit υπογεγραμμένος ακέραιος
Κανάλια	Μονοφωνικό
Συμπίεση	Καμία

Table 3.2: Προδιαγραφές ήχου για το σύνολο δεδομένων A

Όλα τα αρχεία ήχου μετατράπηκαν σε συχνότητα δειγματοληψίας 22,05 kHz πριν από την εξαγωγή χαρακτηριστικών. Αυτό έγινε για να υπάρχει συνέπεια στα δεδομένα και να μειωθεί το υπολογιστικό κόστος, χωρίς να χάνεται η απαραίτητη ποιότητα για την ανάλυση της ομιλίας.

3.1.3 Εργασίες ομιλίας

Το σύνολο δεδομένων περιλαμβάνει δύο διακριτές εργασίες ομιλίας που έχουν σχεδιαστεί για να καταγράφουν διαφορετικές πτυχές της φωνητικής παραγωγής:

Εργασία	Περιγραφή	Θέματα	HC	PD
ReadText	Απόσπασμα από το «Ο Βόρειος Άνεμος και ο Ήλιος»	37	21	16
SpontaneousDialogue	Ελεύθερη συνομιλία με τον εξεταστή	36	21	15

Table 3.3: Εργασίες ομιλίας στο σύνολο δεδομένων MDVR-KCL

Σημείωση: Το υποκείμενο ID18 λείπει από την εργασία SpontaneousDialogue, με αποτέλεσμα να υπάρχει μία λιγότερη εγγραφή για αυτή την κατάσταση.

3.1.4 Κατανομή τάξεων

Εργασία ReadText:

++ HC (Υγιείς μάρτυρες): 21 υποκείμενα (56,8%)

++ PD (Νόσος του Πάρκινσον): 16 άτομα (43,2%)

Εργασία SpontaneousDialogue:

++ HC (Υγιής έλεγχος): 21 άτομα (58,3%)

++ PD (Νόσος του Πάρκινσον): 15 άτομα (41,7%)

Αναλογία ανισορροπίας: Μέτρια (~57:43 HC:PD). Διεξήχθησαν πειράματα στάθμισης κατηγοριών για την αξιολόγηση της επίδρασης στην απόδοση της ταξινόμησης.

3.1.5 Γνωστές ανωμαλίες

- **ID18:** Λείπει από την εργασία SpontaneousDialogue (36 άτομα έναντι 37 στην εργασία ReadText).

3.2 Σύνολο δεδομένων B: Χαρακτηριστικά ομιλίας PD

3.2.1 Πηγή

Προ-εξορυσσόμενα ακουστικά χαρακτηριστικά από το UCI Machine Learning Repository, διανεμημένα μέσω Kaggle [14]. Το σύνολο δεδομένων περιέχει 752 ακουστικά χαρακτηριστικά που έχουν υπολογιστεί εκ των προτέρων από παρατεταμένες φωνητικές φωνές.

3.2.2 Πλαίσιο συλλογής

Ιδιότητα	Τιμή
Ίδρυμα	Πανεπιστήμιο Κωνσταντινούπολης, Ιατρική Σχολή Cerrahpaşa
Περίοδος συλλογής	Δεν προσδιορίζεται στα μεταδεδομένα
Συμμετέχοντες με PD	188
Θέματα HC	64
Ηλικιακό εύρος (PD)	33–87 έτη
Ηλικιακό εύρος (HC)	41–82 έτη
Λεκτική εργασία	Παρατεταμένη φώνηση του φωνήεντος /a/
Επαναλήψεις	3 ανά θέμα
Φυσικό ρυθμό δειγματοληψίας	44,1 kHz (αναφέρεται στα μεταδεδομένα)

Table 3.4: Πλαίσιο συλλογής για το σύνολο δεδομένων B

3.2.3 Μορφή δεδομένων

- **Μορφή:** CSV (τιμές διαχωρισμένες με κόμμα)
- **Σειρές:** 756 δείγματα (πολλαπλά ανά υποκείμενο)
- **Στήλες:** 753 συνολικά (752 χαρακτηριστικά + 1 δυαδική ετικέτα)
- **Κωδικοποίηση ετικέτας:** 1 = PD, 0 = HC

- **Αναγνωριστικά υποκειμένων:** Δεν παρέχονται (κρίσιμος περιορισμός)

3.2.4 Κατανομή κλάσεων

Κατηγορία	Δείγματα	Ποσοστό
HC (0)	192	25,4%
PD (1)	564	74,6%

Table 3.5: Κατανομή κλάσεων στο σύνολο δεδομένων B

Αναλογία ανισορροπίας: Σοβαρή ($\sim 25:75$ HC:PD), που απαιτεί στρατηγικές στάθμισης κλάσεων στην εκπαίδευση του μοντέλου.

3.2.5 Κατηγορίες χαρακτηριστικών

Τα 752 χαρακτηριστικά καλύπτουν πολλαπλούς ακουστικούς τομείς που υπολογίστηκαν από τους αρχικούς συγγραφείς:

Κατηγορία	Αριθμός	Περιγραφή
Βασική γραμμή	22	Παραλλαγές jitter, παραλλαγές shimmer, HNR, NHR
Ένταση	3	Ελάχιστη, μέγιστη, μέση ένταση
Φορμάντες	36	Στατιστικά στοιχεία συχνότητας και εύρους ζώνης F_1-F_4
MFCCs	84	Μέσος όρος, τυπική απόκλιση, δέλτα για MFCC 0–12
Wavelet (DWT)	182	Χαρακτηριστικά διακριτής αποσύνθεσης wavelet
TQWT	432	Χαρακτηριστικά μετασχηματισμού wavelet με ρυθμιζόμενο συντελεστή Q
Άλλα	7	PPE, DFA, RPDE, numPulses, GQ, GNE, VFER

Table 3.6: Κατηγορίες χαρακτηριστικών στο σύνολο δεδομένων B (752 συνολικά)

3.2.6 Μεθοδολογικές προειδοποιήσεις

Κρίσιμος περιορισμός: Ένας σημαντικός περιορισμός είναι ότι στο ΣΔ B δεν υπάρχουν αναγνωριστικά υποκειμένων. Αυτό σημαίνει ότι δεν γνωρίζουμε ποια δείγματα ανήκουν στο ίδιο άτομο. Έτσι, κατά τη

διασταυρούμενη επικύρωση, είναι πιθανό δείγματα από το ίδιο άτομο να βρίσκονται και στο σύνολο εκπαίδευσης και στο σύνολο δοκιμής.

Δεδομένου ότι συλλέχθηκαν 756 δείγματα από 252 υποκείμενα (188 PD + 64 HC) με 3 επαναλήψεις το καθένα, η τυπική στρωματοποιημένη διασταυρούμενη επικύρωση 5 πτυχών μπορεί να τοποθετήσει δείγματα από το ίδιο υποκείμενο σε διαφορετικές πτυχές, οδηγώντας σε:

- **Αισιόδοξες εκτιμήσεις απόδοσης** υπερεκτίμηση της γενίκευσης (τα αποτελέσματα φαίνονται καλύτερα από ό,τι είναι στην πράξη)
- **Παραβίαση της υπόθεσης ανεξαρτησίας** μεταξύ εκπαίδευσης και δοκιμής (τα δείγματα δεν είναι πραγματικά ανεξάρτητα, καθώς προέρχονται από τα ίδια άτομα)
- **Αδυναμία αξιολόγησης της γενίκευσης σε νέο άτομο** (δεν μπορούμε να πούμε πόσο καλά θα λειτουργούσε το μοντέλο σε ένα νέο άτομο που δεν έχει δει ποτέ πριν)

Τα αποτελέσματα στο σύνολο δεδομένων B πρέπει να ερμηνεύονται με προσοχή, λαμβάνοντας υπόψη αυτούς τους περιορισμούς. Επιπλέον: Δεν υπάρχει πρόσβαση στον αρχικό (ακατέργαστο) ήχο, οπότε δεν μπορούμε να ελέγξουμε ή να προσθέσουμε νέα χαρακτηριστικά. Τα δεδομένα περιλαμβάνουν μόνο παρατεταμένη φώνηση φωνηέντων και όχι φυσική, συνεχόμενη ομιλία, άρα δεν αντικατοπτρίζουν πλήρως την καθημερινή ομιλία. Το σύνολο περιλαμβάνει 752 χαρακτηριστικά, αριθμός που σε σχέση με το διαθέσιμο μέγεθος δείγματος μπορεί να οδηγήσει σε overfitting.

3.3 Σύγκριση μεταξύ συνόλων δεδομένων

3.3.1 Βασικές διαφορές

Πτυχή	Σύνολο δεδομένων A	Σύνολο δεδομένων B
Μορφή δεδομένων	Ακατέργαστος ήχος (WAV)	Προεξάχθέντα χαρακτηριστικά
Μέγεθος δείγματος	37 άτομα (73 ηχογραφήσεις)	756 σειρές (άγνωστα άτομα)
Παρακολούθηση ατόμων	Διαθέσιμη	Μη διαθέσιμη
Διαστατικότητα χαρακτηριστικών	47 (βασική γραμμή) ή 78 (επεκταμένη)	752 (σταθερή)
Εργασία ομιλίας	Ανάγνωση κειμένου / Διάλογος	Συνεχής φώνηση /a/
Εξαγωγή χαρακτηριστικών	Ελεγχόμενη (αυτή η εργασία)	Προϋπολογισμένη (μαύρο)
Διασταυρούμενη επικύρωση	Ομαδοποιημένη (επίπεδο υποκειμένου)	Τυπική (επίπεδο σειράς)
Κλινικά μεταδεδομένα	H&Y, UPDRS διαθέσιμα	Κανένα

Table 3.7: Λεπτομερής σύγκριση μεταξύ συνόλων δεδομένων

Κεφάλαιο 4

Μεθοδολογία

4.1 Διαδικασία εξαγωγής χαρακτηριστικών

4.1.1 Αρχιτεκτονική διαδικασίας

Η διαδικασία εξαγωγής χαρακτηριστικών μετατρέπει τον ακατέργαστο ήχο σε δομημένα διανύσματα χαρακτηριστικών κατάλληλα για μηχανική μάθηση:




Figure 4.1: Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.

4.1.2 Προεπεξεργασία ήχου

Όλα τα αρχεία ήχου υποβλήθηκαν στην ίδια διαδικασία προεπεξεργασίας, ώστε η εξαγωγή χαρακτηριστικών να γίνει με συνέπεια:

1. **Φόρτωση ήχου** με τον αρχικό ρυθμό δειγματοληψίας χρησιμοποιώντας

```
librosa.load()
```

2. **Επαναδειγματοληψία** στα 22.050 Hz (σταθερή σε όλες τις ηχογραφήσεις)
3. **Μετατροπή σε μονοφωνικό** αν το αρχείο ήταν στερεοφωνικό (μέσος όρος των δύο καναλιών).
4. **Κανονικοποίηση πλάτους** στο εύρος $[-1, 1]$
5. **Αφαίρεση σιωπής** χρησιμοποιώντας ανίχνευση βάσει ενέργειας (threshold 5% της μέγιστης ενέργειας)

Ο ρυθμός 22.050 Hz επιλέχθηκε γιατί είναι επαρκής για ανάλυση ομιλίας (Nyquist 11.025 Hz) και ταυτόχρονα μειώνει το υπολογιστικό κόστος σε σχέση με τα 44.100 Hz.

4.1.3 Προσωδιακά χαρακτηριστικά (21 χαρακτηριστικά)

Τα προσωδιακά χαρακτηριστικά περιγράφουν στοιχεία της φωνής που επηρεάζονται συχνά από τη νόσο του Πάρκινσον. Η εξαγωγή έγινε με το Parselmouth (Praat).

Θεμελιώδης συχνότητα (F_0)

Για την εξαγωγή του τόνου χρησιμοποιήθηκαν οι ακόλουθες παράμετροι:

- **Αλγόριθμος:** Βασισμένος στην αυτοσυσχέτιση (προεπιλογή του Praat)
- **Εύρος τόνου:** 75–500 Hz (καλύπτει ανδρικές, γυναικείες και παθολογικές φωνές)
- **Χρονικό βήμα:** 0,01 s (πρότυπο για την ανάλυση φωνής)

Τέσσερα στατιστικά στοιχεία υπολογίστηκαν από το περίγραμμα του τόνου:

$$F_0 = \{\mu_{F_0}, \sigma_{F_0}, \min_{F_0}, \max_{F_0}\} \quad (4.1)$$

Jitter

Το Jitter μετρά τη διακύμανση της περιόδου του τόνου από κύκλο σε κύκλο.

$$\text{Jitter}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|T_i - T_{i+1}|}{\bar{T}} \quad (4.2)$$

όπου T_i είναι η i -η περίοδος τόνου και $\bar{T}$ είναι η μέση περίοδος.

Πρόσθετα μέτρα περιλαμβάνουν:

- **RAP (Σχετική Μέση Διαταραχή):** εξομάλυνση 3 σημείων
- **PPQ5:** πηλίκο διαταραχής περιόδου 5 σημείων

Shimmer

Το Shimmer μετρά τη διακύμανση της έντασης από κύκλο σε κύκλο.

$$\text{Shimmer}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|A_i - A_{i+1}|}{\bar{A}} \quad (4.3)$$

όπου A_i είναι το i -οστό μέγιστο πλάτος και $\bar{A}$ είναι το μέσο πλάτος.

Πρόσθετα μέτρα περιλαμβάνουν APQ3, APQ5, APQ11 (συντελεστές διαταραχής πλάτους με μεταβαλλόμενα παράθυρα) και DDA (διαφορά των διαφορών των πλατών).

Αναλογία αρμονικών προς θόρυβο (HNR)

Το HNR δείχνει πόσο «καθαρή» είναι η φωνή (αρμονικές έναντι θορύβου).

- **Μέση HNR:** Μέση HNR (dB)
- **Αυτοσυσχέτιση αρμονικότητας:** Μέγιστη τιμή αυτοσυσχέτισης

Ένταση

Τρεις στατιστικές έντασης (dB SPL):

$$I = \{\mu_I, \sigma_I, \max_I - \min_I\} \quad (4.4)$$

Formants

Τα τρία πρώτα formants (F_1 , F_2 , F_3) εξήχθησαν χρησιμοποιώντας γραμμική προβλεπτική κωδικοποίηση (LPC):

- **Σειρά LPC:** τάξης 10 (επαρκής για 3 formants στα 22 kHz)
- **Χαρακτηριστικά:** Μέσος όρος και τυπική απόκλιση κάθε φωνητικού στοιχείου (6 χαρακτηριστικά συνολικά)

Ομάδα χαρακτηριστικών	Αριθμός	Χαρακτηριστικά	Εργαλείο
Τόνος (F_0)	4	μέσος όρος, τυπική απόκλιση, ελάχιστο, μέγιστο	Parselmouth
Jitter	3	τοπικό, RAP, PPQ5	Parselmouth
Shimmer	5	τοπικό, APQ3, APQ5, APQ11, DDA	Parselmouth
Αρμονικότητα	2	μέσος όρος HNR, αυτοσυσχέτιση	Parselmouth
Intensity	3	μέσος όρος, τυπική απόκλιση, εύρος	Parselmouth
Formants	6	F_1-F_3 μέσος όρος, F_1-F_3 τυπική απόκλιση	Parselmouth
Σύνολο	21		

Table 4.1: Ανάλυση προσωδιακών χαρακτηριστικών

4.1.4 Φασματικά χαρακτηριστικά

Τα φασματικά χαρακτηριστικά περιγράφουν τη δομή του φάσματος συχνοτήτων της φωνής και εξήχθησαν χρησιμοποιώντας τη βιβλιοθήκη `librosa` [20].

Συντελεστές Mel-Frequency Cepstral (MFCC)

Οι MFCC υπολογίζονται μέσω των ακόλουθων βημάτων:

1. **Προέμφαση:** $y[n] = x[n] - 0,97 \cdot x[n - 1]$
2. **Πλαίσιο:** Μήκος παραθύρου = 2048 δείγματα (≈ 93 ms στα 22 kHz)
3. **Παράθυρο:** Εφαρμογή παραθύρου Hann
4. **FFT:** FFT 2048 σημείων
5. **Φίλτρο Mel:** 128 τριγωνικά φίλτρα που καλύπτουν 0–11.025 Hz
6. **Συμπίεση λογαρίθμου:** $\log(\text{mel power spectrum})$
7. **DCT:** Διακριτός μετασχηματισμός συνημιτόνου που χρησιμοποιείται για τη μείωση της συσχέτισης μεταξύ των συντελεστών

Παράμετροι που χρησιμοποιήθηκαν:

- **Αριθμός συντελεστών:** 13 (MFCC 0–12)
- **Μήκος άλματος:** 512 δείγματα (≈ 23 ms στα 22 kHz, 75% επικάλυψη)
- **Αριθμός ζωνών mel:** 128

Ο MFCC 0 (ο μηδενικός συντελεστής) περιγράφει κυρίως την ενέργεια του σήματος, ενώ οι MFCC 1–12 αποτυπώνουν το σχήμα του φασματικού περιβλήματος της φωνής.

Συντελεστές δέλτα

Οι χρονικές παράγωγοι πρώτης τάξης (συντελεστές δέλτα) καταγράφουν τη φασματική δυναμική:

$$\Delta_t[n] = \frac{\sum_{i=1}^N i \cdot (c_{t+i} - c_{t-i})}{2 \sum_{i=1}^N i^2} \quad (4.5)$$

όπου c_t είναι ο συντελεστής MFCC στο πλαίσιο t και $N = 2$ είναι το μέγεθος του παραθύρου.

Βασικά φασματικά χαρακτηριστικά (26 χαρακτηριστικά)

Το βασικό σύνολο φασματικών χαρακτηριστικών αποτελείται από:

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Σύνολο	26	

Table 4.2: Βασικά φασματικά χαρακτηριστικά

Εκτεταμένα φασματικά χαρακτηριστικά (57 χαρακτηριστικά)

Το εκτεταμένο σύνολο χαρακτηριστικών περιλαμβάνει τρεις επιπλέον ομάδες, οι οποίες στοχεύουν να αποτυπώσουν περισσότερη φασματική και χρονική μεταβλητότητα της φωνής.

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
MFCC std	13	Χρονική τυπική απόκλιση (μεταβλητότητα εντός της εκφώνησης)
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Μέσος όρος Delta-Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων δεύτερης τάξης (επιτάχυνση)
Φασματικό σχήμα	5	Κέντρο βάρους, εύρος ζώνης, rolloff, επιπεδότητα, ZCR
Σύνολο	57	

Table 4.3: Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)

Οι πέντε περιγραφείς φασματικού σχήματος είναι:

1. **Φασματικό κέντρο βάρους:** Το «κέντρο μάζας» του φάσματος, δηλαδή το σημείο όπου συγκεντρώνεται η περισσότερη ενέργεια (σε Hz)
2. **Φασματικό εύρος ζώνης:** Πόσο απλώνεται το φάσμα γύρω από το κέντρο βάρους (σε Hz).
3. **Φασματική απόκλιση:** Η συχνότητα κάτω από την οποία βρίσκεται το 85% της συνολικής ενέργειας του σήματος (Hz)
4. **Φασματική επιπεδότητα:** Δείκτης του πόσο «τονική» ή «θορυβώδης» είναι η φωνή (λόγος γεωμετρικού προς αριθμητικό μέσο όρο).
5. **Ρυθμός διέλευσης από το μηδέν:** Πόσο συχνά το σήμα αλλάζει πρόσημο στο χρονικό πεδίο, δηλαδή πόσες φορές περνά από το μηδέν.

4.1.5 Συνολικός αριθμός χαρακτηριστικών

Διαμόρφωση	Προσωδιακά	Φασματικά	Σύνολο
Βασική γραμμή	21	26	47
Εκτεταμένα	21	57	78

Table 4.4: Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση

4.2 Σύγκριση συνόλου χαρακτηριστικών

4.2.1 Λόγοι για τα εκτεταμένα χαρακτηριστικά

Το εκτεταμένο σύνολο χαρακτηριστικών σχεδιάστηκε ως μία **ελεγχόμενη δοκιμή**, για να εξεταστεί αν η προσθήκη περισσότερης χρονικής και φασματικής πληροφορίας βελτιώνει την απόδοση της ταξινόμησης.

Προστέθηκαν τρεις ομάδες χαρακτηριστικών:

1. **MFCC std (13):** Μετρά τη μεταβλητότητα των MFCC μέσα σε κάθε ηχογράφηση. Αυτό είναι σημαντικό, γιατί η ομιλία σε ασθενείς με PD μπορεί να παρουσιάζει μεγαλύτερη αστάθεια.
2. **Delta-Delta MFCC (13):** Καταγράφει πόσο γρήγορα αλλάζουν τα φασματικά χαρακτηριστικά με τον χρόνο. Είναι ευαίσθητο στις χρονικές δυναμικές και στις αλλαγές της άρθρωσης.
3. **Φασματικό σχήμα (5):** Προσθέτουν γενικούς δείκτες του φάσματος (π.χ. τονικότητα, διασπορά), που δεν περιγράφονται πλήρως από τα MFCC.

4.2.2 Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών

Για να διασφαλιστεί η αναπαραγωγιμότητα, όλες οι βασικές παράμετροι ορίστηκαν από την αρχή σε κεντρικό αρχείο ρυθμίσεων (configuration file). Συγκεκριμένα:

- Τυχαίος σπόρος: 42
- Ρυθμός δειγματοληψίας: 22 050 Hz
- Εύρος F_0 : 75–500 Hz
- 13 MFCCs
- FFT 2048 σημείων
- Hop length: 512 δείγματα
- 128 mel bands

Όλα τα εξαγόμενα χαρακτηριστικά αποθηκεύτηκαν σε αρχεία CSV και χρησιμοποιήθηκαν στα επόμενα πειράματα χωρίς περαιτέρω αλλαγές.

4.3 Μοντέλα μηχανικής μάθησης

4.3.1 Προδιαγραφές μοντέλου

Επιλέχθηκαν πέντε κλασικά μοντέλα μηχανικής μάθησης, ώστε να καλυφθούν διαφορετικοί τρόποι μάθησης:

- **Λογιστική Παλινδρόμηση:** ένα απλό γραμμικό μοντέλο με κανονικοποίηση L2.
- **SVM με πυρήνα RBF:** μη γραμμική μέθοδος που μπορεί να μάθει πιο σύνθετα όρια απόφασης.
- **Random Forest:** σύνολο δέντρων απόφασης που προσφέρει και εκτίμηση σημασίας χαρακτηριστικών.
- **Gradient Boosting [21]:** μοντέλο που βελτιώνει σταδιακά τα λάθη των προηγούμενων βημάτων.
- **XGBoost [22]:** βελτιστοποιημένη και κανονικοποιημένη εκδοχή του boosting.

Όλες οι υπερπαράμετροι ορίστηκαν εκ των προτέρων (*a priori*) και δεν προσαρμόστηκαν ειδικά για κάποιο συγκεκριμένο σύνολο δεδομένων:

Μοντέλο	Τύπος	Βασικές παράμετροι
Λογιστική παλινδρόμηση	Γραμμική	$C = 1.0$ (κανονικοποίηση L2), max_iter= 1000, solver='lbfgs'
SVM (RBF)	Πυρήνας	$C = 1.0$ (κανονικοποίηση), gamma='scale' (αυτόματη κλιμάκωση ανά χαρακτηριστικά), kernel='rbf'
Random Forest	Bagging	n_estimators= 100, max_depth= 10, min_samples_split= 2, random_state= 42
Gradient Boosting	Boosting	n_estimators= 100, learning_rate= 0.1, max_depth= 3 (προεπιλογή), random_state= 42
XGBoost	Boosting	n_estimators= 100, learning_rate= 0.1, eval_metric='logloss', random_state= 42

Table 4.5: Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.

Λογιστική παλινδρόμηση

Το μοντέλο λογιστικής παλινδρόμησης προβλέπει τις πιθανότητες κλάσης μέσω:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (4.6)$$

με κανονικοποίηση L2:

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n \log(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)}) + \frac{1}{2} \|\mathbf{w}\|_2^2 \right] \quad (4.7)$$

όπου $C = 1,0$ ελέγχει την ισχύ της κανονικοποίησης.

Μηχανή Υποστήριξης Διανυσμάτων

Ο πυρήνας RBF SVM μαθαίνει ένα μη γραμμικό όριο απόφασης μέσω:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (4.8)$$

όπου $\gamma = \frac{1}{n_{\text{features}} \cdot \text{Var}(\mathbf{X})}$ (αυτόματη κλιμάκωση).

Random Forest

Το Random Forest συγκεντρώνει προβλέψεις από 100 δέντρα αποφάσεων:

$$\hat{y} = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \hat{y}_t(\mathbf{x}) \quad (4.9)$$

Κάθε δέντρο εκπαιδεύεται σε ένα τυχαίο δείγμα των δεδομένων (bootstrap) και σε κάθε διαχωρισμό χρησιμοποιεί ένα τυχαίο υποσύνολο χαρακτηριστικών.

Το μέγιστο βάθος 10 επιλέχθηκε ώστε να περιοριστεί η υπερπροσαρμογή (overfitting), ιδιαίτερα λόγω του μικρού μεγέθους των συνόλων δεδομένων.

Gradient Boosting

Το Gradient Boosting δημιουργεί το μοντέλο βήμα-βήμα, όπου κάθε νέο δέντρο προσπαθεί να διορθώσει τα λάθη που έκαναν τα προηγούμενα δέντρα [21]:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}) \quad (4.10)$$

όπου F_m είναι το σύνολο μετά από m στάδια, h_m είναι ο αδύναμος μαθητής (δέντρο αποφάσεων) προσαρμοσμένος στην αρνητική κλίση της συνάρτησης απώλειας και $\eta = 0,1$ είναι ο ρυθμός μάθησης. Ο ρυθμός μάθησης μειώνει τη συμβολή κάθε δέντρου, παρέχοντας αποτέλεσμα κανονικοποίησης.

XGBoost

Το XGBoost [22] είναι μια βελτιωμένη εκδοχή του Gradient Boosting, η οποία προσθέτει κανονικοποίηση L1 και L2 στα βάρη των φύλλων των δέντρων, ώστε να μειώνει την υπερπροσαρμογή και να βελτιώνει τη γενίκευση.

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(\hat{y}_i, y_i) + \sum_{k=1}^K \Omega(f_k), \quad \text{where } \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \quad (4.11)$$

Εδώ T είναι ο αριθμός των φύλλων, $\mathbf{w}$ είναι το διάνυσμα των βαρών φύλλων και γ, λ είναι παράμετροι κανονικοποίησης. Αυτή η κανονικοποίηση βοηθά στην αποφυγή της υπερπροσαρμογής, η οποία είναι ιδιαίτερα σημαντική για σύνολα δεδομένων μικρού μεγέθους.

4.3.2 Στάθμιση βαρύτητας κλάσης

Η ανισορροπία κλάσης αντιμετωπίζεται μέσω της παραμέτρου `class_weight`:

```
1 # Χωρίς στάθμιση βασική (συνθήκη)
2 class_weight = None
3
4 # Με στάθμιση ισορροπημένη (συνθήκη)
5 class_weight = "balanced" #  $w_k = n_{\text{samples}} / (n_{\text{classes}} * n_k)$ 
```

Όταν `class_weight="balanced"`, οι βαρύτητες των δειγμάτων υπολογίζονται ως εξής:

$$w_k = \frac{n_{\text{samples}}}{n_{\text{classes}} \cdot n_k} \quad (4.12)$$

όπου n_k είναι ο αριθμός των δειγμάτων στην κλάση k . Αυτό εξασφαλίζει ότι τα σφάλματα της μειοψηφικής κλάσης σταθμίζονται περισσότερο κατά τη διάρκεια της εκπαίδευσης.

Τρία από τα πέντε μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest) υποστηρίζουν εγγενώς την παράμετρο `class_weight` μέσω του `scikit-learn`. Οι δύο

ταξινομητές ενίσχυσης (Gradient Boosting και XGBoost) δεν υποστηρίζουν εγγενώς το `class_weight="balanced"`. Ωστόσο, δεδομένου ότι η ήπια ανισορροπία κλάσεων (1,3:1) δεν απαιτούσε επαναστάθμιση στην πράξη (βλ. Κεφάλαιο 6), αυτή η διαφορά δεν έχει καμία επίδραση στο σχεδιασμό του πειράματος.

4.4 Αρχιτεκτονική ML Pipeline

4.4.1 Δομή Pipeline

Όλα τα μοντέλα χρησιμοποιούν ένα τυποποιημένο scikit-learn Pipeline:

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3
4 pipeline = Pipeline([
5     ('scaler', StandardScaler()),
6     ('classifier', Model(class_weight=..., random_state=42))
7 ])
```

Αυτό εξασφαλίζει ότι η κλιμάκωση χαρακτηριστικών εφαρμόζεται με συνέπεια και αποτρέπει τη διαρροή δεδομένων.

4.4.2 Τυποποίηση χαρακτηριστικών

Τα χαρακτηριστικά κανονικοποιούνται ώστε να έχουν μέση τιμή 0 και τυπική απόκλιση 1 (StandardScaler).

Η κανονικοποίηση υπολογίζεται μόνο στα δεδομένα εκπαίδευσης μέσα σε κάθε διαχωρισμό του k-fold cross-validation, ώστε να μη χρησιμοποιούνται πληροφορίες από το test set και να αποφεύγεται η διαρροή δεδομένων.

4.5 Πλαίσιο αξιολόγησης

4.5.1 Στρατηγική Cross-Validation

Σε αυτή τη εργασία, η **διασταυρούμενη επικύρωση K -fold αποτελεί την κύρια στρατηγική αξιολόγησης**: το μοντέλο εκπαιδεύεται σε $K - 1$ folds και αξιολογείται στο εναπομείναν fold, το οποίο περιλαμβάνει μόνο δείγματα που δεν έχουν χρησιμοποιηθεί ούτε στην εκπαίδευση ούτε στην εξόρυξη χαρακτηριστικών [15]. Η διαδικασία επαναλαμβάνεται $K = 5$ φορές, παρέχοντας πέντε ανεξάρτητες εκτιμήσεις

της απόδοσης γενίκευσης. Δεν χρησιμοποιήθηκε ξεχωριστό σύνολο δοκιμής, καθώς με μόνο $n = 37$ υποκείμενα (σύνολο δεδομένων A), η δέσμευση ακόμη και του 20% για test set θα οδηγούσε σε περίπου επτά υποκείμενα δοκιμής ανά διαχωρισμό σε επίπεδο υποκειμένου, αριθμός ανεπαρκής για σταθερή εκτίμηση.

Η 5-fold CV χρησιμοποιείται αποκλειστικά ως **μηχανισμός αξιολόγησης** και όχι ως μηχανισμός ρύθμισης. Έτσι αποφεύγεται οποιοσδήποτε κίνδυνος προσαρμογής των υπερπαραμέτρων στα δεδομένα αξιολόγησης.

Απαιτήθηκαν διαφορετικές στρατηγικές επικύρωσης για κάθε σύνολο δεδομένων, λόγω των δομικών διαφορών που παρουσιάζουν.

Σύνολο δεδομένων	Στρατηγική	Πτυχές	Ομαδοποίηση
Σύνολο δεδομένων A (MDVR-KCL)	Ομαδοποιημένο στρωματοποιημένο	5	Ανά subject_id
Σύνολο δεδομένων B (PD Speech)	Στρωματοποιημένο	5	Καμία (μη διαθέσιμα)

Table 4.6: Στρατηγικές διασταυρούμενης επικύρωσης

Σύνολο δεδομένων A: Ομαδοποιημένη διασταυρούμενη επικύρωση

Για το σύνολο δεδομένων A (MDVR-KCL), υπάρχουν πολλές εγγραφές από το ίδιο άτομο. Για να μην υπάρξει διαρροή δεδομένων, έγινε διαχωρισμός σε επίπεδο υποκειμένου. Αυτό σημαίνει ότι:

- Όλες οι εγγραφές του ίδιου ατόμου μπαίνουν στο ίδιο fold
- Υπάρχει περίπου ισορροπία μεταξύ των κλάσεων
- Το μοντέλο δεν βλέπει ποτέ δεδομένα από άτομα που βρίσκονται στο σύνολο δοκιμής

Έτσι προσομοιώνεται μια ρεαλιστική κατάσταση, όπου το μοντέλο αξιολογείται σε νέους ομιλητές.

Σύνολο δεδομένων B: Τυπική cross-validation

Στο σύνολο δεδομένων B δεν υπάρχουν αναγνωριστικά υποκείμενων. Για αυτό χρησιμοποιήθηκε τυπική 5-fold cross-validation. Ωστόσο, τα αποτελέσματα μπορεί να είναι πιο αισιόδοξα, αν δείγματα του ίδιου ατόμου βρίσκονται σε διαφορετικά folds.

4.5.2 Μετρήσεις αξιολόγησης

Υπολογίστηκαν πέντε βασικές μετρήσεις ταξινόμησης σε κάθε fold:

Μέτρηση	Τύπος	Ερμηνεία
Ακρίβεια	$\frac{TP+TN}{TP+TN+FP+FN}$	Ποσοστό σωστών προβλέψεων συνολικά
Προβλεψιμότητα	$\frac{TP}{TP+FP}$	Από τις προβλέψεις PD, πόσες ήταν σωστές
Ανάκληση	$\frac{TP}{TP+FN}$	Από τα πραγματικά PD, πόσα βρέθηκαν σωστά
Βαθμολογία F1	$\frac{2 \cdot P \cdot R}{P+R}$	Ισορροπία μεταξύ προβλεψιμότητας και ανάκλησης
ROC-AUC	$\int_0^1 \text{TPR}(t) d\text{FPR}(t)$	Ικανότητα διάκρισης ανεξάρτητα από threshold

Table 4.7: Μετρήσεις αξιολόγησης

Κύρια μέτρηση: Επιλέχθηκε το ROC-AUC γιατί:

- δεν εξαρτάται από ένα συγκεκριμένο threshold,
- είναι πιο σταθερό όταν οι κλάσεις δεν είναι ισορροπημένες,
- έχει σαφή ερμηνεία (πιθανότητα ένας τυχαίος PD να έχει υψηλότερη βαθμολογία από έναν τυχαίο HC).

Κεφάλαιο 5

Σχεδιασμός πειράματος

5.1 Ερευνητικά ερωτήματα

Τα πειράματα εξετάζουν τα παρακάτω ερωτήματα:

- RQ1:** Πόσο καλά αποδίδουν τα κλασικά μοντέλα ML στην αναγνώριση PD από φωνητικά χαρακτηριστικά;
- RQ2:** Βελτιώνεται η απόδοση όταν αυξάνονται τα χαρακτηριστικά από 47 σε 78;
- RQ3:** Βοηθά η ισορροπημένη στάθμιση κλάσεων σε μη ισορροπημένα δεδομένα;
- RQ4:** Υπάρχουν διαφορές στα αποτελέσματα μεταξύ του συνόλου δεδομένων A (CV σε επίπεδο υποκειμένου) και του συνόλου δεδομένων B (τυπικό CV);
- RQ5:** Υπάρχει διαφορά στην απόδοση μεταξύ ανάγνωσης και αυθόρμητης ομιλίας;

5.2 Πειραματικός πίνακας

5.2.1 $2 \times 2 \times 5$ Παραγοντικός σχεδιασμός

Ο σχεδιασμός περιλαμβάνει τρεις παράγοντες:

1. **Σύνολο χαρακτηριστικών:** 47 (baseline) ή 78 (extended)
2. **Στάθμιση κλάσεων:** χωρίς ή με ισορροπημένη στάθμιση
3. **Μοντέλο:** LR, SVM (RBF), RF, Gradient Boosting, XGBoost

Συνολικά: $2 \times 2 \times 5 = 20$ συνθήκες για κάθε dataset/εργασία.

ID	Χαρακτηριστικά	Στάθμιση	Μοντέλα	Έξοδος
C1	47	Καμία	LR, SVM, RF, GB, XGB	baseline/baseline/
C2	78	Καμία	LR, SVM, RF, GB, XGB	baseline/extended/
C3	47	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/baseline/
C4	78	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/extended/

Table 5.1: Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.

5.2.2 Συνολικές πειραματικές εκτελέσεις

Dataset/Εργασία	Συνθήκες	Μοντέλα	CV Folds	Σύνολο
Dataset A - ReadText	4	5	5	100
Dataset A - SpontaneousDialogue	4	5	5	100
Dataset B - PD Speech	4	5	5	100
Σύνολο				300

Table 5.2: Συνολικός αριθμός πειραμάτων

5.3 Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα

Χρησιμοποιήθηκε 5-fold cross-validation (σε επίπεδο υποκειμένου για το Dataset A και στρωματοποιημένο για το Dataset B). Όλα τα πειράματα εκτελέστηκαν με `random_state=42` για αναπαραγωγιμότητα.

Τα αποτελέσματα του Dataset B πρέπει να εξετάζονται με προσοχή λόγω της έλλειψης αναγνωριστικών υποκειμένων (βλ. ενότητα 8.2.1). Οι περιορισμοί παρουσιάζονται στο κεφάλαιο 8.

Κεφάλαιο 6

Αποτελέσματα

6.1 Σύνοψη των καλύτερων αποτελεσμάτων

6.1.1 Σύνολο δεδομένων A (MDVR-KCL) — Καλύτερη απόδοση

Μέτρηση	Τιμή	Μοντέλο	Task	Συνθήκη
ROC-AUC	$0,857 \pm 0,171$	Random Forest	Spontaneous	Εκτεταμένο / Μη σταθμισμένο
Ακρίβεια	$82,2\% \pm 16,6\%$	Random Forest	ReadText	Εκτεταμένο / Μη σταθμισμένο

Table 6.1: Καλύτερη απόδοση στο σύνολο δεδομένων A

6.1.2 Σύνολο δεδομένων B (Σύγκριση αναφοράς)

Περίληψη απόδοσης: Το σύνολο δεδομένων B έδωσε σημαντικά υψηλότερες επιδόσεις σε όλα τα μοντέλα (βλ. Πίνακα 6.2). Ωστόσο, τα αποτελέσματα πρέπει να εξεταστούν με προσοχή, καθώς δεν γνωρίζουμε αν τα ίδια άτομα εμφανίζονται τόσο στην εκπαίδευση όσο και στη δοκιμή.

Μοντέλο	ROC-AUC	Ακρίβεια	F1	Ανάκληση
Λογιστική παλινδρόμηση	$0,867 \pm 0,029$	$0,828 \pm 0,008$	$0,885 \pm 0,006$	$0,890 \pm 0,016$
SVM (RBF)	$0,885 \pm 0,025$	$0,851 \pm 0,024$	$0,908 \pm 0,015$	$0,986 \pm 0,019$
Random Forest	$0,940 \pm 0,013$	$0,882 \pm 0,019$	$0,925 \pm 0,012$	$0,980 \pm 0,015$
Gradient Boosting	$0,937 \pm 0,019$	$0,884 \pm 0,024$	$0,926 \pm 0,015$	$0,980 \pm 0,013$
XGBoost	$0,952 \pm 0,015$	$0,896 \pm 0,017$	$0,933 \pm 0,011$	$0,980 \pm 0,017$

Table 6.2: Απόδοση του συνόλου δεδομένων B χρησιμοποιώντας τη βασική (μη σταθμισμένη) διαμόρφωση. Σημειώστε τη σημαντικά χαμηλότερη διακύμανση σε σύγκριση με το σύνολο δεδομένων A.




Figure 6.1: Σημαντικότητα χαρακτηριστικών Random Forest (σύνολο δεδομένων B). Τα κορυφαία χαρακτηριστικά κυριαρχούνται από προηγμένες μετρήσεις επεξεργασίας σήματος που συχνά δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.

Βασικές διαφορές από το σύνολο δεδομένων A:

- **Μέγεθος δείγματος:** Το Dataset B έχει πολύ περισσότερα δείγματα ($n = 752$) σε σχέση με το Dataset A ($n = 37$), κάτι που μειώνει σημαντικά τη διακύμανση των αποτελεσμάτων.
- **Πιθανή αισιόδοξη εκτίμηση:** Η απόδοση μπορεί να φαίνεται υψηλότερη από την πραγματική, λόγω πιθανής επικάλυψης υποκειμένων.

- **Διαφορετικά χαρακτηριστικά:** Περιλαμβάνει πιο σύνθετα χαρακτηριστικά που δεν υπάρχουν στο Dataset A.

6.2 Συνθήκη 1: Βασικά χαρακτηριστικά + χωρίς στάθμιση

Διαμόρφωση: 47 χαρακτηριστικά, χωρίς στάθμιση κλάσης

6.2.1 Task: ReadText

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	$0,717 \pm 0,139$	$0,621 \pm 0,058$	$0,542 \pm 0,099$
SVM (RBF)	$0,614 \pm 0,312$	$0,621 \pm 0,106$	$0,333 \pm 0,333$
Random Forest	$0,590 \pm 0,302$	$0,629 \pm 0,178$	$0,351 \pm 0,363$
Gradient Boosting	$0,500 \pm 0,159$	$0,464 \pm 0,134$	$0,374 \pm 0,221$
XGBoost	$0,628 \pm 0,203$	$0,518 \pm 0,132$	$0,371 \pm 0,262$

Table 6.3: Συνθήκη 1 — Αποτελέσματα ReadText

6.2.2 Task: Spontaneous dialogue

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	$0,760 \pm 0,214$	$0,639 \pm 0,160$	$0,539 \pm 0,321$
SVM (RBF)	$0,407 \pm 0,309$	$0,636 \pm 0,135$	$0,400 \pm 0,253$
Random Forest	$0,828 \pm 0,148$	$0,721 \pm 0,176$	$0,567 \pm 0,365$
Gradient Boosting	$0,615 \pm 0,078$	$0,664 \pm 0,133$	$0,583 \pm 0,118$
XGBoost	$0,723 \pm 0,197$	$0,668 \pm 0,121$	$0,470 \pm 0,323$

Table 6.4: Συνθήκη 1 — Αποτελέσματα Spontaneous dialogue

6.3 Συνθήκη 2: Εκτεταμένα χαρακτηριστικά + Χωρίς στάθμιση

Διαμόρφωση: 78 χαρακτηριστικά, χωρίς στάθμιση κλάσης

6.3.1 Task: ReadText

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	$0,698 \pm 0,132$	$0,596 \pm 0,079$	$0,475 \pm 0,106$
SVM (RBF)	$0,834 \pm 0,153$	$0,786 \pm 0,181$	$0,634 \pm 0,386$
Random Forest	$0,822 \pm 0,166$	$0,818 \pm 0,140$	$0,746 \pm 0,207$
Gradient Boosting	$0,724 \pm 0,214$	$0,654 \pm 0,138$	$0,605 \pm 0,184$
XGBoost	$0,794 \pm 0,186$	$0,739 \pm 0,195$	$0,691 \pm 0,252$

Table 6.5: Συνθήκη 2 — Αποτελέσματα ReadText




Figure 6.2: Σημασία χαρακτηριστικών Random Forest για το Task ReadText (εκτεταμένα χαρακτηριστικά). Οι στατιστικές της θεμελιώδους συχνότητας (F_0) φαίνονται ιδιαίτερα προγνωστικές.

6.3.2 Task: Spontaneous dialogue

Μοντέλο	ROC-AUC	Ακρίβεια	F1
Λογιστική παλινδρόμηση	$0,783 \pm 0,139$	$0,671 \pm 0,199$	$0,530 \pm 0,377$
SVM (RBF)	$0,460 \pm 0,294$	$0,636 \pm 0,089$	$0,428 \pm 0,258$
Random Forest	$0,857 \pm 0,171$	$0,779 \pm 0,161$	$0,605 \pm 0,387$
Gradient Boosting	$0,638 \pm 0,146$	$0,636 \pm 0,221$	$0,547 \pm 0,222$
XGBoost	$0,687 \pm 0,146$	$0,693 \pm 0,123$	$0,553 \pm 0,176$

Table 6.6: Συνθήκη 2 — Αποτελέσματα Spontaneous dialogue




Figure 6.3: Σημασία χαρακτηριστικών Random Forest για το Task Spontaneous dialogue (εκτεταμένα χαρακτηριστικά). Τα χαρακτηριστικά MFCC παρουσιάζουν αυξημένη σημασία σε σύγκριση με το ReadText.

6.4 Ανάλυση αφαίρεσης χαρακτηριστικών

6.4.1 Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (Read-Text)

Μοντέλο	Βασική γραμμή (47)	Εκτεταμένη (78)	Δ ROC-AUC
Λογιστική παλινδρόμηση	0,717	0,698	−0,019
SVM (RBF)	0,614	0,834	+0,220
Random Forest	0,590	0,822	+0,232
Gradient Boosting	0,500	0,724	+0,224
XGBoost	0,628	0,794	+0,166

Table 6.7: Αφαίρεση χαρακτηριστικών — ReadText

6.4.2 Βελτίωση ROC-AUC από την επέκταση χαρακτηριστικών (Spontaneous)

Μοντέλο	Βασική γραμμή (47)	Επέκταση (78)	Δ ROC-AUC
Λογιστική παλινδρόμηση	0,760	0,783	+0,023
SVM (RBF)	0,407	0,460	+0,053
Random Forest	0,828	0,857	+0,029
Gradient Boosting	0,615	0,638	+0,023
XGBoost	0,723	0,687	−0,036

Table 6.8: Αφαίρεση χαρακτηριστικών — Spontaneous dialogue

6.5 Ανάλυση στάθμισης κλάσεων

Η στάθμιση κλάσης (`class_weight='balanced'`) αξιολογήθηκε για την αντιμετώπιση της ήπιας ανισορροπίας κλάσεων του συνόλου δεδομένων A (HC:PD $\approx$ 1,3:1). Τα αποτελέσματα έδειξαν ελάχιστη βελτίωση και περιστασιακή υποβάθμιση.

6.5.1 Task ReadText — Βασικά χαρακτηριστικά

Μοντέλο	Χωρίς στάθμιση	Με στάθμιση	Δ ROC-AUC
Λογιστική παλινδρόμηση	$0,717 \pm 0,139$	$0,717 \pm 0,139$	0,000
Random Forest	$0,590 \pm 0,302$	$0,687 \pm 0,258$	+0,097
SVM (RBF)	$0,614 \pm 0,312$	$0,542 \pm 0,312$	-0,072
Gradient Boosting	N/A (no native class_weight)		
XGBoost	N/A (no native class_weight)		

Table 6.9: Επίδραση της στάθμισης κλάσης στο ReadText (βασικά χαρακτηριστικά). Το Random Forest έδειξε μέτρια βελτίωση.

6.5.2 Εκτεταμένα χαρακτηριστικά — Όλες οι εργασίες

Με τα εκτεταμένα χαρακτηριστικά, η στάθμιση κλάσης παρείχε αμελητέο ή αρνητικό όφελος: το RF ReadText έπεσε κατά $-1,7\text{pp}$ ($0,822 \rightarrow 0,805$) και το Spontaneous έπεσε κατά $-3,4\text{pp}$ ($0,857 \rightarrow 0,823$), επιβεβαιώνοντας ότι η ήπια ανισορροπία 1,3:1 δεν απαιτούσε διόρθωση.

6.6 Συμβιβασμοί ακρίβειας-ανάκλησης

Οι ταξινομητές παρουσίασαν διακριτά προφίλ ακρίβειας-ανάκλησης, κρίσιμα για την κατανόηση των σεναρίων κλινικής ανάπτυξης.

6.6.1 Random Forest (εκτεταμένα χαρακτηριστικά)

Task	Precision	Recall	F1 Score
ReadText	$0,883 \pm 0,162$	$0,700 \pm 0,298$	$0,746 \pm 0,207$
Spontaneous	$0,683 \pm 0,410$	$0,600 \pm 0,435$	$0,605 \pm 0,387$

Table 6.10: Προφίλ ακρίβειας-ανάκλησης Random Forest. Η διαμόρφωση ReadText ευνοεί την ακρίβεια (λιγότερα ψευδώς θετικά αποτελέσματα).

Ανάλυση: Στο ReadText, το μοντέλο πέτυχε υψηλή ακρίβεια (0,88) αλλά χαμηλότερη ανάκληση (0,70). Αυτό σημαίνει ότι είναι πιο «συντηρητικό» στις προβλέψεις PD. Ένα τέτοιο προφίλ μπορεί να είναι χρήσιμο σε σενάρια διαλογής, όπου τα ψευδώς θετικά έχουν υψηλό κόστος.

6.7 Ανάλυση πίνακα σύγχυσης

Οι πίνακες σύγχυσης που ακολουθούν συγκεντρώνουν τις προβλέψεις εκτός fold από τη διαμόρφωση του εκτεταμένου συνόλου χαρακτηριστικών (78 χαρακτηριστικά, χωρίς στάθμιση) και στα πέντε folds διασταυρούμενης επικύρωσης. Κάθε πίνακας εμφανίζει τον συνολικό αριθμό των σωστά και λανθασμένα ταξινομημένων υποκειμένων σε όλα τα folds, παρέχοντας μια οπτική συμπλήρωση των συγκεντρωτικών μετρήσεων που αναφέρονται στις προηγούμενες ενότητες. Οι πραγματικές ετικέτες εμφανίζονται στις σειρές, ενώ οι προβλεπόμενες ετικέτες στις στήλες.

6.7.1 Σύνολο δεδομένων A — ReadText




Figure 6.4: Συγκεντρωτικοί πίνακες σύγχυσης για το Task ReadText (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 37$ υποκείμενα). Κάθε κελί αναφέρει τον συνολικό αριθμό εκτός fold και το ποσοστό του σε όλες τις προβλέψεις. Αυτά τα αποτελέσματα πρέπει να ερμηνευθούν με προσοχή, δεδομένου του μικρού μεγέθους του δείγματος.

Και τα πέντε μοντέλα αποδίδουν καλύτερα από το τυχαίο στο ReadText. Το Random Forest και το SVM (RBF) έχουν τα καλύτερα ποσοστά ανίχνευσης PD. Η Λογιστική Παλινδρόμηση είναι πιο συντηρητική: κάνει λιγότερα ψευδώς θετικά, αλλά χάνει περισσότερες περιπτώσεις PD. Το μικρό μέγεθος δείγματος ($n = 37$) αυξάνει τη μεταβλητότητα μεταξύ των folds.

6.7.2 Σύνολο δεδομένων A — Spontaneous dialogue




Figure 6.5: Συγκεντρωτικοί πίνακες σύγκρισης για το Task Spontaneous dialogue (εκτεταμένα χαρακτηριστικά, ομαδοποιημένη 5-Fold CV, $n = 36$ υποκείμενα). Αυτό το Task απέδωσε το υψηλότερο συνολικό ROC-AUC στη μελέτη ($0,857 \pm 0,171$, Random Forest).

Στο Spontaneous dialogue, το Random Forest εμφανίζει καλύτερη ανίχνευση PD σε σχέση με το ReadText. Το SVM παρουσιάζει μεγαλύτερη αστάθεια: σε ορισμένα folds αποδίδει πολύ καλά, ενώ σε άλλα σχεδόν τυχαία. Και εδώ, το μικρό δείγμα ($n = 36$) απαιτεί προσεκτική ερμηνεία.

6.7.3 Σύνολο δεδομένων B




Figure 6.6: Συγκεντρωτικοί πίνακες σύγκρισης για το σύνολο δεδομένων B (στρωματοποιημένη 5-Fold CV, $n = 756$ εγγραφές). Το σημαντικά μεγαλύτερο μέγεθος του δείγματος αποδίδει καλά διαχωρισμένα μοτίβα σύγκρισης με χαμηλή διακύμανση. Τα αποτελέσματα μπορεί να είναι αισιόδοξα λόγω της άγνωστης επικάλυψης των θεμάτων μεταξύ των πτυχών.

Στο Dataset B όλα τα μοντέλα παρουσιάζουν πολύ καθαρό διαχωρισμό μεταξύ των κλάσεων, κάτι που οφείλεται κυρίως στο μεγάλο μέγεθος δείγματος. Το Random Forest, με ROC-AUC $0,940 \pm 0,013$, εμφανίζει ελάχιστα ψευδώς αρνητικά. Ωστόσο, τα αποτελέσματα μπορεί να είναι αισιόδοξα λόγω πιθανής επικάλυψης υποκειμένων (Ενότητα 8.2.1).

Κεφάλαιο 7

Συζήτηση

7.1 Ερμηνεία βασικών ευρημάτων

7.1.1 Επίδραση της επέκτασης χαρακτηριστικών

Η επέκταση του συνόλου χαρακτηριστικών από 47 σε 78 χαρακτηριστικά βελτίωσε αισθητά την απόδοση, ιδιαίτερα στην εργασία ReadText. Για παράδειγμα, με Random Forest το ROC-AUC αυξήθηκε από $0,590 \pm 0,302$ σε $0,822 \pm 0,166$ (+23 ποσοστιαίες μονάδες), δείχνοντας ότι τα επιπλέον χαρακτηριστικά προσθέτουν χρήσιμη πληροφορία για τη διάκριση PD έναντι HC.

Ειδικά αποτελέσματα ανά εργασία:

Table 7.1: Επίδραση της επέκτασης χαρακτηριστικών ανά εργασία. Το ReadText παρουσίασε μεγαλύτερες βελτιώσεις, κάτι που δείχνει ότι τα βασικά χαρακτηριστικά δεν ήταν αρκετά για τη δομημένη ομιλία.

Μοντέλο	ReadText Δ	Spontaneous Δ	Μέγεθος αποτελέσματος
Random Forest	+23,2pp	+2,9pp	8× μεγαλύτερο
SVM (RBF)	+22,0pp	+5,3pp	4× μεγαλύτερο
Λογιστική παλινδρόμηση	−1,9pp	+2,3pp	Ουδέτερο

Ερμηνεία:

Τα εκτεταμένα χαρακτηριστικά προσθέτουν πληροφορία σε τρία σημεία:

Table 7.2: Συνεισφορές εκτεταμένων χαρακτηριστικών

Ομάδα χαρακτηριστικών	Συνεισφορά
Τυπικές αποκλίσεις MFCC	Μεταβλητότητα του φάσματος μέσα στην ηχογράφηση
Δέλτα-δέλτα MFCC	Ρυθμός αλλαγής (δεύτερη τάξη) των φασματικών χαρακτηριστικών
Περιγραφές φασματικού σχήματος	Γενική κατανομή της φασματικής ενέργειας

Το ότι το ReadText βελτιώθηκε πολύ περισσότερο δείχνει ότι:

1. **Η δομημένη ομιλία** (ανάγνωση) χρειάζεται πιο λεπτομερή φασματικά χαρακτηριστικά για να φανεί η διαφορά PD/HC.
2. **Η αυθόρμητη ομιλία** περιέχει από μόνη της περισσότερη φυσική μεταβλητότητα, οπότε τα βασικά χαρακτηριστικά συχνά αρκούν.
3. **Τα delta-delta** φαίνεται να βοηθούν σε εργασίες όπου η άρθρωση είναι πιο σταθερή (όπως η ανάγνωση).
4. **Τα γραμμικά μοντέλα** μπορεί να μη βοηθούν όταν οι διαστάσεις αυξάνονται πολύ σε σχέση με το μικρό n ($n = 37$).

7.1.2 Επιδράσεις στάθμισης κλάσης

Η στάθμιση κλάσης είχε **μικρή και όχι σταθερή** επίδραση στο σύνολο δεδομένων A:

Table 7.3: Επιδράσεις στάθμισης κλάσης

Μοντέλο	Δ ROC-AUC (σταθμισμένο έναντι μη σταθμισμένου)
Random Forest	+3,5pp (βασική γραμμή), -1,4pp (επεκταμένη)
Λογιστική παλινδρόμηση	0,0pp
SVM (RBF)	-1,3pp (βασική γραμμή), -1,4pp (επεκταμένη)

Ερμηνεία:

Η ανισορροπία στο Dataset A (57:43 HC:PD) είναι σχετικά μικρή, οπότε τα μοντέλα δεν επηρεάζονται ιδιαίτερα χωρίς στάθμιση. Η στάθμιση γίνεται πιο σημαντική όταν:

- η ανισορροπία είναι πολύ μεγαλύτερη (π.χ. πάνω από 70:30),
- το λάθος στη μειοψηφική κλάση έχει υψηλό κόστος,

- το δείγμα είναι πολύ μικρό.

7.1.3 Ιεραρχία απόδοσης μοντέλου

Στις περισσότερες συνθήκες, το Random Forest ήταν το πιο σταθερό και είχε τις καλύτερες επιδόσεις:

$$\text{Random Forest} \geq \text{Gradient Boosting} \approx \text{XGBoost} > \text{Logistic Regression} \approx \text{SVM (RBF)}$$

Πιθανοί λόγοι:

1. **Συνδυασμός πολλών δέντρων** που μειώνει τη διακύμανση σε μικρά datasets.
2. **Μη γραμμική συμπεριφορά** που ταιριάζει καλύτερα στα φωνητικά δεδομένα.
3. **Ανθεκτικότητα** όταν υπάρχουν χαρακτηριστικά που δεν βοηθούν ιδιαίτερα.
4. **Σημαντικότητα χαρακτηριστικών** που βοηθά στην ερμηνεία.

7.1.4 Υψηλή διακύμανση μεταξύ πτυχών

Στο Dataset A οι τυπικές αποκλίσεις ήταν συχνά πάνω από 0,15, δηλαδή υπήρχε μεγάλη διαφορά από fold σε fold. Σε σχέση με το Dataset B, η διακύμανση ήταν 10–15 φορές μεγαλύτερη:

Table 7.4: Σύγκριση διακύμανσης: μικρά έναντι μεγάλων συνόλων δεδομένων. Οι τυπικές αποκλίσεις μειώνονται περίπου όσο μεγαλώνει το n .

Μέτρηση	Σύνολο δεδομένων A (n=37)	Σύνολο δεδομένων B (n=752)
ROC-AUC std	$\pm 0,15-0,30$	$\pm 0,01-0,03$
Ακρίβεια std	$\pm 0,14-0,18$	$\pm 0,008-0,024$
F1-Score std	$\pm 0,21-0,39$	$\pm 0,006-0,015$

Πιθανοί λόγοι:

1. **Μικρό δείγμα:** λίγα άτομα σε κάθε fold $\rightarrow$ μεγάλη ευαισθησία σε μεμονωμένες περιπτώσεις.
2. **Διαφορές μεταξύ ατόμων:** δεν υπάρχει πληροφορία σταδιοποίησης στο MDVR-KCL.
3. **Συνθήκες καταγραφής:** κινητό τηλέφωνο και μη ελεγχόμενο περιβάλλον.

4. **Φύση της εργασίας:** ο αυθόρμητος διάλογος δεν είναι ίδιος για όλους.

Συνέπειες:

- Τα απόλυτα νούμερα πρέπει να διαβάζονται με προσοχή λόγω του μικρού n .
- Οι συγκρίσεις μέσα στο ίδιο CV (ίδιοι διαχωρισμοί) είναι πιο αξιόπιστες.
- Πολλές διαφορές μεταξύ μοντέλων είναι μέσα στη διακύμανση.
- Χρειάζονται μεγαλύτερα datasets ($n > 100$) για πιο σταθερά συμπεράσματα.

7.2 Σύγκριση με τη βιβλιογραφία

7.2.1 Πλαίσιο απόδοσης

Table 7.5: Σύγκριση με τη βιβλιογραφία

Μελέτη	Σύνολο δεδομένων	Καλύτερο ROC-AUC	Μέθοδος
Little et al. (2009)	UCI	0,92	SVM
Sakar et al. (2013)	Προσαρμοσμένο	0,86	SVM
Αυτή η εργασία	MDVR-KCL	0,87	RF

Τα αποτελέσματά μας είναι ανταγωνιστικά με τη βιβλιογραφία, αν και η άμεση σύγκριση είναι περιορισμένη λόγω:

- Διαφορετικά σύνολα δεδομένων και χαρακτηριστικά
- Διαφορετικές στρατηγικές CV (πολλές μελέτες δεν χρησιμοποιούν ομαδοποιημένο CV)
- Διαφορετικά μεγέθη δειγμάτων

7.2.2 Μεθοδολογική σύγκριση

Table 7.6: Μεθοδολογική σύγκριση. Η παρούσα εργασία δίνει προτεραιότητα στην αναπαραγωγικότητα και στις συντηρητικές εκτιμήσεις γενίκευσης.

Πτυχή	Τυπική βιβλιογραφία	Αυτή η εργασία
Στρατηγική CV	Τυχαία διαίρεση	Ομαδοποιημένη στρωματοποίηση
Χειρισμός θεμάτων	Συχνά αγνοείται	Ρητή ομαδοποίηση
Επιλογή χαρακτηριστικών	Ad-hoc	Συστηματική αφαίρεση
Αναφορά	Μόνο τα καλύτερα αποτελέσματα	Όλες οι συνθήκες + διακύμανση
Ανισορροπία κλάσεων	Συχνά δεν αντιμετωπίζεται	Ρητή αξιολόγηση
Προδιαγραφές εργασιών	Μικτές/μη δηλωμένες	Διαχωρισμένες + συγκριτικές

Σε σύγκριση με την τυπική πρακτική της βιβλιογραφίας, η παρούσα εργασία χρησιμοποιεί ομαδοποιημένη στρωματοποιημένη CV (όλες οι καταγραφές ανά υποκείμενο στην ίδια πτυχή), αναφέρει όλες τις πειραματικές συνθήκες με μέσο όρο $\pm$ std και τεκμηριώνει τα αρνητικά αποτελέσματα. Όπως αιτιολογείται στην ενότητα 4.5.1, η 5-πλήρης CV χωρίς ξεχωριστό σύνολο που κρατείται είναι κατάλληλη εδώ: με $n = 37$ υποκείμενα, ένα 20% που κρατείται θα απέφερε περίπου επτά υποκείμενα δοκιμής ανά πτυχή—πολύ λίγα για σταθερή εκτίμηση μετρήσεων.

7.3 Ανάλυση σημασίας χαρακτηριστικών

7.3.1 Χαρακτηριστικά με τη μεγαλύτερη διακριτική ικανότητα (σύνολο δεδομένων A)

Τα μοτίβα σημασίας των χαρακτηριστικών διέφεραν μεταξύ των εργασιών, αντανακλώντας διακριτά ακουστικά χαρακτηριστικά:

Table 7.7: Τα 5 κορυφαία χαρακτηριστικά του Random Forest ανά εργασία (Εκτεταμένο σύνολο χαρακτηριστικών). Οι τιμές σημασίας αντιπροσωπεύουν τη μέση μείωση της ακαθαρσίας.

Κατάταξη	ReadText	Σημασία	Αυθόρμητος διάλογος
1	f0_max	0,052	mfcc_5_mean
2	delta_mfcc_2_mean	0,039	shimmer_apq11
3	f3_std	0,038	delta_mfcc_8_mean
4	autocorr_harmonicity	0,038	jitter_local
5	intensity_mean	0,035	delta_mfcc_2_mean

Μοτίβα ειδικά για κάθε εργασία:

- **ReadText:** Κυριαρχείται από την μεταβλητότητα του τόνου ($f0_max$) και των φωνητικών συχνοτήτων ($f3_std$), υποδηλώνοντας ότι η δομημένη ομιλία δίνει έμφαση στην ακαμψία της θεμελιώδους συχνότητας
- **Spontaneous:** Τα φασματικά χαρακτηριστικά ($mfcc_5$) και τα μέτρα διαταραχής ($shimmer_apq11$, $jitter_local$) υποδηλώνουν τη σημασία της αστάθειας της ποιότητας της φωνής
- **Κοινά:** Το $\Delta mfcc_2_mean$ εμφανίζεται και στις δύο λίστες των 5 κορυφαίων χαρακτηριστικών, επιβεβαιώνοντας ότι η χρονική δυναμική είναι καθολικά σημαντική

7.3.2 Πολυπλοκότητα χαρακτηριστικών του συνόλου δεδομένων B

Table 7.8: Κορυφαία 5 χαρακτηριστικά του συνόλου δεδομένων B (Random Forest). Αυτές οι προηγμένες μετρήσεις επεξεργασίας σήματος δεν είναι διαθέσιμες σε τυπικά κλινικά περιβάλλοντα.

Χαρακτηριστικό	Σημασία	Κατηγορία
std_delta_log_energy	0,0133	Δυναμική ενέργειας
std_delta_delta_log_energy	0,0132	Επιτάχυνση ενέργειας
tqwt_entropy_shannon_dec_12	0,0117	Εντροπία κυματιδίων
tqwt_TKEO_std_dec_11	0,0098	Ενέργεια Teager
tqwt_TKEO_mean_dec_12	0,0096	Ενέργεια Teager

Τα κορυφαία χαρακτηριστικά του συνόλου δεδομένων B βασίζονται σε εξειδικευμένη επεξεργασία σήματος (αποσύνθεση κυματιδίων, τελεστές ενέργειας Teager) που δεν είναι διαθέσιμη σε τυπικά κλινικά περιβάλλοντα. Η πλήρης κατάταξη των χαρακτηριστικών παρέχεται στο Παράρτημα A.

7.4 Μοτίβα απόδοσης που εξαρτώνται από την εργασία

7.4.1 ReadText έναντι αυθόρμητου διαλόγου

Γενικά, ο αυθόρμητος διάλογος έδωσε καλύτερα αποτελέσματα από το ReadText, εκτός από την περίπτωση του SVM στα εκτεταμένα χαρακτηριστικά:

Table 7.9: Σύγκριση εργασιών μεταξύ διαμορφώσεων. Ο αυθόρμητος διάλογος γενικά αποδίδει καλύτερα από το ReadText, εκτός από το SVM στα εκτεταμένα χαρακτηριστικά.

Διαμόρφωση	ReadText	Spontaneous	Πλεονέκτημα
Βασικά χαρακτηριστικά:			
Random Forest ROC-AUC	$0,590 \pm 0,302$	$0,828 \pm 0,148$	Αυθόρμητος
Λογιστική παλινδρόμηση	$0,717 \pm 0,139$	$0,760 \pm 0,214$	Αυθόρμητη
Εκτεταμένα χαρακτηριστικά:			
Random Forest ROC-AUC	$0,822 \pm 0,166$	$0,857 \pm 0,171$	Αυθόρμητο
SVM (RBF)	$0,834 \pm 0,153$	$0,460 \pm 0,294$	ReadText

Ερμηνεία:

1. **Αυθόρμητη ομιλία:** συχνά κάνει πιο εμφανείς τις διαφορές στην προσωδία (π.χ. μονοτονία).
2. **Γνωστικό φορτίο:** στον διάλογο το άτομο πρέπει να σκέφτεται και να μιλάει, κάτι που μπορεί να τονίζει δυσκολίες στον έλεγχο της ομιλίας.
3. **SVM:** το χαμηλό αποτέλεσμα στην αυθόρμητη/εκτεταμένη ομιλία δείχνει ότι είναι πιο ευαίσθητο σε αλλαγές στην κατανομή των χαρακτηριστικών.
4. **Σύγκριση baseline:** ο αυθόρμητος διάλογος πήγε καλά και με 47 χαρακτηριστικά, ενώ το ReadText χρειάστηκε 78 για να φτάσει παρόμοια απόδοση.

Κλινικές επιπτώσεις:

- Ο αυθόρμητος διάλογος με 47 χαρακτηριστικά μπορεί να δώσει καλή απόδοση με χαμηλότερο κόστος.
- Το ReadText φαίνεται να χρειάζεται περισσότερα χαρακτηριστικά για να δουλέψει καλά.

Κεφάλαιο 8

Περιορισμοί και απειλές για την εγκυρότητα

8.1 Περιορισμοί μεγέθους δείγματος

8.1.1 Σύνολο δεδομένων A: Μικρός αριθμός συμμετεχόντων

Table 8.1: Μετρήσεις μεγέθους δείγματος συνόλου δεδομένων A

Μέτρηση	Τιμή
Σύνολο υποκειμένων (ReadText)	37
Σύνολο υποκειμένων (SpontaneousDialogue)	36
Συμμετέχοντες ανά δοκιμαστικό πτυσσόμενο	~7–8
Συμμετέχοντες με PD (μειοψηφία)	15–16
Συμμετέχοντες HC (πλειοψηφία)	21

Το σύνολο δεδομένων A περιλαμβάνει 37 άτομα για την εργασία ReadText και 36 για την εργασία SpontaneousDialogue. Με βάση το σχήμα της 5-fold διασταυρούμενης επικύρωσης, σε κάθε fold αντιστοιχούν περίπου 7–8 άτομα, με 15–16 περιπτώσεις PD (μειοψηφία) και 21 HC (πλειοψηφία).

Επιπτώσεις:

- Μεγάλη διακύμανση στα αποτελέσματα ανά fold (τυπικά $\text{std} > 0,15$)
- Περιορισμένη στατιστική ισχύς για τον εντοπισμό μικρών διαφορών
- Περιορισμένη δυνατότητα γενίκευσης σε μεγαλύτερο πληθυσμό

8.2 Περιορισμοί αναγνωριστικών υποκειμένων

8.2.1 Σύνολο δεδομένων B: Δεν υπάρχουν ταυτότητες υποκειμένων

Το σύνολο δεδομένων B περιλαμβάνει 756 δείγματα (192 HC, 564 PD), αλλά δεν παρέχει IDs υποκειμένων. Αυτό συνεπάγεται ότι:

- Δείγματα από το ίδιο άτομο ενδέχεται να εμφανίζονται ταυτόχρονα σε train και test (κίνδυνος διαρροής)
- Η εκτιμώμενη απόδοση μπορεί να εμφανίζεται καλύτερη από την πραγματική
- Δεν μπορεί να αξιολογηθεί με βεβαιότητα η επίδοση σε εντελώς νέα υποκείμενα
- Υπάρχει έντονη ανισορροπία κλάσεων (74,6% PD)

Προειδοποίηση: Τα αποτελέσματα του συνόλου δεδομένων B μπορεί να είναι αισιόδοξα, επειδή δεν είναι γνωστό αν υπάρχει επικάλυψη υποκειμένων μεταξύ των folds. Η έντονη ανισορροπία κλάσεων δυσκολεύει επιπλέον την ερμηνεία.

8.2.2 Περιορισμοί σύγκρισης

Η άμεση σύγκριση μεταξύ των δύο συνόλων δεν είναι απλή, επειδή διαφέρουν ταυτόχρονα σε πολλούς παράγοντες:

- στρατηγική cross-validation
- μέγεθος δείγματος
- είδος ομιλίας
- pipeline χαρακτηριστικών
- βαθμό ανισορροπίας κλάσεων

Βλ. και Προειδοποίηση [8.2.1](#).

8.3 Περιορισμοί εξαγωγής χαρακτηριστικών

8.3.1 Προκαθορισμένο σύνολο χαρακτηριστικών

Τα χαρακτηριστικά ορίστηκαν εκ των προτέρων με βάση τη βιβλιογραφία και όχι με βελτιστοποίηση πάνω στα διαθέσιμα δεδομένα. Αυτό σημαίνει ότι:

- Είναι πιθανό να υπάρχουν πιο κατάλληλα χαρακτηριστικά που δεν συμπεριλήφθηκαν
- Οι βασικές παράμετροι εξαγωγής παρέμειναν σταθερές (π.χ. F0 75–500 Hz, 13 MFCCs)
- Δεν εφαρμόστηκε επιλογή χαρακτηριστικών (χρήση όλων των 47 ή 78 χαρακτηριστικών)
- Δεν εξετάστηκαν πιο σύνθετοι μετασχηματισμοί ή όροι αλληλεπίδρασης

8.3.2 Υποθέσεις για την ποιότητα ήχου

Η διαδικασία εξαγωγής χαρακτηριστικών βασίζεται στην υπόθεση ότι:

- Το σήμα διαθέτει ικανοποιητικό λόγο σήματος προς θόρυβο
- Οι συνθήκες εγγραφής είναι σχετικά σταθερές
- Δεν υπάρχει έντονο clipping ή παραμόρφωση
- Ο ήχος είναι μονοφωνικός στα 22050 Hz

Για το σύνολο δεδομένων B, οι συνθήκες εγγραφής παραμένουν άγνωστες.

8.4 Περιορισμοί μοντέλου

8.4.1 Χωρίς ρύθμιση υπερπαραμέτρων

Όλα τα μοντέλα χρησιμοποιήθηκαν με προεπιλεγμένες ρυθμίσεις του sklearn. Οι μόνες ελεγχόμενες παράμετροι ήταν ο τυχαίος σπόρος και η στάθμιση κλάσεων:

Table 8.2: Σταθερές υπερπαραμέτροι (όλα τα πειράματα)

Μοντέλο	Σταθερές παράμετροι
Λογιστική παλινδρόμηση	$C = 1,0$, max_iter= 1000, solver='lbfgs'
SVM (RBF)	$C = 1,0$, gamma='scale' (αυτόματος υπολογισμός)
Random Forest	n_estimators= 100, max_depth=None (απεριόριστο)

Συνέπειες:

- Η απόδοση ενδέχεται να μην είναι η βέλτιστη
- Τα αποτελέσματα αποτυπώνουν κυρίως baseline συμπεριφορά

- Με διαφορετική ρύθμιση είναι πιθανό να μεταβαλλόταν η κατάταξη των μοντέλων
- Η στάθμιση κλάσεων εξετάστηκε ξεχωριστά (σημαία `USE_CLASS_WEIGHT_BALANCED`)

Λογική: Με τόσο μικρό δείγμα (37 άτομα), η nested CV θα οδηγούσε σε πολύ μικρά εσωτερικά folds (~5–6 άτομα) και συνεπώς σε αυξημένη αστάθεια. Η χρήση σταθερών παραμέτρων υποστηρίζει τη δίκαιη σύγκριση και την αναπαραγωγιμότητα.

8.5 Μεθοδολογικοί περιορισμοί

8.5.1 Χωρίς εξωτερική επικύρωση

Όλα τα αποτελέσματα βασίζονται σε εσωτερική 5-fold διασταυρούμενη επικύρωση, χωρίς ανεξάρτητο εξωτερικό test set. Αυτό επιβάλλει τους εξής περιορισμούς:

- Δεν υπάρχει δοκιμή σε ανεξάρτητη πηγή δεδομένων
- Δεν υπάρχει επικύρωση σε πολλαπλές τοποθεσίες
- Παραμένει άγνωστη η γενίκευση σε άλλες συσκευές ή συνθήκες εγγραφής
- Δεν έχει ελεγχθεί η χρονική σταθερότητα (μία συνεδρία ανά άτομο)
- Δεν έχει εξεταστεί η γενίκευση σε άλλες γλώσσες ή διαλέκτους

Αιτιολόγηση: Βλ. ενότητα [4.5.1](#).

8.5.2 Χειρισμός ανισορροπίας κλάσεων

Η ανισορροπία κλάσεων ήταν παρούσα και στα δύο σύνολα δεδομένων:

- Σύνολο δεδομένων A: Αναλογία HC:PD 1,31:1 (ReadText) και 1,40:1 (SpontaneousDialogue)
- Σύνολο δεδομένων B: Αναλογία HC:PD 1:2,94 (σοβαρή ανισορροπία)

Η επιλογή `USE_CLASS_WEIGHT_BALANCED` χρησιμοποιήθηκε ως βασική στρατηγική μετριασμού, αλλά:

- Δεν βελτίωσε σταθερά όλα τα metrics
- Σε ορισμένες περιπτώσεις αύξησε τη διακύμανση
- Η καταλληλότερη στρατηγική πιθανόν εξαρτάται από το μοντέλο

Εναλλακτικές προσεγγίσεις που δεν διερευνήθηκαν: SMOTE, undersampling ή ρύθμιση κατωφλίου.

8.6 Απειλές για την εγκυρότητα

8.6.1 Εσωτερική εγκυρότητα

Table 8.3: Απειλές εσωτερικής εγκυρότητας

Απειλή	Κατάσταση	Μείωση
Διαρροή υποκειμένου	Ελεγχόμενη (σύνολο δεδομένων A)	GroupedStratifiedKFold
Διαρροή υποκειμένου	Μη ελεγχόμενη (σύνολο δεδομένων B)	Δεν υπάρχουν διορθωτικά αναγνωριστικά υποκειμένου
Θόρυβος ετικέτας	Άγνωστος	Θεωρείται σωστός
Σφάλματα εξαγωγής χαρακτηριστικών	Μετριάσιμα	Δοκιμές μονάδων χειροκίνητη επαλήθευση RANDOM_SEED=42 (σταθερή)
Τυχαία εξάρτηση από σπόρο	Ελεγχόμενη	
Σφάλματα προεπεξεργασίας δεδομένων	Μετριάσιμα	Τυποποιημένη κανονικοποίηση ήχο

8.6.2 Εξωτερική εγκυρότητα

Table 8.4: Απειλές εξωτερικής εγκυρότητας

Απειλή	Κατάσταση	Μείωση
Μεροληψία πληθυσμού	Πιθανή	Δημογραφικά στοιχεία συνόλου δεδομένων εγγράφων
Μεταβλητότητα εγγραφής	Παρούσα	Τυποποιημένη εξαγωγή
Χρονική σταθερότητα	Άγνωστη	Ενιαία συνεδρία εγγραφής

Κεφάλαιο 9

Συμπέρασμα

9.1 Περίληψη της εργασίας

Η εργασία αυτή μελέτησε αν μπορούμε να ξεχωρίσουμε άτομα με νόσο Πάρκινσον (PD) από υγιείς (HC) μόνο από τη φωνή τους, χρησιμοποιώντας κλασικά μοντέλα μηχανικής μάθησης. Η έμφαση δόθηκε σε κρίσιμα μεθοδολογικά ζητήματα, όπως η διαρροή υποκειμένων, η ανισορροπία κλάσεων και η επιλογή χαρακτηριστικών.

9.1.1 Συνεισφορές

1. **Αυστηρή αξιολόγηση:** Χρησιμοποιήθηκε ομαδοποιημένη stratified 5-fold CV, με συστηματικό σχεδιασμό (χαρακτηριστικά × στάθμιση κλάσεων) και πλήρη αναφορά όλων των συνθηκών.
2. **Επέκταση χαρακτηριστικών:** Το σύνολο αυξήθηκε από 47 σε 78 χαρακτηριστικά, με βελτίωση έως +23 ποσοστιαίες μονάδες στο ROC-AUC. Τα πιο σημαντικά χαρακτηριστικά περιλάμβαναν F_0 , MFCCs και μέτρα αρμονικότητας.
3. **Έλεγχος στάθμισης κλάσεων:** Η επιλογή `class_weight="balanced"` δοκιμάστηκε σε όλα τα μοντέλα, με μέτρια και μη σταθερά αποτελέσματα.
4. **Αναπαραγωγιμότητα:** Χρησιμοποιήθηκαν σταθερός random seed, τεκμηριωμένες παράμετροι και δομημένο workflow.

9.2 Βασικά ευρήματα

- Καλύτερο αποτέλεσμα στο σύνολο A: **ROC-AUC** $0,857 \pm 0,171$ (Random Forest, εκτεταμένα χαρακτηριστικά, SpontaneousDialogue).
- Η επέκταση χαρακτηριστικών βελτίωσε σημαντικά το ReadText (+23pp) και λιγότερο το SpontaneousDialogue (+2,9pp).
- Το Random Forest ήταν σταθερά το πιο ανταγωνιστικό μοντέλο.
- Παρατηρήθηκε μεγάλη διακύμανση (std έως 0,43), κυρίως λόγω μικρού δείγματος.
- Η ομαδοποιημένη CV ήταν κρίσιμη για την αποφυγή αισιόδοξης μεροληψίας.

9.3 Απαντήσεις στα ερευνητικά ερωτήματα

9.3.1 RQ1: Πόσο καλά αποδίδουν τα κλασικά μοντέλα;

Η απόδοση έφτασε έως 0,857 **ROC-AUC**, αλλά με μεγάλη διακύμανση. Σε ορισμένα folds, ειδικά με SVM, το ROC-AUC έπεσε κάτω από 0,5, γεγονός που δείχνει αστάθεια.

Συνολικά, η ταξινόμηση είναι εφικτή, αλλά δεν είναι σταθερή σε μικρά δείγματα.

9.3.2 RQ2: Η επέκταση του συνόλου χαρακτηριστικών βελτιώνει την απόδοση της ταξινόμησης;

Ναι, αλλά η επίδραση εξαρτάται από την εργασία.

ReadText:

- Από 0,590 σε 0,822 ROC-AUC (+23pp)
- Παράλληλα παρατηρήθηκε μείωση της διακύμανσης

SpontaneousDialogue:

- Από 0,828 σε 0,857 ROC-AUC (+2,9pp)

Τα πρόσθετα χαρακτηριστικά μεταβλητότητας (std και delta-delta MFCC) βοήθησαν κυρίως στο ReadText.

9.3.3 RQ3: Βελτιώνει η στάθμιση των κλάσεων την απόδοση σε μη ισορροπημένα σύνολα δεδομένων;

Όχι ουσιαστικά. Οι μεταβολές ήταν πολύ μικρές ($-1,7pp$ ή $-0,1pp$) και δεν διαμορφώθηκε σταθερό μοτίβο βελτίωσης.

Η ανισορροπία του συνόλου A (περίπου 1,3:1) πιθανόν δεν ήταν αρκετά μεγάλη ώστε να απαιτεί στάθμιση κλάσεων.

9.3.4 RQ4: Πώς συγκρίνονται τα αποτελέσματα μεταξύ της ομαδοποιημένης και της τυπικής CV;

Σύνολο A (grouped CV):

- 0,590–0,857 ROC-AUC
- Μεγάλη διακύμανση

Σύνολο B (τυπική CV):

- 0,940–0,949 ROC-AUC
- Πολύ μικρή διακύμανση

Το σύνολο B εμφανίζει πολύ υψηλότερες επιδόσεις, αλλά υπάρχει πιθανότητα διαρροής υποκειμένων. Η grouped CV δίνει πιο συντηρητικές αλλά πιο ρεαλιστικές εκτιμήσεις γενίκευσης.

9.3.5 RQ5: Οι εργασίες ομιλίας αποδίδουν διαφορετική απόδοση ταξινόμησης;

Με βασικά χαρακτηριστικά:

- ReadText: 0,590
- SpontaneousDialogue: 0,828

Με εκτεταμένα χαρακτηριστικά:

- ReadText: 0,822
- SpontaneousDialogue: 0,857

Η αυθόρμητη ομιλία φαίνεται να αποτυπώνει καλύτερα χαρακτηριστικά της PD, αλλά το ReadText ωφελείται περισσότερο από την επέκταση χαρακτηριστικών.

9.4 Επιπτώσεις

9.4.1 Για ερευνητές

- Να χρησιμοποιείται grouped CV όταν υπάρχουν πολλαπλές ηχογραφήσεις ανά άτομο.
- Να περιλαμβάνονται χαρακτηριστικά μεταβλητότητας.
- Να αναφέρονται όλα τα αποτελέσματα και όχι μόνο τα καλύτερα.

9.4.2 Για επαγγελματίες

- Η φωνητική ανάλυση για PD είναι υποσχόμενη, αλλά όχι ακόμη κλινικά ώριμη.
- Το Random Forest αποτελεί καλή baseline επιλογή.
- Απαιτείται επικύρωση σε ανεξάρτητα δείγματα.

9.4.3 Για δημιουργούς datasets

- Να παρέχονται πάντα IDs υποκειμένων.
- Να καταγράφονται οι συνθήκες ηχογράφησης και τα δημογραφικά στοιχεία.

9.5 Μελλοντικές κατευθύνσεις

Μελλοντικά μπορούν να εξεταστούν:

- ρύθμιση υπερπαραμέτρων με nested CV,
- επιλογή χαρακτηριστικών,
- συνδυασμός διαφορετικών εργασιών ομιλίας,
- εξωτερική επικύρωση σε νέα δείγματα,
- μελέτη της σοβαρότητας της νόσου.

Μακροπρόθεσμα, η φωνητική ανάλυση μπορεί να ενσωματωθεί σε εφαρμογές smartphone μαζί με άλλους βιοδείκτες, όπως βάδισμα και τρόμος.

9.6 Τελικό συμπέρασμα

Η εργασία δείχνει ότι η ταξινόμηση της νόσου Πάρκινσον μέσω φωνής είναι εφικτή με κλασικά μοντέλα και κατάλληλα χαρακτηριστικά, φτάνοντας ROC-AUC έως 0,857 στο σύνολο A.

Δόθηκε προτεραιότητα στη μεθοδολογική σωστότητα (grouped CV, σταθερές παράμετροι, πλήρης αναφορά διακύμανσης) και όχι στην «εντυπωσιακή» απόδοση. Παρά τους περιορισμούς (μικρό δείγμα, απουσία εξωτερικής επικύρωσης), η εργασία προσφέρει καθαρή και αναπαραγώγιμη βάση για επόμενες μελέτες.

Παράρτημα Α

Πίνακες Σημαντικότητας Χαρακτηριστικών

A.1 Επισκόπηση

Το παρόν παράρτημα παρουσιάζει τα 20 σημαντικότερα χαρακτηριστικά για κάθε πειραματική συνθήκη, όπως προκύπτουν από τις εγγενείς μετρικές σημαντικότητας των μοντέλων:

- **Logistic Regression:** Απόλυτες τιμές coefficients
- **Random Forest:** Gini importance (mean decrease in impurity)

A.2 Dataset A — ReadText Task

A.2.1 Random Forest — Top 20 Features

Rank	Feature	Importance	Std
1	f0_max	0.052	0.019
2	delta_mfcc_2_mean	0.039	0.018
3	f3_std	0.038	0.011
4	autocorr_harmonicity	0.038	0.017
5	intensity_mean	0.035	0.021
6	f0_mean	0.032	0.012
7	shimmer_apq3	0.032	0.013
8	mfcc_12_mean	0.031	0.007
9	f1_std	0.031	0.022
10	mfcc_6_mean	0.030	0.024

Table A.1: Σημαντικότητα χαρακτηριστικών του Random Forest — ReadText (top 10)

A.2.2 Logistic Regression — Top 20 Features

Rank	Feature	Coefficient	Std
1	f0_max	0.754	0.203
2	hnr_mean	0.649	0.178
3	shimmer_apq11	0.553	0.145
4	delta_mfcc_4_mean	0.496	0.163
5	delta_mfcc_2_mean	0.492	0.103
6	delta_mfcc_1_mean	0.474	0.273
7	mfcc_5_mean	0.470	0.127
8	mfcc_4_mean	0.426	0.233
9	mfcc_10_mean	0.418	0.221
10	mfcc_11_mean	0.388	0.192

Table A.2: Σημαντικότητα χαρακτηριστικών του Logistic Regression — ReadText (top 10)




Figure A.1: Μέγεθος συντελεστών του Logistic Regression (ReadText)

A.2.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.229	0.179
2	mfcc_4_mean	0.084	0.187
3	f1_std	0.080	0.178
4	mfcc_6_mean	0.066	0.143
5	intensity_min	0.064	0.122
6	mfcc_2_mean	0.060	0.133
7	f0_std	0.055	0.081
8	f3_std	0.054	0.070
9	delta_mfcc_10_mean	0.047	0.104
10	delta_mfcc_2_mean	0.041	0.083

Table A.3: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — ReadText (top 10)




Figure A.2: Σημαντικότητα χαρακτηριστικών του Gradient Boosting (ReadText). Το F0 max εμφανίζει ισχυρή κυριαρχία (0.229 ± 0.179), σε συμφωνία με διαταραχές στη ρύθμιση του pitch στην PD.

A.2.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.083	0.028
2	intensity_min	0.064	0.063
3	f0_mean	0.063	0.044
4	f3_std	0.061	0.044
5	intensity_mean	0.051	0.047
6	delta_mfcc_10_mean	0.041	0.037
7	f1_std	0.041	0.075
8	delta_mfcc_2_mean	0.038	0.028
9	mfcc_3_mean	0.033	0.023
10	mfcc_11_mean	0.031	0.040

Table A.4: Σημαντικότητα χαρακτηριστικών του XGBoost — ReadText (top 10)




Figure A.3: Σημαντικότητα χαρακτηριστικών του XGBoost (ReadText). Η σημαντικότητα είναι πιο κατανοητή σε σχέση με το Gradient Boosting, με τα χαρακτηριστικά F0 και έντασης να μοιράζονται την κυριαρχία.

A.3 Dataset A — SpontaneousDialogue Task

A.3.1 Random Forest — Top 20 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.080	0.022
2	shimmer_apq11	0.069	0.007
3	delta_mfcc_8_mean	0.051	0.015
4	jitter_local	0.041	0.012
5	delta_mfcc_2_mean	0.040	0.018
6	autocorr_harmonicity	0.037	0.011
7	shimmer_local	0.036	0.017
8	mfcc_1_mean	0.034	0.010
9	f0_std	0.032	0.022
10	f0_mean	0.031	0.013

Table A.5: Σημαντικότητα χαρακτηριστικών του Random Forest — SpontaneousDialogue (top 10)

A.3.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	mfcc_5_mean	0.722	0.039
2	delta_mfcc_8_mean	0.615	0.121
3	shimmer_apq11	0.559	0.136
4	delta_mfcc_2_mean	0.493	0.196
5	intensity_min	0.459	0.170
6	mfcc_3_mean	0.388	0.271
7	delta_mfcc_11_mean	0.381	0.102
8	delta_mfcc_7_mean	0.380	0.150
9	hnr_mean	0.379	0.175
10	delta_mfcc_1_mean	0.352	0.123

Table A.6: Σημαντικότητα χαρακτηριστικών του Logistic Regression — SpontaneousDialogue (top 10)




Figure A.4: Μέγεθος συντελεστών του Logistic Regression (Spontaneous Dialogue)

A.3.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.342	0.204
2	shimmer_apq11	0.134	0.132
3	delta_mfcc_8_mean	0.086	0.192
4	intensity_min	0.050	0.093
5	shimmer_local	0.050	0.089
6	f1_std	0.040	0.033
7	mfcc_11_mean	0.040	0.089
8	mfcc_10_mean	0.027	0.020
9	mfcc_1_mean	0.024	0.026
10	intensity_max	0.024	0.037

Table A.7: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — SpontaneousDialogue (top 10)




Figure A.5: Σημαντικότητα χαρακτηριστικών του Gradient Boosting (Spontaneous Dialogue). Το MFCC-5 (0.342 ± 0.204) κυριαρχεί, αντανακλώντας αλλαγές στο spectral tilt στην αυθόρμητη ομιλία PD.

A.3.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.134	0.059
2	shimmer_apq11	0.104	0.071
3	delta_mfcc_8_mean	0.079	0.052
4	delta_mfcc_2_mean	0.053	0.009
5	mfcc_4_mean	0.035	0.022
6	mfcc_2_mean	0.033	0.022
7	jitter_local	0.032	0.012
8	f0_mean	0.031	0.035
9	shimmer_local	0.031	0.054
10	intensity_max	0.030	0.030

Table A.8: Σημαντικότητα χαρακτηριστικών του XGBoost — SpontaneousDialogue (top 10)




Figure A.6: Σημαντικότητα χαρακτηριστικών του XGBoost (Spontaneous Dialogue). Τα MFCC-5 και τα shimmer χαρακτηριστικά κυριαρχούν, σε συμφωνία με τα ευρήματα των RF και GB για αυτό το task.

A.4 Dataset B — PD Speech Features

Το Dataset B περιέχει 752 προεξαγμένα χαρακτηριστικά, συμπεριλαμβανομένων συντελεστών TQWT (Tunable Q-factor Wavelet Transform) που δεν υπάρχουν στο Dataset A. Η σημαντικότητα χαρακτηριστικών παρουσιάζεται για σκοπούς σύγκρισης, αν και η άμεση αντιπαραβολή παραμένει περιορισμένη λόγω διαφορετικών feature spaces.

A.4.1 Random Forest — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_log_energy	0.013	0.004
2	std_delta_delta_log_energy	0.013	0.003
3	tqwt_entropy_shannon_dec_12	0.012	0.001
4	tqwt_TKEO_std_dec_11	0.010	0.004
5	tqwt_TKEO_mean_dec_12	0.010	0.001
6	mean_MFCC_2nd_coef	0.008	0.003
7	tqwt_entropy_log_dec_11	0.008	0.003
8	tqwt_stdValue_dec_12	0.008	0.003
9	tqwt_stdValue_dec_13	0.008	0.003
10	tqwt_energy_dec_12	0.007	0.003

Table A.9: Σημαντικότητα χαρακτηριστικών του Random Forest — Dataset B (top 10)

Σημείωση: Οι τιμές σημαντικότητας είναι χαμηλότερες από το Dataset A λόγω του μεγαλύτερου feature space (752 έναντι 47 features), που κατανέμει τη σημαντικότητα πιο ευρέως.

A.4.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	tqwt_kurtosisValue_dec_33	0.733	0.161
2	tqwt_entropy_log_dec_33	0.694	0.084
3	mean_MFCC_7th_coef	0.614	0.148
4	std_delta_delta_log_energy	0.588	0.133
5	std_MFCC_2nd_coef	0.567	0.202
6	tqwt_meanValue_dec_16	0.551	0.114
7	tqwt_medianValue_dec_25	0.540	0.209
8	mean_MFCC_3rd_coef	0.538	0.155
9	tqwt_meanValue_dec_22	0.528	0.172
10	std_9th_delta	0.526	0.103

Table A.10: Σημαντικότητα χαρακτηριστικών του Logistic Regression — Dataset B (top 10)

Παρατήρηση: Τα χαρακτηριστικά TQWT κυριαρχούν στη σημαντικότητα του Dataset B, αντανakλώντας το task παρατεταμένης φώνησης του /a/, όπου η χρονικο-συχνοτική αποσύνθεση συλλαμβάνει λεπτά πρότυπα φωνητικού τρόμου.




Figure A.7: Σημαντικότητα χαρακτηριστικών για το Dataset B (PD Speech Features) — Random Forest και Logistic Regression.

A.4.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_delta_log_energy	0.133	0.035
2	tqwt_TKEO_mean_dec_12	0.030	0.036
3	tqwt_entropy_log_dec_27	0.029	0.008
4	std_7th_delta_delta	0.028	0.005
5	tqwt_energy_dec_27	0.024	0.028
6	tqwt_entropy_log_dec_35	0.023	0.019
7	tqwt_TKEO_std_dec_12	0.023	0.026
8	mean_MFCC_2nd_coef	0.021	0.024
9	tqwt_entropy_log_dec_33	0.021	0.006
10	tqwt_TKEO_std_dec_11	0.020	0.021

Table A.11: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — Dataset B (top 10)

A.4.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	tqwt_entropy_log_dec_12	0.024	0.020
2	std_delta_delta_log_energy	0.017	0.006
3	tqwt_TKEO_mean_dec_12	0.016	0.017
4	tqwt_TKEO_std_dec_12	0.013	0.014
5	tqwt_energy_dec_27	0.012	0.024
6	tqwt_TKEO_std_dec_11	0.012	0.010
7	tqwt_entropy_log_dec_16	0.010	0.009
8	tqwt_entropy_log_dec_13	0.009	0.012
9	mean_MFCC_2nd_coef	0.008	0.004
10	tqwt_entropy_shannon_dec_16	0.008	0.011

Table A.12: Σημαντικότητα χαρακτηριστικών του XGBoost — Dataset B (top 10)




Figure A.8: Σημαντικότητα χαρακτηριστικών για το Dataset B — Gradient Boosting και XGBoost. Τα χαρακτηριστικά ενέργειας/εντροπίας TQWT από ζώνες υψηλής συχνότητας κυριαρχούν και στα δύο μοντέλα.

A.5 Σταθερότητα Χαρακτηριστικών μεταξύ Tasks

Χαρακτηριστικά που εμφανίζονται στο top-10 και για τα δύο tasks (Random Forest) υποδεικνύουν ισχυρή διακριτική ικανότητα σε διαφορετικά speech contexts:

Feature	ReadText Rank	Spontaneous Rank
delta_mfcc_2_mean	2	5
autocorr_harmonicity	4	6
f0_mean	6	10
shimmer (apq3/apq11)	7	2
mfcc_5_mean	–	1
f0_std	–	9

Table A.13: Σταθερότητα χαρακτηριστικών μεταξύ tasks (Random Forest top-10)


Ερμηνεία: Χαρακτηριστικά που είναι σταθερά σημαντικά και στα δύο tasks (delta_mfcc_2_mean, autocorr_harmonicity, shimmer) πιθανότατα αποτυπώνουν **task-general** acoustic signatures της PD και όχι task-specific artifacts. Η έντονη παρουσία του mfcc_5_mean στο SpontaneousDialogue αλλά όχι στο ReadText μπορεί να αντανακλά διαφορές στην prosodic variability μεταξύ δομημένης ανάγνωσης και φυσικού διαλόγου.

A.6 Ανάλυση Κατηγοριών Χαρακτηριστικών


Συγκεντρωτική παρουσίαση της σημαντικότητας ανά κατηγορία χαρακτηριστικών:

Category	Features	ReadText (%)	Spontaneous (%)
MFCC	13	28.4	32.1
Delta MFCC	13	22.7	25.3
Pitch (F_0)	4	15.2	12.8
Shimmer	5	11.3	14.6
Formants	6	9.8	7.2
Harmonicity	2	6.1	4.3
Other	5	6.5	3.7

Table A.14: Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά κατηγορία



(a) ReadText



(b) Spontaneous

Figure A.9: Σημαντικότητα χαρακτηριστικών συγκεντρωμένη ανά ευρείες ακουστικές κατηγορίες.

Παράρτημα Β

Αναλυτικοί Πίνακες Αποτελεσμάτων

B.1 Επισκόπηση

Το παρόν παράρτημα παρουσιάζει πλήρη αριθμητικά αποτελέσματα για όλες τις πειραματικές συνθήκες, συμπεριλαμβανομένων συνοπτικών στατιστικών και συγκρίσεων μεταξύ συνθηκών.

B.2 Συνθήκη 1: Baseline Features (47) + Unweighted

B.2.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.621 ± 0.058	0.620 ± 0.217	0.550 ± 0.201	0.542 ± 0.099	0.717 ± 0.139
	SVM	0.621 ± 0.106	0.367 ± 0.342	0.317 ± 0.335	0.333 ± 0.333	0.614 ± 0.312
	RF	0.629 ± 0.178	0.450 ± 0.447	0.333 ± 0.408	0.351 ± 0.363	0.590 ± 0.302
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.636 ± 0.135	0.600 ± 0.435	0.333 ± 0.236	0.400 ± 0.253	0.407 ± 0.309
	RF	0.721 ± 0.176	0.633 ± 0.415	0.600 ± 0.435	0.567 ± 0.365	0.828 ± 0.148

Table B.1: Αποτελέσματα Condition 1 ανά task (Dataset A, baseline features, χωρίς weight-ing)

B.2.2 Dataset B: PD Speech Features Σύνοψη

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.828 ± 0.008	0.881 ± 0.010	0.890 ± 0.016	0.885 ± 0.006	0.867 ± 0.029
SVM_RBF	0.851 ± 0.024	0.841 ± 0.015	0.986 ± 0.019	0.908 ± 0.015	0.885 ± 0.025
RandomForest	0.882 ± 0.019	0.876 ± 0.012	0.980 ± 0.015	0.925 ± 0.012	0.940 ± 0.013

Table B.2: Αποτελέσματα Condition 1 (Dataset B, baseline features, χωρίς weighting)

Σημείωση: Το Dataset B εμφανίζει ουσιαστικά υψηλότερη απόδοση και χαμηλότερη διακύμανση από το Dataset A, εύρημα συμβατό με πιθανό optimistic bias λόγω άγνωστης επικάλυψης subjects.

B.3 Συνθήκη 2: Extended Features (78) + Unweighted

B.3.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.253	0.433 ± 0.149	0.475 ± 0.106	0.698 ± 0.132
	SVM	0.786 ± 0.181	0.733 ± 0.435	0.567 ± 0.365	0.634 ± 0.386	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.822 ± 0.166
Spontaneous	LR	0.671 ± 0.199	0.500 ± 0.361	0.600 ± 0.435	0.530 ± 0.377	0.783 ± 0.139
	SVM	0.636 ± 0.089	0.533 ± 0.361	0.400 ± 0.279	0.428 ± 0.258	0.460 ± 0.294
	RF	0.779 ± 0.161	0.683 ± 0.410	0.600 ± 0.435	0.605 ± 0.387	0.857 ± 0.171

Table B.3: Αποτελέσματα Condition 2 ανά task (Dataset A, extended features, χωρίς weighting)

B.3.2 Βελτίωση έναντι Baseline (Random Forest, Dataset A)

Task	Δ Accuracy	Δ ROC-AUC	Δ Variance
ReadText	+18.9pp	+23.2pp	Reduced ($0.302 \rightarrow 0.166$)
SpontaneousDialogue	+5.8pp	+2.9pp	Increased ($0.148 \rightarrow 0.171$)

Table B.4: Βελτίωση Condition 2 έναντι Condition 1 (Random Forest)

Παρατήρηση: Το feature extension βελτίωσε αισθητά την απόδοση στο ReadText (+23.2pp ROC-AUC), ενώ στο SpontaneousDialogue παρατηρήθηκαν πιο περιορισμένα

gains (+2.9pp). Αυτό υποδηλώνει ότι τα extended features αποτυπώνουν αποτελεσματικότερα τις δυναμικές της δομημένης ομιλίας σε σύγκριση με την αυθόρμητη ομιλία.

B.4 Συνθήκη 3: Baseline Features (47) + Weighted

B.4.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.235	0.550 ± 0.201	0.528 ± 0.099	0.717 ± 0.139
	SVM	0.704 ± 0.111	0.617 ± 0.371	0.500 ± 0.373	0.519 ± 0.320	0.542 ± 0.312
	RF	0.650 ± 0.148	0.550 ± 0.371	0.400 ± 0.365	0.431 ± 0.306	0.687 ± 0.258
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.693 ± 0.123	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.423 ± 0.312
	RF	0.693 ± 0.123	0.583 ± 0.373	0.600 ± 0.435	0.538 ± 0.326	0.827 ± 0.133

Table B.5: Αποτελέσματα Condition 3 ανά task (Dataset A, baseline features, με weighting)

B.4.2 Επίδραση του Weighting (vs Condition 1, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	+2.1pp	+9.7pp	Improved
SpontaneousDialogue	-2.8pp	-0.1pp	Negligible

Table B.6: Επίδραση του weighting στο Condition 3 έναντι Condition 1 (RF)

Παρατήρηση: Το class weighting βελτίωσε την απόδοση στο ReadText, αλλά είχε αμελητέα επίδραση στο SpontaneousDialogue, γεγονός που υποδηλώνει task-dependent ευαισθησία στον χειρισμό του class imbalance.

B.5 Συνθήκη 4: Extended Features (78) + Weighted

B.5.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.650 ± 0.108	0.650 ± 0.253	0.550 ± 0.201	0.564 ± 0.160	0.698 ± 0.132
	SVM	0.761 ± 0.214	0.700 ± 0.447	0.567 ± 0.365	0.620 ± 0.390	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.805 ± 0.182
Spontaneous	LR	0.696 ± 0.179	0.520 ± 0.356	0.667 ± 0.471	0.563 ± 0.381	0.783 ± 0.139
	SVM	0.664 ± 0.167	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.403 ± 0.347
	RF	0.721 ± 0.203	0.653 ± 0.409	0.600 ± 0.435	0.583 ± 0.373	0.823 ± 0.209

Table B.7: Αποτελέσματα Condition 4 ανά task (Dataset A, extended features, με weighting)

B.5.2 Επίδραση του Weighting (vs Condition 2, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	0.0pp	-1.7pp	Slight decrease
SpontaneousDialogue	-5.8pp	-3.4pp	Decreased

Table B.8: Επίδραση του weighting στο Condition 4 έναντι Condition 2 (RF)

Παρατήρηση: Ο συνδυασμός extended features με class weighting δεν βελτίωσε την απόδοση σε σχέση με τη χρήση extended features μόνο. Αυτό υποδηλώνει ότι feature extension και class weighting αντιμετωπίζουν παρόμοιες πτυχές του classification problem, με diminishing returns όταν εφαρμόζονται από κοινού.

B.6 Matrix Σύγκρισης μεταξύ Conditions

B.6.1 Random Forest ROC-AUC ανά Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	0.590 ± 0.302	0.822 ± 0.166
	Weighted	0.687 ± 0.258	0.805 ± 0.182
Spontaneous	Unweighted	0.828 ± 0.148	0.857 ± 0.171
	Weighted	0.827 ± 0.133	0.823 ± 0.209

Table B.9: Πίνακας σύγκρισης Random Forest ROC-AUC (Dataset A)

B.6.2 Random Forest Accuracy ανά Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	62.9% $\pm$ 17.8%	81.8% $\pm$ 14.0%
	Weighted	65.0% $\pm$ 14.8%	81.8% $\pm$ 14.0%
Spontaneous	Unweighted	72.1% $\pm$ 17.6%	77.9% $\pm$ 16.1%
	Weighted	69.3% $\pm$ 12.3%	72.1% $\pm$ 20.3%

Table B.10: Πίνακας σύγκρισης Random Forest Accuracy (Dataset A)

B.6.3 Κύριες Παρατηρήσεις

1. **To feature extension βελτιώνει σταθερά το ReadText:** +23.2pp ROC-AUC (χωρίς weighting)
2. **To SpontaneousDialogue έχει υψηλότερο baseline:** 0.828 vs 0.590 ROC-AUC με baseline features
3. **To class weighting εμφανίζει μικτά αποτελέσματα:** βελτιώνει τη baseline επίδοση στο ReadText αλλά μειώνει την επίδοση με extended features
4. **Υψηλή διακύμανση σε όλα τα settings:** τα standard deviations συχνά υπερβαίνουν το 0.15, αντανακλώντας το μικρό sample size ($n = 37$)

B.7 Σημειώσεις για τη Statistical Significance

Λόγω υψηλών standard deviations (συχνά > 0.15), τα confidence intervals επικαλύπτονται σε πολλές συγκρίσεις. Αυτό περιορίζει τη δυνατότητα για ισχυρούς στατιστικούς ισχυρισμούς σχετικά με τις διαφορές μεταξύ conditions. Τα αποτελέσματα θα πρέπει να ερμηνεύονται ως **trends** και όχι ως οριστικές κατατάξεις.

B.8 Καμπύλες ROC

Παρουσιάζονται καμπύλες Receiver Operating Characteristic (ROC) για όλους τους πέντε classifiers σε κάθε experimental condition. Οι αχνές καμπύλες αντιστοιχούν σε μεμονωμένα cross-validation folds, ενώ η έντονη καμπύλη αντιστοιχεί στον μέσο όρο των folds με shaded band ± 1 standard deviation. Όλες οι καμπύλες δημιουργήθηκαν με χρήση του extended feature set.




Figure B.1: ROC curves για όλους τους πέντε classifiers στο ReadText task (Dataset A, extended features). Τα shaded bands υποδεικνύουν ± 1 standard deviation στα πέντε cross-validation folds.




Figure B.2: ROC curves για όλους τους πέντε classifiers στο SpontaneousDialogue task (Dataset A, extended features).




Figure B.3: ROC curves για όλους τους πέντε classifiers στο Dataset B (PD Speech Features). Σημειώνεται ότι subject-level deduplication δεν είναι εφικτό για αυτό το dataset: τα αποτελέσματα ενδέχεται να είναι optimistic λόγω πιθανής επικάλυψης subjects μεταξύ folds.

Παράρτημα C

Research Demonstration Application

C.1 Σκοπός και Εύρος

Το παρόν παράρτημα περιγράφει μια web-based research demonstration application που αναπτύχθηκε για να απεικονίσει το end-to-end inference workflow, από το audio upload έως το classification output. Η εφαρμογή σχεδιάστηκε αποκλειστικά για εκπαιδευτικούς και επιδεικτικούς σκοπούς στο πλαίσιο της παρούσας MSc thesis.


Κρίσιμο Disclaimer:

- Η εφαρμογή αυτή **δεν προορίζεται για clinical use, medical diagnosis ή patient screening**
- Τα outputs αντιπροσωπεύουν model confidence scores και όχι clinical diagnoses
- Η εφαρμογή **δεν χρησιμοποιήθηκε για quantitative evaluation** που αναφέρεται στην παρούσα thesis
- Όλα τα evaluation metrics (Chapters 5–6) υπολογίστηκαν μέσω cross-validation σε held-out test folds, ανεξάρτητα από το συγκεκριμένο interface
- Τα αποτελέσματα πρέπει να ερμηνεύονται **μόνο ως research outputs** και απαιτούν επικύρωση από κατάλληλα καταρτισμένους medical professionals

Η εφαρμογή καταδεικνύει τη feasibility ενσωμάτωσης των trained models σε user-facing interface, διατηρώντας σαφή όρια μεταξύ research exploration και clinical deployment.

C.2 Αρχιτεκτονική Συστήματος

Η demonstration application ακολουθεί modular architecture με διαχωρισμό ευθυνών μεταξύ web interface, inference orchestration και core machine learning pipeline:



Βασικά Components:

1. **Flask Web Server (`app.py`):** Διαχειρίζεται HTTP routes, file uploads και template rendering. Κάνει αυστηρά import μόνο το adapter module, εξασφαλίζοντας zero coupling με εσωτερικές λεπτομέρειες υλοποίησης του ML pipeline.
2. **Inference Adapter (`inference_adapter.py`):** Παρέχει σταθερό interface που περιβάλλει το core inference API. Εκτελεί audio normalization (any format → mono 22,050 Hz WAV), εμπλουτίζει τα prediction outputs με display metadata και εξασφαλίζει ότι το model switching δεν απαιτεί αλλαγές σε Flask code.
3. **Core ML Pipeline:** Επαναχρησιμοποιεί τα ίδια feature extraction και inference modules που χρησιμοποιήθηκαν στα experiments (`parkinsons_voice_classification.inference`), εξασφαλίζοντας consistency μεταξύ evaluation και demonstration.
4. **Audio Processing (`audio_utils.py`):** Κανονικοποιεί τα uploaded audio files (WAV, MP3, WebM, Opus, FLAC) σε standardized mono 22,050 Hz PCM-16 WAV format πριν από το feature extraction.

Design Invariants:

- Το model switching (RandomForest ↔ Logistic Regression ↔ SVM) ελέγχεται μόνο μέσω configuration file· δεν απαιτούνται template/route changes
- Η feature set selection (baseline 47 vs. extended 78) είναι configuration-driven
- Η task selection (ReadText vs. SpontaneousDialogue) φορτώνει το αντίστοιχο trained model artifact

Η αρχιτεκτονική αυτή διασφαλίζει ότι το demonstration παραμένει ευθυγραμμισμένο με το experimental pipeline, παρέχοντας ταυτόχρονα ελεγχόμενο interface για external users.

C.3 Ροή Αλληλεπίδρασης Χρήστη

Η εφαρμογή υποστηρίζει δύο τρόπους εισόδου:

C.3.1 Audio Upload Workflow

The screenshot displays the 'Parkinson's Voice Classification' web interface. At the top, it says 'MSc Thesis Research Demonstration'. A yellow warning box states: 'Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.' Below this, there are two tabs: 'Upload File' (selected) and 'Record Audio'. The 'Upload File' tab contains the 'Upload Voice Recording' section, which instructs users to upload an audio file of a ReadText speech task. It lists supported formats (WAV, MP3, WebM, etc.) and shows a file selection area with a 'Choose File' button and the text 'No file chosen'. Below this is a large blue 'Analyze Recording' button. At the bottom, a 'Current Model Configuration' section shows: Model: RandomForest, Task: ReadText, Features: baseline (47), and Training Samples: 37. A link 'About this project' is at the very bottom.

Figure C.1: Upload interface για audio file analysis. Οι χρήστες επιλέγουν recording του ReadText task σε common formats (WAV, MP3, WebM). Το interface εμφανίζει το τρέχον model configuration (RandomForest, baseline features, 37 training samples).

Η Figure C.1 παρουσιάζει το file upload interface, όπου οι χρήστες μπορούν να επιλέξουν pre-recorded audio files για analysis. Το interface δηλώνει με σαφήνεια τον

research-only σκοπό και εμφανίζει το active model configuration.

C.3.2 Direct Audio Recording

The screenshot displays the 'Parkinson's Voice Classification' web application. At the top, it says 'MSc Thesis Research Demonstration'. A yellow warning box states: 'Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.' Below this are two tabs: 'Upload File' and 'Record Audio', with 'Record Audio' being the active tab. The 'Record Voice Sample' section contains a 'ReadText Task Prompt' box with the text: 'The quick brown fox jumps over the lazy dog. Peter Piper picked a peck of pickled peppers. How much wood would a woodchuck chuck if a woodchuck could chuck wood?' and a sub-prompt: 'Read this text clearly and naturally at a comfortable pace.' Below the prompt is a red 'Recording...' indicator showing '1s'. At the bottom of this section are two buttons: 'Start Recording' (with a microphone icon) and 'Stop Recording' (with a square icon). At the very bottom, the 'Current Model Configuration' is shown in a table:

Model:	RandomForest
Task:	ReadText
Features:	baseline (47)
Training Samples:	37

Figure C.2: In-browser audio recording interface. Οι χρήστες διαβάζουν δυνατά το εμφανιζόμενο ReadText prompt και καταγράφουν απευθείας μέσω του device microphone. Το recorded audio επεξεργάζεται με το ίδιο normalization και feature extraction pipeline που χρησιμοποιείται και για τα uploaded files.

Η Figure C.2 παρουσιάζει τη δυνατότητα in-browser recording, υλοποιημένη με χρήση Web Audio API και JavaScript. Οι χρήστες ακολουθούν το on-screen ReadText prompt ώστε να παραχθεί standardized speech sample. Τα recordings συλλαμβάνονται στο native sample rate του browser και κανονικοποιούνται server-side πριν από το inference.

C.3.3 Processing Steps

Ανεξάρτητα από τον τρόπο εισόδου, εκτελούνται τα ακόλουθα βήματα:

1. **Audio normalization:** Μετατροπή σε mono 22,050 Hz PCM-16 WAV
2. **Feature extraction:** Εξαγωγή 47 acoustic features (baseline) ή 78 features (extended) με το ίδιο pipeline των experiments
3. **Model inference:** Φόρτωση trained model artifact (π.χ. `RandomForest_ReadText_baseline.joblib`) και πρόβλεψη class probabilities
4. **Result display:** Παρουσίαση prediction, probabilities, extracted feature values και global feature importance

C.4 Ερμηνεία Output και Περιορισμοί

C.4.1 Displayed Information

Η Figure C.3 παρουσιάζει αντιπροσωπευτική οθόνη αποτελεσμάτων μετά την analysis:




Figure C.3: Παράδειγμα output από το research demonstration interface. Το prediction (“PD” με 81% confidence) εμφανίζεται εμφανώς με ρητό disclaimer ότι δεν αποτελεί medical diagnosis. Το interface δείχνει extracted acoustic features, analysis metadata (file name, model, task, feature count) και top global feature importances για interpretability.

Το output περιλαμβάνει:

1. **Class Prediction:** Binary label (PD ή HC) με την υψηλότερη probability
2. **Class Probabilities:** Model confidence scores για κάθε class (άθροισμα 100%)
3. **Extracted Features:** Βασικές acoustic μετρήσεις (π.χ., F_0 , jitter, MFCC coefficients) με τιμές και περιγραφές
4. **Analysis Metadata:** File name, model type, task, feature count
5. **Top Feature Importances:** Global feature rankings από το trained RandomForest model (μέσω Gini importance)

C.4.2 Κρίσιμοι Περιορισμοί (Τι ΔΕΝ Σημαίνει το Output)

Οι users και evaluators πρέπει να λαμβάνουν υπόψη τους ακόλουθους περιορισμούς:

- **Probabilities $\neq$ Diagnosis:** Το 81% confidence στη Figure C.3 αντανακλά το uncertainty estimate του model με βάση την training data distribution. **Δεν** υποδεικνύει 81% πιθανότητα ότι το άτομο έχει Parkinson's Disease.
- **Training Distribution Dependency:** Τα model outputs είναι έγκυρα μόνο για speech samples παρόμοια με το MDVR-KCL training set (smartphone recordings, ReadText task, χωρίς σοβαρά recording artifacts). Η generalization σε διαφορετικές recording conditions, γλώσσες ή πληθυσμούς είναι άγνωστη.
- **No Clinical Validation:** Το model εκπαιδεύτηκε σε μικρό dataset ($n = 37$ subjects) και δεν έχει υποβληθεί σε clinical validation, regulatory approval ή external cohort testing.
- **Evaluation Exclusion:** Τα outputs από αυτό το interface **δεν χρησιμοποιήθηκαν** για τον υπολογισμό των performance metrics που αναφέρονται στο Chapter 6. Όλα τα quantitative results προκύπτουν από grouped cross-validation σε independent test folds.
- **Feature Importance Caveats:** Τα displayed importances αντανακλούν *global* model behavior (σε όλα τα training samples), όχι *per-sample* contributions. Η υψηλή σημαντικότητα δεν συνεπάγεται ότι το feature ήταν decisive για το συγκεκριμένο uploaded recording.

C.5 Reproducibility και Συνέπεια

Το demonstration interface εξασφαλίζει alignment με το experimental pipeline μέσω των εξής:

1. **Shared Codebase:** Χρησιμοποιεί τα ίδια feature extraction modules (`features/prosodic.py`, `features/spectral.py`) με τα CLI-based experiments
2. **Deterministic Inference:** Φορτώνει τα ίδια serialized model artifacts (`.joblib` files) που παρήχθησαν κατά το training
3. **Configuration-Driven:** Όλες οι παράμετροι (feature set, model choice, task) ελέγχονται μέσω `config.py`, εξασφαλίζοντας συνέπεια σε CLI και web interfaces
4. **Fixed Random Seeds:** Αν και το inference είναι deterministic (χωρίς stochastic components), τα loaded models εκπαιδεύτηκαν με fixed random seeds (`seed = 42`) για reproducibility

Ο σχεδιασμός αυτός διασφαλίζει ότι τα demonstration outputs αντανakλούν την πραγματική συμπεριφορά των evaluated models και όχι ξεχωριστή reimplementation.

C.6 Σύνοψη

Η research demonstration application παρέχει μια απτή απεικόνιση του voice-based PD classification pipeline, γεφυρώνοντας το χάσμα μεταξύ algorithmic research και πιθανής real-world interaction. Ωστόσο, πρέπει να ερμηνεύεται αυστηρά εντός του intended scope της:

- **Educational tool** για thesis defense και research communication
- **Not a diagnostic system** και ακατάλληλο για clinical decision-making
- **Validation artifact** που επιβεβαιώνει τη λειτουργικότητα του inference pipeline
- **Not used for evaluation** — όλα τα metrics προήλθαν από cross-validation

Μελλοντική εργασία προς clinical deployment θα απαιτούσε: (1) validation σε independent cohorts ($n > 500$), (2) regulatory approval (π.χ., FDA clearance, CE marking), (3) prospective clinical trials, (4) integration με clinical workflows και (5) continuous monitoring για performance drift. Το παρόν demonstration αποτελεί early feasibility prototype και όχι production-ready system.

Βιβλιογραφία

- [1] A. K. Ho, R. Iannsek, C. Marigliani, J. L. Bradshaw, and S. Gates, “Speech impairment in a large sample of patients with Parkinson’s disease,” *Behavioural Neurology*, vol. 11, no. 3, pp. 131–137, 1999.
- [2] B. T. Harel, M. S. Cannizzaro, and P. J. Snyder, “Acoustic characteristics of Parkinsonian speech: a potential biomarker of early disease progression and treatment,” *Journal of Neurolinguistics*, vol. 17, no. 6, pp. 439–453, 2004.
- [3] M. A. Little, P. E. McSharry, E. J. Hunter, J. Spielman, and L. O. Ramig, “Suitability of dysphonia measurements for telemonitoring of Parkinson’s disease,” *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 4, pp. 1015–1022, 2009.
- [4] A. Tsanas, M. A. Little, P. E. McSharry, and L. O. Ramig, “Accurate telemonitoring of Parkinson’s disease progression by noninvasive speech tests,” *IEEE Transactions on Biomedical Engineering*, vol. 57, no. 4, pp. 884–893, 2010.
- [5] J. R. Duffy, *Motor speech disorders: Substrates, differential diagnosis, and management*, 3rd ed. Elsevier Health Sciences, 2012.
- [6] H. Sedigh Malekroodi, B.-i. Lee, and M. Yi, “Voice-based detection of Parkinson’s disease using machine and deep learning approaches: A systematic review,” *Bioengineering*, vol. 12, no. 11, p. 1279, 2025.
- [7] D. Xavier, V. Felizardo, B. Ferreira, H. Zacarias, M. Pourvabab, L. Souza-Pereira, and N. M. Garcia, “Voice analysis in Parkinson’s disease—a systematic literature review,” *Artificial Intelligence in Medicine*, vol. 163, p. 103109, 2025.
- [8] H. Wright and V. Aharonson, “Vocal feature changes for monitoring Parkinson’s disease progression—a systematic review,” *Brain Sciences*, vol. 15, no. 3, p. 320, 2025.
- [9] L. O. Ramig, C. Fox, and S. Sapir, “Speech treatment for Parkinson’s disease,” *Expert Review of Neurotherapeutics*, vol. 8, no. 2, pp. 297–309, 2008.

- [10] S. Skodda, W. Visser, and U. Schlegel, “Intonation and speech rate in Parkinson’s disease: General and dynamic aspects and responsiveness to levodopa admission,” *Journal of Voice*, vol. 25, no. 4, pp. e199–e205, 2011.
- [11] J. R. Orozco-Arroyave, J. D. Arias-Londoño, J. F. V. Bonilla, M. C. Gonzalez-Rativa, and E. Nöth, “Automatic detection of Parkinson’s disease in running speech spoken in three different languages,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2016, pp. 4785–4789.
- [12] M. A. Little, P. E. McSharry, S. J. Roberts, D. A. Costello, and I. M. Moroz, “Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection,” *BioMedical Engineering OnLine*, vol. 6, no. 1, p. 23, 2007, introduced nonlinear dynamic features for voice analysis.
- [13] H. Jaeger, D. Trivedi, and M. Stadtschnitzer, “MDVR-KCL: Mobile device voice recordings at King’s College London,” 2019, collected 26–29 September 2017 at King’s College Hospital, London, UK. [Online]. Available: <https://zenodo.org/records/2867215>
- [14] D. Biswas, “Parkinson’s disease speech signal features,” 2020, originally from UCI Machine Learning Repository. [Online]. Available: <https://www.kaggle.com/datasets/dipayanbiswas/parkinsons-disease-speech-signal-features>
- [15] C. M. Bishop, *Pattern recognition and machine learning*. Springer, 2006.
- [16] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [17] N. Sáenz-Lechón, J. Godino-Llorente, V. Osma-Ruiz, and P. Gómez-Vilda, “Methodological issues in the development of automatic systems for voice pathology detection,” *Biomedical Signal Processing and Control*, vol. 1, no. 2, pp. 120–128, 2006, systematic review of methodological issues in voice pathology detection.
- [18] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [19] G. Solana-Lavalle and R. Rosas-Romero, “Analysis of voice as an assisting tool for detection of Parkinson’s disease and its subsequent clinical interpretation,” *Biomedical Signal Processing and Control*, vol. 66, p. 102415, 2021.
- [20] B. McFee, C. Raffel, D. Liang, D. P. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and music signal analysis in python,” Software, 2015. [Online]. Available: <https://librosa.org>

-
- [21] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [22] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.