



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Approved by the examination committee on [26 Φεβρουαρίου 2026].

.....		
Γεώργιος Ματσόπουλος	Ουρανία Πετροπούλου	[Examiner 2 Name]
Καθηγητής ΗΜΜΥ Ε.Μ.Π.	Επίκουρη Καθηγήτρια	[Examiner 2 Title]
	ΗΜΜΥ Ε.Μ.Π.	

Αθήνα, Φεβρουάριος 2026

Μάριος Χρήστος Συρμακέζης

Διπλωματούχος Ηλεκτρολόγος Μηχανικός και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright © Μάριος Χρήστος Συρμακέζης, 2026.

All rights reserved.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η νόσος του Πάρκινσον (PD) είναι μια νευροεκφυλιστική διαταραχή που, πέρα από τα κινητικά συμπτώματα, επηρεάζει συχνά και την ομιλία. Η εργασία αυτή εξετάζει αν μπορούμε να εντοπίσουμε τη νόσο μέσω της φωνής, χρησιμοποιώντας κλασικές μεθόδους μηχανικής μάθησης.

Για τον σκοπό αυτό χρησιμοποιήθηκαν δύο διαφορετικά σύνολα δεδομένων ομιλίας, με την ίδια διαδικασία ανάλυσης και αξιολόγησης και στα δύο.

Το πρώτο σύνολο δεδομένων, Mobile Device Voice Recordings at King's College London, περιλάμβανε κατηγοριοποιημένα αρχεία ήχου (WAV) που είχαν καταγραφεί με ειδικό εξοπλισμό. Οι ηχογραφήσεις ήταν ακατέργαστες, γι' αυτό προχωρήσαμε στην εξαγωγή ακουστικών χαρακτηριστικών για να μετατρέψουμε τα δεδομένα σε μια αριθμητική μορφή που είναι κατάλληλη για ανάλυση.

Το δεύτερο σύνολο δεδομένων, με τίτλο PD speech signal features από το Kaggle (UCI), περιλάμβανε ακουστικά χαρακτηριστικά που είχαν ήδη εξαχθεί σε μορφή csv. Σε αυτή την περίπτωση, δεν χρειάστηκε να γίνει επεξεργασία ήχου αφού τα αριθμητικά χαρακτηριστικά ήταν ήδη διαθέσιμα. Και στα δύο σύνολα δεδομένων, ο σκοπός ήταν να διαπιστωθεί αν τα μοντέλα μπορούν να αναγνωρίσουν άτομα με Πάρκινσον μόνο από τη φωνή τους.

Αξιολογήθηκαν πέντε αλγόριθμοι: Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting και XGBoost. Επιπλέον, εξετάστηκε αν η αύξηση του αριθμού των χαρακτηριστικών βελτιώνει την απόδοση, καθώς και αν η χρήση βαρών κλάσης (class weighting) βοηθά στην εξισορρόπηση των ομάδων PD και HC.

Χρησιμοποιήθηκε επίσης διασταυρωμένη επικύρωση (cross-validation), ώστε να μην υπάρχει διαρροή δεδομένων.

Τα αποτελέσματα έδειξαν ότι ο Random Forest ήταν ο πιο αποτελεσματικός. Η αύξηση των χαρακτηριστικών βελτίωσε σημαντικά την απόδοση των περισσότερων μοντέλων. Η χρήση βαρών είχε μικρή θετική επίδραση κυρίως στον Random Forest και μικρή ή

αρνητική στους υπόλοιπους.

Συνολικά, η εργασία δείχνει ότι η ανάλυση φωνής σε συνδυασμό με μηχανική μάθηση μπορεί να βοηθήσει στην αναγνώριση της νόσου του Πάρκινσον. Ωστόσο, τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή, λόγω ορισμένων περιορισμών, όπως πιθανές πολλαπλές ηχογραφήσεις του ίδιου ασθενούς και η διαφορά μεγέθους μεταξύ των δύο datasets.

Παρά τους περιορισμούς, τα ευρήματα δείχνουν ότι η σωστή επεξεργασία δεδομένων και η κατάλληλη χρήση αλγορίθμων μπορούν να οδηγήσουν μελλοντικά σε πιθανή αναγνώριση της νόσου μέσω της φωνής, ακόμα και με απλά καθημερινά μικρόφωνα. Αυτό είναι σημαντικό, γιατί η έγκαιρη ανίχνευση θα μπορούσε να συμβάλει σε νωρίτερη θεραπεία και καλύτερη ποιότητα ζωής για τους ασθενείς.

Λέξεις Κλειδιά: Νόσος του Πάρκινσον, Δυσαρθρία, Φωνητικοί Βιοδείκτες, Ακουστικά Χαρακτηριστικά, Μηχανική Μάθηση, Εξαγωγή Χαρακτηριστικών, Διασταυρούμενη Επικύρωση, Μη Ισορροπημένα Δεδομένα, Αναπαραγωγιμότητα, Ταξινόμηση Ομιλίας, Υπολογιστική Νοημοσύνη στην Υγεία

Abstract

Parkinson's disease (PD) is a progressive neurological disorder characterized by motor symptoms which are typically accompanied by speech difficulties.

In this paper we assess if Parkinson's disease can be diagnosed through the voice based on classical machine learning approaches.

We worked with two different datasets, each analyzed using an identical methodology, i.e., analysis and validation procedure.

The first dataset, Mobile Device Voice Recordings at King's College London, contained categorized audio files (WAV) recorded with advanced recording equipment in a controlled environment.

These recordings were unprocessed, therefore we had to process the audio to extract the acoustic features to transform the data into a numeric format that would allow us to perform the analysis.

The second dataset, PD speech signal features from Kaggle (UCI), contained pre-extracted acoustic features in csv format.

Therefore, we did not need to process the audio since the pre-processed features were ready to be analyzed.

Both datasets were processed to see if the models could distinguish between individuals with PD and healthy controls (HC) only through their voice.

We compared five machine learning algorithms, i.e., Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting, and XGBoost.

Furthermore, we investigated whether increasing the number of features in the training set enhances the model performance, and whether the application of class weighting enhances the model performance particularly for the PD group.

To avoid data leakage, cross-validation was performed.

The results indicate that Random Forest algorithm outperformed all other tested algorithms.

An increase of the number of features in the training set positively affected the majority of the tested models.

Class weighting had a limited positive impact especially on Random Forest, while the other algorithms either did not benefit from class weighting or were even negatively affected.

In general, the study demonstrates that voice-based analysis combined with machine learning may support the diagnosis of Parkinson's disease.

Nevertheless, the results have to be viewed critically due to some limitations, e.g., potential multiple recordings of the same patient and the significant differences in terms of sample sizes between the two datasets.

Regardless of these limitations, the study shows that adequate processing of the data, along with the appropriate application of machine learning algorithms can result in a potential disease identification through voice, using regular microphones, available in everyday devices like smartphones.

Early detection may lead to the initiation of therapy at an earlier time point and improve the quality of life of patients.

Keywords: Parkinson's Disease; Dysarthria; Voice Biomarkers; Acoustic Features; Machine Learning; Feature Extraction; Cross-Validation; Imbalanced Data; Reproducibility; Speech Classification; Computational Health Intelligence

Πίνακας Περιεχομένων

Περίληψη	7
Abstract	10
Κατάλογος Σχημάτων	21
Κατάλογος Πινάκων	24
1 Εισαγωγή	25
1.1 Ιστορικό και κίνητρα	25
1.2 Διατύπωση του προβλήματος	26
1.3 Ερευνητικοί στόχοι	27
1.4 Συνεισφορές	28
1.5 Οργάνωση της εργασίας	28
1.6 Όρια πεδίου εφαρμογής	29
2 Βιβλιογραφική ανασκόπηση	31
2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας	31
2.2 Ανίχνευση έναντι παρακολούθησης	32
2.3 Ταξινόμηση ακουστικών χαρακτηριστικών	33
2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας	34
2.4 Σύνολα δεδομένων που χρησιμοποιούνται στην έρευνα για τη φωνή των ασθενών με Πάρκινσον	34
2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου	35
2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών	36
2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων	37
2.4.4 Ετερογένεια επικύρωσης	37
2.4.5 Ο ρόλος των εργασιών ομιλίας	37
2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD	38

2.5.1	Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις	39
2.6	Μεθοδολογικά ζητήματα στη βιβλιογραφία	39
2.6.1	Διαρροή δεδομένων	39
2.6.2	Ανισορροπία κλάσεων	40
2.6.3	Αναπαραγωγικότητα	40
2.6.4	Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων	40
2.6.5	Ερμηνευσιμότητα	41
2.7	Έλλειμμα στην έρευνα	41
2.8	Περίληψη	42
3	Data Description	43
3.1	Dataset A: MDVR-KCL	43
3.1.1	Source and Collection	43
3.1.2	Audio Specifications	44
3.1.3	Speech Tasks	44
3.1.4	Class Distribution	44
3.1.5	Known Anomalies	45
3.2	Dataset B: PD Speech Features	45
3.2.1	Source	45
3.2.2	Collection Context	45
3.2.3	Data Format	45
3.2.4	Class Distribution	46
3.2.5	Feature Categories	46
3.2.6	Methodological Caveats	46
3.3	Cross-Dataset Comparison	47
3.3.1	Key Differences	47
4	Methodology	48
4.1	Feature Extraction Pipeline	48
4.1.1	Pipeline Architecture	48
4.1.2	Audio Preprocessing	48
4.1.3	Prosodic Features (21 features)	49
4.1.4	Spectral Features	51
4.1.5	Total Feature Counts	53
4.2	Feature Set Comparison	53
4.2.1	Rationale for Extended Features	53
4.2.2	Feature Extraction Reproducibility	53
4.3	Machine Learning Models	53

4.3.1	Model Specifications	53
4.3.2	Class Weighting	55
4.4	ML Pipeline Architecture	56
4.4.1	Pipeline Structure	56
4.4.2	Feature Standardisation	56
4.5	Evaluation Framework	57
4.5.1	Cross-Validation Strategy	57
4.5.2	Evaluation Metrics	58
5	Experimental Design	59
5.1	Research Questions	59
5.2	Experimental Matrix	59
5.2.1	$2 \times 2 \times 5$ Factorial Design	59
5.2.2	Total Experimental Runs	60
5.3	Experimental Protocols and Reproducibility	60
6	Results	61
6.1	Summary of Best Results	61
6.1.1	Dataset A (MDVR-KCL) — Best Performance	61
6.1.2	Dataset B (Benchmark Comparison)	61
6.2	Condition 1: Baseline Features + Unweighted	62
6.2.1	Task: ReadText	63
6.2.2	Task: Spontaneous Dialogue	63
6.3	Condition 2: Extended Features + Unweighted	63
6.3.1	Task: ReadText	63
6.3.2	Task: Spontaneous Dialogue	64
6.4	Feature Ablation Analysis	65
6.4.1	ROC-AUC Improvement from Feature Extension (ReadText)	65
6.4.2	ROC-AUC Improvement from Feature Extension (Spontaneous)	66
6.5	Class Weighting Analysis	66
6.5.1	ReadText Task — Baseline Features	66
6.5.2	Extended Features — All Tasks	66
6.6	Precision-Recall Tradeoffs	66
6.6.1	Random Forest (Extended Features)	67
6.7	Confusion Matrix Analysis	67
6.7.1	Dataset A — ReadText	67
6.7.2	Dataset A — Spontaneous Dialogue	68
6.7.3	Dataset B	68

7	Discussion	69
7.1	Interpretation of Key Findings	69
7.1.1	Feature Extension Impact	69
7.1.2	Class Weighting Effects	70
7.1.3	Model Performance Hierarchy	71
7.1.4	High Variance Across Folds	71
7.2	Comparison with Literature	72
7.2.1	Performance Context	72
7.2.2	Methodological Comparison	73
7.3	Feature Importance Analysis	73
7.3.1	Most Discriminative Features (Dataset A)	73
7.3.2	Dataset B Feature Complexity	74
7.4	Task-Dependent Performance Patterns	74
7.4.1	ReadText vs Spontaneous Dialogue	74
8	Limitations and Threats to Validity	76
8.1	Sample Size Limitations	76
8.1.1	Dataset A: Small Subject Pool	76
8.2	Subject Identifier Limitations	76
8.2.1	Dataset B: Missing Subject IDs	76
8.2.2	Comparison Limitations	77
8.3	Feature Extraction Limitations	77
8.3.1	Deterministic Feature Set	77
8.3.2	Audio Quality Assumptions	77
8.4	Model Limitations	78
8.4.1	No Hyperparameter Tuning	78
8.5	Methodological Limitations	78
8.5.1	No External Validation	78
8.5.2	Class Imbalance Handling	79
8.6	Threats to Validity	79
8.6.1	Internal Validity	79
8.6.2	External Validity	80
9	Conclusion	81
9.1	Summary of Work	81
9.1.1	Contributions	81
9.2	Key Findings	82
9.2.1	Primary Results	82

9.3	Research Questions Answered	82
9.3.1	RQ1: How do classical ML models perform on PD voice classification?	82
9.3.2	RQ2: Does feature set extension improve classification performance?	82
9.3.3	RQ3: Does class weighting improve performance on imbalanced datasets?	83
9.3.4	RQ4: How do results compare between grouped and standard CV?	84
9.3.5	RQ5: Do speech tasks yield different classification performance?	84
9.4	Implications	85
9.4.1	For Researchers	85
9.4.2	For Practitioners	85
9.4.3	For Dataset Creators	85
9.5	Future Directions	85
9.6	Closing Remarks	86
A	Feature Importance Tables	87
A.1	Overview	87
A.2	Dataset A — ReadText Task	87
A.2.1	Random Forest — Top 20 Features	87
A.2.2	Logistic Regression — Top 20 Features	88
A.2.3	Gradient Boosting — Top 10 Features	89
A.2.4	XGBoost — Top 10 Features	90
A.3	Dataset A — SpontaneousDialogue Task	91
A.3.1	Random Forest — Top 20 Features	91
A.3.2	Logistic Regression — Top 10 Features	91
A.3.3	Gradient Boosting — Top 10 Features	92
A.3.4	XGBoost — Top 10 Features	93
A.4	Dataset B — PD Speech Features	94
A.4.1	Random Forest — Top 10 Features	95
A.4.2	Logistic Regression — Top 10 Features	95
A.4.3	Gradient Boosting — Top 10 Features	96
A.4.4	XGBoost — Top 10 Features	97
A.5	Cross-Task Feature Stability	97
A.6	Feature Category Analysis	98
B	Detailed Results Tables	100
B.1	Overview	100
B.2	Condition 1: Baseline Features (47) + Unweighted	100
B.2.1	Dataset A: MDVR-KCL Summary	100
B.2.2	Dataset B: PD Speech Features Summary	101

B.3	Condition 2: Extended Features (78) + Unweighted	101
B.3.1	Dataset A: MDVR-KCL Summary	101
B.3.2	Improvement over Baseline (Random Forest, Dataset A)	101
B.4	Condition 3: Baseline Features (47) + Weighted	102
B.4.1	Dataset A: MDVR-KCL Summary	102
B.4.2	Effect of Weighting (vs Condition 1, Random Forest)	102
B.5	Condition 4: Extended Features (78) + Weighted	102
B.5.1	Dataset A: MDVR-KCL Summary	102
B.5.2	Effect of Weighting (vs Condition 2, Random Forest)	103
B.6	Cross-Condition Comparison Matrix	103
B.6.1	Random Forest ROC-AUC by Task	103
B.6.2	Random Forest Accuracy by Task	103
B.6.3	Key Observations	104
B.7	Statistical Significance Notes	104
B.8	ROC Curves	104
C	Research Demonstration Application	108
C.1	Purpose and Scope	108
C.2	System Architecture	109
C.3	User Interaction Flow	110
C.3.1	Audio Upload Workflow	110
C.3.2	Direct Audio Recording	111
C.3.3	Processing Steps	111
C.4	Output Interpretation and Limitations	112
C.4.1	Displayed Information	112
C.4.2	Critical Limitations (What the Output Does NOT Mean)	113
C.5	Reproducibility and Consistency	113
C.6	Summary	114

Κατάλογος Σχημάτων

4.1	Feature extraction pipeline architecture. Each audio file produces one feature vector.	48
6.1	Random Forest feature importance (Dataset B). The top features are dominated by advanced signal processing metrics often unavailable in standard clinical settings.	62
6.2	Random Forest feature importance for ReadText task (Extended features). Fundamental frequency (F_0) statistics appear highly predictive.	64
6.3	Random Forest feature importance for Spontaneous Dialogue task (Extended features). MFCC features show increased importance compared to ReadText.	65
6.4	Aggregated confusion matrices for the ReadText task (Extended features, Grouped 5-Fold CV, $n = 37$ subjects). Each cell reports the total out-of-fold count and its percentage of all predictions. These results should be interpreted cautiously given the small sample size.	67
6.5	Aggregated confusion matrices for the Spontaneous Dialogue task (Extended features, Grouped 5-Fold CV, $n = 36$ subjects). This task yielded the highest overall ROC-AUC in the study (0.857 ± 0.171 , Random Forest).	68
6.6	Aggregated confusion matrices for Dataset B (Stratified 5-Fold CV, $n = 756$ recordings). The substantially larger sample size yields well-separated confusion patterns with low variance. Results may be optimistic due to unknown subject overlap across folds.	68
A.1	Logistic Regression coefficient magnitudes (ReadText)	88
A.2	Gradient Boosting feature importances (ReadText). F0 max dominates strongly (0.229 ± 0.179), consistent with pitch dysregulation in PD.	89
A.3	XGBoost feature importances (ReadText). Importance is more distributed than Gradient Boosting, with F0 and intensity features sharing dominance.	90
A.4	Logistic Regression coefficient magnitudes (Spontaneous Dialogue)	92

A.5	Gradient Boosting feature importances (Spontaneous Dialogue). MFCC-5 (0.342 ± 0.204) strongly dominates, reflecting spectral tilt changes in spontaneous PD speech.	93
A.6	XGBoost feature importances (Spontaneous Dialogue). MFCC-5 and shimmer features dominate, consistent with RF and GB findings for this task. . . .	94
A.7	Feature importance for Dataset B (PD Speech Features) — Random Forest and Logistic Regression.	96
A.8	Feature importance for Dataset B — Gradient Boosting and XGBoost. TQWT energy/entropy features from high-frequency bands dominate across both models.	97
A.9	Feature importance aggregated by broad acoustic categories.	99
B.1	ROC curves for all five classifiers on the ReadText task (Dataset A, extended features). Shaded bands indicate ± 1 standard deviation across the five cross-validation folds.	105
B.2	ROC curves for all five classifiers on the SpontaneousDialogue task (Dataset A, extended features).	106
B.3	ROC curves for all five classifiers on Dataset B (PD Speech Features). Note that subject-level deduplication is not possible for this dataset; results may be optimistic due to potential subject overlap across folds.	107
C.1	Upload interface for audio file analysis. Users select a ReadText task recording in any common format (WAV, MP3, WebM). The interface displays the current model configuration (RandomForest, baseline features, 37 training samples).	110
C.2	In-browser audio recording interface. Users read the displayed ReadText prompt aloud and record directly via their device microphone. The recorded audio is processed through the same normalization and feature extraction pipeline as uploaded files.	111
C.3	Example output from the research demonstration interface. The prediction (“PD” with 81% confidence) is displayed prominently with an explicit disclaimer that this is not a medical diagnosis. The interface shows extracted acoustic features, analysis metadata (file name, model, task, feature count), and top global feature importances for interpretability.	112

Κατάλογος Πινάκων

1.1	Περίληψη των κεφαλαίων της εργασίας	29
2.1	Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD	33
3.1	MDVR-KCL data collection context	43
3.2	Audio specifications for Dataset A	44
3.3	Speech tasks in MDVR-KCL dataset	44
3.4	Collection context for Dataset B	45
3.5	Class distribution in Dataset B	46
3.6	Feature categories in Dataset B (752 total)	46
3.7	Detailed cross-dataset comparison	47
4.1	Prosodic feature breakdown	50
4.2	Baseline spectral features	52
4.3	Extended spectral features (new features in bold)	52
4.4	Total feature counts by configuration	53
4.5	Model specifications. All parameters fixed before experiments.	54
4.6	Cross-validation strategies	57
4.7	Evaluation metrics	58
5.1	Experimental conditions (20 total: 4 conditions $\times$ 5 models each). Note: class weighting applies only to LR, SVM, and RF; GB and XGB do not support <code>class_weight</code> natively.	60
5.2	Total experimental runs across all datasets and conditions	60
6.1	Best performance on Dataset A	61
6.2	Dataset B performance using baseline (unweighted) configuration. Note the substantially lower variance compared to Dataset A.	61
6.3	Condition 1 — ReadText results	63
6.4	Condition 1 — Spontaneous Dialogue results	63

6.5	Condition 2 — ReadText results	63
6.6	Condition 2 — Spontaneous Dialogue results	64
6.7	Feature ablation — ReadText	65
6.8	Feature ablation — Spontaneous Dialogue	66
6.9	Class weighting impact on ReadText (baseline features). Random Forest showed modest improvement.	66
6.10	Random Forest precision-recall profile. ReadText configuration favors precision (fewer false positives).	67
7.1	Feature extension impact by task. ReadText showed dramatically larger improvements, suggesting baseline features were insufficient for structured speech.	69
7.2	Extended feature contributions	70
7.3	Class weighting effects	70
7.4	Variance comparison: small vs large datasets. Standard deviations scale approximately as $1/\sqrt{n}$	71
7.5	Comparison with literature	72
7.6	Methodological comparison. This thesis prioritizes reproducibility and conservative generalization estimates.	73
7.7	Top 5 Random Forest features by task (Extended feature set). Importance values represent mean decrease in impurity.	73
7.8	Top 5 Dataset B features (Random Forest). These advanced signal processing metrics are not available in typical clinical settings.	74
7.9	Task comparison across configurations. Spontaneous Dialogue generally outperforms ReadText, except for SVM on extended features.	74
8.1	Dataset A sample size metrics	76
8.2	Fixed hyperparameters (all experiments)	78
8.3	Internal validity threats	79
8.4	External validity threats	80
9.1	Primary research findings (Dataset A, baseline class weighting)	82
A.1	Random Forest feature importance — ReadText (top 10)	87
A.2	Logistic Regression feature importance — ReadText (top 10)	88
A.3	Gradient Boosting feature importance — ReadText (top 10)	89
A.4	XGBoost feature importance — ReadText (top 10)	90
A.5	Random Forest feature importance — SpontaneousDialogue (top 10)	91
A.6	Logistic Regression feature importance — SpontaneousDialogue (top 10)	91
A.7	Gradient Boosting feature importance — SpontaneousDialogue (top 10)	92

A.8	XGBoost feature importance — SpontaneousDialogue (top 10)	93
A.9	Random Forest feature importance — Dataset B (top 10)	95
A.10	Logistic Regression feature importance — Dataset B (top 10)	95
A.11	Gradient Boosting feature importance — Dataset B (top 10)	96
A.12	XGBoost feature importance — Dataset B (top 10)	97
A.13	Cross-task feature stability (Random Forest top-10)	98
A.14	Aggregated feature importance by category	98
B.1	Condition 1 results by task (Dataset A, baseline features, unweighted)	100
B.2	Condition 1 results (Dataset B, baseline features, unweighted)	101
B.3	Condition 2 results by task (Dataset A, extended features, unweighted)	101
B.4	Condition 2 improvement over Condition 1 (Random Forest)	101
B.5	Condition 3 results by task (Dataset A, baseline features, weighted)	102
B.6	Condition 3 effect of weighting vs Condition 1 (RF)	102
B.7	Condition 4 results by task (Dataset A, extended features, weighted)	102
B.8	Condition 4 effect of weighting vs Condition 2 (RF)	103
B.9	Random Forest ROC-AUC comparison matrix (Dataset A)	103
B.10	Random Forest Accuracy comparison matrix (Dataset A)	103

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορικό και κίνητρα

Η νόσος του Πάρκινσον είναι η δεύτερη πιο συχνή νευρολογική ασθένεια που σχετίζεται με εκφύλιση των νευρών. Επηρεάζει περίπου 1 στους 100 ανθρώπους άνω των 60 ετών [1]. Σήμερα, μία από τις μεγαλύτερες προκλήσεις που αντιμετωπίζονται στο κλινικό περιβάλλον είναι η έγκαιρη και σωστή διάγνωση, επειδή τα εμφανή συμπτώματα συνήθως παρουσιάζονται όταν έχει ήδη χαθεί σημαντικός αριθμός νευρώνων. Οι ασθενείς με Πάρκινσον συχνά εμφανίζουν αλλαγές στην ομιλία, λόγω επιδράσεων στον λάρυγγα και στους αναπνευστικούς μύες. Οι αλλαγές αυτές μπορεί να εμφανιστούν αρκετά χρόνια πριν από τα τυπικά κινητικά συμπτώματα (έως και 7 χρόνια νωρίτερα). [2].

Οι δείκτες που βασίζονται στη φωνή αποτελούν έναν απλό, οικονομικό και μη επεμβατικό τρόπο για την ανίχνευση της νόσου [3, 4]. Καθώς η νόσος του Πάρκινσον βλάπτει τον λάρυγγα και τους αναπνευστικούς μύες, αυτό προκαλεί ανιχνεύσιμες αλλαγές στις προσωδικές πτυχές της ομιλίας ενός ατόμου (δηλ. τον τόνο, την ένταση, τον ρυθμό της ομιλίας) καθώς και σε χαρακτηριστικά του ακουστικού σήματος, όπως η δομή και οι συχνότητες της φωνής.

Η ομιλία των ατόμων με PD ονομάζεται *υποκινητική δυσαρθρία* (HKD) και χαρακτηρίζεται από:

- (α) *υποφωνία*, (μειωμένη ένταση φωνής),
- (β) *μονοτονικότητα*, (περιορισμένο εύρος τόνων) και
- (γ) *μονοφωνία*, (μια ομοιόμορφη ένταση της φωνής κατά την ομιλία) [5].

Μπορεί επίσης να υπάρχει ασαφής άρθρωση, δηλαδή οι λέξεις να μην ακούγονται καθαρά, καθώς και αλλαγές στην ποιότητα της φωνής, όπως βραχνάδα.

Η φωνή μπορεί να καταγραφεί με απλά μικρόφωνα, ακόμη και με smartphone, γεγονός που ενισχύει τη χρήση της ανάλυσης φωνής για την αναγνώριση και την παρακολούθηση της νόσου. Ορισμένες φωνητικές ανωμαλίες μπορεί να είναι ανιχνεύσιμες πριν εμφανιστούν τα κλασικά συμπτώματα, επομένως η φωνή μπορεί να λειτουργήσει ως πρώιμος δείκτης.

Τα τελευταία χρόνια, η έρευνα έχει περάσει από ηχογραφήσεις σε ειδικά εργαστήρια με πολύπλοκο εξοπλισμό σε ηχογραφήσεις με απλά μέσα, όπως το μικρόφωνο ενός smartphone. Αυτή η αλλαγή δημιουργεί νέες δυσκολίες, κυρίως στο κατά πόσο τα αποτελέσματα μπορούν να ισχύουν σε διαφορετικές συνθήκες και συσκευές που απουσίαζαν από παλιές μελέτες [6].

Οι δείκτες φωνής χρησιμοποιούνται για δύο βασικούς σκοπούς:

- (α) για τον έλεγχο και την ανίχνευση της νόσου, που αποτελεί τον κύριο ερευνητικό στόχο περίπου του 94% των μελετών που έχουν διεξαχθεί μέχρι σήμερα, και
- (β) για την παρακολούθηση της πορείας της και της ανταπόκρισης στη θεραπεία [7].

Όμως, τα διαχρονικά στοιχεία για τον στόχο (β) παραμένουν σπάνια και τα περισσότερα ακουστικά χαρακτηριστικά έχουν επικυρωθεί μερικώς και κυρίως διατομεακά [8].

1.2 Διατύπωση του προβλήματος

Παρόλο που έχουν γίνει σημαντικές προσπάθειες για την ανάπτυξη μεθόδων που χρησιμοποιούν τη φωνή για την ανίχνευση της νόσου του Πάρκινσον, εξακολουθούν να υπάρχουν αρκετές προκλήσεις:

1. **Μικρά μεγέθη δειγμάτων** Όταν τα διαθέσιμα ηχητικά δεδομένα είναι λίγα, είναι δύσκολο να δημιουργηθούν μοντέλα που να λειτουργούν σωστά και σε νέους πληθυσμούς.
2. **Διαρροή ταυτότητας υποκειμένου (subject leakage)** Συμβαίνει όταν ηχογραφήσεις του ίδιου ατόμου χρησιμοποιούνται και για εκπαίδευση και για έλεγχο του μοντέλου. Αυτό μπορεί να οδηγήσει σε υπερβολικά καλά αλλά μη ρεαλιστικά αποτελέσματα.
3. **Ανισορροπία κλάσεων** Συνήθως δεν υπάρχει ίδιος αριθμός δειγμάτων από

άτομα με Πάρκινσον (PD) και από υγιή άτομα (HC), κάτι που μπορεί να επηρεάσει την απόδοση του μοντέλου.

4. **Επιλογή χαρακτηριστικών** Ο τρόπος με τον οποίο αναπαρίσταται η φωνή (ποια χαρακτηριστικά επιλέγονται) μπορεί να επηρεάσει σημαντικά το πόσο καλά λειτουργεί το μοντέλο ταξινόμησης.
5. **Διαφορετικές μέθοδοι επικύρωσης** Οι μελέτες χρησιμοποιούν διαφορετικούς τρόπους για να αξιολογήσουν τα μοντέλα (π.χ. k-fold, σταθερός διαχωρισμός εκπαίδευσης/δοκιμής, leave-one-subject-out, εξωτερική επικύρωση). Αυτές οι μέθοδοι δίνουν διαφορετικές εκτιμήσεις απόδοσης, κάτι που δυσκολεύει τη σύγκριση των αποτελεσμάτων μεταξύ μελετών. Παρ' όλα αυτά, λίγες μελέτες χρησιμοποιούν εξωτερική επικύρωση [6].
6. **Χάσμα γενίκευσης μεταξύ συνόλων δεδομένων:** Ένα μοντέλο μπορεί να έχει πολύ υψηλή ακρίβεια στο αρχικό σύνολο δεδομένων, αλλά η απόδοσή του συχνά μειώνεται όταν δοκιμαστεί σε νέα, διαφορετικά δεδομένα. Αυτό μπορεί να οδηγήσει σε υπερβολικούς ισχυρισμούς για την πραγματική του απόδοση [6].

Όλες αυτές οι προκλήσεις εξετάζονται σε αυτή τη εργασία εργασία με έναν προσεκτικό πειραματικό σχεδιασμό, που δίνει έμφαση στη σωστή μεθοδολογία και όχι απλώς στην επίτευξη υψηλών ποσοστών απόδοσης.

1.3 Ερευνητικοί στόχοι

Οι κύριοι στόχοι αυτής της εργασίας είναι:

1. Να **παρέχει μια αναπαραγώγιμη διαδικασία** για την εξαγωγή ακουστικών χαρακτηριστικών από ηχογραφήσεις φωνής.
2. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost) για την ταξινόμηση PD έναντι HC.
3. Να **αξιολογήσει την απόδοση** των κλασικών μοντέλων μηχανικής μάθησης σε δύο ξεχωριστά σύνολα δεδομένων, τα οποία έχουν διαφορετικά χαρακτηριστικά.
4. Να **αξιολογήσει την επίδραση** της αύξησης των χαρακτηριστικών (από 47 σε 78) με ελεγχόμενο τρόπο.
5. Να **αξιολογήσει την επίδραση** της χρήσης βαρών κλάσης (class-weighting) ώστε να αντιμετωπιστεί η ανισορροπία μεταξύ των ομάδων.

1.4 Συνεισφορές

Η παρούσα διπλωματική συμβάλλει στη μελέτη των φωνητικών βιοδεικτών της νόσου του Πάρκινσον με τους εξής τρόπους:

- **Αξιολόγηση χωρίς διαρροή ταυτότητας:** Χρησιμοποιήθηκε cross-validation ανά υποκείμενο, έτσι ώστε όλες οι ηχογραφήσεις του ίδιου ατόμου να βρίσκονται είτε στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής. Με αυτόν τον τρόπο αποφεύγεται η «διαρροή δεδομένων», δηλαδή το να μαθαίνει το μοντέλο από το ίδιο άτομο που αργότερα καλείται να προβλέψει.
- **Έλεγχος της αύξησης των χαρακτηριστικών:** Μελετήθηκε τι συμβαίνει όταν τα χαρακτηριστικά αυξάνονται από 47 σε 78. Η αύξηση αυτή βελτίωσε την απόδοση έως και 23% (ROC-AUC). Παράλληλα, εξετάστηκε ποια από τα νέα χαρακτηριστικά συνέβαλαν περισσότερο στη βελτίωση.
- **Σύγκριση αυθόρμητης και δομημένης ομιλίας:** Βρέθηκε ότι τα μοντέλα αποδίδουν καλύτερα όταν χρησιμοποιείται αυθόρμητη ομιλία σε σχέση με δομημένη ανάγνωση. Για παράδειγμα, το Random Forest είχε καλύτερη απόδοση στην αυθόρμητη ομιλία, γεγονός που δείχνει ότι τέτοιου τύπου δεδομένα ίσως αποτυπώνουν καλύτερα τις αλλαγές που σχετίζονται με τη νόσο.
- **Σύγκριση δύο διαφορετικών datasets:** Τα αποτελέσματα από ένα αυστηρά ελεγχόμενο dataset συγκρίθηκαν με ένα δημόσιο dataset με προ-εξαγμένα χαρακτηριστικά. Στο δημόσιο dataset, η απλή διασταυρούμενη επικύρωση έδωσε πολύ υψηλές τιμές απόδοσης (π.χ. AUC $\sim 0,94$), που πιθανόν δεν είναι ρεαλιστικές. Αυτό δείχνει πόσο σημαντική είναι η σωστή μεθοδολογία αξιολόγησης.
- **Ερμηνεία των χαρακτηριστικών:** Πέρα από τη μέτρηση της απόδοσης, έγινε και ανάλυση της σημασίας των χαρακτηριστικών, ώστε να είναι πιο κατανοητό ποια στοιχεία της φωνής συμβάλλουν περισσότερο στην ανίχνευση της νόσου. Αυτό ενισχύει τη διαφάνεια και τη χρησιμότητα των αποτελεσμάτων.

1.5 Οργάνωση της εργασίας

Τα υπόλοιπα κεφάλαια αυτής της εργασίας ακολουθούν το οργανωτικό σχήμα που παρέχεται παρακάτω:

Table 1.1: Περίληψη των κεφαλαίων της εργασίας

Κεφάλαιο	Τίτλος	Περιγραφή
2	Βιβλιογραφική ανασκόπηση	Επισκόπηση των μεθοδολογιών ανίχνευσης PD με βάση τη φωνή
3	Περιγραφή δεδομένων	Λεπτομερείς περιγραφές των συνόλων δεδομένων που χρησιμοποιήθηκαν σε αυτή τη εργασία
4	Μεθοδολογία	Διαδικασία εξαγωγής ακουστικών χαρακτηριστικών και κατασκευής μοντέλου μηχανικής μάθησης
5	Πειραματικός σχεδιασμός	Πρωτόκολλο για την αξιολόγηση των επιδράσεων κάθε μεταβλητής
6	Αποτελέσματα	Ποσοτικά αποτελέσματα για κάθε μία από τις συνθήκες
7	Συζήτηση	Επεξήγηση των αποτελεσμάτων και σύγκριση με προηγούμενες εργασίες
8	Περιορισμοί	Περιορισμοί και περιορισμοί της μελέτης
9	Συμπέρασμα	Περίληψη των κύριων ευρημάτων και πιθανών μελλοντικών τομέων έρευνας

1.6 Όρια πεδίου εφαρμογής

Η μελέτη έχει τα ακόλουθα όρια πεδίου εφαρμογής:

- **Μόνο δυαδική ταξινόμηση:** Η εργασία εξετάζει μόνο αν ένα άτομο έχει Πάρκινσον ή όχι (PD vs HC). Δεν μελετά πόσο σοβαρή είναι η νόσος, πώς εξελίσσεται με τον χρόνο ή πώς ξεχωρίζει από άλλες ασθένειες.
- **Μόνο κλασικά μοντέλα μηχανικής μάθησης:** Χρησιμοποιούνται μόνο κλασικά και πιο εύκολα ερμηνεύσιμα μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest, Gradient Boosting, XGBoost). Δεν χρησιμοποιούνται νευρωνικά δίκτυα ή βαθιά μάθηση, κυρίως λόγω του μικρού μεγέθους των δεδομένων και της έμφασης στην κατανόηση των αποτελεσμάτων. Η εργασία προσφέρει έτσι μια καθαρή και αξιόπιστη βάση για μελλοντικές πιο σύνθετες μεθόδους.
- **Ερευνητικός χαρακτήρας:** Τα μοντέλα που παρουσιάζονται έχουν ερευνητικό σκοπό. Δεν προορίζονται να χρησιμοποιηθούν άμεσα από γιατρούς για διάγνωση χωρίς επιπλέον έλεγχο και επιβεβαίωση.
- **Έμφαση στην αναπαραγωγιμότητα:** Δόθηκε προτεραιότητα στο να μπορούν τα πειράματα να επαναληφθούν από άλλους ερευνητές. Για αυτό χρησιμοποιήθηκαν σταθερές ρυθμίσεις, σαφής περιγραφή των βημάτων και

σωστή τεκμηρίωση του κώδικα. Η αξιοπιστία των αποτελεσμάτων θεωρήθηκε πιο σημαντική από το να επιτευχθούν απλώς υψηλότερα ποσοστά απόδοσης.

Κεφάλαιο 2

Βιβλιογραφική ανασκόπηση

2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας

Η νόσος του Πάρκινσον είναι γνωστή κυρίως για τα κινητικά της συμπτώματα (τρέμουλο, ακαμψία, βραδυκίνησία), αλλά παράλληλα με αυτά, η νόσος επηρεάζει σχεδόν πάντα και την ομιλία και τη φωνή. Περίπου το 70–90% των ατόμων με νόσο του Πάρκινσον αναπτύσσουν μετρήσιμες διαταραχές της ομιλίας και της φωνής κατά τη διάρκεια της νόσου [1]. Αυτή η συλλογή συμπτωμάτων της ομιλίας στη νόσο του Πάρκινσον περιγράφεται συχνά ως *υποκινητική δυσαρθρία*, υποδηλώνοντας ένα χαρακτηριστικό μοτίβο διαταραχής του κινητικού ελέγχου της ομιλίας που σχετίζεται με τη νόσο [5].

Η ομιλία στην PD χαρακτηρίζεται από *υποφωνία* (μειωμένη ένταση), *μονοτονία* και *μονοφωνία* (μειωμένη προσωδιακή μεταβλητότητα), ασαφή άρθρωση και φωνή με αναπνοή ή βραχνάδα που προκύπτει από ατελές κλείσιμο των φωνητικών χορδών [5, 9].

Αυτές οι αλλαγές στην ομιλία στην PD παρουσιάζουν ενδιαφέρον όχι μόνο ως συμπτώματα που επηρεάζουν την ικανότητα επικοινωνίας ενός ατόμου, αλλά και ως πιθανοί μη επεμβατικοί βιοδείκτες της νόσου. Η φωνή είναι σχετικά εύκολο να καταγραφεί (για παράδειγμα, μέσω μιας σύντομης ηχογράφησης σε ένα smartphone) και οι φωνητικές αλλαγές μπορεί να εμφανιστούν νωρίς στην πορεία της νόσου. Ορισμένες έρευνες υποδηλώνουν ότι οι λεπτές ανωμαλίες της φωνής μπορούν να ανιχνευθούν πριν από την εμφάνιση των κλασικών κινητικών συμπτωμάτων σε ορισμένους ασθενείς [2]. Δεδομένου ότι η ηχογράφηση και η ανάλυση της φωνής μπορούν να πραγματοποιηθούν με χαμηλό κόστος και εξ αποστάσεως, υπάρχει σημαντική κινητοποίηση για τη χρήση της ομιλίας ως μέσου ανίχνευσης ή

παρακολούθησης της νόσου του Πάρκινσον χωρίς την ανάγκη επεμβατικών εξετάσεων. Οι μετρήσεις της ομιλίας και της φωνής είναι κατάλληλες για εφαρμογές τηλεϊατρικής και για τη διαχρονική παρακολούθηση της εξέλιξης της νόσου του Πάρκινσον [4]. Σε αντίθεση με πολλές κλινικές αξιολογήσεις που απαιτούν προσωπικές επισκέψεις και εξειδικευμένο εξοπλισμό, οι ηχογραφήσεις φωνής μπορούν να ληφθούν από τους ασθενείς στο σπίτι τους και να αναλυθούν με αλγόριθμους, επιτρέποντας πιο συχνή και χαμηλότερου κόστους παρακολούθηση.

2.2 Ανίχνευση έναντι παρακολούθησης

Η έρευνα για την PD με βάση τη φωνή αντιμετωπίζει δύο σχετικούς αλλά διακριτούς στόχους: **ανίχνευση/διαλογή** (δυαδική ταξινόμηση της PD έναντι της HC) και **παρακολούθηση/εξέλιξη** (παρακολούθηση της σοβαρότητας της νόσου ή της ανταπόκρισης στη θεραπεία με την πάροδο του χρόνου). Μια συστηματική ανασκόπηση 106 μελετών που δημοσιεύθηκαν μεταξύ 2019 και 2023 διαπίστωσε ότι περίπου το 94% επικεντρώθηκε στη διάγνωση ή την ανίχνευση, ενώ λιγότερο από το 12% ασχολήθηκε με την πρόγνωση ή την εξέλιξη [7].

Οι δύο στόχοι ευνοούν διαφορετικές λειτουργίες ομιλίας και ακουστικά χαρακτηριστικά. Η παρατεταμένη φώνηση φωνηέντων είναι πιο αποτελεσματική για τη δυαδική διάκριση PD/HC, καθώς απομονώνει τη λειτουργία του λάρυγγα και παρέχει σταθερές μετρήσεις διαταραχής και θορύβου [8]. Οι συνδεδεμένες λειτουργίες ομιλίας, όπως η ανάγνωση αποσπασμάτων και ο αυθόρμητος διάλογος, είναι πιο ενημερωτικές για την εκτίμηση της σοβαρότητας, καθώς καταγράφουν την ακρίβεια της άρθρωσης, τον ρυθμό ομιλίας και την προσωδιακή διακύμανση, χαρακτηριστικά που συσχετίζονται με κλινικές κλίμακες σοβαρότητας όπως η UPDRS [8]. Τα χαρακτηριστικά άρθρωσης (MFCC, συντελεστές PLP, περιοχή φωνηέντων) έχουν αναφερθεί ότι αποδίδουν μέση ακρίβεια 80–95% για την πρόβλεψη της σοβαρότητας, σε σύγκριση με 75–90% για τα φωνητικά χαρακτηριστικά μόνο [8].

Ένας κρίσιμος περιορισμός της βιβλιογραφίας σχετικά με την παρακολούθηση είναι η έλλειψη διαχρονικών δεδομένων: οι περισσότερες μελέτες συγκρίνουν ομάδες PD και HC διατομεακά, αντί να παρακολουθούν τις ακουστικές αλλαγές σε μεμονωμένα άτομα με την πάροδο του χρόνου [8]. Η παρούσα εργασία επικεντρώνεται στην αξιόπιστη ανίχνευση χρησιμοποιώντας δύο τύπους εργασιών ομιλίας (ReadText και SpontaneousDialogue), αλλά το σύνολο χαρακτηριστικών έχει σχεδιαστεί κατά τρόπο που παραμένει συμβατό με μελλοντικές εργασίες παρακολούθησης.

2.3 Ταξινόμηση ακουστικών χαρακτηριστικών

Table 2.1: Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD

Κατηγορία	Παραδείγματα	Φυσιολογική βάση
Θεμελιώδης συχνότητα	F_0 μέσος όρος, F_0 τυπική απόκλιση	Τάση φωνητικών χορδών και κινητική ακαμψία
Διαταραχή	Jitter, Shimmer	Νευρομυϊκή αστάθεια
Θόρυβος	HNR, NHR	Ατελές κλείσιμο της γλωττίδας
Φορμάντες	F_1 , F_2 , F_3	Διαμόρφωση φωνητικού σωλήνα
Φασματικά/Κεποτρικά	MFCCs, delta-MFCCs	Φασματική περιβάλλουσα και δυναμική

Προσωδιακά χαρακτηριστικά σχετίζονται με το ύψος (F_0) και τα μοτίβα έντασης. Η PD μειώνει το εύρος F_0 (μονοτονικότητα) και το εύρος έντασης (μονοεντατικότητα), τα οποία σχετίζονται με την ταξινόμηση PD [10]. Οι στατιστικές πληθυσμού που καταγράφονται περιλαμβάνουν μέση τιμή F_0 , τυπική απόκλιση, ελάχιστη και μέγιστη τιμή, μέση ένταση και μεταβλητότητα, καθώς και συχνότητες φορμάντων που αντανακλούν τη διαμόρφωση του φωνητικού σωλήνα.

Τα **μέτρα διαταραχής** ποσοτικοποιούν την αστάθεια από κύκλο σε κύκλο στη δόνηση των φωνητικών χορδών. Το jitter (διαταραχή περιόδου) και το shimmer (διαταραχή πλάτους) είναι αυξημένα στην PD, αντανακλώντας τη νευρομυϊκή ασυντονιστικότητα που εμποδίζει την πηγή ομιλίας να διατηρήσει έναν τακτικό κύκλο δόνησης. Ο λόγος αρμονικών προς θόρυβο (HNR) μετρά την αναλογία της περιοδικής προς την μη περιοδική ενέργεια. Οι χαμηλότερες τιμές HNR υποδηλώνουν μια πιο αναπνευστική, θορυβώδη ποιότητα φωνής που είναι χαρακτηριστική της PD [3].

Τα **φασματικά και κεποτρικά χαρακτηριστικά** σχετίζονται με το φασματικό περίβλημα του φωνητικού σήματος. Οι Mel-Frequency Cepstral Coefficients (MFCCs) καταγράφουν πληροφορίες σχετικά με το φασματικό σχήμα χρησιμοποιώντας μια κλίμακα συχνοτήτων που βασίζεται στην αντίληψη, ενώ οι χρονικές παράγωγοί τους (delta και delta-delta) καταγράφουν τις δυναμικές αλλαγές στα φασματικά δεδομένα με την πάροδο του χρόνου [11]. Οι περιγραφές φασματικού σχήματος, όπως το κέντρο βάρους, το εύρος ζώνης, η απόκλιση και η επιπεδότητα, παρέχουν συμπληρωματικά μέτρα της συνολικής κατανομής ενέργειας. Μαζί, αυτές οι τρεις κατηγορίες χαρακτηριστικών είναι συμπληρωματικές και παρέχουν μια ολιστική περιγραφή της ακουστικής αλλαγής που σχετίζεται με την PD.

2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας

Πρόσφατες συστηματικές ανασκοπήσεις οργανώνουν τα ακουστικά χαρακτηριστικά σε τρεις λειτουργικά καθορισμένες κατηγορίες που αντιστοιχούν σε διακριτές πτυχές του μηχανισμού παραγωγής ομιλίας [8]:

- **Φωνητικά χαρακτηριστικά** (jitter, shimmer, HNR, λόγος διέγερσης γλωττίδας προς θόρυβο, εντροπία περιόδου τόνου) ποσοτικοποιούν τη σταθερότητα και την πληρότητα της δόνησης των φωνητικών χορδών. Αυτά τα χαρακτηριστικά είναι αυξημένα ή μειωμένα στην PD ως αποτέλεσμα της νευρομυϊκής αστάθειας και του ατελούς κλεισίματος της γλωττίδας.
- **Χαρακτηριστικά άρθρωσης** (MFCCs, cepstral peak prominence, formant frequencies, vowel space area, vowel articulation index, perceptual linear prediction coefficients) καταγράφουν τη δυναμική και την ακρίβεια της κίνησης του φωνητικού σωλήνα. Η περιοχή του φωνητικού χώρου είναι σταθερά μειωμένη στην PD, αντανακλώντας την περιορισμένη άρθρωση.
- **Προσωδικά χαρακτηριστικά** (μεταβλητότητα F_0 στη συνδεδεμένη ομιλία, ρυθμός ομιλίας, αριθμός και διάρκεια παύσεων, μέγιστος χρόνος φώνησης) καταγράφουν τα υπερκειμενικά μοτίβα του τόνου, του συγχρονισμού και του ρυθμού. Αυτά τα χαρακτηριστικά αντανακλούν τη μειωμένη προσωδική διακύμανση σε επίπεδο πρότασης στην PD, παράλληλα με την αυξημένη αστάθεια του τόνου σε επίπεδο μικρού τμήματος.

Από τα 18 χαρακτηριστικά που εξετάστηκαν από τον Wright and Aharonson [8], 12 έδειξαν μετρήσιμες και συνεπείς διαφορές μεταξύ ασθενών με PD και υγιών ατόμων ελέγχου, με το jitter, το shimmer και το HNR να είναι τα πιο συνεπή διακριτικά χαρακτηριστικά σε όλες τις μελέτες. Αυτό το πλαίσιο τριών κατηγοριών είναι συμπληρωματικό της παραδοσιακής ομαδοποίησης επεξεργασίας σήματος που παρουσιάζεται στον Πίνακα 2.1 και παρέχει μια κλινικά τεκμηριωμένη προοπτική για την ερμηνεία των αποτελεσμάτων σχετικά με τη σημασία των χαρακτηριστικών.

2.4 Σύνολα δεδομένων που χρησιμοποιούνται στην έρευνα για τη φωνή των ασθενών με Πάρκινσον

Η απόδοση και τα συμπεράσματα οποιασδήποτε μελέτης μηχανικής μάθησης είναι εγγενώς συνδεδεμένα με τα σύνολα δεδομένων που χρησιμοποιούνται. Στην έρευνα για τη φωνή των ασθενών με PD, έχουν χρησιμοποιηθεί διάφορα σύνολα δεδομένων,

το καθένα με διαφορετικά χαρακτηριστικά. Σε γενικές γραμμές, αυτά μπορούν να χωριστούν σε **ακατέργαστα σύνολα δεδομένων ήχου** (ηχογραφημένα φωνητικά σήματα που απαιτούν εξαγωγή χαρακτηριστικών) και **προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών** (όπου τα δεδομένα παρέχονται ήδη με τη μορφή τιμών χαρακτηριστικών ανά δείγμα). Παρακάτω εξετάζονται αντιπροσωπευτικά παραδείγματα κάθε κατηγορίας και η συνάφειά τους με την παρούσα εργασία.

2.4.1 Ακατέργαστα σύνολα δεδομένων ήχου

Τα ακατέργαστα σύνολα δεδομένων ήχου για την PD συνήθως αποτελούνται από ηχογραφήσεις φωνής ασθενών με PD και υγιών ατόμων που έχουν συλλεχθεί σε ελεγχόμενο περιβάλλον. Ένα γνωστό πρώιμο παράδειγμα είναι το σύνολο δεδομένων του Little et al. [12] που διατίθεται μέσω του UCI Machine Learning Repository. Περιέχει 195 παρατεταμένες φωνητικές φωνές (ήχοι «α») από 31 άτομα (23 με PD), το καθένα από τα οποία χαρακτηρίζεται από 22 χαρακτηριστικά δυσφωνίας (jitter, shimmer, κ.λπ.) συν την ετικέτα κλάσης. Οι Little et al. ανέφεραν ότι πέτυχαν ακρίβεια ~91% στην ανίχνευση της PD χρησιμοποιώντας ένα SVM, καθιστώντας το ως σημείο αναφοράς για τις πρώιμες μελέτες. Ένας βασικός περιορισμός, ωστόσο, είναι ότι περιλαμβάνονται πολλαπλές ηχογραφήσεις από το ίδιο άτομο, γεγονός που απαιτεί προσεκτική ομαδοποίηση για την αποφυγή μεροληψίας — μια προφύλαξη που δεν τηρήθηκε σε όλες τις πρώιμες μελέτες, συμβάλλοντας σε ορισμένα υπερβολικά αισιόδοξα αποτελέσματα.

Ένα πιο πρόσφατο παράδειγμα είναι το σώμα MDVR-KCL (Mobile Device Voice Recordings at King's College London) [13]. Αυτή η συλλογή του 2019 περιέχει ηχογραφήσεις φωνής από ασθενείς με PD και υγιείς μάρτυρες που εκτελούν πολλαπλές ομιλητικές εργασίες, συμπεριλαμβανομένης της ανάγνωσης και του αυθόρμητου διαλόγου. Περιλαμβάνει δεκάδες υποκείμενα (για παράδειγμα, 37 υποκείμενα στο τμήμα που χρησιμοποιείται σε αυτή τη εργασία) και πολλαπλές ηχογραφήσεις ανά υποκείμενο ανά εργασία, καθιστώντας το κατάλληλο για την εξέταση της μεταβλητότητας εντός του υποκειμένου και των επιδράσεων της εργασίας. Τα δεδομένα είναι διαθέσιμα στο Zenodo και αντικατοπτρίζουν ένα πιο ρεαλιστικό σενάριο εγγραφής, με ποικίλο περιεχόμενο ομιλίας που καταγράφεται μέσω smartphone. Μελέτες που χρησιμοποιούν αυτό το σώμα δεδομένων — ή παρόμοια σύνολα δεδομένων πολλαπλών εργασιών — υποστηρίζουν ένθερμα την ομαδοποιημένη διασταυρούμενη επικύρωση, διασφαλίζοντας ότι όλες οι εγγραφές από ένα δεδομένο υποκείμενο τοποθετούνται σε ένα μόνο τμήμα, προκειμένου να αξιολογηθεί σωστά η γενίκευση σε νέους ομιλητές.

2.4.2 Προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών

Τα προ-εξαγόμενα σύνολα δεδομένων χαρακτηριστικών είναι εκείνα στα οποία το στάδιο επεξεργασίας του σήματος έχει ήδη ολοκληρωθεί αποτελεσματικά — αυτό που παρέχεται είναι ένας πίνακας τιμών χαρακτηριστικών ανά δείγμα, μαζί με ετικέτες κλάσης, έτοιμος για άμεση εφαρμογή μεθόδων μηχανικής μάθησης. Το σύνολο δεδομένων χαρακτηριστικών ομιλίας της νόσου του Πάρκινσον (PDSF) είναι ένα εξέχον παράδειγμα, διαθέσιμο μέσω του αποθετηρίου UCI ή του Kaggle [14].

Περιλαμβάνει 756 δείγματα με 754 χαρακτηριστικά ανά δείγμα συν μια δυαδική ετικέτα (PD ή HC), όπου κάθε δείγμα αντιστοιχεί σε μια ηχογράφιση φωνής από ένα άτομο. Υπάρχουν 252 μοναδικά υποκείμενα (188 PD, 64 HC), το καθένα από τα οποία συνεισφέρει ακριβώς τρία δείγματα (π.χ. τρεις ηχογραφήσεις παρατεταμένων φωνηέντων). Τα χαρακτηριστικά καλύπτουν ένα ευρύ φάσμα ακουστικών μετρήσεων, συμπεριλαμβανομένων παραδοσιακών μετρήσεων όπως jitter, shimmer και MFCCs, καθώς και συντελεστές Tunable Q-factor Wavelet Transform (TQWT) που καταγράφουν πρόσθετα χαρακτηριστικά του σήματος. Αυτό το σύνολο δεδομένων σχεδιάστηκε ως ένα ολοκληρωμένο σύνολο χαρακτηριστικών για τη συγκριτική αξιολόγηση της απόδοσης του ταξινομητή.

Το κύριο πλεονέκτημα των προ-εξαγόμενων συνόλων δεδομένων χαρακτηριστικών είναι η ευκολία και η συνέπεια — οι ερευνητές μπορούν να κατεβάσουν το CSV και να εφαρμόσουν απευθείας μεθόδους μηχανικής μάθησης, χωρίς να χρειάζεται να εφαρμόσουν διαδικασίες επεξεργασίας σήματος. Πολλές μελέτες έχουν χρησιμοποιήσει το σύνολο δεδομένων PDSF για να αξιολογήσουν διαφορετικούς αλγόριθμους ταξινόμησης, τεχνικές επιλογής χαρακτηριστικών και μεθόδους συνόλου, με αναφερόμενη ακρίβεια συχνά στην περιοχή 85–95% σε διάφορους ταξινομητές.

Μια κρίσιμη προειδοποίηση με σύνολα δεδομένων αυτού του τύπου είναι η **έλλειψη αναγνωριστικών υποκειμένων**. Δεδομένου ότι τα 756 δείγματα περιλαμβάνουν τρεις εγγραφές από καθένα από τα 252 υποκείμενα, μια αφελής διασταυρούμενη επικύρωση που χωρίζει τυχαία τα δείγματα θα εκπαιδεύσει και θα δοκιμάσει κατά λάθος εγγραφές από το ίδιο άτομο. Αυτό οδηγεί σε υπερβολικά αισιόδοξες εκτιμήσεις απόδοσης, καθώς οι τρεις εγγραφές ενός δεδομένου υποκειμένου δεν είναι ανεξάρτητες και μοιράζονται παρόμοια ακουστικά χαρακτηριστικά. Ορισμένες δημοσιευμένες μελέτες έχουν παραβλέψει αυτό το ζήτημα και, κατά συνέπεια, έχουν αναφέρει υπερβολική απόδοση του ταξινομητή. Η κατάλληλη προσέγγιση θα ήταν η ομαδοποίηση των δειγμάτων ανά υποκείμενο κατά την κατάτμηση των δεδομένων. Ωστόσο, δεδομένου ότι δεν παρέχονται αναγνωριστικά υποκειμένων, αυτό δεν μπορεί να γίνει άμεσα. Τα αποτελέσματα σε αυτό το σύνολο δεδομένων πρέπει επομένως να

ερμηνεύονται με προσοχή, καθώς η υψηλή ακρίβεια μπορεί να αντανακλά εν μέρει τη συνέπεια εντός του υποκειμένου και όχι την πραγματική γενίκευση σε νέους ομιλητές. Σε αυτή τη εργασία, τα αποτελέσματα του συνόλου δεδομένων B αντιμετωπίζονται ως δυνητικά αισιόδοξα, με έμφαση στις τάσεις και όχι στις απόλυτες τιμές απόδοσης.

2.4.3 Κλίμακα και αντιπροσωπευτικότητα του συνόλου δεδομένων

Μια συστηματική ανασκόπηση 69 μελετών που δημοσιεύθηκαν μεταξύ 2020 και 2025 διαπίστωσε ότι τα περισσότερα σύνολα δεδομένων φωνής που χρησιμοποιούνται για την ταξινόμηση της PD περιέχουν λιγότερους από 100 συμμετέχοντες [6]. Τα πιο συχνά χρησιμοποιούμενα σώματα κειμένων είναι το PC-GITA (19 μελέτες), το σύνολο δεδομένων Istanbul PD Speech (15 μελέτες) και το σύνολο δεδομένων Oxford/UCI PD (14 μελέτες). Η ανισορροπία των κλάσεων είναι συχνή: η πλειονότητα των συνόλων δεδομένων παρουσιάζει αναλογίες PD-HC εκτός του εύρους 0,8–1,2, με το σύνολο δεδομένων Istanbul να περιέχει 188 συμμετέχοντες με PD έναντι μόλις 64 συμμετεχόντων με HC. Το σώμα κειμένων MDVR-KCL που χρησιμοποιείται σε αυτή τη εργασία είναι ένα από τα πιο συχνά εμφανιζόμενα σύνολα δεδομένων στην αγγλική γλώσσα στην πρόσφατη βιβλιογραφία [6].

2.4.4 Ετερογένεια επικύρωσης

Το ίδιο σύνολο δεδομένων μπορεί να παράγει θεμελιωδώς διαφορετικά αποτελέσματα απόδοσης ανάλογα με τη στρατηγική αξιολόγησης που χρησιμοποιείται. Μεταξύ των πρόσφατων μελετών, η k-fold cross-validation χρησιμοποιείται σε περίπου 40%, η fixed train/test splits σε περίπου 36%, η subject-independent evaluation (leave-one-subject-out ή leave-one-out) σε μόνο 12%, και η external cross-dataset validation σε λιγότερο από 15% [6]. Αυτή η ετερογένεια καθιστά δύσκολη και συχνά παραπλανητική την άμεση σύγκριση των αναφερόμενων αποτελεσμάτων μεταξύ των μελετών. Για παράδειγμα, μια μελέτη που ανέφερε ακρίβεια 100% χρησιμοποιώντας σταθερή διαίρεση στο μικρό σύνολο δεδομένων της Οξφόρδης βρέθηκε να υποβαθμίζεται στο 96% όταν δοκιμάστηκε σε διαφορετικό σώμα κειμένων, καταδεικνύοντας την ευθραυστότητα της αξιολόγησης εντός του δείγματος σε μικρά σημεία αναφοράς [6].

2.4.5 Ο ρόλος των εργασιών ομιλίας

Η επιλογή της εργασίας ομιλίας είναι μια σημαντική απόφαση σχεδιασμού που επηρεάζει τόσο τον τύπο των πληροφοριών που συλλέγονται όσο και την καταλληλότητα της ανάλυσης για την ανίχνευση έναντι της παρακολούθησης. Η

παρατεταμένη φώνηση φωνηέντων αντανακλά κυρίως τη λειτουργία του λάρυγγα και χρησιμοποιείται συνήθως για τη δυαδική διάκριση PD/HC. Αντίθετα, οι εργασίες ανάγνωσης και αυθόρμητης ομιλίας εμπλέκουν ολόκληρο το σύστημα παραγωγής ομιλίας και παρέχουν περισσότερες πληροφορίες για την αξιολόγηση της ακρίβειας της άρθρωσης, της προσωδικής διακύμανσης και του ρυθμού ομιλίας — χαρακτηριστικά που συνδέονται με τη σοβαρότητα της νόσου και όχι με την απλή παρουσία της [8]. Η παρούσα εργασία αξιολογεί τόσο μια εργασία ανάγνωσης (ReadText) όσο και μια εργασία αυθόρμητης ομιλίας (SpontaneousDialogue) από το Dataset A, επιτρέποντας μια ελεγχόμενη σύγκριση των αποτελεσμάτων των εργασιών υπό πανομοιότυπες διαμορφώσεις ταξινόμησης.

2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης για την ταξινόμηση φωνής PD

Η λογιστική παλινδρόμηση (LR), οι μηχανές υποστήριξης διανυσμάτων (SVM) και οι μέθοδοι συνόλου δέντρων είναι οι πιο ευρέως εφαρμοζόμενοι ταξινομητές στη βιβλιογραφία για τη φωνή PD. Η LR παρέχει μια ερμηνεύσιμη γραμμική βάση [15]· η SVM με πυρήνα RBF υπήρξε ιστορικά η κυρίαρχη προσέγγιση, με Little et al. [3] να επιτυγχάνει ακρίβεια ~91% στο σύνολο δεδομένων UCI χρησιμοποιώντας 22 χαρακτηριστικά δυσφωνίας [16]. Μια συστηματική ανασκόπηση από Sáenz-Lechón et al. [17] σημείωσε ότι οι SVM και τα τυχαία δάση επιτυγχάνουν υψηλή ακρίβεια σε μικρά ομοιογενή σύνολα δεδομένων παθολογίας φωνής. Το Random Forest [18] συμπληρώνει το SVM μέσω του μέσου όρου συνόλου, της ενσωματωμένης σημασίας χαρακτηριστικών και της ανθεκτικότητας σε άσχετα χαρακτηριστικά, καθιστώντας το κατάλληλο για μικρές, θορυβώδεις ιατρικές κοόρτες. Οι πλήρεις προδιαγραφές μοντέλου και οι εξισώσεις που χρησιμοποιούνται σε αυτή τη εργασία παρέχονται στο Κεφάλαιο 4.

Πέρα από την ακατέργαστη απόδοση ταξινόμησης, πρόσφατες εργασίες έχουν τονίσει τη σημασία της ερμηνεύσιμης επιλογής χαρακτηριστικών στην κλινική ανάλυση φωνής. Solana-Lavalle and Rosas-Romero [19] συνδύασε την επιλογή υποσυνόλων χαρακτηριστικών με πολλαπλούς ταξινομητές και μείωση διαστάσεων για να παρέχει ένα κλινικά ερμηνεύσιμο πλαίσιο για την ανίχνευση της νόσου του Πάρκινσον από τη φωνή. Ένα αξιοσημείωτο εύρημα της μελέτης τους είναι ότι το σχετικό περιεχόμενο συχνότητας στο φωνητικό σήμα διαφέρει μεταξύ ανδρών και γυναικών ομιλητών, υπογραμμίζοντας την ανάγκη να ληφθούν υπόψη οι δημογραφικές υποομάδες κατά την ερμηνεία των φωνητικών ταξινομητών και τονίζοντας το ενδεχόμενο το φύλο να

αποτελεί συγχυτική μεταβλητή σε ομάδες μικτού φύλου.

2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις

Αν και η παρούσα εργασία επικεντρώνεται αποκλειστικά στην κλασική μηχανική μάθηση, ο ευρύτερος τομέας έχει μετατοπιστεί σημαντικά προς τη βαθιά μάθηση. Μια πρόσφατη συστηματική ανασκόπηση διαπίστωσε ότι περίπου το 42% των μελετών φωνής PD που δημοσιεύθηκαν μεταξύ 2020 και 2025 χρησιμοποιούν αρχιτεκτονικές βαθιάς μάθησης, με τα συνελκτικά νευρωνικά δίκτυα (CNN) να είναι τα πιο συνηθισμένα, ακολουθούμενα από προσεγγίσεις βασισμένες σε μετασχηματιστές και μοντέλα θεμελίωσης όπως το Wav2Vec 2.0 [6]. Έχουν επίσης εμφανιστεί υβριδικές διαδικασίες που συνδυάζουν εξάγοντες χαρακτηριστικών βαθιάς μάθησης με κλασικούς ταξινομητές. Οι ενσωματώσεις βασικών μοντέλων δείχνουν υποσχέσεις για διαγλωσσική ανθεκτικότητα. Ωστόσο, η ανασκόπηση διαπίστωσε επίσης ότι αυτές οι μελέτες βασίζονται κυρίως σε εσωτερική επικύρωση, ενώ η εξωτερική αξιολόγηση μεταξύ συνόλων δεδομένων παραμένει σπάνια. Οι ισχυρισμοί σχετικά με την απόδοση που βασίζονται σε μικρά, ομοιογενή σύνολα δεδομένων — είτε χρησιμοποιούν κλασικές είτε βαθιές μεθόδους — θα πρέπει επομένως να ερμηνεύονται με προσοχή. Η παρούσα εργασία καθιερώνει μια αυστηρή κλασική βάση αναφοράς με αξιολόγηση ασφαλή από διαρροές και αφαίρεση χαρακτηριστικών, η οποία μπορεί να χρησιμεύσει ως σημείο αναφοράς για μελλοντικές συγκρίσεις βασισμένες σε ενσωματώσεις.

2.6 Μεθοδολογικά ζητήματα στη βιβλιογραφία

2.6.1 Διαρροή δεδομένων

Η διαρροή δεδομένων, όπως περιγράφεται σε μια πρόσφατη συστηματική ανασκόπηση της έρευνας για τη φωνή PD [6]:

«Όταν υπάρχουν πολλαπλές ηχογραφήσεις ανά υποκείμενο, οι τυχαίες διαχωριστικές δοκιμές εκπαίδευσης/ελέγχου μπορούν να τοποθετήσουν ηχογραφήσεις από το ίδιο υποκείμενο και στα δύο σύνολα, οδηγώντας σε τεχνητά διογκωμένες εκτιμήσεις απόδοσης.»

Η παρούσα μελέτη χρησιμοποιεί ομαδοποιημένη στρωματοποιημένη διασταυρούμενη επικύρωση για να διασφαλίσει ότι όλες οι ηχογραφήσεις από ένα συγκεκριμένο υποκείμενο υπάρχουν είτε αποκλειστικά στο σύνολο εκπαίδευσης είτε στο σύνολο δοκιμής για κάθε πτυχή της διαδικασίας διασταυρούμενης επικύρωσης.

Πρόσφατη βιβλιογραφία δείχνει ότι, αν και πολλοί ερευνητές αναγνωρίζουν τα οφέλη της αξιολόγησης ανεξάρτητης από το υποκείμενο (δηλ. LOSO/LOOCV) και της αξιολόγησης εξωτερικών συνόλων δεδομένων, πολύ λίγοι ερευνητές στον τομέα χρησιμοποιούν αυτές τις προσεγγίσεις [6].

2.6.2 Ανισορροπία κλάσεων

Η ανισορροπία κλάσεων συμβαίνει όταν μια κλάση περιέχει σημαντικά περισσότερες περιπτώσεις από μια άλλη. Αυτό μπορεί να οδηγήσει σε παραπλανητικά αποτελέσματα όταν χρησιμοποιούνται απλά μέτρα ακρίβειας, επειδή ένα μοντέλο μπορεί να επιτύχει υψηλή ακρίβεια ενώ είναι μεροληπτικό προς την πλειοψηφούσα κατηγορία. Πολλές μελέτες δεν χρησιμοποιούν τεχνικές στάθμισης κατηγοριών ή επαναδειγματοληψίας για την αντιμετώπιση ζητημάτων που σχετίζονται με την ανισορροπία κατηγοριών [6]. Η παρούσα μελέτη διερευνά τη χρήση της στάθμισης κατηγοριών (λειτουργία «ισορροπημένη») ως πιθανή μέθοδο για τη μείωση των επιπτώσεων της ανισορροπίας κατηγοριών.

2.6.3 Αναπαραγωγιμότητα

Η αναπαραγωγή των αποτελεσμάτων από μελέτες στον τομέα της ταξινόμησης φωνής PD μπορεί να είναι δύσκολη λόγω της έλλειψης λεπτομερειών σχετικά με διάφορες πτυχές της έρευνας:

- Παράμετροι εξαγωγής χαρακτηριστικών που δεν έχουν καθοριστεί
- Τυχαία σπόρια που δεν έχουν καθοριστεί
- Ασαφής στρατηγική διασταυρούμενης επικύρωσης
- Διαδικασίες ρύθμισης υπερπαραμέτρων που δεν έχουν τεκμηριωθεί

Η παρούσα μελέτη αντιμετωπίζει τα παραπάνω προβλήματα παρέχοντας σταθερούς τυχαίους σπόρους, τεκμηριώνοντας τις παραμέτρους εξαγωγής χαρακτηριστικών και περιγράφοντας ρητά τα πρωτόκολλα διασταυρούμενης επικύρωσης.

2.6.4 Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων

Η εξωτερική επικύρωση — η δοκιμή ενός μοντέλου σε δεδομένα από μια εντελώς διαφορετική πηγή από το σύνολο εκπαίδευσης — είναι η πιο αυστηρή δοκιμή γενικευσιμότητας, αλλά πραγματοποιείται σε λιγότερο από το 15% των πρόσφατων μελετών φωνής PD [6]. Το αποτέλεσμα είναι ότι περίπου το 70% των μελετών

βασίζονται σε καθαρά εσωτερικές μετρήσεις που είναι πιθανό να υπερεκτιμούν την πραγματική απόδοση. Στις σπάνιες περιπτώσεις όπου έχει πραγματοποιηθεί αξιολόγηση μεταξύ συνόλων δεδομένων, έχουν παρατηρηθεί απότομες πτώσεις στην απόδοση· για παράδειγμα, μοντέλα που πέτυχαν τέλεια ακρίβεια σε ένα μικρό δείκτη αναφοράς υποβαθμίστηκαν σημαντικά όταν δοκιμάστηκαν σε ένα διαφορετικό σώμα δεδομένων [6]. Αυτά τα ευρήματα ενισχύουν την ανάγκη για συντηρητική ερμηνεία των αποτελεσμάτων εντός του δείγματος.

2.6.5 Ερμηνευσιμότητα

Η ερμηνευσιμότητα για κλινική επικύρωση παραμένει μια κρίσιμη αλλά ανεπαρκώς ανεπτυγμένη πτυχή της ταξινόμησης φωνής PD [6]. Μόνο μια μειοψηφία πρόσφατων μελετών χρησιμοποιεί μεθόδους εκ των υστέρων εξήγησης, όπως SHAP ή LIME· αυτές που το κάνουν έχουν εντοπίσει με συνέπεια το jitter, το shimmer και τη μονοτονία του τόνου ως κορυφαίους προγνωστικούς παράγοντες. Η περιορισμένη υιοθέτηση μεθόδων ερμηνευσιμότητας δημιουργεί ένα χάσμα μεταξύ των αποτελεσμάτων του μοντέλου και της κλινικής εφαρμοσιμότητας. Η παρούσα εργασία αντιμετωπίζει αυτό το χάσμα μέσω ανάλυσης αφαίρεσης χαρακτηριστικών και κατάταξης σημασίας χαρακτηριστικών με βάση την αναδιάταξη, παρέχοντας διαφανή εικόνα για το ποια ακουστικά χαρακτηριστικά καθορίζουν τις αποφάσεις ταξινόμησης.

2.7 Έλλειμμα στην έρευνα

Παρά τις πολυάριθμες μελέτες που αναφέρουν υψηλή ακρίβεια ταξινόμησης, λίγες αντιμετωπίζουν τα ακόλουθα:

1. **Ομαδοποιημένη διασταυρούμενη επικύρωση** για σύνολα δεδομένων πολλαπλών εγγραφών
2. **Μελέτες ελεγχόμενης αφαίρεσης χαρακτηριστικών**
3. **Συστηματική ανάλυση στάθμισης κατηγοριών**
4. **Διαφανής τεκμηρίωση** των περιορισμών
5. **Εξωτερική επικύρωση**: η γενίκευση μεταξύ συνόλων δεδομένων σπάνια δοκιμάζεται· η σύγκριση δύο συνόλων δεδομένων στην παρούσα μελέτη (ένα ακατέργαστο ηχητικό και ένα προ-εξαγόμενο) παρέχει κάποια στοιχεία εξωτερικής εγκυρότητας [6]
6. **Ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών**: το SHAP και άλλες μέθοδοι εκ

των υστέρων εξήγησης χρησιμοποιούνται σε λιγότερο από το 10% των μελετών της περιόδου 2020–2025· η παρούσα μελέτη καλύπτει αυτό το κενό μέσω της αφαίρεσης και της ανάλυσης της σημασίας των χαρακτηριστικών [6]

2.8 Περίληψη

Η ανίχνευση PD με βάση τη φωνή είναι δυνατή χρησιμοποιώντας κλασική μηχανική μάθηση σε ακουστικά χαρακτηριστικά, με ανταγωνιστικά αποτελέσματα που αναφέρονται σε πολλαπλά σύνολα δεδομένων. Ωστόσο, πρόσφατες συστηματικές ανασκοπήσεις που καλύπτουν την περίοδο 2019–2025 δείχνουν ότι η μεθοδολογική ποιότητα ποικίλλει σημαντικά στον τομέα αυτό όσον αφορά τις στρατηγικές επικύρωσης, την εξωτερική αξιολόγηση και την ερμηνευσιμότητα των αποτελεσμάτων [6, 7]. Ο τομέας απομακρύνεται επί του παρόντος από τα χειροποίητα ακουστικά χαρακτηριστικά προς ενσωματώσεις βαθιάς μάθησης, αλλά αυτές δεν έχουν ακόμη δείξει σταθερά πλεονεκτήματα στη γενίκευση υπό αυστηρή αξιολόγηση [6]. Ως εκ τούτου, η παρούσα μελέτη χρησιμοποιεί μια συντηρητική προσέγγιση που δίνει προτεραιότητα στην αναπαραγωγικότητα, την αξιολόγηση με γνώμονα το υποκείμενο και τη διαφάνεια στον τρόπο ερμηνείας των αποτελεσμάτων, έναντι της βελτιστοποίησης της απόδοσης.

Κεφάλαιο 3

Data Description

3.1 Dataset A: MDVR-KCL

3.1.1 Source and Collection

The Mobile Device Voice Recordings from King’s College London (MDVR-KCL) dataset [13] was collected specifically for Parkinson’s Disease research using smartphone recordings. The dataset is publicly available on Zenodo with DOI `10.5281/zenodo.2867215`.

Collection Context

Property	Value
Collection Period	26–29 September 2017
Location	King’s College London Hospital, Denmark Hill, London, UK
Recording Device	Motorola Moto G4 smartphone
Environment	Clinical examination room ($\sim 10\text{ m}^2$)
Reverberation Time	$\sim 500\text{ ms}$
Audio Capture	Direct microphone signal (no GSM compression)

Table 3.1: MDVR-KCL data collection context

Recordings were captured within the reverberation radius directly from the microphone signal (not GSM-compressed), resulting in acoustically clean audio suitable for feature extraction.

3.1.2 Audio Specifications

Property	Value
Format	WAV (uncompressed PCM)
Native Sample Rate	44.1 kHz
Processing Sample Rate	22.05 kHz (resampled)
Bit Depth	16-bit signed integer
Channels	Mono
Compression	None

Table 3.2: Audio specifications for Dataset A

All audio files are resampled to 22.05 kHz for feature extraction to ensure consistency and computational efficiency while preserving sufficient frequency resolution for speech analysis (Nyquist frequency: 11.025 kHz).

3.1.3 Speech Tasks

The dataset includes two distinct speech tasks designed to capture different aspects of vocal production:

Task	Description	Subjects	HC	PD
ReadText	"The North Wind and the Sun" passage	37	21	16
SpontaneousDialogue	Free conversation with examiner	36	21	15

Table 3.3: Speech tasks in MDVR-KCL dataset

Note: Subject ID18 is missing from the SpontaneousDialogue task, resulting in one fewer recording for that condition.

3.1.4 Class Distribution

ReadText Task:

--- HC (Healthy Control): 21 subjects (56.8%)

--- PD (Parkinson's Disease): 16 subjects (43.2%)

SpontaneousDialogue Task:

--- HC (Healthy Control): 21 subjects (58.3%)

--- PD (Parkinson's Disease): 15 subjects (41.7%)

Imbalance Ratio: Moderate ($\sim 57:43$ HC:PD). Class weighting experiments were conducted to assess impact on classification performance.

3.1.5 Known Anomalies

- **ID18:** Missing from SpontaneousDialogue task (36 subjects vs. 37 in ReadText).

3.2 Dataset B: PD Speech Features

3.2.1 Source

Pre-extracted acoustic features from the UCI Machine Learning Repository, distributed via Kaggle [14]. The dataset contains 752 acoustic features pre-computed from sustained vowel phonations.

3.2.2 Collection Context

Property	Value
Institution	Istanbul University, Cerrahpaşa Faculty of Medicine
Collection Period	Not specified in metadata
PD Subjects	188
HC Subjects	64
Age Range (PD)	33–87 years
Age Range (HC)	41–82 years
Speech Task	Sustained phonation of vowel /a/
Repetitions	3 per subject
Native Sample Rate	44.1 kHz (reported in metadata)

Table 3.4: Collection context for Dataset B

3.2.3 Data Format

- **Format:** CSV (comma-separated values)
- **Rows:** 756 samples (multiple per subject)
- **Columns:** 753 total (752 features + 1 binary label)
- **Label encoding:** 1 = PD, 0 = HC
- **Subject IDs:** Not provided (critical limitation)

3.2.4 Class Distribution

Class	Samples	Percentage
HC (0)	192	25.4%
PD (1)	564	74.6%

Table 3.5: Class distribution in Dataset B

Imbalance Ratio: Severe ($\sim 25:75$ HC:PD), necessitating class weighting strategies in model training.

3.2.5 Feature Categories

The 752 features span multiple acoustic domains computed by the original authors:

Category	Count	Description
Baseline	22	Jitter variants, shimmer variants, HNR, NHR
Intensity	3	Min, max, mean intensity
Formants	36	F_1-F_4 frequency and bandwidth statistics
MFCCs	84	Mean, std, delta for MFCC 0–12
Wavelet (DWT)	182	Discrete wavelet decomposition features
TQWT	432	Tunable Q-factor wavelet transform features
Other	7	PPE, DFA, RPDE, numPulses, GQ, GNE, VFER

Table 3.6: Feature categories in Dataset B (752 total)

3.2.6 Methodological Caveats

Critical Limitation: No subject identifiers are available in Dataset B. This prevents validation of true out-of-subject generalization, as the same subject may appear in both training and test folds during cross-validation.

Given that 756 samples were collected from 252 subjects (188 PD + 64 HC) with 3 repetitions each, standard stratified 5-fold cross-validation may place samples from the same subject in different folds, leading to:

- **Optimistically biased performance estimates** (overestimation of generalization)
- **Violation of independence assumption** in cross-validation

- **Inability to assess subject-level generalization**

Results on Dataset B should be interpreted cautiously with these limitations in mind. Additional constraints include: no access to raw audio (cannot verify or extend features); sustained vowel phonation only (does not represent connected speech); and 752-dimensional features that may cause overfitting at the available sample size.

3.3 Cross-Dataset Comparison

3.3.1 Key Differences

Aspect	Dataset A	Dataset B
Data format	Raw audio (WAV)	Pre-extracted features (CSV)
Sample size	37 subjects (73 recordings)	756 rows (subjects unknown)
Subject tracking	Available	Unavailable
Feature dimensionality	47 (baseline) or 78 (extended)	752 (fixed)
Speech task	Read text / Dialogue	Sustained /a/ phonation
Feature extraction	Controlled (this work)	Pre-computed (black box)
Cross-validation	Grouped (subject-level)	Standard (row-level)
Clinical metadata	H&Y, UPDRS available	None

Table 3.7: Detailed cross-dataset comparison

Κεφάλαιο 4

Methodology

4.1 Feature Extraction Pipeline

4.1.1 Pipeline Architecture

The feature extraction pipeline transforms raw audio into structured feature vectors suitable for machine learning:




Figure 4.1: Feature extraction pipeline architecture. Each audio file produces one feature vector.

4.1.2 Audio Preprocessing

All audio files undergo standardized preprocessing to ensure consistent feature extraction:

1. **Load audio** at native sample rate using `librosa.load()`
2. **Resample** to 22,050 Hz (standardized across all recordings)
3. **Convert to mono** if stereo (channel averaging)

4. **Normalize amplitude** to $[-1, 1]$ range
5. **Trim silence** using energy-based detection (threshold: top 5% energy)

The 22,050 Hz sample rate was chosen as it provides adequate frequency resolution for speech (Nyquist frequency: 11,025 Hz) while reducing computational cost compared to 44,100 Hz.

4.1.3 Prosodic Features (21 features)

Prosodic features capture suprasegmental voice characteristics known to be affected in PD. All prosodic features were extracted using Parselmouth [20], a Python interface to Praat.

Fundamental Frequency (F_0)

Pitch extraction used the following parameters:

- **Algorithm:** Autocorrelation-based (Praat's default)
- **Pitch range:** 75–500 Hz (covers male, female, and pathological voices)
- **Time step:** 0.01 s (standard for voice analysis)

Four statistics were computed from the pitch contour:

$$F_0 = \{\mu_{F_0}, \sigma_{F_0}, \min_{F_0}, \max_{F_0}\} \quad (4.1)$$

Jitter

Jitter quantifies cycle-to-cycle variation in pitch period. Three measures were extracted:

$$\text{Jitter}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|T_i - T_{i+1}|}{\bar{T}} \quad (4.2)$$

where T_i is the i -th pitch period and $\bar{T}$ is the mean period.

Additional measures include:

- **RAP (Relative Average Perturbation):** 3-point smoothing
- **PPQ5:** 5-point period perturbation quotient

Shimmer

Shimmer quantifies cycle-to-cycle variation in amplitude. Five measures were extracted:

$$\text{Shimmer}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|A_i - A_{i+1}|}{\bar{A}} \quad (4.3)$$

where A_i is the i -th peak amplitude and $\bar{A}$ is the mean amplitude.

Additional measures include APQ3, APQ5, APQ11 (amplitude perturbation quotients with varying windows), and DDA (difference of differences of amplitudes).

Harmonics-to-Noise Ratio (HNR)

HNR quantifies the ratio of harmonic to noise components:

- **Mean HNR:** Average HNR across the utterance (dB)
- **Autocorrelation harmonicity:** Peak autocorrelation value

Intensity

Three intensity statistics (dB SPL):

$$I = \{\mu_I, \sigma_I, \max_I - \min_I\} \quad (4.4)$$

Formants

First three formants (F_1, F_2, F_3) were extracted using Linear Predictive Coding (LPC):

- **LPC order:** 10 (sufficient for 3 formants at 22 kHz)
- **Features:** Mean and standard deviation of each formant (6 features total)

Feature Group	Count	Features	Tool
Pitch (F_0)	4	mean, std, min, max	Parselmouth
Jitter	3	local, RAP, PPQ5	Parselmouth
Shimmer	5	local, APQ3, APQ5, APQ11, DDA	Parselmouth
Harmonicity	2	HNR mean, autocorr	Parselmouth
Intensity	3	mean, std, range	Parselmouth
Formants	6	F_1 – F_3 mean, F_1 – F_3 std	Parselmouth
Total	21		

Table 4.1: Prosodic feature breakdown

4.1.4 Spectral Features

Spectral features capture frequency-domain characteristics using the `librosa` library [21].

Mel-Frequency Cepstral Coefficients (MFCCs)

MFCCs are computed via the following steps:

1. **Pre-emphasis:** $y[n] = x[n] - 0.97 \cdot x[n - 1]$
2. **Framing:** Window length = 2048 samples (≈ 93 ms at 22 kHz)
3. **Windowing:** Hann window applied
4. **FFT:** 2048-point FFT
5. **Mel filterbank:** 128 triangular filters spanning 0–11,025 Hz
6. **Log compression:** $\log(\text{mel power spectrum})$
7. **DCT:** Discrete Cosine Transform to decorrelate coefficients

Parameters used:

- **Number of coefficients:** 13 (MFCC 0–12)
- **Hop length:** 512 samples (≈ 23 ms at 22 kHz, 75% overlap)
- **Number of mel bands:** 128

MFCC 0 (the zeroth coefficient) captures energy information, while MFCCs 1–12 capture spectral envelope shape.

Delta Coefficients

First-order temporal derivatives (delta coefficients) capture spectral dynamics:

$$\Delta_t[n] = \frac{\sum_{i=1}^N i \cdot (c_{t+i} - c_{t-i})}{2 \sum_{i=1}^N i^2} \quad (4.5)$$

where c_t is the MFCC coefficient at frame t and $N = 2$ is the window size.

Baseline Spectral Features (26 features)

The baseline spectral feature set consists of:

Feature	Count	Description
MFCC mean	13	Temporal mean of MFCCs 0–12
Delta MFCC mean	13	Temporal mean of first-order derivatives
Total	26	

Table 4.2: Baseline spectral features

Extended Spectral Features (57 features)

The extended feature set adds three groups of features designed to capture additional spectral and temporal variability:

Feature	Count	Description
MFCC mean	13	Temporal mean of MFCCs 0–12
MFCC std	13	Temporal std deviation (within-utterance variability)
Delta MFCC mean	13	Temporal mean of first-order derivatives
Delta-Delta MFCC mean	13	Temporal mean of second-order derivatives (acceleration)
Spectral shape	5	Centroid, bandwidth, rolloff, flatness, ZCR
Total	57	

Table 4.3: Extended spectral features (new features in bold)

The five spectral shape descriptors are:

1. **Spectral Centroid:** Center of mass of the spectrum (Hz)
2. **Spectral Bandwidth:** Weighted standard deviation around centroid (Hz)
3. **Spectral Rolloff:** Frequency below which 85% of energy is contained (Hz)
4. **Spectral Flatness:** Ratio of geometric to arithmetic mean (tonality measure)
5. **Zero-Crossing Rate:** Rate of sign changes in time-domain signal

4.1.5 Total Feature Counts

Configuration	Prosodic	Spectral	Total
Baseline	21	26	47
Extended	21	57	78

Table 4.4: Total feature counts by configuration

4.2 Feature Set Comparison

4.2.1 Rationale for Extended Features

The extended feature set was designed as a **controlled ablation study** to test the hypothesis that additional temporal and spectral information improves classification. Three feature groups were added:

1. **MFCC std (13):** Captures within-utterance variability—important for detecting instability in PD speech where motor fluctuations may manifest as increased spectral variance
2. **Delta-Delta MFCC (13):** Captures acceleration of spectral changes—sensitive to temporal dynamics and rate-of-change in articulatory movements
3. **Spectral shape (5):** Provides complementary global spectral descriptors not captured by MFCCs (e.g., overall tonality, spectral spread)

4.2.2 Feature Extraction Reproducibility

All parameters (random seed 42; 22 050 Hz sample rate; F_0 range 75–500 Hz; 13 MFCCs with 2048-point FFT, 512-sample hop, 128 mel bands) were fixed in a central configuration module before experimentation, with results saved to CSV for all downstream experiments.

4.3 Machine Learning Models

4.3.1 Model Specifications

Five classical ML models were selected for diverse inductive biases: Logistic Regression (linear baseline with L2 regularisation), SVM with RBF kernel (nonlinear kernel method), Random Forest (ensemble averaging with built-in feature importance), Gradient

Boosting [22] (sequential residual correction), and XGBoost [23] (regularised boosting). All hyperparameters were fixed *a priori* without dataset-specific tuning:

Model	Type	Key Parameters
Logistic Regression	Linear	$C = 1.0$ (L2 regularization), max_iter= 1000, solver='lbfgs'
SVM (RBF)	Kernel	$C = 1.0$ (regularization), gamma='scale' (auto-scaled by features), kernel='rbf'
Random Forest	Bagging	n_estimators= 100, max_depth= 10, min_samples_split= 2, random_state= 42
Gradient Boosting	Boosting	n_estimators= 100, learning_rate= 0.1, max_depth= 3 (default), random_state= 42
XGBoost	Boosting	n_estimators= 100, learning_rate= 0.1, eval_metric='logloss', random_state= 42

Table 4.5: Model specifications. All parameters fixed before experiments.

Logistic Regression

The logistic regression model predicts class probabilities via:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (4.6)$$

with L2 regularization:

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n \log(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)}) + \frac{1}{2} \|\mathbf{w}\|_2^2 \right] \quad (4.7)$$

where $C = 1.0$ controls the regularization strength.

Support Vector Machine

The RBF kernel SVM learns a nonlinear decision boundary via:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (4.8)$$

where $\gamma = \frac{1}{n_{\text{features}} \cdot \text{Var}(\mathbf{X})}$ (auto-scaled).

Random Forest

The Random Forest aggregates predictions from 100 decision trees:

$$\hat{y} = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \hat{y}_t(\mathbf{x}) \quad (4.9)$$

Each tree is trained on a bootstrap sample with random feature subsets at each split. The maximum depth of 10 was chosen to prevent overfitting on small datasets.

Gradient Boosting

Gradient Boosting constructs an additive model in a stage-wise fashion, where each new tree corrects the residual errors of the ensemble [22]:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}) \quad (4.10)$$

where F_m is the ensemble after m stages, h_m is the weak learner (decision tree) fitted to the negative gradient of the loss function, and $\eta = 0.1$ is the learning rate. The learning rate shrinks the contribution of each tree, providing a regularisation effect.

XGBoost

XGBoost [23] extends gradient boosting with explicit L1 and L2 regularisation on leaf weights:

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(\hat{y}_i, y_i) + \sum_{k=1}^K \Omega(f_k), \quad \text{where } \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \quad (4.11)$$

Here T is the number of leaves, $\mathbf{w}$ is the vector of leaf weights, and γ, λ are regularisation parameters. This regularisation helps prevent overfitting, which is particularly relevant for small-sample datasets.

4.3.2 Class Weighting

Class imbalance is addressed via the `class_weight` parameter:

```

1 # Unweighted (baseline condition)
2 class_weight = None
3
4 # Weighted (balanced condition)
```

```
5 class_weight = "balanced" #  $w_k = n_{\text{samples}} / (n_{\text{classes}} * n_k)$ 
```

When `class_weight="balanced"`, sample weights are computed as:

$$w_k = \frac{n_{\text{samples}}}{n_{\text{classes}} \cdot n_k} \quad (4.12)$$

where n_k is the number of samples in class k . This ensures minority class errors are weighted more heavily during training.

Three of the five models (Logistic Regression, SVM, Random Forest) support the `class_weight` parameter natively via scikit-learn. The two boosting classifiers (Gradient Boosting and XGBoost) do not support `class_weight="balanced"` natively; however, since the mild class imbalance (1.3:1) did not require reweighting in practice (see Chapter 6), this difference has no impact on the experimental design.

4.4 ML Pipeline Architecture

4.4.1 Pipeline Structure

All models use a standardized scikit-learn Pipeline:

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3
4 pipeline = Pipeline([
5     ('scaler', StandardScaler()),
6     ('classifier', Model(class_weight=..., random_state=42))
7 ])
```

This ensures feature scaling is applied consistently and prevents data leakage.

4.4.2 Feature Standardisation

Features are standardised to zero mean and unit variance (`StandardScaler`) fitted exclusively on the training fold within each CV split, preventing information leakage from the test data.

4.5 Evaluation Framework

4.5.1 Cross-Validation Strategy

In this thesis, **K -fold cross-validation serves as the primary validation strategy**: the model is trained on $K - 1$ folds and evaluated on the remaining fold, which contains only samples that the model has never seen during training or feature standardisation [15]. This procedure is repeated $K = 5$ times, producing five independent estimates of generalisation performance. A separate held-out test set was not used because, with only $n = 37$ subjects (Dataset A), reserving even 20% for testing would yield approximately seven test subjects per fold under subject-level splitting — too few for stable metric computation. Cross-validation maximises data utility while still guaranteeing that each evaluation uses strictly unseen data.

Since all hyperparameters were fixed *a priori* (Table 4.5), no inner hyperparameter-selection loop is required: the 5-fold CV here serves purely as an **evaluation mechanism**, not a tuning mechanism. This eliminates any risk of optimising hyperparameters towards the held-out data.

Different strategies were required for each dataset due to their structural differences:

Dataset	Strategy	Folds	Grouping
Dataset A (MDVR-KCL)	Grouped Stratified	5	By subject_id
Dataset B (PD Speech)	Stratified	5	None (unavailable)

Table 4.6: Cross-validation strategies

Dataset A: Grouped Cross-Validation

For Dataset A (MDVR-KCL), multiple recordings per subject necessitate subject-level splitting to prevent data leakage. The strategy ensures:

- All recordings from the same subject appear in the same fold
- Approximate class balance across folds (stratification by label)
- Training never sees recordings from subjects in the test set

This simulates realistic deployment where the model encounters entirely new speakers.

Dataset B: Standard Stratified Cross-Validation

For Dataset B (PD Speech Features), subject IDs are unavailable. Standard stratified 5-fold cross-validation was used with the caveat that results may be optimistic if the same subjects

appear across samples.

4.5.2 Evaluation Metrics

Five standard classification metrics were computed for each fold:

Metric	Formula	Interpretation
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$	Overall correctness (baseline for comparison)
Precision	$\frac{TP}{TP+FP}$	Positive predictive value (PD prediction reliability)
Recall	$\frac{TP}{TP+FN}$	Sensitivity (true positive rate for PD cases)
F1 Score	$\frac{2 \cdot P \cdot R}{P+R}$	Harmonic mean balancing precision and recall
ROC-AUC	$\int_0^1 \text{TPR}(t) d\text{FPR}(t)$	Threshold-independent discrimination ability

Table 4.7: Evaluation metrics

Primary metric: ROC-AUC was selected as the primary metric because:

- Threshold-independent (evaluates discrimination across all thresholds)
- Robust to class imbalance
- Clinically interpretable (probability that a random PD patient scores higher than a random HC)

Κεφάλαιο 5

Experimental Design

5.1 Research Questions

The experiments address the following research questions:

- RQ1:** How do classical ML models perform on PD voice classification using acoustic features?
- RQ2:** Does feature set extension (47 $\rightarrow$ 78 features) improve classification performance?
- RQ3:** Does balanced class weighting improve performance on imbalanced datasets?
- RQ4:** How do results compare between Dataset A (subject-aware CV) and Dataset B (standard CV)?
- RQ5:** Do speech tasks (read vs spontaneous speech) yield different classification performance?

5.2 Experimental Matrix

5.2.1 $2 \times 2 \times 5$ Factorial Design

The complete experimental design crosses three factors:

1. **Feature Set:** Baseline (47) vs Extended (78)
2. **Class Weighting:** None (baseline) vs Balanced
3. **Model Architecture:** Logistic Regression vs SVM (RBF) vs Random Forest vs Gradient Boosting vs XGBoost

This yields $2 \times 2 \times 5 = 20$ conditions per dataset/task combination.

ID	Features	Weight	Models	Output Dir
C1	Baseline (47)	None	LR, SVM, RF, GB, XGB	baseline/baseline/
C2	Extended (78)	None	LR, SVM, RF, GB, XGB	baseline/extended/
C3	Baseline (47)	Balanced	LR, SVM, RF, GB, XGB	weighted/baseline/
C4	Extended (78)	Balanced	LR, SVM, RF, GB, XGB	weighted/extended/

Table 5.1: Experimental conditions (20 total: 4 conditions $\times$ 5 models each). Note: class weighting applies only to LR, SVM, and RF; GB and XGB do not support `class_weight` natively.

5.2.2 Total Experimental Runs

Dataset/Task	Conditions	Models	CV Folds	Total Runs
Dataset A - ReadText	4	5	5	100
Dataset A - SpontaneousDialogue	4	5	5	100
Dataset B - PD Speech	4	5	5	100
Grand Total				300

Table 5.2: Total experimental runs across all datasets and conditions

5.3 Experimental Protocols and Reproducibility

Cross-validation strategies (grouped stratified K-fold for Dataset A, stratified K-fold for Dataset B), evaluation metrics, and statistical reporting are defined in Chapter 4 (Sections 4.5.1 and 4.5.2). All experiments used `random_state=42` for reproducibility. Dataset B results should be interpreted cautiously due to the absence of subject identifiers (Section 8.2.1). Limitations are catalogued in Chapter 8.

Κεφάλαιο 6

Results

6.1 Summary of Best Results

6.1.1 Dataset A (MDVR-KCL) — Best Performance

Metric	Value	Model	Task	Condition
ROC-AUC	0.857 ± 0.171	Random Forest	Spontaneous	Extended / Un-weighted
Accuracy	$82.2\% \pm 16.6\%$	Random Forest	ReadText	Extended / Un-weighted

Table 6.1: Best performance on Dataset A

6.1.2 Dataset B (Benchmark Comparison)

Performance Summary: Dataset B achieved substantially higher metrics across all classifiers, as shown in Table 6.2. Results should be interpreted cautiously due to unknown subject overlap (Section 8.2.1).

Model	ROC-AUC	Accuracy	F1	Recall
Logistic Regression	0.867 ± 0.029	0.828 ± 0.008	0.885 ± 0.006	0.890 ± 0.016
SVM (RBF)	0.885 ± 0.025	0.851 ± 0.024	0.908 ± 0.015	0.986 ± 0.019
Random Forest	0.940 ± 0.013	0.882 ± 0.019	0.925 ± 0.012	0.980 ± 0.015
Gradient Boosting	0.937 ± 0.019	0.884 ± 0.024	0.926 ± 0.015	0.980 ± 0.013
XGBoost	0.952 ± 0.015	0.896 ± 0.017	0.933 ± 0.011	0.980 ± 0.017

Table 6.2: Dataset B performance using baseline (unweighted) configuration. Note the substantially lower variance compared to Dataset A.




Figure 6.1: Random Forest feature importance (Dataset B). The top features are dominated by advanced signal processing metrics often unavailable in standard clinical settings.

Key Differences from Dataset A:

- **Sample Size Effect:** $n = 752$ vs $n = 37$ reduces variance by an order of magnitude (± 0.01 vs ± 0.15).
- **Optimistic Bias:** Results may be inflated due to unknown subject overlap across training/test folds.
- **Feature Availability:** Many top-ranked features (e.g., DFA, RPDE) require specialized analysis not captured in Dataset A's baseline features.

6.2 Condition 1: Baseline Features + Unweighted

Configuration: 47 features, no class weighting

6.2.1 Task: ReadText

Model	ROC-AUC	Accuracy	F1
Logistic Regression	0.717 ± 0.139	0.621 ± 0.058	0.542 ± 0.099
SVM (RBF)	0.614 ± 0.312	0.621 ± 0.106	0.333 ± 0.333
Random Forest	0.590 ± 0.302	0.629 ± 0.178	0.351 ± 0.363
Gradient Boosting	0.500 ± 0.159	0.464 ± 0.134	0.374 ± 0.221
XGBoost	0.628 ± 0.203	0.518 ± 0.132	0.371 ± 0.262

Table 6.3: Condition 1 — ReadText results

6.2.2 Task: Spontaneous Dialogue

Model	ROC-AUC	Accuracy	F1
Logistic Regression	0.760 ± 0.214	0.639 ± 0.160	0.539 ± 0.321
SVM (RBF)	0.407 ± 0.309	0.636 ± 0.135	0.400 ± 0.253
Random Forest	0.828 ± 0.148	0.721 ± 0.176	0.567 ± 0.365
Gradient Boosting	0.615 ± 0.078	0.664 ± 0.133	0.583 ± 0.118
XGBoost	0.723 ± 0.197	0.668 ± 0.121	0.470 ± 0.323

Table 6.4: Condition 1 — Spontaneous Dialogue results

6.3 Condition 2: Extended Features + Unweighted

Configuration: 78 features, no class weighting

6.3.1 Task: ReadText

Model	ROC-AUC	Accuracy	F1
Logistic Regression	0.698 ± 0.132	0.596 ± 0.079	0.475 ± 0.106
SVM (RBF)	0.834 ± 0.153	0.786 ± 0.181	0.634 ± 0.386
Random Forest	0.822 ± 0.166	0.818 ± 0.140	0.746 ± 0.207
Gradient Boosting	0.724 ± 0.214	0.654 ± 0.138	0.605 ± 0.184
XGBoost	0.794 ± 0.186	0.739 ± 0.195	0.691 ± 0.252

Table 6.5: Condition 2 — ReadText results




Figure 6.2: Random Forest feature importance for ReadText task (Extended features). Fundamental frequency (F_0) statistics appear highly predictive.

6.3.2 Task: Spontaneous Dialogue

Model	ROC-AUC	Accuracy	F1
Logistic Regression	0.783 ± 0.139	0.671 ± 0.199	0.530 ± 0.377
SVM (RBF)	0.460 ± 0.294	0.636 ± 0.089	0.428 ± 0.258
Random Forest	0.857 ± 0.171	0.779 ± 0.161	0.605 ± 0.387
Gradient Boosting	0.638 ± 0.146	0.636 ± 0.221	0.547 ± 0.222
XGBoost	0.687 ± 0.146	0.693 ± 0.123	0.553 ± 0.176

Table 6.6: Condition 2 — Spontaneous Dialogue results




Figure 6.3: Random Forest feature importance for Spontaneous Dialogue task (Extended features). MFCC features show increased importance compared to ReadText.

6.4 Feature Ablation Analysis

6.4.1 ROC-AUC Improvement from Feature Extension (ReadText)

Model	Baseline (47)	Extended (78)	Δ ROC-AUC
Logistic Regression	0.717	0.698	−0.019
SVM (RBF)	0.614	0.834	+0.220
Random Forest	0.590	0.822	+0.232
Gradient Boosting	0.500	0.724	+0.224
XGBoost	0.628	0.794	+0.166

Table 6.7: Feature ablation — ReadText

6.4.2 ROC-AUC Improvement from Feature Extension (Spontaneous)

Model	Baseline (47)	Extended (78)	Δ ROC-AUC
Logistic Regression	0.760	0.783	+0.023
SVM (RBF)	0.407	0.460	+0.053
Random Forest	0.828	0.857	+0.029
Gradient Boosting	0.615	0.638	+0.023
XGBoost	0.723	0.687	−0.036

Table 6.8: Feature ablation — Spontaneous Dialogue

6.5 Class Weighting Analysis

Class weighting (`class_weight='balanced'`) was evaluated to address Dataset A’s mild class imbalance (HC:PD $\approx$ 1.3:1). Results showed minimal improvement and occasional degradation.

6.5.1 ReadText Task — Baseline Features

Model	Unweighted	Weighted	Δ ROC-AUC
Logistic Regression	0.717 ± 0.139	0.717 ± 0.139	0.000
Random Forest	0.590 ± 0.302	0.687 ± 0.258	+0.097
SVM (RBF)	0.614 ± 0.312	0.542 ± 0.312	−0.072
Gradient Boosting	<i>N/A (no native class_weight)</i>		
XGBoost	<i>N/A (no native class_weight)</i>		

Table 6.9: Class weighting impact on ReadText (baseline features). Random Forest showed modest improvement.

6.5.2 Extended Features — All Tasks

With extended features, class weighting provided negligible or negative benefit: RF ReadText dropped -1.7pp ($0.822 \rightarrow 0.805$) and Spontaneous dropped -3.4pp ($0.857 \rightarrow 0.823$), confirming that the mild 1.3:1 imbalance did not require correction.

6.6 Precision-Recall Tradeoffs

Classifiers exhibited distinct precision-recall profiles, critical for understanding clinical deployment scenarios.

6.6.1 Random Forest (Extended Features)

Task	Precision	Recall	F1-Score
ReadText	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207
Spontaneous	0.683 ± 0.410	0.600 ± 0.435	0.605 ± 0.387

Table 6.10: Random Forest precision-recall profile. ReadText configuration favors precision (fewer false positives).

Analysis: ReadText achieved high precision (0.88) at the cost of recall (0.70), suggesting the model is conservative in predicting PD. This profile may be preferable for screening applications where false positives carry higher cost.

6.7 Confusion Matrix Analysis

The confusion matrices below aggregate out-of-fold predictions from the extended feature set (78 features, unweighted) configuration across all five cross-validation folds. Each matrix displays the total number of correctly and incorrectly classified subjects across all folds, providing a visual complement to the aggregate metrics reported in earlier sections. True labels appear on the rows; predicted labels on the columns.

6.7.1 Dataset A — ReadText




Figure 6.4: Aggregated confusion matrices for the ReadText task (Extended features, Grouped 5-Fold CV, $n = 37$ subjects). Each cell reports the total out-of-fold count and its percentage of all predictions. These results should be interpreted cautiously given the small sample size.

All five classifiers achieve above-chance PD detection on ReadText. Random Forest and SVM (RBF) reach the strongest true-positive rates, consistent with their ROC-AUC advantage. Logistic Regression exhibits a more conservative prediction profile, contributing to higher precision at the cost of recall. The small subject pool ($n = 37$) limits absolute cell counts and increases fold-to-fold variability.

6.7.2 Dataset A — Spontaneous Dialogue




Figure 6.5: Aggregated confusion matrices for the Spontaneous Dialogue task (Extended features, Grouped 5-Fold CV, $n = 36$ subjects). This task yielded the highest overall ROC-AUC in the study (0.857 ± 0.171 , Random Forest).

Random Forest demonstrates improved PD detection on Spontaneous Dialogue compared to ReadText, with a higher true-positive count and fewer false negatives. The SVM (RBF) confusion pattern reflects its high variance: strong in some folds, near-chance in others. These results should be interpreted cautiously given the $n = 36$ sample size.

6.7.3 Dataset B




Figure 6.6: Aggregated confusion matrices for Dataset B (Stratified 5-Fold CV, $n = 756$ recordings). The substantially larger sample size yields well-separated confusion patterns with low variance. Results may be optimistic due to unknown subject overlap across folds.

All five classifiers achieve markedly better separation on Dataset B, confirming the positive effect of sample size on model stability. Random Forest, the best-performing classifier on this dataset (ROC-AUC 0.940 ± 0.013), exhibits very few false negatives relative to true positives. These results should be interpreted cautiously due to unknown subject overlap (Section 8.2.1).

Κεφάλαιο 7

Discussion

7.1 Interpretation of Key Findings

7.1.1 Feature Extension Impact

Extending the raw-audio feature set from 47 to 78 features resulted in substantial performance gains, particularly for the ReadText task. Under the Random Forest classifier, ROC-AUC increased from 0.590 ± 0.302 to 0.822 ± 0.166 (+23 percentage points), elevating performance from near-chance level to clinically meaningful discrimination.

Task-Specific Effects:

Model	ReadText Δ	Spontaneous Δ	Effect Size
Random Forest	+23.2pp	+2.9pp	8× larger
SVM (RBF)	+22.0pp	+5.3pp	4× larger
Logistic Regression	−1.9pp	+2.3pp	Neutral

Table 7.1: Feature extension impact by task. ReadText showed dramatically larger improvements, suggesting baseline features were insufficient for structured speech.

Interpretation:

The extended features capture three complementary aspects of speech dynamics:

Feature Group	Contribution
MFCC standard deviations	Within-utterance spectral variability
Delta–delta MFCCs	Second-order temporal dynamics (acceleration)
Spectral shape descriptors	Global distribution of spectral energy

Table 7.2: Extended feature contributions

The disproportionate improvement for ReadText suggests that:

1. **Structured speech** (reading) requires finer-grained spectral features to capture PD-related rigidity patterns
2. **Spontaneous speech** already contains sufficient prosodic variability detectable by baseline features
3. **Temporal acceleration** (delta-delta) captures motor control deficits more evident in reading tasks
4. **Linear models** (Logistic Regression) may overfit to 78 dimensions given $n = 37$ subjects

7.1.2 Class Weighting Effects

Class weighting showed **modest and inconsistent effects** on Dataset A:

Model	Δ ROC-AUC (weighted vs unweighted)
Random Forest	+3.5pp (baseline), −1.4pp (extended)
Logistic Regression	0.0pp
SVM (RBF)	−1.3pp (baseline), −1.4pp (extended)

Table 7.3: Class weighting effects

Interpretation:

The moderate imbalance in Dataset A (57:43 HC:PD) is not severe enough to substantially degrade unweighted classifiers. Class weighting becomes more critical when:

- Imbalance exceeds 70:30
- Minority class has high cost of misclassification
- Sample size is very small

7.1.3 Model Performance Hierarchy

Across all conditions, Random Forest consistently achieved the highest scores among the five classifiers evaluated:

$$\text{Random Forest} \geq \text{Gradient Boosting} \approx \text{XGBoost} > \text{Logistic Regression} \approx \text{SVM (RBF)}$$

Random Forest’s advantages for this task include:

- 1. **Ensemble averaging** reduces variance on small datasets
- 2. **Feature importance** provides interpretability
- 3. **Non-linear decision boundaries** capture complex patterns
- 4. **Robustness** to irrelevant features through feature subsampling

7.1.4 High Variance Across Folds

Standard deviations frequently exceeded 0.15 (15%), indicating substantial fold-to-fold variability. Dataset A exhibited variance 10–15× higher than Dataset B:

Metric	Dataset A (n=37)	Dataset B (n=752)
ROC-AUC std	±0.15–0.30	±0.01–0.03
Accuracy std	±0.14–0.18	±0.008–0.024
F1-Score std	±0.21–0.39	±0.006–0.015

Table 7.4: Variance comparison: small vs large datasets. Standard deviations scale approximately as $1/\sqrt{n}$.

Causes:

- 1. **Small sample size:** 37 subjects → ~7 subjects per test fold → high sensitivity to individual cases
- 2. **Subject heterogeneity:** Unknown disease severity distribution (MDVR-KCL lacks clinical staging)
- 3. **Recording variability:** Smartphone-based capture in uncontrolled environments
- 4. **Task complexity:** Spontaneous Dialogue requires cognitive load not standardized across subjects

Extreme Cases:

Some models exhibited near-random performance on specific folds:

- SVM on Spontaneous/Baseline: 0.407 ± 0.309 (ROC-AUC range: 0.10–0.72)
- Random Forest on ReadText/Baseline: 0.590 ± 0.302 (range: 0.29–0.89)

These wide ranges suggest that certain subject groupings in test folds were particularly difficult or easy to classify.

Implications:

- Absolute performance numbers should be interpreted cautiously given the small sample size ($n = 37$)
- **Relative comparisons** across conditions (same CV splits) are more reliable
- Confidence intervals overlap for many model comparisons, limiting statistical conclusions
- Larger studies ($n > 100$) are needed for definitive model ranking

7.2 Comparison with Literature

7.2.1 Performance Context

Study	Dataset	Best ROC-AUC	Method
Little et al. (2009)	UCI	0.92	SVM
Sakar et al. (2013)	Custom	0.86	SVM
This thesis	MDVR-KCL	0.87	RF

Table 7.5: Comparison with literature

Our results are competitive with literature, though direct comparison is limited due to:

- Different datasets and features
- Different CV strategies (many studies do not use grouped CV)
- Different sample sizes

7.2.2 Methodological Comparison

Aspect	Typical Literature	This Thesis
CV Strategy	Random split	Grouped stratified
Subject handling	Often ignored	Explicit grouping
Feature selection	Ad-hoc	Systematic ablation
Reporting	Best result only	All conditions + variance
Class imbalance	Often unaddressed	Explicit evaluation
Task specification	Mixed/unstated	Separated + compared

Table 7.6: Methodological comparison. This thesis prioritizes reproducibility and conservative generalization estimates.

Compared to typical literature practice, this thesis uses grouped stratified CV (all recordings per subject in the same fold), reports all experimental conditions with mean $\pm$ std, and documents negative results. As justified in Section 4.5.1, 5-fold CV without a separate held-out set is appropriate here: with $n = 37$ subjects, a 20% hold-out would yield approximately seven test subjects per fold—too few for stable metric estimation.

7.3 Feature Importance Analysis

7.3.1 Most Discriminative Features (Dataset A)

Feature importance patterns differed between tasks, reflecting distinct acoustic signatures:

Rank	ReadText	Importance	Spontaneous Dialogue
1	f0_max	0.052	mfcc_5_mean
2	delta_mfcc_2_mean	0.039	shimmer_apq11
3	f3_std	0.038	delta_mfcc_8_mean
4	autocorr_harmonicity	0.038	jitter_local
5	intensity_mean	0.035	delta_mfcc_2_mean

Table 7.7: Top 5 Random Forest features by task (Extended feature set). Importance values represent mean decrease in impurity.

Task-Specific Patterns:

- **ReadText:** Dominated by pitch (f0_max) and formant variability (f3_std), suggesting structured speech emphasizes fundamental frequency rigidity

- **Spontaneous:** Spectral features (mfcc_5) and perturbation measures (shimmer_apq11, jitter_local) indicate importance of voice quality instability
- **Common:** delta_mfcc_2_mean appears in both top-5 lists, confirming temporal dynamics are universally important

7.3.2 Dataset B Feature Complexity

Feature	Importance	Category
std_delta_log_energy	0.0133	Energy dynamics
std_delta_delta_log_energy	0.0132	Energy acceleration
tqwt_entropy_shannon_dec_12	0.0117	Wavelet entropy
tqwt_TKEO_std_dec_11	0.0098	Teager energy
tqwt_TKEO_mean_dec_12	0.0096	Teager energy

Table 7.8: Top 5 Dataset B features (Random Forest). These advanced signal processing metrics are not available in typical clinical settings.

Dataset B’s top features rely on specialised signal processing (wavelet decomposition, Teager energy operators) unavailable in typical clinical settings; full feature rankings are provided in Appendix [A](#).

7.4 Task-Dependent Performance Patterns

7.4.1 ReadText vs Spontaneous Dialogue

The two speech tasks yielded systematically different classification profiles:

Configuration	ReadText	Spontaneous	Advantage
Baseline Features:			
Random Forest ROC-AUC	0.590 ± 0.302	0.828 ± 0.148	Spontaneous
Logistic Regression	0.717 ± 0.139	0.760 ± 0.214	Spontaneous
Extended Features:			
Random Forest ROC-AUC	0.822 ± 0.166	0.857 ± 0.171	Spontaneous
SVM (RBF)	0.834 ± 0.153	0.460 ± 0.294	ReadText

Table 7.9: Task comparison across configurations. Spontaneous Dialogue generally outperforms ReadText, except for SVM on extended features.

Interpretation:

1. **Spontaneous speech dominance:** Unscripted speech may amplify PD-related prosodic deficits (monotone, reduced variability)
2. **Cognitive load hypothesis:** Spontaneous Dialogue requires simultaneous language generation and articulation, stressing motor control
3. **SVM anomaly:** SVM's failure on Spontaneous/Extended (0.460 ± 0.294) suggests kernel sensitivity to feature distribution shifts
4. **Baseline sufficiency:** Spontaneous Dialogue achieved 0.828 with baseline features, while ReadText required extension to reach 0.822

Clinical Implications:

For resource-constrained screening applications:

- **Spontaneous speech + baseline features** (47 dimensions) achieves competitive performance (0.83) with lower computational cost
- ReadText requires extended feature engineering for acceptable discrimination

Κεφάλαιο 8

Limitations and Threats to Validity

8.1 Sample Size Limitations

8.1.1 Dataset A: Small Subject Pool

Metric	Value
Total subjects (ReadText)	37
Total subjects (SpontaneousDialogue)	36
Subjects per test fold	~7–8
PD subjects (minority)	15–16
HC subjects (majority)	21

Table 8.1: Dataset A sample size metrics

Implications:

- High variance in fold-level metrics (std > 0.15 common)
- Limited statistical power for detecting small effects
- Results may not generalize to broader populations

8.2 Subject Identifier Limitations

8.2.1 Dataset B: Missing Subject IDs

Dataset B contains 756 samples (192 HC, 564 PD) with no subject identifiers. This creates potential for:

- **Subject leakage:** Same subject's multiple samples in train and test sets
- **Optimistic bias:** Inflated performance estimates due to within-subject correlation
- **Unknown generalization:** Cannot assess new-subject performance
- **Severe class imbalance:** HC:PD ratio of 1:2.94 (compared to 1.3:1 in Dataset A)

Caveat: Results on Dataset B may be optimistic due to unknown subject overlap across folds. The absence of subject identifiers prevents validation of true out-of-subject generalization. The severe class imbalance (74.6% PD) further complicates interpretation.

8.2.2 Comparison Limitations

Direct cross-dataset comparison is confounded by differing CV strategies, sample sizes, speech tasks, feature pipelines, and class imbalance ratios; see Caveat [8.2.1](#).

8.3 Feature Extraction Limitations

8.3.1 Deterministic Feature Set

The feature set was designed a priori based on literature review, not data-driven optimization. Limitations include:

- **Potentially suboptimal features:** Other features may be more discriminative
- **Fixed parameters:** F0 range 75–500 Hz, MFCC $n_{\text{coeffs}}=13$, $n_{\text{fft}}=2048$, $\text{hop_length}=512$
- **No feature selection:** All 47 (baseline) or 78 (extended) features used without reduction
- **No feature engineering:** No interaction terms, polynomial features, or domain-specific transformations

8.3.2 Audio Quality Assumptions

Feature extraction assumes:

- Reasonable signal-to-noise ratio
- Consistent recording conditions (Dataset A: clinical examination room, ~ 500 ms reverberation)

- No severe clipping or distortion
- Mono audio at 22050 Hz (Dataset A downsampled from 44100 Hz)

Dataset B's recording conditions are unknown.

8.4 Model Limitations

8.4.1 No Hyperparameter Tuning

All models used sklearn default hyperparameters with only random seed and class weighting as controlled variables:

Model	Fixed Parameters
Logistic Regression	$C = 1.0$, max_iter= 1000, solver='lbfgs'
SVM (RBF)	$C = 1.0$, gamma='scale' (auto-computed)
Random Forest	n_estimators= 100, max_depth=None (unlimited)

Table 8.2: Fixed hyperparameters (all experiments)

Implications:

- Performance may be suboptimal compared to tuned baselines
- Results represent out-of-the-box sklearn performance
- Hyperparameter tuning might change relative model rankings
- Class weighting explored separately (USE_CLASS_WEIGHT_BALANCED flag)

Rationale: Nested CV on 37 subjects would lead to extreme variance (inner folds $\sim 5-6$ subjects); fixed parameters ensure reproducibility and fair model comparison.

8.5 Methodological Limitations

8.5.1 No External Validation

All results use internal cross-validation (5-fold) without external test sets. Limitations:

- No held-out test set from different data source or collection protocol
- No multi-site validation (Dataset A: single hospital; Dataset B: single institution)
- Generalization to clinical settings with different recording devices unknown

- Temporal stability not assessed (all recordings from single time point per subject)
- Cross-language and cross-dialect generalization not evaluated

Rationale: See Section [4.5.1](#).

8.5.2 Class Imbalance Handling

Class imbalance was present in both datasets:

- Dataset A: HC:PD ratio 1.31:1 (ReadText) and 1.40:1 (SpontaneousDialogue)
- Dataset B: HC:PD ratio 1:2.94 (severe imbalance)

The `USE_CLASS_WEIGHT_BALANCED` flag was explored as a mitigation strategy, but:

- Did not systematically improve performance across all metrics
- May have increased variance in some conditions
- Optimal weighting strategy may vary by model and dataset

Alternative approaches not explored: SMOTE, undersampling, cost-sensitive learning, or threshold adjustment.

8.6 Threats to Validity

8.6.1 Internal Validity

Threat	Status	Mitigation
Subject leakage	Controlled (Dataset A)	GroupedStratifiedKFold
Subject leakage	Uncontrolled (Dataset B)	No subject IDs available
Label noise	Unknown	Assumed correct
Feature extraction bugs	Mitigated	Unit tests + manual verification
Random seed dependence	Controlled	RANDOM_SEED=42 (fixed)
Data preprocessing errors	Mitigated	Standardized audio normalization

Table 8.3: Internal validity threats

8.6.2 External Validity

Threat	Status	Mitigation
Population bias	Likely	Document dataset demographics
Recording variability	Present	Standardized extraction
Temporal stability	Unknown	Single recording session

Table 8.4: External validity threats

Κεφάλαιο 9

Conclusion

9.1 Summary of Work

This thesis investigated voice-based classification of Parkinson’s Disease (PD) versus healthy controls (HC) using classical machine learning approaches. The work addressed key methodological challenges in the field, including subject-level data leakage, class imbalance, and feature representation.

9.1.1 Contributions

1. **Rigorous Evaluation Framework:** Grouped stratified cross-validation with a systematic 2×2 factorial design (features $\times$ class weighting) and transparent reporting across all conditions.
2. **Feature Engineering Investigation:** Extended the feature set from 47 to 78 acoustic features, demonstrating up to +23pp ROC-AUC improvement and identifying F_0 , MFCCs, and harmonicity as most discriminative.
3. **Class Weighting Analysis:** Evaluated `class_weight="balanced"` across all models, finding modest and inconsistent effects on moderately imbalanced data.
4. **Reproducible Pipeline:** CLI tools, fixed random seeds, documented parameters, and a non-diagnostic research demonstration interface (Appendix C).

9.2 Key Findings

9.2.1 Primary Results

Finding	Evidence
Best ROC-AUC (Dataset A): 0.857 ± 0.171	Random Forest, Extended Features, SpontaneousDialogue
Feature extension improves RF	ReadText: +23.3pp ROC-AUC; Spontaneous: +2.9pp ROC-AUC
Random Forest shows robustness	Highest or competitive ROC-AUC across tasks
Grouped CV is essential	Prevents optimistic bias from subject leakage
High variance observed	Standard deviations 0.13–0.43 across metrics

Table 9.1: Primary research findings (Dataset A, baseline class weighting)

Best performance is summarised in Table 9.1; full per-model importance rankings are in Appendix A.

9.3 Research Questions Answered

9.3.1 RQ1: How do classical ML models perform on PD voice classification?

Classical ML achieves **ROC-AUC up to 0.857 ± 0.171** (Random Forest, extended features, SpontaneousDialogue) on Dataset A with grouped cross-validation. However, performance varies substantially:

- ReadText: 0.590–0.834 ROC-AUC (baseline features, across models)
- SpontaneousDialogue: 0.407–0.857 ROC-AUC (baseline → extended, RF)
- High variance due to small sample size (n=37 subjects)
- Some SVM folds produced ROC-AUC < 0.5 , indicating instability

This demonstrates the **feasibility** of voice-based PD classification, but highlights the **challenge** of robust performance on small datasets.

9.3.2 RQ2: Does feature set extension improve classification performance?

Task-dependent. Extending from 47 baseline to 78 extended features:

ReadText (Random Forest):

- Baseline: 0.590 ± 0.302 ROC-AUC
- Extended: 0.822 ± 0.166 ROC-AUC
- Improvement: +23.3 percentage points (+39% relative)
- Variance reduced from 0.302 to 0.166

SpontaneousDialogue (Random Forest):

- Baseline: 0.828 ± 0.148 ROC-AUC
- Extended: 0.857 ± 0.171 ROC-AUC
- Improvement: +2.9 percentage points (modest)

The additional features capturing spectral variability (MFCC std), temporal dynamics (delta-delta MFCC), and spectral shape contributed most significantly to ReadText performance. Effects were less pronounced for SpontaneousDialogue, possibly due to higher baseline variability in spontaneous speech.

9.3.3 RQ3: Does class weighting improve performance on imbalanced datasets?

Minimal effects observed. On Dataset A (HC:PD ratio 1.31:1 for ReadText, 1.40:1 for SpontaneousDialogue), class weighting showed inconsistent effects:

ReadText (Random Forest, extended features):

- Unweighted: 0.822 ± 0.166 ROC-AUC
- Weighted: 0.805 ± 0.182 ROC-AUC
- Change: -1.7pp (slight decrease)

SpontaneousDialogue (Random Forest, baseline features):

- Unweighted: 0.828 ± 0.148 ROC-AUC
- Weighted: 0.827 ± 0.133 ROC-AUC
- Change: -0.1pp (negligible)

The moderate imbalance (1.3:1) may not be severe enough to benefit from weighting. Additionally, with only 37 subjects, class weighting may introduce additional variance. Effects varied across models and feature sets, with no consistent pattern of improvement.

9.3.4 RQ4: How do results compare between grouped and standard CV?

Dataset A (Grouped CV, n=37 subjects):

- Random Forest: 0.590–0.857 ROC-AUC
- High variance (std 0.15–0.30)
- Subject-level generalization

Dataset B (Standard CV, n=756 samples, subject IDs unknown):

- Random Forest: 0.940–0.949 ROC-AUC (baseline/weighted)
- Low variance (std 0.012–0.013)
- Unknown within-subject correlation

Dataset B shows substantially higher performance (+8–12pp ROC-AUC) and lower variance, consistent with potential optimistic bias from subject leakage. **Grouped CV provides more conservative but more realistic estimates** of out-of-subject generalization. The comparison is confounded by different sample sizes, feature spaces, and speech tasks, limiting direct interpretation.

9.3.5 RQ5: Do speech tasks yield different classification performance?

Baseline features show task differences:

- ReadText: 0.590 ± 0.302 ROC-AUC (Random Forest, baseline)
- SpontaneousDialogue: 0.828 ± 0.148 ROC-AUC (Random Forest, baseline)
- Difference: +23.8pp in favor of spontaneous speech

Extended features reduce gap:

- ReadText: 0.822 ± 0.166 (extended)
- SpontaneousDialogue: 0.857 ± 0.171 (extended)
- Difference: +3.5pp (converged)

SpontaneousDialogue may capture naturalistic PD speech characteristics (monotone prosody, reduced variability) more effectively than structured reading. However, ReadText benefits more from feature extension, possibly because extended features capture structured speech dynamics better.

9.4 Implications

9.4.1 For Researchers

- Use **grouped CV** when multiple recordings per subject exist
- **Include variability features** (std, delta-delta) in feature sets
- **Report all conditions** rather than cherry-picking best results
- **Acknowledge limitations** transparently

9.4.2 For Practitioners

- Voice-based PD screening is feasible but not yet clinical-grade
- Random Forest provides a robust baseline for similar tasks
- Feature interpretability supports clinical understanding
- Results require validation on independent cohorts

9.4.3 For Dataset Creators

- **Always include subject identifiers** to enable proper CV
- Document recording conditions and equipment
- Provide demographic information
- Consider longitudinal designs

9.5 Future Directions

Short-term extensions include hyperparameter optimisation with nested cross-validation, feature selection to reduce dimensionality, multi-task fusion (ReadText and SpontaneousDialogue combined), and additional acoustic features (wavelets, TQWT). Medium-term research should prioritise external validation on independent cohorts, longitudinal tracking of disease progression, and multi-class severity classification. Long-term, voice-based PD monitoring could integrate into smartphone applications alongside multi-modal biomarkers (voice, gait, tremor) and undergo prospective clinical validation.

9.6 Closing Remarks

This thesis demonstrates that **voice-based Parkinson’s Disease classification is feasible** using classical machine learning with carefully engineered acoustic features, achieving ROC-AUC up to 0.857 on Dataset A with grouped cross-validation. By prioritising **methodological validity over performance optimisation**—transparent subject-level splits, fixed parameters, and full variance reporting—this work provides a replicable foundation on which future studies can address the identified limitations of small sample size, absence of external validation, and binary task scope.

Παράρτημα Α

Feature Importance Tables

A.1 Overview

This appendix presents the top-20 most important features for each experimental condition, as determined by model-native importance measures:

- **Logistic Regression:** Absolute coefficient values
- **Random Forest:** Gini importance (mean decrease in impurity)

A.2 Dataset A — ReadText Task

A.2.1 Random Forest — Top 20 Features

Rank	Feature	Importance	Std
1	f0_max	0.052	0.019
2	delta_mfcc_2_mean	0.039	0.018
3	f3_std	0.038	0.011
4	autocorr_harmonicity	0.038	0.017
5	intensity_mean	0.035	0.021
6	f0_mean	0.032	0.012
7	shimmer_apq3	0.032	0.013
8	mfcc_12_mean	0.031	0.007
9	f1_std	0.031	0.022
10	mfcc_6_mean	0.030	0.024

Table A.1: Random Forest feature importance — ReadText (top 10)

A.2.2 Logistic Regression — Top 20 Features

Rank	Feature	Coefficient	Std
1	f0_max	0.754	0.203
2	hnr_mean	0.649	0.178
3	shimmer_apq11	0.553	0.145
4	delta_mfcc_4_mean	0.496	0.163
5	delta_mfcc_2_mean	0.492	0.103
6	delta_mfcc_1_mean	0.474	0.273
7	mfcc_5_mean	0.470	0.127
8	mfcc_4_mean	0.426	0.233
9	mfcc_10_mean	0.418	0.221
10	mfcc_11_mean	0.388	0.192

Table A.2: Logistic Regression feature importance — ReadText (top 10)




Figure A.1: Logistic Regression coefficient magnitudes (ReadText)

A.2.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.229	0.179
2	mfcc_4_mean	0.084	0.187
3	f1_std	0.080	0.178
4	mfcc_6_mean	0.066	0.143
5	intensity_min	0.064	0.122
6	mfcc_2_mean	0.060	0.133
7	f0_std	0.055	0.081
8	f3_std	0.054	0.070
9	delta_mfcc_10_mean	0.047	0.104
10	delta_mfcc_2_mean	0.041	0.083

Table A.3: Gradient Boosting feature importance — ReadText (top 10)




Figure A.2: Gradient Boosting feature importances (ReadText). F0 max dominates strongly (0.229 ± 0.179), consistent with pitch dysregulation in PD.

A.2.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.083	0.028
2	intensity_min	0.064	0.063
3	f0_mean	0.063	0.044
4	f3_std	0.061	0.044
5	intensity_mean	0.051	0.047
6	delta_mfcc_10_mean	0.041	0.037
7	f1_std	0.041	0.075
8	delta_mfcc_2_mean	0.038	0.028
9	mfcc_3_mean	0.033	0.023
10	mfcc_11_mean	0.031	0.040

Table A.4: XGBoost feature importance — ReadText (top 10)




Figure A.3: XGBoost feature importances (ReadText). Importance is more distributed than Gradient Boosting, with F0 and intensity features sharing dominance.

A.3 Dataset A — SpontaneousDialogue Task

A.3.1 Random Forest — Top 20 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.080	0.022
2	shimmer_apq11	0.069	0.007
3	delta_mfcc_8_mean	0.051	0.015
4	jitter_local	0.041	0.012
5	delta_mfcc_2_mean	0.040	0.018
6	autocorr_harmonicity	0.037	0.011
7	shimmer_local	0.036	0.017
8	mfcc_1_mean	0.034	0.010
9	f0_std	0.032	0.022
10	f0_mean	0.031	0.013

Table A.5: Random Forest feature importance — SpontaneousDialogue (top 10)

A.3.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	mfcc_5_mean	0.722	0.039
2	delta_mfcc_8_mean	0.615	0.121
3	shimmer_apq11	0.559	0.136
4	delta_mfcc_2_mean	0.493	0.196
5	intensity_min	0.459	0.170
6	mfcc_3_mean	0.388	0.271
7	delta_mfcc_11_mean	0.381	0.102
8	delta_mfcc_7_mean	0.380	0.150
9	hnr_mean	0.379	0.175
10	delta_mfcc_1_mean	0.352	0.123

Table A.6: Logistic Regression feature importance — SpontaneousDialogue (top 10)




Figure A.4: Logistic Regression coefficient magnitudes (Spontaneous Dialogue)

A.3.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.342	0.204
2	shimmer_apq11	0.134	0.132
3	delta_mfcc_8_mean	0.086	0.192
4	intensity_min	0.050	0.093
5	shimmer_local	0.050	0.089
6	f1_std	0.040	0.033
7	mfcc_11_mean	0.040	0.089
8	mfcc_10_mean	0.027	0.020
9	mfcc_1_mean	0.024	0.026
10	intensity_max	0.024	0.037

Table A.7: Gradient Boosting feature importance — SpontaneousDialogue (top 10)




Figure A.5: Gradient Boosting feature importances (Spontaneous Dialogue). MFCC-5 (0.342 ± 0.204) strongly dominates, reflecting spectral tilt changes in spontaneous PD speech.

A.3.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.134	0.059
2	shimmer_apq11	0.104	0.071
3	delta_mfcc_8_mean	0.079	0.052
4	delta_mfcc_2_mean	0.053	0.009
5	mfcc_4_mean	0.035	0.022
6	mfcc_2_mean	0.033	0.022
7	jitter_local	0.032	0.012
8	f0_mean	0.031	0.035
9	shimmer_local	0.031	0.054
10	intensity_max	0.030	0.030

Table A.8: XGBoost feature importance — SpontaneousDialogue (top 10)




Figure A.6: XGBoost feature importances (Spontaneous Dialogue). MFCC-5 and shimmer features dominate, consistent with RF and GB findings for this task.

A.4 Dataset B — PD Speech Features

Dataset B contains 752 pre-extracted features including TQWT (Tunable Q-factor Wavelet Transform) coefficients not present in Dataset A. Feature importance is reported for comparison, though direct comparison is limited by different feature spaces.

A.4.1 Random Forest — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_log_energy	0.013	0.004
2	std_delta_delta_log_energy	0.013	0.003
3	tqwt_entropy_shannon_dec_12	0.012	0.001
4	tqwt_TKEO_std_dec_11	0.010	0.004
5	tqwt_TKEO_mean_dec_12	0.010	0.001
6	mean_MFCC_2nd_coef	0.008	0.003
7	tqwt_entropy_log_dec_11	0.008	0.003
8	tqwt_stdValue_dec_12	0.008	0.003
9	tqwt_stdValue_dec_13	0.008	0.003
10	tqwt_energy_dec_12	0.007	0.003

Table A.9: Random Forest feature importance — Dataset B (top 10)

Note: Importance values are lower than Dataset A due to the larger feature space (752 vs 47 features), distributing importance more broadly.

A.4.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	tqwt_kurtosisValue_dec_33	0.733	0.161
2	tqwt_entropy_log_dec_33	0.694	0.084
3	mean_MFCC_7th_coef	0.614	0.148
4	std_delta_delta_log_energy	0.588	0.133
5	std_MFCC_2nd_coef	0.567	0.202
6	tqwt_meanValue_dec_16	0.551	0.114
7	tqwt_medianValue_dec_25	0.540	0.209
8	mean_MFCC_3rd_coef	0.538	0.155
9	tqwt_meanValue_dec_22	0.528	0.172
10	std_9th_delta	0.526	0.103

Table A.10: Logistic Regression feature importance — Dataset B (top 10)

Observation: TQWT features dominate Dataset B importance, reflecting the sustained vowel /a/ phonation task where time-frequency decomposition captures subtle vocal tremor patterns.




Figure A.7: Feature importance for Dataset B (PD Speech Features) — Random Forest and Logistic Regression.

A.4.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_delta_log_energy	0.133	0.035
2	tqwt_TKEO_mean_dec_12	0.030	0.036
3	tqwt_entropy_log_dec_27	0.029	0.008
4	std_7th_delta_delta	0.028	0.005
5	tqwt_energy_dec_27	0.024	0.028
6	tqwt_entropy_log_dec_35	0.023	0.019
7	tqwt_TKEO_std_dec_12	0.023	0.026
8	mean_MFCC_2nd_coef	0.021	0.024
9	tqwt_entropy_log_dec_33	0.021	0.006
10	tqwt_TKEO_std_dec_11	0.020	0.021

Table A.11: Gradient Boosting feature importance — Dataset B (top 10)

A.4.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	tqwt_entropy_log_dec_12	0.024	0.020
2	std_delta_delta_log_energy	0.017	0.006
3	tqwt_TKEO_mean_dec_12	0.016	0.017
4	tqwt_TKEO_std_dec_12	0.013	0.014
5	tqwt_energy_dec_27	0.012	0.024
6	tqwt_TKEO_std_dec_11	0.012	0.010
7	tqwt_entropy_log_dec_16	0.010	0.009
8	tqwt_entropy_log_dec_13	0.009	0.012
9	mean_MFCC_2nd_coef	0.008	0.004
10	tqwt_entropy_shannon_dec_16	0.008	0.011

Table A.12: XGBoost feature importance — Dataset B (top 10)




Figure A.8: Feature importance for Dataset B — Gradient Boosting and XGBoost. TQWT energy/entropy features from high-frequency bands dominate across both models.

A.5 Cross-Task Feature Stability

Features that appear in top-10 for both tasks (Random Forest) indicate robust discriminative power across different speech contexts:

Feature	ReadText Rank	Spontaneous Rank
delta_mfcc_2_mean	2	5
autocorr_harmonicity	4	6
f0_mean	6	10
shimmer (apq3/apq11)	7	2
mfcc_5_mean	–	1
f0_std	–	9

Table A.13: Cross-task feature stability (Random Forest top-10)

Interpretation: Features consistently important across tasks (delta_mfcc_2_mean, autocorr_harmonicity, shimmer) likely capture **task-general** acoustic signatures of PD rather than task-specific artifacts. The prominence of mfcc_5_mean in SpontaneousDialogue but not ReadText may reflect prosodic variability differences between structured reading and natural conversation.

A.6 Feature Category Analysis

Aggregating importance by feature category:

Category	Features	ReadText (%)	Spontaneous (%)
MFCC	13	28.4	32.1
Delta MFCC	13	22.7	25.3
Pitch (F_0)	4	15.2	12.8
Shimmer	5	11.3	14.6
Formants	6	9.8	7.2
Harmonicity	2	6.1	4.3
Other	5	6.5	3.7

Table A.14: Aggregated feature importance by category




Figure A.9: Feature importance aggregated by broad acoustic categories.

Παράρτημα Β

Detailed Results Tables

B.1 Overview

This appendix provides complete numerical results for all experimental conditions, including summary statistics and cross-condition comparisons.

B.2 Condition 1: Baseline Features (47) + Unweighted

B.2.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.621 ± 0.058	0.620 ± 0.217	0.550 ± 0.201	0.542 ± 0.099	0.717 ± 0.139
	SVM	0.621 ± 0.106	0.367 ± 0.342	0.317 ± 0.335	0.333 ± 0.333	0.614 ± 0.312
	RF	0.629 ± 0.178	0.450 ± 0.447	0.333 ± 0.408	0.351 ± 0.363	0.590 ± 0.302
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.636 ± 0.135	0.600 ± 0.435	0.333 ± 0.236	0.400 ± 0.253	0.407 ± 0.309
	RF	0.721 ± 0.176	0.633 ± 0.415	0.600 ± 0.435	0.567 ± 0.365	0.828 ± 0.148

Table B.1: Condition 1 results by task (Dataset A, baseline features, unweighted)

B.2.2 Dataset B: PD Speech Features Summary

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.828 ± 0.008	0.881 ± 0.010	0.890 ± 0.016	0.885 ± 0.006	0.867 ± 0.029
SVM_RBF	0.851 ± 0.024	0.841 ± 0.015	0.986 ± 0.019	0.908 ± 0.015	0.885 ± 0.025
RandomForest	0.882 ± 0.019	0.876 ± 0.012	0.980 ± 0.015	0.925 ± 0.012	0.940 ± 0.013

Table B.2: Condition 1 results (Dataset B, baseline features, unweighted)

Note: Dataset B shows substantially higher performance and lower variance than Dataset A, consistent with potential optimistic bias from unknown subject overlap.

B.3 Condition 2: Extended Features (78) + Unweighted

B.3.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.253	0.433 ± 0.149	0.475 ± 0.106	0.698 ± 0.132
	SVM	0.786 ± 0.181	0.733 ± 0.435	0.567 ± 0.365	0.634 ± 0.386	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.822 ± 0.166
Spontaneous	LR	0.671 ± 0.199	0.500 ± 0.361	0.600 ± 0.435	0.530 ± 0.377	0.783 ± 0.139
	SVM	0.636 ± 0.089	0.533 ± 0.361	0.400 ± 0.279	0.428 ± 0.258	0.460 ± 0.294
	RF	0.779 ± 0.161	0.683 ± 0.410	0.600 ± 0.435	0.605 ± 0.387	0.857 ± 0.171

Table B.3: Condition 2 results by task (Dataset A, extended features, unweighted)

B.3.2 Improvement over Baseline (Random Forest, Dataset A)

Task	Δ Accuracy	Δ ROC-AUC	Δ Variance
ReadText	+18.9pp	+23.2pp	Reduced (0.302 $\rightarrow$ 0.166)
SpontaneousDialogue	+5.8pp	+2.9pp	Increased (0.148 $\rightarrow$ 0.171)

Table B.4: Condition 2 improvement over Condition 1 (Random Forest)

Observation: Feature extension dramatically improved ReadText performance (+23.2pp ROC-AUC) while SpontaneousDialogue showed modest gains (+2.9pp). This suggests extended features capture structured speech dynamics more effectively than spontaneous speech characteristics.

B.4 Condition 3: Baseline Features (47) + Weighted

B.4.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.235	0.550 ± 0.201	0.528 ± 0.099	0.717 ± 0.139
	SVM	0.704 ± 0.111	0.617 ± 0.371	0.500 ± 0.373	0.519 ± 0.320	0.542 ± 0.312
	RF	0.650 ± 0.148	0.550 ± 0.371	0.400 ± 0.365	0.431 ± 0.306	0.687 ± 0.258
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.693 ± 0.123	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.423 ± 0.312
	RF	0.693 ± 0.123	0.583 ± 0.373	0.600 ± 0.435	0.538 ± 0.326	0.827 ± 0.133

Table B.5: Condition 3 results by task (Dataset A, baseline features, weighted)

B.4.2 Effect of Weighting (vs Condition 1, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	+2.1pp	+9.7pp	Improved
SpontaneousDialogue	−2.8pp	−0.1pp	Negligible

Table B.6: Condition 3 effect of weighting vs Condition 1 (RF)

Observation: Class weighting improved ReadText performance but had negligible effect on SpontaneousDialogue, suggesting task-dependent sensitivity to class imbalance handling.

B.5 Condition 4: Extended Features (78) + Weighted

B.5.1 Dataset A: MDVR-KCL Summary

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.650 ± 0.108	0.650 ± 0.253	0.550 ± 0.201	0.564 ± 0.160	0.698 ± 0.132
	SVM	0.761 ± 0.214	0.700 ± 0.447	0.567 ± 0.365	0.620 ± 0.390	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.805 ± 0.182
Spontaneous	LR	0.696 ± 0.179	0.520 ± 0.356	0.667 ± 0.471	0.563 ± 0.381	0.783 ± 0.139
	SVM	0.664 ± 0.167	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.403 ± 0.347
	RF	0.721 ± 0.203	0.653 ± 0.409	0.600 ± 0.435	0.583 ± 0.373	0.823 ± 0.209

Table B.7: Condition 4 results by task (Dataset A, extended features, weighted)

B.5.2 Effect of Weighting (vs Condition 2, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	0.0pp	−1.7pp	Slight decrease
SpontaneousDialogue	−5.8pp	−3.4pp	Decreased

Table B.8: Condition 4 effect of weighting vs Condition 2 (RF)

Observation: Combining extended features with class weighting did not improve performance over extended features alone. This suggests that feature extension and class weighting address similar aspects of the classification problem, with diminishing returns when combined.

B.6 Cross-Condition Comparison Matrix

B.6.1 Random Forest ROC-AUC by Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	0.590 ± 0.302	0.822 ± 0.166
	Weighted	0.687 ± 0.258	0.805 ± 0.182
Spontaneous	Unweighted	0.828 ± 0.148	0.857 ± 0.171
	Weighted	0.827 ± 0.133	0.823 ± 0.209

Table B.9: Random Forest ROC-AUC comparison matrix (Dataset A)

B.6.2 Random Forest Accuracy by Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	$62.9\% \pm 17.8\%$	$81.8\% \pm 14.0\%$
	Weighted	$65.0\% \pm 14.8\%$	$81.8\% \pm 14.0\%$
Spontaneous	Unweighted	$72.1\% \pm 17.6\%$	$77.9\% \pm 16.1\%$
	Weighted	$69.3\% \pm 12.3\%$	$72.1\% \pm 20.3\%$

Table B.10: Random Forest Accuracy comparison matrix (Dataset A)

B.6.3 Key Observations

1. **Feature extension consistently improves ReadText:** +23.2pp ROC-AUC (unweighted)
2. **SpontaneousDialogue has higher baseline:** 0.828 vs 0.590 ROC-AUC with baseline features
3. **Class weighting shows mixed effects:** Improves ReadText baseline but decreases extended feature performance
4. **High variance throughout:** Standard deviations often exceed 0.15, reflecting small sample size (n=37)

B.7 Statistical Significance Notes

Due to high standard deviations (often > 0.15), confidence intervals overlap across many comparisons. This limits the ability to make strong statistical claims about differences between conditions. Results should be interpreted as **trends** rather than definitive rankings.

B.8 ROC Curves

Receiver Operating Characteristic (ROC) curves are shown for all five classifiers across each experimental condition. Faint lines represent individual cross-validation folds; the bold curve represents the mean across folds with a ± 1 standard deviation shaded band. All curves were generated using the extended feature set.




Figure B.1: ROC curves for all five classifiers on the ReadText task (Dataset A, extended features). Shaded bands indicate ± 1 standard deviation across the five cross-validation folds.




Figure B.2: ROC curves for all five classifiers on the SpontaneousDialogue task (Dataset A, extended features).




Figure B.3: ROC curves for all five classifiers on Dataset B (PD Speech Features). Note that subject-level deduplication is not possible for this dataset; results may be optimistic due to potential subject overlap across folds.

Παράρτημα C

Research Demonstration Application

C.1 Purpose and Scope

This appendix describes a web-based research demonstration application developed to illustrate the end-to-end inference workflow from audio upload to classification output. The application was designed solely for educational and illustrative purposes as part of this MSc thesis.


Critical Disclaimer:

- This application is **not intended for clinical use, medical diagnosis, or patient screening**
- Outputs represent model confidence scores, not clinical diagnoses
- The application was **not used for any quantitative evaluation** reported in this thesis
- All evaluation metrics (Chapters 5–6) were computed via cross-validation on held-out test folds, independent of this interface
- Results should be interpreted as **research outputs only**, requiring validation by qualified medical professionals

The application demonstrates the feasibility of integrating the trained models into a user-facing interface while maintaining clear boundaries between research exploration and clinical deployment.

C.2 System Architecture

The demonstration application follows a modular architecture separating concerns between the web interface, inference orchestration, and core machine learning pipeline:



Key Components:

- 1. **Flask Web Server (`app.py`):** Handles HTTP routes, file uploads, and template rendering. Strictly imports only the adapter module, ensuring zero coupling to internal ML implementation details.
- 2. **Inference Adapter (`inference_adapter.py`):** Provides a stable interface wrapping the core inference API. Performs audio normalization (any format → mono 22,050 Hz WAV), enriches prediction outputs with display metadata, and ensures model switching requires no Flask code changes.
- 3. **Core ML Pipeline:** Reuses the identical feature extraction and inference modules used for experiments (`parkinsons_voice_classification.inference`), ensuring consistency between evaluation and demonstration.
- 4. **Audio Processing (`audio_utils.py`):** Normalizes uploaded audio files (WAV, MP3, WebM, Opus, FLAC) to a standardized mono 22,050 Hz PCM-16 WAV format before feature extraction.

Design Invariants:

- Model switching (RandomForest ↔ Logistic Regression ↔ SVM) is controlled via configuration file only; no template/route changes required
- Feature set selection (baseline 47 vs. extended 78) is configuration-driven
- Task selection (ReadText vs. SpontaneousDialogue) loads the corresponding trained model artifact

This architecture ensures the demonstration remains aligned with the experimental pipeline while providing a controlled interface for external users.

C.3 User Interaction Flow

The application supports two input modalities:

C.3.1 Audio Upload Workflow

The screenshot displays the 'Parkinson's Voice Classification' application interface. At the top, the title 'Parkinson's Voice Classification' is centered, with the subtitle 'MSc Thesis Research Demonstration' below it. A yellow warning box contains the text: '⚠️ Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.' Below this, there are two tabs: 'Upload File' (active) and 'Record Audio'. The 'Upload File' tab shows a section titled 'Upload Voice Recording' with the instruction: 'Upload an audio file of a ReadText speech task for analysis. All common formats supported (WAV, MP3, WebM, etc.).' Underneath, it says 'Audio File (any format)' and provides a 'Choose File' button next to the text 'No file chosen'. A large blue button labeled 'Analyze Recording' is positioned below the file selection area. At the bottom, a 'Current Model Configuration' section lists the following details: Model: RandomForest, Task: ReadText, Features: baseline (47), and Training Samples: 37. A link 'About this project' is located at the very bottom of the interface.

Figure C.1: Upload interface for audio file analysis. Users select a ReadText task recording in any common format (WAV, MP3, WebM). The interface displays the current model configuration (RandomForest, baseline features, 37 training samples).

Figure C.1 shows the file upload interface, where users can select pre-recorded audio files for analysis. The interface clearly states the research-only purpose and displays the active model configuration.

C.3.2 Direct Audio Recording

The screenshot displays the 'Parkinson's Voice Classification' web application. At the top, it says 'MSc Thesis Research Demonstration'. A yellow warning box states: 'Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.' Below this are two tabs: 'Upload File' and 'Record Audio', with 'Record Audio' being the active tab. The main section is titled 'Record Voice Sample' and contains a 'ReadText Task Prompt' box with the text: 'The quick brown fox jumps over the lazy dog. Peter Piper picked a peck of pickled peppers. How much wood would a woodchuck chuck if a woodchuck could chuck wood?' and the instruction 'Read this text clearly and naturally at a comfortable pace.' Below the prompt is a red 'Recording...' indicator showing '1s'. At the bottom of this section are two buttons: 'Start Recording' (with a microphone icon) and 'Stop Recording' (with a square icon). At the very bottom, a 'Current Model Configuration' section lists: Model: RandomForest, Task: ReadText, Features: baseline (47), and Training Samples: 37.

Figure C.2: In-browser audio recording interface. Users read the displayed ReadText prompt aloud and record directly via their device microphone. The recorded audio is processed through the same normalization and feature extraction pipeline as uploaded files.

Figure C.2 demonstrates the in-browser recording capability, implemented using the Web Audio API with JavaScript. Users follow the on-screen ReadText prompt to produce a standardized speech sample. Recordings are captured at the browser's native sample rate and normalized server-side before inference.

C.3.3 Processing Steps

Regardless of input modality, the following steps execute:

1. **Audio normalization:** Convert to mono 22,050 Hz PCM-16 WAV

2. **Feature extraction:** Extract 47 acoustic features (baseline) or 78 features (extended) using the same pipeline as experiments
3. **Model inference:** Load trained model artifact (e.g., `RandomForest_ReadText_baseline.joblib`) and predict class probabilities
4. **Result display:** Render prediction, probabilities, extracted feature values, and global feature importance

C.4 Output Interpretation and Limitations

C.4.1 Displayed Information

Figure C.3 shows a representative output screen following analysis:




Figure C.3: Example output from the research demonstration interface. The prediction (“PD” with 81% confidence) is displayed prominently with an explicit disclaimer that this is not a medical diagnosis. The interface shows extracted acoustic features, analysis metadata (file name, model, task, feature count), and top global feature importances for interpretability.

The output includes:

1. **Class Prediction:** Binary label (PD or HC) with the higher probability
2. **Class Probabilities:** Model confidence scores for each class (sum to 100%)
3. **Extracted Features:** Key acoustic measurements (e.g., F_0 , jitter, MFCC coefficients) with values and descriptions
4. **Analysis Metadata:** File name, model type, task, feature count
5. **Top Feature Importances:** Global feature rankings from the trained RandomForest model (via Gini importance)

C.4.2 Critical Limitations (What the Output Does NOT Mean)

Users and evaluators must understand the following constraints:

- **Probabilities $\neq$ Diagnosis:** The 81% confidence in Figure C.3 reflects the model's uncertainty estimate based on training data distribution. It does **not** indicate an 81% chance the individual has Parkinson's Disease.
- **Training Distribution Dependency:** Model outputs are valid only for speech samples similar to the MDVR-KCL training set (smartphone recordings, ReadText task, no severe recording artifacts). Generalization to different recording conditions, languages, or populations is unknown.
- **No Clinical Validation:** The model was trained on a small dataset ($n = 37$ subjects) and has not undergone clinical validation, regulatory approval, or external cohort testing.
- **Evaluation Exclusion:** Outputs from this interface were **not used** to compute the performance metrics reported in Chapter 6. All quantitative results derive from grouped cross-validation on independent test folds.
- **Feature Importance Caveats:** Displayed importances reflect *global* model behavior (across all training samples), not *per-sample* contributions. High importance does not imply the feature was decisive for the specific uploaded recording.

C.5 Reproducibility and Consistency

The demonstration interface ensures alignment with the experimental pipeline through:

1. **Shared Codebase:** Uses identical feature extraction modules (`features/prosodic.py`, `features/spectral.py`) as the CLI-based experiments
2. **Deterministic Inference:** Loads the same serialized model artifacts (`.joblib` files) produced during training
3. **Configuration-Driven:** All parameters (feature set, model choice, task) are controlled via `config.py`, ensuring consistency across CLI and web interfaces
4. **Fixed Random Seeds:** Although inference is deterministic (no stochastic components), the loaded models were trained with fixed random seeds (`seed = 42`) for reproducibility

This design ensures the demonstration outputs reflect the actual behavior of the evaluated models, rather than a separate reimplementation.

C.6 Summary

The research demonstration application provides a tangible illustration of the voice-based PD classification pipeline, bridging the gap between algorithmic research and potential real-world interaction. However, it must be interpreted strictly within its intended scope:

- **Educational tool** for thesis defense and research communication
- **Not a diagnostic system** and unsuitable for clinical decision-making
- **Validation artifact** confirming inference pipeline functionality
- **Not used for evaluation** — all metrics derived from cross-validation

Future work toward clinical deployment would require: (1) validation on independent cohorts ($n > 500$), (2) regulatory approval (e.g., FDA clearance, CE marking), (3) prospective clinical trials, (4) integration with clinical workflows, and (5) continuous monitoring for performance drift. This demonstration represents an early feasibility prototype, not a production-ready system.

Βιβλιογραφία

- [1] A. K. Ho, R. Iannsek, C. Marigliani, J. L. Bradshaw, and S. Gates, “Speech impairment in a large sample of patients with Parkinson’s disease,” *Behavioural Neurology*, vol. 11, no. 3, pp. 131–137, 1999.
- [2] B. T. Harel, M. S. Cannizzaro, and P. J. Snyder, “Acoustic characteristics of Parkinsonian speech: a potential biomarker of early disease progression and treatment,” *Journal of Neurolinguistics*, vol. 17, no. 6, pp. 439–453, 2004.
- [3] M. A. Little, P. E. McSharry, E. J. Hunter, J. Spielman, and L. O. Ramig, “Suitability of dysphonia measurements for telemonitoring of Parkinson’s disease,” *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 4, pp. 1015–1022, 2009.
- [4] A. Tsanas, M. A. Little, P. E. McSharry, and L. O. Ramig, “Accurate telemonitoring of Parkinson’s disease progression by noninvasive speech tests,” *IEEE Transactions on Biomedical Engineering*, vol. 57, no. 4, pp. 884–893, 2010.
- [5] J. R. Duffy, *Motor speech disorders: Substrates, differential diagnosis, and management*, 3rd ed. Elsevier Health Sciences, 2012.
- [6] H. Sedigh Malekroodi, B.-i. Lee, and M. Yi, “Voice-based detection of Parkinson’s disease using machine and deep learning approaches: A systematic review,” *Bioengineering*, vol. 12, no. 11, p. 1279, 2025.
- [7] D. Xavier, V. Felizardo, B. Ferreira, H. Zacarias, M. Pourvabab, L. Souza-Pereira, and N. M. Garcia, “Voice analysis in Parkinson’s disease—a systematic literature review,” *Artificial Intelligence in Medicine*, vol. 163, p. 103109, 2025.
- [8] H. Wright and V. Aharonson, “Vocal feature changes for monitoring Parkinson’s disease progression—a systematic review,” *Brain Sciences*, vol. 15, no. 3, p. 320, 2025.
- [9] L. O. Ramig, C. Fox, and S. Sapir, “Speech treatment for Parkinson’s disease,” *Expert Review of Neurotherapeutics*, vol. 8, no. 2, pp. 297–309, 2008.

- [10] S. Skodda, W. Visser, and U. Schlegel, “Intonation and speech rate in Parkinson’s disease: General and dynamic aspects and responsiveness to levodopa admission,” *Journal of Voice*, vol. 25, no. 4, pp. e199–e205, 2011.
- [11] J. R. Orozco-Arroyave, J. D. Arias-Londoño, J. F. V. Bonilla, M. C. Gonzalez-Rativa, and E. Nöth, “Automatic detection of Parkinson’s disease in running speech spoken in three different languages,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2016, pp. 4785–4789.
- [12] M. A. Little, P. E. McSharry, S. J. Roberts, D. A. Costello, and I. M. Moroz, “Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection,” *BioMedical Engineering OnLine*, vol. 6, no. 1, p. 23, 2007, introduced nonlinear dynamic features for voice analysis.
- [13] H. Jaeger, D. Trivedi, and M. Stadtschnitzer, “MDVR-KCL: Mobile device voice recordings at King’s College London,” 2019, collected 26–29 September 2017 at King’s College Hospital, London, UK. [Online]. Available: <https://zenodo.org/records/2867215>
- [14] D. Biswas, “Parkinson’s disease speech signal features,” 2020, originally from UCI Machine Learning Repository. [Online]. Available: <https://www.kaggle.com/datasets/dipayanbiswas/parkinsons-disease-speech-signal-features>
- [15] C. M. Bishop, *Pattern recognition and machine learning*. Springer, 2006.
- [16] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [17] N. Sáenz-Lechón, J. Godino-Llorente, V. Osma-Ruiz, and P. Gómez-Vilda, “Methodological issues in the development of automatic systems for voice pathology detection,” *Biomedical Signal Processing and Control*, vol. 1, no. 2, pp. 120–128, 2006, systematic review of methodological issues in voice pathology detection.
- [18] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [19] G. Solana-Lavalle and R. Rosas-Romero, “Analysis of voice as an assisting tool for detection of Parkinson’s disease and its subsequent clinical interpretation,” *Biomedical Signal Processing and Control*, vol. 66, p. 102415, 2021.
- [20] Y. Jadoul, B. Thompson, and B. de Boer, “Parselmouth: Praat in Python,” Software, 2018. [Online]. Available: <https://github.com/YannickJadoul/Parselmouth>

-
- [21] B. McFee, C. Raffel, D. Liang, D. P. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and music signal analysis in python,” Software, 2015. [Online]. Available: <https://librosa.org>
- [22] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [23] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.