



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Ηλεκτρολόγων Μηχανικών και
Μηχανικών Η/Υ
Συστημάτων Μετάδοσης Πληροφορίας &
Τεχνολογίας Υλικών

Voice-Based Classification of Parkinson's Disease Using Classical Machine Learning

Master's Thesis

Μάριος Χρήστος Συρμακέζης

Supervisor: Γεώργιος Ματσόπουλος
Καθηγητής ΗΜΜΥ Ε.Μ.Π.

Approved by the examination committee on [26 Φεβρουαρίου 2026].

.....		
Γεώργιος Ματσόπουλος	Ουρανία Πετροπούλου	[Examiner 2 Name]
Καθηγητής ΗΜΜΥ Ε.Μ.Π.	Επίκουρη Καθηγήτρια	[Examiner 2 Title]
	ΗΜΜΥ Ε.Μ.Π.	

Αθήνα, Φεβρουάριος 2026

Μάριος Χρήστος Συρμακέζης

Διπλωματούχος Ηλεκτρολόγος Μηχανικός και Μηχανικός Υπολογιστών Ε.Μ.Π.

Copyright © Μάριος Χρήστος Συρμακέζης, 2026.

All rights reserved.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα. Ερωτήματα που αφορούν τη χρήση της εργασίας για κερδοσκοπικό σκοπό πρέπει να απευθύνονται προς τον συγγραφέα.

Οι απόψεις και τα συμπεράσματα που περιέχονται σε αυτό το έγγραφο εκφράζουν τον συγγραφέα και δεν πρέπει να ερμηνευθεί ότι αντιπροσωπεύουν τις επίσημες θέσεις του Εθνικού Μετσόβιου Πολυτεχνείου.

Περίληψη

Η νόσος του Πάρκινσον (PD) είναι μια νευροεκφυλιστική διαταραχή που, πέρα από τα κινητικά συμπτώματα, επηρεάζει συχνά και την ομιλία. Η εργασία αυτή εξετάζει αν μπορούμε να εντοπίσουμε τη νόσο μέσω της φωνής, χρησιμοποιώντας κλασικές μεθόδους μηχανικής μάθησης.

Για τον σκοπό αυτό χρησιμοποιήθηκαν δύο διαφορετικά σύνολα δεδομένων ομιλίας, με την ίδια διαδικασία ανάλυσης και αξιολόγησης και στα δύο.

Το πρώτο σύνολο δεδομένων, Mobile Device Voice Recordings at King's College London, περιλάμβανε κατηγοριοποιημένα αρχεία ήχου (WAV) που είχαν καταγραφεί με ειδικό εξοπλισμό. Οι ηχογραφήσεις ήταν ακατέργαστες, γι' αυτό προχωρήσαμε στην εξαγωγή ακουστικών χαρακτηριστικών για να μετατρέψουμε τα δεδομένα σε μια αριθμητική μορφή που είναι κατάλληλη για ανάλυση.

Το δεύτερο σύνολο δεδομένων, με τίτλο PD speech signal features από το Kaggle (UCI), περιλάμβανε ακουστικά χαρακτηριστικά που είχαν ήδη εξαχθεί σε μορφή csv. Σε αυτή την περίπτωση, δεν χρειάστηκε να γίνει επεξεργασία ήχου αφού τα αριθμητικά χαρακτηριστικά ήταν ήδη διαθέσιμα. Και στα δύο σύνολα δεδομένων, ο σκοπός ήταν να διαπιστωθεί αν τα μοντέλα μπορούν να αναγνωρίσουν άτομα με Πάρκινσον μόνο από τη φωνή τους.

Αξιολογήθηκαν πέντε αλγόριθμοι: Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting και XGBoost. Επιπλέον, εξετάστηκε αν η αύξηση του αριθμού των χαρακτηριστικών βελτιώνει την απόδοση, καθώς και αν η χρήση βαρών κλάσης (class weighting) βοηθά στην εξισορρόπηση των ομάδων PD και HC.

Χρησιμοποιήθηκε επίσης διασταυρωμένη επικύρωση (cross-validation), ώστε να μην υπάρχει διαρροή δεδομένων.

Τα αποτελέσματα έδειξαν ότι ο Random Forest ήταν ο πιο αποτελεσματικός. Η αύξηση των χαρακτηριστικών βελτίωσε σημαντικά την απόδοση των περισσότερων μοντέλων. Η χρήση βαρών είχε μικρή θετική επίδραση κυρίως στον Random Forest και μικρή ή

αρνητική στους υπόλοιπους.

Συνολικά, η εργασία δείχνει ότι η ανάλυση φωνής σε συνδυασμό με μηχανική μάθηση μπορεί να βοηθήσει στην αναγνώριση της νόσου του Πάρκινσον. Ωστόσο, τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή, λόγω ορισμένων περιορισμών, όπως πιθανές πολλαπλές ηχογραφήσεις του ίδιου ασθενούς και η διαφορά μεγέθους μεταξύ των δύο datasets.

Παρά τους περιορισμούς, τα ευρήματα δείχνουν ότι η σωστή επεξεργασία δεδομένων και η κατάλληλη χρήση αλγορίθμων μπορούν να οδηγήσουν μελλοντικά σε πιθανή αναγνώριση της νόσου μέσω της φωνής, ακόμα και με απλά καθημερινά μικρόφωνα. Αυτό είναι σημαντικό, γιατί η έγκαιρη ανίχνευση θα μπορούσε να συμβάλει σε νωρίτερη θεραπεία και καλύτερη ποιότητα ζωής για τους ασθενείς.

Λέξεις Κλειδιά: Νόσος του Πάρκινσον, Δυσαρθρία, Φωνητικοί Βιοδείκτες, Ακουστικά Χαρακτηριστικά, Μηχανική Μάθηση, Εξαγωγή Χαρακτηριστικών, Διασταυρούμενη Επικύρωση, Μη Ισορροπημένα Δεδομένα, Αναπαραγωγιμότητα, Ταξινόμηση Ομιλίας, Υπολογιστική Νοημοσύνη στην Υγεία

Abstract

Parkinson's disease (PD) is a progressive neurological disorder characterized by motor symptoms which are typically accompanied by speech difficulties.

In this paper we assess if Parkinson's disease can be diagnosed through the voice based on classical machine learning approaches.

We worked with two different datasets, each analyzed using an identical methodology, i.e., analysis and validation procedure.

The first dataset, Mobile Device Voice Recordings at King's College London, contained categorized audio files (WAV) recorded with advanced recording equipment in a controlled environment.

These recordings were unprocessed, therefore we had to process the audio to extract the acoustic features to transform the data into a numeric format that would allow us to perform the analysis.

The second dataset, PD speech signal features from Kaggle (UCI), contained pre-extracted acoustic features in csv format.

Therefore, we did not need to process the audio since the pre-processed features were ready to be analyzed.

Both datasets were processed to see if the models could distinguish between individuals with PD and healthy controls (HC) only through their voice.

We compared five machine learning algorithms, i.e., Logistic Regression, Support Vector Machine (SVM), Random Forest, Gradient Boosting, and XGBoost.

Furthermore, we investigated whether increasing the number of features in the training set enhances the model performance, and whether the application of class weighting enhances the model performance particularly for the PD group.

To avoid data leakage, cross-validation was performed.

The results indicate that Random Forest algorithm outperformed all other tested algorithms.

An increase of the number of features in the training set positively affected the majority of the tested models.

Class weighting had a limited positive impact especially on Random Forest, while the other algorithms either did not benefit from class weighting or were even negatively affected.

In general, the study demonstrates that voice-based analysis combined with machine learning may support the diagnosis of Parkinson's disease.

Nevertheless, the results have to be viewed critically due to some limitations, e.g., potential multiple recordings of the same patient and the significant differences in terms of sample sizes between the two datasets.

Regardless of these limitations, the study shows that adequate processing of the data, along with the appropriate application of machine learning algorithms can result in a potential disease identification through voice, using regular microphones, available in everyday devices like smartphones.

Early detection may lead to the initiation of therapy at an earlier time point and improve the quality of life of patients.

Keywords: Parkinson's Disease; Dysarthria; Voice Biomarkers; Acoustic Features; Machine Learning; Feature Extraction; Cross-Validation; Imbalanced Data; Reproducibility; Speech Classification; Computational Health Intelligence

Πίνακας Περιεχομένων

Περίληψη	7
Abstract	10
Κατάλογος Σχημάτων	20
Κατάλογος Πινάκων	22
1 Εισαγωγή	23
1.1 Ιστορικό και κίνητρα	23
1.2 Διατύπωση προβλήματος	23
1.3 Στόχοι της εργασίας	24
1.4 Κύριες συνεισφορές	24
1.5 Οργάνωση της εργασίας	24
1.6 Όρια πεδίου εφαρμογής	25
2 Βιβλιογραφική ανασκόπηση	26
2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας	26
2.2 Ανίχνευση έναντι παρακολούθησης	26
2.3 Ταξινόμηση ακουστικών χαρακτηριστικών	27
2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας	27
2.4 Σύνολα δεδομένων στην έρευνα φωνής PD	28
2.4.1 Ακατέργαστα σύνολα ήχου	28
2.4.2 Προ-εξαγόμενα σύνολα χαρακτηριστικών	28
2.4.3 Κλίμακα και αντιπροσωπευτικότητα	28
2.4.4 Ετερογένεια επικύρωσης	28
2.4.5 Ο ρόλος των εργασιών ομιλίας	28
2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης	29
2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις	29

2.6	Μεθοδολογικά ζητήματα στη βιβλιογραφία	29
2.6.1	Διαρροή δεδομένων	29
2.6.2	Ανισορροπία κλάσεων	29
2.6.3	Αναπαραγωγιμότητα	30
2.6.4	Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων	30
2.6.5	Ερμηνευσιμότητα	30
2.7	Έλλειμμα στην έρευνα	30
2.8	Περίληψη	30
3	Περιγραφή δεδομένων	32
3.1	Επισκόπηση	32
3.2	Σύνολο δεδομένων A: MDVR-KCL	32
3.3	Σύνολο δεδομένων B: PD Speech Features	33
3.4	Συγκριτική αποτίμηση των δύο συνόλων	33
4	Μεθοδολογία	34
4.1	Διαδικασία εξαγωγής χαρακτηριστικών	34
4.1.1	Αρχιτεκτονική διαδικασίας	34
4.1.2	Προεπεξεργασία ήχου	34
4.1.3	Προσωδιακά χαρακτηριστικά (21 χαρακτηριστικά)	35
4.1.4	Φασματικά χαρακτηριστικά	37
4.1.5	Συνολικός αριθμός χαρακτηριστικών	39
4.2	Σύγκριση συνόλου χαρακτηριστικών	40
4.2.1	Λόγοι για τα εκτεταμένα χαρακτηριστικά	40
4.2.2	Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών	40
4.3	Μοντέλα μηχανικής μάθησης	41
4.3.1	Προδιαγραφές μοντέλου	41
4.3.2	Στάθμιση βαρύτητας κλάσης	43
4.4	Αρχιτεκτονική ML Pipeline	44
4.4.1	Δομή Pipeline	44
4.4.2	Τυποποίηση χαρακτηριστικών	44
4.5	Πλαίσιο αξιολόγησης	44
4.5.1	Στρατηγική Cross-Validation	44
4.5.2	Μετρήσεις αξιολόγησης	45
5	Σχεδιασμός πειράματος	47
5.1	Ερευνητικά ερωτήματα	47
5.2	Πειραματικός πίνακας	47

5.2.1	$2 \times 2 \times 5$ Παραγοντικός σχεδιασμός	47
5.2.2	Συνολικές πειραματικές εκτελέσεις	48
5.3	Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα	48
6	Αποτελέσματα	49
6.1	Σύνοψη κύριων αποτελεσμάτων	49
6.2	Επίδραση χαρακτηριστικών και στάθμισης κλάσεων (Dataset A)	50
6.2.1	Σύγκριση baseline έναντι extended χαρακτηριστικών	50
6.2.2	Σύνοψη επίδρασης class weighting	50
6.3	Σταθερότητα και διακύμανση	50
6.4	Οπτική επιβεβαίωση αποτελεσμάτων	51
6.5	Παραπομπή σε πλήρη αποτελέσματα	53
7	Συζήτηση	54
7.1	Ερμηνεία βασικών ευρημάτων	54
7.1.1	Επέκταση χαρακτηριστικών	54
7.1.2	Στάθμιση κλάσεων	54
7.1.3	Ιεραρχία μοντέλων και σταθερότητα	54
7.2	Σύγκριση με προηγούμενη βιβλιογραφία	55
7.3	Ερμηνεία σημαντικότητας χαρακτηριστικών	55
7.4	Μεθοδολογικές συνέπειες	55
8	Περιορισμοί και απειλές για την εγκυρότητα	57
8.1	Περιορισμοί δεδομένων και δειγματοληψίας	57
8.2	Μεθοδολογικοί και τεχνικοί περιορισμοί	58
8.2.1	Επιλογές μοντελοποίησης και ρύθμισης	58
8.2.2	Περιορισμοί εξαγωγής χαρακτηριστικών	58
8.2.3	Εξωτερική επικύρωση και γενίκευση	58
8.3	Απειλές για την εγκυρότητα	59
9	Συμπέρασμα	60
9.1	Περίληψη	60
9.2	Κύριες συνεισφορές	60
9.3	Συνοπτικές απαντήσεις στα ερευνητικά ερωτήματα	60
9.4	Επιπτώσεις και προτεραιότητες συνέχειας	61
9.5	Τελική τοποθέτηση	61
A	Πίνακες Σημαντικότητας Χαρακτηριστικών	62
A.1	Επισκόπηση	62

A.2	Dataset A — ReadText Task	62
A.2.1	Random Forest — Top 20 Features	62
A.2.2	Logistic Regression — Top 20 Features	63
A.2.3	Gradient Boosting — Top 10 Features	64
A.2.4	XGBoost — Top 10 Features	65
A.3	Dataset A — SpontaneousDialogue Task	66
A.3.1	Random Forest — Top 20 Features	66
A.3.2	Logistic Regression — Top 10 Features	66
A.3.3	Gradient Boosting — Top 10 Features	67
A.3.4	XGBoost — Top 10 Features	68
A.4	Dataset B — PD Speech Features	69
A.4.1	Random Forest — Top 10 Features	70
A.4.2	Logistic Regression — Top 10 Features	70
A.4.3	Gradient Boosting — Top 10 Features	71
A.4.4	XGBoost — Top 10 Features	72
A.5	Σταθερότητα Χαρακτηριστικών μεταξύ Tasks	72
A.6	Ανάλυση Κατηγοριών Χαρακτηριστικών	73
B	Αναλυτικοί Πίνακες Αποτελεσμάτων	75
B.1	Επισκόπηση	75
B.2	Συνθήκη 1: Baseline Features (47) + Unweighted	75
B.2.1	Dataset A: MDVR-KCL Σύνοψη	75
B.2.2	Dataset B: PD Speech Features Σύνοψη	76
B.3	Συνθήκη 2: Extended Features (78) + Unweighted	76
B.3.1	Dataset A: MDVR-KCL Σύνοψη	76
B.3.2	Βελτίωση έναντι Baseline (Random Forest, Dataset A)	76
B.4	Συνθήκη 3: Baseline Features (47) + Weighted	77
B.4.1	Dataset A: MDVR-KCL Σύνοψη	77
B.4.2	Επίδραση του Weighting (vs Condition 1, Random Forest)	77
B.5	Συνθήκη 4: Extended Features (78) + Weighted	78
B.5.1	Dataset A: MDVR-KCL Σύνοψη	78
B.5.2	Επίδραση του Weighting (vs Condition 2, Random Forest)	78
B.6	Matrix Σύγκρισης μεταξύ Conditions	79
B.6.1	Random Forest ROC-AUC ανά Task	79
B.6.2	Random Forest Accuracy ανά Task	79
B.6.3	Κύριες Παρατηρήσεις	79
B.7	Σημειώσεις για τη Statistical Significance	79
B.8	Καμπύλες ROC	80

C	Εφαρμογή Ερευνητικής Επίδειξης	83
C.1	Σκοπός και όρια	83
C.2	Αρχιτεκτονική	83
C.3	Ροή χρήσης	84
C.4	Ερμηνεία αποτελέσματος	86
C.5	Αναπαραγωγικότητα και συνέπεια	87
C.6	Σύνοψη	87

Κατάλογος Σχημάτων

4.1	Αρχιτεκτονική της διαδικασίας εξαγωγής χαρακτηριστικών. Κάθε αρχείο ήχου παράγει ένα διάνυσμα χαρακτηριστικών.	34
6.1	ROC curves για ReadText (Dataset A, extended, grouped 5-fold CV).	51
6.2	ROC curves για SpontaneousDialogue (Dataset A, extended, grouped 5-fold CV).	52
6.3	ROC curves για Dataset B (stratified 5-fold CV). Τα αποτελέσματα ενδέχεται να είναι αισιόδοξα λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds.	53
A.1	Μέγεθος συντελεστών του Logistic Regression (ReadText)	63
A.2	Σημαντικότητα χαρακτηριστικών του Gradient Boosting (ReadText). Το $F0$ max εμφανίζει ισχυρή κυριαρχία (0.229 ± 0.179), σε συμφωνία με διαταραχές στη ρύθμιση του pitch στην PD.	64
A.3	Σημαντικότητα χαρακτηριστικών του XGBoost (ReadText). Η σημαντικότητα είναι πιο κατανοητή σε σχέση με το Gradient Boosting, με τα χαρακτηριστικά $F0$ και έντασης να μοιράζονται την κυριαρχία.	65
A.4	Μέγεθος συντελεστών του Logistic Regression (Spontaneous Dialogue)	67
A.5	Σημαντικότητα χαρακτηριστικών του Gradient Boosting (Spontaneous Dialogue). Το MFCC-5 (0.342 ± 0.204) κυριαρχεί, αντανakλώντας αλλαγές στο spectral tilt στην αυθόρμητη ομιλία PD.	68
A.6	Σημαντικότητα χαρακτηριστικών του XGBoost (Spontaneous Dialogue). Τα MFCC-5 και τα shimmer χαρακτηριστικά κυριαρχούν, σε συμφωνία με τα ευρήματα των RF και GB για αυτό το task.	69
A.7	Σημαντικότητα χαρακτηριστικών για το Dataset B (PD Speech Features) — Random Forest και Logistic Regression.	71
A.8	Σημαντικότητα χαρακτηριστικών για το Dataset B — Gradient Boosting και XGBoost. Τα χαρακτηριστικά ενέργειας/εντροπίας TQWT από ζώνες υψηλής συχνότητας κυριαρχούν και στα δύο μοντέλα.	72

A.9	Σημαντικότητα χαρακτηριστικών συγκεντρωμένη ανά ευρείες ακουστικές κατηγορίες.	74
B.1	ROC curves για όλους τους πέντε classifiers στο ReadText task (Dataset A, extended features). Τα shaded bands υποδεικνύουν ± 1 standard deviation στα πέντε cross-validation folds.	80
B.2	ROC curves για όλους τους πέντε classifiers στο SpontaneousDialogue task (Dataset A, extended features).	81
B.3	ROC curves για όλους τους πέντε classifiers στο Dataset B (PD Speech Features). Σημειώνεται ότι subject-level deduplication δεν είναι εφικτό για αυτό το dataset· τα αποτελέσματα ενδέχεται να είναι optimistic λόγω πιθανής επικάλυψης subjects μεταξύ folds.	82
C.1	Διεπαφή μεταφόρτωσης ηχητικού αρχείου.	84
C.2	Διεπαφή άμεσης καταγραφής ήχου μέσω φυλλομετρητή.	85
C.3	Παράδειγμα οθόνης αποτελέσματος της εφαρμογής επίδειξης.	86

Κατάλογος Πινάκων

2.1	Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD	27
3.1	Σύνοψη Dataset A (MDVR-KCL)	32
3.2	Σύνοψη Dataset B	33
3.3	Κύριες διαφορές Dataset A και Dataset B	33
4.1	Ανάλυση προσωδιακών χαρακτηριστικών	37
4.2	Βασικά φασματικά χαρακτηριστικά	38
4.3	Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)	39
4.4	Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση	39
4.5	Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.	41
4.6	Στρατηγικές διασταυρούμενης επικύρωσης	45
4.7	Μετρήσεις αξιολόγησης	46
5.1	Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.	48
5.2	Συνολικός αριθμός πειραμάτων	48
6.1	Κύρια αποτελέσματα ανά σύνολο δεδομένων	49
6.2	Επίδραση feature extension (78 έναντι 47 χαρακτηριστικών) στο Dataset A	50
6.3	Επίδραση class weighting στο Random Forest (Dataset A)	50
6.4	Σύγκριση διακύμανσης μεταξύ Dataset A και Dataset B	50
8.1	Κρίσιμοι περιορισμοί ανά σύνολο δεδομένων	57
8.2	Σύνοψη απειλών εγκυρότητας και μετριάσμων	59
A.1	Σημαντικότητα χαρακτηριστικών του Random Forest — ReadText (top 10)	62
A.2	Σημαντικότητα χαρακτηριστικών του Logistic Regression — ReadText (top 10)	63

A.3	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — ReadText (top 10)	64
A.4	Σημαντικότητα χαρακτηριστικών του XGBoost — ReadText (top 10) . .	65
A.5	Σημαντικότητα χαρακτηριστικών του Random Forest — SpontaneousDialogue (top 10)	66
A.6	Σημαντικότητα χαρακτηριστικών του Logistic Regression — SpontaneousDialogue (top 10)	66
A.7	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — SpontaneousDialogue (top 10)	67
A.8	Σημαντικότητα χαρακτηριστικών του XGBoost — SpontaneousDialogue (top 10)	68
A.9	Σημαντικότητα χαρακτηριστικών του Random Forest — Dataset B (top 10)	70
A.10	Σημαντικότητα χαρακτηριστικών του Logistic Regression — Dataset B (top 10)	70
A.11	Σημαντικότητα χαρακτηριστικών του Gradient Boosting — Dataset B (top 10)	71
A.12	Σημαντικότητα χαρακτηριστικών του XGBoost — Dataset B (top 10) . .	72
A.13	Σταθερότητα χαρακτηριστικών μεταξύ tasks (Random Forest top-10) . .	73
A.14	Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά κατηγορία	73
B.1	Αποτελέσματα Condition 1 ανά task (Dataset A, baseline features, χωρίς weighting)	75
B.2	Αποτελέσματα Condition 1 (Dataset B, baseline features, χωρίς weighting) .	76
B.3	Αποτελέσματα Condition 2 ανά task (Dataset A, extended features, χωρίς weighting)	76
B.4	Βελτίωση Condition 2 έναντι Condition 1 (Random Forest)	76
B.5	Αποτελέσματα Condition 3 ανά task (Dataset A, baseline features, με weighting)	77
B.6	Επίδραση του weighting στο Condition 3 έναντι Condition 1 (RF)	77
B.7	Αποτελέσματα Condition 4 ανά task (Dataset A, extended features, με weighting)	78
B.8	Επίδραση του weighting στο Condition 4 έναντι Condition 2 (RF)	78
B.9	Πίνακας σύγκρισης Random Forest ROC-AUC (Dataset A)	79
B.10	Πίνακας σύγκρισης Random Forest Accuracy (Dataset A)	79

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορικό και κίνητρα

Η νόσος του Πάρκινσον αποτελεί μία από τις συχνότερες νευροεκφυλιστικές διαταραχές και επηρεάζει σημαντικό ποσοστό του πληθυσμού άνω των 60 ετών [1]. Οι φωνητικές διαταραχές εμφανίζονται συχνά πρώιμα, πριν από την πλήρη εγκατάσταση κινητικών συμπτωμάτων [2], και γι' αυτό η φωνή έχει μελετηθεί ως μη επεμβατικός και χαμηλού κόστους βιοδείκτης [3, 4].

Στην PD, η υποκινητική δυσαρθρία συνδέεται με μειωμένη ένταση, μονοτονία και αστάθεια φωνής [5]. Η πρόσφατη μετάβαση από εργαστηριακές ηχογραφήσεις σε καταγραφές με φορητές συσκευές αυξάνει τη δυνητική πρακτική αξία, αλλά εντείνει τα ζητήματα γενίκευσης και μεθοδολογικής αυστηρότητας [6]. Παράλληλα, η πλειονότητα των μελετών εστιάζει στην ανίχνευση και λιγότερο στη διαχρονική παρακολούθηση [7, 8].

1.2 Διατύπωση προβλήματος

Παρά την πρόοδο, παραμένουν κρίσιμα μεθοδολογικά ζητήματα:

1. μικρά μεγέθη δείγματος και υψηλή μεταβλητότητα,
2. subject leakage όταν το ίδιο άτομο εμφανίζεται σε train/test,
3. ανισορροπία κλάσεων,
4. ισχυρή εξάρτηση από την επιλογή χαρακτηριστικών,
5. ετερογένεια πρωτοκόλλων επικύρωσης που δυσκολεύει τις συγκρίσεις [6].

Η παρούσα εργασία δίνει προτεραιότητα στη μεθοδολογική αξιοπιστία και στην αναπαραγωγιμότητα, όχι στη μεγιστοποίηση μεμονωμένων επιδόσεων.

1.3 Στόχοι της εργασίας

1. Ανάπτυξη αναπαραγώγιμης ροής εξαγωγής φωνητικών χαρακτηριστικών.
2. Συγκριτική αξιολόγηση κλασικών ταξινομητών (Logistic Regression, SVM, Random Forest, Gradient Boosting, XGBoost) για PD έναντι HC.
3. Εξέταση της επίδρασης του feature extension (47→78 χαρακτηριστικά).
4. Εξέταση της επίδρασης class weighting σε μη ισορροπημένα δεδομένα.
5. Ανάλυση αποτελεσμάτων σε δύο datasets με διαφορετικά μεθοδολογικά χαρακτηριστικά.

1.4 Κύριες συνεισφορές

- **Αξιολόγηση χωρίς διαρροή υποκειμένων:** grouped cross-validation στο Dataset A.
- **Ελεγχόμενη μελέτη χαρακτηριστικών:** συστηματική σύγκριση baseline και extended feature set.
- **Task-aware ανάλυση:** ξεχωριστή αξιολόγηση ReadText και SpontaneousDialogue.
- **Διαφανής αναφορά:** παρουσίαση mean $\pm$ std για όλες τις συνθήκες και όχι μόνο των καλύτερων τιμών.
- **Ερμηνευσιμότητα:** ανάλυση σημαντικότητας χαρακτηριστικών για κατανόηση των μοτίβων ταξινόμησης.

1.5 Οργάνωση της εργασίας

Το Κεφάλαιο 2 καλύπτει τη βιβλιογραφία, το Κεφάλαιο 3 τα δεδομένα, το Κεφάλαιο 4 τη μεθοδολογία, το Κεφάλαιο 5 τον πειραματικό σχεδιασμό, το Κεφάλαιο 6 τα αποτελέσματα, το Κεφάλαιο 7 τη συζήτηση, το Κεφάλαιο 8 τους περιορισμούς και το Κεφάλαιο 9 τα συμπεράσματα.

1.6 Όρια πεδίου εφαρμογής

Η μελέτη περιορίζεται σε δυαδική ταξινόμηση PD/HC, σε κλασικά μοντέλα μηχανικής μάθησης και σε ερευνητικό (μη κλινικό) πλαίσιο χρήσης. Οι επιλογές σχεδιασμού έγιναν με προτεραιότητα την αναπαραγωγιμότητα και τη συντηρητική ερμηνεία των αποτελεσμάτων.

Κεφάλαιο 2

Βιβλιογραφική ανασκόπηση

2.1 Η νόσος του Πάρκινσον και η διαταραχή της ομιλίας

Η νόσος του Πάρκινσον (PD) συνδέεται όχι μόνο με κινητικά συμπτώματα, αλλά και με συστηματικές διαταραχές ομιλίας. Υπολογίζεται ότι το 70–90% των ατόμων με PD εμφανίζουν μετρήσιμες φωνητικές αλλοιώσεις κατά την πορεία της νόσου [1]. Το κλινικό αυτό πρότυπο περιγράφεται ως υποκινητική δυσαρθρία και περιλαμβάνει υποφωνία, μονοτονία, μειωμένη προσωδιακή μεταβλητότητα, ασαφή άρθρωση και θορυβώδη/βραχνή φώνηση [5, 9].

Οι μεταβολές αυτές έχουν ερευνητικό ενδιαφέρον ως μη επεμβατικοί βιοδείκτες. Η φωνή συλλέγεται εύκολα με χαμηλό κόστος (π.χ. μέσω smartphone), ενώ υπάρχουν ενδείξεις ότι λεπτές φωνητικές ανωμαλίες ενδέχεται να προηγούνται των κλασικών κινητικών εκδηλώσεων [2]. Για αυτό, η ανάλυση φωνής χρησιμοποιείται όλο και περισσότερο σε πλαίσια τηλεϊατρικής και παρακολούθησης [4].

2.2 Ανίχνευση έναντι παρακολούθησης

Η βιβλιογραφία διακρίνει δύο στόχους: (i) **ανίχνευση/διαλογή** (PD έναντι HC) και (ii) **παρακολούθηση εξέλιξης/θεραπευτικής ανταπόκρισης**. Ανασκόπηση 106 μελετών (2019–2023) έδειξε ότι περίπου 94% επικεντρώνονται στην ανίχνευση, ενώ λιγότερο από 12% στη διαχρονική πρόγνωση [7].

Η παρατεταμένη φώνηση φωνηέντων είναι συχνά κατάλληλη για δυαδική διάκριση PD/HC, ενώ η συνδεδεμένη ομιλία (ανάγνωση, αυθόρμητος διάλογος) προσφέρει πλουσιότερη πληροφορία για άρθρωση, ρυθμό και προσωδία που συνδέονται με

σοβαρότητα [8]. Παραμένει, ωστόσο, περιορισμένος ο αριθμός διαχρονικών μελετών σε επίπεδο ατόμου [8].

2.3 Ταξινόμηση ακουστικών χαρακτηριστικών

Πίνακας 2.1: Κατηγορίες ακουστικών χαρακτηριστικών για την ταξινόμηση PD

Κατηγορία	Παραδείγματα	Φυσιολογική βάση
Θεμελιώδης συχνότητα	F_0 μέσος όρος, F_0 τυπική απόκλιση	Τάση φωνητικών χορδών και κινητική ακαμψία
Διαταραχή	Jitter, Shimmer	Νευρομυϊκή αστάθεια
Θόρυβος	HNR, NHR	Ατελές κλείσιμο της γλωττίδας
Φορμάντες	F_1 , F_2 , F_3	Διαμόρφωση φωνητικού σωλήνα
Φασματικά/Κεπστρικά	MFCCs, delta-MFCCs	Φασματική περιβάλλουσα και δυναμική

Οι βασικές κατηγορίες χαρακτηριστικών είναι συμπληρωματικές: προσωδία, διαταραχή φώνησης και φασματική/κεπστρική περιγραφή. Στην PD έχουν αναφερθεί χαμηλότερη μεταβλητότητα F_0 , αυξημένα jitter/shimmer και χαμηλότερες τιμές HNR [3, 10]. Τα MFCC και οι χρονικές παράγωγοι (delta, delta-delta) αποτυπώνουν επιπλέον δυναμική της ομιλίας [11].

2.3.1 Πλαίσιο φώνησης, άρθρωσης και προσωδίας

Σύγχρονες ανασκοπήσεις οργανώνουν τα χαρακτηριστικά σε τρεις λειτουργικές ομάδες [8]:

- **Φώνηση:** jitter, shimmer, HNR και συναφή μέτρα σταθερότητας γλωττιδικής ταλάντωσης.
- **Άρθρωση:** MFCC, formants, cepstral metrics, δείκτες φωνηεντικού χώρου.
- **Προσωδία:** μεταβλητότητα τόνου, ρυθμός, παύσεις και timing.

Από 18 χαρακτηριστικά που εξετάστηκαν από τον Wright and Aharonson [8], τα 12 εμφάνισαν συνεπείς διαφορές μεταξύ PD και HC, με jitter, shimmer και HNR να αναφέρονται συχνότερα ως διακριτικά.

2.4 Σύνολα δεδομένων στην έρευνα φωνής PD

2.4.1 Ακατέργαστα σύνολα ήχου

Τα raw-audio datasets απαιτούν πλήρη pipeline εξαγωγής χαρακτηριστικών, αλλά προσφέρουν έλεγχο στην προεπεξεργασία και στην επιλογή χαρακτηριστικών. Κλασικό παράδειγμα είναι το σύνολο του Little et al. [12] (195 φωνήσεις από 31 άτομα), το οποίο αποτέλεσε πρώιμο σημείο αναφοράς με SVM [3, 13]. Βασικός κίνδυνος είναι η διαρροή υποκειμένων όταν υπάρχουν πολλαπλές εγγραφές ανά άτομο.

Το MDVR-KCL [14] περιλαμβάνει πολλαπλές εργασίες ομιλίας και επαναλαμβανόμενες εγγραφές ανά υποκείμενο, επιτρέποντας task-aware ανάλυση υπό grouped validation.

2.4.2 Προ-εξαγόμενα σύνολα χαρακτηριστικών

Σύνολα όπως το PDSF (UCI/Kaggle) [15] παρέχουν έτοιμο πίνακα χαρακτηριστικών (756 δείγματα, εκατοντάδες features), διευκολύνοντας άμεση σύγκριση ταξινομητών. Το πλεονέκτημα της ευκολίας συνοδεύεται από κρίσιμο μεθοδολογικό περιορισμό: εάν δεν υπάρχουν subject IDs, δεν μπορεί να εφαρμοστεί ασφαλές subject-level split, άρα οι εσωτερικές επιδόσεις μπορεί να είναι αισιόδοξες.

2.4.3 Κλίμακα και αντιπροσωπευτικότητα

Ανασκόπηση 69 μελετών (2020–2025) έδειξε ότι τα περισσότερα datasets περιλαμβάνουν λιγότερους από 100 συμμετέχοντες, ενώ η ανισορροπία κλάσεων είναι συχνή [6]. Αυτό περιορίζει τη σταθερότητα των εκτιμήσεων και δυσκολεύει τη γενίκευση.

2.4.4 Ετερογένεια επικύρωσης

Η αναφερόμενη απόδοση εξαρτάται έντονα από το πρωτόκολλο αξιολόγησης. Σύμφωνα με Sedigh Malekroodi et al. [6], k-fold CV και fixed splits κυριαρχούν, ενώ subject-independent και external validation παραμένουν λιγότερο συχνές. Η ετερογένεια αυτή δυσκολεύει άμεσες συγκρίσεις μεταξύ μελετών.

2.4.5 Ο ρόλος των εργασιών ομιλίας

Η επιλογή task επηρεάζει το είδος της πληροφορίας που αποτυπώνεται. Η παρατεταμένη φώνηση τείνει να ευνοεί τη δυαδική διάκριση, ενώ ανάγνωση και

αυθόρμητη ομιλία προσφέρουν πλουσιότερους δείκτες άρθρωσης/προσωδίας σχετικούς με λειτουργική επιβάρυνση [8].

2.5 Κλασικές προσεγγίσεις μηχανικής μάθησης

Στη φωνητική ταξινόμηση PD, οι πιο συχνές κλασικές μέθοδοι είναι Logistic Regression, SVM και ensemble δέντρων. Η Logistic Regression λειτουργεί ως ερμηνεύσιμη γραμμική βάση [16]. Η SVM έχει ιστορικά ισχυρή παρουσία [3, 13], ενώ το Random Forest είναι δημοφιλές λόγω ανθεκτικότητας, μη γραμμικότητας και ενσωματωμένης σημασίας χαρακτηριστικών [17, 18].

Η ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών έχει αναδειχθεί ως κρίσιμη απαίτηση για κλινικά χρήσιμη τεκμηρίωση. Ο Solana-Lavalle and Rosas-Romero [19] δείχνει ότι η στοχευμένη επιλογή χαρακτηριστικών και η προσεκτική ανάλυση υποομάδων μπορούν να βελτιώσουν την ποιότητα ερμηνείας.

2.5.1 Από χειροποίητα χαρακτηριστικά σε βαθιές αναπαραστάσεις

Η πρόσφατη βιβλιογραφία μετατοπίζεται προς deep learning (CNN, transformers, foundation embeddings), αλλά η εξωτερική αξιολόγηση παραμένει περιορισμένη [6]. Κατά συνέπεια, ακόμη και υψηλές εσωτερικές επιδόσεις πρέπει να ερμηνεύονται με προσοχή όταν η γενίκευση δεν έχει ελεγχθεί επαρκώς.

2.6 Μεθοδολογικά ζητήματα στη βιβλιογραφία

2.6.1 Διαρροή δεδομένων

Όταν πολλαπλές εγγραφές του ίδιου ατόμου κατανέμονται σε train και test, προκύπτει τεχνητή ενίσχυση επιδόσεων [6]. Η grouped αξιολόγηση είναι κρίσιμη για ρεαλιστική εκτίμηση.

2.6.2 Ανισορροπία κλάσεων

Η ανισορροπία επηρεάζει ιδιαίτερα μετρικές που δεν αποτυπώνουν καλά τη μειοψηφική κλάση. Η χρήση στάθμισης κλάσεων ή άλλων στρατηγικών μετριασμού αναφέρεται ανομοιόμορφα στη βιβλιογραφία [6].

2.6.3 Αναπαραγωγιμότητα

Συχνές ελλείψεις τεκμηρίωσης (παράμετροι εξαγωγής, seeds, CV protocol, tuning διαδικασία) δυσκολεύουν την αναπαραγωγή αποτελεσμάτων. Η συστηματική τεκμηρίωση των παραπάνω αποτελεί βασικό κριτήριο ποιότητας.

2.6.4 Εξωτερική επικύρωση και γενίκευση μεταξύ συνόλων δεδομένων

Η εξωτερική επικύρωση παραμένει περιορισμένη (λιγότερο από 15% σε πρόσφατες μελέτες), γεγονός που περιορίζει την εμπιστοσύνη σε ισχυρισμούς γενίκευσης [6]. Οι αναφορές απότομης πτώσης επίδοσης σε cross-dataset δοκιμές ενισχύουν την ανάγκη για συντηρητική ερμηνεία.

2.6.5 Ερμηνευσιμότητα

Παρά την πρόοδο, μέθοδοι post-hoc ερμηνείας (π.χ. SHAP/LIME) εμφανίζονται ακόμη σε μικρό ποσοστό μελετών [6]. Αυτό δημιουργεί χάσμα μεταξύ υψηλής επίδοσης και κλινικής αξιοποίησης.

2.7 Έλλειμμα στην έρευνα

Η βιβλιογραφία εξακολουθεί να παρουσιάζει ελλείψεις σε:

1. συστηματική grouped αξιολόγηση σε datasets πολλαπλών εγγραφών,
2. ελεγχόμενη αφαίρεση/επέκταση χαρακτηριστικών,
3. τεκμηριωμένη ανάλυση επίδρασης class weighting,
4. διαφανή αναφορά περιορισμών και αβεβαιότητας,
5. εξωτερική επικύρωση,
6. ερμηνευσιμότητα σε επίπεδο χαρακτηριστικών.

2.8 Περίληψη

Η φωνητική ταξινόμηση PD/HC είναι ερευνητικά ώριμη ως προς τη διαθεσιμότητα μεθόδων, αλλά όχι πλήρως ώριμη ως προς τη μεθοδολογική ομοιογένεια και τη γενίκευση. Οι ανασκοπήσεις 2019–2025 δείχνουν ότι τα πρωτόκολλα αξιολόγησης, η εξωτερική επικύρωση και η ερμηνευσιμότητα παραμένουν τα κύρια ανοικτά

ζητήματα [6, 7]. Για αυτό, η παρούσα εργασία εστιάζει σε συντηρητική αξιολόγηση, αναπαραγωγιμότητα και διαφανή ερμηνεία αντί σε μεγιστοποίηση μεμονωμένων επιδόσεων.

Κεφάλαιο 3

Περιγραφή δεδομένων

3.1 Επισκόπηση

Η εργασία χρησιμοποιεί δύο συμπληρωματικά σύνολα δεδομένων με διαφορετικό επίπεδο ελέγχου: (i) raw audio με διαθέσιμα subject IDs (Dataset A: MDVR-KCL) και (ii) προ-εξαγμένα χαρακτηριστικά χωρίς subject IDs (Dataset B). Η διάκριση αυτή καθορίζει και το πρωτόκολλο αξιολόγησης.

3.2 Σύνολο δεδομένων A: MDVR-KCL

To Mobile Device Voice Recordings from King's College London (MDVR-KCL) [14] συλλέχθηκε σε κλινικό περιβάλλον με smartphone και περιέχει αρχεία WAV υψηλής ποιότητας (χωρίς GSM συμπίεση).

Ιδιότητα	Τιμή
Πηγή	Zenodo, DOI 10.5281/zenodo.2867215
Μορφή ήχου	WAV PCM, mono, 16-bit
Ρυθμός δειγματοληψίας	44.1 kHz (resample σε 22.05 kHz για επεξεργασία)
Εργασίες ομιλίας	ReadText, SpontaneousDialogue
Υποκείμενα	37 (ReadText), 36 (SpontaneousDialogue)
Κλάσεις	HC: 21, PD: 16 (ReadText) / HC: 21, PD: 15 (SpontaneousDialogue)

Πίνακας 3.1: Σύνοψη Dataset A (MDVR-KCL)

To Dataset A επιτρέπει subject-level διαχωρισμό folds και συνεπώς αυστηρό έλεγχο διαρροής υποκειμένων. Η απουσία του ID18 στο SpontaneousDialogue εξηγεί τη διαφορά 37 έναντι 36 υποκειμένων.

3.3 Σύνολο δεδομένων B: PD Speech Features

Το Dataset B προέρχεται από UCI/Kaggle [15] και παρέχει προ-υπολογισμένα χαρακτηριστικά σε μορφή CSV.

Ιδιότητα	Τιμή
Μορφή	CSV (752 features + 1 label)
Δείγματα	756 γραμμές
Κλάσεις	HC: 192 (25.4%), PD: 564 (74.6%)
Υποκείμενα	Subject IDs δεν παρέχονται
Εργασία ομιλίας	Παρατεταμένη φώνηση /a/

Πίνακας 3.2: Σύνοψη Dataset B

Τα χαρακτηριστικά καλύπτουν πολλαπλούς τομείς (jitter/shimmer, formants, MFCC, wavelet, TQWT κ.ά.), αλλά δεν υπάρχει πρόσβαση στον αρχικό ήχο. Αυτό περιορίζει την επαναληψιμότητα της εξαγωγής και την προσθήκη νέων χαρακτηριστικών.

Κρίσιμη προειδοποίηση: Η απουσία subject IDs στο Dataset B δεν επιτρέπει ασφαλή subject-level cross-validation. Συνεπώς, η τυπική stratified CV μπορεί να οδηγεί σε αισιόδοξες εκτιμήσεις απόδοσης λόγω πιθανής επικάλυψης ίδιων υποκειμένων σε train και test.

3.4 Συγκριτική αποτίμηση των δύο συνόλων

Πτυχή	Dataset A	Dataset B
Μονάδα εισόδου	Raw audio (WAV)	Προ-εξαγμένα features (CSV)
Subject IDs	Διαθέσιμα	Μη διαθέσιμα
Validation	Grouped (subject-level)	Stratified (sample-level)
Speech task	ReadText / Spontaneous Dialogue	Sustained vowel /a/
Feature pipeline	Ελεγχόμενο από την εργασία	Προ-υπολογισμένο

Πίνακας 3.3: Κύριες διαφορές Dataset A και Dataset B

Η μελέτη δεν αντιμετωπίζει τα δύο datasets ως άμεσα συγκρίσιμα σε απόλυτους όρους. Τα αποτελέσματα ερμηνεύονται με βάση τις δομικές διαφορές τους και με ιδιαίτερη προσοχή στο πιθανό optimistic bias του Dataset B.

Μεθοδολογία

4.1.1 Αρχιτεκτονική διαδικασία

+-----+		+-----+		+-----+
Ακατέργαστος	-->	Εξαγωγή	-->	Μήτρα
ήχος (WAV)		χαρακτηριστικών		χαρακτηριστικών
+-----+		+-----+		+-----+
		ν		
		+-----+		
		* Προσωδικά		
		χαρακτηριστικά		
		* Φασματικά		
		χαρακτηριστικά		
		+-----+		

4.1.2 Προεπεξεργασία ήχου

1. **Φόρτωση ήχου** με τον αρχικό ρυθμό δειγματοληψίας χρησιμοποιώντας

```
librosa.load()
```

2. **Επαναδειγματοληψία** στα 22.050 Hz (σταθερή σε όλες τις ηχογραφήσεις)
3. **Μετατροπή σε μονοφωνικό** αν το αρχείο ήταν στερεοφωνικό (μέσος όρος των δύο καναλιών).
4. **Κανονικοποίηση πλάτους** στο εύρος $[-1, 1]$
5. **Αφαίρεση σιωπής** χρησιμοποιώντας ανίχνευση βάσει ενέργειας (threshold 5% της μέγιστης ενέργειας)

Ο ρυθμός 22.050 Hz επιλέχθηκε γιατί είναι επαρκής για ανάλυση ομιλίας (Nyquist 11.025 Hz) και ταυτόχρονα μειώνει το υπολογιστικό κόστος σε σχέση με τα 44.100 Hz.

4.1.3 Προσωδικά χαρακτηριστικά (21 χαρακτηριστικά)

Τα προσωδικά χαρακτηριστικά περιγράφουν στοιχεία της φωνής που επηρεάζονται συχνά από τη νόσο του Πάρκινσον. Η εξαγωγή έγινε με το Parselmouth (Praat).

Θεμελιώδης συχνότητα (F_0)

Για την εξαγωγή του τόνου χρησιμοποιήθηκαν οι ακόλουθες παράμετροι:

- **Αλγόριθμος:** Βασισμένος στην αυτοσυσχέτιση (προεπιλογή του Praat)
- **Εύρος τόνου:** 75–500 Hz (καλύπτει ανδρικές, γυναικείες και παθολογικές φωνές)
- **Χρονικό βήμα:** 0,01 s (πρότυπο για την ανάλυση φωνής)

Τέσσερα στατιστικά στοιχεία υπολογίστηκαν από το περίγραμμα του τόνου:

$$F_0 = \{\mu_{F_0}, \sigma_{F_0}, \min_{F_0}, \max_{F_0}\} \quad (4.1)$$

Jitter

Το Jitter μετρά τη διακύμανση της περιόδου του τόνου από κύκλο σε κύκλο.

$$\text{Jitter}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|T_i - T_{i+1}|}{\bar{T}} \quad (4.2)$$

όπου T_i είναι η i -η περίοδος τόνου και $\bar{T}$ είναι η μέση περίοδος.

Πρόσθετα μέτρα περιλαμβάνουν:

- **RAP (Σχετική Μέση Διαταραχή):** εξομάλυνση 3 σημείων
- **PPQ5:** πηλίκο διαταραχής περιόδου 5 σημείων

Shimmer

Το Shimmer μετρά τη διακύμανση της έντασης από κύκλο σε κύκλο.

$$\text{Shimmer}_{\text{local}} = \frac{1}{N-1} \sum_{i=1}^{N-1} \frac{|A_i - A_{i+1}|}{\bar{A}} \quad (4.3)$$

όπου A_i είναι το i -οστό μέγιστο πλάτος και $\bar{A}$ είναι το μέσο πλάτος.

Πρόσθετα μέτρα περιλαμβάνουν APQ3, APQ5, APQ11 (συντελεστές διαταραχής πλάτους με μεταβαλλόμενα παράθυρα) και DDA (διαφορά των διαφορών των πλατών).

Αναλογία αρμονικών προς θόρυβο (HNR)

Το HNR δείχνει πόσο «καθαρή» είναι η φωνή (αρμονικές έναντι θορύβου).

- **Μέση HNR:** Μέση HNR (dB)
- **Αυτοσυσχέτιση αρμονικότητας:** Μέγιστη τιμή αυτοσυσχέτισης

Ένταση

Τρεις στατιστικές έντασης (dB SPL):

$$I = \{\mu_I, \sigma_I, \max_I - \min_I\} \quad (4.4)$$

Formants

Τα τρία πρώτα formants (F_1 , F_2 , F_3) εξήχθησαν χρησιμοποιώντας γραμμική προβλεπτική κωδικοποίηση (LPC):

- **Σειρά LPC:** τάξης 10 (επαρκής για 3 formants στα 22 kHz)
- **Χαρακτηριστικά:** Μέσος όρος και τυπική απόκλιση κάθε φωνητικού στοιχείου (6 χαρακτηριστικά συνολικά)

Ομάδα χαρακτηριστικών	Αριθμός	Χαρακτηριστικά	Εργαλείο
Τόνος (F_0)	4	μέσος όρος, τυπική απόκλιση, ελάχιστο, μέγιστο	Parselmouth
Jitter	3	τοπικό, RAP, PPQ5	Parselmouth
Shimmer	5	τοπικό, APQ3, APQ5, APQ11, DDA	Parselmouth
Αρμονικότητα	2	μέσος όρος HNR, αυτοσυσχέτιση	Parselmouth
Intensity	3	μέσος όρος, τυπική απόκλιση, εύρος	Parselmouth
Formants	6	F_1-F_3 μέσος όρος, F_1-F_3 τυπική απόκλιση	Parselmouth
Σύνολο	21		

Πίνακας 4.1: Ανάλυση προσωδιακών χαρακτηριστικών

4.1.4 Φασματικά χαρακτηριστικά

Τα φασματικά χαρακτηριστικά περιγράφουν τη δομή του φάσματος συχνοτήτων της φωνής και εξήχθησαν χρησιμοποιώντας τη βιβλιοθήκη `librosa` [20].

Συντελεστές Mel-Frequency Cepstral (MFCC)

Οι MFCC υπολογίζονται μέσω των ακόλουθων βημάτων:

1. **Προέμφαση:** $y[n] = x[n] - 0,97 \cdot x[n - 1]$
2. **Πλαίσιο:** Μήκος παραθύρου = 2048 δείγματα (≈ 93 ms στα 22 kHz)
3. **Παράθυρο:** Εφαρμογή παραθύρου Hann
4. **FFT:** FFT 2048 σημείων
5. **Φίλτρο Mel:** 128 τριγωνικά φίλτρα που καλύπτουν 0–11.025 Hz
6. **Συμπίεση λογαρίθμου:** $\log(\text{mel power spectrum})$
7. **DCT:** Διακριτός μετασχηματισμός συνημιτόνου που χρησιμοποιείται για τη μείωση της συσχέτισης μεταξύ των συντελεστών

Παράμετροι που χρησιμοποιήθηκαν:

- **Αριθμός συντελεστών:** 13 (MFCC 0–12)
- **Μήκος άλματος:** 512 δείγματα (≈ 23 ms στα 22 kHz, 75% επικάλυψη)
- **Αριθμός ζωνών mel:** 128

Ο MFCC 0 (ο μηδενικός συντελεστής) περιγράφει κυρίως την ενέργεια του σήματος, ενώ οι MFCC 1–12 αποτυπώνουν το σχήμα του φασματικού περιβλήματος της φωνής.

Συντελεστές δέλτα

Οι χρονικές παράγωγοι πρώτης τάξης (συντελεστές δέλτα) καταγράφουν τη φασματική δυναμική:

$$\Delta_t[n] = \frac{\sum_{i=1}^N i \cdot (c_{t+i} - c_{t-i})}{2 \sum_{i=1}^N i^2} \quad (4.5)$$

όπου c_t είναι ο συντελεστής MFCC στο πλαίσιο t και $N = 2$ είναι το μέγεθος του παραθύρου.

Βασικά φασματικά χαρακτηριστικά (26 χαρακτηριστικά)

Το βασικό σύνολο φασματικών χαρακτηριστικών αποτελείται από:

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Σύνολο	26	

Πίνακας 4.2: Βασικά φασματικά χαρακτηριστικά

Εκτεταμένα φασματικά χαρακτηριστικά (57 χαρακτηριστικά)

Το εκτεταμένο σύνολο χαρακτηριστικών περιλαμβάνει τρεις επιπλέον ομάδες, οι οποίες στοχεύουν να αποτυπώσουν περισσότερη φασματική και χρονική μεταβλητότητα της φωνής.

Χαρακτηριστικό	Αριθμός	Περιγραφή
Μέσος όρος MFCC	13	Χρονικός μέσος όρος των MFCC 0–12
MFCC std	13	Χρονική τυπική απόκλιση (μεταβλητότητα εντός της εκφώνησης)
Μέσος όρος Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων πρώτης τάξης
Μέσος όρος Delta-Delta MFCC	13	Χρονικός μέσος όρος των παραγώγων δεύτερης τάξης (επιτάχυνση)
Φασματικό σχήμα	5	Κέντρο βάρους, εύρος ζώνης, rolloff, επιπεδότητα, ZCR
Σύνολο	57	

Πίνακας 4.3: Εκτεταμένα φασματικά χαρακτηριστικά (τα νέα χαρακτηριστικά εμφανίζονται με έντονα γράμματα)

Οι πέντε περιγραφείς φασματικού σχήματος είναι:

1. **Φασματικό κέντρο βάρους:** Το «κέντρο μάζας» του φάσματος, δηλαδή το σημείο όπου συγκεντρώνεται η περισσότερη ενέργεια (σε Hz)
2. **Φασματικό εύρος ζώνης:** Πόσο απλώνεται το φάσμα γύρω από το κέντρο βάρους (σε Hz).
3. **Φασματική απόκλιση:** Η συχνότητα κάτω από την οποία βρίσκεται το 85% της συνολικής ενέργειας του σήματος (Hz)
4. **Φασματική επιπεδότητα:** Δείκτης του πόσο «τονική» ή «θορυβώδης» είναι η φωνή (λόγος γεωμετρικού προς αριθμητικό μέσο όρο).
5. **Ρυθμός διέλευσης από το μηδέν:** Πόσο συχνά το σήμα αλλάζει πρόσημο στο χρονικό πεδίο, δηλαδή πόσες φορές περνά από το μηδέν.

4.1.5 Συνολικός αριθμός χαρακτηριστικών

Διαμόρφωση	Προσωδιακά	Φασματικά	Σύνολο
Βασική γραμμή	21	26	47
Εκτεταμένα	21	57	78

Πίνακας 4.4: Συνολικός αριθμός χαρακτηριστικών ανά διαμόρφωση

4.2 Σύγκριση συνόλου χαρακτηριστικών

4.2.1 Λόγοι για τα εκτεταμένα χαρακτηριστικά

Το εκτεταμένο σύνολο χαρακτηριστικών σχεδιάστηκε ως μία **ελεγχόμενη δοκιμή**, για να εξεταστεί αν η προσθήκη περισσότερης χρονικής και φασματικής πληροφορίας βελτιώνει την απόδοση της ταξινόμησης.

Προστέθηκαν τρεις ομάδες χαρακτηριστικών:

1. **MFCC std (13):** Μετρά τη μεταβλητότητα των MFCC μέσα σε κάθε ηχογράφηση. Αυτό είναι σημαντικό, γιατί η ομιλία σε ασθενείς με PD μπορεί να παρουσιάζει μεγαλύτερη αστάθεια.
2. **Delta-Delta MFCC (13):** Καταγράφει πόσο γρήγορα αλλάζουν τα φασματικά χαρακτηριστικά με τον χρόνο. Είναι ευαίσθητο στις χρονικές δυναμικές και στις αλλαγές της άρθρωσης.
3. **Φασματικό σχήμα (5):** Προσθέτουν γενικούς δείκτες του φάσματος (π.χ. τονικότητα, διασπορά), που δεν περιγράφονται πλήρως από τα MFCC.

4.2.2 Αναπαραγωγιμότητα εξαγωγής χαρακτηριστικών

Για να διασφαλιστεί η αναπαραγωγιμότητα, όλες οι βασικές παράμετροι ορίστηκαν από την αρχή σε κεντρικό αρχείο ρυθμίσεων (configuration file). Συγκεκριμένα:

- Τυχαίος σπόρος: 42
- Ρυθμός δειγματοληψίας: 22 050 Hz
- Εύρος F_0 : 75–500 Hz
- 13 MFCCs
- FFT 2048 σημείων
- Hop length: 512 δείγματα
- 128 mel bands

Όλα τα εξαγόμενα χαρακτηριστικά αποθηκεύτηκαν σε αρχεία CSV και χρησιμοποιήθηκαν στα επόμενα πειράματα χωρίς περαιτέρω αλλαγές.

4.3 Μοντέλα μηχανικής μάθησης

4.3.1 Προδιαγραφές μοντέλου

Επιλέχθηκαν πέντε κλασικά μοντέλα μηχανικής μάθησης, ώστε να καλυφθούν διαφορετικοί τρόποι μάθησης:

- **Λογιστική Παλινδρόμηση:** ένα απλό γραμμικό μοντέλο με κανονικοποίηση L2.
- **SVM με πυρήνα RBF:** μη γραμμική μέθοδος που μπορεί να μάθει πιο σύνθετα όρια απόφασης.
- **Random Forest:** σύνολο δέντρων απόφασης που προσφέρει και εκτίμηση σημασίας χαρακτηριστικών.
- **Gradient Boosting [21]:** μοντέλο που βελτιώνει σταδιακά τα λάθη των προηγούμενων βημάτων.
- **XGBoost [22]:** βελτιστοποιημένη και κανονικοποιημένη εκδοχή του boosting.

Όλες οι υπερπαράμετροι ορίστηκαν εκ των προτέρων (*a priori*) και δεν προσαρμόστηκαν ειδικά για κάποιο συγκεκριμένο σύνολο δεδομένων:

Μοντέλο	Τύπος	Βασικές παράμετροι
Λογιστική παλινδρόμηση	Γραμμική	$C = 1.0$ (κανονικοποίηση L2), max_iter= 1000, solver='lbfgs'
SVM (RBF)	Πυρήνας	$C = 1.0$ (κανονικοποίηση), gamma='scale' (αυτόματη κλιμάκωση ανά χαρακτηριστικά), kernel='rbf'
Random Forest	Bagging	n_estimators= 100, max_depth= 10, min_samples_split= 2, random_state= 42
Gradient Boosting	Boosting	n_estimators= 100, learning_rate= 0.1, max_depth= 3 (προεπιλογή), random_state= 42
XGBoost	Boosting	n_estimators= 100, learning_rate= 0.1, eval_metric='logloss', random_state= 42

Πίνακας 4.5: Προδιαγραφές μοντέλου. Όλες οι παράμετροι καθορίστηκαν πριν από τα πειράματα.

Λογιστική παλινδρόμηση

Το μοντέλο λογιστικής παλινδρόμησης προβλέπει τις πιθανότητες κλάσης μέσω:

$$P(y = 1|\mathbf{x}) = \frac{1}{1 + e^{-(\mathbf{w}^T \mathbf{x} + b)}} \quad (4.6)$$

με κανονικοποίηση L2:

$$\min_{\mathbf{w}, b} \left[C \sum_{i=1}^n \log(1 + e^{-y_i(\mathbf{w}^T \mathbf{x}_i + b)}) + \frac{1}{2} \|\mathbf{w}\|_2^2 \right] \quad (4.7)$$

όπου $C = 1,0$ ελέγχει την ισχύ της κανονικοποίησης.

Μηχανή Υποστήριξης Διανυσμάτων

Ο πυρήνας RBF SVM μαθαίνει ένα μη γραμμικό όριο απόφασης μέσω:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (4.8)$$

όπου $\gamma = \frac{1}{n_{\text{features}} \cdot \text{Var}(\mathbf{X})}$ (αυτόματη κλιμάκωση).

Random Forest

Το Random Forest συγκεντρώνει προβλέψεις από 100 δέντρα αποφάσεων:

$$\hat{y} = \frac{1}{N_{\text{trees}}} \sum_{t=1}^{N_{\text{trees}}} \hat{y}_t(\mathbf{x}) \quad (4.9)$$

Κάθε δέντρο εκπαιδεύεται σε ένα τυχαίο δείγμα των δεδομένων (bootstrap) και σε κάθε διαχωρισμό χρησιμοποιεί ένα τυχαίο υποσύνολο χαρακτηριστικών.

Το μέγιστο βάθος 10 επιλέχθηκε ώστε να περιοριστεί η υπερπροσαρμογή (overfitting), ιδιαίτερα λόγω του μικρού μεγέθους των συνόλων δεδομένων.

Gradient Boosting

Το Gradient Boosting δημιουργεί το μοντέλο βήμα-βήμα, όπου κάθε νέο δέντρο προσπαθεί να διορθώσει τα λάθη που έκαναν τα προηγούμενα δέντρα [21]:

$$F_m(\mathbf{x}) = F_{m-1}(\mathbf{x}) + \eta \cdot h_m(\mathbf{x}) \quad (4.10)$$

όπου F_m είναι το σύνολο μετά από m στάδια, h_m είναι ο αδύναμος μαθητής (δέντρο αποφάσεων) προσαρμοσμένος στην αρνητική κλίση της συνάρτησης απώλειας και $\eta = 0,1$ είναι ο ρυθμός μάθησης. Ο ρυθμός μάθησης μειώνει τη συμβολή κάθε δέντρου, παρέχοντας αποτέλεσμα κανονικοποίησης.

XGBoost

Το XGBoost [22] είναι μια βελτιωμένη εκδοχή του Gradient Boosting, η οποία προσθέτει κανονικοποίηση L1 και L2 στα βάρη των φύλλων των δέντρων, ώστε να μειώνει την υπερπροσαρμογή και να βελτιώνει τη γενίκευση.

$$\mathcal{L}(\phi) = \sum_{i=1}^n l(\hat{y}_i, y_i) + \sum_{k=1}^K \Omega(f_k), \quad \text{where } \Omega(f) = \gamma T + \frac{1}{2} \lambda \|\mathbf{w}\|^2 \quad (4.11)$$

Εδώ T είναι ο αριθμός των φύλλων, $\mathbf{w}$ είναι το διάνυσμα των βαρών φύλλων και γ, λ είναι παράμετροι κανονικοποίησης. Αυτή η κανονικοποίηση βοηθά στην αποφυγή της υπερπροσαρμογής, η οποία είναι ιδιαίτερα σημαντική για σύνολα δεδομένων μικρού μεγέθους.

4.3.2 Στάθμιση βαρύτητας κλάσης

Η ανισορροπία κλάσης αντιμετωπίζεται μέσω της παραμέτρου `class_weight`:

```
1 # Χωρίς στάθμιση βασική ( συνθήκη)
2 class_weight = None
3
4 # Με στάθμιση ισορροπημένη ( συνθήκη)
5 class_weight = "balanced" #  $w_k = \frac{n_{\text{samples}}}{n_{\text{classes}} \cdot n_k}$ 
```

Όταν `class_weight="balanced"`, οι βαρύτητες των δειγμάτων υπολογίζονται ως εξής:

$$w_k = \frac{n_{\text{samples}}}{n_{\text{classes}} \cdot n_k} \quad (4.12)$$

όπου n_k είναι ο αριθμός των δειγμάτων στην κλάση k . Αυτό εξασφαλίζει ότι τα σφάλματα της μειοψηφικής κλάσης σταθμίζονται περισσότερο κατά τη διάρκεια της εκπαίδευσης.

Τρία από τα πέντε μοντέλα (Λογιστική Παλινδρόμηση, SVM, Random Forest) υποστηρίζουν εγγενώς την παράμετρο `class_weight` μέσω του scikit-learn. Οι δύο

ταξινομητές ενίσχυσης (Gradient Boosting και XGBoost) δεν υποστηρίζουν εγγενώς το `class_weight="balanced"`. Ωστόσο, δεδομένου ότι η ήπια ανισορροπία κλάσεων (1,3:1) δεν απαιτούσε επαναστάθμιση στην πράξη (βλ. Κεφάλαιο 6), αυτή η διαφορά δεν έχει καμία επίδραση στο σχεδιασμό του πειράματος.

4.4 Αρχιτεκτονική ML Pipeline

4.4.1 Δομή Pipeline

Όλα τα μοντέλα χρησιμοποιούν ένα τυποποιημένο scikit-learn Pipeline:

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3
4 pipeline = Pipeline([
5     ('scaler', StandardScaler()),
6     ('classifier', Model(class_weight=..., random_state=42))
7 ])
```

Αυτό εξασφαλίζει ότι η κλιμάκωση χαρακτηριστικών εφαρμόζεται με συνέπεια και αποτρέπει τη διαρροή δεδομένων.

4.4.2 Τυποποίηση χαρακτηριστικών

Τα χαρακτηριστικά κανονικοποιούνται ώστε να έχουν μέση τιμή 0 και τυπική απόκλιση 1 (StandardScaler).

Η κανονικοποίηση υπολογίζεται μόνο στα δεδομένα εκπαίδευσης μέσα σε κάθε διαχωρισμό του k-fold cross-validation, ώστε να μη χρησιμοποιούνται πληροφορίες από το test set και να αποφεύγεται η διαρροή δεδομένων.

4.5 Πλαίσιο αξιολόγησης

4.5.1 Στρατηγική Cross-Validation

Σε αυτή τη εργασία, η **διασταυρούμενη επικύρωση K -fold αποτελεί την κύρια στρατηγική αξιολόγησης**: το μοντέλο εκπαιδεύεται σε $K - 1$ folds και αξιολογείται στο εναπομείναν fold, το οποίο περιλαμβάνει μόνο δείγματα που δεν έχουν χρησιμοποιηθεί ούτε στην εκπαίδευση ούτε στην εξόρυξη χαρακτηριστικών [16]. Η διαδικασία επαναλαμβάνεται $K = 5$ φορές, παρέχοντας πέντε ανεξάρτητες εκτιμήσεις

της απόδοσης γενίκευσης. Δεν χρησιμοποιήθηκε ξεχωριστό σύνολο δοκιμής, καθώς με μόνο $n = 37$ υποκείμενα (σύνολο δεδομένων A), η δέσμευση ακόμη και του 20% για test set θα οδηγούσε σε περίπου επτά υποκείμενα δοκιμής ανά διαχωρισμό σε επίπεδο υποκειμένου, αριθμός ανεπαρκής για σταθερή εκτίμηση.

Η 5-fold CV χρησιμοποιείται αποκλειστικά ως **μηχανισμός αξιολόγησης** και όχι ως μηχανισμός ρύθμισης. Έτσι αποφεύγεται οποιοσδήποτε κίνδυνος προσαρμογής των υπερπαραμέτρων στα δεδομένα αξιολόγησης.

Απαιτήθηκαν διαφορετικές στρατηγικές επικύρωσης για κάθε σύνολο δεδομένων, λόγω των δομικών διαφορών που παρουσιάζουν.

Σύνολο δεδομένων	Στρατηγική	Πτυχές	Ομαδοποίηση
Σύνολο δεδομένων A (MDVR-KCL)	Ομαδοποιημένο στρωματοποιημένο	5	Ανά subject_id
Σύνολο δεδομένων B (PD Speech)	Στρωματοποιημένο	5	Καμία (μη διαβ

Πίνακας 4.6: Στρατηγικές διασταυρούμενης επικύρωσης

Σύνολο δεδομένων A: Ομαδοποιημένη διασταυρούμενη επικύρωση

Για το σύνολο δεδομένων A (MDVR-KCL), υπάρχουν πολλές εγγραφές από το ίδιο άτομο. Για να μην υπάρξει διαρροή δεδομένων, έγινε διαχωρισμός σε επίπεδο υποκειμένου. Αυτό σημαίνει ότι:

- Όλες οι εγγραφές του ίδιου ατόμου μπαίνουν στο ίδιο fold
- Υπάρχει περίπου ισορροπία μεταξύ των κλάσεων
- Το μοντέλο δεν βλέπει ποτέ δεδομένα από άτομα που βρίσκονται στο σύνολο δοκιμής

Έτσι προσομοιώνεται μια ρεαλιστική κατάσταση, όπου το μοντέλο αξιολογείται σε νέους ομιλητές.

Σύνολο δεδομένων B: Τυπική cross-validation

Στο σύνολο δεδομένων B δεν υπάρχουν αναγνωριστικά υποκείμενων. Για αυτό χρησιμοποιήθηκε τυπική 5-fold cross-validation. Ωστόσο, τα αποτελέσματα μπορεί να είναι πιο αισιόδοξα, αν δείγματα του ίδιου ατόμου βρίσκονται σε διαφορετικά folds.

4.5.2 Μετρήσεις αξιολόγησης

Υπολογίστηκαν πέντε βασικές μετρήσεις ταξινόμησης σε κάθε fold:

Μέτρηση	Τύπος	Ερμηνεία
Ακρίβεια	$\frac{TP+TN}{TP+TN+FP+FN}$	Ποσοστό σωστών προβλέψεων συνολικά
Προβλεψιμότητα	$\frac{TP}{TP+FP}$	Από τις προβλέψεις PD, πόσες ήταν σωστές
Ανάκληση	$\frac{TP}{TP+FN}$	Από τα πραγματικά PD, πόσα βρέθηκαν σωστά
Βαθμολογία F1	$\frac{2 \cdot P \cdot R}{P+R}$	Ισορροπία μεταξύ προβλεψιμότητας και ανάκλησης
ROC-AUC	$\int_0^1 \text{TPR}(t) d\text{FPR}(t)$	Ικανότητα διάκρισης ανεξάρτητα από threshold

Πίνακας 4.7: Μετρήσεις αξιολόγησης

Κύρια μέτρηση: Επιλέχθηκε το ROC-AUC γιατί:

- δεν εξαρτάται από ένα συγκεκριμένο threshold,
- είναι πιο σταθερό όταν οι κλάσεις δεν είναι ισορροπημένες,
- έχει σαφή ερμηνεία (πιθανότητα ένας τυχαίος PD να έχει υψηλότερη βαθμολογία από έναν τυχαίο HC).

Κεφάλαιο 5

Σχεδιασμός πειράματος

5.1 Ερευνητικά ερωτήματα

Τα πειράματα εξετάζουν τα παρακάτω ερωτήματα:

- RQ1:** Πόσο καλά αποδίδουν τα κλασικά μοντέλα ML στην αναγνώριση PD από φωνητικά χαρακτηριστικά;
- RQ2:** Βελτιώνεται η απόδοση όταν αυξάνονται τα χαρακτηριστικά από 47 σε 78;
- RQ3:** Βοηθά η ισορροπημένη στάθμιση κλάσεων σε μη ισορροπημένα δεδομένα;
- RQ4:** Υπάρχουν διαφορές στα αποτελέσματα μεταξύ του συνόλου δεδομένων A (CV σε επίπεδο υποκειμένου) και του συνόλου δεδομένων B (τυπικό CV);
- RQ5:** Υπάρχει διαφορά στην απόδοση μεταξύ ανάγνωσης και αυθόρμητης ομιλίας;

5.2 Πειραματικός πίνακας

5.2.1 $2 \times 2 \times 5$ Παραγοντικός σχεδιασμός

Ο σχεδιασμός περιλαμβάνει τρεις παράγοντες:

1. **Σύνολο χαρακτηριστικών:** 47 (baseline) ή 78 (extended)
2. **Στάθμιση κλάσεων:** χωρίς ή με ισορροπημένη στάθμιση
3. **Μοντέλο:** LR, SVM (RBF), RF, Gradient Boosting, XGBoost

Συνολικά: $2 \times 2 \times 5 = 20$ συνθήκες για κάθε dataset/εργασία.

ID	Χαρακτηριστικά	Στάθμιση	Μοντέλα	Έξοδος
C1	47	Καμία	LR, SVM, RF, GB, XGB	baseline/baseline/
C2	78	Καμία	LR, SVM, RF, GB, XGB	baseline/extended/
C3	47	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/baseline/
C4	78	Ισορροπημένη	LR, SVM, RF, GB, XGB	weighted/extended/

Πίνακας 5.1: Πειραματικές συνθήκες (4 συνθήκες $\times$ 5 μοντέλα = 20). Σημείωση: η στάθμιση εφαρμόζεται σε LR, SVM και RF.

5.2.2 Συνολικές πειραματικές εκτελέσεις

Dataset/Εργασία	Συνθήκες	Μοντέλα	CV Folds	Σύνολο
Dataset A - ReadText	4	5	5	100
Dataset A - SpontaneousDialogue	4	5	5	100
Dataset B - PD Speech	4	5	5	100
Σύνολο				300

Πίνακας 5.2: Συνολικός αριθμός πειραμάτων

5.3 Πειραματικά πρωτόκολλα και αναπαραγωγιμότητα

Χρησιμοποιήθηκε 5-fold cross-validation (σε επίπεδο υποκειμένου για το Dataset A και στρωματοποιημένο για το Dataset B). Όλα τα πειράματα εκτελέστηκαν με `random_state=42` για αναπαραγωγιμότητα.

Τα αποτελέσματα του Dataset B πρέπει να εξετάζονται με προσοχή λόγω της έλλειψης αναγνωριστικών υποκειμένων (βλ. ενότητα 8.1). Οι περιορισμοί παρουσιάζονται στο κεφάλαιο 8.

Κεφάλαιο 6

Αποτελέσματα

6.1 Σύνοψη κύριων αποτελεσμάτων

Dataset	Καλύτερο ROC-AUC	Μοντέλο/Task	Συνθήκη
Dataset A	$0,857 \pm 0,171$	Random Forest / SpontaneousDialogue	Extended (78), u
Dataset A (ReadText)	$0,834 \pm 0,153$	SVM (RBF) / ReadText	Extended (78), u
Dataset B	$0,952 \pm 0,015$	XGBoost	Baseline (47), un

Πίνακας 6.1: Κύρια αποτελέσματα ανά σύνολο δεδομένων

Το Dataset B παρουσιάζει υψηλότερες τιμές και μικρότερη διακύμανση σε σχέση με το Dataset A. Ωστόσο, η σύγκριση πρέπει να ερμηνεύεται με προσοχή λόγω άγνωστης επικάλυψης υποκειμένων (Ενότητα [8.1](#)).

6.2 Επίδραση χαρακτηριστικών και στάθμισης κλάσεων (Dataset A)

6.2.1 Σύγκριση baseline έναντι extended χαρακτηριστικών

Μοντέλο	Δ ROC-AUC ReadText	Δ ROC-AUC SpontaneousDialogue
Λογιστική παλινδρόμηση	−0,019	+0,023
SVM (RBF)	+0,220	+0,053
Random Forest	+0,232	+0,029
Gradient Boosting	+0,224	+0,023
XGBoost	+0,166	−0,036

Πίνακας 6.2: Επίδραση feature extension (78 έναντι 47 χαρακτηριστικών) στο Dataset A

Το feature extension συνδέεται με ουσιαστική βελτίωση στο ReadText, ενώ στο SpontaneousDialogue η μεταβολή είναι μικρότερη και model-dependent.

6.2.2 Σύνοψη επίδρασης class weighting

Task	Δ ROC-AUC RF (baseline)	Δ ROC-AUC RF (extended)
ReadText	+0,097	−0,017
SpontaneousDialogue	−0,001	−0,034

Πίνακας 6.3: Επίδραση class weighting στο Random Forest (Dataset A)

Η στάθμιση κλάσεων δεν παρείχε σταθερό όφελος στις παρούσες συνθήκες, ιδιαίτερα όταν χρησιμοποιήθηκαν extended χαρακτηριστικά.


6.3 Σταθερότητα και διακύμανση

Μετρική	Dataset A	Dataset B
ROC-AUC std	$\pm 0,15-0,30$	$\pm 0,01-0,03$
Accuracy std	$\pm 0,14-0,18$	$\pm 0,008-0,024$
F1 std	$\pm 0,21-0,39$	$\pm 0,006-0,015$


Πίνακας 6.4: Σύγκριση διακύμανσης μεταξύ Dataset A και Dataset B

Η υψηλή διακύμανση στο Dataset A είναι συμβατή με το μικρό μέγεθος δείγματος ($n = 37/36$) και απαιτεί συντηρητική ερμηνεία των διαφορών μεταξύ μοντέλων.


6.4 Οπτική επιβεβαίωση αποτελεσμάτων



Σχήμα 6.1: ROC curves για ReadText (Dataset A, extended, grouped 5-fold CV).



Σχήμα 6.2: ROC curves για SpontaneousDialogue (Dataset A, extended, grouped 5-fold CV).



Σχήμα 6.3: ROC curves για Dataset B (stratified 5-fold CV). Τα αποτελέσματα ενδέχεται να είναι αισιόδοξα λόγω άγνωστης επικάλυψης υποκειμένων μεταξύ folds.

6.5 Παραπομπή σε πλήρη αποτελέσματα

Οι αναλυτικοί πίνακες για όλες τις συνθήκες (Condition 1–4, ανά task και ανά μοντέλο) παρατίθενται στο Παράρτημα B. Η πλήρης κατάταξη σημαντικότητας χαρακτηριστικών παρατίθεται στο Παράρτημα A.

Κεφάλαιο 7

Συζήτηση

7.1 Ερμηνεία βασικών ευρημάτων

Τα αποτελέσματα του Κεφαλαίου 6 υποδηλώνουν ότι η επίδοση εξαρτάται κυρίως από τρεις παράγοντες: (i) το είδος χαρακτηριστικών, (ii) το speech task και (iii) το πρωτόκολλο επικύρωσης. Η καλύτερη επίδοση στο Dataset A ($0,857 \pm 0,171$ ROC-AUC) παρατηρήθηκε με Random Forest και extended χαρακτηριστικά, ενώ η διακύμανση παρέμεινε υψηλή, κάτι αναμενόμενο για μικρό δείγμα.

7.1.1 Επέκταση χαρακτηριστικών

Η επέκταση από 47 σε 78 χαρακτηριστικά βελτίωσε κυρίως το ReadText και πιο ήπια το SpontaneousDialogue. Αυτό υποδηλώνει ότι στη δομημένη ομιλία τα πρόσθετα φασματικά/δυναμικά χαρακτηριστικά προσθέτουν διακριτική πληροφορία που δεν καλύπτεται από το baseline σύνολο.

7.1.2 Στάθμιση κλάσεων

Η επιλογή `class_weight=‘balanced’` δεν παρουσίασε σταθερό όφελος. Σε αρκετές συνθήκες οι διαφορές ήταν μικρές ή αρνητικές, γεγονός συμβατό με την ήπια ανισορροπία του Dataset A και την υψηλή μεταβλητότητα fold-to-fold.

7.1.3 Ιεραρχία μοντέλων και σταθερότητα

Το Random Forest εμφάνισε τη πιο σταθερή συμπεριφορά στις περισσότερες ρυθμίσεις, ενώ τα γραμμικά ή περισσότερο ευαίσθητα μοντέλα εμφάνισαν μεγαλύτερη αστάθεια

σε μικρά folds. Συνεπώς, οι διαφορές πρέπει να διαβάζονται ως τάσεις και όχι ως οριστικές κατατάξεις, ειδικά όταν τα διαστήματα αβεβαιότητας επικαλύπτονται.

7.2 Σύγκριση με προηγούμενη βιβλιογραφία

Η παρούσα μελέτη είναι μεθοδολογικά συντηρητική σε σύγκριση με συχνές πρακτικές της βιβλιογραφίας: χρησιμοποιεί grouped stratified CV στο Dataset A, διαχωρίζει ρητά τα speech tasks και αναφέρει συστηματικά $\text{mean} \pm \text{std}$ για όλες τις συνθήκες. Αυτές οι επιλογές τείνουν να αποφεύγουν αισιόδοξες εκτιμήσεις και να βελτιώνουν την αναπαραγωγιμότητα.

Οι απόλυτες τιμές ROC-AUC είναι συγκρίσιμες με αναφορές κλασικών μελετών, αλλά η άμεση αντιπαραβολή παραμένει περιορισμένη λόγω διαφορών σε datasets, features και validation protocols.

7.3 Ερμηνεία σημαντικότητας χαρακτηριστικών

Τα μοτίβα σημαντικότητας έδειξαν εξάρτηση από το task:

- Στο ReadText, χαρακτηριστικά που σχετίζονται με θεμελιώδη συχνότητα και σταθερότητα φωνής εμφανίστηκαν συχνότερα στις κορυφαίες θέσεις.
- Στο SpontaneousDialogue, αυξήθηκε η συνεισφορά MFCC και μέτρων perturbation, υποδηλώνοντας εντονότερη πληροφορία φασματικής μεταβλητότητας.
- Στο Dataset B, τα κυρίαρχα χαρακτηριστικά περιλαμβάνουν εξειδικευμένες αναπαραστάσεις σήματος, γεγονός που δυσκολεύει την άμεση αντιστοίχιση με πιο απλά κλινικά pipelines.

Η πλήρης κατάταξη χαρακτηριστικών δίνεται στο Παράρτημα [A](#).

7.4 Μεθοδολογικές συνέπειες

Τα ευρήματα υποστηρίζουν τρεις πρακτικές για μελλοντικές μελέτες:

1. χρήση grouped CV όταν υπάρχουν πολλαπλές εγγραφές ανά υποκείμενο,
2. συστηματική αναφορά διακύμανσης και όχι μόνο καλύτερων τιμών,
3. διάκριση μεταξύ ReadText και SpontaneousDialogue αντί για σιωπηρή ενοποίηση.

Στο πλαίσιο αυτό, τα αποτελέσματα του Dataset B πρέπει να ερμηνεύονται ως δυνητικά αισιόδοξα λόγω του περιορισμού που αναφέρεται στην Ενότητα [8.1](#).

Κεφάλαιο 8

Περιορισμοί και απειλές για την εγκυρότητα

8.1 Περιορισμοί δεδομένων και δειγματοληψίας

Ο βασικός περιορισμός της μελέτης είναι η ταυτόχρονη παρουσία μικρού δείγματος στο Dataset A και απουσίας αναγνωριστικών υποκειμένων στο Dataset B.

Πίνακας 8.1: Κρίσιμοι περιορισμοί ανά σύνολο δεδομένων

Σύνολο	Περιορισμός	Επίπτωση
Dataset A (ReadText/SpontaneousDialogue)	37/36 υποκείμενα, περίπου 7–8 ανά fold, ήπια ανισορροπία κλάσεων	Αυξημένη διακύμανση fold-to-fold, περιορισμένη ισχύς για μικρές διαφορές, προσεκτική ερμηνεία γενίκευσης
Dataset B (PD Speech Features)	756 δείγματα χωρίς IDs υποκειμένων, έντονη ανισορροπία (74,6% PD)	Πιθανή επικάλυψη train-test στο ίδιο άτομο, δυνητικά αισιόδοξη εκτίμηση απόδοσης, δυσκολότερη σύγκριση με Dataset A

Προειδοποίηση: Τα αποτελέσματα του Dataset B μπορεί να είναι αισιόδοξα, επειδή δεν είναι γνωστό αν υπάρχει επικάλυψη υποκειμένων μεταξύ των folds. Η έντονη ανισορροπία κλάσεων δυσκολεύει επιπλέον την ερμηνεία.

Η άμεση σύγκριση μεταξύ Dataset A και Dataset B πρέπει να γίνεται με προσοχή, καθώς διαφοροποιούνται ταυτόχρονα η στρατηγική cross-validation, το μέγεθος δείγματος, το είδος ομιλίας και το επίπεδο ανισορροπίας.

8.2 Μεθοδολογικοί και τεχνικοί περιορισμοί

8.2.1 Επιλογές μοντελοποίησης και ρύθμισης

Η μελέτη χρησιμοποίησε προεπιλεγμένες ρυθμίσεις sklearn, με σταθερό random seed και έλεγχο στάθμισης κλάσεων. Η επιλογή αυτή ενισχύει αναπαραγωγιμότητα και δίκαιη σύγκριση μοντέλων, αλλά πιθανόν υποεκτιμά το μέγιστο εφικτό επίπεδο απόδοσης.

Η μη χρήση nested CV για εκτενή ρύθμιση υπερπαραμέτρων είναι συνειδητή: με τόσο μικρό δείγμα στο Dataset A, τα εσωτερικά folds θα ήταν πολύ μικρά και ιδιαίτερα ασταθή. Η αιτιολόγηση της στρατηγικής cross-validation παραμένει στην Ενότητα [4.5.1](#).

8.2.2 Περιορισμοί εξαγωγής χαρακτηριστικών

Το σύνολο χαρακτηριστικών καθορίστηκε εκ των προτέρων από τη βιβλιογραφία (47 baseline, 78 extended), χωρίς διαδικασία επιλογής χαρακτηριστικών ή διερεύνηση εναλλακτικών μετασχηματισμών. Επιπλέον, η εξαγωγή βασίζεται σε υπόθεση επαρκούς ποιότητας ηχογράφησης, η οποία δεν είναι πλήρως ελέγξιμη για το Dataset B.

8.2.3 Εξωτερική επικύρωση και γενίκευση

Όλα τα αποτελέσματα βασίζονται σε εσωτερική 5-fold διασταυρούμενη επικύρωση, χωρίς ανεξάρτητο εξωτερικό test set. Συνεπώς, η γενίκευση σε άλλες συσκευές, περιβάλλοντα, γλώσσες ή χρονικά σημεία παραμένει ανοικτό ερευνητικό ερώτημα.

8.3 Απειλές για την εγκυρότητα

Πίνακας 8.2: Σύνοψη απειλών εγκυρότητας και μετριάσμών

Τύπος εγκυρότητας	Κύριες απειλές	Μέτρα μετριάσμού
Εσωτερική	Διαρροή υποκειμένου (Dataset B), θόρυβος ετικέτας, σφάλματα προεπεξεργασίας	GroupedStratifiedKFold στο Dataset A, σταθερό RANDOM_SEED=42, τυποποιημένη κανονικοποίηση ήχου και έλεγχοι pipeline
Εξωτερική	Μεροληψία πληθυσμού, μεταβλητότητα συνθηκών εγγραφής, άγνωστη χρονική σταθερότητα	Διαφανής αναφορά περιορισμών και συντηρητική ερμηνεία αποτελεσμάτων

Συνολικά, τα ευρήματα είναι χρήσιμα ως αναπαραγώγιμη ερευνητική βάση και όχι ως οριστικό συμπέρασμα κλινικής γενίκευσης.

Κεφάλαιο 9

Συμπέρασμα

9.1 Περίληψη

Η εργασία διερεύνησε την ταξινόμηση PD έναντι HC από φωνητικά χαρακτηριστικά, με έμφαση στη μεθοδολογική αυστηρότητα (ομαδοποιημένη CV όπου απαιτείται, σταθερές παράμετροι, πλήρης αναφορά διακύμανσης). Τα αποτελέσματα δείχνουν ότι η ταξινόμηση είναι εφικτή, αλλά η σταθερότητα εξαρτάται έντονα από το μέγεθος δείγματος, το είδος ομιλίας και το πρωτόκολλο επικύρωσης.

9.2 Κύριες συνεισφορές

1. **Αυστηρό πρωτόκολλο αξιολόγησης:** εφαρμογή grouped stratified 5-fold CV για αποφυγή διαρροής υποκειμένων στο Dataset A.
2. **Συστηματική σύγκριση χαρακτηριστικών:** αξιολόγηση baseline (47) και extended (78) συνόλων με κοινό πειραματικό σχεδιασμό.
3. **Αναπαραγωγιμότητα:** σταθερός random seed, καθορισμένες παράμετροι και ενιαίο workflow εξαγωγής/εκπαίδευσης.

9.3 Συνοπτικές απαντήσεις στα ερευνητικά ερωτήματα

- **RQ1 – Απόδοση κλασικών μοντέλων:** Η καλύτερη επίδοση στο Dataset A έφτασε ROC-AUC $0,857 \pm 0,171$ (Random Forest, extended, SpontaneousDialogue), με εμφανή μεταβλητότητα λόγω μικρού δείγματος.

- **RQ2 – Επίδραση επέκτασης χαρακτηριστικών:** Η επέκταση 47→78 βελτίωσε ουσιαστικά το ReadText και πιο ήπια το SpontaneousDialogue, δείχνοντας εξάρτηση από το task.
- **RQ3 – Στάθμιση κλάσεων:** Η επιλογή `class_weight=‘balanced’` δεν έδωσε σταθερό και γενικεύσιμο όφελος στις παρούσες ρυθμίσεις.
- **RQ4 – Grouped έναντι τυπικής CV:** Το Dataset B εμφάνισε υψηλότερες και σταθερότερες τιμές, αλλά η απουσία IDs υποκειμένων επιβάλλει προσεκτική ερμηνεία.
- **RQ5 – Διαφορά εργασιών ομιλίας:** Η SpontaneousDialogue παρέμεινε ισχυρή, ενώ το ReadText ωφελήθηκε περισσότερο από την επέκταση χαρακτηριστικών.

9.4 Επιπτώσεις και προτεραιότητες συνέχειας

- **Μεθοδολογική πρακτική:** grouped CV όταν υπάρχουν πολλαπλές εγγραφές ανά υποκείμενο και αναφορά όλων των συνθηκών, όχι μόνο των καλύτερων.
- **Διαχείριση δεδομένων:** τα μελλοντικά datasets πρέπει να περιλαμβάνουν IDs υποκειμένων και μεταδεδομένα συνθηκών εγγραφής.
- **Επόμενα βήματα:** εξωτερική επικύρωση, nested CV για υπερπαραμέτρους, και στοχευμένη επιλογή χαρακτηριστικών.

9.5 Τελική τοποθέτηση

Τα ευρήματα υποστηρίζουν ότι η φωνητική ταξινόμηση PD/HC με κλασικά μοντέλα είναι επιστημονικά τεκμηριώσιμη ως ερευνητική προσέγγιση, όχι όμως έτοιμη για κλινική χρήση. Τα αποτελέσματα πρέπει να ερμηνεύονται με προσοχή δεδομένου του μικρού δείγματος στο Dataset A και της πιθανής αισιοδοξίας στο Dataset B λόγω άγνωστης επικάλυψης υποκειμένων.

Παράρτημα Α

Πίνακες Σημαντικότητας Χαρακτηριστικών

A.1 Επισκόπηση

Το παρόν παράρτημα παρουσιάζει τα 20 σημαντικότερα χαρακτηριστικά για κάθε πειραματική συνθήκη, όπως προκύπτουν από τις εγγενείς μετρικές σημαντικότητας των μοντέλων:

- **Logistic Regression:** Απόλυτες τιμές coefficients
- **Random Forest:** Gini importance (mean decrease in impurity)

A.2 Dataset A — ReadText Task

A.2.1 Random Forest — Top 20 Features


Rank	Feature	Importance	Std
1	f0_max	0.052	0.019
2	delta_mfcc_2_mean	0.039	0.018
3	f3_std	0.038	0.011
4	autocorr_harmonicity	0.038	0.017
5	intensity_mean	0.035	0.021
6	f0_mean	0.032	0.012
7	shimmer_apq3	0.032	0.013
8	mfcc_12_mean	0.031	0.007
9	f1_std	0.031	0.022
10	mfcc_6_mean	0.030	0.024

Πίνακας A.1: Σημαντικότητα χαρακτηριστικών του Random Forest — ReadText (top 10)

A.2.2 Logistic Regression — Top 20 Features

Rank	Feature	Coefficient	Std
1	f0_max	0.754	0.203
2	hnr_mean	0.649	0.178
3	shimmer_apq11	0.553	0.145
4	delta_mfcc_4_mean	0.496	0.163
5	delta_mfcc_2_mean	0.492	0.103
6	delta_mfcc_1_mean	0.474	0.273
7	mfcc_5_mean	0.470	0.127
8	mfcc_4_mean	0.426	0.233
9	mfcc_10_mean	0.418	0.221
10	mfcc_11_mean	0.388	0.192

Πίνακας A.2: Σημαντικότητα χαρακτηριστικών του Logistic Regression — ReadText (top 10)




Σχήμα A.1: Μέγεθος συντελεστών του Logistic Regression (ReadText)

A.2.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.229	0.179
2	mfcc_4_mean	0.084	0.187
3	f1_std	0.080	0.178
4	mfcc_6_mean	0.066	0.143
5	intensity_min	0.064	0.122
6	mfcc_2_mean	0.060	0.133
7	f0_std	0.055	0.081
8	f3_std	0.054	0.070
9	delta_mfcc_10_mean	0.047	0.104
10	delta_mfcc_2_mean	0.041	0.083

Πίνακας Α.3: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — ReadText (top 10)




Σχήμα Α.2: Σημαντικότητα χαρακτηριστικών του Gradient Boosting (ReadText). Το F0 max εμφανίζει ισχυρή κυριαρχία (0.229 ± 0.179), σε συμφωνία με διαταραχές στη ρύθμιση του pitch στην PD.

A.2.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	f0_max	0.083	0.028
2	intensity_min	0.064	0.063
3	f0_mean	0.063	0.044
4	f3_std	0.061	0.044
5	intensity_mean	0.051	0.047
6	delta_mfcc_10_mean	0.041	0.037
7	f1_std	0.041	0.075
8	delta_mfcc_2_mean	0.038	0.028
9	mfcc_3_mean	0.033	0.023
10	mfcc_11_mean	0.031	0.040

Πίνακας A.4: Σημαντικότητα χαρακτηριστικών του XGBoost — ReadText (top 10)



Σχήμα A.3: Σημαντικότητα χαρακτηριστικών του XGBoost (ReadText). Η σημαντικότητα είναι πιο κατανοητή σε σχέση με το Gradient Boosting, με τα χαρακτηριστικά F0 και έντασης να μοιράζονται την κυριαρχία.

A.3 Dataset A — SpontaneousDialogue Task

A.3.1 Random Forest — Top 20 Features


Rank	Feature	Importance	Std
1	mfcc_5_mean	0.080	0.022
2	shimmer_apq11	0.069	0.007
3	delta_mfcc_8_mean	0.051	0.015
4	jitter_local	0.041	0.012
5	delta_mfcc_2_mean	0.040	0.018
6	autocorr_harmonicity	0.037	0.011
7	shimmer_local	0.036	0.017
8	mfcc_1_mean	0.034	0.010
9	f0_std	0.032	0.022
10	f0_mean	0.031	0.013

Πίνακας A.5: Σημαντικότητα χαρακτηριστικών του Random Forest — SpontaneousDialogue (top 10)

A.3.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	mfcc_5_mean	0.722	0.039
2	delta_mfcc_8_mean	0.615	0.121
3	shimmer_apq11	0.559	0.136
4	delta_mfcc_2_mean	0.493	0.196
5	intensity_min	0.459	0.170
6	mfcc_3_mean	0.388	0.271
7	delta_mfcc_11_mean	0.381	0.102
8	delta_mfcc_7_mean	0.380	0.150
9	hnr_mean	0.379	0.175
10	delta_mfcc_1_mean	0.352	0.123

Πίνακας A.6: Σημαντικότητα χαρακτηριστικών του Logistic Regression — SpontaneousDialogue (top 10)




Σχήμα A.4: Μέγεθος συντελεστών του Logistic Regression (Spontaneous Dialogue)

A.3.3 Gradient Boosting — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.342	0.204
2	shimmer_apq11	0.134	0.132
3	delta_mfcc_8_mean	0.086	0.192
4	intensity_min	0.050	0.093
5	shimmer_local	0.050	0.089
6	f1_std	0.040	0.033
7	mfcc_11_mean	0.040	0.089
8	mfcc_10_mean	0.027	0.020
9	mfcc_1_mean	0.024	0.026
10	intensity_max	0.024	0.037

Πίνακας A.7: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — SpontaneousDialogue (top 10)




Σχήμα Α.5: Σημαντικότητα χαρακτηριστικών του Gradient Boosting (Spontaneous Dialogue). Το MFCC-5 (0.342 ± 0.204) κυριαρχεί, αντανακλώντας αλλαγές στο spectral tilt στην αυθόρμητη ομιλία PD.

A.3.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	mfcc_5_mean	0.134	0.059
2	shimmer_apq11	0.104	0.071
3	delta_mfcc_8_mean	0.079	0.052
4	delta_mfcc_2_mean	0.053	0.009
5	mfcc_4_mean	0.035	0.022
6	mfcc_2_mean	0.033	0.022
7	jitter_local	0.032	0.012
8	f0_mean	0.031	0.035
9	shimmer_local	0.031	0.054
10	intensity_max	0.030	0.030

Πίνακας Α.8: Σημαντικότητα χαρακτηριστικών του XGBoost — SpontaneousDialogue (top 10)



Σχήμα A.6: Σημαντικότητα χαρακτηριστικών του XGBoost (Spontaneous Dialogue). Τα MFCC-5 και τα shimmer χαρακτηριστικά κυριαρχούν, σε συμφωνία με τα ευρήματα των RF και GB για αυτό το task.

A.4 Dataset B — PD Speech Features

Το Dataset B περιέχει 752 προεξαγμένα χαρακτηριστικά, συμπεριλαμβανομένων συντελεστών TQWT (Tunable Q-factor Wavelet Transform) που δεν υπάρχουν στο Dataset A. Η σημαντικότητα χαρακτηριστικών παρουσιάζεται για σκοπούς σύγκρισης, αν και η άμεση αντιπαραβολή παραμένει περιορισμένη λόγω διαφορετικών feature spaces.

A.4.1 Random Forest — Top 10 Features

Rank	Feature	Importance	Std
1	std_delta_log_energy	0.013	0.004
2	std_delta_delta_log_energy	0.013	0.003
3	tqwt_entropy_shannon_dec_12	0.012	0.001
4	tqwt_TKEO_std_dec_11	0.010	0.004
5	tqwt_TKEO_mean_dec_12	0.010	0.001
6	mean_MFCC_2nd_coef	0.008	0.003
7	tqwt_entropy_log_dec_11	0.008	0.003
8	tqwt_stdValue_dec_12	0.008	0.003
9	tqwt_stdValue_dec_13	0.008	0.003
10	tqwt_energy_dec_12	0.007	0.003

Πίνακας A.9: Σημαντικότητα χαρακτηριστικών του Random Forest — Dataset B (top 10)


Σημείωση: Οι τιμές σημαντικότητας είναι χαμηλότερες από το Dataset A λόγω του μεγαλύτερου feature space (752 έναντι 47 features), που κατανέμει τη σημαντικότητα πιο ευρέως.

A.4.2 Logistic Regression — Top 10 Features

Rank	Feature	Coefficient	Std
1	tqwt_kurtosisValue_dec_33	0.733	0.161
2	tqwt_entropy_log_dec_33	0.694	0.084
3	mean_MFCC_7th_coef	0.614	0.148
4	std_delta_delta_log_energy	0.588	0.133
5	std_MFCC_2nd_coef	0.567	0.202
6	tqwt_meanValue_dec_16	0.551	0.114
7	tqwt_medianValue_dec_25	0.540	0.209
8	mean_MFCC_3rd_coef	0.538	0.155
9	tqwt_meanValue_dec_22	0.528	0.172
10	std_9th_delta	0.526	0.103

Πίνακας A.10: Σημαντικότητα χαρακτηριστικών του Logistic Regression — Dataset B (top 10)

Παρατήρηση: Τα χαρακτηριστικά TQWT κυριαρχούν στη σημαντικότητα του Dataset B, αντανakλώντας το task παρατεταμένης φώνησης του /a/, όπου η χρονικο-συχνοτική αποσύνθεση συλλαμβάνει λεπτά πρότυπα φωνητικού τρόμου.



Σχήμα A.7: Σημαντικότητα χαρακτηριστικών για το Dataset B (PD Speech Features) — Random Forest και Logistic Regression.

A.4.3 Gradient Boosting — Top 10 Features


Rank	Feature	Importance	Std
1	<code>std_delta_delta_log_energy</code>	0.133	0.035
2	<code>lqwt_TKEO_mean_dec_12</code>	0.030	0.036
3	<code>lqwt_entropy_log_dec_27</code>	0.029	0.008
4	<code>std_7th_delta_delta</code>	0.028	0.005
5	<code>lqwt_energy_dec_27</code>	0.024	0.028
6	<code>lqwt_entropy_log_dec_35</code>	0.023	0.019
7	<code>lqwt_TKEO_std_dec_12</code>	0.023	0.026
8	<code>mean_MFCC_2nd_coef</code>	0.021	0.024
9	<code>lqwt_entropy_log_dec_33</code>	0.021	0.006
10	<code>lqwt_TKEO_std_dec_11</code>	0.020	0.021

Πίνακας A.11: Σημαντικότητα χαρακτηριστικών του Gradient Boosting — Dataset B (top 10)

A.4.4 XGBoost — Top 10 Features

Rank	Feature	Importance	Std
1	tqwt_entropy_log_dec_12	0.024	0.020
2	std_delta_delta_log_energy	0.017	0.006
3	tqwt_TKEO_mean_dec_12	0.016	0.017
4	tqwt_TKEO_std_dec_12	0.013	0.014
5	tqwt_energy_dec_27	0.012	0.024
6	tqwt_TKEO_std_dec_11	0.012	0.010
7	tqwt_entropy_log_dec_16	0.010	0.009
8	tqwt_entropy_log_dec_13	0.009	0.012
9	mean_MFCC_2nd_coef	0.008	0.004
10	tqwt_entropy_shannon_dec_16	0.008	0.011

Πίνακας A.12: Σημαντικότητα χαρακτηριστικών του XGBoost — Dataset B (top 10)



Σχήμα A.8: Σημαντικότητα χαρακτηριστικών για το Dataset B — Gradient Boosting και XGBoost. Τα χαρακτηριστικά ενέργειας/εντροπίας TQWT από ζώνες υψηλής συχνότητας κυριαρχούν και στα δύο μοντέλα.

A.5 Σταθερότητα Χαρακτηριστικών μεταξύ Tasks

Χαρακτηριστικά που εμφανίζονται στο top-10 και για τα δύο tasks (Random Forest) υποδεικνύουν ισχυρή διακριτική ικανότητα σε διαφορετικά speech contexts:

Feature	ReadText Rank	Spontaneous Rank
delta_mfcc_2_mean	2	5
autocorr_harmonicity	4	6
f0_mean	6	10
shimmer (apq3/apq11)	7	2
mfcc_5_mean	–	1
f0_std	–	9

Πίνακας A.13: Σταθερότητα χαρακτηριστικών μεταξύ tasks (Random Forest top-10)


Ερμηνεία: Χαρακτηριστικά που είναι σταθερά σημαντικά και στα δύο tasks (delta_mfcc_2_mean, autocorr_harmonicity, shimmer) πιθανότατα αποτυπώνουν **task-general** acoustic signatures της PD και όχι task-specific artifacts. Η έντονη παρουσία του mfcc_5_mean στο SpontaneousDialogue αλλά όχι στο ReadText μπορεί να αντανακλά διαφορές στην prosodic variability μεταξύ δομημένης ανάγνωσης και φυσικού διαλόγου.

A.6 Ανάλυση Κατηγοριών Χαρακτηριστικών


Συγκεντρωτική παρουσίαση της σημαντικότητας ανά κατηγορία χαρακτηριστικών:

Category	Features	ReadText (%)	Spontaneous (%)
MFCC	13	28.4	32.1
Delta MFCC	13	22.7	25.3
Pitch (F_0)	4	15.2	12.8
Shimmer	5	11.3	14.6
Formants	6	9.8	7.2
Harmonicity	2	6.1	4.3
Other	5	6.5	3.7

Πίνακας A.14: Συγκεντρωτική σημαντικότητα χαρακτηριστικών ανά κατηγορία



(a) ReadText



(b) Spontaneous

Σχήμα Α.9: Σημαντικότητα χαρακτηριστικών συγκεντρωμένη ανά ευρείες ακουστικές κατηγορίες.

Παράρτημα Β

Αναλυτικοί Πίνακες Αποτελεσμάτων

B.1 Επισκόπηση

Το παρόν παράρτημα παρουσιάζει πλήρη αριθμητικά αποτελέσματα για όλες τις πειραματικές συνθήκες, συμπεριλαμβανομένων συνοπτικών στατιστικών και συγκρίσεων μεταξύ συνθηκών.

B.2 Συνθήκη 1: Baseline Features (47) + Unweighted

B.2.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.621 ± 0.058	0.620 ± 0.217	0.550 ± 0.201	0.542 ± 0.099	0.717 ± 0.139
	SVM	0.621 ± 0.106	0.367 ± 0.342	0.317 ± 0.335	0.333 ± 0.333	0.614 ± 0.312
	RF	0.629 ± 0.178	0.450 ± 0.447	0.333 ± 0.408	0.351 ± 0.363	0.590 ± 0.302
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.636 ± 0.135	0.600 ± 0.435	0.333 ± 0.236	0.400 ± 0.253	0.407 ± 0.309
	RF	0.721 ± 0.176	0.633 ± 0.415	0.600 ± 0.435	0.567 ± 0.365	0.828 ± 0.148

Πίνακας B.1: Αποτελέσματα Condition 1 ανά task (Dataset A, baseline features, χωρίς weighting)

B.2.2 Dataset B: PD Speech Features Σύνοψη

Model	Accuracy	Precision	Recall	F1	ROC-AUC
LogisticRegression	0.828 ± 0.008	0.881 ± 0.010	0.890 ± 0.016	0.885 ± 0.006	0.867 ± 0.029
SVM_RBF	0.851 ± 0.024	0.841 ± 0.015	0.986 ± 0.019	0.908 ± 0.015	0.885 ± 0.025
RandomForest	0.882 ± 0.019	0.876 ± 0.012	0.980 ± 0.015	0.925 ± 0.012	0.940 ± 0.013

Πίνακας B.2: Αποτελέσματα Condition 1 (Dataset B, baseline features, χωρίς weighting)

Σημείωση: Το Dataset B εμφανίζει ουσιαστικά υψηλότερη απόδοση και χαμηλότερη διακύμανση από το Dataset A, εύρημα συμβατό με πιθανό optimistic bias λόγω άγνωστης επικάλυψης subjects.

B.3 Συνθήκη 2: Extended Features (78) + Unweighted

B.3.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.253	0.433 ± 0.149	0.475 ± 0.106	0.698 ± 0.132
	SVM	0.786 ± 0.181	0.733 ± 0.435	0.567 ± 0.365	0.634 ± 0.386	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.822 ± 0.166
Spontaneous	LR	0.671 ± 0.199	0.500 ± 0.361	0.600 ± 0.435	0.530 ± 0.377	0.783 ± 0.139
	SVM	0.636 ± 0.089	0.533 ± 0.361	0.400 ± 0.279	0.428 ± 0.258	0.460 ± 0.294
	RF	0.779 ± 0.161	0.683 ± 0.410	0.600 ± 0.435	0.605 ± 0.387	0.857 ± 0.171

Πίνακας B.3: Αποτελέσματα Condition 2 ανά task (Dataset A, extended features, χωρίς weighting)

B.3.2 Βελτίωση έναντι Baseline (Random Forest, Dataset A)

Task	Δ Accuracy	Δ ROC-AUC	Δ Variance
ReadText	+18.9pp	+23.2pp	Reduced ($0.302 \rightarrow 0.166$)
SpontaneousDialogue	+5.8pp	+2.9pp	Increased ($0.148 \rightarrow 0.171$)

Πίνακας B.4: Βελτίωση Condition 2 έναντι Condition 1 (Random Forest)

Παρατήρηση: Το feature extension βελτίωσε αισθητά την απόδοση στο ReadText (+23.2pp ROC-AUC), ενώ στο SpontaneousDialogue παρατηρήθηκαν πιο περιορισμένα

gains (+2.9pp). Αυτό υποδηλώνει ότι τα extended features αποτυπώνουν αποτελεσματικότερα τις δυναμικές της δομημένης ομιλίας σε σύγκριση με την αυθόρμητη ομιλία.

B.4 Συνθήκη 3: Baseline Features (47) + Weighted

B.4.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.596 ± 0.079	0.600 ± 0.235	0.550 ± 0.201	0.528 ± 0.099	0.717 ± 0.139
	SVM	0.704 ± 0.111	0.617 ± 0.371	0.500 ± 0.373	0.519 ± 0.320	0.542 ± 0.312
	RF	0.650 ± 0.148	0.550 ± 0.371	0.400 ± 0.365	0.431 ± 0.306	0.687 ± 0.258
Spontaneous	LR	0.639 ± 0.160	0.469 ± 0.292	0.667 ± 0.408	0.539 ± 0.321	0.760 ± 0.214
	SVM	0.693 ± 0.123	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.423 ± 0.312
	RF	0.693 ± 0.123	0.583 ± 0.373	0.600 ± 0.435	0.538 ± 0.326	0.827 ± 0.133

Πίνακας B.5: Αποτελέσματα Condition 3 ανά task (Dataset A, baseline features, με weighting)

B.4.2 Επίδραση του Weighting (vs Condition 1, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	+2.1pp	+9.7pp	Improved
SpontaneousDialogue	-2.8pp	-0.1pp	Negligible

Πίνακας B.6: Επίδραση του weighting στο Condition 3 έναντι Condition 1 (RF)

Παρατήρηση: Το class weighting βελτίωσε την απόδοση στο ReadText, αλλά είχε αμελητέα επίδραση στο SpontaneousDialogue, γεγονός που υποδηλώνει task-dependent ευαισθησία στον χειρισμό του class imbalance.

B.5 Συνθήκη 4: Extended Features (78) + Weighted

B.5.1 Dataset A: MDVR-KCL Σύνοψη

Task	Model	Accuracy	Precision	Recall	F1	ROC-AUC
ReadText	LR	0.650 ± 0.108	0.650 ± 0.253	0.550 ± 0.201	0.564 ± 0.160	0.698 ± 0.132
	SVM	0.761 ± 0.214	0.700 ± 0.447	0.567 ± 0.365	0.620 ± 0.390	0.834 ± 0.153
	RF	0.818 ± 0.140	0.883 ± 0.162	0.700 ± 0.298	0.746 ± 0.207	0.805 ± 0.182
Spontaneous	LR	0.696 ± 0.179	0.520 ± 0.356	0.667 ± 0.471	0.563 ± 0.381	0.783 ± 0.139
	SVM	0.664 ± 0.167	0.567 ± 0.365	0.600 ± 0.365	0.560 ± 0.318	0.403 ± 0.347
	RF	0.721 ± 0.203	0.653 ± 0.409	0.600 ± 0.435	0.583 ± 0.373	0.823 ± 0.209

Πίνακας B.7: Αποτελέσματα Condition 4 ανά task (Dataset A, extended features, με weighting)

B.5.2 Επίδραση του Weighting (vs Condition 2, Random Forest)

Task	Δ Accuracy	Δ ROC-AUC	Effect
ReadText	0.0pp	-1.7pp	Slight decrease
SpontaneousDialogue	-5.8pp	-3.4pp	Decreased

Πίνακας B.8: Επίδραση του weighting στο Condition 4 έναντι Condition 2 (RF)

Παρατήρηση: Ο συνδυασμός extended features με class weighting δεν βελτίωσε την απόδοση σε σχέση με τη χρήση extended features μόνο. Αυτό υποδηλώνει ότι feature extension και class weighting αντιμετωπίζουν παρόμοιες πτυχές του classification problem, με diminishing returns όταν εφαρμόζονται από κοινού.

B.6 Matrix Σύγκρισης μεταξύ Conditions

B.6.1 Random Forest ROC-AUC ανά Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	0.590 ± 0.302	0.822 ± 0.166
	Weighted	0.687 ± 0.258	0.805 ± 0.182
Spontaneous	Unweighted	0.828 ± 0.148	0.857 ± 0.171
	Weighted	0.827 ± 0.133	0.823 ± 0.209

Πίνακας B.9: Πίνακας σύγκρισης Random Forest ROC-AUC (Dataset A)

B.6.2 Random Forest Accuracy ανά Task

Task		Baseline (47)	Extended (78)
ReadText	Unweighted	$62.9\% \pm 17.8\%$	$81.8\% \pm 14.0\%$
	Weighted	$65.0\% \pm 14.8\%$	$81.8\% \pm 14.0\%$
Spontaneous	Unweighted	$72.1\% \pm 17.6\%$	$77.9\% \pm 16.1\%$
	Weighted	$69.3\% \pm 12.3\%$	$72.1\% \pm 20.3\%$

Πίνακας B.10: Πίνακας σύγκρισης Random Forest Accuracy (Dataset A)

B.6.3 Κύριες Παρατηρήσεις

1. **To feature extension βελτιώνει σταθερά το ReadText:** +23.2pp ROC-AUC (χωρίς weighting)
2. **To SpontaneousDialogue έχει υψηλότερο baseline:** 0.828 vs 0.590 ROC-AUC με baseline features
3. **To class weighting εμφανίζει μικτά αποτελέσματα:** βελτιώνει τη baseline επίδοση στο ReadText αλλά μειώνει την επίδοση με extended features
4. **Υψηλή διακύμανση σε όλα τα settings:** τα standard deviations συχνά υπερβαίνουν το 0.15, αντανακλώντας το μικρό sample size ($n = 37$)


B.7 Σημειώσεις για τη Statistical Significance

Λόγω υψηλών standard deviations (συχνά > 0.15), τα confidence intervals επικαλύπτονται σε πολλές συγκρίσεις. Αυτό περιορίζει τη δυνατότητα για ισχυρούς στατιστικούς


ισχυρισμούς σχετικά με τις διαφορές μεταξύ conditions. Τα αποτελέσματα θα πρέπει να ερμηνεύονται ως **trends** και όχι ως οριστικές κατατάξεις.

B.8 Καμπύλες ROC


Παρουσιάζονται καμπύλες Receiver Operating Characteristic (ROC) για όλους τους πέντε classifiers σε κάθε experimental condition. Οι αχνές καμπύλες αντιστοιχούν σε μεμονωμένα cross-validation folds, ενώ η έντονη καμπύλη αντιστοιχεί στον μέσο όρο των folds με shaded band ± 1 standard deviation. Όλες οι καμπύλες δημιουργήθηκαν με χρήση του extended feature set.



Σχήμα B.1: ROC curves για όλους τους πέντε classifiers στο ReadText task (Dataset A, extended features). Τα shaded bands υποδεικνύουν ± 1 standard deviation στα πέντε cross-validation folds.



Σχήμα B.2: ROC curves για όλους τους πέντε classifiers στο SpontaneousDialogue task (Dataset A, extended features).



Σχήμα Β.3: ROC curves για όλους τους πέντε classifiers στο Dataset B (PD Speech Features). Σημειώνεται ότι subject-level deduplication δεν είναι εφικτό για αυτό το dataset: τα αποτελέσματα ενδέχεται να είναι optimistic λόγω πιθανής επικάλυψης subjects μεταξύ folds.

Παράρτημα C

Εφαρμογή Ερευνητικής Επίδειξης

C.1 Σκοπός και όρια

Το παρόν παράρτημα περιγράφει τη διαδικτυακή εφαρμογή επίδειξης που αναπτύχθηκε για την παρουσίαση της ροής *inference* από φωνητικό δείγμα έως πρόβλεψη. Η εφαρμογή έχει αποκλειστικά ερευνητικό και εκπαιδευτικό χαρακτήρα.

Κρίσιμη διευκρίνιση:

- Δεν αποτελεί κλινικό εργαλείο και δεν χρησιμοποιείται για διάγνωση.
- Οι πιθανότητες εξόδου είναι δείκτες εμπιστοσύνης του μοντέλου, όχι ιατρική απόφαση.
- Δεν χρησιμοποιήθηκε για τον υπολογισμό των μετρικών των Κεφαλαίων 5–6.

C.2 Αρχιτεκτονική

Η εφαρμογή ακολουθεί απλή αρθρωτή αρχιτεκτονική:

Flask διεπαφή -> Inference Adapter -> Πυρήνας ML

- **Flask (app.py):** διαχείριση διαδρομών, μεταφόρτωσης/καταγραφής ήχου και προβολής αποτελεσμάτων.
- **Adapter (inference_adapter.py):** ενιαίο σημείο ελέγχου για προεπεξεργασία ήχου, κλήση μοντέλου και μορφοποίηση εξόδου.
- **Πυρήνας μοντέλου:** χρήση των ίδιων modules εξαγωγής χαρακτηριστικών και πρόβλεψης με τα πειράματα.

- **Κανονικοποίηση ήχου (`audio_utils.py`):** μετατροπή κάθε εισόδου σε mono 22,050 Hz PCM-16 WAV.

Αμετάβλητες αρχές:

- Αλλαγή μοντέλου/feature set μέσω ρυθμίσεων, χωρίς τροποποίηση των Flask routes.
- Κοινή βάση κώδικα με το πειραματικό pipeline για συνέπεια αποτελεσμάτων.

C.3 Ροή χρήσης

Υποστηρίζονται δύο τρόποι εισόδου: μεταφόρτωση αρχείου και άμεση καταγραφή από μικρόφωνο.

The screenshot shows a web application titled "Parkinson's Voice Classification" with the subtitle "MSc Thesis Research Demonstration". A yellow warning box states: "Research Demonstration Only. This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use." Below this, there are two tabs: "Upload File" (selected) and "Record Audio". The "Upload File" tab contains the "Upload Voice Recording" section, which instructs users to upload an audio file of a ReadText speech task. It includes a text input for the audio file, a "Choose File" button, and a status "No file chosen". Below this is a large blue "Analyze Recording" button. At the bottom, the "Current Model Configuration" is displayed in a table:

Model:	RandomForest
Task:	ReadText
Features:	baseline (47)
Training Samples:	37

At the very bottom, there is a link "About this project".

Σχήμα C.1: Διεπαφή μεταφόρτωσης ηχητικού αρχείου.

Parkinson's Voice Classification

MSc Thesis Research Demonstration

⚠ **Research Demonstration Only.** This application is part of an MSc thesis and is not intended for medical diagnosis or clinical use.

Upload File

Record Audio

Record Voice Sample

ReadText Task Prompt

"The quick brown fox jumps over the lazy dog. Peter Piper picked a peck of pickled peppers. How much wood would a woodchuck chuck if a woodchuck could chuck wood?"

Read this text clearly and naturally at a comfortable pace.

● Recording... 1s

🎤 Start Recording

🛑 Stop Recording

Current Model Configuration


Model:	RandomForest
Task:	ReadText
Features:	baseline (47)
Training Samples:	37

Σχήμα C.2: Διεπαφή άμεσης καταγραφής ήχου μέσω φυλλομετρητή.

Για κάθε είσοδο εκτελούνται τα ίδια βήματα:

1. Κανονικοποίηση ήχου.
2. Εξαγωγή χαρακτηριστικών (47 ή 78).
3. Φόρτωση εκπαιδευμένου μοντέλου και πρόβλεψη.
4. Προβολή ετικέτας, πιθανοτήτων και μεταδεδομένων ανάλυσης.

C.4 Ερμηνεία αποτελέσματος



Σχήμα C.3: Παράδειγμα οθόνης αποτελέσματος της εφαρμογής επίδειξης.

Η οθόνη αποτελέσματος εμφανίζει:

- δυαδική πρόβλεψη (PD/HC),
- πιθανότητες ανά κλάση,
- βασικά χαρακτηριστικά και μεταδεδομένα,
- συνολική σημαντικότητα χαρακτηριστικών του μοντέλου.

Περιορισμοί ερμηνείας:

- Πιθανότητα μοντέλου δεν ισοδυναμεί με πιθανότητα νόσου.
- Η συμπεριφορά αναφέρεται σε δεδομένα παρόμοια με το training distribution.
- Δεν υπάρχει κλινική επικύρωση ή κανονιστική έγκριση.

C.5 Αναπαραγωγικότητα και συνέπεια

Η συνέπεια με τα πειράματα διασφαλίζεται από:

1. κοινά modules εξαγωγής χαρακτηριστικών,
2. φόρτωση των ίδιων `.joblib` artifacts,
3. ρυθμίσεις μέσω `config.py`,
4. μοντέλα εκπαιδευμένα με σταθερό random seed.

C.6 Σύνοψη

Η εφαρμογή λειτουργεί ως εργαλείο παρουσίασης της ερευνητικής ροής και της λειτουργικότητας του *inference* pipeline. Δεν αποτελεί διαγνωστικό σύστημα και δεν πρέπει να χρησιμοποιείται για κλινικές αποφάσεις.

Βιβλιογραφία

- [1] A. K. Ho, R. Iannsek, C. Marigliani, J. L. Bradshaw, and S. Gates, “Speech impairment in a large sample of patients with Parkinson’s disease,” *Behavioural Neurology*, vol. 11, no. 3, pp. 131–137, 1999.
- [2] B. T. Harel, M. S. Cannizzaro, and P. J. Snyder, “Acoustic characteristics of Parkinsonian speech: a potential biomarker of early disease progression and treatment,” *Journal of Neurolinguistics*, vol. 17, no. 6, pp. 439–453, 2004.
- [3] M. A. Little, P. E. McSharry, E. J. Hunter, J. Spielman, and L. O. Ramig, “Suitability of dysphonia measurements for telemonitoring of Parkinson’s disease,” *IEEE Transactions on Biomedical Engineering*, vol. 56, no. 4, pp. 1015–1022, 2009.
- [4] A. Tsanas, M. A. Little, P. E. McSharry, and L. O. Ramig, “Accurate telemonitoring of Parkinson’s disease progression by noninvasive speech tests,” *IEEE Transactions on Biomedical Engineering*, vol. 57, no. 4, pp. 884–893, 2010.
- [5] J. R. Duffy, *Motor speech disorders: Substrates, differential diagnosis, and management*, 3rd ed. Elsevier Health Sciences, 2012.
- [6] H. Sedigh Malekroodi, B.-i. Lee, and M. Yi, “Voice-based detection of Parkinson’s disease using machine and deep learning approaches: A systematic review,” *Bioengineering*, vol. 12, no. 11, p. 1279, 2025.
- [7] D. Xavier, V. Felizardo, B. Ferreira, H. Zacarias, M. Pourvabab, L. Souza-Pereira, and N. M. Garcia, “Voice analysis in Parkinson’s disease—a systematic literature review,” *Artificial Intelligence in Medicine*, vol. 163, p. 103109, 2025.
- [8] H. Wright and V. Aharonson, “Vocal feature changes for monitoring Parkinson’s disease progression—a systematic review,” *Brain Sciences*, vol. 15, no. 3, p. 320, 2025.
- [9] L. O. Ramig, C. Fox, and S. Sapir, “Speech treatment for Parkinson’s disease,” *Expert Review of Neurotherapeutics*, vol. 8, no. 2, pp. 297–309, 2008.

- [10] S. Skodda, W. Visser, and U. Schlegel, “Intonation and speech rate in Parkinson’s disease: General and dynamic aspects and responsiveness to levodopa admission,” *Journal of Voice*, vol. 25, no. 4, pp. e199–e205, 2011.
- [11] J. R. Orozco-Arroyave, J. D. Arias-Londoño, J. F. V. Bonilla, M. C. Gonzalez-Rativa, and E. Nöth, “Automatic detection of Parkinson’s disease in running speech spoken in three different languages,” in *IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2016, pp. 4785–4789.
- [12] M. A. Little, P. E. McSharry, S. J. Roberts, D. A. Costello, and I. M. Moroz, “Exploiting nonlinear recurrence and fractal scaling properties for voice disorder detection,” *BioMedical Engineering OnLine*, vol. 6, no. 1, p. 23, 2007, introduced nonlinear dynamic features for voice analysis.
- [13] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [14] H. Jaeger, D. Trivedi, and M. Stadtschnitzer, “MDVR-KCL: Mobile device voice recordings at King’s College London,” 2019, collected 26–29 September 2017 at King’s College Hospital, London, UK. [Online]. Available: <https://zenodo.org/records/2867215>
- [15] D. Biswas, “Parkinson’s disease speech signal features,” 2020, originally from UCI Machine Learning Repository. [Online]. Available: <https://www.kaggle.com/datasets/dipayanbiswas/parkinsons-disease-speech-signal-features>
- [16] C. M. Bishop, *Pattern recognition and machine learning*. Springer, 2006.
- [17] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [18] N. Sáenz-Lechón, J. Godino-Llorente, V. Osma-Ruiz, and P. Gómez-Vilda, “Methodological issues in the development of automatic systems for voice pathology detection,” *Biomedical Signal Processing and Control*, vol. 1, no. 2, pp. 120–128, 2006, systematic review of methodological issues in voice pathology detection.
- [19] G. Solana-Lavalle and R. Rosas-Romero, “Analysis of voice as an assisting tool for detection of Parkinson’s disease and its subsequent clinical interpretation,” *Biomedical Signal Processing and Control*, vol. 66, p. 102415, 2021.
- [20] B. McFee, C. Raffel, D. Liang, D. P. Ellis, M. McVicar, E. Battenberg, and O. Nieto, “librosa: Audio and music signal analysis in python,” Software, 2015. [Online]. Available: <https://librosa.org>

- [21] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [22] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 785–794.